# Capítol 1: Introducció i Marc Teòric

## 1.1 Introducció i Justificació de la Investigació

La recerca fonamental en l'àmbit de la Intel·ligència Artificial (IA) i la Ciència de Dades ha utilitzat històricament els entorns lúdics i els jocs d'estratègia com a bancs de proves primordials per avaluar, quantificar i expandir les capacitats cognitives, de planificació a llarg termini i de presa de decisions dels sistemes computacionals.[1] Des dels albors de la informàtica, amb l'aparició dels primers algorismes capaços de resoldre jocs matemàtics simples com el Nim l'any 1941, fins a les fites històriques i mediàtiques assolides en els Escacs amb Deep Blue i en el Go amb AlphaGo, l'evolució estructural i algorísmica de la IA ha estat intrínsecament lligada a la complexitat creixent dels entorns de simulació.[1] Aquests dominis proporcionen un marc objectiu, mesurable i controlat on l'eficiència de noves arquitectures de xarxes neuronals pot ser avaluada sistemàticament. Tot i això, la immensa majoria d'aquests èxits fundacionals s'han produït en entorns d'informació perfecta i de naturalesa determinista, on ambdós jugadors tenen accés absolut i ininterromput a la totalitat de l'estat del joc en qualsevol moment donat.[2]

A mesura que el camp científic ha madurat, l'interès de la comunitat investigadora s'ha desplaçat inexorablement cap a entorns virtuals que emulen amb major fidelitat la naturalesa caòtica i fragmentada del món real: sistemes caracteritzats per la informació imperfecta, l'alta estocasticitat i la imperiosa necessitat de presa de decisions simultànies sota pressió i incertesa.[4] En aquest context de transició paradigmàtica, el present Treball de Final de Màster (TFM) se centra en el disseny, entrenament i avaluació d'un sistema avançat, titulat formalment: "Desenvolupament d'un agent de Deep Reinforcement Learning per a la presa de decisions estratègiques en entorns estocàstics d'informació imperfecta: El cas de Pokémon VGC".

La justificació per a l'elecció d'aquest subjecte d'estudi rau en el fet que el format competitiu de Pokémon, específicament el Video Game Championships (VGC), transcendeix la seva aparença de franquícia d'entreteniment per revelar-se com un dels problemes de resolució matemàtica i algorísmica més formidables en l'àmbit de la IA contemporània.[4] No es tracta simplement d'un joc d'estratègia per torns, sinó d'un ecosistema altament estocàstic on la informació oculta (atributs invisibles, objectes equipats, conjunts de moviments no revelats), la combinatòria massiva d'estats —estimada en més de $10^{100}$ configuracions possibles— i les decisions preses sota condicions d'incertesa constant conformen un repte superlatiu per a l'enginyeria de dades.[6] La finalitat última de l'agent a desenvolupar no és executar accions basades en arbres de decisió o regles heurístiques predefinides, sinó aprendre una política òptima generalitzable que maximitzi l'esperança matemàtica de victòria, mitigant l'impacte de l'atzar sistèmic i deduint la informació no revelada per l'oponent a través de l'experiència.[5]

Aquest primer capítol estableix els fonaments teòrics absolutament necessaris que emparen la investigació. A continuació, es defineix l'evolució històrica i el context de la IA en els jocs, es

formalitza el problema matemàtic subjacent a través de la lent estricta dels Processos de Decisió de Màrkov Parcialment Observables (POMDP), s'analitza l'estocasticitat inherent i les variables del subjecte d'estudi, i es detallen les arquitectures d'aprenentatge per reforç profund i les tècniques de representació matricial de dades necessàries per traduir la inabastable complexitat de l'entorn en un model computable i optimitzable d'aprenentatge automàtic.

## 1.2 Evolució de la Intel·ligència Artificial en Entorns Lúdics: De la Informació Perfecta a la Imperfecta

Per comprendre la magnitud del repte que suposa Pokémon VGC, és imprescindible contextualitzar l'evolució dels algorismes de resolució en la teoria de jocs clàssica i moderna. Els pioners de la intel·ligència artificial, incloent-hi figures com Herbert Simon, Alan Newell i John McCarthy, van abordar l'estudi de la cognició artificial primant habilitats cerebrals relacionades amb la lògica matemàtica i la resolució de problemes seqüencials.[2] Aquesta visió epistemològica va afavorir la creació de programes basats en la cerca heurística i l'avaluació de símbols físics, el que eventualment va desembocar en l'ús massiu d'arbres de decisió per al control de comportaments no jugables (NPCs) en aplicacions interactives primerenques.[1] Aquests mètodes d'escriptura de guions (*scripting*), si bé eren computacionalment econòmics, presentaven una gran rigidesa, resultant freqüentment en patrons repetitius i en la incapacitat d'adaptació davant situacions no previstes explícitament pels desenvolupadors durant el temps de programació.[1]

La dicotomia estructural més rellevant en el disseny d'agents autònoms per a jocs es troba en la naturalesa i la disponibilitat de la informació. Històricament, el focus s'ha centrat en jocs d'**informació perfecta**, dels quals els Escacs i el Go en són els paradigmes indiscutibles. En aquests dominis teòrics, l'estat complet i absolut de l'entorn és completament observable per a tots els participants al llarg de tota la partida.[2] No hi ha informació asimètrica, variables ocultes ni incertesa sobre l'estat actual del tauler; addicionalment, són sistemes deterministes, on l'execució d'una acció en un estat concret transita inequívocament cap a un únic estat subsegüent previsible.[2] L'èxit d'algorismes com el Minimax o la poda Alfa-Beta en aquests entorns va dependre de funcions d'avaluació precises i del creixement exponencial de la potència de càlcul (força bruta) per explorar branques futures.[2]

No obstant això, quan s'introdueix la **informació imperfecta** i l'**estocasticitat**, les metodologies esmentades col·lapsen computacionalment i estratègicament.[7] Jocs complexos moderns i simulacions d'estratègia competitiva representen dominis on parts crítiques de l'estat del joc romanen deliberadament ocultes per als jugadors.[5] En aquests entorns, la manca de coneixement sobre les intencions, capacitats i recursos de l'adversari (com ara els moviments seleccionats o els atributs estadístics d'una criatura) impossibilita la construcció d'un arbre de cerca determinista i exhaustiu.[6] Qualsevol simulació heurística sobre l'impacte futur d'una decisió està supeditada a centenars d'hipòtesis paral·leles sobre quin és l'estat real i

vertader del joc.[7]

L'evolució cap a entorns estocàstics d'informació asimètrica ha requerit, per tant, un canvi de paradigma fonamental. En lloc de calcular rutes fixes, la investigació ha migrat cap al *Reinforcement Learning* (RL) o Aprenentatge per Reforç, on els agents aprenen a partir de l'experiència directa mitjançant el mètode d'assaig i error interagint massivament amb el seu entorn.[3] Ja a l'any 1996, experiments amb xarxes neuronals artificials en el videojoc de vida artificial *Creatures* van demostrar que el processament d'entrades de l'entorn (com el perill o la gana) a través de capes ocultes permetia l'aprenentatge de respostes adaptatives dinàmiques que les heurístiques no podien replicar.[9] En l'actualitat, la integració de l'aprenentatge profund (*Deep Learning*) amb el RL, originant el *Deep Reinforcement Learning* (DRL), constitueix l'estat de l'art absolut. Les xarxes neuronals profundes permeten als agents comprendre i generalitzar patrons a partir de milions d'interaccions autònomes (joc autònom o *self-play*), aproximant funcions de valor i polítiques complexes que superen les limitacions de la cerca exhaustiva en dominis de dimensionalitat intractable.[3]

## 1.3 Formalització Matemàtica del Problema: Processos de Decisió de Màrkov Parcialment Observables (POMDP)

Per abordar amb rigor acadèmic i matemàtic la construcció d'un agent intel·ligent capaç de navegar, sobreviure i prosperar en aquest entorn asimètric, és imperatiu definir l'ecosistema sencer mitjançant el formalisme d'un Procés de Decisió de Màrkov Parcialment Observable (POMDP).[10] Un POMDP representa l'extensió natural i la generalització directa d'un Procés de Decisió de Màrkov (MDP) convencional, dissenyada específicament per modelar seqüències de decisió sota la influència de dues capes d'incertesa severa: l'estocasticitat en l'efecte de les accions (incertesa de transició) i l'observabilitat parcial de l'estat real del sistema (incertesa de percepció).[12]

Aquest model conceptual, definit originalment a la dècada de 1960 per a la investigació d'operacions i posteriorment introduït a la intel·ligència artificial durant la dècada de 1990, proporciona l'estructura matemàtica per formular objectius a llarg termini i deduir polítiques d'actuació.[13] Formalment, un POMDP en temps discret es descriu com una tupla de vuit elements, representada per l'expressió matemàtica $(S, A, T, R, \Omega, O, \gamma, b_0)$ .[10] La definició detallada de cadascun d'aquests paràmetres, i la seva translació empírica directa a l'entorn competitiu objecte d'aquest estudi, es detallen a continuació:

| Element | Representació | Descripció Teòrica i Aplicació a l'Entorn d'Estudi |
|---|---|---|

| POMDP | Matemàtica | (Pokémon VGC) |
|---|---|---|
| **Espai d'Estats** | $S$ | Un conjunt finit, encara que astronòmicament gran, d'estats que representen totes les configuracions teòricament possibles de l'entorn. En l'ecosistema en qüestió, un estat $s \in S$ inclou no només els elements visibles (Punts de Salut restants, climes actius), sinó la totalitat de la veritat oculta: valors d'esforç (EVs), valors individuals (IVs), habilitats passives no revelades, objectes equipats ocults i moviments no utilitzats dels dotze integrants presents en la partida.[6] L'estat engloba més de $10^{100}$ permutacions.[6] |
| **Espai d'Accions** | $A$ | Un conjunt finit d'accions discretes o contínues disponibles per a l'agent en qualsevol moment $t$. En la praxi del simulador, això correspon al conjunt de decisions permeses per la interfície en cada torn: utilitzar un moviment específic, fixar l'objectiu de l'atac en una casella particular de les quatre disponibles, o invocar un intercanvi amb una de les criatures de la reserva.[12] |
| **Model de Transició** | $T$ | Una funció de probabilitat o distribució $T(s, a, s') = P(s' \mid$ que defineix la dinàmica mecànica del sistema.[12] Representa la probabilitat de transitar cap a l'estat futur $s'$ si s'executa l'acció $a$ partint de l'estat actual $s$. Atès que el joc inclou elements aleatoris massius com percentatges d'encert, fluctuacions de dany aleatòries i probabilitats d'efectes d'estat (congelació, cremada), l'estat resultant mai és determinista, sinó probabilístic.[6] |
| **Funció de Recompensa** | $R$ | Una funció $R(s, a$ que atorga un valor numèric immediat (reforç positiu o negatiu) a l'agent per haver executat l'acció $a$ en l'estat $s$.[10] Aquest |

| | | |
|---|---|---|
| | | senyal escalar s'utilitza durant l'optimització per indicar a l'agent si el seu comportament és adequat. Habitualment s'estructura al voltant de la diferència de percentatge de punts de salut, la incapacitació de les unitats oponents o la victòria final de l'episodi.[15] |
| **Espai d'Observacions** | $\Omega$ | Un conjunt finit d'observacions possibles. És la fracció de l'estat real que la interfície del joc permet veure a l'agent (el "punt de vista en primera persona").[10] Això inclou exclusivament la informació que ha estat explícitament revelada durant el transcurs dels torns i els paràmetres numèrics propis.[14] |
| **Model d'Observació** | $O$ | Una funció $O(o, s', a) = P(o \mid$ que defineix rigorosament la probabilitat que l'agent rebi l'observació $o \in$ just després d'executar l'acció $a$ i de produir-se la transició cap a l'estat subjacent $s'$.[10] Modela els errors de percepció o l'ocultació deliberada de dades pel sistema.[12] |
| **Factor de Descompte** | $\gamma$ | Un escalar continu on $\gamma \in |

La característica definitòria i el desafiament principal d'operar en un model POMDP recau en el fet que l'agent absolutament mai coneix amb total i indiscutible certesa en quin estat $s \in S$ es troba realment. El sistema no proporciona aquesta informació per disseny. Per compensar aquesta carència d'observabilitat directa, l'agent es veu obligat a mantenir una distribució de probabilitat contínua sobre tot l'espai d'estats possibles, una abstracció teòrica que es denomina estat de creença o *belief state* $b(s)$.[11] El *belief state* actua com una memòria probabilística acumulativa de tot l'historial del combat.

A cada increment del temps $t$ (cada torn del joc), quan l'agent executa una acció particular $a$ i subseqüentment rep una observació $o$ de l'entorn virtual, el seu *belief state* s'ha d'actualitzar invariablement aplicant el rigor del Teorema de Bayes i les lleis de probabilitat total. Aquesta complexitat matemàtica inherent fa que la resolució analítica exacta d'un POMDP en entorns d'alta dimensionalitat sigui un problema generalment indecidible o, en el millor dels casos,

computacionalment inabastable (P-SPACE hard).[11] Aquest obstacle metodològic fonamental és precisament el motiu pel qual les investigacions contemporànies, incloent-hi el present projecte, utilitzen xarxes neuronals profundes com a aproximadors de funcions no lineals; no busquen resoldre analíticament el POMDP, sinó aproximar una política d'actuació òptima $\pi^*$ mapejant llargues seqüències d'històrics d'observacions directament cap a distribucions probables d'accions.[8]

## 1.4 El Subjecte d'Estudi: Pokémon VGC des de l'Òptica de la Teoria de Jocs

Encara que dins del discurs públic Pokémon sigui concebut predominantment com una franquícia d'entreteniment lúdic, des de l'òptica estricta de les matemàtiques aplicades i la informàtica teòrica, el seu format de torneig oficial competitiu (Video Game Championships o VGC) s'estructura i es defineix formalment com un Joc Estocàstic Parcialment Observable de Suma Zero entre Dos Jugadors (POSG per les seves sigles en anglès).[4] La seva profunditat estratègica, la combinatòria immensa del seu ecosistema d'equips i la naturalesa simultània del seu sistema de decisions el converteixen en un subjecte d'estudi teòric i empíric de primera magnitud per a investigadors.[4]

Per tal d'habilitar experiments científics controlables, asíncrons i repetibles a gran escala, la comunitat acadèmica utilitza Pokémon Showdown com a infraestructura i simulador central d'interacció.[14] Pokémon Showdown és un simulador de batalla de codi obert i d'arquitectura client-servidor que replica amb una fidelitat algorísmica micromètrica totes i cadascuna de les regles internes de la franquícia oficial, actuant com el camp de proves definitiu que permet a agents autònoms operar, competir i recollir dades milers de vegades per segon sense les limitacions de les consoles físiques.[5]

### 1.4.1 La Dinàmica Multi-Agent i l'Estratègia de Dobles

L'ecosistema competitiu VGC divergeix dràsticament de les batalles individuals tradicionals en requerir un format exclusiu de "Dobles". En aquesta modalitat, cada jugador manté dos elements vius de manera simultània al camp de batalla de forma activa.[6] Des del punt de vista geomètric i de teoria de grafs, això significa que l'arbre de ramificació de l'espai d'accions en cada torn pateix una explosió combinatòria brutal.[4] Per cadascun dels dos Pokémon actius, l'agent ha de decidir no només quin moviment ofrenar entre el seu catàleg limitat a quatre habilitats (o l'alternativa estructural d'intercanviar la unitat per un membre sa situat a la rereguarda de la banqueta), sinó també determinar de manera explícita l'objectiu d'aquest atac.[6] Això inclou triar quin dels dos oponents atacar, i en casos estratègics altament específics i avançats, la possibilitat de seleccionar el mateix company com a objectiu per activar habilitats combinades.

Com que l'estructura del joc imposa una arquitectura d'**accions simultànies**, on tots dos

participants bloquegen les seves intencions sense que l'altre les conegui prèviament, l'entorn imposa reptes severíssims de no-estacionarietat.[4] Un jugador humà o un agent artificial no pot fonamentar l'èxit en una resposta reactiva post-observacional directa, sinó que ha de predir constantment les creences i el raonament de l'adversari mitjançant el modelatge de l'oponent ("Opponent Modeling"). Això porta l'escenari al territori de l'estudi matemàtic dels Equilibris de Nash.[20] En un escenari VGC on ambdós participants posseeixen informació incompleta, l'algorisme de resolució prova que poques vegades existeix una única acció determinista pura que resulti infal·lible. Ans al contrari, es demana l'adopció de sistemes estocàstics (estratègies mixtes) on l'agent assigna variables de probabilitat a diferents respostes vàlides per evitar convertir-se en un element previsible i, en conseqüència, explotable.[4]

Aquesta execució asincrònica introdueix un fenomen addicional ben conegut en els models d'aprenentatge multi-agent: el problema de l'assignació correcta de crèdit (*credit assignment problem*).[8] Si considerem un torn particular en què les dues unitats aliades ataquen coordinadament la mateixa criatura enemiga i aquesta acaba neutralitzada, però una de les meves unitats va utilitzar un moviment que va fallar per precisió o que resultava ser completament immune, la funció de recompensa global del torn percebrà un sumatori positiu. No obstant això, el sistema d'IA podria desenvolupar dificultats crítiques per discriminar retroactivament quina de les accions va ser la veritable generadora de valor i quina va ser supèrflua o subòptima, alentint dramàticament el procés general d'optimització de la política.[8]

### 1.4.2 El Desafiament de Selecció: "Bring 6 Pick 4" i la Fase de Team Preview

Si les interaccions descrites conformen el nucli de la tàctica a curt termini, la mecànica coneguda oficialment com a "Bring 6 Pick 4" (Portar sis, triar quatre) juntament amb la visió prèvia (*Team Preview*) representen el cim de la reflexió estratègica macro a llarg termini.[4] Segons el reglament, cada participant inscriu una llista oficial i tancada de sis integrants configurats. Però en el moment d'entaular combat, s'inicia una fase preliminar estrictament temporitzada on els jugadors assoleixen visibilitat general de la plantilla del rival (coneixent les identitats de les criatures, però ignorant les variants estadístiques o les eleccions d'objectes i moviments ofensius).[21] A partir d'aquesta observació inicial parcial, s'ha d'executar una elecció compromesa i irrevocable: escollir quatre membres per lluitar i estructurar l'ordre posicional determinant qui liderarà l'avantguarda (les posicions 1 i 2) i qui quedarà reservat a l'espera (les posicions 3 i 4).[23]

Aquesta condició crea un autèntic subjoc autònom de deducció abans que es processin els danys del primer torn, dissenyat específicament per posar a prova la cognició estratègica avançada i la capacitat de generalització d'una arquitectura neuronal.[4] D'acord amb els teoremes combinatoris bàsics de probabilitat sense reemplaçament, per una llista determinada de sis possibles membres de l'equip, escollint un sub-equip ordenat parcialment (on l'ordre intern de la parella inicial importa estratègicament pel control d'habilitats, però l'ordre de la

parella suplent és intercanviable fins a la seva crida al camp), la xifra de configuracions legals es pot extreure de la següent manera:

$$\binom{6}{2} \cdot \binom{4}{2} = \left(\frac{6!}{2!(6-2)!}\right) \cdot \left(\frac{4!}{2!(4-2)!}\right) = 15 \cdot 6 = \text{ 90 decisions per jugador}$$

Si un jugador pot presentar 90 formacions estructurades diferents, el creuament mutu en l'inici d'una partida eleva el volum total a $90 \times 90 = 8.100$ escenaris inicials d'obertura radicalment diferents.[4] Una elecció subòptima durant aquesta finestra de 90 segons resulta sovint irreversible.[23] Requereix una comprensió abstracta de sinergies, aplicant principis teòrics per endevinar la condició de victòria de l'oponent (*win condition*), reconèixer els nuclis defensius, anticipar possibles respostes disruptives, avaluar la dependència de control de velocitat (ex. el moviment *Tailwind* o l'habilitat *Trick Room*), i en última instància, modelar un mapa mental de com una composició interactua matemàticament contra una altra al llarg d'una simulació contínua de múltiples minuts.[21] Ensenyar aquesta competència abstracta d'identificació d'amenaces a llarg termini a un agent computacional suposa l'autèntic límit fronterer de la investigació actual en el subcamp de l'aprenentatge multi-agent, especialment tenint present que les conseqüències (les recompenses $R$) associades a l'esmentat *pick* no es manifesten clarament al sistema fins a les últimes escaramusses del combat.[4]

## 1.5 L'Estocasticitat, la Incertesa i la Dimensionalitat Inabastable de l'Espai d'Estats

Com s'ha introduït anteriorment, la principal raó que fa que Pokémon sobrepassi les metodologies tradicionals és el vertiginós creixement hiper-dimensional del seu espai d'estats subjacents i la implementació implacable del factor atzar.[6] L'enginyeria de l'entorn dicta una simfonia on vectors continus (com els punts de vida) col·lideixen amb modificadors probabilístics i regles de truncament matemàtic.[6] Podem disseccionar les variables principals en dos grans blocs estructurals que configuren el POMDP: les variables deterministes (que aporten profunditat) i les variables d'atzar pur (que injecten incertesa crítica).

### 1.5.1 L'Arquitectura de les Variables Deterministes i les Fórmules de Resolució

Dins de les directrius oficials competitives de Pokémon VGC, tots els elements participants passen per una funció d'escala normalitzadora cap al Nivell 50 i s'apliquen de manera intransigent la Clàusula d'Espècie (no duplicitat d'espècies en l'equip) i la Clàusula d'Objecte (no duplicitat d'eines equipables).[6] La fortalesa resistent, l'agilitat i l'amplitud destructiva provenen de diverses variables superposades:

**1. Matrius Multidimensionals de Tipus i Funcions d'Efectivitat:** L'eix vertebrador de l'equilibri

rau en un complex sistema de 18 categories o "tipus" elementals. Quan s'ordena una acció ofensiva, l'afinitat de tipus d'aquest atac es confronta matemàticament de forma individualitzada contra la composició de tipus del defensor (que pot incloure una designació primària i una designació secundària). Això produeix coeficients multiplicadors de dany constants predefinits [6]:

- Funció d'Immunitat Absoluta: El dany es modula per $0\times$.
- Funció de Resistència: El dany es penalitza negativament modulant-se per $0.5\times$ (o fins a $0.25\times$ en cas de dobles resistències creuades).
- Funció de Neutralitat: Aplicació de base inalterada del $1.0\times$.
- Funció de Vulnerabilitat (Súper Efectiu): Multiplicador geomètric exponencial del $2.0\times$ o fins i tot $4.0\times$.[6]

Addicionalment, actua un sumatori multiplicatiu fonamental conegut com a STAB (*Same Type Attack Bonus*). Si la natura inherent de la criatura emissora coincideix categòricament amb la del projectil llançat, la potència base sofreix un augment del $1.5\times$, podent-se maximitzar fins al $2.0\times$ quan l'entitat posseeix l'atribut passiu anomenat "Adaptability".[6]

**2. Formats Matemàtics de Càlcul d'Estadístiques i Atributs de Competició:** Més enllà de la representació gràfica de les espècies, el múscul real d'una criatura recau en variables escalars precises calculades mitjançant polinomis establerts. Els vectors ocults inclouen els Valors Individuals d'Atribut (IVs), fixats per naixement entre $0$ i $31$, i els Valors d'Esforç d'Atribut (EVs), distribuïbles per l'entrenador amb un màxim de $252$ punts per estadística.[6] La translació matemàtica d'aquests elements a l'interior del simulador en les condicions de Nivell 50 es regeix per funcions de part entera [6]:

Per determinar la capacitat màxima de Punts de Salut (HP), la funció imposada és:

$$HP = \left\lfloor \frac{(2 \times \text{Base} + IV + \lfloor \frac{EV}{4} \rfloor) \times 50}{100} \right\rfloor + 50 + 10$$

Per a la resta dels paràmetres de rendiment (com l'Atac Físic, la Defensa, l'Atac Especial, la Defensa Especial i l'Atribut de Velocitat), la fórmula altera les constants i inclou modificadors fraccionaris associats a la naturalesa intrínseca de l'ésser (augment o reducció del 10% de rendiment general):

$$Stat = \left\lfloor \left( \frac{(2 \times \text{Base} + IV + \lfloor \frac{EV}{4} \rfloor) \times 50}{100} + 5 \right) \times \text{Modificador Naturalesa} \right\rfloor$$

És capital i transcendent comprendre l'efecte devastador de les funcions de truncament contínues i iteratives ( $\lfloor x \rfloor$ ) presentades en la multiplicació pas a pas. En intel·ligència artificial, i concretament durant el càlcul retrospectiu (Backpropagation) típic de l'aprenentatge profund, les constants arrodonides cap a baix produeixen serioses discontinuïtats matemàtiques que fracturen els gradients, fet que suposa que tècniques clàssiques de derivació d'optimització local poden experimentar estancaments quan els paràmetres ocults s'apropen a les fronteres decimals d'inflexió.[6]

**3. La Dinàmica Condicional de l'Àmbit de Control Temporal i la Propagació en Àrea:** La infraestructura de prioritats constitueix el rellotge atòmic del motor d'esdeveniments. La seqüència on cada entitat fa efectiva la seva acció s'estableix de forma lineal prioritzant l'entitat amb el factor de Velocitat superior.[6] A diferència d'iteracions històriques antigues, les variants modernes de la franquícia recalculen de forma asíncrona en temps real els marcs de velocitat. Si es produeix un efecte anomenat "Tailwind" que multiplica de sobte per dos els paràmetres d'agilitat general per a l'equip o bé una "Trick Room" (que col·loca de manera subversiva les mètriques i inverteix tot l'ordre tradicional durant 5 torns complets), el torn immediat es bifurca amb una alteració absoluta de la cronologia establerta.[6]

En l'arquitectura exclusiva del mode dobles, destaca la regla omnipresent del descens de dany propagat. Aquelles interaccions orientades a penetrar en múltiples entitats oponents de forma conjunta i simultània —per exemple atacs sísmics o trencament rocós aeri— s'enfronten a un paràmetre reductor penalitzador de potència d'exactament el $75\%$ de la seva eficiència base inicial respecte si fossin atacs unitaris concrets.[6] Una política d'IA ha de comprendre aquesta diferenciació per evitar pèrdues massives de rendiment de les capacitats letals i jutjar constantment la compensació entre el dany de penetració focal o el de distribució estesa.

## 1.5.2 Capes de Pertorbació Aleatòria, Estocasticitat Pura i Condicionants Dissonants

No obstant això, la veritable complexitat computacional del model emana directament dels nodes controlats per l'atzar en temps d'execució.[4] Les transicions de l'ecosistema es veuen subjectes a processos distribuïts amb una gran variància estadísitca. A destacar:

- **Els multiplicadors crítics i la precisió imperfeta:** Certs atacs posseeixen percentatges d'exactitud basats en tirs RNG entre el $0.70$ i el $0.95$, implicant constants llançaments de probabilitat que poden esbiaixar radicalment un combat en qüestió de mil·lisegons.[4] Encara més desestabilitzador és el multiplicador de cop crític (històricament ajustat a proporcions de dany extra significatiu), un esdeveniment que esquiva, anul·la o ignora per

complet els escuts defensius numèrics prèviament aplicats pels agents mitjançant tàctiques de mitigació.[6]

- **Afeccions d'Estats Alterats No-Volàtils:** Aquest factor injecta un nou nivell dimensional i perllongat d'entropia al sistema. Les condicions que atenuen atributs específics (com una afecció parasitària de cremada que destrueix mecànicament el 50% exacte de l'algoritme de càlcul de dany d'atac físic actiu, limitant l'agent a un rendiment sub-òptim permanent, o una afecció de paralització, on no només l'agilitat es veu severament mutilada al 50%, sinó que a més afegeix i sobreposa una taxa autònoma d'impediment complet per l'execució d'accions en un terç dels intents) demanen que la xarxa d'actor-crític mantingui un context històric recurrent immens.[6]

Amb aquest escenari configurat teòricament, queda clar per què el subjecte d'estudi no és abordable a través de regles escrites per un teòric de manera exhaustiva. La convergència demanda dades.

# 1.6 Anàlisi de Variables i Enginyeria de Representació per a Models de Machine Learning

Per aconseguir que una xarxa neuronal profunda (DNN) entengui de manera analítica els fluxos descrits en un simulador com Showdown, és necessari aplicar metodologies d'enginyeria de característiques (*feature engineering*) que prenguin l'estat brut $s$ (una matriu heterogènia de conceptes en format de text, nombres i banderes lògiques variables) per transformar-lo i decodificar-lo en tensors matemàtics densos i continus.[14] Aquest subcapítol il·lustra tècnicament les rutes d'extracció de característiques predominants i els paràmetres d'integració necessaris en aquest tipus d'anàlisi investigativa.

## 1.6.1 L'Abstracció Paramètrica de l'Estat: One-Hot Encoding versus Estructures d'Embeddings

En el tractament inicial de la vasta dimensió d'informació categòrica present en els entorns estructurats de jocs com les habilitats passives o l'identificador dels propis moviments ofensius de cada agent i objectes, les aproximacions històriques primerenques han depès massivament de la implementació del *One-Hot Encoding*.[28]

Aquesta tècnica heurística preveu convertir qualsevol categoria disjunta en estructures de matriu de vector dispers on la profunditat de l'alineació depèn íntegrament de l'amplitud del diccionari global de categories úniques.[28] Seguint el paradigma d'aquesta definició, un element donat només posseeix una posició activa indicant el valor d'activació "1", mentre tota la longitud residual mostra zeros.[28] Amb un bestiari teòric compositiu superior a centenars de nodes (1000 entitats diverses) combinat amb més de 800 variacions de tipologia de cops d'actuació, la tècnica col·lapsa immediatament per l'explosió multiplicativa, generant un coll d'ampolla a

escala computacional anomenat "Cursa de Dimensionalitat" (Dimensionality Curse) per falta de context informacional dens necessari a l'inici d'arquitectures com Xarxes Neuronals Recurrents (RNN).[28] Un aspecte estructuralment crític del seu declivi es basa en la manca teòrica de correlació inter-semàntica. Dues categories aïllades es mantenen alienes: dins la topologia projectiva, un moviment "Placatge" te exactament el mateix estatus paral·lel geomètricament envers "Bomba Foc" que cap a una acció de recuperació de vitalitat.[30]

Ateses aquestes enormes i incapacitants restriccions avaluatives de rendiment, la metodologia implementada avui i prioritària per l'esquema d'aquest TFM és la implementació estructural de l'arquitectura d'**Embeddings** (o incrustacions denses).[15] Els mòduls d'Embedding projecten un gran vocabulari de caràcters categòrics en vectors de dimensions tancades, densos, continus i matemàticament modelables durant el desenvolupament.[28] A través del procediment analític del gradient iteratiu, les matrius capturen dinàmiques de dependència i relació topològica entre variables no quantificades, organitzant característiques amb semàntiques anàlogues a zones pròximes entre si dintre de plans i volums.[28] Un pes neuronal adaptat dins dels Embeddings escurçaria dràsticament la relació directa entre una informació teòrica purament descriptiva, atorgant respostes tàctiques fluides pel motor d'aprenentatge del software central.[15]

### 1.6.2 Arquitectura d'Integració i Funcions de Recompensa: La Llibreria Poke-env

El desenvolupament experimental en simulacions autònomes a gran escala descansa en la integració tàcita del marc *Gymnasium* d'OpenAI utilitzant un mòdul intercessor altament optimitzat escrit en Python, identificat sota el repositori poke-env.[15] Aquest paquet d'anàlisi orquestra un flux actiu de paquets de dades a temps real establint un teixit asíncron de doble via capaç de rebre i enviar estats directament del core computacional i motor intern de Pokémon Showdown a qualsevol script compatible d'RL, assolint taxes de flux per milers d'iteracions síncrones intervingudes.[5]

Sota els estàndards rectors de la interfície de *Gymnasium* configurats dins l'ecosistema poke-env, l'**espai d'observació de l'agent** requereix definicions de codificació matricial tancades i concretes.[15] Exemple d'això resulta el prototipatge típic emprat a la documentació base de l'arquitectura, on es propaga un vector de 10 components que encapsula fraccions abstractes prenormalitzades, com ara l'escalament numèric descendent del valor de força mètrica de l'ofensiva (dividint la força bruta d'actuació per exponents base per afavorir les ponderacions lineals capes internes tipus $\frac{1}{100}$), junt amb el monitoratge de valors de supervivents globals al llarg de l'execució en intervals tancats que ponderen estats crítics de components propis versus enemics aliats disponibles.[15] Més enllà d'aquestes funcions simplificades teòriques, l'arquitectura de l'estat de l'art (com la del conegut motor *Metamon*, basat completament en Transformers autònoms) utilitza combinacions d'entrades híbrides amb 87 cadenes d'instrucció semàntiques (*tokens* text) aglutinant indicadors ocults (formats de xoc, alteracions asimètriques en la via de memòria) emparellats amb una col·lecció de 48

indicadors purament continus del simulador.[14]

D'altra banda, una faceta indispensable on l'enginyeria interactua directament amb l'optimització local és l'establiment meticulós d'allò conegut com el senyal de retroalimentació de valor (*reward shaping* o funció del factor $R$).[5] Poke-env proporciona estructures de codi (*reward computing helper functions*) modelades de tal manera que l'aprenentatge es fragmenta gradualment, desincentivant moviments buits i castigant conductes ineficients.[15] Segons marcs documentals verificables empíricament, una funció escalar de recompenses típica dissenyada per batalles d'alta tensió pot modelar els incentius amb fraccions marginals de variables quantitatives, premiant els miniguanys tàctics (bonificant amb punts derivats segons l'HP% perdut per una unitat rival colpejada) així com atorgant grans xocs d'ajustament al debilitar integralment una de les fitxes adverses (per exemple amb un atorgament del factor +2) i llançant les condicions de terme amb grans senyals per al càlcul iterat en aconseguir i concloure amb èxit les victòries absolutes (factor +30 en triomf, penalització diametral asimètrica de menys 30 amb desfeta).[15] Aquests vectors intermèdios modelats esdevenen claus essencials per evitar col·lapses i comportaments d'evasió còmics on els bots perden continuament contra variables de cost excessivament restrictives.[35]

## 1.7 Fonaments Algorísmics de Formació: L'Adveniment del Deep Reinforcement Learning en Competició Autònoma

L'abordatge i obtenció històrica d'agents informàtics competents pel subjecte descrit revela una ràpida obsolescència en paral·lel de models computacionals tradicionals a mesura que les exigències no han parat d'elevar-se amb el pas de les iteracions i l'augment logarítmic de l'escala dels equips a processar.[27] Els estudis de literatura tècnica acadèmica, publicats entre els diferents períodes del repte a la *Showdown AI Competition*, assenyalen una dinàmica inicial amb programari basat fonamentalment en models fixos.[8] Aquestes aproximacions rudimentàries basaven els fonaments analítics en estructures d'arquitectura explícita dissenyades exclusivament per desenvolupadors a partir del modelat del sentit comú empíric humà i regles pre-calculades.[8] En la següent etapa històrica, la comunitat algorísmica migrà a models de recerca deductiva complexos, com el clàssic algorisme d'entramat Minimax i les variants híbrides Expectimax, les quals projectaven iterativament estructures cap al futur immediat intentant predir estadísticament la continuació probabilística on es trobaria les condicions de les derivacions teòriques trencadores i assumir opcions que suposadament portarien menys riscos (garantia de subsistència defensiva i minimització).[8] Avui, però, tot aquest context clàssic de càlcul retrocedeix davant de les metodologies modernes recolzades fonamentalment en l'arquitectura i aplicació estructural sobre xarxes complexes (*Deep Learning*), un fet acreditat de la recerca recent amb models empírics lliures de models apriorístics (com la incorporació estesa d'intel·ligència artificial massiva autogenerativa del

segment dels Grans Models de Llenguatge *LLM* per emular seleccions).[4]

Les metodologies hegemòniques per entrenar xarxes profundes que dedueixin una política estratègica eficient es distingeixen històricament en dues subfamílies cardinals del DRL d'alt nivell operatiu emprades extensament per estudis recents orientats al fenomen Pokemon.[16] Aquestes conformen un segment principal sobre l'estructuració base que s'incorpora com a part del present TFM: **Deep Q-Network (DQN)** i l'algorisme de la família actor-crític **Proximal Policy Optimization (PPO)**.[16]

### 1.7.1 Tècniques Basades en Valors Abstractes: La Metodologia Deep Q-Network (DQN)

L'arquitectura DQN, coneguda tècnicament en el sector acadèmic com a base dels aprenentatges d'origen *Value-Based* pel fet que pretén assolir directament i avaluar la puntuació contínua i numèrica per qualsevol moviment aplicable respecte a l'observació d'estat latent de les dades del tauler, és àmpliament reconeguda pel seu potencial inicial de capacitat teòrica tractant i modificant dades històriques sense fi dins de formats de xoc discrets.[16] En els sistemes VGC, l'execució per cadascun dels membres del camp equival només a decidir una branca discreta limitada per selecció directa dins l'extensió variable de $\approx 4$ atacs equipables o alternatives d'escuts operacionals per intercanvi.[14]

Aquesta maquinària algorísmica fonamental fa ús intern d'iteracions sota estructures formals derivades per l'equació de Bellman per calcular de forma continuada, ajustant dinàmicament cada pes a l'avaluació que rep per les diferències observades (Temporal Difference). El seu triomf respecte de les estructures tabulades, que es destrossaven front els volums astronòmics del *Team Preview* de selecció múltiple o les funcions estadístiques continuades de probabilitat paral·lela, prové especialment del component d'experiència mnemotècnica o del retrovisor (*Experience Replay*).[16] Els agents basats en DQN utilitzen memòries emmagatzemades d'assaig amb milers de línies transaccionals aleatoritzades de mostres separades totalment del temps cronològic de manera asíncrona per forjar i corregir una estimació predictiva sense decaure ràpidament i assegurant l'anomenada eficiència de components (*Sample Efficiency*).[16]

Malgrat la seva introducció relativament prolífica per ser una aproximació més ràpida d'èxit en primeres estructures i asseure's a un llistó molt superior respecte de bots programats per selecció d'accions atzaroses purs o heurístiques ingènues d'alt dany continu basades només a triar valors purs [18], experiments realitzats per analitzar comportaments més subtils en models i espais amb fluctuacions on les dades s'esvaeixen i muten profundament d'acció contínua adverteixen sovint deficiències. A l'ecosistema de Pokemon i especialment els VGC simultanis, aquest sistema falla moltes vegades en estabilitzar la seva funció per problemes estructurals inherents a la no-estacionarietat d'enfrontaments dinàmics (On allò que abans produïa guany constant de valoració ara produeix un gran càstig atesa l'alteració psicològica en les respostes

de decisió que l'oponent incorpora d'amagatotis per no esdevenir explotat constantment, generant fenòmens de pèrdua i descalibratge teòric als vectors per la subestimació de valors).[8]

### 1.7.2 Tècniques pel Gradient de Política Estocàstica (Policy Gradients) i Sistemes Actor-Crític (PPO)

Atesa l'extensió de la inestabilitat trobada com a llindar en les equacions pures d'avaluació al límit, els assoliments bibliogràfics acadèmics definitius i contemporanis del sector evidencien de forma concloent el predomini sistemàtic de metodologies procedents de xarxes duals híbrides, tals com el *Proximal Policy Optimization* (PPO) d'OpenAI, basats directament en ajustament paral·lel d'estocasticitat sobre probabilitats d'aprenentatge del mateix acte físic d'executar variables, més enllà del simple retorn numèric.[4]

L'arquitectura central que acompanya la immensa eficàcia demostrada d'aquests sistemes rau en el paradigma iteratiu **Actor-Crític**.[4] Dins de les ramificacions de xarxes alimentades amb milions de cicles computacionals en xocs paral·lels:

- L'estructura del model identificat com a **Actor** actua generant direccions empíriques en una matriu probabilística de tendències.[14] L'actor emet a cada pas de selecció i presa de decisió les diferents taxes fraccionaries amb valors d'acció o vectors operatius.[14] En permetre resultats en valors i probabilitats contínues per qualsevol distribució potencial i d'intencionalitat, la màquina s'ajusta empíricament cap a l'objectiu estipulat al disseny per als models basats a solucionar conflictes per aplicació i cerca estricta en jocs d'estratègia del mètode d'equilibris asimètrics o Equilibri de Nash.[16]
- D'altra part actuant com un jutge integrat al cor temporal del cicle operatiu de retro-càlcul paral·lel trobem el **Crític**, focalitzant operativament exclusivament funcions d'estimació empírica de l'anomenat avantatge comparatiu (*Advantage Function*). Compara si les expectatives creades inicialment es corresponen a les taxes finals.[14]

La natura asimètrica de les polítiques iteratives derivades de tècniques model PPO ha esdevingut pilar fonamental doncs incorporen la funció restrictiva teòrica de subrogació tallada (Clipped Surrogate Objective), un artefacte de càlcul intern d'estabilització matemàtica capaç de blocar canvis violents dins el procés continu de reestructuració localitzada post-torn.[16] Tot i demanar immensament més taxes d'experimentació continuada per observar una convergència òptima d'accions, agents elaborats sota aquestes especificacions permeten operacions més fines que eviten sobrecàrregues desastroses pel sistema de gradients propis.[4] Aplicacions avançades de referència internacional sobre aprenentatge fora de línia d'alta escala combinat amb mètodes Transformer asíncrons de 200 milions de paràmetres, com s'ha posat en consideració al protocol d'evolució estructural "Metamon", utilitzen components equivalents integrants d'acció-crític de gradient operatiu aconseguint, sense aplicació i implementació directa sobre cerca prèvia analítica del model explícit de l'entorn de jocs complexos, posicions dins del top 10% del rànquing d'escalada global integrat totalment per mestres en condicions anònimes de joc massiu competitiu en línia real, tot sent plenament capaç d'intervenir sobre

variables tancades inferint la totalitat formativa o de preparació estratègica a curt termini per efectes d'aplicació seqüencial (seqüències del vector llarg memorístic o LSTM i derivats basats en atenció).[14]

Per resumir l'àmplia divergència analítica s'adjunta la següent representació comparativa respecte al procediment operacional intern dels dominis sobre aquest marc del TFM:

| **Paràmetres Operacionals Constants** | **Model Predictiu: Deep Q-Network (DQN)** | **Model Híbrid Estocàstic: Proximal Policy Optimization (PPO)** | **Transcendència Metodològica pel Desenvolupament en Simulacions (VGC)** |
|---|---|---|---|
| **Arquitectura Algorísmica** | Fonaments clàssics iteratius de convergència basada purament en optimització contínua general i del valor de retorn teòric (*Q-Values*). | Basat fonamentalment al paradigma continu per l'avaluació en el teixit Actor-Crític recolzat en actualitzacions graduals de gradients. | La distribució continuada possibilita un modelatge eficaç dels equilibris i atzars per a seleccions de probabilitat.[14] |
| **Resiliència contra Volatilitat** | Presenta deficiències de robustesa severes pel bootstrap, l'esvaïment de regles tàctiques en entorns mutables (No-estacionari). | Propietats extremadament resilients i blindades via models avançats d'amortització algorísmica local. | PPO absorbeix i reacciona sòlidament envers comportaments imprevisibles procedents dels llançaments d'aleatorització a temps real o alteració massiva com les taxes de "Cops Crítics" propis i interns.[6] |
| **Modelatge Temporal d'Eficiència** | Reutilització sistèmica forçada d'interaccions temporals | Procediment natural basat i estipulat en actualitzacions dinàmiques del | PPO sol demostrar nivells de retenció superior si es recolza i |

| | | | |
|---|---|---|---|
| | mitjançant conjunts massius separats (*Experience Replay* de caràcter *Off-Policy*). | component present de traçat iteratiu cronològic de càlcul d'avantatge (*On-Policy*). | suplementa amb mètodes complexos de mecanisme causal per entendre tàctiques sacrificables o de retardament continu d'impacte llarg (condicionals d'estat com Toxines acumulables o retencions ambientals de Terrenys alterables).[6] |

## 1.8 Justificació Tecnològica, Aplicació Sectorial i Objectius Clau de Desenvolupament en Dades Autònomes

La rigorosa implementació paramètrica per al tractament d'optimització, creació, interconnexió, operació computacional de la informació asimètrica i resolució tàctica definitiva d'agents dinàmics altament capaços fonamentats de ple sobre arquitectures híbrides del *Deep Reinforcement Learning* dintre d'un entorn restrictiu, fragmentat i fosc i estocàstic imposat pel format de campionats interactius de Pokemon VGC encapsula de ple un repte computacional que manté unes ramificacions paral·leles d'interès global.[4] Tals resultats obtinguts per a la matèria transcendiran d'una aplicabilitat d'evolució analítica confinada absolutament dins les limitacions de qualsevol pur repte de simulació sectorial associat lúdica competitiva orientada a l'interès digital per projectar-se de base per a models de predicció empírica.[3]

Exposar que aquest determinat programari de base és realment operatiu, generalitzant deduccions paramètriques per la captura passiva de tendències estructurals de canvi d'equips rivals i inferir de ple models autònoms paral·lels de tàctica contínua front contrincants asíncrons dins la multiplicitat caòtica estocàstica del present o l'omissió temporal on actuen els nodes sense transparència —un camp i espai topològic on l'abstracció matemàtica i l'escala dels esdeveniments pseudoaleatoris per processos i les cascada massiva implacable de variables (milers de modificacions basades amb condicions truncades internes no accessibles) xoquen constantment— significa verificar de ple protocols intel·ligents per a dominis que es podrien transportar directament.[4] Les solucions i tractaments matemàtics que modelen aquest projecte particularment en la generació abstracta o aproximada de model d'oponent mantenen

relacions formals absolutes paral·leles amb dominis crítics relacionats amb el risc real logístic, modelització teòrica de subhastes i anàlisis i respostes interactives contra l'amenaça oculta a la ciberseguretat on variables massives mutables romanen alienes als nostres propis canals interns d'anàlisi de sistemes dinàmics complexos no-estacionaris.[4]

La finalitat i la fita principal d'operació del prototip recau expressament a provar no de buscar un retorn pur exclusiu i aïllat sense variables paral·leles de cost sinó generar processos aïllats en optimització massiva on un programari capaç dedueixi de manera automàtica que l'acció amb retorn d'estalvi o increment de la salut immediata és realment irracional de fons d'acord amb la informació amagada (deduint el dany subjacent previst en el torn immediat per les ràtios analítiques ocultes de conjunts o equips *sets*) d'acord al component de maximització de probabilitats d'esperança teòrica en la consecució estratègica.[4]

Sota aquest estricte prisma fundacional global argumentatiu aportat per la present base prèvia introductòria dels fonaments bibliogràfics tecnològics establerts detalladament al llarg d'aquest present informe i revisió contínua de l'art estructural aplicat, s'han delimitat de manera programàtica i absolutament metòdica els següents blocs analítics concrets per vertebrar la validació resolutiva de caràcter oficial al TFM:

1. **Desenvolupament, Codificació Tècnica i Connexió Operativa d'Entorns de Simulació massius:** Produir l'establiment i blindatge intern d'una xarxa d'interconnexió robusta, fluida, segura per la creació de l'espai d'experimentació d'escala entre una aplicació i node remot a l'interior i els models del teixit base recolzats de manera prioritària amb estructures compatibles sobre els sistemes generals del paquet orientat poke-env amb l'ecosistema de l'arquitectura teòrica pròpia i l'aplicatiu integral de retroalimentació de valor estipulat i conformat global de *Gymnasium* garantitzant i mantenint constantment milers de connexions iteratives.
2. **Abstracció Analítica Paramètrica o Representació Estructural Complexa per Tensors:** Concebre amb tota garantia de procediments i optimitzacions d'experimentació directa algorítmica una configuració densa matricial de generació contínua de variables (*Feature Engineering*) via incrustacions semàntiques dimensionals tancades o generadores d'associació en continu d'informació de tipus *Embeddings* processant de forma unida i compacta el volum desproporcionat inherent en variables d'indicadors continus combinats (indicadors d'edat mecànica com l'eficiència a alteradors d'informació dels equips o STAB).
3. **Implementació Empírica Base dels Sistemes d'Enginyeria DRL:** Construir els components primaris estructurals amb l'aprenentatge necessari en l'assimilació paral·lela i capacitació estructural analítica general sobre mecanismes autònoms operacionals basats directament al camp de control iteratiu en les branques o tècniques i polítiques contínues Actor-Crític (sobre mètodes estocàstics robustos similars a PPO i derivades operants del sistema) convergint amb estabilitat al desenvolupament dels episodis controlats d'assaig automàtic basat per aprenentatge fora de línia o mitjançant simulacions estables contra agents alternatius procedurals del nucli mateix de generació auto referent (simulacions paral·leles generades i integrades sota *Self-Play* estricte

continu).

4. **Codificació Numèrica Abstracta i Tractament sobre els Espais Incrementals Estratègics Tancats o "Bring 6 Pick 4":** Cuantificar numèricament la base paramètrica deductiva, la convergència local i avaluar profundament empíricament quina correlació de dependència exerceix directament un agent informàtic davant de la fase abstracta limitadora de temps asimètric i del fenomen prèviament relatat de *Team Preview*, generant i dissenyant un sistema on els factors associatius combinatoris d'assignació puguin ser extrets durant els entrenaments previs sobre rutes obertes desvinculant el pes exclusiu atorgat habitualment a xarxes purament orientades només a accions de curt recorregut en el temps per deduir el risc i condició latent sense indicadors constants ni evidents de resposta d'assimilació analítica.
5. **Demostració del Retorn per Validació Absoluta Paramètrica i Empírica per a l'Esperança Global de Victòria:** Efectuar com a cloenda de l'assaig, simulació o experiment tècnic procedimental la verificació teòrica i asíncrona validada on aquest programari sota desenvolupament i estudi pot desenvolupar mètodes lògics, inferències d'agressió controlada abstracta racional en escalada superant el rendiment teòric previ basat i establert d'efectivitat a l'atzar d'una probabilitat d'una esperança establerta per taxa d'encert i ràtio genèric del $50\%$, verificant paral·lelament de ple una superior resiliència tàctica d'ordre sistèmic continuat si es testegen arquitectures enfront programacions construïdes íntegrament pel mecanisme bàsic arrelat en simples rutes deterministes algorísmiques pures en profunditat rígida d'escales derivades sota expectació purament heurística tradicional de deducció lineal de respostes estàtiques.

## Obras citadas


1. Artificial intelligence in video games - Wikipedia, fecha de acceso: febrero 25, 2026, https://en.wikipedia.org/wiki/Artificial_intelligence_in_video_games
2. AI and Play, Part 1: How Games Have Driven Two Schools of AI Research - CHM, fecha de acceso: febrero 25, 2026, https://computerhistory.org/blog/ai-and-play-part-1-how-games-have-driven-two-schools-of-ai-research/
3. The Role of Artificial Intelligence in Gaming - MDPI, fecha de acceso: febrero 25, 2026, https://www.mdpi.com/2076-3417/15/23/12358
4. VGC-Bench: Towards Mastering Diverse Team Strategies in Competitive Pokémon - arXiv, fecha de acceso: febrero 25, 2026, https://arxiv.org/html/2506.10326v3
5. Competitive Deep Reinforcement Learning over a Pokémon Battling Simulator, fecha de acceso: febrero 25, 2026, https://www.semanticscholar.org/paper/Competitive-Deep-Reinforcement-Learning-over-a-Sim%C3%B5es-Reis/65b691e8bbf21be59cb71a88de7e37dc30a58518
6. theory_corrected.md
7. A Self-Play Policy Optimization Approach to Battling Pokémon - IEEE CoG 2025, fecha de acceso: febrero 25, 2026,

http://ieee-cog.org/2019/papers/paper_175.pdf
8. VGC-Bench: A Benchmark for Generalizing Across Diverse Team Strategies in Competitive Pokémon - arXiv, fecha de acceso: febrero 25, 2026, https://arxiv.org/html/2506.10326v2
9. AI in video games: a historical evolution, from Search Trees to LLMs. Chapter 2: 1980–2000., fecha de acceso: febrero 25, 2026, https://medium.com/@jjmcarrascosa/ai-in-video-games-a-historical-evolution-from-search-trees-to-llms-chapter-2-1980-2000-341bc31860d9
10. Partially observable Markov decision process - Wikipedia, fecha de acceso: febrero 25, 2026, https://en.wikipedia.org/wiki/Partially_observable_Markov_decision_process
11. Revelations: A Decidable Class of POMDPs with Omega-Regular Objectives, fecha de acceso: febrero 25, 2026, https://ojs.aaai.org/index.php/AAAI/article/view/34845/37000
12. Partially Observable Markov Decision Process (POMDP) in AI - GeeksforGeeks, fecha de acceso: febrero 25, 2026, https://www.geeksforgeeks.org/artificial-intelligence/partially-observable-markov-decision-process-pomdp-in-ai/
13. Revelations: A Decidable Class of POMDPs with Omega-Regular Objectives - arXiv, fecha de acceso: febrero 25, 2026, https://arxiv.org/html/2412.12063v1
14. Human-Level Competitive Pokémon via Scalable Offline ... - RLJ, fecha de acceso: febrero 25, 2026, https://rlj.cs.umass.edu/2025/papers/RLJ_RLC_2025_340.pdf
15. Reinforcement learning with the Gymnasium wrapper — Poke-env ..., fecha de acceso: febrero 25, 2026, https://poke-env.readthedocs.io/en/stable/examples/rl_with_gymnasium_wrapper.html
16. (PDF) Comparative Study of Reinforcement Learning Performance Based on PPO and DQN Algorithms - ResearchGate, fecha de acceso: febrero 25, 2026, https://www.researchgate.net/publication/393613412_Comparative_Study_of_Reinforcement_Learning_Performance_Based_on_PPO_and_DQN_Algorithms
17. hsahovic/poke-env: A python interface for training Reinforcement Learning bots to battle on pokemon showdown - GitHub, fecha de acceso: febrero 25, 2026, https://github.com/hsahovic/poke-env
18. OAR@UM: Comparative performance analysis of AI algorithms in competitive Pokémon Showdown battles, fecha de acceso: febrero 25, 2026, https://www.um.edu.mt/library/oar/handle/123456789/115294
19. Competitive Deep Reinforcement Learning over a Pokémon Battling Simulator | Request PDF - ResearchGate, fecha de acceso: febrero 25, 2026, https://www.researchgate.net/publication/341497785_Competitive_Deep_Reinforcement_Learning_over_a_Pokemon_Battling_Simulator
20. Game Theory Approaches for Pokémon AI Battle Simulation | springerprofessional.de, fecha de acceso: febrero 25, 2026, https://www.springerprofessional.de/en/game-theory-approaches-for-pokemon-ai-battle-simulation/51238204
21. Team Preview - VGC guide, fecha de acceso: febrero 25, 2026,

https://www.vgcguide.com/team-preview
22. Question for VGC players: Do you like the "Bring 6, pick 4" rule? : r/stunfisk - Reddit, fecha de acceso: febrero 25, 2026, https://www.reddit.com/r/stunfisk/comments/125ranr/question_for_vgc_players_do_you_like_the_bring_6/
23. A Preview to Team Preview in VGC - Nugget Bridge, fecha de acceso: febrero 25, 2026, https://nuggetbridge.com/articles/a-preview-to-team-preview-in-vgc/
24. Open question: Do you like the "Bring 6, pick 4" rule? : r/VGC - Reddit, fecha de acceso: febrero 25, 2026, https://www.reddit.com/r/VGC/comments/125s3oj/open_question_do_you_like_the_bring_6_pick_4_rule/
25. Learn how to Win in Team Preview (Pokémon VGC Coaching) - YouTube, fecha de acceso: febrero 25, 2026, https://www.youtube.com/watch?v=6dbWN_lhdkY
26. What algorithm to use in completely randomized pokemon battles? : r/reinforcementlearning, fecha de acceso: febrero 25, 2026, https://www.reddit.com/r/reinforcementlearning/comments/1kozxq4/what_algorithm_to_use_in_completely_randomized/
27. Learning to Play Pokémon Showdown with Reinforcement Learning - CS230, fecha de acceso: febrero 25, 2026, https://cs230.stanford.edu/projects_fall_2018/reports/12447633.pdf
28. What is the difference between embeddings and one-hot encoding? - Milvus, fecha de acceso: febrero 25, 2026, https://milvus.io/ai-quick-reference/what-is-the-difference-between-embeddings-and-onehot-encoding
29. From Encodings to Embeddings | Towards Data Science, fecha de acceso: febrero 25, 2026, https://towardsdatascience.com/from-encodings-to-embeddings-5b59bceef094/
30. One Hot Encoding vs Embedding - Medium, fecha de acceso: febrero 25, 2026, https://medium.com/@heyamit10/one-hot-encoding-vs-embedding-ca8552f60f20
31. Why do char-level rnns use 1 hot encoding instead of embeddings? : r/MLQuestions - Reddit, fecha de acceso: febrero 25, 2026, https://www.reddit.com/r/MLQuestions/comments/6ux8si/why_do_charlevel_rnns_use_1_hot_encoding_instead/
32. One Hot Encoding vs Word Embedding - When to choose one or another?, fecha de acceso: febrero 25, 2026, https://datascience.stackexchange.com/questions/29851/one-hot-encoding-vs-word-embedding-when-to-choose-one-or-another
33. Poke-env: A Python Interface for Training Reinforcement Learning Pokémon Bots — Poke-env documentation, fecha de acceso: febrero 25, 2026, https://poke-env.readthedocs.io/
34. Examples — Poke-env documentation, fecha de acceso: febrero 25, 2026, https://poke-env.readthedocs.io/en/stable/examples/index.html
35. Pokémon Showdown with Reinforcement Learning | by Vivek Keval - Medium,

fecha de acceso: febrero 25, 2026, https://medium.com/@kevalvivek4/pok%C3%A9mon-showdown-with-reinforcement-learning-f5aad9a93cef
36. Learning complex games through self play ... - UPCommons, fecha de acceso: febrero 25, 2026, https://upcommons.upc.edu/bitstreams/f3815b36-f3cf-49c4-9053-07d96442f279/download
37. Large Language Models as Pokémon Battle Agents: Strategic Play and Content Generation, fecha de acceso: febrero 25, 2026, https://arxiv.org/html/2512.17308
38. Comparison of Artificial Intelligence Algorithms for Pokémon Battles - Chalmers ODR, fecha de acceso: febrero 25, 2026, https://odr.chalmers.se/bitstreams/b5fac289-1328-41b8-ad78-f89eb39fce30/download
39. Learning Competitive Pokemon through Neural Network and Reinforcement Learning - CS230, fecha de acceso: febrero 25, 2026, http://cs230.stanford.edu/projects_spring_2022/reports/127608668.pdf