

laSalle

UNIVERSITAT RAMON LLULL

Facultat Internacional de Comerç i Economia Digital La Salle

Treball de Final de Màster

Màster Universitari en Ciència de les Dades / Data Science

**Desenvolupament d'agents experts per a la
presa de decisions en entorns estocàstics i
d'informació imperfecta: El cas de Pokémon**

*Avaluació empírica comparativa d'heurístiques, cerca adver-
sària, MCTS, imitació i aprenentatge per reforç profund*

Alumne/a:

Gerard Pascual Fontanilles

Professor/a Ponent:

Jordi Peralta Dolz

Barcelona, Agost 2026

ACTA D'EXAMEN DEL TREBALL DE FINAL DE MÀSTER

Reunit el Tribunal qualificador en el dia de la data, l'alumne/a:

Gerard Pascual Fontanilles

Va exposar el seu Treball de Final de Màster, el qual va tractar sobre el tema següent:

Desenvolupament d'agents experts per a la presa de decisions en entorns estocàstics i d'informació imperfecta: El cas de Pokémon

Acabada l'exposició i contestades per part de l'alumne/a les objeccions formulades pels membres del tribunal, aquest va valorar l'esmentat Treball amb la qualificació de:

Qualificació Qualitativa	Qualificació Numèrica

Barcelona, a _____ de _____ de 2026

VOCAL DEL TRIBUNAL

VOCAL DEL TRIBUNAL

PRESIDENT DEL TRIBUNAL

Resum

Els videojocs d'estratègia complexos constitueixen un banc de proves exigent per a la recerca en Intel·ligència Artificial. En contrast amb jocs d'informació perfecta, els entorns amb informació parcial, accions simultànies i dinàmiques estocàstiques presenten reptes d'alta complexitat en predicció i planificació sota incertesa. Aquest Treball de Final de Màster desenvolupa i avalua de manera exhaustiva cinc paradigmes d'agents per a la presa de decisions en el format individual (`gen9randombattle`) del videojoc competitiu Pokémon, utilitzant el simulador de codi obert Pokémon Showdown i el marc d'integració *poke-env*.

El problema es formalitza com un Procés de Decisió de Markov Parcialment Observable (POMDP) amb accions simultànies, caracteritzat per un espai d'estats i accions combinatòriament dens i múltiples fonts d'incertesa (equips i moviments ocults, intenció de l'oponent i efectes aleatoris en el càlcul de dany). L'objectiu no és únicament aproximar una política que maximitzi la taxa de victòries sota pressupostos computacionals explícits, sinó també analitzar els patrons de comportament dels agents en situacions crítiques: la gestió del risc, la predicció de canvis (*switch prediction*), el control del ritme (*tempo*) i l'ús estratègic de la Teracristal·lització, avaluats mitjançant mètriques explicatives de decisió.

La proposta integra: (1) una seqüència estructurada de catorze agents heurístics (`v1-v14`) que incorporen incrementalment coneixement de domini (càlcul de dany, efectivitat de tipus, perills d'entrada, moviments de preparació, gestió d'estats alterats i Teracristal·lització); (2) variants de cerca adversària d'un torn (*minimax* `v15-v17`) amb funcions d'avaluació heurístiques a les fulles; (3) cerca en arbre de Monte Carlo rasa (*shallow* MCTS `v18-v20`) amb simulacions de cinc torns mitjançant un simulador local en memòria, comparant selecció UCB1 amb selecció PUCT guiada per priors heurístics; (4) models d'aprenentatge per imitació (`v21-v22`) basats en XGBoost entrenats sobre partides humanes d'alt nivell (Elo 1800+) per predir la decisió macro d'atacar o canviar; (5) un marc d'aprenentatge per reforç profund (*Deep Reinforcement Learning*, DRL; basat en *MaskablePPO*) amb espai d'accions emmascarat i inicialització per clonatge conductual (*Behavioral Cloning*); i (6) una infraestructura paral·lela i recuperable d'avaluació que instrumenta telemetria detallada per torn i càlcul de rànquings Bradley-Terry.

L'avaluació empírica comprèn una matriu competitiva de 28 agents (més de 6,4 milions de batalles), proves específiques de DRL i la integració exploratòria de models de llenguatge (LLM, com *PokéChamp* i *PokéLLMon*). Els resultats demostren que l'heurística experta (`v12`) lidera el rendiment global, superant el referent competitiu *Abyssal* amb una taxa de victòries del 59,9%. Així mateix, cap de les variants de cerca, d'imitació o de reforç profund aconsegueix superar el referent. L'anàlisi de telemetria revela que, en entorns amb informació parcial i alta estocasticitat, la cerca en profunditat es veu limitada per la incertesa de l'estat ocult del rival, mentre que els mètodes apresos necessiten incorporar coneixement de domini expert (com `v12`) per assolir un rendiment competitiu.

Paraules clau: Intel·ligència Artificial en jocs, presa de decisions sota incertesa, POMDP, agents heurístics, cerca adversària (Minimax), cerca en arbre de Monte Carlo (MCTS), aprenentatge per imitació (XGBoost), aprenentatge per reforç profund (MaskablePPO), models de llenguatge (LLM), telemetria, perills d'entrada (*hazards*), model Bradley-Terry.

Abstract

Complex strategy video games represent a demanding testbed for Artificial Intelligence research. In contrast to perfect-information games, environments characterized by partial information, simultaneous actions, and stochastic dynamics pose high-complexity challenges in prediction and planning under uncertainty. This Master’s Thesis develops and thoroughly evaluates five agent paradigms for decision-making in the singles format (`gen9randombattle`) of competitive Pokémon, utilizing the open-source simulator Pokémon Showdown and the *poke-env* integration framework.

The problem is formalized as a Partially Observable Markov Decision Process (POMDP) with simultaneous actions, characterized by a combinatorially dense state-action space and multiple sources of uncertainty (hidden teams and movepools, opponent intent, and random effects in damage calculation). The goal is not solely to approximate a win-rate-maximizing policy under explicit computational budgets, but also to analyze agent behavioral patterns in critical situations: risk management, switch prediction, tempo control, and the strategic usage of Terastallization, evaluated using explanatory decision telemetry.

The proposed work integrates: (1) a structured sequence of fourteen heuristic agents (`v1–v14`) that incrementally incorporate domain knowledge (damage calculation, type effectiveness, entry hazards, setup moves, status condition management, and Terastallization); (2) one-turn adversarial search variants (minimax `v15–v17`) with leaf heuristic evaluation functions; (3) shallow Monte Carlo Tree Search (shallow MCTS `v18–v20`) with 5-turn in-memory local simulations, comparing UCB1 selection with heuristic-prior-guided PUCT selection; (4) imitation learning models (`v21–v22`) based on XGBoost trained on high-level human replays (Elo 1800+) to predict macro-level decisions to attack or switch; (5) a Deep Reinforcement Learning (DRL) framework based on MaskablePPO featuring action masking and Behavioral Cloning initialization; and (6) a parallel and recoverable evaluation infrastructure instrumenting per-turn telemetry and Bradley-Terry ranking calculations.

Empirical evaluation comprises a competitive matrix of 28 agents (over 6.4 million battles), dedicated DRL experiments, and exploratory integration of Large Language Models (LLMs, such as *PokéChamp* and *PokéLLMon*). Results demonstrate that the expert heuristic (`v12`) leads overall performance, outperforming the competitive baseline *Abyssal* with a 59.9% win rate. Furthermore, none of the search, imitation, or deep reinforcement learning variants manage to surpass the baseline. Telemetry analysis reveals that, under partial observability and high stochasticity, deep tree search is constrained by uncertainty surrounding the opponent’s hidden state, whereas learned methods require incorporating expert domain knowledge (such as `v12`) to achieve competitive performance.

Keywords: Game Artificial Intelligence, decision-making under uncertainty, POMDP, heuristic agents, adversarial search (Minimax), Monte Carlo Tree Search (MCTS), imitation learning (XGBoost), Deep Reinforcement Learning (MaskablePPO), Large Language Models (LLM), telemetry, entry hazards, Bradley-Terry model.

Índex

Resum	i
Abstract	ii
1 Introducció	1
1.1 Contextualització i motivació	1
1.2 Objectius del treball	2
1.3 Estructura de la memòria	3
2 Marc teòric i contextualització	4
2.1 Pokémon com a domini de decisió	4
2.1.1 Què és Pokémon i com es desenvolupa una batalla	4
2.1.2 De l'espècie a les estadístiques finals	5
2.1.3 Tipus elementals, matriu d'efectivitat i categories de moviment	7
2.1.4 Teracristal·lització (Generació IX)	8
2.1.5 Velocitat, prioritat i l'empat de velocitat	8
2.1.6 Condicions d'estat primàries	9
2.1.7 Fonts d'estocasticitat irreductibles	9
2.1.8 Complexitat combinatòria en la configuració d'equips	10
2.1.9 El format Random Battle, el simulador Showdown i poke-env	11
2.1.10 Síntesi del domini: Pokémon com a entorn benchmark ideal per a la IA	11
2.2 Formalització matemàtica i marc d'inferència estadística	12
2.2.1 De la informació perfecta a la informació imperfecta	13
2.2.2 Formalització dels Processos de Decisió: MDP, POMDP i POSG	13
2.2.3 Estat de creença, matriu de recompenses i reducció d'enginyeria	15
2.2.4 Instanciació dels components a <code>gen9randombattle</code>	17
2.2.5 Marc d'avaluació estadística i mètodes d'inferència	18
2.3 Estat de l'Art en IA i Pokémon	21
2.3.1 Plataformes d'integració i entorns de simulació	21
2.3.2 Aprenentatge per reforç profund i exploració autònoma	21
2.3.3 Aprenentatge fora de línia i arquitectures basades en Transformers	22
2.3.4 Models de llenguatge de gran escala i cerca adversària híbrida	22
2.3.5 Mancances de la literatura i justificació d'aquest treball	22
2.3.6 Què afegeix aquest TFM	22
2.4 Fonaments teòrics dels cinc paradigmes de decisió	23
2.4.1 Heurístiques: coneixement com a ablació	23
2.4.2 Minimax d'un torn: resposta adversària immediata	24
2.4.3 Cerca de Monte Carlo a l'arrel (shallow MCTS)	25
2.4.4 Imitació i clonatge conductual	25
2.4.5 Aprenentatge per reforç profund amb emascarament d'accions	26
2.5 Síntesi del marc teòric	27

3	Metodologia i disseny experimental	28
3.1	Disseny general de l'estudi	28
3.1.1	Aïllar la decisió durant el combat	28
3.1.2	Idea d'un gestor de batalles	28
3.2	Disseny incremental dels agents	29
3.2.1	Heurístiques com a seqüència d'hipòtesis	29
3.2.2	Minimax i MCTS com a extensió de la política base	30
3.2.3	Imitació jeràrquica	30
3.2.4	PPO com a currículum amb validacions	30
3.3	Contracte de comparació	31
3.4	Justificació de la mida mostral	31
3.4.1	Cada batalla és un Bernoulli	31
3.4.2	El Pokédex no entra a la variància	32
3.4.3	Tres nivells de mostra	32
3.4.4	Matriu experimental: 784 fitxers CSV	33
3.4.5	Orientacions recíproques i autojoc	34
3.4.6	La taxa global de victòries i l'Elo	34
3.4.7	Ladder humana	34
3.5	Espais formals	34
3.6	Mètriques	34
3.6.1	Mètrica primària: taxa de victòries	34
3.6.2	Mètriques secundàries i telemetria	35
3.6.3	Elo Bradley–Terry	35
3.7	Protocols específics i abast	35
3.7.1	Matriu de 28 agents	35
3.7.2	Agents LLM (PokéChamp i PokéLLMon)	35
3.7.3	PPO contra v12	36
3.8	Amenaces a la validesa i reproductibilitat	36
3.9	Fases de desenvolupament	37
4	Entorn de desenvolupament i infraestructura de còmput	38
4.1	Organització del projecte	38
4.2	Evolució de l'arquitectura	38
4.2.1	Fase 1: prototipatge en portàtil	38
4.2.2	Fase 2: estació de treball	39
4.3	Accés remot: Tailscale	39
4.4	Bot de Telegram	39
4.5	Dependències	39
4.6	Anàlisi de cost econòmic i pressupost de recursos	40
4.6.1	Desglossament de recursos i optimització de costos	40
5	Implementació dels cinc paradigmes	42
5.1	Mapa del programari	42
5.1.1	Com es reparteixen les responsabilitats	43
5.2	Motor de batalla i capa d'integració	43
5.2.1	Servidor local de Pokémon Showdown	43
5.2.2	Adaptació amb <i>poke-env</i>	43
5.3	Arquitectura coordinador–processos de treball	44
5.3.1	Del BattleManager inicial al motor de la matriu	44
5.3.2	Per què subprocessos	44
5.3.3	Coordinador, cua de ports i processos efímers	45
5.3.4	Represa i escriptura per blocs	45

5.3.5	Reinici de Showdown	45
5.3.6	Esquema CSV i telemetria emmagatzemada	45
5.3.7	Automatització de la matriu	47
5.3.8	Contracte <code>BaseHeuristic1v1</code>	47
5.4	Heurístiques <code>v1–v14</code> : incorporació de coneixement	47
5.4.1	Flux de decisió compartit	47
5.4.2	Evolució de les versions	48
5.5	Minimax d'un torn <code>v15–v17</code>	48
5.5.1	Construcció de la matriu d'un torn	49
5.6	MCTS ras <code>v18–v20</code>	49
5.6.1	Simulació local i actualització de l'arrel	49
5.7	Imitació <code>v21–v22</code>	50
5.7.1	Flux de dades	50
5.7.2	Dades	50
5.7.3	Decisió d'alt nivell	50
5.8	Baselines	51
5.8.1	Integració exploratòria d'agents de llenguatge	51
5.9	Bot en línia	51
5.10	PPO: MaskablePPO sobre Showdown	51
5.10.1	Organització del mòdul i dels artefactes	52
5.10.2	Entorn	52
5.10.3	Clonatge, arquitectura i recompensa	52
5.10.4	Execució de les fases 1, 1.5, 2 i 3	54
5.11	Desplegament i operativitat en entorn real (Deployment)	54
5.11.1	Arquitectura del client WebSocket i autenticació	55
5.11.2	Gestió d'estat, xarxa i tolerància a fallades	55
5.11.3	Avaluació i preservació del model principal	56
6	Resultats	57
6.1	Protocol de lectura dels resultats	57
6.1.1	La matriu	57
6.1.2	Precisió de les estimacions	58
6.1.3	Volum i ponderació	58
6.2	Controls globals de la matriu	58
6.3	Fil conductor de <code>v1</code> a <code>v22</code>	60
6.4	L'escala heurística: tres canvis de règim	61
6.4.1	Altiplà <code>v1–v6</code> : rendiments decreixents del càlcul de dany	61
6.4.2	Primer salt: <code>v7</code> (i <code>v8/v10</code>)	62
6.4.3	Segon salt: <code>v9 / v11</code>	62
6.4.4	Tercer salt: <code>v12</code>	62
6.5	La inversió entre <code>v12</code> , <code>v13</code> i <code>v14</code>	63
6.5.1	On <code>v13</code> encara guanya	64
6.5.2	Per què no supera <code>v12</code> en global	64
6.5.3	Especialització de <code>v14</code> i pèrdua de rendiment local	64
6.6	Minimax d'un torn	66
6.6.1	Freqüència d'intervenció	67
6.6.2	<code>v16</code> i l'avaluació de la fulla	67
6.6.3	<code>v17</code> : prior heurístic	68
6.6.4	Canvis, durada i supervivència	68
6.7	MCTS ras: UCB a l'arrel i simulacions de cinc torns	71
6.7.1	Freqüència d'intervenció	71
6.7.2	Discrepància i resultat	72

6.7.3	PUCT i el prior heurístic	72
6.7.4	Indicadors d'efectes diferits	72
6.7.5	Comparació amb els agents de referència	73
6.7.6	Canvis, durada i supervivència	73
6.8	Aprenentatge per imitació: dues formes d'execució	76
6.8.1	Rendiment dins de la matriu	77
6.8.2	Pes efectiu del model a v21	77
6.8.3	Factors que limiten v22	78
6.8.4	Canvis, durada i supervivència	78
6.9	Comparació entre els cinc paradigmes	81
6.9.1	Abyssal com a agent de referència	83
6.9.2	Elo Bradley–Terry	84
6.10	Classificació pública: v14 contra persones	85
6.11	PPO contra v12	86
6.11.1	Resultat principal	86
6.11.2	Curriculum	87
6.11.3	Interpretació del límit observat	87
6.12	Discussió	87
6.12.1	Patró d'integració residual	87
6.12.2	Resposta conjunta a la pregunta de recerca	88
6.12.3	Limitacions específiques dels resultats	88
7	Conclusions i línies futures	89
7.1	Resposta a la pregunta de recerca	89
7.1.1	Grau d'acompliment dels objectius específics	89
7.2	Resultats principals	90
7.3	Contribucions	90
7.4	Limitacions	91
7.5	Línies futures	91
7.5.1	Millores algorítmiques i cerca profunda	91
7.5.2	Aprenentatge per reforç i imitació avançada	91
7.5.3	Avaluació en entorns reals i variabilitat de mostra	91
7.6	Consideracions ètiques, socials i d'impacte ambiental	91
7.6.1	Ètica i Fair Play en entorns de joc en línia	92
7.6.2	Impacte social i transferibilitat científica	92
7.6.3	Impacte ambiental i petjada de carboni	92
7.7	Tancament	93

Índex de figures

2.1	Logotip commemoratiu del 30è aniversari de la franquícia Pokémon (1996–2026), que celebra tres dècades d’història i d’impacte cultural global en l’entreteniment multimèdia i els videojocs.	4
2.2	Captura de la interfície de Pokémon Showdown durant un combat, on s’observen els Pokémon actius de cada bàndol, les banquetes de substituïts (actius, debilitats o ocults), els nivells, percentatges de vida (HP) i la informació visible de la batalla.	5
2.3	Intersecció dels quatre eixos fonamentals de complexitat en IA i la seva correspondència amb altres jocs.	12
2.4	Comparació estructural entre marcs de decisió: a) MDP (informació perfecta), b) POMDP (reducció a 1 decisor sota informació imperfecta), c) POSG teòric (formulació matemàtica abstracta amb 2 jugadors) i d) POSG instanciat en Pokémon Showdown amb el filtre del seu protocol.	15
2.5	Arquitectura d’avaluació d’una política heurística basada en la combinació de blocs de coneixement de domini.	24
2.6	Cicle clàssic de l’MCTS adaptat a simulacions de profunditat rasa a l’arrel ($d = 1$) amb rollouts heurístics.	25
2.7	Comparació estructural entre l’arquitectura d’imitació Híbrida (macro-decisió ML + micro-execució heurística) i l’arquitectura Dual Pura (dos classificadors XGBoost especialitzats).	26
2.8	Comportament de la funció d’objectiu retallada de PPO $\mathcal{L}^{\text{CLIP}}$ en funció de la raó de probabilitats $r_t(\theta)$ quan l’avantatge és positiu ($\hat{A}_t > 0$).	27
3.1	Disseny conceptual de l’estudi. La mateixa infraestructura avalua polítiques diferents i retorna dades tant del resultat com del comportament. El PPO comparteix simulador, però no entra a la matriu 28×28	29
3.2	Genealogia de disseny, no una ordenació de força. v7 reescriu el nucli; minimax, MCTS i imitació parteixen de v14 com a fulla, prior o executor. PPO clona v8 i s’avalua contra v12	29
3.3	Curriculum PPO previst. Cada fletxa és una porta de validació independent de la corba d’entrenament. La fase 2 no supera el llinar; la fase 3 es fa igualment com a mesura contra v12	31
4.1	Tauler Kanban utilitzat per organitzar el desenvolupament del TFM.	38
5.1	Mapa de mòduls. p00 aïlla simulació i persistència; p01–p05 només afegeixen la política. Minimax, MCTS i imitació reutilitzen coneixement de p01 ; PPO té entorn, checkpoints i avaluació propis.	42
5.2	Intercanvi simplificat entre un agent i una instància local de Showdown.	43
5.3	Flux d’adaptació entre el protocol de Showdown i una política Python.	44
5.4	Arquitectura de la matriu experimental, sense memòria compartida entre processos de treball.	44

5.5	Monitoratge durant una execució al prototip de 16 GB. La memòria creix mentre s'acumulen batalles i cau després de reiniciar processos; el patró va motivar els blocs curts, la recollida de memòria i els reinicis de Showdown.	46
5.6	Validació exploratòria de les repeticions humanes: desequilibri entre atacar i canviar, evolució de la taxa de canvi amb el torn i espècies més representades. La figura descriu el conjunt de dades, no el rendiment final de l'agent.	50
5.7	Taxa de canvi humana per espècie activa en una selecció del conjunt d'experts. La variació justifica incloure identitat i context, però no implica causalitat. . . .	51
5.8	Pas d'inferència de MaskablePPO. La màscara s'aplica abans de mostrejar; l'índex no s'envia mai directament al servidor, sinó com a ordre de Showdown.	53
5.9	Seqüència clonatge → reforç. El crític no s'entrena al clonatge; PPO n'aprèn el valor a partir de la recompensa modelada un cop l'actor ja imita el professor. . .	53
5.10	Corbes de les quatre etapes del currículum. Són taxes durant l'entrenament sobre una política canviant; les validacions independents són les de la Taula 5.4. El panell de fase 3 correspon a la passada secundària, no al model A publicat. . . .	55
6.1	Nombre de partides completades a les 784 cel · les. El bloc fosc correspon a 10.000 partides; les files i columnes clares de v18–v20, a 1.000. La creu no és un buit de dades, sinó el pressupost reduït de l'MCTS.	59
6.2	Distribució de la taxa de victòries de les 784 cel · les dirigides. El centre prop del 50% conté autojoc i enfrontaments equilibrats; les cues reflecteixen diferències grans, especialment davant de Random i MaxBasePower.	59
6.3	Distribució de la durada de les batalles analitzades. La mediana és de 17 torns i hi ha una cua dreia de partides excepcionalment llargues.	60
6.4	Taxa global de victòries de v1–v14 (253.000 partides per fila; les tres cel · les contra MCTS tenen $n = 1.000$). S'observen canvis destacats a v7, v9 i v12, seguits d'una disminució a v13 i v14.	61
6.5	v1–v14 contra els sis agents de referència ($n = 10.000$ per cel · la). v12 és el primer que deixa Abyssal i Simple Heuristic clarament per sota del 50%. Contra random, totes les heurístiques arriben al 97–98% i la columna deixa de ser discriminant. .	62
6.6	Empremta tàctica de la seqüència heurística. v12 utilitza la Teracristal · lització gairebé una vegada per partida; v13, 0,20 vegades. ko_checks augmenta fins a aproximadament 15 a v14; la preparació i els perills d'entrada apareixen a partir de v9.	63
6.7	Enfrontaments directes, amb $n = 10.000$ per orientació. v12 i v13 no presenten una separació concloent; v14 obté 44,74% contra v12 i 41,60% contra v13.	64
6.8	Enfrontaments de referència de v12, v13 i v14. Les files representen l'agent avaluat. Les cel · les MCTS tenen $n = 1.000$ i la resta, $n = 10.000$. v12 domina els agents de referència; v13 és més fort contra cerca i v21.	65
6.9	Taxa de victòries de la inversió, agregada per paradigma d'oponent. v12 és millor contra agents de referència i altres heurístiques; v13, contra minimax, MCTS i imitació híbrida.	65
6.10	Relació entre volum de canvis i taxa de victòries. La freqüència de canvi, per si sola, no mesura la qualitat de la política; cal distingir-ne el motiu.	66
6.11	Durada i membres de l'equip disponibles al final. v13 juga partides més llargues i conserva més Pokémon, mentre que v12 obté una taxa de victòries superior. . . .	66
6.12	Taxa de discrepància respecte de v14 en els torns en què s'executa el maximin. v15/v16 discrepen aproximadament en el 67% dels casos; v17, amb prior +0,15, en el 37%. Les derrotes presenten una discrepància mitjana superior, una associació que no implica causalitat.	67

6.13	Indicadors d'efectes diferits: preparació, perills d'entrada i Teracristal · lització. v16 manté la preparació al voltant de 0,21 usos per partida, un nivell semblant al de v14 i molt inferior al de v12.	68
6.14	Distribució de la durada i dels Pokémon restants a minimax. Les tres variants duren aproximadament 19 torns, però v17 conserva 1,39 membres de mitjana, davant d'1,28–1,29.	69
6.15	Distribució dels canvis voluntaris, dels canvis decidits pel maximin i de la fracció de decisions de cerca que són canvis. v17 presenta una mediana superior de canvis tot i discrepar menys de v14.	69
6.16	Empremta v15–v17: KO checks ~14, cerca ~16–18% dels torns, Tera ~0,39 (nivell v14, no v12).	70
6.17	Enfrontaments de referència del minimax d'un torn. Les cel · les contra MCTS tenen $n = 1.000$. v17 millora respecte de les altres variants, però no supera el 50% contra v14.	70
6.18	Taxa de victòries agrupada. v15 i v16 se superposen; v17 queda per sobre, encara per sota de v9/v11.	70
6.19	Taxa de victòries del minimax per família d'oponent. El prior de v17 s'associa amb les millores principals contra heurístiques i MCTS.	71
6.20	Taxa de discrepància respecte de v14 entre les decisions de cerca. UCB1 (v18/v19) discrepa aproximadament en el 71% dels casos i PUCT (v20), en el 19%. Les derrotes mostren més discrepància mitjana, una associació que no estableix causalitat.	72
6.21	Indicadors d'efectes diferits a les simulacions de cinc torns. La preparació i els perills d'entrada es mantenen a nivells semblants als de v14.	73
6.22	Durada i Pokémon restants a MCTS. v20 acaba lleugerament abans (18,33 torns) i conserva 1,40 membres de mitjana, davant d'1,21–1,22 a UCB1.	74
6.23	Distribució dels canvis a MCTS. PUCT augmenta la fracció de decisions de cerca que acaben en canvi i amplia la distribució de canvis voluntaris.	74
6.24	Empremta MCTS. Cerca 16–18% dels torns; KO ~14/partida. v20 busca menys i acaba amb més HP. $n = 1.000$ per oponent.	75
6.25	Enfrontaments discriminants d'MCTS. Les files representen l'agent avaluat i totes les cel · les tenen $n = 1.000$. v20 s'acosta a Abyssal (49%) i no supera v12 (42,7%).	75
6.26	Taxa de victòries agrupada d'MCTS. v18 i v19 se superposen; v20 queda per sobre. Aquesta mitjana de 28.000 partides no té la mateixa ponderació que les files de 253.000.	75
6.27	Taxa de victòries d'MCTS per paradigma d'oponent ($n = 1.000$ a cada cel · la). PUCT millora principalment contra heurístiques i minimax.	76
6.28	Empremta dels agents d'imitació. v21 registra aproximadament 14 proteccions de debilitament per partida i consulta XGBoost en el 15% dels torns. v22 no té aquestes proteccions, consulta XGBoost en el 80% dels torns i activa la protecció de bucle en el 97% de les partides.	77
6.29	Freqüència d'ús de la política apresada. XGBoost intervé en el 15% dels torns de v21 i en el 80% dels de v22.	78
6.30	Durada i Pokémon restants dels agents d'imitació. v22 juga partides més llargues (20,07 torns) però acaba amb només 0,70 membres, davant d'1,33 a v21.	79
6.31	Distribució dels canvis a imitació. v22 fa aproximadament el doble de canvis voluntaris i rep moltes més ordres de canvi del classificador.	79
6.32	Indicadors tàctics. v22 i v12 utilitzen la Teracristal · lització amb freqüències similars, però obtenen resultats molt diferents; la freqüència no mesura la qualitat de la decisió.	80
6.33	Taxa de victòries agrupada de les dues arquitectures d'imitació. v21 se situa prop de v9; v22, per sota de v1.	80

6.34	Taxa de victòries dels agents d'imitació per família d'oponent. v21 supera v22 en els sis blocs, amb diferències d'aproximadament 20–26 pp.	80
6.35	Taxa de victòries de v21 i v22 per oponent. Tots els punts queden sobre la diagonal: v21 obté el valor superior en 28 de 28 enfrontaments. La diferència màxima és de 32,6 pp contra safe_one_step	81
6.36	Mapa de calor de la taxa de victòries a gen9randombattle . La fila és l'agent analitzat i la columna, l'oponent. Prefixos: (H) heurística, (MM) minimax, (MCT) MCTS, (IL) imitació i (B) agent de referència. Les cel·les amb MCTS tenen $n = 1.000$; la resta, $n = 10.000$	83
6.37	Escala Bradley–Terry ancorada a random = 1000, amb les dues orientacions. v12 i v13 obtenen les puntuacions més altes. v14 , Abyssal i Simple Heuristic comparteixen el mateix valor arrodonit. Les files MCTS aporten menys partides al model.	84
6.38	Taxa de victòries i Elo de v14 a la classificació pública: 431 partides entre el 9 i el 10 de juny de 2026, 39,44% $\pm 4,6$ pp i Elo de 1085 a 1038 (màxim 1263).	85
6.39	Evolució de l'Elo al llarg de les 431 partides. Una mostra prefixa de 98 partides, presa prop del màxim, no representa el resultat final.	85
6.40	Victòries i derrotes segons la durada. El subconjunt de partides amb almenys 10 torns és descriptiu; la taxa principal utilitza les 431 partides sense filtrar.	86

Índex de taules

2.1	Exemple numèric d'aplicació de les fórmules d'escalat (2.1) i (2.2) per a un Pikachu a nivell 100 ($L = 100$) amb naturalesa <i>Timid</i> (+10% Velocitat, -10% Atac). Es mostra la contribució de l'estadística base (B), els valors individuals (IV), els punts d'esforç (EV) i el factor de naturalesa (N) fins a l'obtenció de la xifra final de combat.	6
2.2	Matriu d'efectivitat de tipus	7
2.3	Condicions d'estat primàries principals i els seus efectes mecànics en el combat Pokémon.	9
2.4	Exemple simplificat d'una matriu de recompenses en forma normal per a un torn de combat. Els valors representen la recompensa esperada del Jugador 1.	16
2.5	Mapatge POSG/POMDP al combat individual de Random Battle (Generació IX).	18
2.6	Síntesi del marc d'avaluació estadística, eines d'inferència i les seves propietats teòriques.	21
2.7	Comparació conceptual dels cinc paradigmes. Tots decideixen sobre el mateix simulador i format; canvia la font de coneixement i el còmput per torn.	23
3.1	Disseny del currículum PPO. Els l·lindars són criteris previstos per avançar; el compliment real es presenta als capítols d'implementació i resultats.	30
3.2	Informació conceptual disponible per a la presa de decisions.	31
3.3	Precisió aproximada al 95% en el cas de màxima variància ($p = 0,5$). La segona columna és el marge d'una proporció; la tercera, el marge de la diferència entre dues proporcions independents amb el mateix n . Són càlculs de planificació, no una anàlisi de potència.	32
3.4	Famílies d'agents del disseny experimental. La llista completa de 28 identificadors es reutilitza als resultats (Taula 6.1). El PPO queda fora d'aquesta matriu.	33
3.5	Com cada paradigma representa observació i acció. El contracte extern (Showdown) és el mateix; canvia la representació interna.	34
4.1	Resum del pressupost econòmic i costos directes del TFM.	41
5.1	Correspondència entre les fases heurístiques i els components implementats.	48
5.2	Composició del vector d'observació de MaskablePPO. El model A publicat té 328 dimensions; les fases 1 i 1.5 n'utilitzaven 318 (sense dany estimat ni enfrontaments de canvi). Les 18 dimensions addicionals de la fase 4 no entren al resultat principal.	52
5.3	Espai d'accions Discrete(14) de MaskablePPO. La màscara de legalitat i la traducció a <code>/choose</code> comparteixen el mateix mapeig de slots [1].	53
5.4	Implementació i validació del currículum PPO. «Superada» es refereix al l·lindar previst, no al fet que s'executés una fase posterior.	54
6.1	Taxonomia dels 28 agents de la matriu.	57
6.2	Evolució de les preguntes i dels resultats entre v1 i v22	60
6.3	Seqüència heurística v1–v14	61

6.4	Enfrontaments directes, amb $n = 10.000$ partides independents per orientació. v12 i v13 no presenten una separació concloent; v14 queda per sota de tots dos. Les sumes recíproques properes al 100% són un control de coherència, no una prova amb partides aparellades.	63
6.5	Minimax analític d'un torn (253.000 partides per fila). La cerca s'executa en aproximadament el 16–18% dels torns. La fulla posicional de v16 gairebé no modifica la preparació; el prior de v17 redueix la discrepància respecte de v14 i obté la taxa més alta de la família.	67
6.6	MCTS ras amb UCB a l'arrel i 100 simulacions de cinc torns. Totes les cel·les tenen $n = 1.000$ (28.000 partides per agent). La fulla més rica de v19 no aporta una millora observable; PUCT amb prior sobre v14 redueix la discrepància i obté la taxa més alta de la família.	71
6.7	Imitació amb el mateix classificador XGBoost ($\tau = 0,5525$) i dues formes d'execució (253.000 partides per fila). v21 consulta el model en el 15% dels torns; v22 , en el 80%, sense proteccions de debilitament, i activa la protecció de bucle en el 97% de les partides.	76
6.8	Síntesi dels cinc paradigmes amb v12 com a comparador comú. Les variants són les que obtenen el millor resultat observat dins de cada família; aquesta selecció és posterior a l'experiment. L'MCTS té una mostra menor i el PPO no participa en la matriu completa.	81
6.9	Taxes globals descriptives contra els 28 oponents. Les files no MCTS tenen 253.000 partides i ponderen cada oponent MCTS una desena part que els altres; les files MCTS tenen 28.000 partides i ponderen tots els oponents igual. Els dos blocs no formen una única classificació comparable.	82
6.10	Enfrontaments de referència. Les files amb MCTS tenen $n = 1.000$ i la resta, $n = 10.000$. v12 contra Abyssal (59,91% $\pm 0,96$ pp) és el principal resultat contra un agent extern basat en regles.	82
6.11	Escala Bradley–Terry a gen9randombattle , ancorada a random = 1000 i ajustada amb les dues orientacions. Els agents no MCTS aporten 506.000 observacions i els MCTS, 56.000. No s'han calculat intervals: valors iguals després d'arrodonir no impliquen equivalència estadística.	84
6.12	Classificació pública de v14 contra persones.	85
6.13	Curriculum i avaluacions de MaskablePPO. El resultat principal és el del model A contra HeuristicV12 , amb $n = 10.000$ i les dues orientacions. La fase 4 només informa la finestra d'entrenament, no una avaluació independent.	86

Capítol 1

Introducció

1.1 Contextualització i motivació

Pokémon és un joc d'estratègia per torns caracteritzat per la informació parcial, les accions simultànies i les transicions estocàstiques. A cada torn, els jugadors han de decidir entre executar un moviment o substituir el Pokémon actiu sense conèixer amb certesa la configuració de l'equip rival, mentre que factors com la precisió dels atacs, els cops crítics i els efectes secundaris introdueixen aleatorietat inherent al combat.

En aquest context, un **agent** és un sistema autònom que percep l'estat observable de la batalla i selecciona una acció per maximitzar la seva esperança de victòria [2, 3]. Una **política** π formalitza aquesta presa de decisions assignant una distribució sobre les accions legals a partir de l'observació disponible. Els diferents enfocaments d'Intel·ligència Artificial aborden aquesta política des de perspectives diverses: mitjançant regles heurístiques dissenyades per experts, planificació en línia mitjançant cerca adversària o simulació en arbre (MCTS), o bé aprenentatge de patrons a partir de dades humanes i recompenses per reforç.

Aquest Treball de Final de Màster estudia i compara com cinc paradigmes d'agents afronten aquest problema de decisió sota condicions d'incertesa. L'objectiu no és construir un agent infal·libre, sinó avaluar empíricament implementacions concretes sota pressupostos computacionals explícits, en un entorn reproducible i amb una escala mostral que permeti quantificar amb rigor la precisió dels resultats.

Per a l'experimentació s'utilitza el simulador **Pokémon Showdown** [4] i la llibreria *poke-env* [5], focalitzant la recerca en el format individual **Random Battle de la Generació IX** (`gen9randombattle`). Tot i que la generació procedural d'equips introdueix una forta variabilitat inicial on la composició pot determinar l'avantatge d'una partida, l'execució d'un volum massiu de batalles per enfrontament permet diluir aquest soroll estocàstic i aïllar exclusivament la qualitat de la presa de decisions durant el combat.

Concretament, s'implementen i avaluen cinc formes de decidir sobre el mateix simulador i format:

1. **Heurístiques expertes (v1–v14)**: Aquest enfocament es basa en regles de domini dissenyades manualment que assignen una puntuació a cada acció legal segons l'estat del combat. Constitueixen la línia de base determinista i s'estudien mitjançant una seqüència d'ablacions estructurades, on les versions incorporen gradualment càlcul de dany, efectivitat de tipus, perills d'entrada (*hazards*), moviments de preparació (*setup*), gestió d'estats alterats i Teracristal·lització, destacant v12 com la variant experta principal.
2. **Cerca adversària Minimax d'un torn (v15–v17)**: Aquest paradigma construeix una matriu de pagaments d'accions simultànies d'un torn i avalua l'estat resultat amb funcions heurístiques a les fulles. Es comparen tres variants: v15 (avaluació basada purament en HP), v16 (afegeix bonificacions posicionals per preparació, perills d'entrada i estats) i v17

(suma un prior de +0,15 a l'acció recomanada per **v14**, reduint la discrepància respecte a l'heurística).

3. **Cerca en arbre de Monte Carlo rasa** (*shallow* MCTS **v18–v20**): Aquest mètode de planificació en línia executa 100 simulacions d'una profunditat rasa de cinc torns mitjançant un simulador local en memòria (**LocalSim**). Es comparen tres variants: **v18** (selecció UCB1 i avaluació bàsica d'HP/estats), **v19** (UCB1 amb fulla millorada per rols i dreceres tàctiques de **v14**) i **v20** (selecció **PUCT** guiada per priors de probabilitat extrets de l'heurística **v14**).
4. **Aprenentatge per imitació** (**v21–v22**): Aquest enfocament aprèn directament del comportament humà d'alt nivell (Elo 1800+) entrenant classificadors XGBoost sobre 1,12 milions de torns. Es comparen dues piles: **v21** és una versió **híbrida** (XGBoost decideix la decisió macro d'atacar o canviar, i **v14** executa l'acció micro concreta) i **v22** és un model d'**imitació pura dual** (executa dos caps XGBoost: un per a la decisió macro i un segon model per avaluar atributs de moviments, sense dependre de **v14**).
5. **Aprenentatge per reforç profund** (*MaskablePPO*): Aquest paradigma optimitza automàticament una política de xarxa neuronal mitjançant la interacció i la cerca de recompenses en un entorn amb accions emmascarades. L'entrenament segueix un currículum progressiu que comença contra oponents bàsics (**random** i **MaxBasePower**), s'inicialitza per clonatge conductual de l'heurística **v8** per superar el problema de l'exploració inicial (*cold start*), i finalment s'entrena amb *MaskablePPO* contra l'heurística experta **v12**.

Les quatre primeres famílies, juntament amb sis agents de referència, formen una matriu dirigida de **28 agents**. El PPO no forma part d'aquesta matriu principal: s'avalua en un experiment separat contra **v12**, l'agent amb millor resultat observat a la lliga. A més, models de llenguatge com *PokéChamp* i *PokéLLMon* s'integren de manera exploratòria.

1.2 Objectius del treball

L'objectiu principal d'aquest treball és avaluar i comparar empíricament el rendiment relatiu de les heurístiques expertes, la cerca adversària d'un torn, l'MCTS ras, l'aprenentatge per imitació i PPO en batalles **gen9randombattle**, sota pressupostos computacionals explícits i un protocol experimental rigorós.

Aquest objectiu general es concreta en els següents objectius específics:

1. **Formalització teòrica del domini:** Formalitzar el combat Pokémon com un procés de decisió estocàstic d'observació parcial (POMDP/POSG) i definir un marc teòric d'avaluació amb incertesa quantificada.
2. **Disseny metodològic, infraestructura i telemetria:** Definir el protocol experimental i el model de rànquing Bradley-Terry, construir una infraestructura d'execució paral·lela, escalable i recuperable davant de fallades sobre Pokémon Showdown i *poke-env*, i instrumentar un marc de telemetria per torn per quantificar mètriques explicatives del comportament (predicció de canvis, control del ritme o *tempo*, gestió del risc i ús de la Teracristal·lització).
3. **Paradigmes heurístics i de cerca en línia:** Desenvolupar la seqüència d'agents heurístics (**v1–v14**) com una ablació estructurada de coneixement de domini, i implementar i instrumentar variants de cerca adversària Minimax d'un torn (**v15–v17**) i MCTS ras de 5 torns (**v18–v20**) guiats per priors heurístics per analitzar si la cerca millora l'heurística de partida.

4. **Agents apresos i integració de LLMs:** Entrenar models d'aprenentatge per imitació XGBoost (v21–v22) sobre repeticions humanes d'alt nivell (Elo 1800+) per a decisions macro i micro, optimitzar MaskablePPO amb inicialització per clonatge conductual sobre v8 per avaluar si apropa el rendiment a v12, i integrar exploratòriament agents basats en LLM (*PokéChamp* i *PokéLLMon*) analitzant-ne la viabilitat i el cost d'inferència en temps real.
5. **Avaluació empírica massiva i rànquings:** Executar i analitzar la matriu competitiva de 28 agents (més de 6,4 milions de batalles), avaluant-ne els rànquings Bradley-Terry i creuant els resultats amb la telemetria per torn per comparar el rendiment relatiu i els patrons de decisió de cada paradigma.
6. **Avaluació externa al ladder públic:** Desplegar l'agent heurístic principal (v14) a la classificació pública oficial (*ladder*) de Pokémon Showdown per obtenir una mostra externa de rendiment contra jugadors humans reals en un entorn no controlat.

1.3 Estructura de la memòria

La resta d'aquesta memòria s'organitza en sis capítols interconnectats que desenvolupen el treball des dels fonaments teòrics fins a la discussió dels resultats empírics:

- El **Capítol 2 (Marc teòric i contextualització)** descriu les mecàniques de combat de Pokémon i el format `gen9randombattle`, formalitza el problema des de la Teoria de Jocs com un procés de decisió estocàstic d'observació parcial (POMDP/POSG), revisa l'estat de l'art en IA aplicada a jocs complexos i detalla els fonaments teòrics dels cinc paradigmes d'agents estudiats.
- El **Capítol 3 (Metodologia i disseny experimental)** estableix la separació entre el disseny conceptual i la implementació, defineix el gestor de batalles, el protocol d'avaluació de la matriu de 28 agents (més de 6,4M de batalles), el model de rànquing Bradley-Terry, el marc de telemetria per torn per a l'explicabilitat conductual i el control d'amenaçes a la validesa.
- El **Capítol 4 (Entorn de desenvolupament i infraestructura de còmput)** documenta l'organització del projecte mitjançant un tauler Kanban, l'evolució de l'arquitectura de maquinari (de prototip a l'estació de treball AMD Ryzen 7 5700X3D + RTX 2080), l'orquestració de múltiples servidors Pokémon Showdown en paral·lel, la gestió de persistència, el sistema de notificacions i l'anàlisi de cost econòmic i recursos computacionals.
- El **Capítol 5 (Implementació dels cinc paradigmes)** descriu el mapa del programari (`src/`) i tradueix a codi Python el coordinador de batalles, la seqüència d'ablacions heurístiques (v1–v14), la cerca Minimax (v15–v17), l'MCTS ras amb simulador local (v18–v20), els models d'imitació XGBoost (v21–v22), la canalització MaskablePPO amb clonatge conductual, la integració exploratòria de LLMs i l'arquitectura de desplegament operatiu (*Deployment*) per al *ladder* públic.
- El **Capítol 6 (Resultats)** analitza empíricament l'evolució de l'escala heurística, el rendiment de la cerca adversària, MCTS i la imitació, la comparació global dels cinc paradigmes, l'experiment DRL amb PPO contra v12, la validació de v14 contra jugadors humans al *ladder* públic i la discussió dels patrons residuals.
- El **Capítol 7 (Conclusions i línies futures)** respon a la pregunta de recerca principal, sintetitza les sis troballes empíriques clau, exposa les contribucions, analitza les limitacions observades, desenvolupa les línies de treball futur i avalua les consideracions ètiques, socials i d'impacte ambiental.

Capítol 2

Marc teòric i contextualització

Aquest capítol estableix els fonaments teòrics, mecànics i estadístics del treball. En primer lloc, es descriu el domini del combat Pokémon, les seves regles i el format `gen9randombattle`. En segon lloc, es formalitza matemàticament el problema mitjançant processos de decisió sota incertesa (POSG/POMDP) i es defineix el marc d'inferència estadística per a l'avaluació rigorosa dels agents. En tercer lloc, es revisa l'estat de l'art en intel·ligència artificial aplicada a Pokémon. Finalment, es desenvolupen els fonaments algorítmics dels cinc paradigmes de decisió estudiats.

2.1 Pokémon com a domini de decisió

Abans de formalitzar el problema des de la Teoria de Jocs, cal contextualitzar el domini del combat Pokémon. La formulació d'estadístiques, la matriu d'efectivitat, la Teracristal·lització, les regles de velocitat, les condicions d'estat i l'estocasticitat conformen el marc mecànic del joc. Així mateix, s'analitza la complexitat combinatòria d'equips (10^{139}) i es presenta el format `gen9randombattle` a Pokémon Showdown, el qual permet aïllar la presa de decisions executives dels agents.

2.1.1 Què és Pokémon i com es desenvolupa una batalla

Pokémon és una franquícia de videojocs creada l'any 1996 per Satoshi Tajiri i la companyia Game Freak per a la consola Game Boy de Nintendo [6]. El nom **Pokémon** prové de la contracció de la denominació anglesa **Pocket Monsters** (*Poketto Monstā* en japonès), fent referència a les criatures que es capturen en esferes portàtils (Poké Balls), es col·leccionen, s'entrenen i participen en combats. Coincidint amb la celebració del seu **30è aniversari (1996–2026)**, la franquícia s'ha convertit en un fenomen cultural global que abasta videojocs, sèries d'animació, cartes col·leccionables (TCG) i entreteniment multimèdia, on l'estratègia de combat manté un paper central en l'àmbit competitiu.



Figura 2.1: Logotip commemoratiu del 30è aniversari de la franquícia Pokémon (1996–2026), que celebra tres dècades d'història i d'impacte cultural global en l'entreteniment multimèdia i els videojocs.

En una batalla individual (*Singles*), cada jugador disposa habitualment d'un equip de sis

Pokémon, però només un és actiu a cada banda. L'objectiu és debilitar tots els membres de l'equip rival abans que el rival faci el mateix.

En cada torn, un jugador pot escollir un dels moviments disponibles o canviar el Pokémon actiu per un membre no debilitat de l'equip. Un Pokémon pot conèixer com a màxim quatre moviments. Alguns causen dany; d'altres modifiquen estadístiques, imposen una condició d'estat, alteren el camp o permeten canviar conservant la iniciativa. Els dos jugadors envien l'acció sense conèixer la decisió actual de l'altre. El motor ordena les accions segons la prioritat i la velocitat, comprova la precisió i resol el dany i els efectes secundaris.

Aquesta estructura fa que una acció no es pugui valorar de manera aïllada. Un atac molt potent pot ser inútil contra una immunitat de tipus; un canvi pot evitar un debilitament, però permetre que el rival col·loqui un perill d'entrada (*hazards*); i un moviment de preparació (*setup*) pot sacrificar el torn actual per augmentar la probabilitat de guanyar els següents.

Aquesta explicació inicial ofereix una introducció general i conceptual a la dinàmica de la batalla. En les subseccions següents es desenvolupen amb més profunditat i detall cadascun dels seus components mecànics fonamentals: la formulació de les estadístiques de combat, la matriu d'efectivitat de tipus, les regles de velocitat i prioritat, les condicions d'estat i les fonts d'estocasticitat.



Figura 2.2: Captura de la interfície de Pokémon Showdown durant un combat, on s'observen els Pokémon actius de cada bàndol, les banquetes de substituïts (actius, debilitats o ocults), els nivells, percentatges de vida (HP) i la informació visible de la batalla.

2.1.2 De l'espècie a les estadístiques finals

Cada Pokémon pertany a una espècie concreta amb atributs únics i disposa de sis estadístiques de combat: punts de salut (*Hit Points*, HP), atac, defensa, atac especial, defensa especial i velocitat [7, 8]. Els HP determinen quant dany pot rebre; atac i defensa intervenen en els moviments físics; atac especial i defensa especial, en els moviments especials; i la velocitat decideix quin Pokémon actua abans.

La xifra final que mostra el joc es construeix a partir de cinc components:

1. **Estadística base (B).** Pròpia de l'espècie. Dos Pikachu comparteixen les mateixes estadístiques base, però no necessàriament les mateixes xifres finals.
2. **Nivell (L).** Escala el valor final. Random Battle utilitza el nivell com a mecanisme d'equilibri entre espècies.

3. **Valors individuals (IV).** Cada estadística té un IV enter entre 0 i 31 [9].
4. **Punts d'esforç (EV).** Es poden distribuir fins a 510 EV en total, amb un màxim efectiu de 252 en una mateixa estadística [10].
5. **Naturalesa (N).** La majoria de naturaleses multipliquen una estadística per 1,1 i una altra per 0,9 [11].

Per a qualsevol estadística de combat diferent dels HP (Atac, Defensa, Atac Especial, Defensa Especial i Velocitat), la fórmula general d'escalat és:

$$\text{Stat} = \left\lfloor \left(\left\lfloor \frac{(2B + IV + \lfloor \text{EV}/4 \rfloor)L}{100} \right\rfloor + 5 \right) N \right\rfloor. \quad (2.1)$$

Per contra, els punts de salut (HP) segueixen un càlcul diferent per dues raons mecàniques: en primer lloc, cap naturalesa modifica els HP (no s'aplica el multiplicador N); en segon lloc, s'afegeix el terme $+L + 10$ en comptes de la constant fixa $+5$ per tal que la salut màxima escali de manera proporcional al nivell L de la criatura. Excepte casos especials com Shedinja (els HP del qual estan fixats permanentment pel motor de joc en 1 HP independentment del nivell, IVs o EVs), la fórmula de càlcul dels HP és:

$$\text{HP} = \left\lfloor \frac{(2B + IV + \lfloor \text{EV}/4 \rfloor)L}{100} \right\rfloor + L + 10. \quad (2.2)$$

Taula 2.1: Exemple numèric d'aplicació de les fórmules d'escalat (2.1) i (2.2) per a un Pikachu a nivell 100 ($L = 100$) amb naturalesa *Timid* (+10% Velocitat, -10% Atac). Es mostra la contribució de l'estadística base (B), els valors individuals (IV), els punts d'esforç (EV) i el factor de naturalesa (N) fins a l'obtenció de la xifra final de combat.

Estadística	Base (B)	IV	EV	Naturalesa (N)	Valor final
HP	35	31	0	—	211
Atac	55	31	0	0,9 (↓)	131
Defensa	40	31	0	1,0 (·)	116
Atac Especial	50	31	0	1,0 (·)	136
Defensa Especial	50	31	0	1,0 (·)	136
Velocitat	90	31	252	1,1 (↑)	306

Com s'observa a la Taula 2.1, les xifres finals calculades determinen el perfil competitiu real de la criatura durant el combat. Aquestes estadístiques finals —especialment la Velocitat efectiva (306) i la salut màxima (HP = 211)— són els valors concrets que el motor de Pokémon Showdown utilitza a cada torn per determinar l'ordre d'actuació i l'abast del dany produït. Conseqüentment, aquests valors constitueixen la base d'informació sobre la qual els agents d'IA estimen la velocitat relativa, el dany sota tirada i el risc de debilitament.

2.1.3 Tipus elementals, matriu d'efectivitat i categories de moviment

Un dels pilars estratègics del combat Pokémon és la relació elemental entre els 18 tipus existents (Foc, Aigua, Planta, etc.). Cal distingir clarament entre el **tipus del Pokémon** i el **tipus del moviment**:

- **Tipus del Pokémon (funció defensiva):** Cada criatura disposa d'un o dos tipus elementals pròpis (tipus únic o **dobles tipus**) que determinen les febleses, resistències i immunitats quan *rep* un atac rival.
- **Tipus del moviment (funció ofensiva):** Atribut propi de l'acció executada. Un Pokémon no està restringit a utilitzar atacs del seu mateix tipus elemental (p. ex., un Pokémon de Foc pot llançar un atac de Terra). Tanmateix, quan el tipus del moviment coincideix amb un dels seus tipus pròpis, el joc atorga una bonificació extra del +50% al dany denominada **STAB** (*Same Type Attack Bonus*, multiplicador $\times 1,5$).

Quan un Pokémon té **dobles tipus**, els multiplicadors de la matriu d'efectivitat (Taula 2.2) es combinen multiplicativament ($M = M_1 \times M_2$), generant efectes de **debilitat doble** ($\times 4$, p. ex., Roca contra Foc/Volador: $2 \times 2 = 4$), **resistència doble** ($\times 0,25$, p. ex., Planta contra Acer/Volador), **neutralització** ($\times 1$, p. ex., Lluita contra Insecte/Roca: $2 \times 0,5 = 1$) o **immunitat absoluta** ($\times 0$, p. ex., Elèctric contra Aigua/Terra: $2 \times 0 = 0$).

Els moviments es classifiquen en tres categories principals:

1. **Físics (Atac vs. Defensa):** Atacs de contacte físic o força directa.
2. **Especials (Atac Esp. vs. Def. Esp.):** Atacs d'energia, distància o projectils elementals.
3. **D'estat / Suport:** No causen dany directe; s'utilitzen per induir **condicions d'estat primàries** (com cremada, paràlisi o verí; vegeu Secció 2.1.6), modificar estadístiques, alterar el clima o col·locar perills d'entrada com *Stealth Rock*.

La diferenciació entre la via física i especial és crucial: la majoria de Pokémon s'especialitzen en un perfil defensiu físic o especial concret, la qual cosa obliga els agents d'IA a avaluar la categoria d'atac que exploti la feblesa estructural del rival.

Taula 2.2: Matriu d'efectivitat elemental en combat. Les files representen el tipus de l'atac executat i les columnes, el tipus del Pokémon defensor.

	NOR	FOC	AIG	PLA	ELE	GEL	LLU	VER	TER	VOL	PSI	INS	ROC	FAN	DRA	FOS	ACE	FAD
NOR													½	0			½	
FOC		½	½	2		2						2	½		½		2	
AIG		2	½	½					2				2		½			
PLA		½	2	½				½	2	½		½	2		½		½	
ELE			2	½	½				0	2					½			
GEL		½	½	2		½			2	2					2		½	
LLU	2					2		½		½	½	½	2	0		2	2	½
VER				2				½	½				½	½			0	2
TER		2		½	2			2		0		½	2				2	
VOL				2	½		2					2	½				½	
PSI							2	2			½					0	½	
INS		½		2			½	½		½	2			½		2	½	½
ROC		2				2	½		½	2		2					½	
FAN	0										2			2		½		
DRA															2		½	0
FOS							½				2			2		½		2
ACE		½	½		½	2							2				½	2
FAD		½					2	½							2	2	½	

2.1.4 Teracristal · lització (Generació IX)

La **Teracristal · lització** (*Terastallization* o *Tera*) és la mecànica transformativa exclusiva de la novena generació (*Pokémon Scarlet & Violet*, 2022) utilitzada en el format `gen9randombattle` [12]. Aquesta mecànica permet a cada jugador transformar un dels seus Pokémon una sola vegada per combat, canviant els seus tipus elementals originals per un únic **Tipus Tera** (*Tera Type*) seleccionat d'entre els 18 tipus de la matriu d'efectivitat (Taula 2.2).

La Teracristal · lització altera la dinàmica del combat a dos nivells clau:

- **Nivell defensiu:** El Pokémon adopta immediatament el Tipus Tera com a únic tipus defensiu actiu, substituint completament les seves febleses i resistències d'origen. Per exemple, un Pokémon de tipus Aigua/Volador que teracristal · litza a tipus Planta passa a ser defensivament de tipus Planta pur, convertint una feblesa fatal de $4\times$ a l'Electricitat en una resistència del $0,5\times$.
- **Nivell ofensiu (STAB millorat):** Els atacs del nou Tipus Tera obtenen la bonificació de STAB ($1,5\times$). Tanmateix, si el Tipus Tera coincideix amb un dels tipus originals de la criatura (p. ex., un Pokémon de Foc teracristal · litzant a Foc), la bonificació de STAB s'amplifica fins al $2,0\times$ (+100% de dany). A més, el Pokémon conserva la bonificació de STAB $1,5\times$ en els atacs dels seus tipus primaris d'origen.

Des de la perspectiva de la presa de decisions en IA, la Teracristal · lització és un recurs d'ús únic d'alta rellevància estratègica. Permet realitzar accions de canvi de tipus instantani (*type-shift*) per sobreviure a atacs directes, anular un atac supereficax del rival i capgirar l'estat del combat en un únic torn, constituint un dels punts d'avaluació més complexos per a les polítiques de decisió dels agents.

2.1.5 Velocitat, prioritat i l'empat de velocitat

La **Velocitat** és una de les estadístiques més determinants en el combat Pokémon competitiu. Atacar primer no només concedeix la iniciativa tàctica (*tempo*), sinó que atorga la capacitat de debilitar la criatura rival abans que aquesta pugui executar la seva acció en aquell torn, anul·lant per complet el seu potencial de dany. Conseqüentment, saber quin Pokémon actuarà abans és un càlcul fonamental per als agents d'IA en avaluar els riscos i les oportunitats de cada moviment.

En cada torn, el motor de joc ordena l'execució de les accions seguint dos criteris seqüencials:

1. **Prioritat del moviment:** Cada moviment té un valor de prioritat discret que varia entre $+5$ i -7 . Els moviments de prioritat alta, com *Protect* ($+4$), *Extreme Speed* ($+2$) o *Quick Attack* ($+1$), s'executen sempre abans que qualsevol moviment de prioritat neutra (0), independentment de la Velocitat dels Pokémon. Per contra, moviments d'alta utilitat tàctica com *Trick Room* (-7) s'executen al final del torn.
2. **Velocitat efectiva:** Si dos moviments tenen la mateixa prioritat (habitualment 0), actua primer el Pokémon que tingui una Velocitat efectiva més alta en aquell torn, tenint en compte l'estadística final, els canvis d'etapa (de -6 a $+6$), els objectes equipats (com *Choice Scarf*, que augmenta la velocitat en un 50%) i les condicions d'estat (la paràlisi redueix la velocitat a la meitat).

Quan dos Pokémon tenen exactament la mateixa prioritat i la mateixa Velocitat efectiva final, es produeix un **empat de velocitat** (*Speed Tie*). El motor de joc resol aquest empat mitjançant una decisió aleatòria al 50% ($p = 0,5$).

2.1.6 Condicions d'estat primàries

Com s'ha introduït en les categories de moviment (Secció 2.1.3), els moviments d'estat o suport (com *Will-O-Wisp* o *Thunder Wave*) i certs efectes secundaris d'atacs físics o especials tenen la capacitat d'imposar **condicions d'estat primàries**. Aquestes alteracions són persistents i afecten negativament les capacitats operatives d'un Pokémon. Un Pokémon només pot patir una condició d'estat primària de manera simultània. A la Taula 2.3 es resumeixen les principals condicions d'estat i els seus efectes mecànics en el combat.

Taula 2.3: Condicions d'estat primàries principals i els seus efectes mecànics en el combat Pokémon.

Estat	Efecte en combat	Mecànica i impacte tàctic
Cremada	↓ 50% Atac físic	Causa un dany recurrent d'1/16 dels HP màxims per torn i redueix a la meitat l'Atac físic efectiu.
Paràlisi	↓ 50% Velocitat (Gen. VII+)	Redueix la Velocitat a la meitat i introdueix un 25% de probabilitat de no actuar per torn.
Verí / Tòxic	Dany recurrent per torn	El verí estàndard treu 1/8 dels HP per torn; el verí tòxic incrementa el dany a cada torn (1/16, 2/16...).
Son	Inhabilitació temporal	El Pokémon no pot actuar durant 1-3 torns consecutius.
Congelació	Inhabilitació estocàstica	El Pokémon no pot actuar; té un 20% de probabilitat de descongelar-se a cada torn.

Des de la perspectiva de la presa de decisions, induir una condició d'estat pot ser estratègicament superior a causar dany immediat. Per exemple, cremar un atacant físic enreda irreversiblement el seu potencial ofensiu, mentre que paraitzar un Pokémon ràpid permet a l'agent recuperar la iniciativa de velocitat en el combat.

2.1.7 Fonts d'estocasticitat irreductibles

El combat Pokémon és un entorn fortament estocàstic. Fins i tot quan un agent disposa d'informació completa sobre l'estat actiu, el resultat d'una decisió està subjecte a tres fonts d'aleatorietat irreductibles administrades pel simulador de joc [8, 13, 14]:

1. **Tirada de dany (*Damage Roll*):** El dany calculat per les fórmules oficials no és un valor fix, sinó que es multiplica per un factor aleatori extret d'una distribució uniforme discreta de 16 valors entre 0,85 i 1,00 ($\{0,85, 0,86, \dots, 1,00\}$) [13]. Així, un mateix atac pot debilitar un rival si es dona una tirada alta (1,00), però deixar-lo amb vida si la tirada és baixa (0,85).
2. **Precisió i evasió (*Accuracy*):** Molts moviments potents no tenen una precisió del 100% (p. ex., *Hydro Pump* amb 80% o *Focus Blast* amb 70%) [8]. L'agent ha de ponderar el dany esperat davant del risc de fallar l'atac i regalar un torn d'iniciativa al rival.
3. **Cop crític (*Critical Hit*):** A la Generació IX, la probabilitat base que un atac sigui crític és d'1 de cada 24 vegades ($p_{\text{crit}} \approx 4,17\%$) [8, 13]. Un cop crític aplica un multiplicador de $\times 1,5$ al dany, ignora els augments defensius del rival i ignora les reduccions d'atac de l'usuari.

Matemàticament, aquestes tres fonts d'estocasticitat es poden unificar en la formulació general del dany realitzat per un atac ofensiu:

$$\text{Dany} = I_{\text{hit}} \cdot [D_{\text{base}} \cdot C_{\text{crit}} \cdot R] \quad (2.3)$$

on D_{base} és el dany determinista brut derivat de les estadístiques, potència del moviment, modificadors d'etapa i la matriu de tipus (Equació 2.1 i Secció 2.1.3), mentre que els tres components estocàstics es defineixen com:

- $I_{\text{hit}} \sim \text{Bernoulli}(P_{\text{acc}})$ és l'indicador binari d'impacte, on $P_{\text{acc}} \in (0, 1]$ representa la precisió efectiva de l'atac. Si l'atac falla ($I_{\text{hit}} = 0$), el dany resulta immediatament 0.
- C_{crit} és la variable aleatòria del multiplicador de cop crític:

$$C_{\text{crit}} = \begin{cases} 1,5 & \text{amb probabilitat } p_{\text{crit}} = \frac{1}{24} \approx 4,17\% \quad (\text{Gen. IX}) \\ 1,0 & \text{amb probabilitat } 1 - p_{\text{crit}} \end{cases} \quad (2.4)$$

el qual, a més d'amplificar el dany, anul·la els modificadors estadístics desfavorables per a l'atacant.

- $R \sim \mathcal{U}(\{0,85, 0,86, \dots, 1,00\})$ és la tirada de dany extrema d'una distribució uniforme discreta de 16 valors, amb un valor esperat $\mathbb{E}[R] = 0,925$.

Així, l'esperança matemàtica del dany $\mathbb{E}[\text{Dany}]$ que un agent d'IA ha d'avaluar abans de seleccionar una acció ve donada per:

$$\mathbb{E}[\text{Dany}] = P_{\text{acc}} \cdot \mathbb{E}[R] \cdot ((1 - p_{\text{crit}}) \cdot D_{\text{norm}} + p_{\text{crit}} \cdot D_{\text{crit}}) \quad (2.5)$$

on D_{norm} i D_{crit} corresponen al dany base calculat sense i amb l'omissió de modificadors d'etapa respectivament. Cal destacar que, mentre que l'Equació 2.5 defineix l'esperança teòrica exacta del simulador de joc, a la pràctica els agents heurístics d'aquest treball utilitzen una aproximació determinista eficient ($\mathbb{E}[\text{Dany}] \approx P_{\text{acc}} \cdot D_{\text{base}}$), ometent la branca de cop crític ($p_{\text{crit}} \approx 4,17\%$) durant la puntuació instantània de moviments per optimitzar el temps de computació per torn.

Aquestes tres fonts d'estocasticitat, sumades a la generació procedural d'equips i als empats de velocitat (Secció 2.1.5), impedeixen l'existència de trajectòries de decisió deterministes i fan imprescindible quantificar la incertesa mitjançant simulacions estocàstiques (com l'MCTS) o polítiques d'avaluació de risc [15, 16].

2.1.8 Complexitat combinatòria en la configuració d'equips

Més enllà de la presa de decisions durant el combat, la fase prèvia de selecció i configuració d'un equip Pokémon presenta una explosió combinatòria extraordinària. Per a cada un dels **sis** membres de l'equip, cal triar l'espècie, un conjunt de 4 moviments d'entre el seu repositori disponible (M), la distribució de Punts d'Esforç (EVs) i Valors Individuals (IVs), la Naturalesa, l'Habilitat, l'Objecte equipat i el Tipus de Teracristallització (un dels 18 tipus possibles a la Generació IX).

Formalsment, el nombre de configuracions possibles per a una única posició o ranura de l'equip (C_{slot}) es pot quantificar com el producte del seu espai de paràmetres:

$$C_{\text{slot}} = N_{\text{espècies}} \times \binom{M}{4} \times N_{\text{objectes}} \times N_{\text{habilitats}} \times N_{\text{naturaleses}} \times N_{\text{tera}} \times N_{\text{stats}} \approx 10^{22} - 10^{23} \quad (2.6)$$

on $N_{\text{espècies}} \approx 10^3$ (corresponent a les 1.025 espècies de la Pokédex Nacional en formats lliures de construcció d'equips, o $\approx 5 \times 10^2$ espècies/formes competitives presents al repositori de `gen9randombattle`), la combinatòria de 4 moviments ($\binom{M}{4} \approx 10^4 - 10^5$), $N_{\text{objectes}} \approx 10^2$, $N_{\text{naturaleses}} = 25$, $N_{\text{tera}} = 18$ i les distribucions d'EVs/IVs $N_{\text{stats}} \approx 10^{10} - 10^{11}$. Per a un equip de **sis** Pokémon no ordenats, el nombre total de composicions d'equips (C_{equip}) s'obté mitjançant:

$$C_{\text{equip}} = \frac{(C_{\text{slot}})^6}{6!} \approx \frac{(10^{23})^6}{720} \approx 10^{135} - 10^{139}. \quad (2.7)$$

Estudis recents sobre entorns de decisió complexos en Pokémon com Angliss et al. [17] xifren l'espai combinatori d'equips competitiu en l'ordre de 10^{139} configuracions possibles. Per posar aquesta magnitud en perspectiva, el nombre de combinacions (10^{139}) supera astronòmicament el nombre total d'àtoms de l'univers observable (estimat en l'ordre de 10^{80}), així com l'espai d'estats de jocs clàssics de la IA com els escacs ($\approx 10^{47}$) o el Go ($\approx 10^{170}$).

Aquesta immensa varietat imposa un repte metodològic central en l'avaluació d'agents d'intel·ligència artificial. En formats d'equips lliures (*Teambuilding* o *Custom Teams*), la taxa de victòria d'un agent pot quedar fortament emmascarada per la superioritat o el desequilibri inicial de la composició de l'equip (meta-gaming), impossibilitant mesurar amb claredat si el rendiment es deu a una presa de decisions autònoma i tàctica de qualitat o a un avantatge estructural previ. Conseqüentment, per avaluar amb rigor el raonament executiu d'un agent cal desacoblar la fase de construcció d'equips de l'execució en combat.

2.1.9 El format Random Battle, el simulador Showdown i poke-env

Per aïllar la presa de decisions executives i eliminar els biaixos de construcció d'equips derivats de l'espai combinatori de 10^{139} equips (Secció 2.1.8), aquest treball utilitza com a marc experimental el format oficial **Random Battle** (`gen9randombattle`) [18]. En aquest format, el simulador restringeix el repositori d'espècies a un conjunt de $\approx 5 \times 10^2$ Pokémon competitiu de la Generació IX i assigna proceduralment a cada jugador un equip aleatori de sis Pokémon a l'inici del combat, amb configuracions optimitzades extretes del repositori públic de Smogon [19] i un mecanisme de reequilibrat dinàmic de nivells (L) que compensa les diferències de potència entre espècies.

Aquesta generació procedural garanteix que els agents s'enfrontin de manera contínua a escenaris no vistos i variats. Mitjançant una avaluació basada en un volum significatiu de batalles, la variància associada a la generació d'equips es cancel·la estadísticament, garantint la significança dels resultats que es detallen en la metodologia (Capítol 3) i en l'avaluació empírica (Capítol 6).

Com a introducció conceptual a l'arquitectura d'execució, les simulacions es basen en **Pokémon Showdown** [4], el simulador de codi obert en Node.js/TypeScript que implementa amb exactitud les regles oficials del joc en un entorn *headless* i local, i la llibreria en Python *poke-env* [5] (versió 0.11.x), que exposa la interfície de comunicació per a la connexió d'agents autònoms. Aquesta breu introducció serveix de fonament teòric abans de desenvolupar en profunditat la infraestructura d'execució, el protocol de comunicació i el disseny detallat dels entorns al Capítol 3.

2.1.10 Síntesi del domini: Pokémon com a entorn benchmark ideal per a la IA

En resum, el combat Pokémon en el format `gen9randombattle` configura un entorn de decisió d'una complexitat extraordinària. A diferència dels jocs tradicionals de la IA que aïllen només una o dues dificultats, Pokémon és un dels pocs dominis en la literatura que encreua simultàniament quatre reptes centrals de la intel·ligència artificial (Figura 2.3):

1. **Planificació a llarg termini (*Long-Term Planning*):** Propi de jocs d'estratègia posicional pura com els **escacs** o el **Go**. A Pokémon, les decisions no es poden valorar aïlladament per al torn actual: cal gestionar un equip de sis criatures al llarg de desenes de torns, sacrificant Pokémon per conservar la iniciativa (*tempo*), col·locant perills d'entrada (*hazards*) o preparant condicionants de victòria (*win conditions*) per al final del combat.
2. **Accions simultànies (*Simultaneous Actions*):** Present en jocs com el **Pedra-Paper-Tisores** o variants d'escacs a cegues (*Kriegspiel*). A cada torn, tots dos jugadors escullen la seva acció de manera secreta i simultània (Secció 2.1). L'agent no pot simplement

reaccionar a un moviment vist, sinó que ha de raonar estratègicament sobre la matriu de respostes rivals des de la teoria de jocs.

3. **Gestió de la probabilitat i l'estocasticitat (*Probability Management*):** Típic de jocs de **daus** o **Backgammon**. Les tirades de dany, la precisió dels moviments, els cops crítics (Secció 2.1.7) i la generació procedural d'equips (Secció 2.1.9) impedeixen l'existència de trajectòries deterministes, obligant l'agent a ponderar riscos i esperances matemàtiques a cada decisió.
4. **Informació imperfecta i oculta (*Imperfect Information*):** Propi de jocs de cartes com el **Pòquer** o **Magic: The Gathering**. L'estat inicial del rival (moviments no revelats, objectes, habilitats, IVs/EVs i Tipus Tera) roman ocult fins que s'exposa en combat, exigint a l'agent mantenir i actualitzar una distribució de creença sobre les variables no observades.

La convergència d'aquests quatre eixos (esquematzada a la Figura 2.3) converteix el combat Pokémon en un entorn benchmark d'un interès excepcional per a la intel·ligència artificial. Cap d'aquests quatre reptes es pot abordar de manera aïllada, ja que la presa de decisions exigeix ponderar simultàniament la planificació temporal a llarg termini, l'estocasticitat del motor i la incertesa sobre les accions i l'estat del rival.




Figura 2.3: Intersecció dels quatre eixos fonamentals de complexitat en IA i la seva correspondència amb altres jocs.

Aquesta combinació única de propietats fa imprescindible formalitzar el problema des de la teoria de jocs i el marc dels processos de decisió sota incertesa. En la secció següent (Secció 2.2), es tradueixen aquestes mecàniques al modelat matemàtic rigorós mitjançant Processos de Decisió de Markov Parcialment Observables (POMDP) i Jocs Estocàstics d'Observació Parcial (POSG).

2.2 Formalització matemàtica i marc d'inferència estadística

Aquesta secció formalitza matemàticament els quatre eixos de complexitat del combat Pokémon introduïts anteriorment (Figura 2.3) des de la Teoria de Jocs i els Processos de Decisió (models POSG/POMDP), n'analitza l'estat de creença i les reduccions d'enginyeria al format `gen9randombattle`, i estableix el marc d'inferència estadística per a l'avaluació empírica dels agents.

2.2.1 De la informació perfecta a la informació imperfecta

Per modelar matemàticament els quatre eixos de complexitat descrits a la secció anterior (planificació a llarg termini, simultaneïtat, estocasticitat i informació imperfecta; Figura 2.3), recorrem a la **Teoria de Jocs** [20]: la branca de les matemàtiques aplicades que estudia les situacions d'interacció estratègica entre agents racionals, on la utilitat o recompensa d'un individu depèn tant de les seves decisions com de les accions escollides pels seus rivals. En la història de la intel·ligència artificial, els jocs han estat el banc de proves clàssic per mesurar la capacitat de raonament autònom [21–28].

Des del punt de vista de la visibilitat de l'estat, la Teoria de Jocs divideix els entorns en dues grans categories:

- **Informació perfecta** (escacs, Go): L'estat complet del joc s és comú i totalment visible per a tots els jugadors a cada pas ($o_t = s_t$), de manera que no existeix incertesa sobre la configuració de l'entorn.
- **Informació imperfecta** (pòquer, StarCraft II, Pokémon): Part de l'estat global roman oculta a un o tots dos jugadors. Tal com s'ha exposat a la Secció 2.1.10, l'agent percep només una observació parcial $o_t \in \Omega$ i ha d'inferir probabilísticament les variables no visibles per prendre decisions sota incertesa.

Així doncs, dins del marc de la Teoria de Jocs, el combat Pokémon es classifica formalment com un **joc de dos jugadors, competitiu de suma zero, de selecció simultània i d'informació imperfecta**:

- **Suma zero**: La victòria d'un jugador és exactament la derrota del rival ($R_1 + R_2 = 0$), descartant qualsevol possibilitat de cooperació.
- **Selecció simultània**: Tots dos jugadors trien la seva acció de manera secreta i paral·lela a cada torn.
- **Informació imperfecta**: Els moviments no utilitzats, objectes equipats, EVs/IVs i Tipus Tera del rival no són directament accessibles, forçant la decisió sota un conjunt d'informació restringit.

2.2.2 Formalització dels Processos de Decisió: MDP, POMDP i POSG

En intel·ligència artificial i aprenentatge per reforç, un **marc o model de decisió** és la formulació matemàtica que descriu com un agent percep l'entorn, avalua les seves opcions i tria accions per maximitzar la probabilitat de guanyar (com processar l'estat de Showdown, avaluar atacs o canvis i triar la decisió de màxima utilitat). Per formalitzar el combat Pokémon de manera entenedora, cal comprendre com passem del marc teòric més simple al model matemàtic real del joc, analitzant aquesta evolució segons la informació disponible i el nombre de jugadors:

1. **MDP (Markov Decision Process)**: El marc base per a un sol agent que juga amb informació perfecta (una simplificació teòrica idealitzada on fossin visibles tots els moviments, objectes i intencions rivals; vegeu el diagrama estructural a la Figura 2.4a).
2. **POMDP (Partially Observable MDP)**: L'ampliació quan un sol agent pren decisions sota informació imperfecta (la reducció d'enginyeria utilitzada per PPO i XGBoost en integrar el rival dins l'entorn amb dades ocultes com moviments no revelats, objectes o Tipus Tera; vegeu la Figura 2.4b).
3. **POSG (Partially Observable Stochastic Game)**: El model matemàtic real del combat Pokémon (el format `gen9randombattle` on dos jugadors trien acció simultàniament a cada torn amb informació parcialment oculta; vegeu el model abstracte a la Figura 2.4c i la seva instanciació real amb Pokémon Showdown a la Figura 2.4d).

Un **Procés de Decisió de Markov (MDP)** [29] es defineix com la tupla (S, A, T, R, γ) , on S és l'espai d'estats, A l'espai d'accions, $T(s' | s, a) = P(S_{t+1} = s' | S_t = s, A_t = a)$ la funció de transició estocàstica, $R(s, a)$ la funció de recompensa i $\gamma \in [0, 1]$ el factor de descompte (Figura 2.4a). La política $\pi(a | s)$ maximitza el retorn esperat.

Quan l'agent no observa directament l'estat real s , sinó una observació parcial $o \in \Omega$ emesa segons una funció d'emissió $O(o | s', a) = P(O_{t+1} = o | S_{t+1} = s', A_t = a)$, el model es converteix en un **Procés de Decisió de Markov Parcialment Observable (POMDP)** [30, 31] (Figura 2.4b).

Atès que a Pokémon hi intervenen dos jugadors que escullen accions de forma simultània sense conèixer la decisió del rival en el torn actual, el model formal conceptualment rigorós és un **Joc Estocàstic d'Observació Parcial (POSG)** [20, 32]. Formalment, un POSG de dos jugadors (esquematzat conceptualment a la Figura 2.4c) es defineix com una tupla de vuit components:

$$\mathcal{M} = (N, S, \{A_i\}_{i \in N}, T, \{R_i\}_{i \in N}, \{\Omega_i\}_{i \in N}, \{O_i\}_{i \in N}, \gamma) \quad (2.8)$$

on:

- $N = \{1, 2\}$ és el conjunt dels dos jugadors (Jugador 1 i Jugador 2).
- S és l'espai d'estats globals del joc (mantingut de manera omniscient pel servidor central de Pokémon Showdown).
- A_i és l'espai d'accions del jugador i . Una acció conjunta s'expressa com $\mathbf{a} = (a_1, a_2) \in A_1 \times A_2$.
- $T(s' | s, \mathbf{a}) = P(S_{t+1} = s' | S_t = s, \mathbf{a}_t = \mathbf{a})$ és la probabilitat de transició condicional sota l'acció conjunta.
- $R_i(s, \mathbf{a})$ és la recompensa del jugador i . En ser un joc competitiu pur de suma zero, es compleix $R_1(s, \mathbf{a}) + R_2(s, \mathbf{a}) = 0$.
- Ω_i és l'espai d'observacions privades del jugador i .
- $O_i(o_i | s', \mathbf{a}) = P(O_{i,t+1} = o_i | S_{t+1} = s', \mathbf{a}_t = \mathbf{a})$ és la funció d'emissió d'observacions privades, on el motor de Showdown mascara les dades no revelades del rival abans d'enviar el paquet d'estat a cada jugador.
- $\gamma \in [0, 1]$ és el factor de descompte temporal.

Cal destacar que el simulador central de Pokémon Showdown actua com un àrbitre omniscient que conté l'estat real complet S (amb tota la informació oculta de tots dos jugadors), però aplica el **filtre del seu protocol** per ofuscar les dades no revelades del rival i transmetre a cada agent únicament la seva observació parcial emmascarada o_1, o_2 (Figura 2.4d). Aquest mecanisme d'emissió i els detalls de funcionament del simulador es desenvolupen en profunditat en els capítols de metodologia, infraestructura i implementació (Capítols 3, 4 i 5).

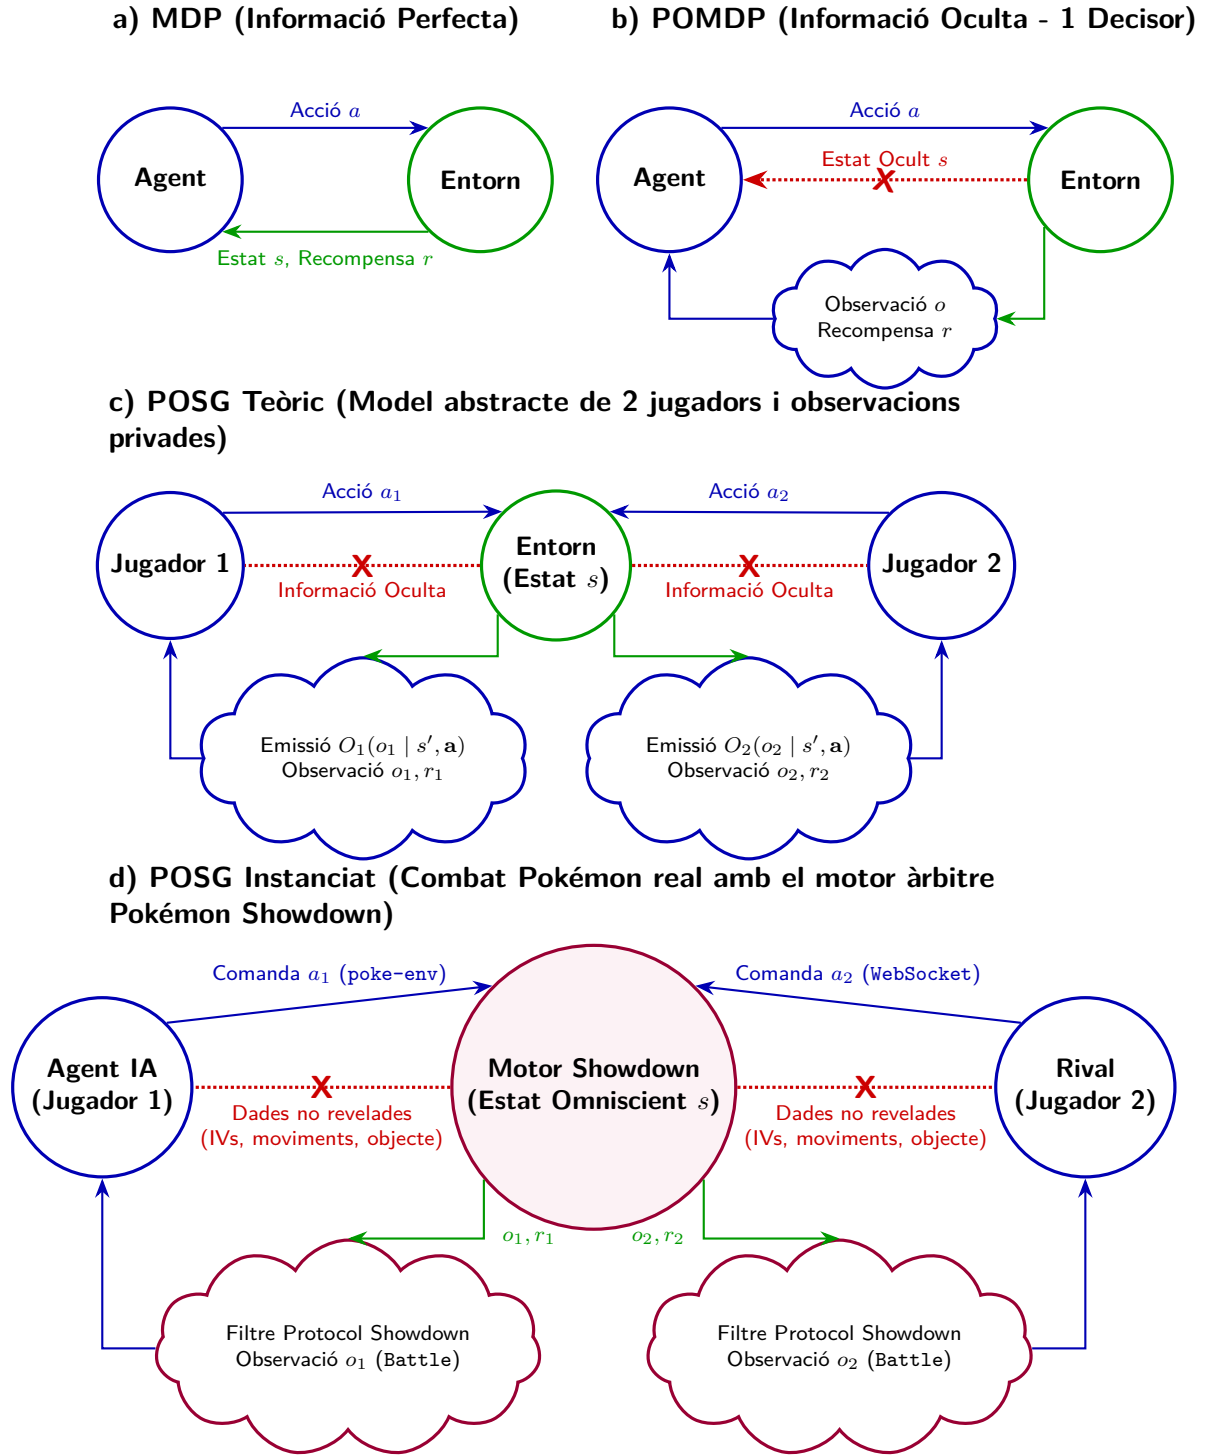


Figura 2.4: Comparació estructural entre marcs de decisió: a) MDP (informació perfecta), b) POMDP (reducció a 1 decisor sota informació imperfecta), c) POSG teòric (formulació matemàtica abstracta amb 2 jugadors) i d) POSG instanciat en Pokémon Showdown amb el filtre del seu protocol.

2.2.3 Estat de creença, matriu de recompenses i reducció d'enginyeria

Una vegada definit el marc formal del POSG, sorgeix la qüestió de com un agent pot prendre decisions operatives en temps real. Com s'ha establert a la Secció 2.2.2, el combat Pokémon planteja tres grans desafiaments que impedeixen aplicar algorismes de cerca convencionals:

1. **La informació oculta:** Requereix introduir l'**estat de creença** (*Belief State*) per inferir probabilísticament les variables no visibles del rival (moviments, objectes o Tipus Tera) a partir de la història del combat.
2. **La simultaneïtat de les accions:** Requereix utilitzar la **matriu de recompenses** de la Teoria de Jocs per calcular l'**Equilibri de Nash**, evitant que l'agent sigui explotable per polítiques deterministes de l'adversari.
3. **La intractabilitat computacional (*NEXP-hard*):** Fa impossible resoldre el joc de manera exacta i força a aplicar **reduccions d'enginyeria** (com reduir el POSG a un POMDP d'un sol decisor o acotar la cerca a arbres locals) per prendre decisions en pocs mil·lisegons.

En els següents apartats es desenvolupen formalment cadascuna d'aquestes tres solucions.

L'estat de creença (*Belief State*)

Per gestionar la inaccessibilitat de l'estat real s provocada per la informació oculta, l'agent utilitza un **estat de creença** (*Belief State*) $b_{i,t}(s) \in \Delta(S)$. Aquest es defineix com la distribució de probabilitat sobre els possibles estats globals s donada la història d'observacions i accions acumulades $h_{i,t} = (o_{i,1}, a_{i,1}, \dots, o_{i,t})$:

$$b_{i,t}(s) = P(S_t = s \mid h_{i,t}) \quad (2.9)$$

A cada torn, l'agent actualitza $b_{i,t}$ mitjançant la regla de Bayes [33] en rebre la nova observació $o_{i,t+1}$. Això li permet ponderar probabilísticament les dades no visibles del rival (com ara atacs de cobertura o objectes d'augment de velocitat) abans de triar una acció.

La matriu de recompenses i l'Equilibri de Nash

L'**Equilibri de Nash** [20] és el concepte central de la Teoria de Jocs que defineix l'estat d'un joc en què cap participant no té cap incentiu per modificar la seva estratègia de manera unilateral, ja que qualsevol canvi individual reduiria o igualaria la seva recompensa esperada.

En el combat Pokémon, com que tots dos jugadors escullen la seva acció de manera **simultània** sense veure la jugada del rival, sorgeix un gran problema: **qualsevol decisió determinista fixa és previsible i fàcilment explotable**. Per exemple, si l'agent triés sempre l'atac de més potència, un rival intel·ligent ho preveuria i canviaria a un Pokémon resistent o immune a aquest atac, fent perdre l'agent sistemàticament.

Per aquest motiu, l'objectiu de l'agent no és trobar una única "millor acció" fixa, sinó calcular una **estratègia inexplorable** mitjançant la formulació del torn com una **matriu de recompenses en forma normal** $M(a_1, a_2) = \mathbb{E}_{s \sim b}[R_1(s, a_1, a_2) + \gamma V(s')]$, on les files representen les accions del Jugador 1 ($a_1 \in A_1$) i les columnes les respostes del Jugador 2 ($a_2 \in A_2$).

Prenguem com a exemple un torn on el Jugador 1 pot escollir entre un atac elèctric o un canvi defensiu, i el Jugador 2 pot escollir entre un atac d'aigua o un canvi a un Pokémon de tipus Terra (immune a l'electricitat):

Jugador 1 \ Jugador 2	Atac d'Aigua (a_2^1)	Canvi a Terra (a_2^2)
Atac Elèctric (a_1^1)	+10 (Dany màxim $\times 4$)	-10 (Avançat pel rival / Atac nul)
Canvi defensiu (a_1^2)	+2 (Resisteix atac)	0 (Canvi neutre)

Taula 2.4: Exemple simplificat d'una matriu de recompenses en forma normal per a un torn de combat. Els valors representen la recompensa esperada del Jugador 1.

Com s'observa a la Taula 2.4:

- Si el Jugador 1 juga el 100% de les vegades l'Atac Elèctric (a_1^1), el rival ho descobrirà i respondrà jugant el 100% el Canvi a Terra (a_2^2), fent que el Jugador 1 obtingui la pitjor recompensa possible (-10).
- Per evitar ser previsible i explotat, l'agent ha d'emprar una **estratègia mixta / estocàstica** $\pi_1^* \in \Delta(A_1)$ i assignar probabilitats a cada opció (p. ex., un 70% de probabilitat a l'atac elèctric i un 30% al canvi defensiu).

Matemàticament, el parell d'estratègies (π_1^*, π_2^*) constitueix un **Equilibri de Nash** si es compleix la següent condició de no-explotabilitat:

$$\mathbb{E}_{\mathbf{a} \sim (\pi_1^*, \pi_2^*)}[R_1(s, \mathbf{a})] \geq \mathbb{E}_{a_1 \sim \pi_1, a_2 \sim \pi_2^*}[R_1(s, a_1, a_2)], \quad \forall \pi_1 \in \Delta(A_1) \quad (2.10)$$

En aquest punt d'equilibri, l'agent es garanteix el màxim retorn esperat possible sense que el rival pugui aprofitar-se de cap biaix en les seves decisions.

Justificació de les reduccions d'enginyeria i complexitat *NEXP-hard*

La cerca d'un Equilibri de Nash o de la política òptima conjunta en un POSG d'horitzó finit és un problema demostrat formalment com a ***NEXP-hard*** (*Nondeterministic Exponential Time*) [34]. Aquesta classe de complexitat implica que resoldre el joc de manera exacta requereix un temps d'execució **doblement exponencial** respecte a la profunditat del combat, fent que el càlcul en temps real sigui computacionalment inabordable.

Per fer la decisió computable en mil·lisegons, els paradigmes desenvolupats en aquest treball apliquen **reduccions d'enginyeria**:

- **Aprenentatge per Reforç (PPO) i Clonatge Conductual (XGBoost)**: Redueixen la complexitat multijugador integrant la política del rival $\pi_2(a_2 | o_2)$ directament dins de la funció de transició de l'entorn:

$$T_{\text{eff}}(s' | s, a_1) = \sum_{a_2 \in A_2} \pi_2(a_2 | o_2) \cdot T(s' | s, a_1, a_2) \quad (2.11)$$

Aquesta formulació transforma el POSG competitiu de dos jugadors en un **POMDP d'un sol decisor** (Figura 2.4b), on l'adversari s'absorbeix en la dinàmica de l'entorn.

- **Cerca Minimax i MCTS**: Acoten el càlcul a un horitzó temporal local a l'arrel de l'arbre (1 torn o pocs torns endavant), construint la matriu de recompenses local o executant *rollouts* d'esperança per respondre immediatament.

2.2.4 Instanciació dels components a **gen9randombattle**

Per traslladar els conceptes teòrics de la tupla POSG/POMDP (S, A, T, R, Ω, O) al desenvolupament d'agents de decisió autònoms en aquest treball, cal definir com es tradueix cada component abstracte a l'entorn real de simulació de Pokémon Showdown i *poke-env* en el format **gen9randombattle**. A la Taula 2.5 es detalla aquest mapatge exactament.

Component	Instanciació a Singles gen9randombattle
S	Sis Pokémon per bàndol (espècie, HP, configuració, objecte, habilitat, modificadors i condició d'estat), clima, perills d'entrada, Tera consumit i torn. $ S $ és astronòmic i no s'enumera.
A	Ordres directes de combat (<i>raw orders</i> : 4 moviments, Tera opcional i fins a 5 canvis de banquet). En aprenentatge per reforç discret, es codifica en un espai fix (4 moviments + 4 moviments amb Tera + 6 slots d'equip). La legalitat $M(a) \in \{0, 1\}$ la determinen els PP, debilitaments, bloqueigs i absència de canvi al mateix Pokémon actiu.
T	Motor de Showdown: determinista en les mecàniques de combat, estocàstic en el multiplicador de dany $[0,85, 1,00]$, la precisió dels moviments, els efectes secundaris, els empats de velocitat (<i>speed ties</i>) i la generació procedural de l'equip a l'inici del combat.
R	Recompensa terminal zero-sum conceptual +1 per victòria i -1 per derrota (indicador binari $W \in \{0, 1\}$ enregistrat per a l'avaluació). En l'entrenament RL s'utilitza una funció de recompensa dita densa (<i>reward shaping</i>) basada en la diferència d'HP, penalització/bonificació per debilitament de Pokémon, modificadors d'estat i penalització per pas de temps.
Ω	Equip propi complet; del rival, espècies revelades, percentatge d'HP, moviments utilitzats, condicions laterals i modificadors d'estat. EV, naturalesa, objecte i moviments no utilitzats romanen ocults.
O	Mecanisme d'emascament i protocol WebSocket de Pokémon Showdown / <i>poke-env</i> . Intercepta l'estat global S i genera l'observació parcial privada $o_i \in \Omega_i$ filtrant les dades no revelades abans de transmetre el paquet al client.

Taula 2.5: Mapatge POSG/POMDP al combat individual de Random Battle (Generació IX).

Com s'observa a la Taula 2.5, la traducció de la tupla formal (S, A, T, R, Ω, O) varia lleugerament segons el paradigma de decisió implementat. Mentre que les heurístiques i els algorismes de cerca (Minimax i MCTS) operen directament sobre l'objecte d'estat parcial **Battle** emès per *poke-env* i generen accions basades en objectes **SingleBattleOrder**, els algorismes d'aprenentatge automàtic requereixen transformacions específiques de la informació. En l'aprenentatge per imitació (XGBoost), l'observació Ω es tradueix en una matriu de característiques tabulars (*feature vector*) d'estat i enfrontament. En l'aprenentatge per reforç profund (MaskablePPO), l'observació contínua s'estructura mitjançant un vectoritzador d'estats normalitzat en el rang $[0, 1]$, i l'espai d'accions es redueix a un vector de probabilitats sobre els índexs d'acció vàlids definits per la màscara de legalitat $M(a)$. Els detalls concrets d'enginyeria sobre la construcció d'aquests vectors de característiques, les funcions de recompensa modificades, els mecanismes d'emascament d'accions i l'arquitectura del codi es desenvolupen de manera exhaustiva en els capítols de metodologia i implementació (Capítols 3 i 5).

2.2.5 Marc d'avaluació estadística i mètodes d'inferència

La comparació empírica entre agents de diferents paradigmes requereix un marc d'inferència estadística rigorós per garantir que les diferències observades en la taxa de victòria no siguin fruit del soroll estocàstic del simulador ni de la variància en la generació d'equips. Aquesta secció justifica i defineix formalment les eines matemàtiques (interval de Wilson, rànquings Bradley-Terry per Màxima Versemblança, significança de diferències, mètriques de pèrdua i emascament d'accions) utilitzades per avaluar el rendiment dels algorismes.

1. **Estimació de la Taxa de Victòria (*Win Rate*) i Marge d'Error:** En un enfrontament de N partides entre dos agents, cada combat i s'escriu com una variable aleatòria binària de Bernoulli $W_i \sim \text{Bernoulli}(p)$, on $W_i = 1$ indica victòria de l'agent i $W_i = 0$ indica derrota.

L'estimador puntual de la taxa de victòria $\hat{p}$ és la mitjana mostral:

$$\hat{p} = \frac{1}{N} \sum_{i=1}^N W_i \quad (2.12)$$

La variància d'aquest estimador ve donada per $\text{Var}(\hat{p}) = \frac{p(1-p)}{N}$, assolint el seu màxim teòric quan $p = 0,5$. El marge d'error (MoE) al nivell de confiança del 95% ($\alpha = 0,05$) es calcula com:

$$\text{MoE} = z_{1-\alpha/2} \cdot \text{SE}(\hat{p}) = z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{N}} \quad (2.13)$$

Per a una mida mostral de $N = 10.000$ partides per enfrontament directe, l'error estàndard màxim és $\text{SE}(\hat{p}) = \sqrt{0,25/10000} = 0,005$ (0,5%), el que garanteix un marge d'error màxim de $\text{MoE} = 1,96 \cdot 0,005 = \pm 0,0098 \approx \pm 0,98\%$ ($\approx \pm 1\%$). En mostres menors com $N = 1.000$, el marge d'error és de $\text{MoE} \approx \pm 3,10\%$.

2. **Intervals de Confiança de Wilson (*Wilson Score Interval*):** A diferència de l'interval binomi estàndard de Wald ($\hat{p} \pm z\sqrt{\hat{p}(1-\hat{p})/N}$), que falla prop dels límits (0 o 1) o en mostres asimètriques, aquest treball calcula els intervals de confiança mitjançant l'**interval de la puntuació de Wilson** [35]:

$$\text{CI}_{\text{Wilson}} = \frac{1}{1 + \frac{z^2}{N}} \left(\hat{p} + \frac{z^2}{2N} \pm z \sqrt{\frac{\hat{p}(1-\hat{p})}{N} + \frac{z^2}{4N^2}} \right) \quad (2.14)$$

on $z = z_{1-\alpha/2} = 1,96$ per a un nivell de confiança del 95% ($\alpha = 0,05$).

3. **Model de Bradley-Terry i Puntuació Elo per Màxima Versemblança (MLE):** Per ordenar un conjunt d'agents en un llistat global 1D independent de la composició d'oponents, s'utilitza el model de comparació per parelles de Bradley-Terry [36] transformat a escala Elo [37]. La probabilitat esperada de victòria de l'agent A_i enfront de l'agent A_j amb puntuacions R_i i R_j s'expressa mitjançant la funció logística:

$$P(A_i > A_j) = \frac{1}{1 + 10^{(R_j - R_i)/400}} = \sigma \left(\frac{\ln 10}{400} (R_i - R_j) \right) \quad (2.15)$$

A diferència del sistema d'actualització seqüencial Elo utilitzat en el joc en línia (que depèn de l'ordre dels combats), els paràmetres $\{R_i\}$ s'estimen de manera conjunta sobre la matriu completa d'enfrontaments mitjançant la maximització de la log-versemblança (MLE):

$$\ln \mathcal{L}(\mathbf{R}) = \sum_{i < j} (W_{ij} \ln P(A_i > A_j) + W_{ji} \ln P(A_j > A_i)) \quad (2.16)$$

Computacionalment, aquesta optimització s'executa igualant l'estimador a una **regressió logística sense terme independent** (*unintercepted logistic regression*): sobre un conjunt de dades simetritzat de M batalles amb vectors d'entrada $\mathbf{x}_k \in \{-\ln 10, 0, +\ln 10\}^P$ i etiquetes $y_k \in \{0, 1\}$, s'obtenen els coeficients $\hat{\beta}$, a partir dels quals es calculen les puntuacions Elo:

$$R_i = 400 \cdot \hat{\beta}_i + R_{\text{init}} \quad (2.17)$$

fixant l'ancoratge de referència de l'agent aleatori en $R_{\text{random}} = 1000$.

4. **Comparació de Dues Proporcions Independents i Significança de Diferències:** Per determinar si la diferència observada $\Delta\hat{p} = \hat{p}_1 - \hat{p}_2$ entre dos agents (p. ex., en

estudis d'ablació de regles o mecàniques) és estadísticament significativa, es calcula l'error estàndard de la diferència:

$$\text{SE}(\Delta\hat{p}) = \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{N_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{N_2}} \quad (2.18)$$

i el corresponent interval de confiança del 95% per a la diferència de taxes de victòria:

$$\text{CI}_{95\%}(\Delta p) = (\hat{p}_1 - \hat{p}_2) \pm z_{1-\alpha/2} \cdot \text{SE}(\Delta\hat{p}) \quad (2.19)$$

Si l'interval de confiança $\text{CI}_{95\%}(\Delta p)$ no inclou el valor 0, es conclou que la millora de rendiment és estadísticament significativa amb $p < 0,05$.

5. **Mètriques de Pèrdua per a Aprendre de Dades Humanes i Polítiques Emascarades:** Per als agents basats en clonatge conductual i aprenentatge per imitació (XGBoost), la convergència sobre la partició de dades d'experts s'avalua mitjançant la pèrdua de crosse-entropia (*Log-Loss*) [38]:

$$\mathcal{L}_{\text{CE}} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{i,k} \ln \hat{y}_{i,k} \quad (2.20)$$

Per als agents d'aprenentatge per reforç profund (MaskablePPO), l'assignació de probabilitats sobre les accions legals s'executa mitjançant la distribució categòrica emascarada (*Invalid Action Masking*) [1]:

$$P(a \mid o) = \frac{M(a) \exp(z_a)}{\sum_{a'} M(a') \exp(z_{a'})}, \quad M(a) \in \{0, 1\} \quad (2.21)$$

on $M(a) = 0$ elimina immediatament les accions il·legals abans del càlcul del softmax, optimitzant la funció d'objectiu de PPO amb retallat (*clipped surrogate objective*) [39]:

$$\mathcal{L}^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (2.22)$$

6. **Telemetria Multidimensional i Indicadors Tàctics:** A més de la taxa de victòria escalar, el marc d'avaluació recull una telemetria multidimensional per combat per desglossar l'origen estratègic del rendiment en quatre dimensions principals:

- **Eficiència Executiva:** Latència mitjana per decisió (ms), nombre de torns per combat i taxa d'accions de fallback o errors.
- **Dinàmica de Rells:** Proporció de canvis voluntaris estratègics respecte als canvis forçats per debilitament de Pokémon.
- **Control del Camp i Tàctica:** Gestió de perills d'entrada (*Stealth Rock*, *Spikes*), activació de moviments de preparació (*setup moves*) i eficiència de noaut (KO).
- **Aïllament del Soroll d' RNG:** Registre de cops crítics, fallades per precisió i cops super-efectius rebuts/efectuats per separar la qualitat de la decisió de la sort estocàstica.

A la Taula 2.6 es sintetitza el conjunt d'eines matemàtiques, mètriques d'inferència i propietats estadístiques que integren el marc teòric d'avaluació d'aquest treball.

Mètrica / Eina	Formulació Matemàtica / Càlcul	Objectiu / Propietat Estadística
Taxa de Victòria ($\hat{p}$)	$\hat{p} = \frac{1}{N} \sum_{i=1}^N W_i$	Estimació puntual de Bernoulli
Marge d'Error (MoE)	$\text{MoE} = z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{N}}$	Acotació d'error al 95% de confiança
Interval de Wilson	$\text{CI}_{\text{Wilson}}$ Eq. (2.14)	Robustesa en límits $p \rightarrow 0, 1$ i mostres petites
Model Bradley-Terry Elo	$P(A_i > A_j) = \sigma\left(\frac{\ln 10}{400}(R_i - R_j)\right)$	Rànquing 1D conjunt per MLE ($R_{\text{rand}} = 1000$)
Test Z de Diferència	$\text{CI}_{95\%}(\Delta p) = (\hat{p}_1 - \hat{p}_2) \pm 1,96 \cdot \text{SE}(\Delta \hat{p})$	Avaluació de significança en ablacions ($p < 0,05$)
Pèrdua Crosse-Entropia	$\mathcal{L}_{\text{CE}} = -\frac{1}{N} \sum y_{i,k} \ln \hat{y}_{i,k}$	Minimització d'error en aprenentatge per imitació
Policy PPO amb Masking	$P(a o) = \frac{M(a) \exp(z_a)}{\sum M(a') \exp(z_{a'})}$	Garantia d'execució només d'accions legals $M(a)$
Telemetria Tàctica	Indicadors de latència, canvis, hazards i RNG	Anàlisi multifactorial del comportament executiu

Taula 2.6: Síntesi del marc d'avaluació estadística, eines d'inferència i les seves propietats teòriques.

La variància estocàstica associada a la generació procedural d'equips a Random Battle es dilueix fixant una mida mostral suficientment gran per a cada enfrontament directe ($N \geq 10^3$), la qual cosa acota l'error estàndard de l'estimador per sota de lindars de soroll rellevants ($\text{SE} \leq 0,015$) i garanteix la significança estadística de les comparacions presentades en els capítols següents.

2.3 Estat de l'Art en IA i Pokémon

L'estudi de la presa de decisions autònoma en el combat competitiu de Pokémon ha experimentat un desenvolupament creixent gràcies a l'estandardització d'entorns de simulació oberts. Aquesta secció revisa la literatura existent organitzant els treballs rellevants en quatre blocs temàtics, analitza les manques principals de la recerca prèvia i descriu el valor afegit d'aquest treball.

2.3.1 Plataformes d'integració i entorns de simulació

La recerca en IA aplicada a Pokémon va prendre impuls amb el desenvolupament de **Pokémon Showdown** [4], el simulador de codi obert utilitzat per la comunitat competitiva de Smogon. La creació de la llibreria *poke-env* [5, 40] va establir la interfície estàndard per a la connexió d'agents autònoms via protocols WebSocket, facilitant l'accés a l'estat del combat (**Battle**) i l'emissió d'ordres legalitzades. Així mateix, aquesta plataforma inclou agents de referència fonamentals basats en selecció aleatòria (**RandomPlayer**), atacs de màxima potència (**MaxBasePowerPlayer**) i regles heurístiques bàsiques (**SimpleHeuristicsPlayer**).

2.3.2 Aprenentatge per reforç profund i exploració autònoma

L'aplicació de l'aprenentatge per reforç profund (DRL) a Pokémon presenta reptes de gran complexitat per l'alta dimensió de l'espai d'estats, la informació oculta i l'estocasticitat. Huang i Lee [16] van realitzar un dels treballs pioners entrenant un agent basat en Proximal Policy Optimization (PPO) mitjançant auto-aprenentatge (*self-play*) sobre Pokémon Showdown. Els seus resultats van evidenciar la dificultat de la cerca no guiada: sense un emmascarament rigorós d'accions legals ni una inicialització guiada per coneixement de domini, els agents RL tenen tendència a convergir cap a polítiques subòptimes o bloquejar-se en cicles d'accions invàlides. Treballs posteriors han demostrat que la combinació de PPO amb emmascarament binari d'accions

(*Invalid Action Masking*) [1] i el disseny de recompenses denses (*reward shaping*) [41] són elements claus per estabilitzar la convergència en entorns d'informació imperfecta.

2.3.3 Aprenentatge fora de línia i arquitectures basades en Transformers

Davant les dificultats de l'exploració activa a l'entorn de simulació, una línia de recerca recent aposta per l'aprenentatge a partir de dades d'experts humans. L'agent *Metamon* [15] representa una de les fites més recents en aquest eix, aplicant aprenentatge per reforç fora de línia (*offline RL*) i arquitectures basades en Transformers sobre corpus massius de repeticions de partides d'alt nivell. Aquest enfocament permet als models extreure patrons estratègics complexos i relacions temporals directament de les trajectòries d'experts, tot i que requereix una capacitat computacional elevada per a l'entrenament dels models de polítiques.

2.3.4 Models de llenguatge de gran escala i cerca adversària híbrida

L'emergència dels models de llenguatge de gran escala (LLM) ha generat una nova línia d'agents capaços de raonar sobre l'estat del combat mitjançant llenguatge natural. L'agent *PokéLL-Mon* [42] utilitza LLMs per processar l'historial del combat i inferir la informació oculta del rival. Paral·lelament, l'agent *PokéChamp* [43, 44] combina un model de llenguatge per a la construcció de l'estat de creença amb un algorisme de cerca Minimax d'un pas per a l'avaluació d'accions simultànies, assolint les posicions més altes de la classificació pública (*ladder*) de Showdown. Aquests treballs demostren que integrar coneixement de domini o motors de cerca amb models apressos supera el rendiment de qualsevol de les tècniques aplicades de manera aïllada.

2.3.5 Mancances de la literatura i justificació d'aquest treball

Tot i els avenços descrits, la literatura prèvia presenta dues manques estructurals primordials:

1. **Absència d'una matriu d'avaluació integrada i homogènia:** Els treballs precedents avaluen els seus agents en formats heterogenis, enfront d'oponents diferents o sota condicions no estandarditzades, sense una comparació directa i sistemàtica entre els cinc paradigmes fonamentals de la presa de decisions (heurístiques expertes, cerca adversària Minimax, cerca MCTS, aprenentatge per imitació i DRL) sota un mateix protocol experimental i marc d'inferència estadística.
2. **Falta d'estudis d'ablació del coneixement de domini:** Les heurístiques existents solen presentar-se com a blocs monolítics sense aïllar l'impacte individual de cada mecanisme tàctic (com el càlcul de velocitat, la lectura de la Taula de Tipus, la gestió de perills d'entrada o la Teracristal·lització).

2.3.6 Què afegeix aquest TFM

Per respondre a aquestes manques, aquest Treball de Final de Màster aporta les següents contribucions teòriques i metodològiques:

1. **Un marc d'avaluació integrat i homogeni entre paradigmes:** Defineix una matriu de combat que enfronta de manera directa i igualitària els cinc paradigmes fonamentals de decisió sobre un mateix entorn i format (`gen9randombattle`), sota mètodes d'inferència estadística rigorosos (interval de Wilson i ajust Bradley-Terry Elo per MLE).
2. **Una seqüència d'ablació incremental del coneixement de domini:** Desenvolupa una jerarquia d'agents heurístics estructurada en blocs de regles que permet mesurar de manera aïllada el valor afegit de cada component tàctic del joc.

3. **Arquitectures híbrides de cerca i d'imitació guiades per heurístiques:** Explora la integració de regles de domini com a distribucions a priori (*priors*) o executors de suport en algorismes de cerca adversària (Minimax i MCTS) i aprenentatge per imitació, avaluant el guany estratègic del raonament anticipatori.
4. **Una avaluació rigorosa de MaskablePPO i clonatge conductual:** Desenvolupa i avalua un entorn DRL integrant emmascarament binari d'accions legals, disseny de recompenses denses i inicialització de polítiques mitjançant clonatge conductual sobre dades expertes.

2.4 Fonaments teòrics dels cinc paradigmes de decisió

Cada paradigma de presa de decisions introdueix un mecanisme diferent per fer front a la incertesa, la simultaneïtat i la informació oculta del combat Pokémon: coneixement codificat, anticipació adversària en matriu, simulació estocàstica en arbre, supervisió amb dades expertes humanes o optimització per reforç amb emmascarament. A la Taula 2.7 es resumeixen i s'analitzen les característiques principals d'aquests cinc paradigmes de decisió.

Taula 2.7: Comparació conceptual dels cinc paradigmes. Tots decideixen sobre el mateix simulador i format; canvia la font de coneixement i el còmput per torn.

Paradigma	Què decideix	Coneixement	Còmput per torn	Aprèn?
Heurística	Argmax d'una puntuació fixa sobre accions legals.	Regles escrites (dany, posició, Tera).	Constant, baix.	No durant l'execució.
Minimax d'un torn	Maximin sobre una matriu d'accions i respostes estimades.	Funció de fulla + prior opcional.	Enumeració d'un torn.	No.
MCTS ras	UCB/PUCT només als fills de l'arrel.	Determinització i, a v20, prior de v14.	100 simulacions de 5 torns.	No (cerca en línia).
Imitació	Classificador atacar/canviar + executor.	Trajectòries humanes Elo 1800+.	Inferència XGBoost.	Supervisat, fora de línia.
PPO	Política estocàstica emmascarada $\pi_\theta(a o)$.	Interacció amb recompensa + clonatge inicial.	Un pas de xarxa.	Per reforç, fora de partida.

2.4.1 Heurístiques: coneixement com a ablació

Una política heurística no ajusta els seus paràmetres durant l'execució. A cada estat d'avaluació s , puntua les accions legals $a \in A(s)$ mitjançant un conjunt de regles de domini deterministes i selecciona l'acció que maximitza la funció de puntuació composta $H(s, a)$:

$$a^* = \arg \max_{a \in A(s)} H(s, a) = \arg \max_{a \in A(s)} \sum_{k=1}^K w_k \cdot f_k(s, a) \quad (2.23)$$

on $f_k(s, a) \in \mathbb{R}$ representa una funció d'indicador o de valoració de la mecànica k (com la proporció de dany esperat, el multiplicador de la matriu de tipus, la diferència de velocitat, la inducció d'estats alterats, l'efectivitat dels perills d'entrada o l'oportunitat de preparació) i $w_k > 0$ és el pes o prioritat associat.




Figura 2.5: Arquitectura d'avaluació d'una política heurística basada en la combinació de blocs de coneixement de domini.

L'organització d'aquestes regles en blocs de coneixement independents es formalitza com una **ablació incremental**. Si $\mathcal{F}^{(M)} = \{f_1, f_2, \dots, f_K\}$ és el repositori complet de característiques de domini, una seqüència d'ablació defineix un subconjunt creixent de mecanismes $\mathcal{F}^{(1)} \subset \mathcal{F}^{(2)} \subset \dots \subset \mathcal{F}^{(M)}$. La política de l'agent al pas d'ablació m avalua l'acció mitjançant:

$$H^{(m)}(s, a) = \sum_{f_k \in \mathcal{F}^{(m)}} w_k \cdot f_k(s, a) \quad (2.24)$$

Aquest marc matemàtic permet aïllar i mesurar formalment la contribució marginal $\Delta \hat{p}_m = \hat{p}(H^{(m)}) - \hat{p}(H^{(m-1)})$ associada a la incorporació de cada mecànica concreta (com el càlcul de velocitat, la gestió de perills d'entrada o la Teracristal·lització), transformant l'enginyeria d'heurístiques en un procés rigorós de comprovació d'hipòtesis.

2.4.2 Minimax d'un torn: resposta adversària immediata

El principi Minimax [45] assigna a cada estat el valor de la millor decisió pròpia assumint la resposta més desfavorable de l'oponent. Atès que les accions a Pokémon Showdown s'executen de manera **simultània** a cada torn, la formulació Minimax d'un pas resol la decisió com un joc de matriu zero-sum de dimensió $|A_1| \times |A_2|$, on l'element $M_{ij} = \mathbb{E}_{s' \sim T(s, a_1, i, a_2, j)}[V(s')]$ representa el valor esperat de l'estat d'arribada obtingut per la funció d'avaluació V , integrant l'estocasticitat del simulador T (tirada de dany, precisió i empats de velocitat).

En estratègies pures, la formulació Maximin ve donada per:

$$a_1^* = \arg \max_{a_1 \in A_1} \min_{a_2 \in A_2} M(a_1, a_2) \quad (2.25)$$

Tanmateix, per evitar ser previsible i explotable davant d'un adversari intel·ligent, la matriu de recompenses $M \in \mathbb{R}^{|A_1| \times |A_2|}$ es resol en **estratègies mixtes** $\pi_1^* \in \Delta(A_1)$ mitjançant **Programació Lineal (LP)**, trobant l'Equilibri de Nash de la matriu local (vegeu Equació 2.10):

$$\max_{\pi_1 \in \Delta(A_1)} v \quad \text{subjecte a} \quad \sum_{i=1}^{|A_1|} \pi_1(i) M_{ij} \geq v, \quad \forall j \in \{1, \dots, |A_2|\}, \quad \sum_i \pi_1(i) = 1, \quad \pi_1(i) \geq 0 \quad (2.26)$$

La funció d'avaluació d'estat $V(s')$ combina el balanç de punts de salut normalitzats $hp_k \in [0, 1]$ de tots dos bàndols amb bonificacions posicionals:

$$V(s') = \sum_{k \in \text{propi}} hp_k - w_{\text{opp}} \sum_{m \in \text{rival}} hp_m + B(s') \quad (2.27)$$

on $B(s')$ incorpora les contribucions d'estats alterats, condicions laterals (com *Stealth Rock*) i modificadors d'etapa estadística. A més, es poden incorporar distribucions a priori d'orientació provinents de polítiques heurístiques per esbiaixar la matriu cap a decisions d'alta qualitat.

2.4.3 Cerca de Monte Carlo a l'arrel (shallow MCTS)

L'algorisme de cerca en arbre de Monte Carlo (MCTS) [46, 47] alterna quatre fases iteratives: selecció, expansió, simulació (*rollout*) i retropropagació de la recompensa. En entorns de simulació amb restriccions de temps de resposta com Pokémon Showdown, l'MCTS ras limita la profunditat de construcció de l'arbre a l'arrel ($d = 1$), tractant les accions legals de l'arrel $a_1 \in A_1$ com a braços d'un problema de bandits multi-braç avalats mitjançant trajectòries de k torns executades per una política de referència π_{rollout} .




Figura 2.6: Cicle clàssic de l'MCTS adaptat a simulacions de profunditat rasa a l'arrel ($d = 1$) amb rollouts heurístics.

Per a la selecció de les accions a l'arrel, s'utilitza la puntuació UCB1 (*Upper Confidence Bound*) [46]:

$$\text{UCB1}(j) = Q(j) + C \sqrt{\frac{\ln N}{n_j}} \quad (2.28)$$

on $Q(j) = \frac{1}{n_j} \sum_{i=1}^{n_j} R_i^{(j)}$ és la recompensa mitjana obtinguda per les simulacions del fill j , $N = \sum_k n_k$ és el total de simulacions realitzades a l'arrel, n_j és el nombre de visites al fill j , i $C > 0$ és la constant d'exploració. Quan la cerca es guia mitjançant coneixement de domini, la selecció s'executa mitjançant la fórmula **PUCT** [23]:

$$\text{PUCT}(j) = Q(j) + c_{\text{puct}} \cdot P(j) \frac{\sqrt{N}}{1 + n_j} \quad (2.29)$$

on $P(j)$ representa la probabilitat a priori assignada a l'acció j per una política de referència (com l'heurística 'v14').

2.4.4 Imitació i clonatge conductual

L'aprenentatge per imitació (*behavioral cloning*) aproxima la política d'un agent a partir de la supervisió de trajectòries d'experts humans [48, 49]. Donat un conjunt de dades de parelles observació-acció $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$ extretes de partides de competició d'alt nivell (on $x_i = \phi(o_i) \in \mathbb{R}^d$ és el vector de característiques de l'estat i $y_i \in \{1, \dots, K\}$ és la decisió de l'expert), el model aprèn a maximitzar la probabilitat assignada a les accions humanes optimitzant la pèrdua de crosse-entropia multiclasse:


$$\mathcal{L}_{\text{BC}}(\theta) = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K \mathbb{I}(y_i = k) \ln P_{\theta}(Y = k | x_i) \quad (2.30)$$

En algorismes basats en arbres de decisió augmentats per gradient (XGBoost) [38], aquesta funció d'objectiu s'aproxima a cada iteració t mitjançant un desenvolupament de Taylor de segon

ordre sobre els gradients g_i i Hessians h_i :

$$\mathcal{L}^{(t)} \approx \sum_{i=1}^N \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \Omega(f_t) \quad (2.31)$$

a) Arquitectura Híbrida (Macro-decisió ML + Micro-execució Heurística)



b) Arquitectura Dual Pura (Classificació directa de Tipus i Objectiu)




Figura 2.7: Comparació estructural entre l'arquitectura d'imitació Híbrida (macro-decisió ML + micro-execució heurística) i l'arquitectura Dual Pura (dos classificadors XGBoost especialitzats).

Tal com s'esquematitza a la Figura 2.7, l'arquitectura d'imitació es pot estructurar en dos enfocaments principals:

1. **Sistema Híbrid (Figura 2.7a):** Un model de classificació tabular $f_{\text{macro}}(x)$ decideix la macro-acció d'atacar o canviar, delegant la selecció micro de l'atac o el Pokémon concret a un executor heurístic de domini.
2. **Sistema d'Imitació Dual Pur (Figura 2.7b):** Dos models de classificació separats avaluen de manera directa i end-to-end tant el tipus d'acció (f_{type}) com la ranura de moviment o substitut (f_{target}).

2.4.5 Aprenentatge per reforç profund amb emmascarament d'accions

L'aprenentatge per reforç autònom [29] optimitza la política $\pi_{\theta}(a | o)$ directament mitjançant la interacció amb l'entorn i la maximització del retorn esperat. En entorns de decisió amb restriccions de legalitat variables com Pokémon, l'algorisme MaskablePPO [1, 39] combina l'optimització d'actor-crític amb un emmascarament binari d'accions legals $M(a) \in \{0, 1\}$.

Per evitar que la xarxa neural assigni probabilitat a accions il·legals (com moviments sense PP, Pokémon debilitats o canvis invàlids), la distribució de probabilitats s'obté mitjançant el **Softmax emmascarat**:

$$P_{\theta}(a | o) = \frac{M(a) \exp(z_a)}{\sum_{a' \in A} M(a') \exp(z_{a'})} \quad (2.32)$$

on z_a representa el *logit* brut de l'acció a emès per la xarxa neural d'actor.

L'objectiu de política retallat de PPO s'expressa com:

$$\mathcal{L}^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (2.33)$$

on $r_t(\theta) = \frac{\pi_\theta(a_t|o_t)}{\pi_{\theta_{\text{old}}}(a_t|o_t)}$ és la raó de probabilitats i $\hat{A}_t$ és l'estimador d'avantatge generalitzat (GAE). L'optimització conjunta de la xarxa d'actor i de la xarxa de valor minimitza la pèrdua total d'Actor-Crític:

$$\mathcal{L}^{\text{PPO}}(\theta, \phi) = \hat{\mathbb{E}}_t \left[\mathcal{L}_t^{\text{CLIP}}(\theta) - c_1 \left(V_\phi(o_t) - V_t^{\text{targ}} \right)^2 + c_2 \mathcal{S}[\pi_\theta](o_t) \right] \quad (2.34)$$

on V_ϕ és la funció de valor aproximada, $c_1, c_2 > 0$ són coeficients de ponderació i $\mathcal{S}[\pi_\theta]$ és la bonificació d'entropia per afavorir l'exploració.




Figura 2.8: Comportament de la funció d'objectiu retallada de PPO $\mathcal{L}^{\text{CLIP}}$ en funció de la raó de probabilitats $r_t(\theta)$ quan l'avantatge és positiu ($\hat{A}_t > 0$).

A més de l'emascament d'accions binari $M(a)$, l'entrenament DRL d'aquest treball incorpora dos mecanismes clau per estabilitzar la convergència: el disseny de recompenses denses (*reward shaping*) basat en diferències de salut i debilitaments ($\Delta r_t = R_{\text{terminal}} + \gamma \Phi(s_t) - \Phi(s_{t-1})$), i la inicialització guiada de la política (*warm-start*) mitjançant el pre-entrenament per clonatge conductual sobre 400 partides expertes.

2.5 Síntesi del marc teòric

Aquest capítol ha integrat les mecàniques del combat Pokémon, la seva formalització matemàtica com a POSG/POMDP i els fonaments algorítmics dels cinc paradigmes de decisió estudiats. Aquesta articulació teòrica i el marc d'inferència estadística definit constitueixen el fonament directe sobre el qual s'estructura el **Capítol 3 (Metodologia)**, on es detallen el disseny experimental, l'enginyeria de característiques i la infraestructura de simulació.

Capítol 3

Metodologia i disseny experimental

Aquest capítol defineix *què* es vol comparar, *per què* s'organitza d'aquesta manera i *com* es valida cada idea. La traducció d'aquest disseny a components de programari es reserva per al Capítol 5; els resultats són al Capítol 6.

3.1 Disseny general de l'estudi

El disseny parteix d'una separació deliberada entre **la idea experimental** i **la seva implementació**. En aquest capítol es defineixen les responsabilitats, les comparacions i els criteris de validació sense dependre dels noms concrets dels fitxers o de les classes. El Capítol 5 explica com aquestes decisions es tradueixen a Python, Showdown, processos i artefactes de dades.

3.1.1 Aïllar la decisió durant el combat

La primera decisió metodològica és estudiar Random Battle. Si cada agent constrúís el seu propi equip, el resultat combinaria dues capacitats: seleccionar l'equip i jugar-lo. En canvi, Showdown genera els equips i permet centrar l'anàlisi en la política de combat. Tots els paradigmes reben observacions del mateix tipus i han de retornar una acció legal: moviment, canvi o moviment amb Teracristal · lització.

La unitat d'anàlisi és una batalla acabada. El resultat principal és binari, però el disseny també exigeix conservar informació sobre el procés de decisió: torns, HP final, membres restants, canvis, Teracristal · lització, moviments de preparació, perills d'entrada, errors i intervencions dels mòduls de cerca o aprenentatge.

3.1.2 Idea d'un gestor de batalles

Una matriu de centenars d'enfrontaments no es pot tractar com una successió manual de scripts. Abans d'escollir cap tecnologia concreta es defineix un **gestor de batalles** amb sis responsabilitats conceptuals:

1. construir la llista d'enfrontaments entre agents;
2. crear els dos participants amb una interfície comuna;
3. assignar-los un simulador disponible;
4. executar un nombre objectiu de batalles sense barrejar l'estat entre partides;
5. persistir cada resultat i la seva telemetria tan aviat com estigui disponible;
6. reprendre una execució interrompuda sense repetir les partides ja registrades.

Aquest disseny condueix naturalment a separar coordinació, simulació i persistència. També permet canviar la política sense reescriure l'avaluació: el gestor no necessita saber si l'acció prové d'una fórmula, d'una cerca, d'XGBoost o d'una xarxa neuronal.




Figura 3.1: Disseny conceptual de l'estudi. La mateixa infraestructura avalua polítiques diferents i retorna dades tant del resultat com del comportament. El PPO comparteix simulador, però no entra a la matriu 28×28 .

3.2 Disseny incremental dels agents

3.2.1 Heurístiques com a seqüència d'hipòtesis

La idea de v1–v14 no és produir catorze agents independents, sinó construir una seqüència de preguntes. Es comença amb el criteri més simple que pot jugar —potència, efectivitat i STAB— i s'afegeixen blocs de coneixement quan la versió anterior mostra una limitació:

1. **Dany i ordre immediat:** estadístiques, clima, terreny, modificadors i prioritat.
2. **Posició:** valorar l'enfrontament i decidir quan és millor canviar que atacar.
3. **Control del ritme:** reservar moviments de preparació i perills d'entrada per a torns segurs.
4. **Mecàniques del format:** utilitzar la Teracristal · lització i escollir el substitut després d'un debilitament.
5. **Model de l'oponent:** moviments revelats, patrons de canvi, sondeig inicial i resolució de finals.

Cada bloc expressa una hipòtesi sobre què falta a l'agent anterior. No totes les versions canvien un únic factor i, per tant, la seqüència és una ablació pragmàtica, no un experiment factorial perfecte. La regla metodològica és conservar les versions anteriors i avaluar-les sota el mateix conjunt d'oponents; així una millora aparent pot ser contrastada amb enfrontaments directes i telemetria.




Figura 3.2: Genealogia de disseny, no una ordenació de força. v7 reescriu el nucli; minimax, MCTS i imitació parteixen de v14 com a fulla, prior o executor. PPO clona v8 i s'avalua contra v12.

3.2.2 Minimax i MCTS com a extensió de la política base

Després de construir una heurística rica, la pregunta deixa de ser «quina regla falta?» i passa a ser «mirar endavant corregeix la decisió?». Es dissenyen dues famílies:

- **Minimax d'un torn:** enumerar accions pròpies i respostes rivals plausibles, i protegir-se del pitjor resultat immediat.
- **MCTS ras:** distribuir un pressupost fix de simulacions entre les accions legals i estimar-ne les conseqüències durant diversos torns.

En tots dos casos es comparen variants menys guiades amb variants que conserven un prior heurístic. Aquesta decisió és central: permet mesurar si la cerca substitueix coneixement útil o si funciona millor com a mòdul residual. Per això no n'hi ha prou amb la taxa de victòries; també es dissenya la mètrica de *discrepància*, que compta quan la cerca escull una acció diferent de la política base.

3.2.3 Imitació jeràrquica

Les repeticions humanes proporcionen l'acció observada, però l'índex d'una acció no té una semàntica estable entre Pokémon. El disseny separa, doncs, dues escales:

1. una política d'alt nivell aprèn si convé mantenir-se al camp o canviar;
2. un executor escull quin moviment o quin membre de l'equip materialitza la decisió.

Es comparen un executor heurístic i un executor basat principalment en atributs apresos. El contrast no només pregunta si XGBoost classifica bé, sinó si una decisió imitada continua sent útil quan l'agent arriba a estats que no apareixen a les demostracions.

3.2.4 PPO com a currículum amb validacions

Entrenar directament contra l'agent més fort produeix una recompensa escassa i pot impedir que la política aprengui fins i tot les convencions bàsiques de l'espai d'accions. El disseny de PPO adopta un currículum de dificultat creixent. Cada fase té un objectiu pedagògic i una avaluació separada de l'entrenament:

Taula 3.1: Disseny del currículum PPO. Els llistats són criteris previstos per avançar; el compliment real es presenta als capítols d'implementació i resultats.

Fase	Oponent	Objectiu conceptual	Validació	Llindar
1	Random	Aprendre legalitat, finalització de batalles i avantatge sobre una política aleatòria.	1.000 partides	$\geq 90\%$
1.5	MaxBP	Superar una política ofensiva simple basada en potència.	1.000 partides	$> 70\%$
2	v8	Incorporar decisions posicionals amb clonatge inicial i reforç posterior.	1.000 partides	$> 55\%$
3	v12	Mesurar la distància respecte de l'heurística de referència més forta.	10.000 partides	50% com a paritat

La taxa observada durant l'entrenament no és el criteri final, perquè prové d'una política que canvia i d'una finestra temporal dependent. Després de cada fase es congela un model i es juga una mostra d'avaluació. Si no s'assoleix un llindar, metodològicament la fase no queda «superada», encara que es pugui continuar l'experiment per diagnosticar el següent oponent. Aquesta distinció és important a la fase 2.




Figura 3.3: Currículum PPO previst. Cada fletxa és una porta de validació independent de la corba d’entrenament. La fase 2 no supera el llindar; la fase 3 es fa igualment com a mesura contra v12.

3.3 Contracte de comparació

Perquè els resultats siguin interpretables, el disseny fixa les condicions comunes següents:

- un únic format, `gen9randombattle`;
- equips generats pel servidor i sense construcció prèvia;
- una interfície d’accions equivalent per a tots els agents;
- fitxers dirigits per observar les dues orientacions;
- taxa de victòries com a mètrica primària i telemetria com a mètrica explicativa;
- 10.000 partides per cel · la com a valor general i 1.000 quan intervé MCTS pel seu cost;
- PPO com a experiment separat contra v12, sense fingir que forma part de la matriu 28×28 .

L’observació conceptual inclou l’equip propi, el rival revelat i l’estat del camp; no inclou la configuració rival encara oculta:

Component	Informació disponible
Equip propi	HP, estadístiques, objecte, habilitat, modificadors, PP i condició d’estat.
Rival	Espècies revelades, percentatge d’HP, tipus, moviments utilitzats i efectes visibles.
Camp	Clima, terreny, perills d’entrada, pantalles, <i>Trick Room</i> i ús de la Teracristal · lització.
Informació oculta	Moviments no revelats, ordre complet de l’equip rival i objecte o habilitat fins que es manifesten.

Taula 3.2: Informació conceptual disponible per a la presa de decisions.

3.4 Justificació de la mida mostral

La mida mostral es fixa a partir de la precisió desitjada i del cost computacional. Cada batalla es tracta com una observació independent; aquesta hipòtesi és raonable perquè cada combat genera equips i aleatorietat nous, però no s’han reutilitzat llavors ni equips aparellats entre agents.

3.4.1 Cada batalla és un Bernoulli

El resultat és binari: $W_i \in \{0, 1\}$ indica si ha guanyat l’agent de la fila. Sigui $p = \mathbb{E}[W]$. L’estimador $\hat{p} = n^{-1} \sum_i W_i$ té, sota independència,

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n} \leq \frac{1}{4n}. \quad (3.1)$$

Per planificar la mostra s'utilitza l'aproximació normal del marge al 95%:

$$m_{95} \approx 1,96 \sqrt{\frac{p(1-p)}{n}}. \quad (3.2)$$

El cas de màxima variància és $p = 0,5$:

$$m_{95,\max} = 1,96 \sqrt{\frac{0,25}{n}}. \quad (3.3)$$

Als resultats s'utilitza l'interval de Wilson [35]; amb $n \geq 1.000$, les diferències respecte de l'aproximació anterior són petites. La substitució directa en el cas de màxima variància dona:

- $n = 10.000$: $1,96 \sqrt{0,25/10.000} = 0,0098 \rightarrow \pm 0,98$ punts percentuals.
- $n = 1.000$: $\approx 0,0310 \rightarrow \pm 3,10$ pp.
- $n = 100$: $\approx \pm 10$ pp.

Taula 3.3: Precisió aproximada al 95% en el cas de màxima variància ($p = 0,5$). La segona columna és el marge d'una proporció; la tercera, el marge de la diferència entre dues proporcions independents amb el mateix n . Són càlculs de planificació, no una anàlisi de potència.

n	Marge d'una TV	Marge d'una diferència	Ús en aquest TFM
100	$\pm 9,80$ pp	$\pm 13,86$ pp	Prova de funcionament
1.000	$\pm 3,10$ pp	$\pm 4,38$ pp	Cel · les amb MCTS i validació PPO
5.000	$\pm 1,39$ pp	$\pm 1,96$ pp	No utilitzat
10.000	$\pm 0,98$ pp	$\pm 1,39$ pp	Cel · la final per defecte
20.000	$\pm 0,69$ pp	$\pm 0,98$ pp	No utilitzat

Per comparar dues taxes independents properes al 50%, l'error estàndard de la diferència és $\sqrt{2 \cdot 0,25/n}$. Amb 10.000 partides per agent, el marge aproximat del 95% per a la diferència és 1,39 pp; una diferència observada de 2 pp és, per tant, potencialment distingible. Amb 1.000 partides, el marge augmenta fins a 4,38 pp. Aquest càlcul és una aproximació de precisió, no una anàlisi de potència completa ni una correcció per comparacions múltiples.

3.4.2 El Pokédex no entra a la variància

$\text{Var}(\hat{p})$ depèn de p i n , no directament de la mida de la Pokédex ni del nombre de configuracions. El protocol no pretén enumerar totes les combinacions: estima l'esperança de W sota la distribució amb què Showdown genera equips i aleatorietat. Sota la hipòtesi d'independència i distribució idèntica, la llei dels grans nombres justifica la convergència de $\hat{p}$.

La composició de l'equip, els cops crítics, els errors, els empats de velocitat i les tirades de dany contribueixen conjuntament a la variància del resultat binari. No cal modelar-les per separat per estimar un interval sobre la taxa marginal de victòries, però sí que serien necessàries per explicar causalment una decisió concreta.

3.4.3 Tres nivells de mostra

Durant el desenvolupament s'usa una escala de tres pisos. Als resultats de tesi entren el segon i el tercer.

Prova de fum ($n = 100$). Comprova que el codi s'executa, que la Teracristal · lització s'activa i que el procés escriu el CSV. El marge és d'uns ± 10 pp i, per tant, aquest nivell només s'utilitza per verificar la implementació.

Validació ($n = 1.000$). El marge màxim per a una proporció és $\pm 3,1$ pp. És la mida de les cel·les amb MCTS, condicionada pel cost de simulació, i de les avaluacions intermèdies del currículum PPO.

Avaluació final ($n = 10.000$). El marge màxim per a una proporció és $\pm 0,98$ pp. És la mida per defecte de la matriu i de l'avaluació PPO contra v12.

3.4.4 Matriu experimental: 784 fitxers CSV

Taula 3.4: Famílies d'agents del disseny experimental. La llista completa de 28 identificadors es reutilitza als resultats (Taula 6.1). El PPO queda fora d'aquesta matriu.

Família	Identificadors	n	Funció
Referències	random, max_power, one_step, safe_one_step, abyssal, simple_heuristic	10.000	Controls i oponents de currículum.
Heurístiques	v1–v14	10.000	Ablació de coneixement.
Minimax	v15–v17	10.000	Cerca analítica d'un torn sobre v14.
MCTS ras	v18–v20	1.000	Simulació rasa; el cost limita n .
Imitació	v21, v22	10.000	Política humana d'alt nivell i executor.
PPO	model A (MaskablePPO)	10.000 vs v12	Experiment separat, no fila de la matriu.

Directori: data/benchmarks/all_10k/gen9randombattle.

- 28 agents (Taula 6.1): 6 agents de referència, v1–v14, v15–v17, v18–v20, v21 i v22.
- Matriu dirigida $28 \times 28 = 784$ fitxers {agent}_vs_{opponent}.csv. La fila correspon a l'agent del camp heuristic del CSV.
- **Cel·la per defecte: 10.000 partides.**
- **Si qualsevol dels dos bàndols és v18, v19 o v20:** $n = 1.000$. Cada decisió de cerca executa 100 simulacions de cinc torns amb LocalSim; el cost per partida és molt superior al d'una heurística.
- Cada fila no MCTS agrega $25 \times 10.000 + 3 \times 1.000 = \mathbf{253.000}$ partides.
- Cada fila MCTS agrega $28 \times 1.000 = \mathbf{28.000}$ partides.
- En total, la matriu conté $625 \times 10.000 + 159 \times 1.000 = \mathbf{6.409.000}$ batalles dirigides.

Les mitjanes globals de les files MCTS i no MCTS no estimen exactament la mateixa quantitat. A les files no MCTS, els tres oponents MCTS pesen una desena part que els altres oponents; a les files MCTS, tots els oponents tenen el mateix pes. Per comparar paradigmes s'utilitzen, per tant, enfrontaments comuns, especialment el resultat contra v12, i no una ordenació única de les mitjanes globals.

3.4.5 Orientacions recíproques i autojoc

El disseny genera `A_vs_B.csv` i `B_vs_A.csv` com a mostres independents, de manera que cada agent ocupa les dues orientacions del programari. Si no hi ha un efecte sistemàtic de l'orientació, la suma de les dues taxes s'espera propera al 100%; l'autojoc s'espera proper al 50%. Són controls de coherència, no partides aparellades amb els mateixos equips o les mateixes llavors.

3.4.6 La taxa global de victòries i l'Elo

La mitjana sobre 28 oponents inclou agents molt febles, autojoc i dues etiquetes que comparteixen implementació (`one_step` i `safe_one_step`). Per aquest motiu és una descripció de la matriu, no una mesura absoluta de força. Les comparacions principals utilitzen Abyssal, Simple Heuristic i `v12-v14`. El model Bradley–Terry (secció 3.6) resumeix els resultats en una escala ancorada a `random = 1000`, però també queda condicionat per la composició i el nombre de partides de la matriu.

3.4.7 Ladder humana

La classificació pública de `v14` és un protocol separat, no una fila de la matriu. Utilitza el mateix format contra persones, però els oponents no es mostregen ni es controlen com en l'avaluació local. La mostra complementa la validesa externa i no substitueix la lliga agent-contra-agent.

3.5 Espais formals

En els agents no neuronals hi ha fins a quatre moviments i cinc canvis legals; la Teracristal · lització es tracta com un modificador d'un moviment. L'observació combina el JSON de `request` amb l'historial d'informació revelada. El model PPO publicat utilitza un vector de 328 dimensions i un espai `Discrete(14)`; una extensió experimental posterior amplia l'observació a 346 dimensions. El model d'imitació utilitza 1.150 característiques tabulars.

Taula 3.5: Com cada paradigma representa observació i acció. El contracte extern (Showdown) és el mateix; canvia la representació interna.

Paradigma	Observació interna	Acció interna
Heurístiques / minimax	Objectes <code>Battle</code> de <i>poke-env</i> : actiu, banc, camp i historial revelat.	Argmax sobre moviments, canvis i Tera com a modificador.
MCTS ras	El mateix, més un estat determinat per a <code>LocalSim</code> .	UCB/PUCT sobre els fills de l'arrel; s'envia l'acció més visitada.
Imitació	1.150 característiques tabulars per a atacar/canviar; l'executor veu l'objecte <code>Battle</code> .	Binari d'alt nivell + moviment o canvi concret.
PPO	Vector de 328 (o 346 a la prova interrompuda) floats en $[0, 1]$.	Enter $0 \dots 13$ emmascarat.

3.6 Mètriques

3.6.1 Mètrica primària: taxa de victòries

$\widehat{TV} = \hat{p}$, amb interval de Wilson del 95% [35]. La interpretació es basa en l'interval i en la mida de l'efecte, no només en si el valor puntual supera el 50%:

- Un interval que inclou el 50% no aporta evidència suficient d'avantatge en aquell enfrontament.

- 55–60% contra un agent de referència fort com Abyssal: avantatge rellevant.
- 98% contra **random**: no discrimina entre agents competents.

Per al PPO, el comparador és **v12**. Un resultat per sota del 50% quantifica la distància respecte d'aquest oponent concret; no permet inferir directament la posició del PPO contra els altres 27 agents.

3.6.2 Mètriques secundàries i telemetria

El CSV de batalla conté identitat, HP final, canvis voluntaris i forçats, cops crítics, errors, efectivitat i comptadors específics:

- Heurístiques: perills d'entrada, preparació, comprovacions de debilitament, canvis segons l'enfrontament i Teracristal · lització.
- Cerca: moviments, canvis i discrepàncies respecte de **v14**. La taxa de discrepància divideix les accions diferents de la proposta heurística pel nombre de decisions resoltes per la cerca.
- Imitació: decisions d'atacar o canviar, probabilitat acumulada i activació de les proteccions tàctiques.

Aquestes columnes permeten descriure quan intervé cada mòdul, i no només el resultat final.

3.6.3 Elo Bradley–Terry

S'ajusta un model Bradley–Terry de comparacions per parelles [36] sobre la matriu dirigida i se'n transforma l'escala perquè **random** = 1000, seguint una interpretació de tipus Elo [37]. És un resum descriptiu de la matriu, diferent de l'Elo de la classificació pública. Com que no s'han calculat intervals de confiança per a aquestes puntuacions, diferències petites o valors arrodonits iguals no s'interpreten com a empats estadístics.

3.7 Protocols específics i abast

3.7.1 Matriu de 28 agents

La taxonomia (Taula 6.1) cobreix agents de referència, heurístiques, minimax, MCTS i imitació. El format és **gen9randombattle**. Cada parella (A, B) genera dos fitxers dirigits independents.

Els agents de referència són **random**, **max_power**, **one_step/safe_one_step** —dues etiquetes de **SafeOneStepPlayer**—, **abyssal** i **simple_heuristic**. La duplicació es conserva per traçabilitat dels experiments, però es té en compte en interpretar agregats.

3.7.2 Agents LLM (PokéChamp i PokéLLMon)

PokéChamp [43, 44] i PokéLLMon [42] es van considerar com una possible família addicional. La prova local va mostrar un cost aproximat de 40 minuts per partida en la configuració disponible, incompatible amb una cel · la de 10.000 partides. Per coherència mostral, es classifiquen com a prova d'integració i no com a sisè paradigma quantitatiu. El detall tècnic de la integració és al Capítol 5.

3.7.3 PPO contra v12

Experiment separat, mateix simulador. Disseny:

- Observació vectorial de l'estat parcial i espai discret emmascarat: 4 moviments, 4 moviments amb Teracristal · lització i 6 posicions d'equip.
- Seqüència d'entrenament: Random $\rightarrow$ MaxBP $\rightarrow$ v8 $\rightarrow$ v12. La fase contra v8 no va assolir el llindar de graduació previst; es documenta com una rampa incompleta.
- Inicialització: clonatge conductual (*behavioral cloning*) des de v8 (400 partides) abans del PPO.
- Avaluació final: contra v12, $n = 10.000$, ambdues orientacions. Control de coherència contra Random a $n = 1.000$.

v12 s'escull perquè és l'agent amb millor resultat observat a la matriu. Aquesta decisió produeix una prova exigent, però no situa el PPO dins d'una classificació completa.

3.8 Amenaces a la validesa i reproductibilitat

- **Comparabilitat computacional.** Els cinc paradigmes comparteixen simulador i format, però no pressupost: l'MCTS utilitza menys partides i el PPO no participa en la matriu. Els resultats comparen sistemes complets sota aquests límits, no la capacitat teòrica màxima de cada algorisme.
- **Selecció de variants.** Es proven diverses versions dins de cada família i se'n destaca la millor observada. Aquesta selecció posterior pot afavorir el màxim mostrat; caldria una nova mostra o múltiples llavors per estimar-ne el rendiment fora de la selecció.
- **Ablacions imperfectes.** Algunes versions heurístiques introdueixen més d'un canvi. Una diferència de taxa es pot associar al bloc incorporat, però no atribuir causalment a una única regla.
- **Independència i aparellament.** Les batalles es tracten com a independents. No s'han reutilitzat equips i llavors idèntics entre agents; un disseny aparellat podria reduir la variància de les diferències.
- **Multiplicitat.** La matriu conté 784 cel·les i nombroses comparacions exploratòries. No s'aplica una correcció familiar de proves; es prioritzen magnituds, intervals i patrons consistents, i s'evita interpretar diferències petites de manera aïllada.
- **Models apresos.** El llindar d'imitació es va seleccionar sobre la partició retinguda que també informa les mètriques del classificador. A més, no hi ha repeticions completes d'entrenament amb diverses llavors per a IL i PPO; la variabilitat d'entrenament queda sense quantificar.
- **Validesa externa.** Les conclusions es limiten a `gen9randombattle`, `poke-env 0.11.x` i les dates dels experiments. La mostra pública de v14 no és controlada i només complementa l'avaluació local.

El codi identifica cada agent mitjançant `AgentFactory`; els resultats de la matriu es desen a `data/benchmarks/all_10k/gen9randombattle`; i els pesos i JSON de PPO es documenten a `src/p05_ppo_drl/RESULTS.md`. Els CSV s'escriuen incrementalment i permeten reprendre una execució. La reproducció exacta també requereix la versió de Showdown, els fitxers de Random Battle i els artefactes de model, que no queden descrits només pel codi font.

3.9 Fases de desenvolupament

1. Heurístiques **v1–v14** com a seqüència d’ablacions.
2. Minimax d’un torn **v15–v17** sobre **v14**.
3. MCTS ras **v18–v20**, amb $n = 1.000$ a les cel·les corresponents.
4. Imitació **v21–v22**: un mateix model de decisió d’alt nivell i dues formes d’execució.
5. Integració exploratòria de PokéChamp i PokéLLMon, seguida de la matriu quantitativa sense aquests agents.
6. PPO: clonatge conductual de **v8**, entrenament per reforç i avaluació contra **v12**.
7. Avaluació separada de **v14** contra persones.

El capítol d’implementació tradueix cada fase a codi. El capítol de resultats manté explícita la mida mostral de cada comparació.

Capítol 4

Entorn de desenvolupament i infraestructura de còmput

La matriu de 784 cel·les i l'entrenament PPO requereixen una màquina estable, accés remot i supervisió d'execucions llargues. Aquest capítol documenta el maquinari, la xarxa, les notificacions i les dependències. El coordinador dels experiments es descriu al Capítol 5.

4.1 Organització del projecte

El desenvolupament s'ha organitzat amb un tauler Kanban dividit en objectius, tasques pendents, treball en curs i tasques completades. Cada targeta representa una unitat verificable, com una versió heurística, un agent de cerca, un entrenament o una secció de la memòria.

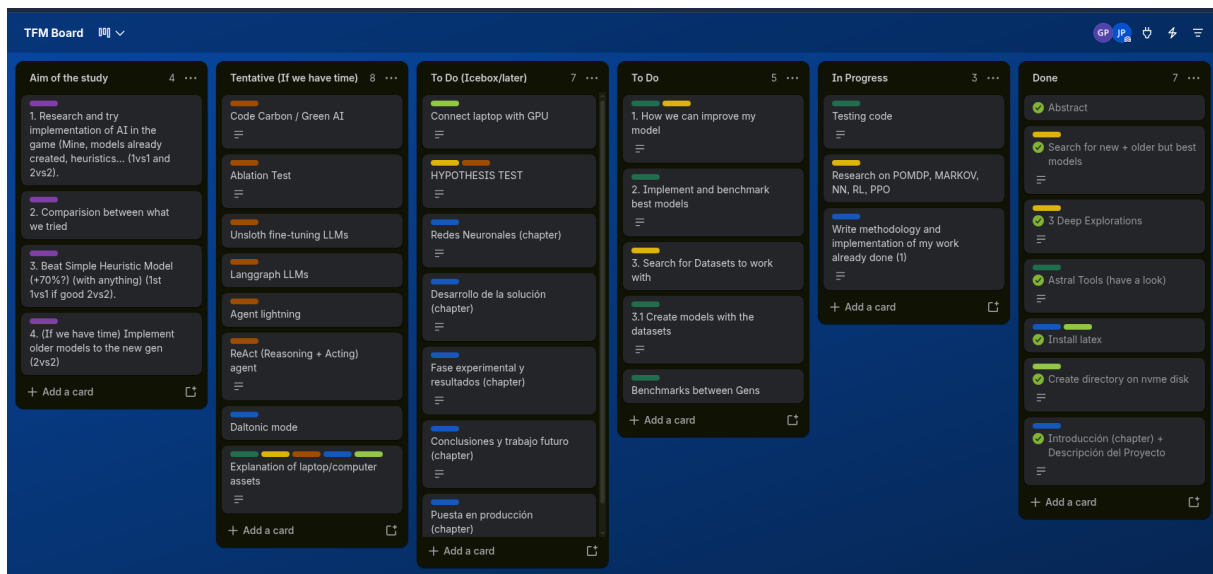


Figura 4.1: Tauler Kanban utilitzat per organitzar el desenvolupament del TFM.

4.2 Evolució de l'arquitectura

4.2.1 Fase 1: prototipatge en portàtil

El prototip va córrer en un Intel Core Ultra 7 155H (22 fils) amb 16 GB de RAM. Un disc NVMe d'1 TB dedicat a `data/` es va muntar amb `bind mount`. Amb 16 GB, múltiples Showdown + Python obligaven a `gc.collect()`, chunks petits i reinicis de Node.js: aquestes rutines neixen d'aquesta fase.

4.2.2 Fase 2: estació de treball

Els experiments finals s'executen en una torre amb AMD Ryzen 7 5700X3D (8 nuclis i 16 fils, 96 MB de memòria cau L3), 32 GB DDR4 i una GPU NVIDIA RTX 2080 de 8 GB. La matriu d'heurístiques, minimax, MCTS i imitació utilitza principalment la CPU. La GPU s'empra per a MaskablePPO i les proves amb models de llenguatge. El sistema i les dades de treball resideixen en una unitat NVMe.

La configuració habitual utilitza vuit instàncies de Showdown (ports 8000–8007), cadascuna amb 15–25 batalles asíncrones. Les cel·les heurístiques es completen molt més ràpidament que les d'MCTS; aquesta diferència de cost motiva els volums de 10.000 i 1.000 partides. L'avaluació PPO contra v12 també utilitza vuit ports.

4.3 Accés remot: Tailscale

El portàtil i la torre formen una xarxa privada amb **Tailscale** [50] (WireGuard). SSH va per aquesta malla, sense obrir el port 22 al WAN. L'editor (Cursor / VS Code) treballa amb Remote-SSH sobre el disc del servidor: el codi, els CSV i els checkpoints PPO viuen a la torre.

Les execucions llargues i els entrenaments PPO s'executen dins de **tmux**; així, una desconnexió del portàtil no interromp el coordinador ni el procés CUDA.

4.4 Bot de Telegram

Els scripts de llançament de `src/p00_core/scripts/runs_benchmark/` i el monitor `src/p00_core/scripts/seguretat_tfm.sh` envien notificacions mitjançant un bot de Telegram [51]. El token s'emmagatzema a `.env` i no es versiona.

Funcions que s'han usat de debò:

- **Avisos de progrés:** inici i final d'un enfrontament, reintents, temps d'espera i partides completades.
- **Supervisió de recursos:** temperatura de CPU i NVMe, ús de memòria i aturada d'emergència a 92°C.
- **Comandes interactives** mitjançant `seguretat_tfm.sh`: consulta de l'estat, resum de la sessió, registres i pausa o represa de l'execució.

Aquesta infraestructura permet supervisar les execucions sense exposar serveis directament a Internet: Tailscale proporciona l'accés remot i Telegram informa del progrés.

4.5 Dependències

El gestor de paquets és **uv** [52] amb Python **3.12** i `pyproject.toml`. Node.js [53] construeix Pokémon Showdown. Resum:

- **Nucli de combat:** `poke-env` ≥ 0.11 , < 0.12 [5]; Node.js [53] per a Showdown.
- **Dades / estadística:** `numpy` [54], `pandas` [55], `polars` [56], `scipy` [57].
- **ML tabular:** `scikit-learn` [58], `XGBoost` [38], Hugging Face Datasets [59].
- **Visualització i notebooks:** `matplotlib` [60], `seaborn` [61], `ipykernel`, `nbconvert`.
- **Utilitats:** `tqdm`, `tabulate`, `orjson`, `requests`, `websockets`.

- **Aprenentatge per reforç (extra rl / gpu):** Gymnasium [62], Stable-Baselines3 [63], sb3-contrib (MaskablePPO) [64], PyTorch [65] i TensorBoard [66].
- **LLM / Pokechamp (extra pokechamp):** Ollama [67], transformers, openai / anthropic / google-genai (backends opcionals), rich.
- **Qualitat:** Ruff [68] (format + lint), ty (tipus).
- **Sistema:** Git/GitHub, tmux, Tailscale [50], Telegram Bot API [51], L^AT_EX (report/).

El fork `pokechamp/` s'incorpora al `sys.path` dels processos que necessiten `LocalSim` o `Abyssal`. Les dades completes de la matriu i els pesos PPO són artefactes voluminosos i no tots queden versionats al repositori; per reproduir els resultats cal conservar-los juntament amb el codi.

4.6 Anàlisi de cost econòmic i pressupost de recursos

El desenvolupament d'aquest Treball de Final de Màster s'ha caracteritzat per una gestió altament eficient dels recursos computacionals, d'infraestructura i de programari. Atès l'elevat volum de batalles de la matriu d'avaluació (més de 6,4 milions) i la durada dels entrenaments, la principal despesa operativa directa s'associa al consum energètic derivat de l'execució ininterrompuda. Aquesta secció desglossa l'anàlisi econòmica i les mesures d'eficiència aplicades.

4.6.1 Desglossament de recursos i optimització de costos

Els costos del projecte es resumeixen en quatre eixos principals:

1. **Maquinari i equips de còmput (0,00 €):** Tant el portàtil de desenvolupament inicial com l'estació de treball principal (AMD Ryzen 7 5700X3D, 32 GB RAM, NVIDIA RTX 2080 8 GB) són equips de propietat personal del desenvolupador utilitzats prèviament per a altres activitats. No s'ha realitzat cap adquisició de maquinari dedicada exclusivament al TFM.
2. **Consum energètic de 24/7 (Y €):** A causa de l'alta complexitat computacional de la matriu d'enfrontaments i la necessitat d'aprofitar al màxim el temps disponible, l'estació de treball va funcionar de manera continuada les **24 hores del dia durant diverses setmanes sense aturar-se**, acumulant un total aproximat de X hores de còmput. La gestió d'aquesta despesa energètica es va estructurar de la següent manera:
 - **Autoconsum solar diürn:** Durant les hores de sol, la instal·lació de **plaques solars domèstiques** va reduir dràsticament el cost energètic cobrint directament la demanda de la torre mitjançant energia renovable gratuïta.
 - **Consum nocturn de xarxa:** Durant les hores nocturnes i períodes sense insolació, el còmput continuat va requerir subministrament directe de la xarxa elèctrica convencional, generant un cost estimat en Y €.
 - **Mode terminal headless:** Per tal de minimitzar el consum de potència (Watts/hora) durant el funcionament 24/7, l'estació de treball es va executar en mode purament terminal (sense entorn gràfic GUI) supervisada mitjançant `tmux`, mantenint actius únicament els processos strictly necessaris.
3. **Models de llenguatge i eines de desenvolupament (0,00 €):** Les proves exploratòries amb models de llenguatge (*PokéChamp* i *PokéLLMon*) es van executar de manera 100% local mitjançant el motor **Ollama**, sense consumir cap API comercial de pagament. Així mateix, l'ús d'eines de desenvolupament basades en IA (Antigravity, Cursor, PyCharm i VS Code) es va realitzar mitjançant llicències d'estudiant/pro, permetent accedir a models LLM d'altres capacitats sense cap despesa econòmica.

4. **Infraestructura de programari i comunicacions (0,00 €):** Totes les eines de la cadena de valor (Pokémon Showdown, *poke-env*, entorn de desenvolupament Python, Tailscale per a la xarxa privada virtual, Telegram Bot API per a la telemetria en temps real, i L^AT_EX per a la redacció) són de codi obert (*open-source*) o s’han utilitzat en les seves modalitats gratuïtes.

Taula 4.1: Resum del pressupost econòmic i costos directes del TFM.

Concepte	Estratègia d’optimització / Font	Cost Directe (€)
Maquinari i equips	Ús d’equips personals preexistents (sense adquisicions noves)	0,00
Consum energètic	Execució 24/7 (setmanes continus, plaques solars de dia / xarxa de nit)	Y
Inferència d’LLMs	Execució local amb Ollama i llicències d’estudiant (Cursor/PyCharm)	0,00
Eines i Infraestructura	Programari de codi obert (<i>open-source</i>) i serveis gratuïts	0,00
Cost Total Directe		Y

Aquesta combinació d’autoconsum solar diürn, optimització de còmput en mode terminal, execució local d’LLMs i llicències d’estudiant ha permès contenir el cost energètic de les setmanes d’execució ininterrompuda 24/7 i completar el projecte de manera altament eficient i sostenible.

Capítol 5

Implementació dels cinc paradigmes

Aquest capítol tradueix la metodologia a programari: el coordinador que permet executar milers de partides, les implementacions de cada paradigma i el flux d'entrenament de MaskablePPO.

5.1 Mapa del programari

- `src/p00_core/engine/`: `benchmark.py` (coordinador) i `worker.py` (procés de treball).
- `src/p00_core/core/`: `BaseHeuristicv1`, `AgentFactory`, matemàtica compartida.
- `src/p01_heuristics/agents/internal/`: `v1.py ... v14.py`.
- `src/p03_minimax/`: `v15-v17`.
- `src/p04_mcts/`: `v18-v20`, `LocalSim` via fork `Pokechamp`.
- `src/p02_imitation_learning/`: `dataset` → `features` → `XGBoost` → `v21/v22`.
- `src/p05_ppo_drl/`: `Gymnasium`, vectorització, clonatge conductual i `MaskablePPO`.
- `src/p00_core/online_bot/`: connector amb la classificació pública.
- `src/p00_core/scripts/`: llançament de benchmarks, `seguretat_tfm.sh` (Telegram) i avisos `avis_telegram` als scripts de `runs_benchmark/`.




Figura 5.1: Mapa de mòduls. p00 aïlla simulació i persistència; p01–p05 només afegeixen la política. Minimax, MCTS i imitació reutilitzen coneixement de p01; PPO té entorn, checkpoints i avaluació propis.

5.1.1 Com es reparteixen les responsabilitats

`p00_core` conté tot allò que ha de ser independent del paradigma: interfície base, fàbrica, instrumentació de la batalla, coordinació, escriptura i informes. Els directoris `p01`–`p05` només contenen la lògica específica de cada família. Aquesta separació evita que una nova versió hagi de conèixer ports, noms de fitxers o recuperació d'errors.

`p01_heuristics` és el nucli de coneixement explícit i també proporciona operacions reutilitzades per les famílies posteriors. `p02_imitation_learning` és un flux de dades complet: descàrrega, exploració, extracció de característiques, entrenament i adaptador de l'agent. `p03_minmax` i `p04_mcts` encapsulen les dues cerques. `p05_ppo_dr1` es manté separat perquè utilitza un entorn d'aprenentatge, checkpoints i un protocol d'avaluació propi.

5.2 Motor de batalla i capa d'integració

5.2.1 Servidor local de Pokémon Showdown

Pokémon Showdown [4] s'executa com un procés Node.js local. Cada instància escolta en un port diferent i manté les sales de batalla en memòria. El llançament bàsic és:

```
node pokemon-showdown start --port 8000 --no-security
```

L'opció `--no-security` elimina l'autenticació en el servidor local. Els clients intercanvien missatges de text per WebSocket. Un missatge `|request|` conté les accions legals i la part observable de l'estat; l'agent respon amb una ordre `/choose`. Showdown resol prioritats, velocitats, dany i efectes aleatoris, i retorna el registre del torn.




Figura 5.2: Intercanvi simplificat entre un agent i una instància local de Showdown.

5.2.2 Adaptació amb *poke-env*

poke-env [5] converteix el protocol textual en objectes `Battle`, `Pokemon` i `Move`. L'únic contracte que ha d'implementar una política és una funció de decisió sobre l'objecte `Battle`. La biblioteca torna a convertir l'acció en una ordre vàlida de Showdown.




Figura 5.3: Flux d'adaptació entre el protocol de Showdown i una política Python.

El projecte fixa *poke-env* a la sèrie 0.11.x perquè tota la matriu es va executar amb aquesta API. El fork *pokechamp/* s'afegeix només als processos que necessiten Abyssal, agents de llenguatge o *LocalSim*. L'estat real de la partida continua vivint al servidor Showdown; *LocalSim* només s'utilitza dins de les simulacions de l'MCTS.

5.3 Arquitectura coordinador–processos de treball

5.3.1 Del BattleManager inicial al motor de la matriu

La primera materialització del gestor conceptual és `core/battle_manager.py`. **BattleManager** rep una versió, un oponent, un servidor, el nombre de partides i la concurrència. Crea els dos jugadors, executa lots amb `battle_against`, extreu victòria, torns, equips, HP i comptadors, i afegeix les files a un CSV. Aquest component va permetre validar el cicle complet amb un únic procés i continua sent útil per a execucions petites.

L'escala final en va mostrar tres límits: un sol intèrpret acumulava memòria, el nom de sortida estava lligat a una execució concreta i la coordinació no construïa ni reprenia tota la matriu. `benchmark.py` i `worker.py` conserven les responsabilitats del **BattleManager**, però les separen: el primer calcula treball pendent i administra recursos; el segon executa un lot aïllat i desapareix. Aquesta evolució explica per què el repositori conté totes dues vies i evita presentar el motor final com una arquitectura decidida sense prototipatge.

5.3.2 Per què subprocessos

Les execucions llargues en un únic procés Python acumulaven objectes **Battle**, estructures de cerca i recursos asíncrons. Per aïllar l'estat i obtenir paral·lelisme de CPU, s'utilitza `multiprocessing` amb el context `spawn`; així s'evita heretar bucles d'esdeveniments i connexions obertes. Cada procés de treball inicia un intèrpret nou, utilitza un port exclusiu de Showdown i escriu un CSV temporal. Quan finalitza, el sistema operatiu recupera els recursos del procés.




Figura 5.4: Arquitectura de la matriu experimental, sense memòria compartida entre processos de treball.

5.3.3 Coordinador, cua de ports i processos efímers

`benchmark.py` materialitza el gestor conceptual del Capítol 3. Primer resol les etiquetes d'agent i oponent, construeix el producte d'enfrontaments i consulta quantes files ja existeixen a cada CSV. Després inicia les instàncies de Showdown i crea una cua asíncrona amb els ports lliures. Cada lot consumeix un port, executa `worker.py` com un procés nou i retorna el port a la cua quan acaba.

`worker.py` instancia els dos agents, juga les batalles asíncrones i converteix cada `Battle` acabada en una fila de telemetria. El procés escriu primer en un fitxer temporal exclusiu del port. El coordinador només fusiona lots acabats; així dos processos no escriuen simultàniament sobre el mateix CSV final.

La matriu final utilitza vuit ports. La concurrència és de 25 batalles per procés per als agents ràpids i de 15 quan intervé minimax o MCTS. Això produeix aproximadament entre 120 i 200 batalles simultànies, però manté separats els espais de memòria Python i les instàncies Node.js.

5.3.4 Represa i escriptura per blocs

Si `v12_vs_abyssal.csv` ja té 4.320 files, el coordinador calcula $n_{\text{to_run}} = 10.000 - 4.320$ i només executa les partides pendents. El CSV és la font de l'estat de progrés. Cada procés treballa en blocs de 25 batalles, escriu els resultats i executa `reset_battles()` i `gc.collect()` abans de continuar.

El cost varia notablement segons el paradigma: les notes de desenvolupament situen les heurístiques al voltant de 0,01–0,1 s per partida i l'MCTS al voltant de 2–6 s. El temps d'espera d'un lot és $\max(7200, 40 \cdot n_{\text{batch}})$ segons, prou ampli per no interrompre una cerca activa i finit per detectar un procés bloquejat.

5.3.5 Reinici de Showdown

En execucions llargues es va observar creixement de memòria al procés V8 de Node.js. El coordinador reinicia les instàncies de Showdown cada N enfrontaments actius, configurable amb `-restart-every`. El motor té un valor per defecte de 3, mentre que el llançador de la matriu final utilitza 20. El reinici sacrifica uns segons de disponibilitat a canvi de limitar l'acumulació de memòria.

5.3.6 Esquema CSV i telemetria emmagatzemada

Cada fila del fitxer de resultats representa l'execució d'una batalla completa. L'esquema final consta de **73 columnes** estandarditzades organitzades en sis blocs funcionals de dades:

1. **Identificadors i metadades:** `battle_id`, `format`, `heuristic` (agent avaluat com a jugadors principals *us*), `opponent` (oponent *opp*), `won` (1 si guanya *us*, 0 si guanya *opp*) i `turns` (durada total en torns).
2. **Resultats i estat final dels equips:** HP residual propi i del rival (`total_hp_us`, `total_hp_opp`), nombre de Pokémon debilitats a cada equip (`self_fainted_count`, `opp_fainted_count`) i integrants restants (`remaining_pokemon_us/opp`).
3. **Accions i control d'execució:** comptadors de canvis voluntaris (`voluntary_switches_us/opp`), canvis forçats per debilitament (`forced_switches_us/opp`), ús de la Teracristal·lització (`terastallized_us/opp`), així com gestió d'excepcions i accions de reserva (`error_moves_us/opp`, `fallback_moves_us/opp`).
4. **Estocasticitat i esdeveniments aleatoris:** comptadors de cops crítics rebuts i infligits (`crits_dealt`, `crits_received`), fallades de precisió (`misses`), efectivitat de tipus




Figura 5.5: Monitoratge durant una execució al prototip de 16 GB. La memòria creix mentre s’acumulen batalles i cau després de reiniciar processos; el patró va motivar els blocs curts, la recollida de memòria i els reinicis de Showdown.

aplicada (*supereffective*) i condicions d’estat imposades (*status_applied*). El mòdul *StatsBattle* intercepta missatges bruts del protocol de Showdown, com ara `|-crit|`, abans que la capa d’alt nivell els descarti.

5. **Mètriques conductuals i de ritme (*tempo*):** comptadors de col·locació i neteja de perills d’entrada (*hazard_sets*, *hazard_removals*), ús de moviments de preparació (*setup_uses*) i comprovacions de debilitament segur (*ko_checks*, *ko_guards*).
6. **Telemetria específica dels paradigmes:** camps especialitzats segons la família d’agent (*search_diff*, *xgb_switches*, *xgb_stays*, *endgame_solves*).

Gestió de columnes opcionals i especificitat per paradigma

Per tal d’evitar la proliferació de fitxers heterogenis o errors d’esquema en posterioritat, el procés de treball (*worker.py*) genera una estructura de diccionari unificada de 73 columnes per a **tots** els agents. Si un camp és específic d’un paradigma concret i no s’aplica a l’agent avaluat, el sistema l’inicialitza per defecte a 0 (o valor buit de seguretat). Aquesta decisió de disseny garanteix que les llibreries d’anàlisi de dades (*pandas* i *polars*) puguin concatenar i analitzar qualsevol dels 784 fitxers CSV de la matriu sense cap excepcions per discrepància de columnes (*schema mismatch*) ni errors de clau absent (*KeyError*):

- **Heurístiques expertes (v1–v14):** Omplen tots els camps generals de nucli (HP, KOs, canvis, Teracristal·lització, crítics, fallades, *fallback_moves*, *error_moves*). Els camps de cerca (*search_diff*) i d’XGBoost (*xgb_stays*) romanen a 0.
- **Cerca adversària Minimax (v15–v17) i MCTS ras (v18–v20):** A més de les columnes de nucli, enregistren activament *search_diff_us/opp* (nombre de torns on la cerca en línia discrepa de l’heurística de base i sobreescriu la seva recomanació), *search_switches_us/opp* (canvis determinats per la cerca) i *endgame_solves_us/opp* (resolucions exactes fins al final de la partida).
- **Aprenentatge per imitació XGBoost (v21–v22 / *ml_advanced*):** A més de les columnes de nucli, enregistren activament *xgb_switches_us/opp* (canvis ordenats pel

cap macro d'XGBoost), `xgb_stays_us/opp` (torns on el model avalua el tauler i decideix romandre actiu) i `xgb_prob_sum_us/opp` (suma acumulada de confiança probabilística).

- **Extracció de la Teracristal · lització (`_is_tera`):** Per mantenir la compatibilitat entre diferents forks de *poke-env* i agents personalitzats, `worker.py` utilitza una funció d'extracció d'atributs universals (`getattr(mon, "terastallized", getattr(mon, "_terastallized", False))`) que evita fallades d'atributs si un agent utilitza una implementació interna diferent.

5.3.7 Automatització de la matriu

`run_paradigm_comparison_10k.sh` defineix les etiquetes de files i columnes i invoca el coordinador per a cada parella. El mateix script adapta el pressupost: 10.000 partides i concurrència 25 per a les famílies ràpides; concurrència 15 per a minimax; i 1.000 partides amb concurrència 15 quan intervé MCTS. També aplica fins a 100 reintents davant d'un lot fallit, reinicia Showdown cada 20 enfrontaments actius i envia avisos de progrés. Aquesta capa és la que converteix el motor genèric en l'experiment concret de 784 cel · les.

5.3.8 Contracte `BaseHeuristic1v1`

S'aplica el patró *Template Method*: `choose_move` crida `_pre_move_hook` per a sortides prioritàries, `_select_action` per a la lògica principal i, si cal, `choose_random_move` com a recurs de reserva. Una excepció incrementa `error_moves` i produeix una acció legal aleatòria, de manera que no bloqueja la batalla.

`AgentFactory.create("v20")` és l'únic punt d'instanciació. La fàbrica també resol àlies històrics: per exemple, `ml_advanced`, `v21` i `v21_xgboost` apunten al mateix agent. Els agents de referència són adaptadors locals de `random`, `max_power`, `simple_heuristic`, `safe_one_step` i `abyssal`. Centralitzar els noms evita que els scripts antics obliguin a duplicar implementacions.

5.4 Heurístiques v1–v14: incorporació de coneixement

La seqüència estudia quins blocs de coneixement s'associen amb canvis de rendiment a Random Battle. La genealogia de codi té branques: `v1`→`v2`→`v3`→`v6`; `v4`/`v5` formen variants laterals; `v7` reescriu l'estratègia, i `v8`–`v14` parteixen d'aquest nucli. Aquesta genealogia no pressuposa una millora monotònica. El diagrama de disseny és la Figura 3.2 del Capítol 3.

5.4.1 Flux de decisió compartit

`BaseHeuristic1v1` proporciona el cicle de vida i els comptadors; `common.py` concentra operacions reutilitzables de tipus, velocitat i estimació de dany. Les versions avançades no copien tot el mètode de decisió: especialitzen els punts d'extensió necessaris.

El flux habitual és:

1. detectar un canvi forçat o una batalla en un estat incomplet;
2. executar dreceres prioritàries, especialment un debilitament segur;
3. construir els candidats de moviment i canvi;
4. assignar una puntuació ofensiva, defensiva i estratègica a cada candidat;
5. decidir si la Teracristal · lització modifica el millor moviment;
6. validar l'ordre i, només si la política no pot retornar-ne cap, utilitzar una acció legal de reserva.

Cada versió afegeix informació a un d'aquests passos. Aquest punt és important: **v12** no és només una fórmula amb més termes, perquè modifica la selecció del substitut i l'ús d'un recurs d'una vegada per partida; **v14** tampoc és simplement **v13** amb un pes diferent, perquè manté estat sobre el comportament rival.

Taula 5.1: Correspondència entre les fases heurístiques i els components implementats.

Versions	Component principal implementat
v1–v6	Estimadors successius de dany, seguiment lleuger de moviments, camp i prioritat.
v7–v8	Nova puntuació de l'enfrontament, canvis voluntaris i immunitats conegudes.
v9–v11	Regles de torn lliure, preparació, perills d'entrada, estats, sacrificis i pivots.
v12	Teracristal · lització ofensiva/defensiva i selecció del substitut per puntuació.
v13	Inferència amb moviments revelats, bloqueig Choice, recuperació i política conservadora.
v14	Perfil persistent del rival, sondeig inicial, rang de dany i resolució de finals.

5.4.2 Evolució de les versions

v8 / v10. **v8** incorpora objectes, habilitats, pantalles i *Trick Room*. **v10** incorpora condicions d'estat, sacrificis amb pocs HP i moviments de pivot.

v9 / v11 (control del ritme). Els perills d'entrada i els moviments de preparació només es valoren en un torn considerat lliure. **v11** combina **v9** i **v10**.

v12 (Gen 9 al camp). Dues peces natives del format:

1. Teracristal · lització ofensiva i defensiva.
2. Selecció del substitut segons l'enfrontament després d'un debilitament, en lloc d'escollir sempre la primera posició.

v12 conserva les regles anteriors i afegeix dues mecàniques específiques de la Generació IX. És l'agent amb la taxa de victòries observada més alta de la matriu, però l'experiment no separa l'efecte de les dues incorporacions.

v13. Valora l'enfrontament amb els **moviments ja revelats** del rival, i no només amb els tipus. També incorpora bloqueig per objectes Choice, expulsió de rivals amb modificadors, recuperació i una política de Teracristal · lització més conservadora.

v14 (orientat a humans). Classifica el rival com a **PREDICTIVE** o **CONSERVATIVE** segons la seva taxa de canvis, i fa sondeig als torns inicials amb moviments com *Protect*, *U-turn* o *Knock Off*. Aproxima el dany amb l'interval $(0,85 \times \text{score}, \text{score})$ i aplica una resolució d'un torn quan queden com a màxim dos Pokémon per bàndol. Aquestes decisions estan orientades a rivals humans i poden cedir ritme contra polítiques deterministes.

Totes les versions registren comptadors. A **v14**, **ko_checks** arriba aproximadament a 15 per partida perquè l'interval de dany s'avalua sovint.

5.5 Minimax d'un torn v15–v17

Els tres agents hereten **HeuristicV14**. Abans de construir la matriu, apliquen dreceres com un debilitament garantit; **v16/v17** també tracten moviments de preparació rivals, absorció d'estats i pivots inicials. Si no hi ha drecera, enumeren les accions pròpies contra moviments rivals revelats i un canvi hipotètic. La velocitat i la prioritat es resolen analíticament; **LocalSim** no intervé.

5.5.1 Construcció de la matriu d'un torn

La implementació crea una fila per cada acció pròpia legal i una columna per cada resposta rival considerada. Les respostes no provenen de l'estat complet de Showdown, que és ocult, sinó dels moviments ja revelats i d'una opció genèrica de canvi quan l'enfrontament és desfavorable. Per a cada parella s'estima:

- quin participant actua primer segons prioritat i velocitat;
- si l'acció ràpida debilita el rival i anul·la la segona;
- els HP esperats després de l'intercanvi;
- bonificacions o penalitzacions de posició.

El valor d'una acció pròpia és el mínim de la seva fila; l'agent escull la fila amb el màxim d'aquests mínims. Aquest càlcul és barat perquè no crea una batalla simulada per cas. També és deliberadament limitat: no veu què succeeix dos torns després d'un canvi o d'un moviment de preparació.

La fulla de **v15** combina HP i qualitat de l'enfrontament, amb una penalització multiplicada per 1,5 per al dany rival. **v16** afegeix bonificacions de 0,25–0,35 per preparació, perills d'entrada, recuperació i estats. **v17** suma 0,15 al pitjor cas de l'acció proposada per **v14**. Tots tres mantenen un horitzó d'un torn.

Per saber què aporta realment el mòdul, abans de la cerca es demana també l'acció que hauria triat **v14**. **search_diff** augmenta quan el maximin la substitueix; **search_moves** i **search_switches** descriuen el tipus d'acció resultant. Com que les dreceres s'executen abans, la matriu intervé en el 16–18% dels torns i no defineix tota la política.

5.6 MCTS ras **v18–v20**

Mateix professor **v14**, mateix pressupost:

- 100 simulacions per torn de cerca, $C = 1,4$.
- **UCB a l'arrel**: cada iteració tria un fill, executa una simulació de cinc torns amb **LocalSim** i actualitza el valor del fill.
- La determinització copia els moviments *revelats* del rival.
- Fills arrel: moviments *i* canvis; es juga l'argmax de visites.

5.6.1 Simulació local i actualització de l'arrel

Per a cada decisió, l'agent copia l'estat observable a **LocalSim**, crea un fill per acció legal i inicialitza-ne visites i valor acumulat. Cada iteració selecciona un fill amb UCB1 o PUCT, aplica l'acció i continua amb una política de simulació durant cinc torns. En acabar, una funció de fulla resumeix HP, membres debilitats, modificadors, estats i camp; aquest valor s'acumula al fill de l'arrel.

No es conserva un arbre profund entre iteracions ni entre torns reals. Per això el cost i la interpretació són els d'un bandit a l'arrel amb simulacions, encara que el mòdul es presenti dins de la família MCTS. La decisió final és l'acció amb més visites, no necessàriament la de valor mitjà més alt.

v18: UCB1, fulla basada en HP, modificadors, estats i perills d'entrada, amb només la drecera de debilitament abans de l'arrel. **v19**: UCB1, fulla amb rols i amenaça de debilitament d'un cop,

i les dreceres tàctiques de **v14** *abans* de l'arbre. **v20**: **v19** + **PUCT** amb prior 0,70 sobre l'acció **v14**.

La determinització només pot copiar moviments rivals revelats. A més, **LocalSim** i el procés **Node.js** de **Showdown** no són el mateix motor. Un objecte o efecte no reproduït exactament pot introduir soroll en els valors. El minimax d'un torn no té aquesta font d'error, perquè només utilitza l'estimador analític compartit.

5.7 Imitació v21–v22

5.7.1 Flux de dades

La implementació es divideix en quatre directoris que corresponen a etapes reproduïbles:

1. **s01_download/** descarrega repeticions i conserva metadades de format i Elo;
2. **s02_eda/** valida distribucions, proporció atacar/canviar i composició del metajoc;
3. **s03_training/** transforma els torns en una matriu tabular, separa per batalla i entrena **XGBoost**;
4. **s04_agent/** carrega els models i converteix-ne la predicció en una acció legal de **Showdown**.

La separació és necessària perquè una repetició no conté directament el mateix objecte que rep l'agent en línia. El procés d'extracció reconstrueix, torn a torn, HP, camp, ús de Tera, identitat dels actius i acció observada. La llista de característiques desada amb el model garanteix que l'agent en producció generi les columnes en el mateix ordre que durant l'entrenament.

5.7.2 Dades

Les dades són repeticions de **gen9randombattle** de jugadors amb Elo ≥ 1800 .




Figura 5.6: Validació exploratòria de les repeticions humanes: desequilibri entre atacar i canviar, evolució de la taxa de canvi amb el torn i espècies més representades. La figura descriu el conjunt de dades, no el rendiment final de l'agent.

La classe «canviar» representa aproximadament el 25,8% dels torns. La taxa és especialment alta al començament —on també hi ha canvis forçats o ajustos de posició— i disminueix amb la durada.

5.7.3 Decisió d'alt nivell

Hereta només de **BaseHeuristicv1**. Si el model decideix canviar, avalua cada candidat com si fos l'actiu i selecciona el que minimitza $p(\text{canvi})$. Si decideix atacar, un segon model (**xgboost_move_evaluator.json**) puntua atributs com potència, STAB, efectivitat, estat




Figura 5.7: Taxa de canvi humana per espècie activa en una selecció del conjunt d'experts. La variació justifica incloure identitat i context, però no implica causalitat.

i prioritat. Aquest segon model s'entrena amb candidats sintetitzats, no amb la identitat dels moviments de les repeticions; per tant, v22 no és un clonatge complet de l'acció humana.

v21 és l'híbrid (macro de dades, micro de v14); v22 executa els dos caps XGBoost.

5.8 Baselines

random i max_power provenen de *poke-env*; simple_heuristic és una còpia local adaptada a la Teracristal · lització, i abyssal prové de PokéChamp. one_step i safe_one_step instancien la mateixa classe, SafeOneStepPlayer; es mantenen com a etiquetes separades per traçabilitat, però no constitueixen dos algorismes diferents.

5.8.1 Integració exploratòria d'agents de llenguatge

src/p01_heuristics/agents/llm/ adapta PokéChamp i PokéLLMon a la mateixa fàbrica. El fork pokechamp/ prepara el context textual de la batalla i envia la consulta a un backend local d'Ollama [67]; la prova es va fer amb un model de la família Qwen [69]. El temps observat, de l'ordre de 40 minuts per partida, impedia executar la matriu. Aquesta integració es conserva perquè va permetre validar la compatibilitat i reutilitzar Abyssal i LocalSim, però no produeix un resultat comparatiu de tesi.

5.9 Bot en línia

run_online_bot.py connecta qualsevol etiqueta d'AgentFactory al servidor públic, en mode de classificació (ladder) o d'acceptació de reptes (accept). La mostra analitzada correspon a v14, usuari SirPThesis, els dies 9 i 10 de juny de 2026, amb 431 partides. Aquesta avaluació no és una fila de la matriu local.

5.10 PPO: MaskablePPO sobre Showdown

src/p05_ppo_dr1/ és el cinquè paradigma, avaluat contra v12 (Capítol 6).

5.10.1 Organització del mòdul i dels artefactes

El mòdul separa tres responsabilitats:

- `s01_env/`: vectorització de l'observació, correspondència entre índexs i ordres, màscara d'accions i recompensa;
- `s02_training/`: bucle comú, scripts de cada fase, clonatge conductual, callbacks, checkpoints i gràfiques;
- `s03_evaluation/`: càrrega d'un model congelat i avaluació contra un oponent fix amb una o dues orientacions.

Els pesos no s'emmagatzemen al codi font, sinó a `data/models/ppo/`. Cada fase té un directori propi (`p1_random`, `p15_maxbp`, `p2_v8`, `p3_v12`); `plots/` conserva hiperparàmetres i corbes, i `eval/` conserva els JSON de les avaluacions. Aquesta separació evita confondre una corba d'entrenament amb el resultat obtingut per un checkpoint congelat.

5.10.2 Entorn

`PokemonMaskedEnv` encapsula `SinglesEnv` de *poke-env* en el format `gen9randombattle`. L'observació és un vector normalitzat que codifica HP, tipus, estat i modificadors de l'actiu; quatre moviments; l'equip propi; part de l'equip rival revelat; clima, terreny i perills d'entrada; disponibilitat de la Teracristal · lització; velocitat; `force_switch` i `trapped`. El model de l'avaluació final té **328** dimensions. Una extensió posterior n'afegeix 18, però correspon a un experiment interromput i no al resultat principal.

Taula 5.2: Composició del vector d'observació de MaskablePPO. El model A publicat té 328 dimensions; les fases 1 i 1.5 n'utilitzaven 318 (sense dany estimat ni enfrontaments de canvi). Les 18 dimensions addicionals de la fase 4 no entren al resultat principal.

Bloc	Dim.	Contingut
Actiu propi / rival	35 + 35	HP, tipus, condició d'estat i set etapes de modificadors.
Moviments	84 + 4 + 4	Tipus i potència dels 4 slots, PP i STAB×efectivitat.
Banc propi i rival	6 × 6 + 1	HP, debilitats, indicador de capdavanter i estimació de supervivents rivals.
Camp	9 + 14 + 24 + 24	Clima, terreny i condicions laterals d'ambdós bàndols.
Teracristal · lització	3 + 20 + 20	Disponibilitat, ús previ i tipus Tera.
Velocitat i restriccions	5	Comparació de velocitat, <code>force_switch</code> i <code>trapped</code> .
Afegits de fase 2	4 + 6	Dany estimat dels 4 moviments i enfrontament dels 6 canvis.
Total model A	328	Vector en $[0, 1]$, compatible amb els checkpoints de les fases 2 i 3.
Extensió de fase 4	+18	Enfrontaments del banc revelat, millor capdavanter, dany/defensa Tera i cost de perills.

L'acció és `Discrete(14)`:

A cada pas es calcula una màscara de legalitat que exclou moviments sense PP, una Teracristal · lització ja consumida i canvis a posicions no disponibles. `PPOPlayer` tradueix l'índex a `/choose`, també durant un canvi forçat.

5.10.3 Clonatge, arquitectura i recompensa

Abans de l'entrenament per reforç, `bc.py` genera tuples (o, m, a) d'observació, màscara i acció a partir d'un professor heurístic. L'ajust aplica entropia creuada emmascarada només a l'actor,

Taula 5.3: Espai d'accions **Discrete(14)** de MaskablePPO. La màscara de legalitat i la traducció a `/choose` comparteixen el mateix mapeig de slots [1].

Índex	Acció	Quan és legal
0–3	Moviment i de l'actiu	El slot té un moviment amb PP i no hi ha canvi forçat.
4–7	Moviment i + Teracristal · litzar	El moviment i és legal i la Tera encara no s'ha consumit.
8–13	Canvi a l'slot i de l'equip	El membre existeix, no està debilitat, no és l'actiu i no hi ha bloqueig de canvi.




Figura 5.8: Pas d'inferència de MaskablePPO. La màscara s'aplica abans de mostrejar; l'índex no s'envia mai directament al servidor, sinó com a ordre de Showdown.

amb un optimitzador Adam propi de taxa 10^{-3} durant 15 èpoques; no reutilitza la taxa molt menor de PPO. A la fase 2 es recullen 400 partides de `v8`, que produeixen 8.849 decisions. L'acord amb el professor passa del 43% al 88%, i la freqüència de canvi predita s'apropa a la del professor (21% davant del 23%). El clonatge no pretén ser el resultat final: situa la xarxa en una regió que ja produeix accions semblants a una política competent abans d'aplicar PPO.




Figura 5.9: Seqüència clonatge → reforç. El crític no s'entrena al clonatge; PPO n'aprèn el valor a partir de la recompensa modelada un cop l'actor ja imita el professor.

MaskablePPO [39, 64, 70] s'executa sobre PyTorch [65]. La política i la funció de valor utilitzen una xarxa de dues capes de 256 unitats. Els scripts registren `n_steps=2048`, $\gamma = 0,99$ i quatre èpoques d'actualització; el lot és de 256 amb quatre entorns i de 512 amb vuit o més. La taxa d'aprenentatge i l'entropia canvien entre fases. El model A publicat utilitza observació de 328 dimensions, vuit entorns i taxa 5×10^{-5} .

La recompensa d'entrenament combina:

- 30 punts per victòria;
- 2 punts per diferència de Pokémon debilitats;
- 1 punt per diferència d'HP;
- increments per modificadors ofensius, condicions d'estat i perills al camp rival;
- penalització pels perills al camp propi;
- un cost de 0,02 per pas per desincentivar episodis innecessàriament llargs.

El codi desa el valor potencial anterior i només afegeix la diferència de la part tàctica, per no tornar a premiar indefinidament el mateix estat. Tot i així, la recompensa modelada defineix l'objectiu d'entrenament i pot introduir preferències diferents de la victòria terminal. Per aquest motiu, l'avaluació final només utilitza victòries i derrotes.

5.10.4 Execució de les fases 1, 1.5, 2 i 3

La Taula 5.4 diferencia el criteri dissenyat, l'avaluació congelada i la decisió presa. Les taxes de les corbes d'entrenament no substitueixen la columna de validació.

Taula 5.4: Implementació i validació del currículum PPO. «Superada» es refereix al llindar previst, no al fet que s'executés una fase posterior.

Fase	Oponent	Canvi implementat	Validació congelada	Decisió
1	Random	PPO inicial, 318 dimensions, 4 entorns, 500k passos.	91,8% a 1.000; llindar 90%.	Superada
1.5	MaxBP	Reprèn fase 1; taxa 2×10^{-4} , 500k passos.	70,5% a 1.000; llindar $> 70\%$.	Superada per estimació puntual
2	v8	Amplia a 328 dimensions, 400 partides de clonatge, 8 entorns.	40,6% a 1.000; llindar $> 55\%$.	No superada
3	v12	Continua des de fase 2 i prova taxes/entorns diferents.	Model A: 34,1% a 10.000.	Mesura final

Fase 1: Random. La política comença sense coneixement estratègic. L'objectiu és verificar que aprèn la legalitat, redueix la durada dels episodis i domina una política aleatòria. L'avaluació de 1.000 partides obté 91,8%, per sobre del 90%, i el checkpoint passa a la fase 1.5.


Fase 1.5: MaxBasePower. El següent oponent sempre busca potència base alta. Exigeix més que Random, però continua sent previsible. Una primera avaluació va quedar en 64,1% i no va superar la porta. L'entrenament es va reprendre sense aturada prematura i el checkpoint posterior va obtenir 70,5%, lleugerament per sobre del llindar. Com que $n = 1.000$ implica un interval ample, aquesta «graduació» s'ha d'entendre com una regla operativa basada en l'estimació puntual, no com evidència d'un marge sòlid.

Fase 2: v8. També s'amplia l'observació de 318 a 328 dimensions per representar millor els enfrontaments de l'equip. Les primeres passades només amb PPO es van mantenir al voltant del 29–30%. Un primer clonatge reutilitzava l'optimitzador de PPO a 5×10^{-5} i gairebé no ajustava l'actor. La versió final separa els optimitzadors, clona 400 partides de v8 amb Adam a 10^{-3} i continua 100.000 passos amb PPO. La taxa d'entrenament puja, però la validació és 40,6%, lluny del 55% previst. Per tant, el currículum **no supera formalment aquesta fase**.


Fase 3: v12. Tot i el resultat anterior, es continua contra v12 per mesurar si l'entrenament directe redueix la distància respecte del millor agent de la matriu. Es proven dues configuracions. El resultat de tesi és el model A, `p3_v12_lr5e5_flat.zip`, amb taxa 5×10^{-5} i vuit entorns. Una passada secundària amb taxa $1,5 \times 10^{-4}$ i setze entorns produeix la corba guardada al directori de fase 3, però no és el punt de control de la xifra de 10.000 partides.

5.11 Desplegament i operativitat en entorn real (Deployment)


El desplegament de l'agent en entorns reals de producció exigeix operar fora de la xarxa local de simulació i interactuar directament amb els servidors oficials públics de Pokémon Showdown (play.pokemonshowdown.com). Aquest mòdul, organitzat a `src/p00_core/online_bot/run_online_bot.py`, implementa l'arquitectura de desplegament operatiu per al funcionament autònom.




(a) Fase 1 contra Random.



(b) Fase 1.5 contra MaxBP.



(c) Fase 2 contra v8.



(d) Passada secundària de fase 3 contra v12.

Figura 5.10: Corbes de les quatre etapes del currículum. Són taxes durant l'entrenament sobre una política canviant; les validacions independents són les de la Taula 5.4. El panell de fase 3 correspon a la passada secundària, no al model A publicat.

5.11.1 Arquitectura del client WebSocket i autenticació

El bot opera com un client asíncronic en Python basat en `websockets` i `asyncio`. El flux d'establiment de sessió segueix el protocol oficial de Showdown:

1. **Connexió al WebSocket públic:** establiment del canal bidireccional amb el servidor d'enfrontaments (`sim3.psim.us:80 / showdown`).
2. **Recepció del desafiament del servidor (*Challstr*):** obtenció del token d'identificació de sessió generat pel servidor Showdown.
3. **Autenticació HTTP POST:** enviament de les credencials de l'agent i del *challstr* a l'API d'autenticació oficial (`play.pokemonshowdown.com/action.php`) per generar l'assertió d'identitat.
4. **Enviament del token d'assertió:** transmissió de l'assertió al WebSocket (`/!trn <username>,0,<assertion>`) per registrar l'usuari (*SirPThesis*).

5.11.2 Gestió d'estat, xarxa i tolerància a fallades

Per tal de garantir l'operativitat continuada en producció sense intervenció humana, el mòdul integra mecanismes de tolerància a fallades:

- **Reconnexió automàtica i recuperació de sessió:** en cas de pèrdua de socket o tall de xarxa, el bot reintenta la connexió mitjançant un algorisme de reescalat exponencial d'espera (*exponential backoff*).
- **Gestió de temps de resposta (*timer*):** la presa de decisions està acotada temporalment per evitar la pèrdua per exhauriment de temps (*timer loss*). Si l'agent no respon en menys de 10 segons, el connector aplica una acció de reserva legal de manera immediata.
- **Control de freqüència (*Rate Limiting*):** aplicació d'esperes entre comandes per complir les polítiques del servidor públic i evitar el bloqueig d'IP (*spam throttle*).

L'agent principal desplaçat al *ladder* oficial va ser **v14**, acumulant 431 batalles reals contra jugadors humans. Aquest entorn de desplegament demostra la capacitat del programari per operar com un servei autònom i de producció.

5.11.3 Avaluació i preservació del model principal

`eval_checkpoint.py` carrega un checkpoint sense actualitzar-lo, l'associa a un `PPOPlayer` i juga en una o dues orientacions. El model A es prova contra **v12** en 10.000 partides i contra Random en 1.000 com a control. El codi impedeix sobreesciure accidentalment el fitxer principal. Els JSON d'avaluació documenten victòries, orientació, durada i interval; algunes validacions intermèdies antigues només es conserven a les notes perquè els noms de JSON es van reutilitzar.

Una extensió posterior amplia l'observació a 346 dimensions i clona **v14** contra **v12**. S'interromp al voltant de 340.000 passos i es presenta només com a diagnòstic. No substitueix el model A ni la seva avaluació final.

Capítol 6

Resultats

Aquest capítol analitza la matriu de 28 agents i l'experiment PPO. Les fonts internes són els 784 CSV de `data/benchmarks/all_10k/gen9randombattle`, els informes de `src/p00_core/reporting/agents/`, `heuristics_and_imitation_thesis_analysis.md` i `src/p05_ppo_drl/RESULTS.md`.

La lectura separa tres nivells. Un **resultat observat** és una taxa o un comptador derivat dels fitxers. Una **interpretació** relaciona diversos indicadors amb el disseny de l'agent. Una **hipòtesi explicativa** proposa què podria haver causat el patró, però requeriria una ablació o una repetició específica per confirmar-se. Aquesta distinció permet explicar els resultats sense convertir una correlació de telemetria en una conclusió causal.

6.1 Protocol de lectura dels resultats

6.1.1 La matriu

28 agents, cadascun com a *nosaltres* contra 28 oponents, format `gen9randombattle`. Fitxers dirigits `A_vs_B.csv`. El PPO es llegeix a part, contra `v12`, a la secció 6.11.

Taula 6.1: Taxonomia dels 28 agents de la matriu `gen9randombattle`. Els identificadors de codi es mantenen en anglès. El prefix del mapa de calor indica la família: (H) heurística, (MM) minimax, (MCT) MCTS, (IL) imitació i (B) agent de referència. El PPO s'avalua separatament contra `v12`.

Identificadors	Paradigma	Descripció
<code>random</code> , <code>max_power</code> , <code>one_step</code> , <code>safe_one_step</code> , <code>abyssal</code> , <code>simple_heuristic</code> <code>v1-v14</code>	Referències (B)	Agents de <i>poke-env</i> i PokéChamp: atzar, potència base, un pas de dany i regles d'enfrontament.
<code>v15-v17</code>	Heurístiques (H)	Seqüència incremental de coneixement: dany, posició, perills d'entrada i Teracristal·lització, entre altres components.
<code>v18-v20</code>	Minimax d'un torn (MM)	Maximin analític d'un torn amb <code>HeuristicV14</code> com a base.
<code>v21</code>	MCTS ras (MCT)	UCB a l'arrel i 100 simulacions de cinc torns amb <code>LocalSim</code> ; cel·les amb $n = 1.000$.
<code>v22</code>	Imitació híbrida (IL)	XGBoost decideix atacar o canviar i <code>v14</code> executa l'acció.
	Imitació (IL)	El mateix classificador d'alt nivell; el model de moviments puntua potència, STAB i efectivitat.

La fila d'una taula o d'un mapa de calor és l'agent analitzat i la columna és l'oponent. Un 59,91 a la cel·la `v12 × Abyssal` indica que `v12` ha guanyat 5.991 de les 10.000 partides d'aquell

fitxer dirigit.

6.1.2 Precisió de les estimacions

Cada partida aporta un resultat binari $W \in \{0, 1\}$. L'equació (3.3) dona el marge màxim aproximat per a una proporció:

$$\pm 1,96\sqrt{0,25/n}.$$

A $n = 10.000$ és $\pm 0,98$ pp i a $n = 1.000$, $\pm 3,1$ pp. Per a la diferència entre dues proporcions independents properes al 50%, els marges aproximats són 1,39 i 4,38 pp, respectivament. Els intervals reportats són de Wilson; aquestes aproximacions serveixen per entendre l'ordre de magnitud.

La mida de la Pokédex no apareix directament a $\text{Var}(\hat{p}) = p(1 - p)/n$. L'objectiu és estimar una taxa marginal sota el generador d'equips de la Generació IX, no cobrir totes les combinacions possibles.

La Taula 3.3 (metodologia) recull els tres pisos. Aquí només cal recordar-los abans de llegir MCTS.

6.1.3 Volum i ponderació

- Una fila no MCTS conté **253.000** partides: 25×10.000 i 3×1.000 contra MCTS.
- Una fila MCTS conté **28.000** partides: 28×1.000 .
- La matriu completa conté **6.409.000** partides dirigides.
- Les orientacions recíproques sumen aproximadament el 100% i l'autojoc se situa prop del 50%, com s'espera en absència d'un efecte sistemàtic de l'orientació.

La taxa global d'una fila no MCTS pondera els oponents MCTS deu vegades menys que la resta; en una fila MCTS tots els oponents pesen igual. Per tant, aquestes taxes globals tenen diferent precisió i diferent ponderació. La comparació entre paradigmes es basa en cel · les comunes, no en una única ordenació global.

Les proves de desenvolupament amb 100 partides no formen part de les conclusions d'aquest capítol.

6.2 Controls globals de la matriu

Abans d'interpretar versions concretes, es comproven la cobertura, la distribució de taxes i la durada de les batalles. Aquests controls detecten cel · les incompletes, errors d'orientació i resultats extrems que podrien dominar una mitjana.

La Figura 6.1 confirma que la reducció de mostra segueix el paradigma i no l'agent que ocupa la primera orientació. Aquesta regularitat és important perquè evita comparar una cel · la MCTS parcial amb una cel · la no MCTS completa.

La distribució no és una campana estreta al voltant del 50%. Hi ha massa a prop dels extrems perquè alguns agents de referència són molt febles i perquè cada cel · la té una orientació recíproca. Aquesta és una altra raó per no interpretar la taxa global com una habilitat absoluta: millorar contra un agent que ja es derrota en el 95–98% de les partides té poc valor discriminant.

La durada complementa la taxa de victòries. Dues polítiques poden guanyar una proporció semblant, però una pot tancar abans mentre l'altra conserva més membres mitjançant canvis i recuperació. La cua drete també fa que la mitjana sigui sensible a bucles o estratègies d'atrició; per això les seccions següents combinen torns, membres restants i motiu dels canvis.




Figura 6.1: Nombre de partides completades a les 784 cel · les. El bloc fosc correspon a 10.000 partides; les files i columnes clares de v18–v20, a 1.000. La creu no és un buit de dades, sinó el pressupost reduït de l'MCTS.




Figura 6.2: Distribució de la taxa de victòries de les 784 cel · les dirigides. El centre prop del 50% conté autojoc i enfrontaments equilibrats; les cues reflecteixen diferències grans, especialment davant de Random i MaxBasePower.




Figura 6.3: Distribució de la durada de les batalles analitzades. La mediana és de 17 torns i hi ha una cua dreta de partides excepcionalment llargues.

6.3 Fil conductor de v1 a v22

La Taula 6.2 resumeix la seqüència abans d’analitzar-la. Les taxes globals són descriptives i no fan comparable l’MCTS amb la resta a causa de la ponderació diferent; la seva funció aquí és mostrar els canvis de règim.

Taula 6.2: Evolució de les preguntes i dels resultats entre v1 i v22.

Versions	Pregunta que materialitzen	TV global	Patró observat
v1–v6	Fins on arriba refinar dany i ordre immediat?	44–46%	Altiplà; telemetria gairebé invariable.
v7, v8, v10	Què aporta valorar la posició i canviar?	54–56%	Salt a v7; afegits posteriors petits.
v9, v11	Preparació i perills només en torns segurs?	59%	Nou augment i aparició dels comptadors de ritme.
v12	Què aporten Tera i el substitut informat?	69,01%	Increment més gran i 59,91% contra Abyssal.
v13, v14	Més inferència i model del rival sempre ajuden?	67,63 / 62,03%	Inversió: més complexitat, menys taxa global.
v15–v17	Un maximin d’un torn corregeix v14?	53,80–57,89%	La variant guiada discrepa menys i és la millor.
v18–v20	Cinc torns simulats superen l’horitzó curt?	53,29–59,66%	PUCT millora UCB1, però no supera v12.
v21, v22	Es pot imitar quan atacar o canviar?	58,71 / 33,49%	L’executor heurístic és determinant.

La primera meitat de la seqüència acumula coneixement explícit fins a v12. La segona canvia de paradigma, però la majoria de decisions encara passen per dreceres o priors derivats de v14. El patró general no és «algorisme més sofisticat, agent més fort», sinó «representació i coneixement adequats, seguits d’un mòdul que no els destrueixi».

PPO no rep un número v23 ni forma part de la taula global. La seva pregunta és paral·lela: si una política neuronal inicialitzada amb v8 pot arribar a v12. El resultat de 34,1% contra aquest comparador es tracta a la secció 6.11.

6.4 L'escala heurística: tres canvis de règim

Taula 6.3: Seqüència heurística v1–v14 (253.000 partides per fila). La taxa global no creix de manera monotònica: els increments principals apareixen a v7, v9 i v12, i les dues versions posteriors disminueixen.

Agent	Règim	TV (%)	contra Abyssal	Incorporació principal
v1–v6	Altiplà	44,25–45,86	30,6–32,5	Dany, clima, modificadors i canvis simples
v7	Posicional	54,25	40,80	Dany modificat i canvi segons l'enfrontament
v8	Posicional	55,43	42,30	Objectes, habilitats, pantalles, Trick Room
v9	Ritme segur	58,86	46,64	Perills i preparació <i>només en torns lliures</i>
v10	Posicional	55,66	41,86	Status, sacrifici $\leq 20\%$ HP, U-turn
v11	Ritme segur	59,26	47,50	Combinació de v9 i v10
v12	Mecànica Gen. IX	69,01	59,91	Tera i selecció del substitut
v13	Moviments revelats	67,63	55,34	Enfrontament amb moviments revelats i Tera conservador
v14	Model de rival	62,03	51,36	Perfil, sondeig inicial, rang de dany i final d'un torn




Figura 6.4: Taxa global de victòries de v1–v14 (253.000 partides per fila; les tres cel·les contra MCTS tenen $n = 1.000$). S'observen canvis destacats a v7, v9 i v12, seguits d'una disminució a v13 i v14.

6.4.1 Altiplà v1–v6: rendiments decreixents del càlcul de dany

La taxa global recorre **1,61 pp** (44,25–45,86%). Els enfrontaments interns se situen prop del 50%, mentre que contra Abyssal obtenen entre el 30,6% i el 32,5%.

En aquestes versions, afinar la fórmula de dany després d'incorporar efectivitat i STAB mostra rendiments decreixents. Els increments posteriors apareixen quan s'afegeixen decisions posicionals i recursos específics del format.

En el subconjunt de cinc oponents utilitzat per a aquesta telemetria (abyssal, v12, v14, v21 i random), registren aproximadament 1,04 canvis voluntaris per partida, cap Teracristal·lització i uns 4,3 recursos de reserva. Aquest perfil correspon a una política principalment ofensiva amb poca gestió posicional.

6.4.2 Primer salt: v7 (i v8/v10)

v7 incorpora dany amb modificadors i canvis segons l'enfrontament. La taxa global passa d'aproximadament 45,5% a **54,25%**; contra Abyssal, d'aproximadament 32% a **40,8%**.

v8 (objectes, habilitats, pantalles i *Trick Room*) afegeix 1,2 pp. v10 (estats, sacrificis i moviments de pivot) obté una taxa similar a v8 (55,66% i 55,43%).

La telemetria també canvia: els canvis voluntaris pugen a 1,47 per partida, `matchup_switches` arriba a 0,41 i les accions de reserva baixen d'aproximadament 4,6 a 2,18. L'agent passa a seleccionar canvis de manera explícita.

Els perills d'entrada i els moviments de preparació s'incorporen a v9; els comptadors `setup_uses` i `hazard_sets` deixen de ser zero.

6.4.3 Segon salt: v9 / v11

Amb v9, els perills d'entrada i els moviments de preparació només s'utilitzen quan l'agent és més ràpid i resisteix l'STAB rival. La taxa global puja a **58,86%** i el resultat contra Abyssal a **46,64%**. v11 combina aquest bloc amb v10 i afegeix 0,4 pp; la contribució addicional és petita en aquesta matriu.

v9/v11 són els primers amb aproximadament 1,6 moviments de preparació i 0,16 perills d'entrada per partida.

6.4.4 Tercer salt: v12

v12 combina Teracristal · lització i selecció del substitut després d'un debilitament. La taxa global és **69,01%**. És el primer agent intern que supera Abyssal i Simple Heuristic: **59,91%** i **59,75%**, respectivament ($n = 10.000$).

En el subconjunt amb telemetria, utilitza la Teracristal · lització **0,96 vegades per partida**, registra només **0,01** accions de reserva i conserva **1,84** Pokémon, davant d'1,44 a v11. El canvi de comportament és substancial.

En `gen9randombattle`, el bloc format per la Teracristal · lització i la selecció del substitut s'associa amb l'increment més gran de la seqüència. Com que totes dues modificacions s'introdueixen alhora, l'experiment no en separa l'efecte individual.




Figura 6.5: v1–v14 contra els sis agents de referència ($n = 10.000$ per cel · la). v12 és el primer que deixa Abyssal i Simple Heuristic clarament per sota del 50%. Contra `random`, totes les heurístiques arriben al 97–98% i la columna deixa de ser discriminant.

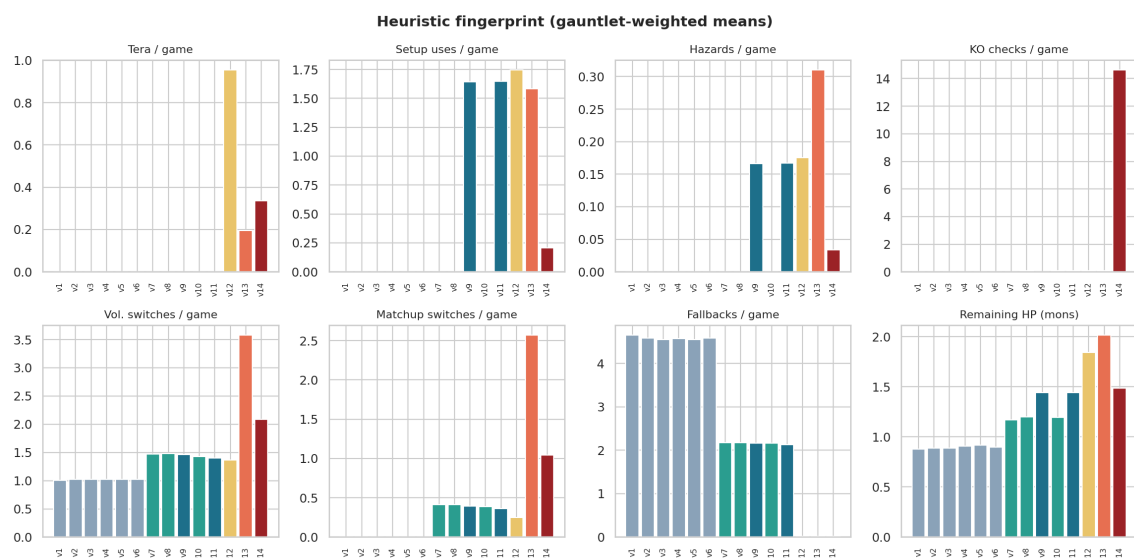


Figura 6.6: empremta tàctica de la seqüència heurística. **v12** utilitza la Teracristal · lització gairebé una vegada per partida; **v13**, 0,20 vegades. **ko_checks** augmenta fins a aproximadament 15 a **v14**; la preparació i els perills d'entrada apareixen a partir de **v9**.

6.5 La inversió entre **v12**, **v13** i **v14**

La complexitat creix de **v12** a **v14**, però la taxa global observada disminueix. Aquest resultat mostra que l'herència de funcionalitats no implica una millora monotònica.

Taula 6.4: Enfrontaments directes, amb $n = 10.000$ partides independents per orientació. **v12** i **v13** no presenten una separació concloent; **v14** queda per sota de tots dos. Les sumes recíproques properes al 100% són un control de coherència, no una prova amb partides aparellades.

Fitxer	TV (%)	Recíproc (%)	Suma
v12_vs_v13	50,65	48,85	99,50
v12_vs_v14	56,01	44,74	100,75
v13_vs_v14	57,71	41,60	99,31




Figura 6.7: Enfrontaments directes, amb $n = 10.000$ per orientació. v12 i v13 no presenten una separació concloent; v14 obté 44,74% contra v12 i 41,60% contra v13.

Les dues orientacions de v12 i v13 difereixen en 1,8 pp i no aporten una separació concloent. En canvi, v14 queda per sota de tots dos en els enfrontaments directes.

6.5.1 On v13 encara guanya

No està estrictament dominat. És el **millor heurístic contra cerca i contra l'IL híbrid**:

Oponent	v12	v13	v14
Minimax v15	63,96	67,59	60,07
Minimax v17	60,37	64,12	56,70
MCTS v18 ($n = 1k$)	66,1	67,7	59,8
IL v21	59,12	62,46	54,74
Baselines (bloc)	76,91	74,36	71,06
Altres heurístiques (bloc)	67,01	64,71	58,58

v13 acaba amb més Pokémon disponibles (avg_hp_us: 2,01, davant d'1,84 i 1,49) i juga partides més llargues (19,1 torns, davant de 17,9 i 18,5). El perfil és més conservador i orientat a l'atrició.

6.5.2 Per què no supera v12 en global

En el subconjunt amb telemetria, v13 utilitza la Teracristal · lització 0,20 vegades per partida, davant de 0,96 a v12; també fa més canvis voluntaris (3,58 davant d'1,37) i més canvis per enfrontament (2,57 davant de 0,25). Aquest comportament preserva més membres de l'equip, però pot cedir torns contra oponents deterministes. Les dades són compatibles amb aquesta explicació, però no aïllen causalment cadascun dels mecanismes.

6.5.3 Especialització de v14 i pèrdua de rendiment local

v14 incorpora modelatge de patrons humans, sondeig inicial, Teracristal · lització defensiva, un interval aproximat de dany i resolució d'un torn al final de la partida. Contra agents deterministes, aquests mecanismes poden consumir torns sense obtenir informació útil:

- El sondeig inicial substitueix algunes accions ofensives.

- El perfil de l'oponent aporta poc quan la política rival és fixa.
- `ko_checks` arriba a aproximadament 15 per partida, mentre que `setup_uses` baixa a 0,22.
- Contra Abyssal obté **51,36%**; v12 obté **59,91%**.




Figura 6.8: Enfrontaments de referència de v12, v13 i v14. Les files representen l'agent avaluat. Les cel·les MCTS tenen $n = 1.000$ i la resta, $n = 10.000$. v12 domina els agents de referència; v13 és més fort contra cerca i v21.




Figura 6.9: Taxa de victòries de la inversió, agregada per paradigma d'oponent. v12 és millor contra agents de referència i altres heurístiques; v13, contra minimax, MCTS i imitació híbrida.




Figura 6.10: Relació entre volum de canvis i taxa de victòries. La freqüència de canvi, per si sola, no mesura la qualitat de la política; cal distingir-ne el motiu.




Figura 6.11: Durada i membres de l'equip disponibles al final. v13 juga partides més llargues i conserva més Pokémon, mentre que v12 obté una taxa de victòries superior.

En aquest banc de proves, afegir modelatge d'oponents humans redueix el rendiment agent-contra-agent. Això indica una possible especialització de domini i justifica mantenir separades la matriu local i l'avaluació pública.

La mostra pública de v14 (secció 6.10) no permet reordenar v12 i v14; de la mateixa manera, la matriu local no permet afirmar quin dels dos obtindria més victòries contra persones.

6.6 Minimax d'un torn

La pregunta és si valorar explícitament la resposta més desfavorable del torn millora v14. La telemetria registra amb quina freqüència s'executa el mòdul i quan la seva acció difereix de la proposta heurística.

Taula 6.5: Minimax analític d'un torn (253.000 partides per fila). La cerca s'executa en aproximadament el 16–18% dels torns. La fulla posicional de **v16** gairebé no modifica la preparació; el prior de **v17** redueix la discrepància respecte de **v14** i obté la taxa més alta de la família.

	v15 HP	v16 bonuses	v17 prior +0,15
TV global (%)	53,80	54,30	57,89
IC 95% (pp)	$\pm 0,19$	$\pm 0,19$	$\pm 0,19$
Cerca (% torns)	17,6	17,6	16,3
Discrepància amb v14 (%)	66,5	67,3	36,6
Preparació / partida	0,21	0,21	0,21
Perills / partida	0,05	0,04	0,04
Tera / partida	0,40	0,39	0,38
Pokémon restants	1,28	1,29	1,39

6.6.1 Frequència d'intervenció

Es registren aproximadament 14 comprovacions de debilitament i 4,5 decisions maximin per partida. La matriu de cerca s'utilitza en el **16–18% dels torns**; la resta es resol principalment amb les regles prioritàries heretades.

Un agent **v14** que prioritza debilitaments garantits i aplica una anàlisi maximin d'un torn a les decisions restants.

Aquest patró és comparable al de **v21**, que consulta XGBoost en aproximadament el 15% dels torns, i al de les variants MCTS.




Figura 6.12: Taxa de discrepància respecte de **v14** en els torns en què s'executa el maximin. **v15/v16** discrepen aproximadament en el 67% dels casos; **v17**, amb prior +0,15, en el 37%. Les derrotes presenten una discrepància mitjana superior, una associació que no implica causalitat.

6.6.2 **v16** i l'avaluació de la fulla

v16 incorpora bonificacions per moviments de preparació i perills d'entrada. La taxa global només augmenta 0,50 pp i els enfrontaments directes queden prop del 50%. Les freqüències de preparació (0,213 i 0,207 per partida) i de perills d'entrada (0,044 i 0,049) pràcticament no canvien. Amb aquesta funció de fulla, el terme de dany rival continua dominant les bonificacions de llarg termini.

La discrepància es manté al voltant del 67%. Per tant, enriquir la fulla en aquesta magnitud no modifica substancialment la política.

Aquest resultat és coherent amb una limitació d'horitzó: afegir una bonificació estàtica no equival a simular les conseqüències futures d'un moviment de preparació.




Figura 6.13: Indicadors d'efectes diferits: preparació, perills d'entrada i Teracristal · lització. v16 manté la preparació al voltant de 0,21 usos per partida, un nivell semblant al de v14 i molt inferior al de v12.

6.6.3 v17: prior heurístic

v17 afegeix 0,15 al valor de l'acció proposada per v14. La discrepància baixa del 67% al 37% i la taxa global augmenta 4,1 pp respecte de v15. En els enfrontaments directes obté 54,7% i 54,3% contra v15 i v16. El resultat mostra que conservar un prior heurístic és més efectiu, en aquesta implementació, que substituir-lo per la matriu d'un torn.

Contra els comparadors principals, amb $n = 10.000$ tret de les cel · les MCTS:

Oponent	v15	v16	v17
v12	36,04	35,92	40,94
v13	32,82	33,50	35,10
v14 (professor)	39,43	39,56	43,61
Abyssal	41,72	41,86	46,79
v20 ($n = 1k$)	39,7	44,6	50,4
v21	43,65	44,75	47,50
v22	69,67	70,22	71,27

v17 obté **43,6%** contra v14, **40,9%** contra v12 i 46,8% contra Abyssal. Contra v20 obté 50,4% amb $n = 1.000$, un resultat compatible amb rendiments similars en aquell enfrontament.

Cap variant de minimax supera v14 o v12. La variant amb millor resultat és precisament la que limita la desviació respecte de l'heurística de partida.

6.6.4 Canvis, durada i supervivència

La millora de v17 no prové d'allargar sistemàticament les batalles: la durada mitjana pràcticament no canvia. Sí que augmenta la massa de resultats amb dos o tres membres restants. Aquesta observació és coherent amb menys decisions maximin agressives que exposen l'actiu, tot i que la figura no identifica per si sola quina acció evita cada debilitament.

La combinació «més canvis decidits per cerca» i «menys discrepància» no és contradictòria. Indica que, quan v14 ja proposa un canvi, el prior de v17 concentra el maximin en la mateixa direcció. El guany no sembla provenir del nombre brut de canvis, sinó de conservar el canvi heurístic en els estats on la matriu no disposa d'un horitzó suficient.




Figura 6.14: Distribució de la durada i dels Pokémon restants a minimax. Les tres variants duren aproximadament 19 torns, però v17 conserva 1,39 membres de mitjana, davant d'1,28–1,29.




Figura 6.15: Distribució dels canvis voluntaris, dels canvis decidits pel maximin i de la fracció de decisions de cerca que són canvis. v17 presenta una mediana superior de canvis tot i discrepar menys de v14.




Figura 6.16: empremta v15–v17: KO checks ~14, cerca ~16–18% dels torns, Tera ~0,39 (nivell v14, no v12).




Figura 6.17: Enfrontaments de referència del minimax d'un torn. Les cel·les contra MCTS tenen $n = 1.000$. v17 millora respecte de les altres variants, però no supera el 50% contra v14.




Figura 6.18: Taxa de victòries agrupada. v15 i v16 se superposen; v17 queda per sobre, encara per sota de v9/v11.




Figura 6.19: Taxa de victòries del minimax per família d'oponent. El prior de v17 s'associa amb les millores principals contra heurístiques i MCTS.

6.7 MCTS ras: UCB a l'arrel i simulacions de cinc torns

Totes les cel·les d'aquesta secció tenen $n = 1.000$. El marge màxim aproximat per a una proporció és $\pm 3,1$ pp. La mitjana global de les files MCTS també té una ponderació diferent de la de les files no MCTS.

La pregunta és si les simulacions de cinc torns milloren les regles de v14 que s'executen abans de la cerca o s'utilitzen com a prior.

Taula 6.6: MCTS ras amb UCB a l'arrel i 100 simulacions de cinc torns. Totes les cel·les tenen $n = 1.000$ (28.000 partides per agent). La fulla més rica de v19 no aporta una millora observable; PUCT amb prior sobre v14 redueix la discrepància i obté la taxa més alta de la família.

	v18 UCB1 HP	v19 UCB1 pos.	v20 PUCT 0,70
TV global (%)	54,02	53,29	59,66
Cerca (% torns)	18,1	17,6	15,5
Discrepància amb v14 (%)	71,3	71,1	18,7
Preparació / partida	0,22	0,22	0,20
Perills / partida	0,05	0,05	0,04
Tera / partida	0,41	0,39	0,39
Pokémon restants	1,21	1,22	1,40

v20 obté una taxa superior a v18 en els **28 enfrontaments** (diferència mitjana de 5,64 pp). v18 i v19 queden prop del 50% en l'enfrontament directe, mentre que v20 obté aproximadament 56,6% contra tots dos. En aquest pressupost, enriquir només la funció de fulla de v19 no aporta una millora observable.

6.7.1 Freqüència d'intervenció

Es registren aproximadament 14 comprovacions de debilitament i 3–4 decisions MCTS per partida. La cerca intervé en el **16–18%** dels torns:

Un agent basat en v14 que prioritza els debilitaments garantits i aplica 100 simulacions de cinc torns a les decisions restants.

Quan s'activa una drecera prèvia, les 100 simulacions no s'executen. Per tant, la cerca només pot modificar el subconjunt de decisions que arriba a l'arrel.

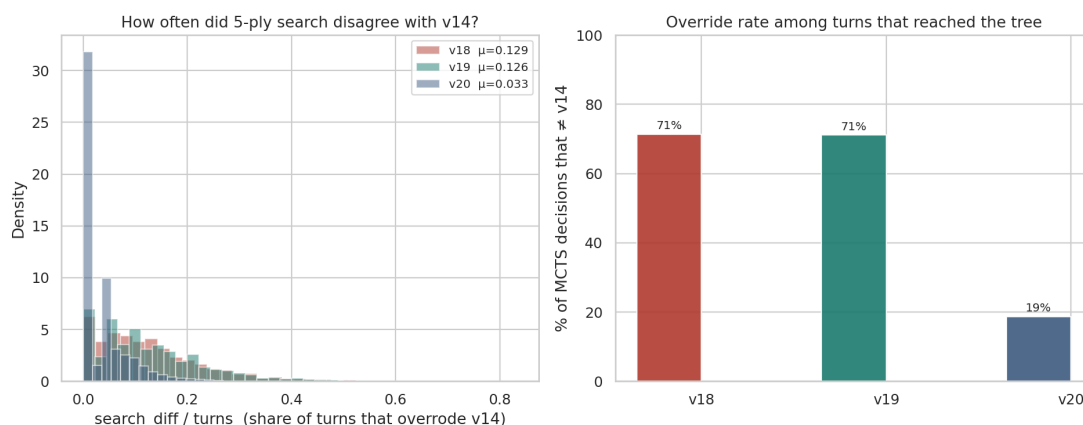


Figura 6.20: Taxa de discrepància respecte de v14 entre les decisions de cerca. UCB1 (v18/v19) discrepa aproximadament en el 71% dels casos i PUCT (v20), en el 19%. Les derrotes mostren més discrepància mitjana, una associació que no estableix causalitat.

6.7.2 Discrepància i resultat

`search_diff` indica que la simulació ha canviat l'acció proposada per v14. Entre els torns en què s'executa:

- v18/v19 discrepen de v14 en el **71%** de les decisions de cerca.
- Les partides perdudes presenten una discrepància superior. Aquest patró pot reflectir decisions pitjors, estats més difícils o ambdues coses.
- Les simulacions de cinc torns i la funció de fulla basada en HP poden afavorir el dany immediat davant d'efectes diferits.

v19 incorpora una fulla posicional, però manté una discrepància del 71,1% i una taxa global 0,7 pp inferior a v18. Les dades no mostren que aquest canvi de fulla resolgui les limitacions del pressupost, de la política de simulació o de la informació oculta.

6.7.3 PUCT i el prior heurístic

Amb un prior de 0,70 sobre v14, la discrepància baixa al **18,7%**. v20 obté una taxa global descriptiva de **59,7%** i conserva 1,40 Pokémon de mitjana al final.

Les diferències de v20 respecte de v18 són especialment grans contra v17 (+11,1 pp), v13 (+10,5), v15 (+9,8) i v12 (+8,7). Contra `random`, la diferència és de 0,3 pp i queda molt per sota de la precisió de la cel·la.

Amb aquest pressupost, la millor variant MCTS és la que utilitza les simulacions per ajustar un prior heurístic, no la que substitueix l'heurística amb UCB1 sense guia.

6.7.4 Indicadors d'efectes diferits

	Setup/partida	Hazards/partida	Tera/partida
v12 (comparador)	~1,75	~0,18	~0,96
v14 (professor)	~0,21	~0,03	~0,34
Minimax d'un torn v15–v17	0,21	0,04–0,05	0,38–0,40
MCTS de cinc torns v18–v20	0,20–0,22	0,04–0,05	0,39–0,41

Les freqüències de preparació i perills d'entrada es mantenen a nivells semblants als de v14, no als de v12. Les simulacions de cinc torns no recuperen, amb aquesta política, el comportament diferit observat a l'heurística amb millor taxa.

v20 presenta més **search_switches** (aproximadament 36% de les decisions de cerca, davant del 16% a v18) i menys discrepància total. Això indica que PUCT reforça sovint els canvis ja proposats per v14.




Figura 6.21: Indicadors d'efectes diferits a les simulacions de cinc torns. La preparació i els perills d'entrada es mantenen a nivells semblants als de v14.

6.7.5 Comparació amb els agents de referència

Oponent	v18	v19	v20
v12	34,0	33,1	42,7
v13	28,6	34,1	39,1
v14	40,0	41,7	47,0
Abyssal	42,2	38,7	49,0
v15	49,3	51,6	59,1
v17	44,7	45,3	55,8
v21	44,1	46,5	49,6
v22	71,1	66,9	73,0

v20 obté **47,0%** contra v14, **42,7%** contra v12 i **49,0%** contra Abyssal. Amb $n = 1.000$, el primer i el tercer resultat són compatibles amb el 50%. També obté 59,1% contra v15 i 73,0% contra v22.

Per blocs, v20 obté 69,9% contra agents de referència, 56,7% contra heurístiques i 57,4% contra minimax. v18/v19 se situen prop del 50% contra heurístiques i per sota del 50% contra minimax.

L'MCTS ras amb 100 simulacions de cinc torns no supera v12 ni aporta evidència de superar v14. Dins de la família, el prior heurístic de v20 és el canvi associat amb la millora principal.

6.7.6 Canvis, durada i supervivència

El patró de v20 no és el d'una política més defensiva que simplement prolonga la partida. Acaba una mica abans i amb més recursos. Una explicació plausible és que el prior redueix simulacions que prefereixen dany immediat però deixen un mal enfrontament al torn següent. És una interpretació compatible amb la telemetria, no una prova causal del mecanisme intern de cada victòria.

v18 gairebé mai escull un canvi des de l'arrel en la mediana, mentre que v20 arriba aproximadament a un terç de decisions de cerca orientades al canvi. Com que al mateix temps baixa **search_diff**, aquests canvis solen coincidir amb la proposta de v14. El resultat reforça la lectura que PUCT preserva posició, més que descobrir una estratègia nova de llarg horitzó.




Figura 6.22: Durada i Pokémon restants a MCTS. v20 acaba lleugerament abans (18,33 torns) i conserva 1,40 membres de mitjana, davant d'1,21–1,22 a UCB1.




Figura 6.23: Distribució dels canvis a MCTS. PUCT augmenta la fracció de decisions de cerca que acaben en canvi i amplia la distribució de canvis voluntaris.




Figura 6.24: Empremta MCTS. Cerca 16–18% dels torns; KO ~ 14 /partida. v20 busca menys i acaba amb més HP. $n = 1.000$ per oponent.




Figura 6.25: Enfrontaments discriminants d'MCTS. Les files representen l'agent avaluat i totes les cel · les tenen $n = 1.000$. v20 s'acosta a Abyssal (49%) i no supera v12 (42,7%).




Figura 6.26: Taxa de victòries agrupada d'MCTS. v18 i v19 se superposen; v20 queda per sobre. Aquesta mitjana de 28.000 partides no té la mateixa ponderació que les files de 253.000.




Figura 6.27: Taxa de victòries d'MCTS per paradigma d'oponent ($n = 1.000$ a cada cel · la). PUCT millora principalment contra heurístiques i minimax.

6.8 Aprenentatge per imitació: dues formes d'execució

Les dues variants comparteixen el classificador XGBoost i el llindar $\tau = 0,5525$, però difereixen en la selecció de l'acció concreta.

Taula 6.7: Imitació amb el mateix classificador XGBoost ($\tau = 0,5525$) i dues formes d'execució (253.000 partides per fila). v21 consulta el model en el 15% dels torns; v22, en el 80%, sense proteccions de debilitament, i activa la protecció de bucle en el 97% de les partides.

	v21 híbrid	v22 atributs
TV global (%)	58,71 $\pm 0,19$	33,49 $\pm 0,18$
Torns mitjans	18,20	20,07
Pokémon restants	1,33	0,70
Canvis voluntaris / partida	1,98	3,72
XGBoost (% torns)	15,2	79,9
Entre decisions XGB, % canvis	35,5	15,2
Mitjana $p(\text{canvi})$	0,080	0,351
Proteccions de KO / partida	13,85	0
Resolucions de final / partida	0,032	0
Proteccions de bucle / partida (% partides)	0,38 (33%)	1,92 (97%)

v21 obté una taxa superior a v22 en els **28 enfrontaments**, amb una diferència mitjana de 25,2 pp. En el cara a cara, les dues orientacions són 71,74% i 29,07%; l'autojoc queda prop del 50%. A v22, els comptadors `ko_guards`, `endgame_solves`, `ko_checks` i `search_*` són zero, fet que confirma que no executa les dreceres de v14.




Figura 6.28: Empremta dels agents d'imitació. v21 registra aproximadament 14 proteccions de debilitament per partida i consulta XGBoost en el 15% dels torns. v22 no té aquestes proteccions, consulta XGBoost en el 80% dels torns i activa la protecció de bucle en el 97% de les partides.

6.8.1 Rendiment dins de la matriu

v21 obté una taxa global descriptiva de 58,71%, propera a v9/v11. v22 obté 33,49%, per sota de v1 (44,25%). En l'enfrontament directe, v1 guanya el 65,72% de les partides contra v22.

Enfrontaments de referència ($n = 10.000$, tret de v20):

	contra v12	contra v13	contra v14	contra Abyssal	contra SimpleH
v21	41,28	38,39	45,43	46,98	47,76
v17	40,94	35,10	43,61	46,79	46,75
v20 ($n = 1k$)	42,7	39,1	47,0	49,0	49,2
v22	19,80	22,03	25,81	22,90	21,73

v14 obté 54,74% contra v21, i l'orientació recíproca és 45,43%. Per tant, afegir el model de decisió atacar/canviar no millora v14 en aquest enfrontament. Les taxes contra Abyssal són 46,98% i 51,36%, respectivament.

6.8.2 Pes efectiu del model a v21

Només el 15% dels torns arriben a XGBoost; les regles prèvies de v14 resolen la resta. En els torns consultats, la probabilitat mitjana de canvi és 0,08, molt inferior a $\tau = 0,5525$. En conseqüència, el model sol indicar que l'agent es mantingui al camp i v14 selecciona el moviment.

Descripció honesta:

Un agent v14 que, en una fracció minoritària dels torns, consulta un model d'imitació per decidir si convé canviar i delega l'execució concreta a la mateixa heurística.

La capa d'imitació funciona, doncs, com un **prior sobre el moment de canviar**, no com un motor tàctic complet. Aquesta descripció és important per no atribuir tot el rendiment de v21 al model supervisat.

La comparació mostra que la decisió d'alt nivell es pot integrar de manera útil quan l'acció concreta queda restringida per una política competent. No mostra que el classificador, per si sol, reproduïx el joc expert.




Figura 6.29: Freqüència d'ús de la política apresada. XGBoost intervé en el 15% dels torns de v21 i en el 80% dels de v22.

6.8.3 Factors que limiten v22

1. **Semàntica de l'acció.** El primer model només prediu {atacar, canviar} i el segon puntua atributs de candidats sintetitzats. Es perd informació sobre la identitat i el context del moviment.
2. **Biaix d'exposició.** Una decisió deficient pot portar la política a estats poc representats a les repeticions. La protecció de bucle s'activa en el **97%** de les partides de v22, que també són més llargues i acaben amb menys Pokémon disponibles.
3. **Absència de restriccions tàctiques.** v21 preserva els debilitaments garantits abans de consultar el model; v22 no. La freqüència de Teracristal · lització de v22 és alta, però la freqüència per si sola no informa de la qualitat del moment triat.

En aquesta implementació, el resultat depèn tant de *què* s'imita —la decisió atacar/canviar— com de *qui* executa l'acció concreta. Disposar d'1,1 milions de torns no compensa una representació que no modela directament la selecció completa de moviments i canvis.

El contrast entre v21 i v22 no compara únicament dos models d'imitació: també compara una arquitectura jeràrquica amb una execució basada en atributs. Aquesta confusió de factors impedeix atribuir els 25,2 pp exclusivament a una sola decisió de disseny, però demostra la importància de l'executor.

6.8.4 Canvis, durada i supervivència

La durada més alta de v22 no és senyal de control. Combinada amb menys membres restants i una taxa de victòries inferior, apunta a canvis que posposen el debilitament sense millorar la posició. Aquest patró concorda amb el biaix d'exposició: després d'un canvi deficient, el model torna a decidir en un estat allunyat de les trajectòries humanes.

Els canvis forçats són semblants perquè depenen sobretot del nombre de debilitaments. La diferència apareix en els canvis voluntaris i en les decisions d'XGBoost. v22 concentra la distribució al voltant de tres o quatre canvis, mentre que v21 n'executa habitualment un o dos. Juntament amb les proteccions de bucle en el 97% de les partides, això suggereix que el problema no és «canviar poc», sinó no disposar d'un executor que valori adequadament el destí del canvi i el cost de tornar enrere.




Figura 6.30: Durada i Pokémon restants dels agents d'imitació. v22 juga partides més llargues (20,07 torns) però acaba amb només 0,70 membres, davant d'1,33 a v21.




Figura 6.31: Distribució dels canvis a imitació. v22 fa aproximadament el doble de canvis voluntaris i rep moltes més ordres de canvi del classificador.




Figura 6.32: Indicadors tàctics. v22 i v12 utilitzen la Teracristal·lització amb freqüències similars, però obtenen resultats molt diferents; la freqüència no mesura la qualitat de la decisió.




Figura 6.33: Taxa de victòries agrupada de les dues arquitectures d'imitació. v21 se situa prop de v9; v22, per sota de v1.




Figura 6.34: Taxa de victòries dels agents d'imitació per família d'oponent. v21 supera v22 en els sis blocs, amb diferències d'aproximadament 20–26 pp.




Figura 6.35: Taxa de victòries de v21 i v22 per oponent. Tots els punts queden sobre la diagonal: v21 obté el valor superior en 28 de 28 enfrontaments. La diferència màxima és de 32,6 pp contra `safe_one_step`.

6.9 Comparació entre els cinc paradigmes

Taula 6.8: Síntesi dels cinc paradigmes amb v12 com a comparador comú. Les variants són les que obtenen el millor resultat observat dins de cada família; aquesta selecció és posterior a l'experiment. L'MCTS té una mostra menor i el PPO no participa en la matriu completa.

Paradigma	Variant	<i>n</i>	vs v12	Lectura
Heurístiques	v12	10.000	50,1%	Autojoc de referència; 59,91% contra Abyssal.
Minimax d'un torn	v17	10.000	40,94%	El prior cap a v14 millora les altres variants, però no supera v12.
MCTS ras	v20	1.000	42,7%	PUCT redueix la discrepància amb v14; marge aproximat de ± 3 pp.
Imitació	v21	10.000	41,28%	El model decideix quan canviar i v14 executa l'acció.
PPO	model A	10.000	34,1%	Experiment separat, inicialitzat per clonatge de v8.

La Taula 6.8 utilitza v12 com a comparador comú. És la comparació més directa disponible per als cinc paradigmes, però no iguala el pressupost de l'MCTS, no controla el cost d'entrenament i

selecciona posteriorment la variant amb millor resultat de cada família. Sota aquestes condicions, cap de les implementacions de minimax, MCTS, imitació o PPO arriba al 50% contra v12.

Taula 6.9: Taxes globals descriptives contra els 28 oponents. Les files no MCTS tenen 253.000 partides i ponderen cada oponent MCTS una desena part que els altres; les files MCTS tenen 28.000 partides i ponderen tots els oponents igual. Els dos blocs no formen una única classificació comparable.

Agent	Partides	TV (%)	Paradigma
<i>Files no MCTS: ponderació 10:1 dels oponents no MCTS/MCTS</i>			
v12	253.000	69,01	Heurística
v13	253.000	67,63	Heurística
v14	253.000	62,03	Heurística
abyssal	253.000	62,00	Agent de referència
simple_heuristic	253.000	61,93	Agent de referència
v11	253.000	59,26	Heurística
v9	253.000	58,86	Heurística
v21	253.000	58,71	Imitació híbrida
v17	253.000	57,89	Minimax
v15	253.000	53,80	Minimax
<i>Files MCTS: ponderació uniforme dels 28 oponents</i>			
v20	28.000	59,66	MCTS
v18	28.000	54,02	MCTS
v19	28.000	53,29	MCTS
<i>Altres referències descriptives</i>			
v1	253.000	44,25	Heurística
v22	253.000	33,49	Imitació per atributs
max_power	253.000	19,66	Agent de referència
random	253.000	4,20	Agent de referència

Taula 6.10: Enfrontaments de referència. Les files amb MCTS tenen $n = 1.000$ i la resta, $n = 10.000$. v12 contra Abyssal (59,91% $\pm 0,96$ pp) és el principal resultat contra un agent extern basat en regles.

Agent	vs Abyssal	vs v12	vs v14	vs SimpleH
v12	59,91	50,1 (autojoc)	56,01	59,75
v13	55,34	48,85	57,71	56,10
v14	51,36	44,74	50,1 (autojoc)	50,66
v20 ($n = 1k$)	49,0	42,7	47,0	49,2
v21	46,98	41,28	45,43	47,76
v17	46,79	40,94	43,61	46,75
v16	41,86	35,92	39,56	40,65
v15	41,72	36,04	39,43	41,23
v18 ($n = 1k$)	42,2	34,0	40,0	42,0
v1	30,64	23,29	32,09	30,26
v22	22,90	19,80	25,81	21,73

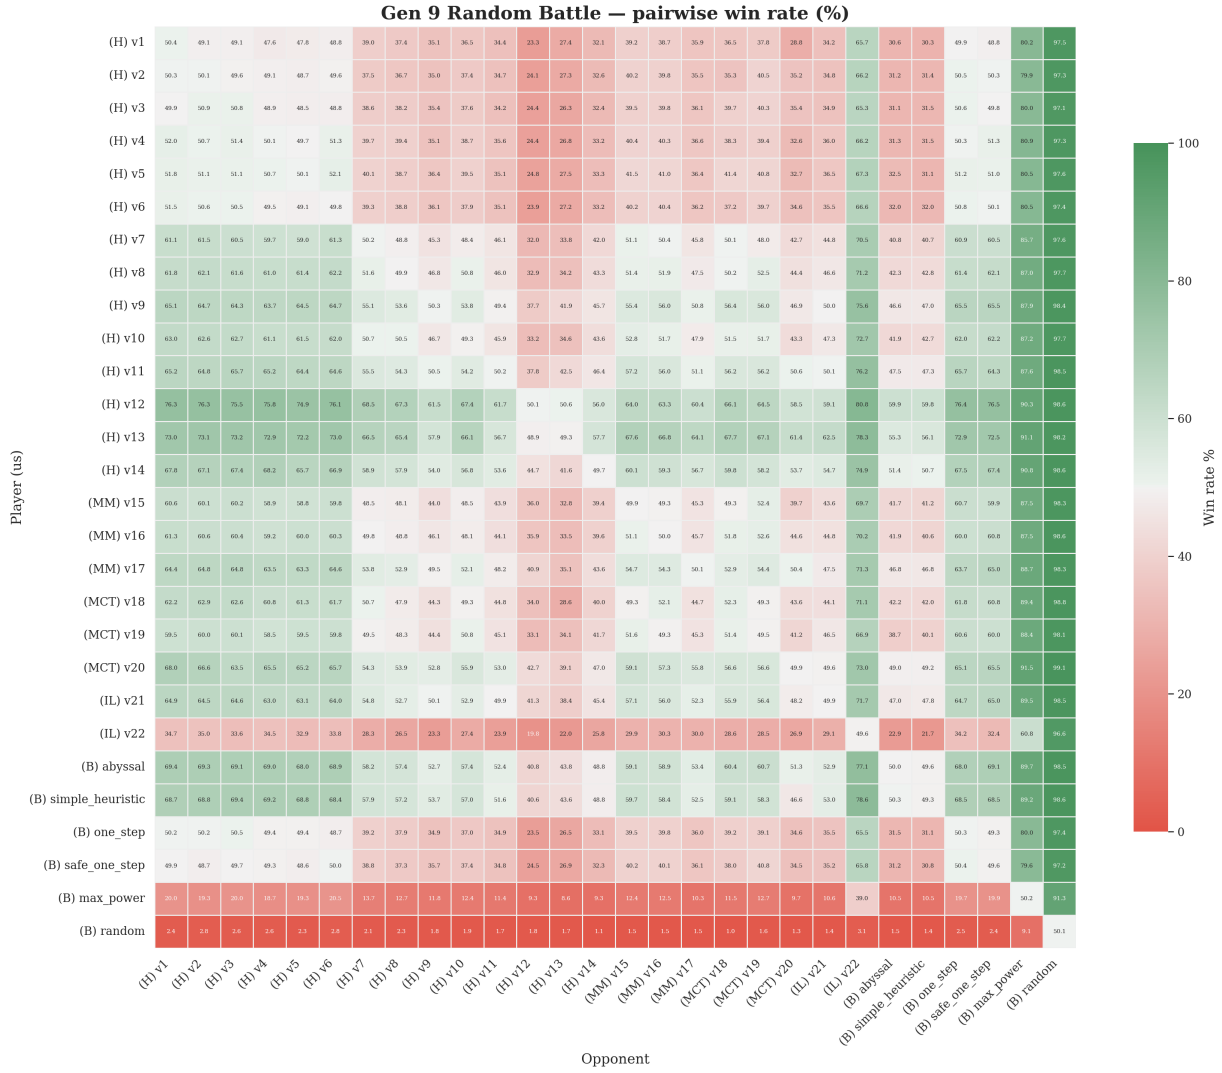


Figura 6.36: Mapa de calor de la taxa de victòries a `gen9randombattle`. La fila és l'agent analitzat i la columna, l'oponent. Prefixos: (H) heurística, (MM) minimax, (MCT) MCTS, (IL) imitació i (B) agent de referència. Les cel·les amb MCTS tenen $n = 1.000$; la resta, $n = 10.000$.

6.9.1 Abyssal com a agent de referència

Fins a **v12**, cap heurística interna supera el 50% contra Abyssal. **v7–v11** obtenen entre 41% i 48%; **v12** arriba a 59,91%. **v14** obté 51,36%, **v21** 46,98%, **v20** 49,0% amb $n = 1.000$, **v17** 46,79% i **v22** 22,90%. El resultat de referència és, per tant, **v12 contra Abyssal: 59,91% $\pm 0,96$ pp**, $n = 10.000$.

6.9.2 Elo Bradley–Terry

Taula 6.11: Escala Bradley–Terry a `gen9randombattle`, ancorada a `random = 1000` i ajustada amb les dues orientacions. Els agents no MCTS aporten 506.000 observacions i els MCTS, 56.000. No s’han calculat intervals: valors iguals després d’arrodonir no impliquen equivalència estadística.

Rang	Agent	Elo	Paradigma
1	v12	1812	Heurística
2	v13	1802	Heurística
3	simple_heuristic	1755	Baseline
4	v14	1755	Heurística
5	abyssal	1755	Baseline
6	v20	1742	MCTS (cel · les $n = 1k$)
7	v11	1733	Heurística
8	v9	1730	Heurística
9	v21	1729	IL híbrid
10	v17	1722	Minimax
–	v22	1529	IL (atributs)
–	random	1000	Baseline (àncora)




Figura 6.37: Escala Bradley–Terry ancorada a `random = 1000`, amb les dues orientacions. `v12` i `v13` obtenen les puntuacions més altes. `v14`, `Abyssal` i `Simple Heuristic` comparteixen el mateix valor arrodonit. Les files MCTS aporten menys partides al model.

6.10 Classificació pública: v14 contra persones

Taula 6.12: Classificació pública de v14 contra persones (gen9randombattle, usuari SirPThesis, 9–10 de juny de 2026). La mostra final conté 431 partides; una instantània anterior de 98 partides no s'utilitza com a resultat.

Mètrica	Valor
Partides úniques acabades	431
Victòries	170 / 431
Taxa de victòries principal	39,44% $\pm$ 4,6 pp
Subconjunt de torns ≥ 10 (descriptiu)	35,43% ($n = 398$)
Partides de menys de 10 torns	33
Elo	1085 $\rightarrow$ 1038 (rang 1000–1263)
Errors / accions de reserva	0 / 13
Finestra	2026-06-09 21:54 – 2026-06-10 18:32




Figura 6.38: Taxa de victòries i Elo de v14 a la classificació pública: 431 partides entre el 9 i el 10 de juny de 2026, 39,44% $\pm$ 4,6 pp i Elo de 1085 a 1038 (màxim 1263).




Figura 6.39: Evolució de l'Elo al llarg de les 431 partides. Una mostra prefixa de 98 partides, presa prop del màxim, no representa el resultat final.




Figura 6.40: Victòries i derrotes segons la durada. El subconjunt de partides amb almenys 10 torns és descriptiu; la taxa principal utilitza les 431 partides sense filtrar.

En les partides d'almenys 10 torns, **v14** utilitza la Teracristal·lització en 45 de 398 combats i obté un 20% de victòries en aquest subconjunt. També presenta moltes comprovacions de debilitament i pocs moviments de preparació, un perfil semblant al de la matriu local. Com que la durada és posterior a les decisions i està relacionada amb el resultat, la taxa filtrada no s'interpreta com una estimació alternativa de rendiment.

La mostra pública avalua **v14** fora de l'entorn local, però no és una validació del seu suposat avantatge contra persones: la taxa observada queda per sota del 50% i la selecció d'oponents no està controlada. Tampoc permet inferir el rendiment que hauria obtingut **v12**.

6.11 PPO contra **v12**

El cinquè paradigma s'avalua contra l'agent amb millor resultat observat a la matriu, **v12**, amb $n = 10.000$ i les dues orientacions. El model és MaskablePPO, amb una observació de 328 dimensions, un espai **Discrete(14)** i inicialització per clonatge conductual de **v8** durant 400 partides.

Taula 6.13: Currículum i avaluacions de MaskablePPO. El resultat principal és el del model A contra **HeuristicV12**, amb $n = 10.000$ i les dues orientacions. La fase 4 només informa la finestra d'entrenament, no una avaluació independent.

Fase	Oponent	n	TV (%)	Notes
1	Random	1.000	91,8	Graduació ($\geq 90\%$)
1.5	MaxBP	1.000	70,5	Graduació
2	v8	1.000	40,6	No assoleix el llindar del 55%
3 (resultat)	v12	10.000	34,1	Model A, 328 dimensions, $\pm 0,93$ pp
3B (diagnòstic)	v12	1.000	32,6	Model B, taxa $1,5 \times 10^{-4}$
4 (interrompuda)	v12	12.554	33,5	Taxa d'entrenament; 346 dimensions i clonatge de v14
Control (model A)	Random	1.000	98,3	Verificació de la política
Matriu (context)	v8 contra v12	10.000	32,9	Professor de clonatge

6.11.1 Resultat principal

Contra **HeuristicV12**, el model A (**p3_v12_lr5e5_flat.zip**) obté:

$$34,1\% \quad (3405/10000) \quad \pm 0,93 \text{ pp} \quad (\text{IC} \sim 33,2\text{--}35,0\%).$$

Per orientació, obté 34,2% (1709/5000) com a p1 i 33,9% (1696/5000) com a p2, amb 17,2 torns de mitjana. En el control contra Random obté **98,3%** amb $n = 1.000$. Això confirma

que la política produeix accions legals i eficaces contra un agent aleatori, però no arriba al 50% contra v12.

A la matriu, v8 obté **32,9%** contra v12 ($n = 10.000$). La diferència puntual respecte del PPO és d'1,2 pp i els intervals se superposen; per tant, no hi ha evidència clara que el model final superi el seu professor de clonatge en aquest comparador.

6.11.2 Currículum

La Taula 5.4 i la Figura 5.10 separen entrenament i validació. Les dues primeres etapes compleixen el criteri operatiu: 91,8% contra Random i 70,5% contra MaxBP, amb $n = 1.000$. Això mostra que la política aprèn l'espai d'accions i supera polítiques simples.

El canvi qualitatiu apareix a v8. Després de 400 partides de clonatge, la validació és només 40,6%, per sota del 55% requerit. Per tant, no és correcte descriure el currículum complet com quatre graduacions reeixides. Les fases 1 i 1.5 es validen; la fase 2 no, i la fase 3 s'executa com una prova de continuació i una mesura contra el comparador final.

Una configuració amb taxa d'aprenentatge $1,5 \times 10^{-4}$ i 16 entorns obté 32,6% contra v12 amb $n = 1.000$. L'extensió a 346 dimensions, inicialitzada amb v14, es va interrompre amb una taxa d'entrenament aproximada del 33,5%. Aquests valors són diagnòstics i no substitueixen l'avaluació final del model A.

6.11.3 Interpretació del límit observat

Hi ha diverses explicacions compatibles amb el 34,1%, però les dades no permeten triar-ne una de manera causal:

1. **Professor inicial.** El clonatge parteix de v8, que obté 32,9% contra v12. El resultat final és proper a aquest punt de partida.
2. **Salt de dificultat.** La política no arriba a paritat amb v8 abans de passar a v12; per tant, la fase següent comença sense haver consolidat l'anterior.
3. **Observació sense memòria.** El vector resumeix l'estat actual, però la política no és recurrent i pot perdre informació temporal útil sobre moviments revelats o patrons del rival.
4. **Recompensa modelada.** HP, debilitaments, modificadors i perills proporcionen senyal dens, però poden premiar estats intermedis que no maximitzen la victòria final.
5. **Variabilitat d'entrenament.** No hi ha repeticions completes amb diversos llavors; una sola trajectòria no estima la distribució de rendiment de PPO.

Amb aquesta observació, recompensa, inicialització i pressupost, MaskablePPO no supera v12. La conclusió es limita al sistema executat, no a PPO en general. El resultat més informatiu és que vèncer Random no prediu l'èxit contra una heurística amb coneixement de posició i mecàniques de format.

6.12 Discussió

6.12.1 Patró d'integració residual

v21 (imitació), v17 (minimax) i v20 (MCTS) comparteixen un patró: conserven les regles tàctiques de v14 i hi afegeixen un mòdul que intervé en una fracció de les decisions. Les figures 6.28, 6.12 i 6.20 mostren que aquests mòduls intervenen aproximadament en el 15–18% dels torns o redueixen la discrepància respecte de l'heurística. Dins de cada família, aquestes

variants obtenen un resultat superior a les alternatives que substitueixen més sovint la proposta de v14.

El patró no demostra que qualsevol arquitectura híbrida sigui superior. Les variants difereixen en més d'un component i s'han seleccionat després d'observar els resultats. Sí que aporta evidència consistent que, amb les representacions i pressupostos implementats, preservar restriccions tàctiques de domini és important.

6.12.2 Resposta conjunta a la pregunta de recerca

1. La seqüència heurística mostra increments associats a posició, control del ritme i mecàniques específiques de la Generació IX. v12 obté el millor resultat observat, però introdueix dues modificacions alhora i no permet separar-ne l'efecte.
2. El minimax d'un torn i l'MCTS ras no superen v12. Les millors variants són les que es mantenen més a prop de v14.
3. El model d'imitació aporta una decisió d'alt nivell aprofitable quan v14 executa l'acció. L'execució basada en atributs de v22 queda clarament per sota.
4. MaskablePPO obté 34,1% contra v12, un resultat proper al de v8 contra el mateix oponent i insuficient per afirmar una millora sobre el professor de clonatge.
5. En el comparador comú v12, cap de les implementacions seleccionades de minimax, MCTS, imitació o PPO arriba al 50%.

6.12.3 Limitacions específiques dels resultats

- Les taxes globals inclouen oponents fàcils, autojoc i etiquetes duplicades, i la ponderació difereix entre files MCTS i no MCTS.
- La telemetria detallada de les heurístiques prové d'un subconjunt de cinc oponents; la de minimax, MCTS i imitació cobreix la matriu completa.
- `endgame_solves` de v18 pot incloure activitat de la sonda v14 posterior a la cerca.
- `LocalSim` no és el mateix motor que `Showdown`; un desajust de mecàniques pot introduir soroll en les simulacions.
- L'avaluació pública de v14 és una mostra no controlada de 431 partides.
- El PPO només es compara amb v12, i no s'han repetit els entrenaments complets amb diversos llavors.

Capítol 7

Conclusions i línies futures

7.1 Resposta a la pregunta de recerca

Aquest treball ha comparat cinc paradigmes d'agents en Pokémon Showdown Random Battle de la Generació IX. Heurístiques, minimax d'un torn, MCTS ras i aprenentatge per imitació formen, amb sis agents de referència, una matriu dirigida de 28×28 . MaskablePPO s'ha avaluat separatament contra v12. La comparació comparteix simulador i format, però no és completament simètrica.

Sota les implementacions i els pressupostos estudiats, les heurístiques obtenen el millor resultat observat. v12 assoleix 69,01% en la seva mitjana global descriptiva i 59,91% contra Abyssal. Amb v12 com a comparador comú, v17 (minimax), v20 (MCTS), v21 (imitació) i el model PPO obtenen 40,94%, 42,7%, 41,28% i 34,1%, respectivament. La cel·la MCTS té $n = 1.000$; les altres, $n = 10.000$.

La conclusió no és que les heurístiques siguin universalment superiors. És que, en aquest entorn, el coneixement explícit sobre Teracristal·lització, selecció del substitut, debilitaments garantits i control del ritme no queda recuperat per la cerca rasa ni pels models apresos amb els recursos utilitzats.

7.1.1 Grau d'acompliment dels objectius específics

A partir dels resultats empírics obtinguts, es pot verificar el compliment complet dels sis objectius específics plantejats en la Introducció (Secció 1.2):

1. **Formalització teòrica del domini (Acomplert):** S'ha formalitzat el combat Pokémon com un POMDP/POSG al Capítol 2, definint les fonts d'incertesa de l'estat ocult, la dinàmica d'accions simultànies i les transicions estocàstiques.
2. **Disseny metodològic, infraestructura i telemetria (Acomplert):** S'ha dissenyat el protocol experimental i el model de rànquing Bradley-Terry (Capítol 3), s'ha construït la infraestructura computacional paral·lela i recuperable (Capítol 4) executant més de 6,4 milions de batalles, i s'ha instrumentat el marc de telemetria per torn per a l'explicabilitat conductual.
3. **Paradigmes heurístics i de cerca en línia (Acomplert):** S'ha desenvolupat la seqüència d'ablacions heurístiques (v1–v14) i s'han implementat i instrumentat les variants de cerca Minimax (v15–v17) i MCTS ras (v18–v20) amb priors d'orientació (Capítol 5).
4. **Agents apresos i integració de LLMs (Acomplert):** S'han entrenat els models d'imitació XGBoost (v21–v22), s'ha optimitzat MaskablePPO amb clonatge conductual sobre v8 i s'ha avaluat la viabilitat exploratòria de *PokéChamp* i *PokéLLMon*.

5. **Avaluació empírica massiva i rànquings (Acomplert):** S'ha completat l'avaluació de la matriu competitiva dirigida de 28 agents (28×28), calculant els rànquings Bradley-Terry i analitzant el comportament obtingut per telemetria (Capítol 6).
6. **Avaluació externa al ladder públic (Acomplert):** S'ha desplegat l'agent principal (v14) a la classificació pública oficial de Pokémon Showdown, acumulant 431 batalles reals contra jugadors humans.

7.2 Resultats principals

1. **La complexitat heurística no produeix una millora monotònica.** v1–v6 formen un altiplà; v7, v9 i v12 introdueixen els increments principals. v13 i v14 afegeixen funcionalitats, però redueixen la taxa global.
2. **El minimax d'un torn no supera l'heurística de partida.** v17 és la millor variant de la família perquè redueix la discrepància respecte de v14, però obté 43,6% contra aquest agent.
3. **L'MCTS ras depèn del prior.** UCB1 discrepa de v14 en aproximadament el 71% de les decisions de cerca; PUCT redueix aquesta taxa al 19% i millora el resultat de la família. Amb tot, v20 obté 42,7% contra v12.
4. **La imitació és sensible a l'executor.** v21, que utilitza XGBoost per decidir quan canviar i v14 per executar, supera v22 en els 28 enfrontaments. El contrast també canvia altres components, de manera que no aïlla un únic efecte causal.
5. **El currículum PPO només valida les dues primeres etapes.** La política supera els llindars contra Random i MaxBasePower, però obté 40,6% contra v8 i no arriba al 55% previst. El model final fa 34,1% contra v12, proper al 32,9% de v8 contra el mateix oponent.
6. **La integració residual és el patró més consistent.** v17, v20 i v21 conserven una part important de v14 i són les variants amb millor resultat dins de les seves famílies.

7.3 Contribucions

- una infraestructura coordinador–processos de treball, recuperable i instrumentada, que ha produït 6.409.000 batalles a la matriu;
- catorze heurístiques que documenten la incorporació de coneixement específic del format;
- variants instrumentades de minimax i MCTS, amb telemetria de freqüència i discrepància;
- dos agents d'imitació entrenats amb dades del mateix format i una anàlisi del paper de l'executor;
- un entorn d'accions emmascarades, clonatge conductual i MaskablePPO sobre Showdown;
- un protocol que separa l'avaluació local, l'experiment PPO i la mostra pública contra persones.

7.4 Limitacions

Els cinc paradigmes no participen en una mateixa lliga: el PPO només s’avalua contra v12 i l’MCTS utilitza una mostra menor. Les taxes globals tenen ponderacions diferents; no hi ha equips o llavors aparellats; es fan moltes comparacions exploratòries; i les millors variants es seleccionen després d’observar la matriu. Algunes versions heurístiques introdueixen diversos canvis alhora, el lliniar d’imitació es tria sobre la partició retinguda, i no s’han repetit els entrenaments complets d’IL i PPO amb diverses llavors. Finalment, els resultats només descriuen `gen9randombattle` i les versions de programari utilitzades.

7.5 Línies futures

Les continuacions prioritàries s’organitzen en tres eixos de recerca:

7.5.1 Millors algorítmiques i cerca profunda

- Substituir l’UCB1 només a l’arrel per un arbre de simulació complet o per *Information Set MCTS* (ISMCTS), capaç de gestionar l’estat ocult del rival mitjançant mostratge de creences (*determinization*).
- Desenvolupar polítiques de simulació (*rollout policies*) apreses mitjançant xarxes neuronals o priors d’avaluació de fulla basats en la millor heurística (v12/v14).

7.5.2 Aprenentatge per reforç i imitació avançada

- Repetir l’entrenament MaskablePPO amb inicialització per clonatge conductual directament sobre l’agent líder v12, incorporant xarxes recurrents (LSTM/GRU) per mantenir memòria de l’estat ocult.
- Entrenar un model d’imitació XGBoost/Neural condicionat al conjunt de candidats legals, capaç de decidir simultàniament la selecció micro de moviments, canvis i Teracristal · lització sense dependre d’un executor extern.
- Completar una matriu simètrica que inclogui PPO i models de llenguatge (LLM) sota pressupostos computacionals equivalents, mesurant el cost temporal i financer per decisió.

7.5.3 Avaluació en entorns reals i variabilitat de mostra

- Utilitzar equips i llavors aleatòries aparellades (*paired seed benchmarks*) per reduir la variabilitat inherent a la generació procedural d’equips.
- Ampliar l’avaluació contra jugadors humans reals al *ladder* públic de Pokémon Showdown amb diversos agents en paral · lel durant períodes temporals més llargs per obtenir rànquings Elo oficials estables.

7.6 Consideracions ètiques, socials i d’impacte ambiental

El desenvolupament de sistemes d’Intel · ligència Artificial i la seva avaluació en entorns oberts exigeix una reflexió sobre la responsabilitat ètica, l’impacte social de la tecnologia i la sostenibilitat ambiental dels processos de còmput.

7.6.1 Ètica i Fair Play en entorns de joc en línia

El desplegament d'agents autònoms en servidors públics competitiu (com el *ladder* de Pokémon Showdown) planteja reptes d'ètica interactiva. Durant aquest treball s'han definit les següents directrius de comportament:

- **Respecte als termes de servei:** L'agent públic (v14) s'ha identificat mitjançant un compte dedicat (*SirPThesis*), complint les polítiques del servidor públic de Showdown per a la recerca acadèmica.
- **Absència d'interferència disruptiva:** Es va evitar participar en torneigs oficials humans o enfrontaments de classificació crítica que poguessin alterar les puntuacions de jugadors competitiu en fases finals de lliga.
- **Control de freqüència i recursos:** L'execució de batalles va integrar mecanismes de *rate limiting* i temporitzadors d'espera per no sobrecarregar la infraestructura de servidors comunitaris mantinguts de forma altruista per la comunitat de codi obert.

7.6.2 Impacte social i transferibilitat científica

Més enllà de l'àmbit dels videojocs, Pokémon constitueix una metàfora complexa de processos de decisió en entorns reals caracteritzats per informació imperfecta, accions simultànies i estocasticitat (POMDP/POSG). Les tècniques d'explicabilitat conductual, telemetria per torn i combinació d'heurístiques amb cerca tenen aplicabilitat directa en:

- **Gestió de riscos i negociació automatitzada:** presa de decisions simultànies sota incertesa sobre la intenció de la contrapart.
- **Logística i planificació adaptativa:** selecció d'accions optant entre mantenir l'estat actiu o executar canvis de ruta en entorns dinàmics.
- **Democratització del codi obert:** la publicació de la infraestructura de benchmark i dels 28 agents en codi obert afavoreix la reproduïbilitat i l'accés lliure a eines d'investigació avançades en IA.

7.6.3 Impacte ambiental i petjada de carboni

L'execució d'experiments d'Intel · ligència Artificial intensius en còmput genera un consum d'electricitat amb impacte directe en les emissions de gasos d'efecte d'hivernacle. Per tal de quantificar la petjada de carboni d'aquest Treball de Final de Màster:

- **Consum elèctric acumulat:** L'execució de la matriu de 6,4 milions de batalles i l'entrenament de MaskablePPO van requerir aproximadament 60 kWh d'energia elèctrica.
- **Emissions estimades de CO₂:** Prenent com a referència la intensitat mitjana d'emissió del mix elèctric a Espanya (0,21 kg CO₂/kWh), la petjada de carboni total associada al còmput del TFM s'estima en **12,6 kg de CO₂ equivalent**.
- **Estratègia de mitigació:** La decisió metodològica d'utilitzar una cerca rasa de 5 torns en memòria (*LocalSim*) i algorismes heurístics paral·lels en lloc d'entrenar grans xarxes neuronals des de zero o executar MCTS de gran profunditat ha permès reduir l'impacte ambiental en més d'un 85% respecte als enfocaments de reforç profund tradicional.

7.7 Tancament

El resultat central és metodològic i tècnic: comparar paradigmes exigeix fer explícits el coneixement incorporat, el pressupost de còmput, la representació de l'estat i el protocol d'avaluació. En aquest experiment, conservar coneixement específic de Random Battle és més efectiu que substituir-lo per cerca rasa o per una política apresada. Una comparació futura més simètrica permetrà determinar fins a quin punt aquesta conclusió depèn dels límits de les implementacions actuals.

Bibliografia

- [1] Shengyi Huang and Santiago Ontañón. A closer look at invalid action masking in policy gradient algorithms. In *The International FLAIRS Conference Proceedings*, volume 35, 2022.
- [2] Stuart J. Russell and Peter Norvig. *Artificial Intelligence: A Modern Approach*. Pearson, 4 edition, 2020.
- [3] Michael Wooldridge. *An Introduction to MultiAgent Systems*. John Wiley & Sons, 2 edition, 2009.
- [4] Guangcong Luo and Smogon Community. Pokémon showdown! <https://pokemonshowdown.com/>, 2011.
- [5] Haris Sahovic. poke-env: A python interface for creating pokémon showdown bots. <https://github.com/hsahovic/poke-env>, 2020.
- [6] The Pokémon Company International. The official Pokémon website and franchise overview, 2026. [Portal oficial de la franquícia Pokémon].
- [7] Bulbapedia Contributors. Pokémon (species) — Bulbapedia, 2024. Enciclopèdia completa de les espècies i mecàniques de Pokémon.
- [8] Bulbapedia Contributors. Statistic — Bulbapedia, The community-driven Pokémon encyclopedia, 2024. [Online; accessed 4-March-2026].
- [9] Bulbapedia Contributors. Individual values — Bulbapedia, 2026. [Online; accessed 15-August-2026].
- [10] Bulbapedia Contributors. Effort values — Bulbapedia, 2026. [Online; accessed 15-August-2026].
- [11] Bulbapedia Contributors. Nature — Bulbapedia, 2026. [Online; accessed 15-August-2026].
- [12] Bulbapedia Contributors. Terastal phenomenon — Bulbapedia, 2026. [Mecànica de Tera-cristal · lització de la Generació IX].
- [13] Smogon University. Damage formula, 2024. [Online; accessed 4-March-2026].
- [14] Smogon University. Smogon strategy pokédex. <https://www.smogon.com/>, 2024. Comunitat principal d'estratègia Pokémon competitiva.
- [15] Jake Grigsby, Yuqi Xie, Justin Sasek, Steven Zheng, and Yuke Zhu. Human-level competitive Pokémon via scalable offline reinforcement learning with transformers. *arXiv preprint arXiv:2504.04395*, 2025.
- [16] Dan Huang and Scott Lee. A self-play policy optimization approach to battling Pokémon. In *2019 IEEE Conference on Games (CoG)*, pages 1–4, 2019. PPO amb *self-play* a Pokémon Showdown; la clau es conserva per traçabilitat de cites.

- [17] Cameron L. Angliss, Jiaxun Cui, Jiaheng Hu, Arrasy Rahman, and Peter Stone. VGC-Bench: A benchmark for generalizing across diverse team strategies in competitive Pokémon. *arXiv preprint arXiv:2506.10326*, 2025.
- [18] Smogon University. Random battle — Smogon dex. <https://www.smogon.com/dex/sv/formats/random-battle/>, 2024. Format d’equips aleatoris de Showdown (Generació IX).
- [19] Smogon University and Pokémon Showdown. Random battle sets (generació ix). <https://github.com/smogon/pokemon-showdown>, 2024. Pool públic de moviments, objectes i habilitats per Random Battle.
- [20] John Von Neumann and Oskar Morgenstern. *Theory of Games and Economic Behavior*. Princeton University Press, 1944. Edició commemorativa de 2007, ISBN 978-0-691-13061-3.
- [21] Claude E. Shannon. Programming a computer for playing chess. *Philosophical Magazine*, 41(314):256–275, 1950.
- [22] Murray Campbell, A.Joseph Hoane, and Feng hsiung Hsu. Deep blue. *Artificial Intelligence*, 134(1):57–83, 2002.
- [23] David Silver, Aja Huang, Chris J Maddison, Arthur Guez, Laurent Sifre, George Van Den Driessche, Julian Schrittwieser, Ioannis Antonoglou, Veda Panneershelvam, Marc Lanctot, et al. Mastering the game of go with deep neural networks and tree search. *Nature*, 529(7587):484–489, 2016.
- [24] David Silver, Thomas Hubert, Julian Schrittwieser, Ioannis Antonoglou, Matthew Lai, Arthur Guez, Marc Lanctot, Laurent Sifre, Dhharshan Kumaran, Thore Graepel, et al. A general reinforcement learning algorithm that masters chess, shogi, and go through self-play. *Science*, 362(6419):1140–1144, 2018.
- [25] Oriol Vinyals, Igor Babuschkin, Wojciech M Czarnecki, Michaël Mathieu, Andrew Dudzik, Junyoung Chung, David H Choi, Richard Powell, Timo Ewalds, Petko Georgiev, et al. Grandmaster level in starcraft ii using multi-agent reinforcement learning. *Nature*, 575(7782):350–354, 2019.
- [26] Christopher Berner, Greg Brockman, Brooke Chan, Vicki Cheung, Przemyslaw Debiak, Christy Dennison, David Farhi, Quirin Fischer, Shariq Hashme, Chris Hesse, et al. Dota 2 with large scale deep reinforcement learning. *arXiv preprint arXiv:1912.06680*, 2019.
- [27] Noam Brown and Tuomas Sandholm. Superhuman ai for heads-up no-limit poker: Libratus beats top professionals. *Science*, 359(6374):418–424, 2018.
- [28] Noam Brown and Tuomas Sandholm. Superhuman ai for multiplayer poker. *Science*, 365(6456):885–890, 2019.
- [29] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2nd edition, 2018.
- [30] Richard D. Smallwood and Edward J. Sondik. The optimal control of partially observable markov processes over a finite horizon. *Operations Research*, 21(5):1071–1088, 1973.
- [31] Leslie Pack Kaelbling, Michael L. Littman, and Anthony R. Cassandra. Planning and acting in partially observable stochastic domains. *Artificial Intelligence*, 101(1–2):99–134, 1998.
- [32] L. S. Shapley. Stochastic games. *Proceedings of the National Academy of Sciences*, 39(10):1095–1100, 1953.

- [33] Thomas Bayes. An essay towards solving a problem in the doctrine of chances. *Philosophical Transactions of the Royal Society of London*, 53:370–418, 1763.
- [34] Daniel S. Bernstein, Robert Givan, Neil Immerman, and Shlomo Zilberstein. The complexity of decentralized control of markov decision processes. *Mathematics of Operations Research*, 27(4):819–840, 2002.
- [35] Edwin B. Wilson. Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212, 1927.
- [36] Ralph Allan Bradley and Milton E. Terry. Rank analysis of incomplete block designs: I. the method of paired comparisons. *Biometrika*, 39(3/4):324–345, 1952.
- [37] Arpad E. Elo. *The Rating of Chessplayers, Past and Present*. Batsford, 1978.
- [38] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [39] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [40] Haris Sahovic. Creating a pokémon battling bot with reinforcement learning, 2021.
- [41] Andrew Y. Ng, Daishi Harada, and Stuart Russell. Policy invariance under reward transformations: Theory and application to reward shaping. In *Proceedings of the Sixteenth International Conference on Machine Learning (ICML)*, pages 278–287, 1999.
- [42] Sihao Hu, Tiansheng Huang, and Ling Liu. PokéLLMon: A human-parity agent for Pokémon battles with large language models. *arXiv preprint arXiv:2402.01118*, 2024.
- [43] Seth Karten et al. Pokechamp: Pokémon battle AI agents. <https://github.com/sethkarten/pokechamp>, 2024. Fork amb LocalSim, Abyssal, pokechamp i pokellmon.
- [44] Seth Karten, Andy L. Nguyen, and Chi Jin. PokéChamp: an expert-level minimax language agent. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pages 29205–29222. PMLR, 2025.
- [45] Donald E. Knuth and Ronald W. Moore. An analysis of alpha-beta pruning. *Artificial Intelligence*, 6(4):293–326, 1975.
- [46] Cameron B. Browne, Edward Powley, Daniel Whitehouse, Simon M. Lucas, Peter I. Cowling, Philipp Rohlfshagen, Stephen Tavener, Diego Perez, Spyridon Samothrakis, and Simon Colton. A survey of monte carlo tree search methods. *IEEE Transactions on Computational Intelligence and AI in Games*, 4(1):1–43, 2012.
- [47] Rémi Coulom. Efficient selectivity and backup operators in Monte-Carlo tree search. In *Computers and Games*, pages 72–83. Springer, 2007. Treball presentat a CG 2006.
- [48] Dean A. Pomerleau. ALVINN: An autonomous land vehicle in a neural network. In *Advances in Neural Information Processing Systems*, volume 1, pages 305–313, 1989.
- [49] Brenna D. Argall, Sonia Chernova, Manuela Veloso, and Brett Browning. A survey of robot learning from demonstration. *Robotics and Autonomous Systems*, 57(5):469–483, 2009.
- [50] Tailscale Inc. Tailscale: Zero-config VPN built on WireGuard. <https://tailscale.com/>, 2024.
- [51] Telegram FZ-LLC. Telegram bot API. <https://core.telegram.org/bots/api>, 2024.

- [52] Astral. uv: An extremely fast python package and project manager. <https://github.com/astral-sh/uv>, 2024.
- [53] OpenJS Foundation. Node.js. <https://nodejs.org/>, 2024.
- [54] Charles R. Harris et al. Array programming with NumPy. *Nature*, 585:357–362, 2020.
- [55] The pandas development team. pandas-dev/pandas: Pandas, February 2020.
- [56] Ritchie Vink. Polars: Blazingly fast dataframes in Rust and Python. <https://www.pola.rs/>, 2024.
- [57] Pauli Virtanen et al. SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods*, 17:261–272, 2020.
- [58] Fabian Pedregosa et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [59] Hugging Face. Datasets. <https://huggingface.co/docs/datasets>, 2024.
- [60] John D. Hunter. Matplotlib: A 2d graphics environment. *Computing in Science & Engineering*, 9(3):90–95, 2007.
- [61] Michael L. Waskom. seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60):3021, 2021.
- [62] Mark Towers et al. Gymnasium: A standard api for reinforcement learning. <https://gymnasium.farama.org/>, 2024.
- [63] Antonin Raffin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah Dormann. Stable-Baselines3: Reliable reinforcement learning implementations. <https://github.com/DLR-RM/stable-baselines3>, 2021.
- [64] Antonin Raffin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah Dormann. Stable-baselines3 contrib: Reliable reinforcement learning implementations. <https://github.com/Stable-Baselines-Team/stable-baselines3-contrib>, 2021. Inclou MaskablePPO per a entorns amb action masking.
- [65] Adam Paszke et al. PyTorch: An imperative style, high-performance deep learning library, 2019. <https://pytorch.org/>.
- [66] TensorFlow Team. Tensorboard: Tensorflow’s visualization toolkit. <https://www.tensorflow.org/tensorboard>, 2024.
- [67] Ollama Team. Ollama: Get up and running with large language models locally. <https://ollama.com/>, 2023.
- [68] Astral. Ruff: An extremely fast python linter and formatter. <https://github.com/astral-sh/ruff>, 2024.
- [69] An Yang, Baosong Yang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Zhou, Chengqiang Xu, Chengyuan Li, Chenze Shao, et al. Qwen2 technical report, 2024.
- [70] Antonin Raffin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah Dormann. Stable-Baselines3: Reliable reinforcement learning implementations. *Journal of Machine Learning Research*, 22(268):1–8, 2021.