



Facultat Internacional de Comerç i Economia Digital La Salle

Treball de Final de Màster

Màster Universitari en Ciència de les Dades / Data Science

Presa de decisions en entorns estocàstics d'informació imperfecta: comparació de paradigmes d'agents a Pokémon

*Avaluació empírica d'heurístiques, minimax
d'un torn, MCTS ras, imitació i MaskablePPO*

Alumne/a:

Gerard Pascual Fontanilles

Professor/a Ponent:

Laura Serra Roig

Barcelona, Setembre 2026

ACTA D'EXAMEN DEL TREBALL DE FINAL DE MÀSTER

Reunit el Tribunal qualificador en el dia de la data, l'alumne/a:

Gerard Pascual Fontanilles

Va exposar el seu Treball de Final de Màster, el qual va tractar sobre el tema següent:

Presa de decisions en entorns estocàstics d'informació imperfecta: comparació de paradigmes d'agents a Pokémon

Acabada l'exposició i contestades per part de l'alumne/a les objeccions formulades pels membres del tribunal, aquest va valorar l'esmentat Treball amb la qualificació de:

Qualificació Qualitativa	Qualificació Numèrica

Barcelona, a _____ de _____ de 2026

VOCAL DEL TRIBUNAL

VOCAL DEL TRIBUNAL

PRESIDENT DEL TRIBUNAL

Resum

Els videojocs d'estratègia amb informació imperfecta, accions simultànies i dinàmica estocàstica constitueixen un banc de proves exigent per a la presa de decisions en Intel·ligència Artificial. Aquest Treball de Final de Màster formula, desenvolupa i avalua cinc paradigmes d'agents en el format individual (**gen9randombattle**) de Pokémon competitiu, utilitzant el simulador Pokémon Showdown i el marc *poke-env*.

El problema es formalitza com un joc estocàstic d'observació parcial (POSG) de dos jugadors i suma zero amb accions simultànies, reduït a POMDP en PPO i XGBoost en operar sobre observacions parcials $o_i \in \Omega_i$. En un espai combinatòriament ingent amb equips i moviments ocults, l'objectiu no és només maximitzar la taxa de victòries sota pressupostos explícits, sinó analitzar, mitjançant telemetria per torn, la gestió del risc, la predicció de canvis, el ritme i l'ús estratègic de la Teracristal·lització.

S'implementen cinc paradigmes homogenis: (1) una seqüència d'ablació de catorze heurístiques (**v1–v14**) amb coneixement de domini incremental (càlcul de dany, efectivitat de tipus, *hazards*, preparació, estats alterats i Teracristal·lització); (2) cerca adversària d'un torn (*minimax* **v15–v17**) amb funcions d'avaluació a les fulles; (3) cerca en arbre de Monte Carlo superficial (*shallow* MCTS **v18–v20**, 5 torns) comparant UCB1 i PUCT amb priors heurístics; (4) aprenentatge per imitació (**v21–v22**) amb XGBoost sobre partides humanes d'alt nivell (Elo 1800+) per classificar atacs o canvis; i (5) aprenentatge per reforç profund (*MaskablePPO*) amb accions emmascarades i clonatge conductual. L'avaluació emprà una infraestructura paral·lela amb telemetria per torn i rànquings Bradley–Terry.

L'avaluació empírica sobre 28 agents (6,4 milions de batalles) i proves de DRL situa l'heurística **v12** com a líder global, superant el referent competitiu *Abyssal* amb un 59,9% de victòries. **v14**, més exhaustiva en regles i utilitzada com a fulla, prior i agent al *ladder* públic, no millora el rendiment de **v12**. Cap variant de cerca, imitació o DRL supera **v12** sota els pressupostos avaluats. La telemetria conclou que la incertesa de l'estat ocult rival limita la cerca superficial, mentre que els mètodes apresos requereixen integrar coneixement de domini expert per assolir nivell competitiu.

Paraules clau: Intel·ligència Artificial en jocs, presa de decisions sota incertesa, POSG, POMDP, agents heurístics, cerca adversària (Minimax), cerca en arbre de Monte Carlo (MCTS), aprenentatge per imitació (XGBoost), aprenentatge per reforç profund (MaskablePPO), telemetria, perills d'entrada (*hazards*), model Bradley–Terry.

Resumen

Los videojuegos de estrategia con información imperfecta, acciones simultáneas y dinámica estocástica plantean un reto complejo para la toma de decisiones en Inteligencia Artificial. Este Trabajo de Fin de Máster formula, desarrolla y evalúa cinco paradigmas de agentes en el formato individual (**gen9randombattle**) del videojuego competitivo Pokémon, utilizando Pokémon Showdown y el marco *poke-env*.

El problema se formaliza como un juego estocástico de observación parcial (POSG) de dos jugadores y suma cero con acciones simultáneas, reducido a POMDP en PPO y XGBoost al operar sobre observaciones locales $o_i \in \Omega_i$. En un espacio combinatoriamente inmenso con equipos y movimientos ocultos, el objetivo no es solo maximizar victorias bajo presupuestos explícitos, sino analizar mediante telemetría por turno la gestión del riesgo, la predicción de cambios, el ritmo y el uso táctico de la Teracristalización.

Se implementan cinco paradigmas homogéneos: (1) una serie de ablación de catorce heurísticas (**v1–v14**) con conocimiento incremental (cálculo de daño, efectividad de tipos, *hazards*, potenciación, estados y Teracristalización); (2) búsqueda adversaria de un turno (*minimax* **v15–v17**) con evaluación en hojas; (3) búsqueda en árbol de Monte Carlo superficial (*shallow* MCTS **v18–v20**, 5 turnos) contrastando UCB1 y PUCT con priors heurísticos; (4) aprendizaje por imitación (**v21–v22**) con XGBoost sobre partidas humanas de élite (Elo 1800+) para clasificar ataques o cambios; y (5) aprendizaje por refuerzo profundo (*MaskablePPO*) con acciones enmascaradas y clonación conductual. La evaluación utiliza una infraestructura paralela con telemetría por turno y clasificaciones Bradley–Terry.

La evaluación empírica sobre 28 agentes (6,4 millones de batallas) y pruebas de DRL posiciona a la heurística **v12** como líder global, superando al referente competitivo *Abyssal* con un 59,9% de victorias. **v14**, más exhaustiva en reglas y empleada como hoja, prior y agente en el *ladder* público, no supera a **v12**. Ninguna variante de búsqueda, imitación o DRL supera a **v12** bajo los presupuestos evaluados. La telemetría revela que la incertidumbre del estado oculto rival limita la búsqueda superficial, y que los modelos aprendidos requieren incorporar conocimiento experto de dominio para ser competitivos.

Palabras clave: Inteligencia Artificial en juegos, toma de decisiones bajo incertidumbre, POSG, POMDP, agentes heurísticos, búsqueda adversaria (Minimax), búsqueda en árbol de Monte Carlo (MCTS), aprendizaje por imitación (XGBoost), aprendizaje por refuerzo profundo (MaskablePPO), telemetría, peligros de entrada (*hazards*), modelo Bradley–Terry.

Abstract

Complex strategy video games with imperfect information, simultaneous actions, and stochastic dynamics represent a demanding testbed for decision-making in Artificial Intelligence. This Master’s Thesis formulates, implements, and benchmarks five agent paradigms for the singles format (**gen9randombattle**) of competitive Pokémon, leveraging Pokémon Showdown and the *poke-env* framework.

The environment is formalized as a two-player, zero-sum Partially Observable Stochastic Game (POSG) with simultaneous actions, reduced to a POMDP in PPO and XGBoost via partial observations $o_i \in \Omega_i$. Across a combinatorially vast state space with hidden teams and movepools, the objective extends beyond maximizing win rates under explicit budgets: fine-grained per-turn telemetry is used to analyze risk management, switch prediction, tempo control, and tactical Terastallization.

Five standardized paradigms are developed: (1) a 14-agent ablation sequence (**v1–v14**) incrementally incorporating domain expertise (damage formulas, type charts, hazards, setup moves, status conditions, and Terastallization); (2) one-turn adversarial search (*minimax* **v15–v17**) with leaf evaluations; (3) shallow Monte Carlo Tree Search (*shallow* MCTS **v18–v20**, 5-turn rollouts) comparing UCB1 with heuristic-prior-guided PUCT; (4) imitation learning (**v21–v22**) using XGBoost trained on high-level human replays (Elo 1800+) to predict attack vs. switch decisions; and (5) Deep Reinforcement Learning (*MaskablePPO*) with action masking and Behavioral Cloning initialization. Evaluation relies on a parallel, resilient pipeline with per-turn telemetry and Bradley–Terry rankings.

Empirical benchmarking across 28 agents (6.4 million battles) and dedicated DRL experiments identifies heuristic **v12** as the top performer, surpassing the competitive baseline *Abyssal* with a 59.9% win rate. Meanwhile, **v14**—the most rule-complete agent, used as leaf evaluator, search prior, and live ladder agent—does not improve upon **v12**. Under the evaluated computational budgets, no search, imitation, or DRL variant beats **v12**. Telemetry demonstrates that hidden state uncertainty severely constrains shallow search, while learned models strictly require expert domain knowledge to achieve competitive play.

Keywords: Game Artificial Intelligence, decision-making under uncertainty, POSG, POMDP, heuristic agents, adversarial search (Minimax), Monte Carlo Tree Search (MCTS), imitation learning (XGBoost), Deep Reinforcement Learning (MaskablePPO), telemetry, entry hazards, Bradley–Terry model.

Índex

Resum	i
Resumen	ii
Abstract	iii
1 Introducció	1
1.1 Contextualització i motivació	1
1.2 Objectius del treball i hipòtesis de recerca	2
1.2.1 Objectius específics	2
1.2.2 Hipòtesis de recerca	2
1.3 Estructura de la memòria	3
2 Marc teòric i contextualització	4
2.1 Pokémon com a domini de decisió	4
2.1.1 Què és Pokémon i com es desenvolupa una batalla	4
2.1.2 De l'espècie a les estadístiques finals	5
2.1.3 Tipus elementals, matriu d'efectivitat i categories de moviment	6
2.1.4 Teracristal·lització (Generació IX)	7
2.1.5 Velocitat, prioritat i l'empat de velocitat	8
2.1.6 Condicions d'estat primàries	8
2.1.7 Fonts d'estocasticitat irreductibles	9
2.1.8 Complexitat combinatoria en la configuració d'equips	10
2.1.9 El format Random Battle, el simulador Showdown i poke-env	11
2.1.10 Síntesi del domini: Pokémon com a entorn benchmark ideal per a la IA	11
2.2 Formalització matemàtica i marc d'inferència estadística	12
2.2.1 De la informació perfecta a la informació imperfecta	13
2.2.2 Formalització dels Processos de Decisió: MDP, POMDP i POSG	14
2.2.3 Estat de creença, matriu de recompenses i reducció d'enginyeria	16
2.2.4 Instanciació dels components a <code>gen9randombattle</code>	17
2.2.5 Marc d'avaluació estadística i mètodes d'inferència	18
2.3 Estat de l'Art en IA i Pokémon	20
2.3.1 Plataformes d'integració i entorns de simulació	20
2.3.2 Aprenentatge per reforç profund i exploració autònoma	20
2.3.3 Aprenentatge fora de línia i arquitectures basades en Transformers	21
2.3.4 Models de llenguatge de gran escala i cerca adversària híbrida	21
2.3.5 Mancances de la literatura i justificació d'aquest treball	21
2.3.6 Què afegeix aquest TFM	21
2.3.7 Posicionament comparatiu respecte a la literatura	22
2.4 Fonaments teòrics dels cinc paradigmes de decisió	22
2.4.1 Heurístiques: coneixement com a ablació	23
2.4.2 Minimax d'un torn: resposta adversària immediata	23

2.4.3	Cerca de Monte Carlo a l'arrel (shallow MCTS)	24
2.4.4	Imitació i clonatge conductual	25
2.4.5	Aprenentatge per reforç profund amb emmascarament d'accions	26
2.5	Síntesi del marc teòric	27
3	Metodologia i disseny experimental	28
3.1	Disseny general de l'estudi	28
3.1.1	Unitat d'anàlisi i telemetria	28
3.1.2	Concepte i responsabilitats del gestor de batalles	28
3.2	Contracte d'entorn i protocol de comunicació	29
3.2.1	Showdown i <i>poke-env</i> : àrbitre, protocol i objecte de batalla	30
3.2.2	Cicle d'un torn de batalla	31
3.3	Arquitectura conceptual d'avaluació massiva	32
3.3.1	Per què una arquitectura paral·lela i aïllada	33
3.3.2	Model coordinador i treballadors efímers	33
3.3.3	Represa, persistència i reinici del simulador	34
3.4	Disseny conceptual de les famílies d'agents	34
3.4.1	Agents de referència	35
3.4.2	Família Heurística: genealogia, hipòtesis d'ablació i la pregunta del valor marginal	35
3.4.3	Família Minimax: tres variants de resolució de la matriu d'un torn	36
3.4.4	Família MCTS: variants de simulació i mètrica de discrepància	38
3.4.5	Família d'Imitació Jeràrquica: desacoblament macro/micro i dues arquitectures	40
3.4.6	Família DRL (MaskablePPO): currículum de dificultat creixent	41
3.5	Contracte de comparació i espais d'observació	43
3.6	Matriu experimental i nivells mostrals	43
3.6.1	Orientacions recíproques, autojoc i escala Bradley–Terry	44
3.7	Mètriques de rendiment i telemetria d'execució	45
3.7.1	Mètrica primària: taxa de victòries i model Bradley–Terry	45
3.7.2	Mètriques secundàries i capa d'intercepció de telemetria (<i>StatsBattle</i>)	45
3.8	Protocols d'avaluació especials i abast	46
3.8.1	Integració exploratòria d'agents LLM	46
3.8.2	Avaluació dedicada de MaskablePPO	47
3.8.3	Avaluació en la classificació pública i coordinació amb desenvolupadors	47
3.9	Amenaces a la validesa i reproductibilitat	48
3.10	Síntesi i continuïtat	48
4	Entorn de desenvolupament i infraestructura de còmput	49
4.1	Organització del projecte i gestió amb Kanban	49
4.2	Evolució de l'arquitectura	49
4.2.1	Fase 1: prototipatge en portàtil	49
4.2.2	Fase 2: estació de treball	50
4.3	Control de versions, traçabilitat i mètriques del programari	50
4.4	Accés remot i continuïtat	51
4.5	Bot de Telegram i monitoratge de seguretat	51
4.6	Dependències	51
4.6.1	Congelació de versions i integració dels tres repositoris clau	52
4.7	Ecosistema de redacció i documentació en $\text{\LaTeX}$	52
4.8	Anàlisi de cost econòmic i pressupost de recursos	52
4.8.1	Estimació de dedicació de l'equip i costos de personal	53
4.8.2	Costos directes d'infraestructura, maquinari i energia	54

4.8.3	Pressupost econòmic total consolidat	55
5	Implementació dels cinc paradigmes	57
5.1	Mapa del programari	57
5.2	Motor de batalla i capa d'integració	57
5.2.1	Servidor local de Pokémon Showdown	58
5.2.2	Versions i forks de <i>poke-env</i>	58
5.3	Arquitectura coordinador–processos de treball	58
5.3.1	Esquema CSV: captura, escriptura i columnes per família	59
5.3.2	De la matriu a les figures	60
5.3.3	Llançador de la matriu	60
5.3.4	Contracte <code>BaseHeuristicv1</code> i <code>AgentFactory</code>	62
5.4	Heurístiques <code>v1–v14</code> : incorporació de coneixement	62
5.4.1	Estructura de classes i operacions compartides	62
5.4.2	Decisions que no es desprenen de la genealogia	63
5.5	Minimax d'un torn <code>v15–v17</code>	63
5.5.1	Construcció de la matriu	63
5.6	MCTS ras <code>v18–v20</code>	64
5.7	Imitació <code>v21–v22</code>	64
5.7.1	Dades i entrenament	65
5.7.2	Adaptadors en línia	66
5.8	Baselines i agents de llenguatge	66
5.9	PPO: MaskablePPO sobre Showdown	66
5.9.1	Organització del mòdul i dels artefactes	66
5.9.2	Entorn	67
5.9.3	Clonatge, arquitectura i recompensa	68
5.9.4	Execució de les fases 1, 1.5, 2 i 3	68
5.10	Desplegament a la classificació pública	69
5.10.1	Arquitectura del client i autenticació	69
5.10.2	Tolerància a fallades	70
5.11	Síntesi i continuïtat	70
6	Resultats	71
6.1	Protocol de lectura dels resultats	71
6.2	Controls globals de la matriu	72
6.3	Fil conductor de <code>v1</code> a <code>v22</code>	72
6.4	L'escala heurística: tres canvis de règim	73
6.4.1	Altiplà <code>v1–v6</code> : rendiments decreixents del càlcul de dany	73
6.4.2	Primer salt: <code>v7</code> (i <code>v8/v10</code>)	74
6.4.3	Segon salt: <code>v9</code> / <code>v11</code>	75
6.4.4	Tercer salt: <code>v12</code>	75
6.5	La inversió entre <code>v12</code> , <code>v13</code> i <code>v14</code>	76
6.5.1	On <code>v13</code> encara guanya	77
6.5.2	Per què no supera <code>v12</code> en global	77
6.5.3	Especialització de <code>v14</code> i pèrdua de rendiment local	77
6.6	Minimax d'un torn	79
6.6.1	Freqüència d'intervenció	79
6.6.2	<code>v16</code> i l'avaluació de la fulla	79
6.6.3	<code>v17</code> : prior heurístic	80
6.6.4	Canvis, durada i supervivència	80
6.7	MCTS ras: UCB a l'arrel i simulacions de cinc torns	82
6.7.1	Freqüència d'intervenció	82

6.7.2	Discrepància i resultat	83
6.7.3	PUCT i el prior heurístic	83
6.7.4	Indicadors d'efectes diferits	83
6.7.5	Comparació amb els agents de referència	83
6.7.6	Canvis, durada i supervivència	84
6.8	Aprenentatge per imitació: dues formes d'execució	85
6.8.1	Rendiment dins de la matriu	85
6.8.2	Pes efectiu del model a v21	86
6.8.3	Factors que limiten v22	87
6.8.4	Canvis, durada i supervivència	87
6.9	Comparació entre els cinc paradigmes	89
6.9.1	Abyssal com a agent de referència	89
6.9.2	Escala Bradley–Terry	89
6.10	Classificació pública: avaluació exploratòria de v14	93
6.11	PPO contra v12	94
6.11.1	Resultat principal	94
6.11.2	Curriculum	95
6.11.3	Interpretació del límit observat	95
6.12	Discussió	95
6.12.1	Patró d'integració residual	95
6.12.2	Resposta conjunta a la pregunta de recerca	96
6.12.3	Limitacions específiques dels resultats	96
7	Conclusions i línies futures	97
7.1	Resposta a la pregunta de recerca	97
7.1.1	Grau d'acompliment dels objectius específics	97
7.2	Resultats principals i avaluació de les hipòtesis	98
7.3	Contribucions	99
7.4	Limitacions	99
7.5	Línies futures	99
7.5.1	Cerca, creences i priors	99
7.5.2	Aprenentatge per reforç i imitació	100
7.5.3	Avaluació: llavors i persones	100
7.6	Consideracions ètiques, socials i d'impacte ambiental	100
7.6.1	Ètica i fair play en entorns de joc en línia	100
7.6.2	Impacte social i transferibilitat científica	101
7.6.3	Impacte ambiental i petjada de carboni	101
7.7	Tancament	101
A	Material complementari	102
A.1	Detalls operatius de la infraestructura	102
A.1.1	Configuració de xarxa Tailscale	102
A.1.2	Bot de Telegram: detalls de les comandes	102
A.1.3	Congelació de versions dels repositoris externs	103
A.2	Glossari de terminologia i acrònims	103
A.2.1	Terminologia de combat competitiu i teoria de jocs	103
A.2.2	Agents de referència (<i>Baselines</i>)	104
A.2.3	Acrònims metodològics i algorítmics	104
A.3	Catàleg complet i fitxa tècnica dels agents	105
A.4	Diccionari complet de dades de la telemetria (StatsBattle)	105
A.5	Especificació de prompts, serialització i raonament CoT dels agents LLM	108
A.5.1	Arquitectura d'inferència local	108

A.5.2	Prompt de sistema (<i>System Prompt</i>)	110
A.5.3	Esquema de serialització textual de l'estat del combat	110
A.5.4	Protocol d'acció JSON i traça de raonament CoT	110
A.6	Hiperparàmetres de Machine Learning (XGBoost i MaskablePPO)	111
A.6.1	Classificador macro i avaluador micro XGBoost	111
A.6.2	Configuració i funció de recompensa de MaskablePPO	111

Índex de figures

2.1	Logotip commemoratiu del 30è aniversari de la franquícia Pokémon (1996–2026), que celebra tres dècades d’història i d’impacte cultural global en l’entreteniment multimèdia i els videojocs.	4
2.2	Captura de la interfície de Pokémon Showdown durant un combat, on s’observen els Pokémon actius de cada bàndol, les banquetes de substituïts (actius, debilitats o ocults), els nivells, percentatges de vida (HP) i la informació visible de la batalla.	5
2.3	Comparativa en escala logarítmica ($\log_{10}$) de l’espai combinatori d’equips Pokémon ($\approx 10^{139}$) amb l’espai d’estats dels escacs ($\approx 10^{47}$) i el Go ($\approx 10^{170}$).	11
2.4	Exemple compacte de text amb l’estat del combat i l’espai d’accions discret (moviments [1–4], Teracristal·lització i canvis [5–8]) disponible per a l’agent a cada torn.	12
2.5	Intersecció dels quatre eixos fonamentals de complexitat en IA i la seva correspondència amb altres jocs (adaptat del treball divulgatiu d’Aaron Traylor [1]).	13
2.6	Comparació estructural entre marcs de decisió: a) MDP (informació perfecta), b) POMDP (reducció a 1 decisor sota informació imperfecta), c) POSG teòric (formulació matemàtica abstracta amb 2 jugadors) i d) POSG instanciat en Pokémon Showdown amb el filtre del seu protocol.	15
2.7	Arquitectura d’avaluació d’una política heurística basada en la combinació de blocs de coneixement de domini.	24
2.8	Cicle clàssic de l’MCTS adaptat a simulacions de profunditat rasa a l’arrel ($d = 1$) amb rollouts heurístics.	25
2.9	Comparació estructural entre l’arquitectura d’imitació Híbrida (macro-decisió ML + micro-execució heurística) i l’arquitectura Dual Pura (dos classificadors XGBoost especialitzats).	26
2.10	Comportament de la funció d’objectiu retallada de PPO $\mathcal{L}^{\text{CLIP}}$ en funció de la raó de probabilitats $r_t(\theta)$ quan l’avantatge és positiu ($\hat{A}_t > 0$).	27
3.1	Disseny metodològic i flux experimental de l’estudi: orquestració d’agents sobre el simulador comú, extracció de telemetria i validació estadística mitjançant Bootstrap BCa.	29
3.2	Exemple d’estructura del missatge JSON de petició d’acció (<code> request </code>) enviat per Pokémon Showdown a cada jugador.	30
3.3	Tres capes del contracte. Showdown és l’àrbitre omniscient; <i>poke-env</i> tradueix el protocol a un objecte i a una ordre legal; la política és l’únic bloc específic de cada paradigma. La fletxa discontinua tanca el torn al motor.	31
3.4	Intercanvi d’un torn. Showdown filtra l’estat i no resol fins a tenir les dues ordres; <i>poke-env</i> estructura l’observació i legalitza l’acció. L’agent no accedeix mai a S	32
3.5	Arquitectura conceptual d’avaluació massiva. El coordinador gestiona la matriu i supervisa la consolidació; cada treballador opera en un procés aïllat amb un Showdown dedicat i escriu el seu lot temporal (<code>.csv</code>) abans de reciclar-se.	34

3.6	Genealogia de disseny dels agents (v1–v22). Les rutes de desenvolupament i ramificació entre variants s'agrupen per color segons el bloc de funcionalitat descrit a la llegenda.	36
3.7	Esquema del mètode Maximin d'un torn. Es construeix la matriu de recompenses M avaluant la resposta de l'adversari amb el nucli v14 i es tria l'acció amb el millor resultat en el pitjor cas ($\max_i \min_j M_{ij}$).	38
3.8	Arquitectura del cicle de cerca MCTS de quatre fases a l'arrel ($d = 1$). (1) Selecció de l'acció fill a^* (UCB1/PUCT); (2) Simulació local de 5 torns amb LocalSim; (3) Avaluació de la fulla s_5 amb el nucli v14; i (4) Retropropagació de la recompensa v i actualització d'estadístiques (Q, N) durant 100 iteracions.	39
3.9	Arquitectura d'imitació jeràrquica. El classificador macro XGBoost prediu la intenció (atacar/canviar); v21 combina filtres i execució amb v14, mentre que v22 resol el nivell micro amb models apresos (contrafactual i atributs).	42
3.10	Curriculum PPO previst. Cada fletxa és una porta de validació independent de la corba d'entrenament. El clonatge s'insereix abans de la fase 2; la fase 3 mesura distància contra v12 encara que una porta anterior falli.	43
4.1	Calendari d'activitat i mapa de calor de <i>commits</i> a GitHub des de l'inici del projecte (14/02/2026) fins a la versió final (25/08/2026).	51
5.1	Mapa modular del repositori. p00_core centralitza simulació i persistència; Minimax, MCTS i imitació reutilitzen v14 (p01); PPO i el <i>ladder</i> públic disposen d'entorns d'execució dedicats.	58
5.2	Cicle d'execució de la matriu. El traç discontinu indica la represa incremental: el coordinador llegeix les files ja existents al CSV final i només programa les batalles pendents.	58
5.3	Monitoratge durant una execució al prototip de 16 GB. La memòria creix mentre s'acumulen batalles i cau després de reiniciar processos.	59
5.4	Captura i consolidació de la telemetria per partida. Les tres fonts s'integren en un esquema rígid de 70 columnes per garantir la compatibilitat amb eines d'anàlisi columnar.	60
5.5	Arquitectura de control i monitoratge. El llançador orquestra les 784 cel·les i emet notifikacions <i>push</i> ; el dimoni vigila el maquinari i atén comandes interactives.	61
5.6	Pipeline de decisió compartit. Minimax, MCTS i v21 especialitzen <code>_select_action</code> (i, si cal, el hook) sense reimplementar el cicle de vida ni els comptadors.	62
5.7	Validació exploratòria de les repeticions humanes: desequilibri entre atacar i canviar, evolució de la taxa de canvi amb el torn i espècies més representades. La figura descriu el conjunt de dades, no el rendiment final de l'agent.	65
5.8	Taxa de canvi humana per espècie activa en una selecció del conjunt d'experts. La variació justifica incloure identitat i context, però no implica causalitat.	65
5.9	Pas d'inferència de MaskablePPO. La màscara s'aplica abans de mostrejar; l'índex s'envia com a ordre de Showdown, no com a enter cru.	67
5.10	Seqüència clonatge $\rightarrow$ reforç. El crític no s'entrena al clonatge; PPO n'aprèn el valor a partir de la recompensa modelada un cop l'actor ja imita el professor.	68
5.11	Corbes de les quatre etapes del curriculum: taxes durant l'entrenament sobre una política canviant. Les validacions independents són la Taula 6.17. El panell de fase 3 correspon a la passada secundària, no al model A publicat.	69
6.1	Distribució de la durada de les batalles analitzades. La mediana és de 17 torns i hi ha una cua dreita de partides excepcionalment llargues.	73

6.2	Taxa global de victòries de v1–v14 (253.000 partides per fila; les tres cel · les contra MCTS tenen $n = 1.000$). S’observen canvis destacats a v7 , v9 i v12 , seguits d’una disminució a v13 i v14	74
6.3	v1–v14 contra els quatre agents de referència discriminants ($n = 10.000$ per cel · la): Abyssal, Simple Heuristic, one_step i safe_one_step . v12 és el primer que deixa Abyssal i Simple Heuristic clarament per sota del 50%. Random i MaxBasePower s’ometen: contra Random totes les heurístiques arriben al 97–98% i la columna no discrimina.	76
6.4	Empremta tàctica de la seqüència heurística (mitjanes ponderades de la matriu). v12 utilitza la Teracristal · lització gairebé una vegada per partida; v13 , 0,20 vegades. ko_checks augmenta fins a aproximadament 15 a v14 ; la preparació i els perills d’entrada apareixen a partir de v9	76
6.5	Taxa de victòries de la inversió, agregada per paradigma d’oponent. v12 és millor contra agents de referència i altres heurístiques; v13 , contra minimax, MCTS i imitació híbrida.	78
6.6	Taxa de discrepància respecte de v14 en els torns en què s’executa el maximin. v15/v16 discrepen aproximadament en el 67% dels casos; v17 , amb prior +0,15, en el 37%.	79
6.7	Empremta v15–v17 : KO checks ~ 14 , cerca ~ 16 –18% dels torns, Tera $\sim 0,39$ (nivell v14 , no v12).	81
6.8	Taxa de victòries del minimax per família d’oponent. El prior de v17 s’associa amb les millores principals contra heurístiques i MCTS.	81
6.9	Taxa de discrepància respecte de v14 entre les decisions de cerca. UCB1 (v18/v19) discrepa aproximadament en el 71% dels casos i PUCT (v20), en el 19%.	82
6.10	Empremta MCTS. Cerca 16–18% dels torns; KO ~ 14 /partida. v20 busca menys i acaba amb més HP. $n = 1.000$ per oponent.	85
6.11	Taxa de victòries d’MCTS per paradigma d’oponent ($n = 1.000$ a cada cel · la). PUCT millora principalment contra heurístiques i minimax.	85
6.12	Empremta dels agents d’imitació. v21 registra aproximadament 14 proteccions de debilitament per partida; v22 no. El panell dret mostra que v22 consulta XGBoost moltes més vegades i activa més sovint la protecció de bucle.	86
6.13	Freqüència d’ús de la política apresada. XGBoost intervé en el 15% dels torns de v21 i en el 80% dels de v22	87
6.14	Taxa de victòries dels agents d’imitació per família d’oponent. v21 supera v22 en els sis blocs, amb diferències d’aproximadament 20–26 pp.	88
6.15	Taxa de victòries de v21 i v22 per oponent. Tots els punts queden <i>per sobre</i> de la diagonal $y = x$: v21 obté el valor superior en 28 de 28 enfrontaments. La diferència màxima és de 32,6 pp contra safe_one_step	89
6.16	Mapa de calor de la taxa de victòries a gen9randombattle . La fila és l’agent analitzat i la columna, l’oponent. Prefixos: (H) heurística, (MM) minimax, (MCT) MCTS, (IL) imitació i (B) agent de referència. Les cel · les amb MCTS tenen $n = 1.000$; la resta, $n = 10.000$	91
6.17	Escala latent Bradley–Terry ancorada a random = 1000 ajustada sobre les dues orientacions de la matriu. v12 i v13 obtenen les puntuacions més altes; v14 , Abyssal i Simple Heuristic comparteixen un altiplà a 1755 punts. Les files i columnes d’MCTS aporten una desena part de partides al model ($n = 1.000$). . .	92
6.18	Taxa de victòries acumulada i Elo de v14 a la classificació pública: 431 partides entre el 9 i el 10 de juny de 2026, 39,44% $\pm 4,6$ pp i Elo de 1085 a 1038 (màxim 1263). Una instantània prefixa de 98 partides, presa prop del màxim d’Elo, no representa el resultat final.	93

- 6.19 Telemetria de **v14** al *ladder*, separada per victòria i derrota: durada i membres debilitats, canvis, i tàctiques (**ko_checks** ~16 per partida; preparació, perills i Teracristal · lització molt baixos). El perfil tàctic s'assembla al de la matriu local. 93

Índex de taules

2.1	Exemple numèric d'aplicació de les fórmules d'escalat (2.1) i (2.2) per a un Pikachu a nivell 100 ($L = 100$) amb naturalesa <i>Timid</i> (+10% Velocitat, -10% Atac). Es mostra la contribució de l'estadística base (B), els valors individuals (IV), els punts d'esforç (EV) i el factor de naturalesa (N) fins a l'obtenció de la xifra final de combat.	6
2.2	Matriu d'efectivitat de tipus	7
2.3	Condicions d'estat primàries principals i els seus efectes mecànics en el combat Pokémon.	9
2.4	Exemple simplificat d'una matriu de recompenses en forma normal per a un torn de combat. Els valors representen la recompensa esperada del Jugador 1.	17
2.5	Mapatge POSG/POMDP al combat individual de Random Battle (Generació IX).	18
2.6	Síntesi del marc d'avaluació estadística, eines d'inferència i les seves propietats teòriques.	20
2.7	Posicionament comparatiu d'aquest treball respecte als principals sistemes d'IA per a Pokémon a la literatura.	22
2.8	Comparació conceptual dels cinc paradigmes. Tots decideixen sobre el mateix simulador i format; canvia la font de coneixement i el còmput per torn.	23
3.1	Disseny conceptual de les catorze versions heurístiques. Cada versió aïlla un bloc de coneixement de domini.	37
3.2	Disseny del currículum PPO. Els llistats són criteris previstos per avançar; el compliment es presenta al Capítol 5 i als resultats.	42
3.3	Com cada paradigma representa observació i acció. El contracte extern (Showdown) és el mateix; canvia la representació interna.	44
3.4	Precisió aproximada al 95% en el cas de màxima variància ($p = 0,5$). La segona columna és el marge d'una proporció; la tercera, el marge de la diferència entre dues proporcions independents amb el mateix n . Són càlculs de planificació, no una anàlisi de potència.	44
3.5	Famílies d'agents del disseny experimental. La llista completa de 28 identificadors es reutilitza als resultats (Taula 6.1). El PPO queda fora d'aquesta matriu.	45
4.1	Desglossament d'hores de treball i costos laborals de l'equip per fase del projecte.	54
4.2	Resum dels costos directes materials i d'infraestructura del TFM.	55
4.3	Pressupost econòmic global consolidat del TFM.	56
5.1	Qui omple cada bloc de columnes. La columna existeix sempre; el valor no nul només on s'indica.	60
5.2	Pressupost que el llançador passa a <code>benchmark.py</code> . Coincideix amb la Secció 3.6; aquí es concreta en arguments.	61
5.3	Criteris de reinici del monitor intern del llançador. Tots acaben en fusió de CSV temporals + <code>pkill</code> + reintent.	61

5.4	Correspondència entre els blocs de disseny de la Taula 3.1 i els components implementats.	63
5.5	Composició del vector d'observació de MaskablePPO. El model A publicat té 328 dimensions; les fases 1 i 1.5 n'utilitzaven 318 (sense dany estimat ni enfrontaments de canvi). Les 18 dimensions addicionals de la fase 4 no entren al resultat principal.	67
5.6	Espai d'accions Discrete(14) de MaskablePPO. La màscara de legalitat i la traducció a <code>/choose</code> comparteixen el mateix mapeig de slots [2].	67
5.7	Artefactes i hiperparàmetres del currículum PPO. Les portes numèriques (90%, > 70%, > 55%) són les del disseny; el resultat de cada porta és al Capítol 6.	68
6.1	Taxonomia dels 28 agents de la matriu.	71
6.2	Evolució de les preguntes i dels resultats entre v1 i v22	73
6.3	Seqüència heurística v1–v14	74
6.4	Enfrontaments directes, amb $n = 10.000$ partides independents per orientació. v12 i v13 no presenten una separació concloent ($z = 1,30$, $p = 0,19$ respecte a la paritat del 50%); v14 queda per sota de tots dos amb diferències estadísticament inequívokes ($p < 10^{-15}$). Les sumes recíproques properes al 100% són un control de coherència, no una prova amb partides aparellades.	77
6.5	Rendiment comparatiu de v12 , v13 i v14 contra cerca, imitació i blocs de control (taxa de victòries en %).	77
6.6	Minimax analític d'un torn (253.000 partides per fila). La cerca s'executa en aproximadament el 16–18% dels torns. La fulla posicional de v16 gairebé no modifica la preparació; el prior de v17 redueix la discrepància respecte de v14 i obté la taxa més alta de la família.	79
6.7	Comparativa de les variants Minimax (v15 , v16 , v17) davant dels principals oponents (taxa de victòries en %).	80
6.8	MCTS ras amb UCB a l'arrel i 100 simulacions de cinc torns. Totes les cel·les tenen $n = 1.000$ (28.000 partides per agent). La fulla més rica de v19 no aporta una millora observable; PUCT amb prior sobre v14 redueix la discrepància i obté la taxa més alta de la família.	82
6.9	Freqüències mitjanes d'activació de mecàniques diferides (<i>setup</i> , <i>hazards</i> i Tera-cristal·lització per partida) segons paradigma.	83
6.10	Rendiment de les variants MCTS (v18 , v19 , v20) davant dels oponents de referència (taxa de victòries en %).	84
6.11	Imitació amb el mateix classificador XGBoost ($\tau = 0,5525$) i dues formes d'execució (253.000 partides per fila). v21 consulta el model en el 15% dels torns; v22 , en el 80%, sense proteccions de debilitament, i activa la protecció de bucle en el 97% de les partides.	86
6.12	Comparació de rendiment dels models d'imitació jeràrquica (v21 , v22) enfront de la cerca i referències (taxa de victòries en %).	86
6.13	Síntesi dels cinc paradigmes amb v12 com a comparador comú. Les variants són les que obtenen el millor resultat observat dins de cada família; aquesta selecció és posterior a l'experiment. L'MCTS té una mostra menor i el PPO no participa en la matriu completa.	90
6.14	Taxes globals descriptives contra els 28 oponents. Les files no MCTS tenen 253.000 partides i ponderen cada oponent MCTS una desena part que els altres; les files MCTS tenen 28.000 partides i ponderen tots els oponents igual. Els dos blocs no formen una única classificació comparable.	90
6.15	Enfrontaments de referència. Les files amb MCTS tenen $n = 1.000$ i la resta, $n = 10.000$. v12 contra Abyssal (59,91% $\pm 0,96$ pp) és el principal resultat contra un agent extern basat en regles.	90
6.16	Classificació pública de v14 contra persones.	93

6.17	Curriculum i avaluacions de MaskablePPO. Els artefactes i hiperparàmetres d'entrenament es detallen a la Taula 5.7. El resultat principal correspon al model A contra HeuristicV12 ($n = 10.000$ i ambdues orientacions). La fase 4 només informa de la taxa interna durant l'entrenament, no d'una avaluació independent.	94
6.18	Integració residual sobre v14 . El percentatge de torns és la fracció en què s'executa el mòdul afegit; la discrepància és la taxa en què aquest mòdul no retorna l'acció de v14 (no aplica a XGBoost ni a PPO). $n = 10.000$ tret de v20 ($n = 1.000$).	96
A.1	Llindars del dimoni seguretat_tfm.sh . L'avís espera 15 minuts abans de repetir-se; el pànic apaga la màquina (poweroff).	103
A.2	Comandes del bot de Telegram (dimoni seguretat_tfm.sh).	103
A.3	Catàleg complet i fitxa tècnica dels agents de referència (<i>baselines</i>) i heurístics (v1–v14). Totes les classes hereten de Player de <i>poke-env</i> i operen a la matriu 28×28 amb $n = 10.000$ partides per cel·la.	106
A.4	Catàleg complet dels agents de cerca adversarial (v15–v20), aprenentatge per imitació (v21–v22), aprenentatge per reforç profund (MaskablePPO) i models de llenguatge (LLM).	107
A.5	Diccionari de dades de telemetria (StatsBattle): blocs 1 (Identificació i resultat), 2 (Robustesa i decisions) i 3 (Salut, equips i supervivència).	108
A.6	Diccionari de dades de telemetria (StatsBattle): blocs 4 (Mobilitat, condicions de camp i RNG) i 5 (Ablació de domini).	109
A.7	Diccionari de dades de telemetria (StatsBattle): bloc 6 (Telemetria de cerca adversarial i aprenentatge automàtic).	109
A.8	Consolidació d'hiperparàmetres per als models d'aprenentatge supervisat per imitació (XGBoost).	112
A.9	Consolidació d'hiperparàmetres per al model d'aprenentatge per reforç profund (MaskablePPO) i clonatge conductual.	113

Capítol 1

Introducció

1.1 Contextualització i motivació

Pokémon és un joc d'estratègia per torns caracteritzat per la informació parcial, les accions simultànies i les transicions estocàstiques. A cada torn, els jugadors han de decidir entre executar un moviment o substituir el Pokémon actiu sense conèixer amb certesa la configuració de l'equip rival, mentre que factors com la precisió dels atacs, els cops crítics i els efectes secundaris introdueixen aleatorietat inherent al combat.

En aquest context, un **agent** és un sistema autònom que percep l'estat observable de la batalla i selecciona una acció per maximitzar la seva esperança de victòria [3, 4]. Una **política** π formalitza aquesta presa de decisions assignant una distribució sobre les accions legals a partir de l'observació disponible. Els diferents enfocaments d'Intel·ligència Artificial aborden aquesta política des de perspectives diverses: mitjançant regles heurístiques dissenyades per experts, planificació en línia mitjançant cerca adversària o simulació en arbre (MCTS), o bé aprenentatge de patrons a partir de dades humanes i recompenses per reforç.

Aquest Treball de Final de Màster estudia i compara com cinc paradigmes d'agents afronten aquest problema de decisió sota condicions d'incertesa. L'objectiu no és construir un agent infal·libre, sinó avaluar empíricament implementacions concretes sota pressupostos computacionals explícits, en un entorn reproducible i amb una escala mostral que permeti quantificar amb rigor la precisió dels resultats.

Per a l'experimentació s'utilitza el simulador **Pokémon Showdown** [5] i la llibreria *poke-env* [6], focalitzant la recerca en el format individual **Random Battle de la Generació IX** (`gen9randombattle`). La generació procedural d'equips introdueix variabilitat inicial; un volum massiu de batalles per enfrontament dilueix aquest soroll i aïlla la qualitat de la presa de decisions durant el combat (Secció 2.1.9).

S'implementen i s'avaluen cinc formes de decidir sobre el mateix simulador i format. Cada família té una pregunta distinta; el detall de variants i hiperparàmetres és al Capítol 3:

1. **Heurístiques expertes** (v1–v14): ablació de coneixement de domini (càlcul de dany, efectivitat de tipus, perills d'entrada, preparació, estats alterats i Teracristal·lització). v12 és l'heurística de millor rendiment observat; v14 és l'heurística terminal de servei (fulla, prior i executor de cerca i imitació, i agent del *ladder* públic).
2. **Cerca adversària Minimax d'un torn** (v15–v17): matriu d'accions simultànies amb avaluació heurística a les fulles, amb i sense prior de v14.
3. **Cerca en arbre de Monte Carlo rasa** (*shallow* MCTS v18–v20): cerca a l'arrel amb rollouts locals de cinc torns; se'n comparen UCB1 i PUCT guiada per v14.
4. **Aprenentatge per imitació** (v21–v22): XGBoost sobre repeticions humanes d'alt nivell (Elo 1800+). v21 és híbrid (macro apres, micro v14); v22 és imitació dual pura, sense v14.

5. **Aprenentatge per reforç profund** (*MaskablePPO*): política neuronal amb accions emmascarades, currículum d’oponents i clonatge conductual sobre **v8**; s’avalua fora de la matriu contra **v12**.

Les quatre primeres famílies, juntament amb sis agents de referència, formen una matriu dirigida de **28 agents**. El PPO no hi entra: s’avalua en un experiment separat contra **v12**, l’agent amb millor resultat observat a la lliga. Models de llenguatge com *PokéChamp* i *PokéLLMon* s’integren de manera exploratòria.

1.2 Objectius del treball i hipòtesis de recerca

L’objectiu principal d’aquest treball és avaluar i comparar empíricament el rendiment relatiu de les heurístiques expertes, la cerca adversària d’un torn, l’MCTS ras, l’aprenentatge per imitació i MaskablePPO en batalles **gen9randombattle**, sota pressupostos computacionals explícits i un protocol experimental rigorós.

1.2.1 Objectius específics

Aquest objectiu general es concreta en els següents objectius específics:

1. **Formalització teòrica del domini:** Formalitzar el combat Pokémon com un joc estocàstic d’observació parcial (POSG) i la reducció a POMDP d’un sol decisor, i definir un marc d’inferència amb incertesa quantificada.
2. **Disseny metodològic, infraestructura i telemetria:** Definir el protocol experimental i el model de rànquing Bradley–Terry, construir una infraestructura d’execució paral·lela, escalable i recuperable davant de fallades sobre Pokémon Showdown i *poke-env*, i instrumentar telemetria per torn (predicció de canvis, *tempo*, gestió del risc i Teracristal·lització).
3. **Paradigmes heurístics i de cerca en línia:** Desenvolupar la seqüència d’agents heurístics (**v1–v14**) com a ablació de coneixement de domini, i implementar variants de minimax d’un torn (**v15–v17**) i MCTS ras (**v18–v20**) guiats per **v14** per analitzar si la cerca millora l’heurística de partida.
4. **Agents apresos i integració de LLMs:** Entrenar models XGBoost (**v21–v22**) sobre repeticions Elo 1800+ per a decisions macro i micro, optimitzar MaskablePPO amb clonatge conductual sobre **v8** per avaluar si s’acosta a **v12**, i integrar exploratòriament *PokéChamp* i *PokéLLMon*.
5. **Avaluació empírica massiva i rànquings:** Executar i analitzar la matriu competitiva de 28 agents (6,4 milions de batalles), calcular els rànquings Bradley–Terry i creuar-los amb la telemetria per torn.
6. **Avaluació externa al ladder públic:** Desplegar l’heurística terminal de servei (**v14**) a la classificació pública oficial (*ladder*) de Pokémon Showdown per obtenir una mostra externa contra jugadors humans.

1.2.2 Hipòtesis de recerca

Per articular l’avaluació empírica sota el mètode científic, es formulen cinc hipòtesis de recerca falsables, cadascuna vinculada a un experiment i capítol específic:

- **H₁ (Monotonicitat de l’ablació heurística):** La incorporació acumulativa i progressiva de regles de domini expertes (càlcul de dany, tipus, *hazards*, preparació, estats alterats i Teracristal·lització) en la sèrie **v1–v14** produirà una millora monòtona en la taxa de victòries global sobre el conjunt d’adversaris de la matriu (avaluada a la Secció 6.4).

- **H₂ (Superació de la política de base mitjançant cerca en línia):** La planificació cap endavant mitjançant cerca adversària d'un torn (minimax v15–v17) o cerca en arbre de Monte Carlo rasa a cinc torns (MCTS v18–v20) millorarà la qualitat decisonal i superarà en taxa de victòries l'heurística utilitzada com a fulla o prior (v14) i l'heurística líder (v12) (avaluada a les Seccions 6.6 i 6.7).
- **H₃ (Eficàcia del guiatge per priors a l'MCTS ras):** Sota observabilitat parcial i pressupost de simulació estricta, l'algorisme PUCT guiat per distribucions a priori d'heurística experta (v14) reduirà de forma significativa la taxa de discrepància d'accions i millorarà la taxa de victòries enfront de la selecció uniforme no informada UCB1 (avaluada a la Secció 6.7).
- **H₄ (Andamiatge de domini en aprenentatge per imitació):** Un model d'imitació basat en XGBoost entrenat sobre repeticions humanes d'elit (Elo 1800+) requereix regles expertes de microexecució per ser competitiu (agent híbrid v21), superant de manera estadísticament significativa un model d'imitació dual purament basat en dades (v22) (avaluada a la Secció 6.8).
- **H₅ (Aproximació a l'heurística d'elit mitjançant currículum i DRL):** La inicialització neuronal per clonatge conductual (BC) sobre una heurística intermèdia (v8) combinada amb l'emascament d'accions invàlides permetrà a MaskablePPO superar les etapes d'un currículum d'adversaris i assolir un rendiment competitiu comparable al de l'heurística experta de referència (v12) (avaluada a la Secció 6.11).

1.3 Estructura de la memòria

La resta d'aquesta memòria s'organitza en sis capítols:

- El **Capítol 2 (Marc teòric i contextualització)** descriu les mecàniques de combat i el format `gen9randombattle`, formalitza el problema com a POSG/POMDP, revisa l'estat de l'art i detalla els fonaments dels cinc paradigmes.
- El **Capítol 3 (Metodologia i disseny experimental)** fixa el contracte d'entorn, el gestor de batalles, la matriu de 28 agents, el model Bradley–Terry, la telemetria per torn i les amenaces a la validesa.
- El **Capítol 4 (Entorn de desenvolupament i infraestructura de còmput)** documenta el maquinari, l'orquestració de servidors Showdown, la persistència, el monitoratge i el cost de còmput que fan viable l'execució del Capítol 5, a més de l'organització del projecte i les dependències de programari.
- El **Capítol 5 (Implementació dels cinc paradigmes)** tradueix a codi el disseny del Capítol 3: coordinador, heurístiques, minimax, MCTS, imitació, MaskablePPO, LLM i el connector amb el *ladder* públic.
- El **Capítol 6 (Resultats)** analitza l'escala heurística, la cerca, la imitació, l'experiment PPO contra v12, la mostra de v14 al *ladder* i els patrons residuals.
- El **Capítol 7 (Conclusions i línies futures)** respon a la pregunta de recerca, avalua les cinc hipòtesis plantejades, sintetitza les troballes, exposa contribucions, limitacions, treball futur i consideracions ètiques i ambientals.

Capítol 2

Marc teòric i contextualització

Aquest capítol estableix els fonaments teòrics, mecànics i estadístics del treball. En primer lloc, es descriu el domini del combat Pokémon, les seves regles i el format `gen9randombattle`. En segon lloc, es formalitza matemàticament el problema mitjançant processos de decisió sota incertesa (POSG/POMDP) i es defineix el marc d'inferència estadística per a l'avaluació rigorosa dels agents. En tercer lloc, es revisa l'estat de l'art en intel·ligència artificial aplicada a Pokémon. Finalment, es desenvolupen els fonaments algorítmics dels cinc paradigmes de decisió estudiats.

2.1 Pokémon com a domini de decisió

Abans de formalitzar el problema des de la Teoria de Jocs, cal contextualitzar el domini del combat Pokémon. La formulació d'estadístiques, la matriu d'efectivitat, la Teracristal·lització, les regles de velocitat, les condicions d'estat i l'estocasticitat conformen el marc mecànic del joc. Així mateix, s'analitza la complexitat combinatòria d'equips (10^{139}) i es presenta el format `gen9randombattle` a Pokémon Showdown, el qual permet aïllar la presa de decisions executives dels agents.

2.1.1 Què és Pokémon i com es desenvolupa una batalla

Pokémon és una franquícia de videojocs creada l'any 1996 per Satoshi Tajiri i la companyia Game Freak per a la consola Game Boy de Nintendo [7]. El nom **Pokémon** prové de la contracció de la denominació anglesa **Pocket Monsters** (*Poketto Monstā* en japonès), fent referència a les criatures que es capturen en esferes portàtils (Poké Balls), es col·leccionen, s'entrenen i participen en combats. El 2026 la franquícia celebra trenta anys (1996–2026); l'estratègia de combat en continua sent el nucli competitiu.



Figura 2.1: Logotip commemoratiu del 30è aniversari de la franquícia Pokémon (1996–2026), que celebra tres dècades d'història i d'impacte cultural global en l'entreteniment multimèdia i els videojocs.

En una batalla individual (*Singles*), cada jugador disposa habitualment d'un equip de sis Pokémon, però només un és actiu a cada banda. L'objectiu és debilitar tots els membres de l'equip rival abans que el rival faci el mateix.

En cada torn, un jugador pot escollir un dels moviments disponibles o canviar el Pokémon actiu per un membre no debilitat de l'equip. Un Pokémon pot conèixer com a màxim quatre moviments. Alguns causen dany; d'altres modifiquen estadístiques, imposen una condició d'estat, alteren el camp o permeten canviar conservant la iniciativa. Els dos jugadors envien l'acció sense conèixer la decisió actual de l'altre. El motor ordena les accions segons la prioritat i la velocitat, comprova la precisió i resol el dany i els efectes secundaris.

Aquesta estructura fa que una acció no es pugui valorar de manera aïllada. Un atac molt potent pot ser inútil contra una immunitat de tipus; un canvi pot evitar un debilitament, però permetre que el rival col·loqui un perill d'entrada (*hazards*); i un moviment de preparació (*setup*) pot sacrificar el torn actual per augmentar la probabilitat de guanyar els següents.



Figura 2.2: Captura de la interfície de Pokémon Showdown durant un combat, on s'observen els Pokémon actius de cada bàndol, les banquetes de substituents (actius, debilitats o ocults), els nivells, percentatges de vida (HP) i la informació visible de la batalla.

2.1.2 De l'espècie a les estadístiques finals

Cada Pokémon pertany a una espècie concreta amb atributs únics i disposa de sis estadístiques de combat: punts de salut (*Hit Points*, HP), atac, defensa, atac especial, defensa especial i velocitat [8]. Els HP determinen quant dany pot rebre; atac i defensa intervenen en els moviments físics; atac especial i defensa especial, en els moviments especials; i la velocitat decideix quin Pokémon actua abans.

La xifra final que mostra el joc es construeix a partir de cinc components:

1. **Estadística base (B).** Pròpia de l'espècie. Dos Pikachu comparteixen les mateixes estadístiques base, però no necessàriament les mateixes xifres finals.
2. **Nivell (L).** Escala el valor final. Random Battle utilitza el nivell com a mecanisme d'equilibri entre espècies.
3. **Valors individuals (IV).** Cada estadística té un IV enter entre 0 i 31.
4. **Punts d'esforç (EV).** Es poden distribuir fins a 510 EV en total, amb un màxim efectiu de 252 en una mateixa estadística.
5. **Naturalesa (N).** La majoria de naturaleses multipliquen una estadística per 1,1 i una altra per 0,9.

Per a qualsevol estadística de combat diferent dels HP (Atac, Defensa, Atac Especial, Defensa Especial i Velocitat), la fórmula general d'escalat és:

$$\text{Stat} = \left\lfloor \left(\left\lfloor \frac{(2B + IV + \lfloor EV/4 \rfloor)L}{100} \right\rfloor + 5 \right) N \right\rfloor. \quad (2.1)$$

Per contra, els punts de salut (HP) segueixen un càlcul diferent per dues raons mecàniques: en primer lloc, cap naturalesa modifica els HP (no s'aplica el multiplicador N); en segon lloc, s'afegeix el terme $+L + 10$ en comptes de la constant fixa $+5$ per tal que la salut màxima escali de manera proporcional al nivell L de la criatura. Excepte casos especials com Shedinja (els HP del qual estan fixats permanentment pel motor de joc en 1 HP independentment del nivell, IVs o EVs), la fórmula de càlcul dels HP és:

$$\text{HP} = \left\lfloor \frac{(2B + IV + \lfloor EV/4 \rfloor)L}{100} \right\rfloor + L + 10. \quad (2.2)$$

Taula 2.1: Exemple numèric d'aplicació de les fórmules d'escalat (2.1) i (2.2) per a un Pikachu a nivell 100 ($L = 100$) amb naturalesa *Timid* (+10% Velocitat, -10% Atac). Es mostra la contribució de l'estadística base (B), els valors individuals (IV), els punts d'esforç (EV) i el factor de naturalesa (N) fins a l'obtenció de la xifra final de combat.

Estadística	Base (B)	IV	EV	Naturalesa (N)	Valor final
HP	35	31	0	—	211
Atac	55	31	0	0,9 (↓)	131
Defensa	40	31	0	1,0 (·)	116
Atac Especial	50	31	0	1,0 (·)	136
Defensa Especial	50	31	0	1,0 (·)	136
Velocitat	90	31	252	1,1 (↑)	306

Com s'observa a la Taula 2.1, les xifres finals calculades determinen el perfil competitiu real de la criatura durant el combat. Aquestes estadístiques finals —especialment la Velocitat efectiva (306) i la salut màxima (HP = 211)— són els valors concrets que el motor de Pokémon Showdown utilitza a cada torn per determinar l'ordre d'actuació i l'abast del dany produït. Conseqüentment, aquests valors constitueixen la base d'informació sobre la qual els agents d'IA estimen la velocitat relativa, el dany sota tirada i el risc de debilitament.

2.1.3 Tipus elementals, matriu d'efectivitat i categories de moviment

Un dels pilars estratègics del combat Pokémon és la relació elemental entre els 18 tipus existents (Foc, Aigua, Planta, etc.). Cal distingir clarament entre el **tipus del Pokémon** i el **tipus del moviment**:

- **Tipus del Pokémon (funció defensiva):** Cada criatura disposa d'un o dos tipus elementals pròpis (tipus únic o **dobles tipus**) que determinen les febleses, resistències i immunitats quan *rep* un atac rival.

- **Tipus del moviment (funció ofensiva):** Atribut propi de l'acció executada. Un Pokémon no està restringit a utilitzar atacs del seu mateix tipus elemental (p. ex., un Pokémon de Foc pot llançar un atac de Terra). Tanmateix, quan el tipus del moviment coincideix amb un dels seus tipus pròpis, el joc atorga una bonificació extra del +50% al dany denominada **STAB** (*Same Type Attack Bonus*, multiplicador $\times 1,5$).

Quan un Pokémon té **dobles tipus**, els multiplicadors de la matriu d'efectivitat (Taula 2.2) es combinen multiplicativament ($M = M_1 \times M_2$), generant efectes de **debilitat doble** ($\times 4$, p. ex., Roca contra Foc/Volador: $2 \times 2 = 4$), **resistència doble** ($\times 0,25$, p. ex., Planta contra Acer/Volador), **neutralització** ($\times 1$, p. ex., Lluita contra Insecte/Roca: $2 \times 0,5 = 1$) o **immunitat absoluta** ($\times 0$, p. ex., Elèctric contra Aigua/Terra: $2 \times 0 = 0$).

Els moviments es classifiquen en tres categories principals:

1. **Físics (Atac vs. Defensa):** Atacs de contacte físic o força directa.
2. **Especials (Atac Esp. vs. Def. Esp.):** Atacs d'energia, distància o projectils elementals.
3. **D'estat / Suport:** No causen dany directe; s'utilitzen per induir **condicions d'estat primàries** (com cremada, paràlisi o verí; vegeu Secció 2.1.6), modificar estadístiques, alterar el clima o col·locar perills d'entrada com *Stealth Rock*.

La diferenciació entre la via física i especial és crucial: la majoria de Pokémon s'especialitzen en un perfil defensiu físic o especial concret, la qual cosa obliga els agents d'IA a avaluar la categoria d'atac que exploti la feblesa estructural del rival.

Taula 2.2: Matriu d'efectivitat elemental en combat. Les files representen el tipus de l'atac executat i les columnes, el tipus del Pokémon defensor.

	NOR	FOC	AIG	PLA	ELE	GEL	LLU	VER	TER	VOL	PSI	INS	ROC	FAN	DRA	FOS	ACE	FAD
NOR																		
FOC			$\frac{1}{2}$	$\frac{1}{2}$	2		2					2		$\frac{1}{2}$				
AIG				$\frac{1}{2}$	$\frac{1}{2}$				2				2		$\frac{1}{2}$			
PLA			$\frac{1}{2}$		$\frac{1}{2}$			$\frac{1}{2}$	2	$\frac{1}{2}$		$\frac{1}{2}$	2		$\frac{1}{2}$		$\frac{1}{2}$	
ELE				2	$\frac{1}{2}$	$\frac{1}{2}$			0	2					$\frac{1}{2}$			
GEL			$\frac{1}{2}$	$\frac{1}{2}$	2		$\frac{1}{2}$		2	2					2		$\frac{1}{2}$	
LLU	2					2		$\frac{1}{2}$		$\frac{1}{2}$	$\frac{1}{2}$	$\frac{1}{2}$	2	0		2	2	$\frac{1}{2}$
VER				2				$\frac{1}{2}$	$\frac{1}{2}$				$\frac{1}{2}$	$\frac{1}{2}$			0	2
TER		2		$\frac{1}{2}$	2			2		0		$\frac{1}{2}$	2				2	
VOL				2	$\frac{1}{2}$		2					2	$\frac{1}{2}$				$\frac{1}{2}$	
PSI							2	2			$\frac{1}{2}$					0	$\frac{1}{2}$	
INS		$\frac{1}{2}$		2			$\frac{1}{2}$	$\frac{1}{2}$		$\frac{1}{2}$	2			$\frac{1}{2}$		2	$\frac{1}{2}$	$\frac{1}{2}$
ROC		2				2	$\frac{1}{2}$		$\frac{1}{2}$	2		2					$\frac{1}{2}$	
FAN	0										2			2		$\frac{1}{2}$		
DRA															2		$\frac{1}{2}$	0
FOS							$\frac{1}{2}$				2			2		$\frac{1}{2}$		$\frac{1}{2}$
ACE		$\frac{1}{2}$	$\frac{1}{2}$		$\frac{1}{2}$	2							2				$\frac{1}{2}$	2
FAD		$\frac{1}{2}$					2	$\frac{1}{2}$							2	2	$\frac{1}{2}$	

2.1.4 Teracristal · lització (Generació IX)

La **Teracristal · lització** (*Terastallization* o *Tera*) és la mecànica transformativa exclusiva de la novena generació (*Pokémon Scarlet & Violet*, 2022) utilitzada en el format `gen9randombattle` [8]. Aquesta mecànica permet a cada jugador transformar un dels seus Pokémon una sola vegada per combat, canviant els seus tipus elementals originals per un únic **Tipus Tera** (*Tera Type*) seleccionat d'entre els 18 tipus de la matriu d'efectivitat (Taula 2.2).

La Teracristal · lització altera la dinàmica del combat a dos nivells clau:

- **Nivell defensiu:** El Pokémon adopta immediatament el Tipus Tera com a únic tipus defensiu actiu, substituint completament les seves febleses i resistències d'origen. Per exemple, un Pokémon de tipus Aigua/Volador que teracristal·litza a tipus Planta passa a ser defensivament de tipus Planta pur, convertint una feblesa fatal de $4\times$ a l'Electricitat en una resistència del $0,5\times$.
- **Nivell ofensiu (STAB millorat):** Els atacs del nou Tipus Tera obtenen la bonificació de STAB ($1,5\times$). Tanmateix, si el Tipus Tera coincideix amb un dels tipus originals de la criatura (p. ex., un Pokémon de Foc teracristal·litzant a Foc), la bonificació de STAB s'amplifica fins al $2,0\times$ (+100% de dany). A més, el Pokémon conserva la bonificació de STAB $1,5\times$ en els atacs dels seus tipus primaris d'origen.

Des de la perspectiva de la presa de decisions en IA, la Teracristal·lització és un recurs d'ús únic d'alta rellevància estratègica. Permet realitzar accions de canvi de tipus instantani (*type-shift*) per sobreviure a atacs directes, anular un atac supereficax del rival i capgirar l'estat del combat en un únic torn, constituint un dels punts d'avaluació més complexos per a les polítiques de decisió dels agents.

2.1.5 Velocitat, prioritat i l'empat de velocitat

La **Velocitat** és una de les estadístiques més determinants en el combat Pokémon competitiu. Atacar primer no només concedeix la iniciativa tàctica (*tempo*), sinó que atorga la capacitat de debilitar la criatura rival abans que aquesta pugui executar la seva acció en aquell torn, anul·lant per complet el seu potencial de dany. Conseqüentment, saber quin Pokémon actuarà abans és un càlcul fonamental per als agents d'IA en avaluar els riscos i les oportunitats de cada moviment.

En cada torn, el motor de joc ordena l'execució de les accions seguint dos criteris seqüencials:

1. **Prioritat del moviment:** Cada moviment té un valor de prioritat discret que varia entre $+5$ i -7 . Els moviments de prioritat alta, com *Protect* ($+4$), *Extreme Speed* ($+2$) o *Quick Attack* ($+1$), s'executen sempre abans que qualsevol moviment de prioritat neutra (0), independentment de la Velocitat dels Pokémon. Per contra, moviments d'alta utilitat tàctica com *Trick Room* (-7) s'executen al final del torn.
2. **Velocitat efectiva:** Si dos moviments tenen la mateixa prioritat (habitualment 0), actua primer el Pokémon que tingui una Velocitat efectiva més alta en aquell torn, tenint en compte l'estadística final, els canvis d'etapa (de -6 a $+6$), els objectes equipats (com *Choice Scarf*, que augmenta la velocitat en un 50%) i les condicions d'estat (la paràlisi redueix la velocitat a la meitat).

Quan dos Pokémon tenen exactament la mateixa prioritat i la mateixa Velocitat efectiva final, es produeix un **empat de velocitat** (*Speed Tie*). El motor de joc resol aquest empat mitjançant una decisió aleatòria al 50% ($p = 0,5$).

2.1.6 Condicions d'estat primàries

Com s'ha introduït en les categories de moviment (Secció 2.1.3), els moviments d'estat o suport (com *Will-O-Wisp* o *Thunder Wave*) i certs efectes secundaris d'atacs físics o especials tenen la capacitat d'imposar **condicions d'estat primàries**. Aquestes alteracions són persistents i afecten negativament les capacitats operatives d'un Pokémon. Un Pokémon només pot patir una condició d'estat primària de manera simultània. A la Taula 2.3 es resumeixen les principals condicions d'estat i els seus efectes mecànics en el combat.

Des de la perspectiva de la presa de decisions, induir una condició d'estat pot ser estratègicament superior a causar dany immediat. Per exemple, cremar un atacant físic enreda irreversiblement el seu potencial ofensiu, mentre que paraitzar un Pokémon ràpid permet a l'agent recuperar la iniciativa de velocitat en el combat.

Taula 2.3: Condicions d'estat primàries principals i els seus efectes mecànics en el combat Pokémon.

Estat	Efecte en combat	Mecànica i impacte tàctic
Cremada	↓ 50% Atac físic	Causa un dany recurrent d'1/16 dels HP màxims per torn i redueix a la meitat l'Atac físic efectiu.
Paràlisi	↓ 50% Velocitat (Gen. VII+)	Redueix la Velocitat a la meitat i introdueix un 25% de probabilitat de no actuar per torn.
Verí / Tòxic	Dany recurrent per torn	El verí estàndard treu 1/8 dels HP per torn; el verí tòxic incrementa el dany a cada torn (1/16, 2/16...).
Son	Inhabilitació temporal	El Pokémon no pot actuar durant 1–3 torns consecutius.
Congelació	Inhabilitació estocàstica	El Pokémon no pot actuar; té un 20% de probabilitat de descongelar-se a cada torn.

2.1.7 Fonts d'estocasticitat irreductibles

El combat Pokémon és un entorn fortament estocàstic. Fins i tot quan un agent disposa d'informació completa sobre l'estat actiu, el resultat d'una decisió està subjecte a tres fonts d'aleatorietat irreductibles administrades pel simulador de joc [8–10]:

1. **Tirada de dany (*Damage Roll*):** El dany calculat per les fórmules oficials no és un valor fix, sinó que es multiplica per un factor aleatori extret d'una distribució uniforme discreta de 16 valors entre 0,85 i 1,00 ($\{0,85, 0,86, \dots, 1,00\}$) [9]. Així, un mateix atac pot debilitar un rival si es dona una tirada alta (1,00), però deixar-lo amb vida si la tirada és baixa (0,85).
2. **Precisió i evasió (*Accuracy*):** Molts moviments potents no tenen una precisió del 100% (p. ex., *Hydro Pump* amb 80% o *Focus Blast* amb 70%) [8]. L'agent ha de ponderar el dany esperat davant del risc de fallar l'atac i regalar un torn d'iniciativa al rival.
3. **Cop crític (*Critical Hit*):** A la Generació IX, la probabilitat base que un atac sigui crític és d'1 de cada 24 vegades ($p_{\text{crit}} \approx 4,17\%$) [8, 9]. Un cop crític aplica un multiplicador de $\times 1,5$ al dany, ignora els augments defensius del rival i ignora les reduccions d'atac de l'usuari.

El terme determinista sobre el qual s'apliquen aquestes fonts és el dany brut D_{base} , donat per la fórmula oficial de combat (Generació V en endavant) [8, 9]:

$$D_{\text{base}} = \left\lfloor \left(\left\lfloor \frac{[(2L/5 + 2) \cdot P \cdot A/D]}{50} \right\rfloor + 2 \right) \cdot M_{\text{STAB}} \cdot M_{\text{tipus}} \cdot M_{\text{altres}} \right\rfloor \quad (2.3)$$

on P és la potència del moviment, A i D són l'atac i la defensa efectius de la categoria corresponent (Equació 2.1 i modificadors d'etapa), $M_{\text{STAB}} \in \{1, 1,5, 2\}$ (Seccions 2.1.3 i 2.1.4), M_{tipus} és el multiplicador de la matriu d'efectivitat i M_{altres} agrupa clima, objectes i altres modificadors deterministes. El cop crític i la tirada R no entren a D_{base} .

Les tres fonts aleatòries es componen sobre aquest terme:

$$\text{Dany} = I_{\text{hit}} \cdot [D_{\text{base}} \cdot C_{\text{crit}} \cdot R] \quad (2.4)$$

on:

- $I_{\text{hit}} \sim \text{Bernoulli}(P_{\text{acc}})$ és l'indicador binari d'impacte, on $P_{\text{acc}} \in (0, 1]$ representa la precisió efectiva de l'atac. Si l'atac falla ($I_{\text{hit}} = 0$), el dany resulta immediatament 0.

- C_{crit} és la variable aleatòria del multiplicador de cop crític:

$$C_{\text{crit}} = \begin{cases} 1,5 & \text{amb probabilitat } p_{\text{crit}} = \frac{1}{24} \approx 4,17\% \quad (\text{Gen. IX}) \\ 1,0 & \text{amb probabilitat } 1 - p_{\text{crit}} \end{cases} \quad (2.5)$$

el qual, a més d'amplificar el dany, anul·la els modificadors estadístics desfavorables per a l'atacant.

- $R \sim \mathcal{U}(\{0,85, 0,86, \dots, 1,00\})$ és la tirada de dany extrema d'una distribució uniforme discreta de 16 valors, amb un valor esperat $\mathbb{E}[R] = 0,925$.

L'esperança matemàtica del dany que un agent ha d'avaluar abans de seleccionar una acció és:

$$\mathbb{E}[\text{Dany}] = P_{\text{acc}} \cdot \mathbb{E}[R] \cdot ((1 - p_{\text{crit}}) \cdot D_{\text{norm}} + p_{\text{crit}} \cdot D_{\text{crit}}) \quad (2.6)$$

on D_{norm} i D_{crit} corresponen al dany base sense i amb l'omissió de modificadors d'etapa desfavorables. L'Equació 2.6 és l'esperança del simulador. Les heurístiques d'aquest treball no la calculen: ometen el crit ($p_{\text{crit}} \approx 4,17\%$) i la tirada ($\mathbb{E}[R] = 0,925$) i puntuen $\mathbb{E}[\text{Dany}] \approx P_{\text{acc}} \cdot D_{\text{base}}$. El biaix és deliberat (latència per torn); MCTS reintrodueix l'estocasticitat via rollouts.

Aquestes fonts, juntament amb la generació procedural d'equips, els empats de velocitat (Secció 2.1.5) i els efectes secundaris binaris del motor (paralització completa, flinch, descongelació), impedeixen trajectòries deterministes i obliguen a quantificar la incertesa mitjançant simulació o polítiques de risc [11, 12].

2.1.8 Complexitat combinatòria en la configuració d'equips

Més enllà de la presa de decisions durant el combat, la fase prèvia de selecció i configuració d'un equip Pokémon presenta una explosió combinatòria extraordinària. Per a cada un dels sis membres de l'equip, cal triar l'espècie, un conjunt de 4 moviments d'entre el seu repositori disponible (M), la distribució de Punts d'Esforç (EVs) i Valors Individuals (IVs), la Naturalesa, l'Habilitat, l'Objecte equipat i el Tipus de Teracristallització (un dels 18 tipus possibles a la Generació IX).

Formalment, el nombre de configuracions possibles per a una única posició o ranura de l'equip ($\mathcal{C}_{\text{slot}}$) es pot acotar com el producte del seu espai de paràmetres:

$$\mathcal{C}_{\text{slot}} = N_{\text{espècies}} \times \binom{M}{4} \times N_{\text{objectes}} \times N_{\text{habilitats}} \times N_{\text{naturaleses}} \times N_{\text{tera}} \times N_{\text{stats}} \approx 10^{22} - 10^{23} \quad (2.7)$$

on $N_{\text{espècies}} \approx 10^3$ (corresponent a les 1.025 espècies de la Pokédex Nacional en formats lliures de construcció d'equips, o $\approx 5 \times 10^2$ espècies/formes competitives presents al repositori de **gen9randombattle**), la combinatòria de 4 moviments $\binom{M}{4} \approx 10^4 - 10^5$, $N_{\text{objectes}} \approx 10^2$, $N_{\text{naturaleses}} = 25$, $N_{\text{tera}} = 18$ i les distribucions d'EVs/IVs $N_{\text{stats}} \approx 10^{10} - 10^{11}$. Per a un equip de sis Pokémon no ordenats, el nombre total de composicions d'equips ($\mathcal{C}_{\text{equip}}$) s'obté mitjançant:

$$\mathcal{C}_{\text{equip}} = \frac{(\mathcal{C}_{\text{slot}})^6}{6!} \approx \frac{(10^{23})^6}{720} \approx 10^{135} - 10^{139}. \quad (2.8)$$

Estudis recents sobre entorns de decisió complexos en Pokémon com Angliss et al. [13] xifren l'espai combinatori d'equips competitiu en l'ordre de 10^{139} configuracions. Aquesta magnitud se situa entre l'espai d'estats dels escacs ($\approx 10^{47}$) i el del Go ($\approx 10^{170}$), tal com s'il·lustra a la Figura 2.3. El valor exacte del producte depèn del repositori d'espècies i de N_{stats} ; el que importa metodològicament no és la xifra, sinó que la construcció d'equips confon la mesura de la política.

Aquesta immensa varietat imposa un repte metodològic central en l'avaluació d'agents d'intel·ligència artificial. En formats d'equips lliures (*Teambuilding* o *Custom Teams*), la taxa de




Figura 2.3: Comparativa en escala logarítmica ($\log_{10}$) de l'espai combinatori d'equips Pokémon ($\approx 10^{139}$) amb l'espai d'estats dels escacs ($\approx 10^{47}$) i el Go ($\approx 10^{170}$).

victòria d'un agent pot quedar fortament emmascarada per la superioritat o el desequilibri inicial de la composició de l'equip (meta-gaming), impossibilitant mesurar amb claredat si el rendiment es deu a una presa de decisions autònoma i tàctica de qualitat o a un avantatge estructural previ. Conseqüentment, per avaluar amb rigor el raonament executiu d'un agent cal desacoblar la fase de construcció d'equips de l'execució en combat.

2.1.9 El format Random Battle, el simulador Showdown i poke-env

Per aïllar la presa de decisions executives i eliminar els biaixos de construcció d'equips derivats de l'espai combinatori de 10^{139} equips (Secció 2.1.8), aquest treball utilitza com a marc experimental el format oficial **Random Battle** (`gen9randombattle`) [14]. En aquest format, el simulador restringeix el repositori d'espècies a un conjunt de $\approx 5 \times 10^2$ Pokémon competitius de la Generació IX i assigna proceduralment a cada jugador un equip aleatori de sis Pokémon a l'inici del combat, amb configuracions optimitzades extretes del repositori públic de Smogon [15] i un mecanisme de reequilibrat dinàmic de nivells (L) que compensa les diferències de potència entre espècies.

Aquesta generació procedural garanteix que els agents s'enfrontin de manera contínua a escenaris no vistos i variats. Mitjançant una avaluació basada en un volum significatiu de batalles, la variància associada a la generació d'equips es cancel·la estadísticament, garantint la significança dels resultats que es detallen en la metodologia (Capítol 3) i en l'avaluació empírica (Capítol 6).

Pokémon Showdown [5] és el simulador de codi obert (Node.js/TypeScript) que implementa les regles oficials; *poke-env* [6] n'exposa la interfície Python. El servidor manté l'estat omniscient S i emet a cada agent només o_i (Figura 2.6d). L'espai d'accions discret per torn comprèn fins a 4 moviments (amb Teracristal·lització opcional) i fins a 5 canvis, com a la Figura 2.4. El contracte experimental —protocol, objecte `Battle` i ordre legal— es tanca al Capítol 3.

2.1.10 Síntesi del domini: Pokémon com a entorn benchmark ideal per a la IA

En resum, el combat Pokémon en `gen9randombattle` encreua quatre reptes que altres bancs de proves de la IA solen aïllar (Figura 2.5, adaptada de Traylor [1]):

1. **Planificació a llarg termini (*Long-Term Planning*):** Propi de jocs d'estratègia posicional pura com els **escacs** o el **Go**. A Pokémon, les decisions no es poden valorar aïlladament per al torn actual: cal gestionar un equip de sis criatures al llarg de desenes de

```

[Turn 7] Battle: gen9randombattle | Weather: None | Tera: Available (Water)
Opponent: Dragapult (Lv. 79) | HP: 82% [231/282] | Moves: Shadow Ball, Draco Meteor, ...
Active:   Garchomp (Lv. 74)   | HP: 100% [274/274] | Item: Life Orb | Boosts: None

Available moves:
[1] Earthquake (Ground, Physical, BP: 100, Acc: 100%, PP: 16/16)
[2] Outrage (Dragon, Physical, BP: 120, Acc: 100%, PP: 16/16)
[3] Swords Dance (Normal, Status, Boost: +2 Atk, PP: 32/32)
[4] Stone Edge (Rock, Physical, BP: 100, Acc: 80%, PP: 8/8)

Available switches:
[5] Corviknight (Lv. 76, Flying/Steel) | HP: 100% [269/269] | Healthy
[6] Iron Valiant (Lv. 78, Fairy/Fighting) | HP: 64% [151/236] | Healthy
[7] Rotom-Wash (Lv. 82, Electric/Water) | HP: 100% [216/216] | Healthy
[8] Skeledirge (Lv. 77, Fire/Ghost) | HP: 42% [128/305] | Healthy

> Choose action [1-4 (+ 'terastallize'), 5-8]: 1

```

Figura 2.4: Exemple compacte de text amb l'estat del combat i l'espai d'accions discret (moviments [1–4], Teracristal · lització i canvis [5–8]) disponible per a l'agent a cada torn.

torns, sacrificant Pokémon per conservar la iniciativa (*tempo*), col·locant perills d'entrada (*hazards*) o preparant condicionants de victòria (*win conditions*) per al final del combat.

2. **Accions simultànies (*Simultaneous Actions*):** Present en jocs com el **Pedra-Paper-Tisores** o variants d'**escacs a cegues** (*Kriegspiel*). A cada torn, tots dos jugadors escullen la seva acció de manera secreta i simultània (Secció 2.1). L'agent no pot simplement reaccionar a un moviment vist, sinó que ha de raonar estratègicament sobre la matriu de respostes rivals des de la teoria de jocs.
3. **Gestió de la probabilitat i l'estocasticitat (*Probability Management*):** Típic de jocs de **daus** o **Backgammon**. Les tirades de dany, la precisió dels moviments, els cops crítics (Secció 2.1.7) i la generació procedural d'equips (Secció 2.1.9) impedeixen l'existència de trajectòries deterministes, obligant l'agent a ponderar riscos i esperances matemàtiques a cada decisió.
4. **Informació imperfecta i oculta (*Imperfect Information*):** Propi de jocs de cartes com el **Pòquer** o *Magic: The Gathering*. L'estat inicial del rival (moviments no revelats, objectes, habilitats, IVs/EVs i Tipus Tera) roman ocult fins que s'exposa en combat, exigint a l'agent mantenir i actualitzar una distribució de creença sobre les variables no observades.

La convergència d'aquests quatre eixos (Figura 2.5) converteix el combat Pokémon en un banc de proves on planificació, simultaneïtat, estocasticitat i informació oculta s'han de tractar alhora. Cap agent d'aquest treball no manté la distribució de creença completa de l'ítem 4: condicionen a la història revelada $o_{i,t}$ (Secció 2.2.3).

Aquesta combinació fa imprescindible el modelat com a POSG. La Secció 2.2 tradueix les mecàniques a POMDP i POSG.

2.2 Formalització matemàtica i marc d'inferència estadística

Aquesta secció formalitza matemàticament els quatre eixos de complexitat del combat Pokémon introduïts anteriorment (Figura 2.5) des de la Teoria de Jocs i els Processos de Decisió (models POSG/POMDP), n'analitza l'estat de creença i les reduccions d'enginyeria al format `gen9randombattle`, i estableix el marc d'inferència estadística per a l'avaluació empírica dels agents.




Figura 2.5: Intersecció dels quatre eixos fonamentals de complexitat en IA i la seva correspondència amb altres jocs (adaptat del treball divulgatiu d'Aaron Traylor [1]).

2.2.1 De la informació perfecta a la informació imperfecta

Per modelar matemàticament els quatre eixos de complexitat descrits a la secció anterior (planificació a llarg termini, simultaneïtat, estocasticitat i informació imperfecta; Figura 2.5), recorrem a la **Teoria de Jocs** [16]: la branca de les matemàtiques aplicades que estudia les situacions d'interacció estratègica entre agents racionals, on la utilitat o recompensa d'un individu depèn tant de les seves decisions com de les accions escollides pels seus rivals. En la història de la intel·ligència artificial, els jocs han estat el banc de proves clàssic per mesurar la capacitat de raonament autònom [17–24].

Des del punt de vista de la visibilitat de l'estat, la Teoria de Jocs divideix els entorns en dues grans categories:

- **Informació perfecta** (escacs, Go): L'estat complet del joc s és comú i totalment visible per a tots els jugadors a cada pas ($o_t = s_t$), de manera que no existeix incertesa sobre la configuració de l'entorn.
- **Informació imperfecta** (pòquer, StarCraft II, Pokémon): Part de l'estat global roman oculta a un o tots dos jugadors. Tal com s'ha exposat a la Secció 2.1.10, l'agent percep només una observació parcial $o_t \in \Omega$ i ha d'inferir probabilísticament les variables no visibles per prendre decisions sota incertesa.

Així doncs, dins del marc de la Teoria de Jocs, el combat Pokémon es classifica formalment com un **joc de dos jugadors, competitiu de suma zero, de selecció simultània i d'informació imperfecta**:

- **Suma zero:** La victòria d'un jugador és exactament la derrota del rival ($R_1 + R_2 = 0$), descartant qualsevol possibilitat de cooperació.
- **Selecció simultània:** Tots dos jugadors trien la seva acció de manera secreta i paral·lela a cada torn.
- **Informació imperfecta:** Els moviments no utilitzats, objectes equipats, EVs/IVs i Tipus Tera del rival no són directament accessibles, forçant la decisió sota un conjunt d'informació restringit.

2.2.2 Formalització dels Processos de Decisió: MDP, POMDP i POSG

En intel·ligència artificial i aprenentatge per reforç, un **marc o model de decisió** és la formulació matemàtica que descriu com un agent percep l'entorn, avalua les seves opcions i tria accions per maximitzar la probabilitat de guanyar (com processar l'estat de Showdown, avaluar atacs o canvis i triar la decisió de màxima utilitat). Per formalitzar el combat Pokémon de manera entenedora, cal comprendre com passem del marc teòric més simple al model matemàtic real del joc, analitzant aquesta evolució segons la informació disponible i el nombre de jugadors:

1. **MDP (Markov Decision Process):** El marc base per a un sol agent que juga amb informació perfecta (una simplificació teòrica idealitzada on fossin visibles tots els moviments, objectes i intencions rivals; vegeu el diagrama estructural a la Figura 2.6a).
2. **POMDP (Partially Observable MDP):** L'ampliació quan un sol agent pren decisions sota informació imperfecta (la reducció d'enginyeria utilitzada per PPO i XGBoost en integrar el rival dins l'entorn amb dades ocultes com moviments no revelats, objectes o Tipus Tera; vegeu la Figura 2.6b).
3. **POSG (Partially Observable Stochastic Game):** El model matemàtic real del combat Pokémon (el format `gen9randombattle` on dos jugadors trien acció simultàniament a cada torn amb informació parcialment oculta; vegeu el model abstracte a la Figura 2.6c i la seva instanciació real amb Pokémon Showdown a la Figura 2.6d).

Un **Procés de Decisió de Markov (MDP)** [25] es defineix com la tupla (S, A, T, R, γ) , on S és l'espai d'estats, A l'espai d'accions, $T(s' | s, a) = P(S_{t+1} = s' | S_t = s, A_t = a)$ la funció de transició estocàstica, $R(s, a)$ la funció de recompensa i $\gamma \in [0, 1]$ el factor de descompte (Figura 2.6a). La política $\pi(a | s)$ maximitza el retorn esperat.

Quan l'agent no observa directament l'estat real s , sinó una observació parcial $o \in \Omega$ emesa segons una funció d'emissió $O(o | s', a) = P(O_{t+1} = o | S_{t+1} = s', A_t = a)$, el model es converteix en un **Procés de Decisió de Markov Parcialment Observable (POMDP)** [26, 27] (Figura 2.6b).

Atès que a Pokémon hi intervenen dos jugadors que escullen accions de forma simultània sense conèixer la decisió del rival en el torn actual, el model formal conceptualment rigorós és un **Joc Estocàstic d'Observació Parcial (POSG)** [16, 28]. Formalment, un POSG de dos jugadors (esquematitzat conceptualment a la Figura 2.6c) es defineix com una tupla de vuit components:

$$\mathcal{M} = (N, S, \{A_i\}_{i \in N}, T, \{R_i\}_{i \in N}, \{\Omega_i\}_{i \in N}, \{O_i\}_{i \in N}, \gamma) \quad (2.9)$$

on:

- $N = \{1, 2\}$ és el conjunt dels dos jugadors (Jugador 1 i Jugador 2).
- S és l'espai d'estats globals del joc (mantingut de manera omniscient pel servidor central de Pokémon Showdown).
- A_i és l'espai d'accions del jugador i . Una acció conjunta s'expressa com $\mathbf{a} = (a_1, a_2) \in A_1 \times A_2$.
- $T(s' | s, \mathbf{a}) = P(S_{t+1} = s' | S_t = s, \mathbf{a}_t = \mathbf{a})$ és la probabilitat de transició condicional sota l'acció conjunta.
- $R_i(s, \mathbf{a})$ és la recompensa del jugador i . En ser un joc competitiu pur de suma zero, es compleix $R_1(s, \mathbf{a}) + R_2(s, \mathbf{a}) = 0$.
- Ω_i és l'espai d'observacions privades del jugador i .

- $O_i(o_i | s', \mathbf{a}) = P(O_{i,t+1} = o_i | S_{t+1} = s', \mathbf{a}_t = \mathbf{a})$ és la funció d'emissió d'observacions privades, on el motor de Showdown mascara les dades no revelades del rival abans d'enviar el paquet d'estat a cada jugador.
- $\gamma \in [0, 1]$ és el factor de descompte temporal.

Cal destacar que el simulador central de Pokémon Showdown actua com un àrbitre omniscient que conté l'estat real complet S (amb tota la informació oculta de tots dos jugadors), però aplica el **filtre del seu protocol** per obfuscar les dades no revelades del rival i transmetre a cada agent únicament la seva observació parcial emmascarada o_1, o_2 (Figura 2.6d). Aquest mecanisme d'emissió i els detalls de funcionament del simulador es desenvolupen en profunditat en els capítols de metodologia, infraestructura i implementació (Capítols 3, 4 i 5).




Figura 2.6: Comparació estructural entre marcs de decisió: a) MDP (informació perfecta), b) POMDP (reducció a 1 decisor sota informació imperfecta), c) POSG teòric (formulació matemàtica abstracta amb 2 jugadors) i d) POSG instanciat en Pokémon Showdown amb el filtre del seu protocol.

2.2.3 Estat de creença, matriu de recompenses i reducció d'enginyeria

Una vegada definit el marc formal del POSG, sorgeix la qüestió de com un agent pot prendre decisions operatives en temps real. Com s'ha establert a la Secció 2.2.2, el combat Pokémon planteja tres grans desafiaments que impedeixen aplicar algorismes de cerca convencionals:

1. **La informació oculta:** Requereix introduir l'estat de creença (*Belief State*) per inferir probabilísticament les variables no visibles del rival (moviments, objectes o Tipus Tera) a partir de la història del combat.
2. **La simultaneïtat de les accions:** Requereix utilitzar la **matriu de recompenses** de la Teoria de Jocs per calcular l'**Equilibri de Nash**, evitant que l'agent sigui explotable per polítiques deterministes de l'adversari.
3. **La intractabilitat computacional (NEXP-complet):** Fa impossible resoldre el joc de manera exacta i força a aplicar **reduccions d'enginyeria** (POMDP d'un sol decisor o arbres locals) per decidir en mil·lisegons.

En els següents apartats es desenvolupen formalment cadascuna d'aquestes tres solucions.

L'estat de creença (*Belief State*)

Per gestionar la inaccessibilitat de l'estat real s provocada per la informació oculta, l'agent utilitza un **estat de creença** (*Belief State*) $b_{i,t}(s) \in \Delta(S)$. Aquest es defineix com la distribució de probabilitat sobre els possibles estats globals s donada la història d'observacions i accions acumulades $h_{i,t} = (o_{i,1}, a_{i,1}, \dots, o_{i,t})$:

$$b_{i,t}(s) = P(S_t = s \mid h_{i,t}) \quad (2.10)$$

A cada torn, l'agent actualitza $b_{i,t}$ mitjançant la regla de Bayes [29] en rebre la nova observació $o_{i,t+1}$. Això li permetria ponderar atacs de cobertura o objectes no revelats. En aquest treball, però, cap paradigma no manté $b_{i,t}$ com a posterior sobre S : les polítiques condicionen a la filtració d'informació *ja revelada* ($o_{i,t}$). L'MCTS, a més, determina cada rollout de manera consistent amb o_t , no pren l'esperança sobre $b(s)$.

La matriu de recompenses i l'Equilibri de Nash

L'**Equilibri de Nash** [30], fonamentat en els jocs matricials de suma zero de Von Neumann i Morgenstern [16], és el concepte central de la Teoria de Jocs que defineix l'estat d'un joc en què cap participant no té cap incentiu per modificar la seva estratègia de manera unilateral, ja que qualsevol canvi individual reduiria o igualaria la seva recompensa esperada.

En el combat Pokémon, com que tots dos jugadors escullen la seva acció de manera **simultània** sense veure la jugada del rival, sorgeix un gran problema: **qualsevol decisió determinista fixa és previsible i fàcilment explotable**. Per exemple, si l'agent triés sempre l'atac de més potència, un rival intel·ligent ho preveuria i canviaria a un Pokémon resistent o immune a aquest atac, fent perdre l'agent sistemàticament.

Per aquest motiu, l'objectiu de l'agent no és trobar una única "millor acció" fixa, sinó calcular una **estratègia inexplorable** mitjançant la formulació del torn com una **matriu de recompenses en forma normal** $M(a_1, a_2) = \mathbb{E}_{s \sim b}[R_1(s, a_1, a_2) + \gamma V(s')]$, on les files representen les accions del Jugador 1 ($a_1 \in A_1$) i les columnes les respostes del Jugador 2 ($a_2 \in A_2$).

Prenguem com a exemple un torn on el Jugador 1 pot escollir entre un atac elèctric o un canvi defensiu, i el Jugador 2 pot escollir entre un atac d'aigua o un canvi a un Pokémon de tipus Terra (immune a l'electricitat):

Com s'observa a la Taula 2.4:

Jugador 1 \ Jugador 2	Atac d'Aigua (a_1^1)	Canvi a Terra (a_2^2)
Atac Elèctric (a_1^1)	+10 (<i>Dany màxim</i> ×4)	-10 (<i>Avançat pel rival / Atac nul</i>)
Canvi defensiu (a_1^2)	+2 (<i>Resisteix atac</i>)	0 (<i>Canvi neutre</i>)

Taula 2.4: Exemple simplificat d'una matriu de recompenses en forma normal per a un torn de combat. Els valors representen la recompensa esperada del Jugador 1.

- Si el Jugador 1 juga el 100% de les vegades l'Atac Elèctric (a_1^1), el rival ho descobrirà i respondrà jugant el 100% el Canvi a Terra (a_2^2), fent que el Jugador 1 obtingui la pitjor recompensa possible (-10).
- Per evitar ser previsible i explotat, l'agent ha d'emprar una **estratègia mixta / estocàstica** $\pi_1^* \in \Delta(A_1)$ i assignar probabilitats a cada opció (p. ex., un 70% de probabilitat a l'atac elèctric i un 30% al canvi defensiu).

Matemàticament, el parell d'estratègies (π_1^*, π_2^*) constitueix un **Equilibri de Nash** si es compleix la següent condició de no-explotabilitat:

$$\mathbb{E}_{\mathbf{a} \sim (\pi_1^*, \pi_2^*)}[R_1(s, \mathbf{a})] \geq \mathbb{E}_{a_1 \sim \pi_1, a_2 \sim \pi_2^*}[R_1(s, a_1, a_2)], \quad \forall \pi_1 \in \Delta(A_1) \quad (2.11)$$

En aquest punt d'equilibri, l'agent es garanteix el màxim retorn esperat possible sense que el rival pugui aprofitar-se de cap biaix en les seves decisions.

Justificació de les reduccions d'enginyeria i complexitat NEXP

La cerca d'un Equilibri de Nash o de la política òptima conjunta en un POSG d'horitzó finit és **NEXP-complet** [31]: no hi ha algorisme exacte viable en el temps de resposta d'un combat. Les polítiques d'aquest treball no resolen el POSG; n'apliquen reduccions:

- **Aprenentatge per Reforç (PPO) i Clonatge Conductual (XGBoost):** Redueixen la complexitat multijugador integrant la política del rival $\pi_2(a_2 | o_2)$ directament dins de la funció de transició de l'entorn:

$$T_{\text{eff}}(s' | s, a_1) = \sum_{a_2 \in A_2} \pi_2(a_2 | o_2) \cdot T(s' | s, a_1, a_2) \quad (2.12)$$

Aquesta formulació transforma el POSG competitiu de dos jugadors en un **POMDP d'un sol decisor** (Figura 2.6b), on l'adversari s'absorbeix en la dinàmica de l'entorn.

- **Cerca Minimax i MCTS:** Acoten l'horitzó a un torn (maximin pur sobre la matriu local; l'equilibri mixt es reserva com a referent teòric, Secció 2.4.2) o a rollouts rasos a l'arrel. L'MCTS determina cada simulació de manera consistent amb o_t .

2.2.4 Instanciació dels components a `gen9randombattle`

Per traslladar els conceptes teòrics de la tupla POSG/POMDP (S, A, T, R, Ω, O) al desenvolupament d'agents de decisió autònoms en aquest treball, cal definir com es tradueix cada component abstracte a l'entorn real de simulació de Pokémon Showdown i *poke-env* en el format `gen9randombattle`. A la Taula 2.5 es detalla aquest mapatge exactament.

La Taula 2.5 tanca el mapatge. Heurístiques i cerca operen sobre l'objecte `Battle`; XGBoost el projecta a un vector tabular; MaskablePPO, a un vector en $[0, 1]$ i a una màscara $M(a)$. El detall d'aquestes representacions és als Capítols 3 i 5.

Component	Instanciació a Singles <code>gen9randombattle</code>
S	Sis Pokémon per bàndol (espècie, HP, configuració, objecte, habilitat, modificadors i condició d'estat), clima, perills d'entrada, Tera consumit i torn. $ S $ és astronòmic i no s'enumera.
A	Ordres directes de combat (<i>raw orders</i> : 4 moviments, Tera opcional i fins a 5 canvis de banquet). En aprenentatge per reforç discret, es codifica en un espai fix (4 moviments + 4 moviments amb Tera + 6 slots d'equip). La legalitat $M(a) \in \{0, 1\}$ la determinen els PP, debilitaments, bloqueigs i absència de canvi al mateix Pokémon actiu.
T	Motor de Showdown: determinista en les mecàniques de combat, estocàstic en el multiplicador de dany $[0,85, 1,00]$, la precisió dels moviments, els efectes secundaris, els empats de velocitat (<i>speed ties</i>) i la generació procedural de l'equip a l'inici del combat.
R	Recompensa terminal zero-sum conceptual +1 per victòria i -1 per derrota (indicador binari $W \in \{0, 1\}$ enregistrat per a l'avaluació). En l'entrenament RL s'utilitza una funció de recompensa dita densa (<i>reward shaping</i>) basada en la diferència d'HP, penalització/bonificació per debilitament de Pokémon, modificadors d'estat i penalització per pas de temps.
Ω	Equip propi complet; del rival, espècies revelades, percentatge d'HP, moviments utilitzats, condicions laterals i modificadors d'estat. EV, naturalesa, objecte i moviments no utilitzats romanen ocults.
O	Mecanisme d'emascament i protocol WebSocket de Pokémon Showdown / <i>poke-env</i> . Intercepta l'estat global S i genera l'observació parcial privada $o_i \in \Omega_i$ filtrant les dades no revelades abans de transmetre el paquet al client.

Taula 2.5: Mapatge POSG/POMDP al combat individual de Random Battle (Generació IX).

2.2.5 Marc d'avaluació estadística i mètodes d'inferència

La comparació empírica entre agents requereix un marc d'inferència que separi diferències de política del soroll del simulador i de la generació d'equips. Aquesta secció defineix la taxa de victòries, els intervals de Wilson, el rànquing Bradley–Terry per MLE i els contrastes de dues proporcions. Les funcions de pèrdua d'imitació i l'emascament PPO es defineixen a la Secció 2.4; la telemetria conductual, al Capítol 3.

1. **Estimació de la Taxa de Victòria (*Win Rate*) i Marge d'Error:** En un enfrontament de N partides entre dos agents, cada combat i s'escriu com una variable aleatòria binària de Bernoulli $W_i \sim \text{Bernoulli}(p)$, on $W_i = 1$ indica victòria de l'agent i $W_i = 0$ indica derrota. L'estimador puntual de la taxa de victòria $\hat{p}$ és la mitjana mostral:

$$\hat{p} = \frac{1}{N} \sum_{i=1}^N W_i \quad (2.13)$$

La variància d'aquest estimador ve donada per $\text{Var}(\hat{p}) = \frac{p(1-p)}{N}$, assolint el seu màxim teòric quan $p = 0,5$. El marge d'error (MoE) al nivell de confiança del 95% ($\alpha = 0,05$) es calcula com:

$$\text{MoE} = z_{1-\alpha/2} \cdot \text{SE}(\hat{p}) = z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{N}} \quad (2.14)$$

Per a una mida mostral de $N = 10.000$ partides per enfrontament directe, l'error estàndard màxim és $\text{SE}(\hat{p}) = \sqrt{0,25/10000} = 0,005$ (0,5%), el que garanteix un marge d'error màxim de $\text{MoE} = 1,96 \cdot 0,005 = \pm 0,0098 \approx \pm 0,98\%$ ($\approx \pm 1\%$). En mostres menors com $N = 1.000$, el marge d'error és de $\text{MoE} \approx \pm 3,10\%$.

2. **Intervals de Confiança de Wilson (*Wilson Score Interval*):** A diferència de l'interval binomi estàndard de Wald ($\hat{p} \pm z\sqrt{\hat{p}(1-\hat{p})/N}$), que falla prop dels límits (0 o 1) o en mostres asimètriques, aquest treball calcula els intervals de confiança mitjançant l'**interval de la puntuació de Wilson** [32]:

$$CI_{\text{Wilson}} = \frac{1}{1 + \frac{z^2}{N}} \left(\hat{p} + \frac{z^2}{2N} \pm z\sqrt{\frac{\hat{p}(1-\hat{p})}{N} + \frac{z^2}{4N^2}} \right) \quad (2.15)$$

on $z = z_{1-\alpha/2} = 1,96$ per a un nivell de confiança del 95% ($\alpha = 0,05$).

3. **Model de Bradley–Terry i puntuació Elo per màxima versemblança (MLE):**

Per projectar un conjunt d'agents sobre una escala global unidimensional de força relativa independent de la composició d'oponents, s'utilitza el model de comparació per parelles de Bradley–Terry [33] transformat a escala Elo [34]. La probabilitat esperada de victòria de l'agent A_i enfront de l'agent A_j amb puntuacions R_i i R_j s'expressa mitjançant la funció logística:

$$P(A_i > A_j) = \frac{1}{1 + 10^{(R_j - R_i)/400}} = \sigma \left(\frac{\ln 10}{400} (R_i - R_j) \right) \quad (2.16)$$

A diferència del sistema d'actualització seqüencial Elo utilitzat en el joc en línia (que depèn de l'ordre dels combats), els paràmetres $\{R_i\}$ s'estimen de manera conjunta sobre la matriu completa d'enfrontaments mitjançant la maximització de la log-versemblança (MLE):

$$\ln \mathcal{L}(\mathbf{R}) = \sum_{i < j} (W_{ij} \ln P(A_i > A_j) + W_{ji} \ln P(A_j > A_i)) \quad (2.17)$$

Computacionalment, aquesta optimització s'executa igualant l'estimador a una **regressió logística sense terme independent** (*unintercepted logistic regression*): sobre un conjunt de dades simetritzat de M batalles amb vectors d'entrada $\mathbf{x}_k \in \{-\ln 10, 0, +\ln 10\}^P$ i etiquetes $y_k \in \{0, 1\}$, s'obtenen els coeficients $\hat{\beta}$, a partir dels quals es calculen les puntuacions Elo:

$$R_i = 400 \cdot \hat{\beta}_i + R_{\text{init}} \quad (2.18)$$

fixant l'ancoratge de referència de l'agent aleatori en $R_{\text{random}} = 1000$.

4. **Comparació de Dues Proporcions Independents i Significança de Diferències:**

Per determinar si la diferència observada $\Delta\hat{p} = \hat{p}_1 - \hat{p}_2$ entre dos agents (p. ex., en estudis d'ablació de regles o mecàniques) és estadísticament significativa, es calcula l'error estàndard de la diferència:

$$SE(\Delta\hat{p}) = \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{N_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{N_2}} \quad (2.19)$$

i el corresponent interval de confiança del 95% per a la diferència de taxes de victòria:

$$CI_{95\%}(\Delta p) = (\hat{p}_1 - \hat{p}_2) \pm z_{1-\alpha/2} \cdot SE(\Delta\hat{p}) \quad (2.20)$$

Si l'interval de confiança $CI_{95\%}(\Delta p)$ no inclou el valor 0, es conclou que la millora de rendiment és estadísticament significativa amb $p < 0,05$.

A la Taula 2.6 es sintetitza el conjunt d'eines matemàtiques, mètriques d'inferència i propietats estadístiques que integren el marc teòric d'avaluació d'aquest treball.

La variància estocàstica associada a la generació procedural d'equips a Random Battle es dilueix fixant una mida mostral suficientment gran per a cada enfrontament directe ($N \geq 10^3$), la qual cosa acota l'error estàndard de l'estimador per sota de llindars de soroll rellevants ($SE \leq 0,015$) i garanteix la significança estadística de les comparacions presentades en els capítols següents.

Mètrica / Eina	Formulació Matemàtica / Càlcul	Objectiu / Propietat Estadística
Taxa de Victòria ($\hat{p}$)	$\hat{p} = \frac{1}{N} \sum_{i=1}^N W_i$	Estimació puntual de Bernoulli
Marge d'Error (MoE)	$\text{MoE} = z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{N}}$	Acotació d'error al 95% de confiança
Interval de Wilson	$\text{CI}_{\text{Wilson}}$ Eq. (2.15)	Robustesa en límits $p \rightarrow 0, 1$ i mostres petites
Model Bradley–Terry Elo	$P(A_i > A_j) = \sigma\left(\frac{\ln 10}{400}(R_i - R_j)\right)$	Rànquing 1D conjunt per MLE ($R_{\text{rand}} = 1000$)
Test Z de Diferència	$\text{CI}_{95\%}(\Delta p) = (\hat{p}_1 - \hat{p}_2) \pm 1,96 \cdot \text{SE}(\Delta \hat{p})$	Avaluació de significança en ablacions ($p < 0,05$)
Entropia creuada (IL)	Equació 2.28	Pèrdua de clonatge conductual (Secció 2.4.4)
Softmax emmascarat (PPO)	Equació 2.30	Accions legals $M(a)$ (Secció 2.4.5)
Telemetria tàctica	Indicadors de latència, canvis, hazards i RNG	Definit al Capítol 3

Taula 2.6: Síntesi del marc d'avaluació estadística, eines d'inferència i les seves propietats teòriques.

2.3 Estat de l'Art en IA i Pokémon

L'estudi de la presa de decisions autònoma en el combat competitiu de Pokémon ha experimentat un desenvolupament creixent gràcies a l'estandardització d'entorns de simulació oberts. Aquesta secció revisa la literatura existent organitzant els treballs rellevants en quatre blocs temàtics, analitza les manques principals de la recerca prèvia i descriu el valor afegit d'aquest treball.

2.3.1 Plataformes d'integració i entorns de simulació

La recerca en IA aplicada a Pokémon va prendre impuls amb el desenvolupament de **Pokémon Showdown** [5], el simulador de codi obert utilitzat per la comunitat competitiva de Smogon. La creació de la llibreria *poke-env* [6, 35] va establir la interfície estàndard per a la connexió d'agents autònoms via protocols WebSocket, facilitant l'accés a l'estat del combat (**Battle**) i l'emissió d'ordres legalitzades. Així mateix, aquesta plataforma inclou agents de referència fonamentals basats en selecció aleatòria (**RandomPlayer**), atacs de màxima potència (**MaxBasePowerPlayer**) i regles heurístiques bàsiques (**SimpleHeuristicsPlayer**).

2.3.2 Aprenentatge per reforç profund i exploració autònoma

L'aplicació de l'aprenentatge per reforç profund (DRL) a Pokémon presenta reptes de gran complexitat per l'alta dimensió de l'espai d'estats, la informació oculta i l'estocasticitat. Huang i Lee [12] van realitzar un dels treballs pioners entrenant un agent basat en Proximal Policy Optimization (PPO) mitjançant auto-aprenentatge (*self-play*) sobre Pokémon Showdown. Els seus resultats van evidenciar la dificultat de la cerca no guiada: sense un emmascarament rigorós d'accions legals ni una inicialització guiada per coneixement de domini, els agents RL tenen tendència a convergir cap a polítiques subòptimes o bloquejar-se en cicles d'accions invàlides. Treballs posteriors han demostrat que la combinació de PPO amb emmascarament binari d'accions (*Invalid Action Masking*) [2] i el disseny de recompenses denses (*reward shaping*) [36] són elements claus per estabilitzar la convergència en entorns d'informació imperfecta.

2.3.3 Aprenentatge fora de línia i arquitectures basades en Transformers

Davant les dificultats de l'exploració activa a l'entorn de simulació, una línia de recerca recent aposta per l'aprenentatge a partir de dades d'experts humans. L'agent *Metamon* [11] representa una de les fites més recents en aquest eix, aplicant aprenentatge per reforç fora de línia (*offline RL*) i arquitectures basades en Transformers sobre corpus massius de repeticions de partides d'alt nivell. Aquest enfocament permet als models extreure patrons estratègics complexos i relacions temporals directament de les trajectòries d'experts, tot i que requereix una capacitat computacional elevada per a l'entrenament dels models de polítiques.

2.3.4 Models de llenguatge de gran escala i cerca adversària híbrida

L'emergència dels models de llenguatge de gran escala (LLM) ha generat una nova línia d'agents capaços de raonar sobre l'estat del combat mitjançant llenguatge natural. L'agent *PokéLLMon* [37] utilitza LLMs (GPT-4) amb recuperació de coneixement extern (KAG) i aprenentatge en context per inferir la informació oculta del rival en el format `gen8randombattle`, sense requerir entrenament neuronal específic. Paral·lelament, l'agent *PokéChamp* [38, 39] combina models de llenguatge per a la construcció de l'estat de creença amb cerca Minimax d'un pas en el format d'equips construïts `gen9ou` (recolzat en un corpus de 3 milions de partides competitives), assolint posicions destacades al *ladder* de Showdown. Aquests treballs demostren que integrar coneixement de domini o motors de cerca amb models apresos supera el rendiment de qualsevol de les tècniques aplicades de manera aïllada.

2.3.5 Mancances de la literatura i justificació d'aquest treball

Tot i els avenços descrits, la literatura prèvia presenta dues manques estructurals primordials:

1. **Absència d'una matriu d'avaluació integrada i homogènia:** Els treballs precedents avaluen els seus agents en formats heterogenis, enfront d'oponents diferents o sota condicions no estandarditzades, sense una comparació directa i sistemàtica entre els cinc paradigmes fonamentals de la presa de decisions (heurístiques expertes, cerca adversària Minimax, cerca MCTS, aprenentatge per imitació i DRL) sota un mateix protocol experimental i marc d'inferència estadística.
2. **Falta d'estudis d'ablació del coneixement de domini:** Les heurístiques existents solen presentar-se com a blocs monolítics sense aïllar l'impacte individual de cada mecanisme tàctic (com el càlcul de velocitat, la lectura de la Taula de Tipus, la gestió de perills d'entrada o la Teracristal·lització).

2.3.6 Què afegeix aquest TFM

Per respondre a aquestes manques, aquest Treball de Final de Màster aporta les següents contribucions teòriques i metodològiques:

1. **Un marc d'avaluació integrat i homogeni entre paradigmes:** Defineix una matriu de combat que enfronta de manera directa i igualitària els cinc paradigmes fonamentals de decisió sobre un mateix entorn i format (`gen9randombattle`), sota mètodes d'inferència estadística rigorosos (interval de Wilson i ajust Bradley–Terry Elo per MLE).
2. **Una seqüència d'ablació incremental del coneixement de domini:** Desenvolupa una jerarquia d'agents heurístics estructurada en blocs de regles que permet mesurar de manera aïllada el valor afegit de cada component tàctic del joc.
3. **Arquitectures híbrides de cerca i d'imitació guiades per heurístiques:** Explora la integració de regles de domini com a distribucions a priori (*priors*) o executors de suport

en algorismes de cerca adversària (Minimax i MCTS) i aprenentatge per imitació, avaluant el guany estratègic del raonament anticipatori.

4. **Una avaluació rigorosa de MaskablePPO i clonatge conductual:** Desenvolupa i avalua un entorn DRL integrant emmascarament binari d'accions legals, disseny de recompenses denses i inicialització de polítiques mitjançant clonatge conductual sobre dades expertes.

2.3.7 Posicionament comparatiu respecte a la literatura

A fi de sintetitzar les diferències metodològiques i posicionar amb precisió aquest Treball de Final de Màster en relació amb els principals sistemes d'intel·ligència artificial desenvolupats per a Pokémon, la Taula 2.7 presenta una comparativa estructurada segons el format de joc, el paradigma emprat, l'escala mostral d'avaluació, la presència d'estudis d'ablació i el tipus de validació externa.

Taula 2.7: Posicionament comparatiu d'aquest treball respecte als principals sistemes d'IA per a Pokémon a la literatura.

Treball / Sistema	Any	Format	Paradigma i Dades d'Entrenament	Escala (N)	Ablació	Ladder
Huang i Lee [12]	2019	Gen 7 Random	DRL (PPO <i>self-play</i> pur, sense dades humanes)	$N \sim 3,8 \cdot 10^6$	No	Sí (Gen 7)
Sahovic (<i>poke-env</i>) [6]	2020	Gen 8 Rand./OU	Heurístiques estàtiques i DQN bàsic en línia [40]	$N \sim 10^2$	No	No
PokéLLMon [37]	2024	Gen 8 Random	LLM (GPT-4 + KAG/ICRL, <i>prompting</i> sense entrenar)	$N \sim 10^2$	Parcial	Sí ($N \approx 50$)
PokéChamp [38, 39]	2024	Gen 9 OU	Híbrid: LLM + Minimax (dataset de 3M partides OU)	$N \sim 10^3$	No	Sí (Gen 9 OU)
Metamon [11]	2025	Gen 1–4 / 9 OU	<i>Offline RL</i> (Decision Transformer sobre replays Smogon)	$N \sim 10^4$ (offline)	No	No
Aquest treball (TFM)	2026	Gen 9 Random	5 paradigmes (Heur., Minimax, MCTS, XGBoost Elo 1800+, DRL)	6,4M batalles	Sí (14 var.)	Sí ($N = 431$)

Com s'observa a la Taula 2.7, la literatura prèvia s'ha centrat en el desenvolupament d'agents aïllats sota un únic paradigma, sovint amb mostres reduïdes ($N \leq 10^3$) o sense ablacions que permetin quantificar la contribució marginal de cada regla tàctica. Aquest treball omple aquest buit oferint l'estudi comparatiu més extens fins a la data (6,4 milions de batalles en la matriu principal), amb una jerarquia d'ablació de 14 etapes i una avaluació creuada de 28 agents sota condicions idèntiques.

2.4 Fonaments teòrics dels cinc paradigmes de decisió

Cada paradigma de presa de decisions introdueix un mecanisme diferent per fer front a la incertesa, la simultaneïtat i la informació oculta del combat Pokémon: coneixement codificat, anticipació adversària en matriu, simulació estocàstica en arbre, supervisió amb dades expertes humanes o optimització per reforç amb emmascarament. A la Taula 2.8 es resumeixen i s'analitzen les característiques principals d'aquests cinc paradigmes de decisió.

Taula 2.8: Comparació conceptual dels cinc paradigmes. Tots decideixen sobre el mateix simulador i format; canvia la font de coneixement i el còmput per torn.

Paradigma	Què decideix	Coneixement	Còmput per torn	Aprèn?
Heurística	Argmax d'una puntuació fixa sobre accions legals.	Regles escrites (dany, posició, Tera).	Constant, baix.	No durant l'execució.
Minimax d'un torn	Maximin sobre una matriu d'accions i respostes estimades.	Funció de fulla + prior opcional.	Enumeració d'un torn.	No.
MCTS ras	UCB/PUCT només als fills de l'arrel.	Determinització i, a v20, prior de v14.	100 simulacions de 5 torns.	No (cerca en línia).
Imitació	Classificador atacar/canviar + executor.	Trajectòries humanes Elo 1800+.	Inferència XGBoost.	Supervisat, fora de línia.
PPO	Política estocàstica emmascarada $\pi_\theta(a \mid o)$.	Interacció amb recompensa + clonatge inicial.	Un pas de xarxa.	Per reforç, fora de partida.

2.4.1 Heurístiques: coneixement com a ablació

Una política heurística no ajusta els seus paràmetres durant l'execució. A cada estat d'avaluació s , puntua les accions legals $a \in A(s)$ mitjançant un conjunt de regles de domini deterministes i selecciona l'acció que maximitza la funció de puntuació composta $H(s, a)$:

$$a^* = \arg \max_{a \in A(s)} H(s, a) = \arg \max_{a \in A(s)} \sum_{k=1}^K w_k \cdot f_k(s, a) \quad (2.21)$$

on $f_k(s, a) \in \mathbb{R}$ representa una funció d'indicador o de valoració de la mecànica k (com la proporció de dany esperat, el multiplicador de la matriu de tipus, la diferència de velocitat, la inducció d'estats alterats, l'efectivitat dels perills d'entrada o l'oportunitat de preparació) i $w_k > 0$ és el pes o prioritat associat.

L'organització d'aquestes regles en blocs de coneixement independents es formalitza com una **ablació incremental**. Si $\mathcal{F}^{(M)} = \{f_1, f_2, \dots, f_K\}$ és el repositori complet de característiques de domini, una seqüència d'ablació defineix un subconjunt creixent de mecanismes $\mathcal{F}^{(1)} \subset \mathcal{F}^{(2)} \subset \dots \subset \mathcal{F}^{(M)}$. La política de l'agent al pas d'ablació m avalua l'acció mitjançant:

$$H^{(m)}(s, a) = \sum_{f_k \in \mathcal{F}^{(m)}} w_k \cdot f_k(s, a) \quad (2.22)$$

Aquest marc matemàtic permet aïllar i mesurar formalment la contribució marginal $\Delta \hat{p}_m = \hat{p}(H^{(m)}) - \hat{p}(H^{(m-1)})$ associada a la incorporació de cada mecànica concreta (com el càlcul de velocitat, la gestió de perills d'entrada o la Teracristal·lització), transformant l'enginyeria d'heurístiques en un procés rigorós de comprovació d'hipòtesis.

2.4.2 Minimax d'un torn: resposta adversària immediata

El principi Minimax [16, 41] assigna a cada estat el valor de la millor decisió pròpia assumint la resposta més desfavorable de l'oponent. Atès que les accions a Pokémon Showdown s'executen de




Figura 2.7: Arquitectura d'avaluació d'una política heurística basada en la combinació de blocs de coneixement de domini.

manera **simultània** a cada torn, la formulació Minimax d'un pas resol la decisió com un joc de matriu zero-sum de dimensió $|A_1| \times |A_2|$, on l'element $M_{ij} = \mathbb{E}_{s' \sim T(s, a_1, i, a_2, j)}[V(s')]$ representa el valor esperat de l'estat d'arribada obtingut per la funció d'avaluació V , integrant l'estocasticitat del simulador T (tirada de dany, precisió i empats de velocitat).

En estratègies pures, la formulació Maximin ve donada per:

$$a_1^* = \arg \max_{a_1 \in A_1} \min_{a_2 \in A_2} M(a_1, a_2) \quad (2.23)$$

Tanmateix, per evitar ser previsible i explotable davant d'un adversari intel·ligent, la matriu completa es podria resoldre en **estratègies mixtes** $\pi_1^* \in \Delta(A_1)$ mitjançant **Programació Lineal (LP)**, trobant l'Equilibri de Nash local (vegeu Equació 2.11):

$$\max_{\pi_1 \in \Delta(A_1)} v \quad \text{subjecte a} \quad \sum_{i=1}^{|A_1|} \pi_1(i) M_{ij} \geq v, \quad \forall j \in \{1, \dots, |A_2|\}, \quad \sum_i \pi_1(i) = 1, \quad \pi_1(i) \geq 0 \quad (2.24)$$

Aquesta formulació assumeix que A_2 és conegut. En combat amb observació parcial només es veuen els moviments ja revelats, de manera que el disseny experimental (Capítol 3) adopta el maximin pur de l'Equació 2.23 i reserva l'LP com a referent teòric, no com a variant implementada.

La funció d'avaluació d'estat $V(s')$ combina el balanç de punts de salut normalitzats $hp_k \in [0, 1]$ de tots dos bàndols amb bonificacions posicionals:

$$V(s') = \sum_{k \in \text{propi}} hp_k - w_{\text{opp}} \sum_{m \in \text{rival}} hp_m + B(s') \quad (2.25)$$

on $B(s')$ incorpora les contribucions d'estats alterats, condicions laterals (com *Stealth Rock*) i modificadors d'etapa estadística. A més, es poden incorporar distribucions a priori d'orientació provinents de polítiques heurístiques per esbiaixar la matriu cap a decisions d'alta qualitat.

2.4.3 Cerca de Monte Carlo a l'arrel (shallow MCTS)

L'algorisme de cerca en arbre de Monte Carlo (MCTS) [42, 43] alterna quatre fases iteratives: selecció, expansió, simulació (*rollout*) i retropropagació de la recompensa. En entorns amb restricció de temps de resposta, l'MCTS ras limita l'arbre a l'arrel ($d = 1$) i tracta les accions legals $a_1 \in A_1$ com a braços d'un bandit multi-braç, avalats amb trajectòries de k torns sota π_{rollout} . Cada rollout és una *determinització* consistent amb o_t , no una esperança sobre $b(s)$ com en la cerca sobre conjunts d'informació (ISMCTS) [44].




Figura 2.8: Cicle clàssic de l'MCTS adaptat a simulacions de profunditat rasa a l'arrel ($d = 1$) amb rollouts heurístics.

Per a la selecció de les accions a l'arrel, s'utilitza la puntuació UCB1 (*Upper Confidence Bound*) en cerca en arbre [42, 45]:

$$\text{UCB1}(j) = Q(j) + C \sqrt{\frac{\ln N}{n_j}} \quad (2.26)$$

on $Q(j) = \frac{1}{n_j} \sum_{i=1}^{n_j} R_i^{(j)}$ és la recompensa mitjana obtinguda per les simulacions del fill j , $N = \sum_k n_k$ és el total de simulacions realitzades a l'arrel, n_j és el nombre de visites al fill j , i $C > 0$ és la constant d'exploració. Quan la cerca es guia mitjançant coneixement de domini, la selecció s'executa mitjançant la fórmula **PUCT** [19]:

$$\text{PUCT}(j) = Q(j) + c_{\text{puct}} \cdot P(j) \frac{\sqrt{N}}{1 + n_j} \quad (2.27)$$

on $P(j)$ representa la probabilitat a priori assignada a l'acció j per una política de referència (com l'heurística 'v14').

2.4.4 Imitació i clonatge conductual

L'aprenentatge per imitació (*behavioral cloning*) aproxima la política d'un agent a partir de la supervisió de trajectòries d'experts humans [46–48]. Donat un conjunt de dades de parelles observació-acció $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$ extretes de partides de competició d'alt nivell (on $x_i = \phi(o_i) \in \mathbb{R}^d$ és el vector de característiques de l'estat i $y_i \in \{1, \dots, K\}$ és la decisió de l'expert), el model aprèn a maximitzar la probabilitat assignada a les accions humanes optimitzant la pèrdua d'entropia creuada multiclasse:

$$\mathcal{L}_{\text{BC}}(\theta) = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K \mathbb{I}(y_i = k) \ln P_{\theta}(Y = k | x_i) \quad (2.28)$$


En algorismes basats en arbres de decisió augmentats per gradient (XGBoost) [49], aquesta funció d'objectiu s'aproxima a cada iteració t mitjançant un desenvolupament de Taylor de segon ordre sobre els gradients g_i i Hessians h_i :

$$\mathcal{L}^{(t)} \approx \sum_{i=1}^N \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \Omega(f_t) \quad (2.29)$$

Tal com s'esquematitza a la Figura 2.9, l'arquitectura d'imitació es pot estructurar en dos enfocaments principals:

1. **Sistema Híbrid (Figura 2.9a):** Un model de classificació tabular $f_{\text{macro}}(x)$ decideix la macro-acció d'atacar o canviar, delegant la selecció micro de l'atac o el Pokémon concret a un executor heurístic de domini.
2. **Sistema d'Imitació Dual Pur (Figura 2.9b):** Dos models de classificació separats avaluen de manera directa i end-to-end tant el tipus d'acció (f_{type}) com la ranura de moviment o substitut (f_{target}).

a) Arquitectura Híbrida (Macro-decisió ML + Micro-execució Heurística)



b) Arquitectura Dual Pura (Classificació directa de Tipus i Objectiu)




Figura 2.9: Comparació estructural entre l'arquitectura d'imitació Híbrida (macro-decisió ML + micro-execució heurística) i l'arquitectura Dual Pura (dos classificadors XGBoost especialitzats).

2.4.5 Aprenentatge per reforç profund amb emmascarament d'accions

L'aprenentatge per reforç autònom [25] optimitza la política $\pi_\theta(a | o)$ directament mitjançant la interacció amb l'entorn i la maximització del retorn esperat. En entorns de decisió amb restriccions de legalitat variables com Pokémon, l'algorisme MaskablePPO [2, 50] combina l'optimització d'actor-crític [51] amb un emmascarament binari d'accions legals $M(a) \in \{0, 1\}$.

Per evitar que la xarxa neural assigni probabilitat a accions il·legals (com moviments sense PP, Pokémon debilitats o canvis invàlids), la distribució de probabilitats s'obté mitjançant el **Softmax emmascarat**:

$$P_\theta(a | o) = \frac{M(a) \exp(z_a)}{\sum_{a' \in A} M(a') \exp(z_{a'})} \quad (2.30)$$

on z_a representa el *logit* brut de l'acció a emès per la xarxa neural d'actor.

L'objectiu de política retallat de PPO s'expressa com:

$$\mathcal{L}^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (2.31)$$

on $r_t(\theta) = \frac{\pi_\theta(a_t|o_t)}{\pi_{\theta_{\text{old}}}(a_t|o_t)}$ és la raó de probabilitats i $\hat{A}_t$ és l'estimador d'avantatge generalitzat (GAE) [52]. L'optimització conjunta de la xarxa d'actor i de la xarxa de valor minimitza la pèrdua total d'Actor-Crític:

$$\mathcal{L}^{\text{PPO}}(\theta, \phi) = \hat{\mathbb{E}}_t \left[\mathcal{L}_t^{\text{CLIP}}(\theta) - c_1 \left(V_\phi(o_t) - V_t^{\text{targ}} \right)^2 + c_2 \mathcal{S}[\pi_\theta](o_t) \right] \quad (2.32)$$

on V_ϕ és la funció de valor aproximada, $c_1, c_2 > 0$ són coeficients de ponderació i $\mathcal{S}[\pi_\theta]$ és la bonificació d'entropia per afavorir l'exploració.

A més de l'emascarament d'accions binari $M(a)$, l'entrenament DRL d'aquest treball incorpora dos mecanismes per estabilitzar la convergència: recompenses denses (*reward shaping*) basades en diferències de salut i debilitaments ($\Delta r_t = R_{\text{terminal}} + \gamma \Phi(s_t) - \Phi(s_{t-1})$), i inicialització guiada (*warm-start*) per clonatge conductual sobre l'heurística intermèdia **v8** (no **v12**).




Figura 2.10: Comportament de la funció d'objectiu retallada de PPO $\mathcal{L}^{\text{CLIP}}$ en funció de la raó de probabilitats $r_t(\theta)$ quan l'avantatge és positiu ($\hat{A}_t > 0$).

2.5 Síntesi del marc teòric

Aquest capítol ha fixat el domini, el POSG/POMDP, el marc d'inferència i els cinc paradigmes. El Capítol 3 n'aplica el disseny experimental; el Capítol 4, l'entorn d'execució.

Capítol 3

Metodologia i disseny experimental

Aquest capítol presenta el **disseny experimental** de l'estudi. El Capítol 2 ha fixat el domini —el format `gen9randombattle` (Secció 2.1.9), la formalització POSG/POMDP (Secció 2.2.2) i el marc d'inferència estadística (Secció 2.2.5)— i els algorismes dels cinc paradigmes (Secció 2.4). Aquí es decideix com s'apliquen: quin contracte d'entorn fa comparables totes les polítiques, quina arquitectura ha de suportar milions de batalles independents, quines variants es posen a prova i amb quin protocol mostral. El Capítol 4 documenta el maquinari, la xarxa i el monitoratge que executen aquest disseny; el Capítol 5 en recull la implementació.

3.1 Disseny general de l'estudi

Com s'ha argumentat a la Secció 2.1.9, l'estudi treballa en `gen9randombattle` per aïllar la tàctica de la construcció d'equips. Sense aquest desacoblament, una taxa de victòria es podria deure tant a una bona decisió com a un equip més fort, i els cinc paradigmes deixarien de ser comparables.

Sobre aquest marc, el disseny experimental fixa tres peces. La **unitat d'anàlisi** defineix què es mesura i amb quina incertesa. El **gestor conceptual d'enfrontaments** existeix perquè comparar 28 polítiques no és un únic combat, sinó una matriu de centenars de cel · les que ha de ser reproducible. El **contracte d'observació i acció** existeix perquè, com s'ha formalitzat a la Secció 2.2.2, tots els agents han de veure la mateixa o_i i actuar sobre el mateix A ; si cada paradigma parlés amb el simulador a la seva manera, les diferències de rendiment es barrejarien amb diferències d'informació.

3.1.1 Unitat d'anàlisi i telemetria

La unitat d'anàlisi és la batalla acabada. El resultat primari és binari —victòria o derrota—, coherent tant amb la naturalesa competitiva de suma zero del joc ($R_1 + R_2 = 0$, Seccions 2.2 i 2.2.2) com amb el marc de l'assaig de Bernoulli (Secció 2.2.5). Tanmateix, una sola taxa no explica *com* decideix cada política; per això, l'estudi vol distingir mecanismes subjacents (pressió ofensiva, conservació de l'equip o ús de cerca) i exigeix un registre exhaustiu de telemetria del procés. Tot i que el sistema recull un conjunt molt més ampli d'indicadors detallats, les principals dimensions analitzades inclouen la durada en torns, les salutats restants, els canvis voluntaris i forçats, l'ús de mecàniques de Generació IX (perills d'entrada, preparació i Teracristal · lització) i les intervencions de cerca o aprenentatge quan s'escau.

3.1.2 Concepte i responsabilitats del gestor de batalles

Comparar cinc paradigmes i sis controls exigeix el producte cartesià de parelles, no una selecció ad hoc d'oponents. Sense un gestor, cada família d'agents acabaria amb un protocol d'avaluació propi —un n diferent, un simulador diferent, un criteri de victòria diferent— i la matriu deixaria

de ser un experiment. Es defineix conceptualment un **gestor de batalles** amb sis responsabilitats, cadascuna motivada per un risc concret:

1. **Generació d'enfrontaments:** Construir el producte cartesià de parelles. Es vol que cada política es mesuri contra les altres, no només contra un baseline convenient.
2. **Instanciació homogènia:** Inicialitzar els dos participants amb la mateixa interfície. Es vol que la diferència observada sigui de política, no de manera de connectar-se al simulador.
3. **Orquestració de simuladors:** Assignar instàncies independents de Showdown, una per treballador. Es vol paral·lelitzar sense que dues partides comparteixin estat intern del motor.
4. **Aïllament de l'estat:** Executar el nombre objectiu de partides sense contaminar la memòria entre batalles. Es vol que la partida $k + 1$ no hereti objectes, historial ni fuites de la k .
5. **Persistència incremental:** Enregistrar resultat i telemetria en acabar cada partida. Es vol poder interrompre una execució de dies sense perdre el que ja s'ha validat.
6. **Tolerància a fallades:** Reprendre sense duplicar les batalles ja enregistrades. Es vol que un procés caigut no obligui a recomençar la cel·la.




Figura 3.1: Disseny metodològic i flux experimental de l'estudi: orquestració d'agents sobre el simulador comú, extracció de telemetria i validació estadística mitjançant Bootstrap BCa.

Aquest esquema (Figura 3.1) desacobla la coordinació de l'avaluació de la lògica interna dels agents. Una heurística de tres línies i una xarxa neuronal entrenada per reforç es poden enfrontar sota les mateixes condicions: mateix format, mateixa observació parcial i mateixa resolució estocàstica del torn. El motiu d'aquest desacoblament és metodològic: si el gestor coneixés com decideix cada agent, seria temptador adaptar el protocol a cada família, i la comparació deixaria de ser un experiment únic.

3.2 Contracte d'entorn i protocol de comunicació

A la Secció 2.1.9 s'ha situat Pokémon Showdown com a simulador autoritatiu i *poke-env* com a interfície Python; a la Taula 2.5 s'ha mapat la tupla POSG sobre aquests dos components. El que cal tancar aquí és el **contracte experimental** que se'n deriva, i *per què* s'adopta aquesta pila en lloc de reimplementar un motor propi o de parlar directament amb el protocol textual.

Es vol que tots els paradigmes competeixin sota la mateixa funció d'emissió O i el mateix espai d'accions A . Un motor propi seria més fàcil d'instrumentar, però divergiria de les regles oficials i invalidaria la comparació amb la literatura (Secció 2.3) i amb el *ladder* públic. Parlar amb el protocol cru, d'altra banda, obligaria cada agent a reimplementar el parser: un error de

descodificació en una família —per exemple, no veure un perill d’entrada— es confondria amb una diferència de política. Per això el disseny situa Showdown com a àrbitre únic i *poke-env* com a única traducció d’observació i d’ordre.

3.2.1 Showdown i *poke-env*: àrbitre, protocol i objecte de batalla

El contracte reutilitza l’àrbitre de la Figura 2.6d: Showdown [5] manté S , aplica T (Secció 2.1) i emet o_i (Taula 2.5). Els clients hi participen; no executen el combat. La comunicació és un protocol textual sobre WebSocket, amb línies prefixades amb `|`. Dues classes de missatge vertebran el torn:

- **Petició d’acció (`|request|`).** JSON privat per jugador: bàndol propi, accions legals i, del rival, només el que el protocol ja ha revelat. Aquest paquet és o_i : el filtre O el fa Showdown abans d’enviar el missatge (Figura 3.2).

```
{
  "active": [{
    "moves": [
      {"move": "Thunderbolt", "id": "thunderbolt", "pp": 15, "disabled": false},
      {"move": "Volt Switch", "id": "voltswitch", "pp": 32, "disabled": false}
    ],
    "canTerastallize": "Ice"
  }],
  "side": {
    "name": "p1",
    "pokemon": [
      {"ident": "p1: Gengar", "condition": "216/216", "active": true,
       "moves": ["thunderbolt", "voltswitch"]},
      {"ident": "p1: Great Tusk", "condition": "303/303", "active": false,
       "moves": ["headlongrush", "closecombat"]}
    ]
  },
  "rqid": 12
}
```

Figura 3.2: Exemple d’estructura del missatge JSON de petició d’acció (`|request|`) enviat per Pokémon Showdown a cada jugador.

- **Registre de resolució.** Un cop *tots dos* jugadors han enviat una ordre, el motor desbloqueja el torn —accions simultànies, no per torns com als escacs— i emet el log (`|move|`, `|switch|`, `|-damage|`, `|-crit|`, `|win|`, ...). Fins que no arriben les dues ordres, l’estat no avança. Aquest *lock* simultani és la raó per la qual Minimax es formula com a matriu d’un pas (Secció 2.4.2) i no com a arbre d’alternança.

L’agent mai no llegeix S : si un paradigma «mirés» l’equip ocult, deixaria de ser un POSG. Les instàncies són *headless* i locals —no el *ladder* públic— perquè la matriu pugui córrer sense cua; el protocol és el mateix.

poke-env [6] és la capa que tradueix aquest protocol a Python. Internament fa tres feines que l’estudi no vol duplicar a cada agent:

1. **Manté la connexió asíncrona** amb una instància de Showdown i identifica la sala de la batalla.
2. **Parseja les línies del protocol** i actualitza un objecte `Battle`: Pokémon actius, banqueta, camp, moviments revelats, accions legals (`available_moves`, `available_switches`) i flags com el canvi forçat. Aquest objecte és Ω ja estructurat, no el JSON cru.
3. **Crida la política** `choose_move(battle)` i serialitza el resultat —un `BattleOrder`— a una ordre que el servidor accepta (`/choose move 1`, `/choose switch 3`, Teracristal · lització com a modificador). Si l’ordre és il·legal, la batalla es bloqueja: per això el contracte exigeix actuar només sobre el conjunt legal que *poke-env* exposa.

La Figura 3.3 resumeix aquestes tres capes. El que canvia entre paradigmes és només el bloc central —com es calcula l’acció a partir de **Battle**—. Heurístiques i minimax operen directament sobre l’objecte; l’imitació el projecta a una fila tabular; MaskablePPO el projecta a un vector i a una màscara. El Showdown que resol el torn és sempre el mateix.




Figura 3.3: Tres capes del contracte. Showdown és l’àrbitre omniscient; *poke-env* tradueix el protocol a un objecte i a una ordre legal; la política és l’únic bloc específic de cada paradigma. La fletxa discontinua tanca el torn al motor.

3.2.2 Cicle d’un torn de batalla

El cicle de la Figura 3.4 és el bucle que el gestor ha de poder repetir milions de vegades. Cada pas té una funció concreta en el POSG; ometre’n el context faria semblar el protocol una seqüència arbitrària de missatges.

1. **Connexió a una instància local.** El client obre un WebSocket contra un Showdown *headless*. Es fa en local perquè la matriu no depengui de la cua ni de les normes del servidor públic, i perquè cada treballador pugui tenir el seu port (Secció 3.3).
2. **Repte `gen9randombattle`.** El simulador genera els dos equips i obre la sala. En aquest moment S ja és complet, però cap agent el veu: només rebrà o_i . És el punt on s’aïlla la tàctica del *teambuilding* (Secció 2.1.9).
3. **Petició amb observació i legalitat.** Showdown envia `|request|` a cada bàndol. Aquest missatge fixa alhora Ω (què es veu) i A (què es pot triar). Un canvi forçat, per exemple, buida la llista de moviments: l’agent no ha de «inventar» accions, ha de triar dins d’aquest conjunt.
4. **Actualització de l’objecte **Battle**.** *poke-env* incorpora el JSON i el log previ a l’objecte estructurat. Sense aquest pas, cada política hauria de reimplementar el parser i el risc d’observacions inconsistents seria alt.
5. **Decisió de la política.** L’agent executa la seva regla, matriu, arbre, classificador o xarxa sobre **Battle**. És l’únic pas que difereix entre famílies. El temps d’aquest pas condiciona l’arquitectura paral·lela: una heurística acaba en mil·lisegons; un MCTS ras, en segons.

6. **Enviament de l'ordre.** *poke-env* tradueix el `BattleOrder` a `/choose`. Showdown no avança fins que l'oponent ha fet el mateix: l'agent no observa l'acció rival *abans* de decidir, tal com exigeix el joc de matriu simultània.
7. **Resolució estocàstica del torn.** El motor aplica T —prioritat, velocitat, dany, crítics i efectes, Secció 2.1— i emet el registre. Aquest log actualitza les creences (moviments revelats, HP, camp) de cara al torn següent.
8. **Tancament.** El cicle es repeteix fins a `|win|`. La batalla acabada és la unitat d'anàlisi de la Secció 3.1.




Figura 3.4: Intercanvi d'un torn. Showdown filtra l'estat i no resol fins a tenir les dues ordres; *poke-env* estructura l'observació i legalitza l'acció. L'agent no accedeix mai a S .

Aquest flux —i no una API pròpia de cada paradigma— és el que fa comparable una heurística amb un classificador o amb MaskablePPO. El Capítol 5 detalla versions, ports i la classe base que implementa `choose_move`; el que importa aquí és el motiu: un sol àrbitre, una sola traducció, polítiques intercanviables.

3.3 Arquitectura conceptual d'avaluació massiva

Les sis responsabilitats del gestor (Secció 3.1) s'han de poder executar a l'escala de la matriu d'enfrontaments: centenars de creuaments de polítiques (o cel · les) i milions de batalles independents. Aquesta magnitud no és un gust d'enginyeria: deriva del protocol estadístic del Capítol 2. Cada batalla és un assaig independent (Secció 2.2.5) i el marge d'error objectiu exigeix un nombre n de l'ordre de milers per cel · la (Secció 3.6). Un experiment d'aquest volum, executat de manera seqüencial en un sol procés, no cabria en el calendari del treball ni seria numèricament estable. El que cal dissenyar, doncs, no és «com llançar partides», sinó una arquitectura que faci viable, aïllada i reprenable aquesta matriu.

3.3.1 Per què una arquitectura paral·lela i aïllada

Per assolir els tres requisits fixats anteriorment —viabilitat en calendari, aïllament d’execució i estabilitat numèrica— cal abandonar definitivament la idea d’un únic procés seqüencial. L’elecció d’un disseny paral·lel basat en treballadors aïllats i efímers és la resposta directa a quatre colls d’ampolla tècnics derivats del cicle de comunicació de la Secció 3.2.1 i de l’avaluació d’agents heterogenis:

- **Volum i heterogeneïtat temporal.** Una heurística decideix en mil·lisegons; l’MCTS ras, per la formulació de la Secció 2.4.3, executa desenes de simulacions locals a cada torn i és ordres de magnitud més lent. Si totes les partides compartissin una cua seqüencial, les cel·les ràpides quedarien bloquejades darrere de les lentes, i el calendari el dictaria el pitjor cas. Es vol paral·lelitzar per ocupar el maquinari i, alhora, *no* exigir el mateix n a totes les famílies (Secció 3.6).
- **Estat i memòria.** Showdown (motor JavaScript V8 de Node.js) i *poke-env* (objectes *Battle*, historials, estructures de cerca) acumulen memòria a mesura que es succeeixen les partides. En un intèrpret únic, una fuga o un objecte retingut contamina les milers de batalles següents i acaba esgotant la RAM. Es vol que cada lot visqui en un procés que, en acabar, el sistema operatiu pugui recollir del tot.
- **Fallades independents.** Una cerca que es bloqueja, una ordre il·legal o un servidor Node.js que creix sense límit no ha de fer caure la matriu sencera. Es vol aïllament: el coordinador sobreviu; el treballador és descartable.
- **Independència estadística.** El protocol de la Secció 2.2.5 tracta cada batalla com un assaig de Bernoulli. Si dues partides compartissin RNG, sala o estat intern del motor, aquesta hipòtesi es trencaria. Un Showdown dedicat per treballador redueix aquest risc.

Una alternativa —un *pool* persistent de jugadors en un sol procés, o un únic Showdown multiplexat— seria més simple d’arrencar. Es descarta perquè no separa memòria, no recupera un treballador mort i no permet reprendre una execució de dies sense duplicar feina. El disseny que s’adopta, doncs, és coordinador/treballadors efímers amb simulador dedicat, persistència com a font de veritat i reinici periòdic del motor.

3.3.2 Model coordinador i treballadors efímers

Per donar resposta als quatre requisits d’aïllament, volum i estabilitat justificats a la Secció 3.3.1, l’estudi adopta un patró d’arquitectura **Coordinador–Treballador** (*Master–Worker*) amb cicle de vida efímer. La clau d’aquest disseny rau en el desacoblament estricte entre la gestió global de l’experiment i l’execució física dels combats.

En lloc de mantenir simuladors o agents persistents que acumulin memòria o puguin bloquejar l’execució, l’arquitectura conceptual distingeix dos rols clarament diferenciats (Figura 3.5), evitant barrejar la planificació («què queda pendent de jugar») amb la simulació («executar un lot de partides»):

- **Coordinador:** No juga cap partida. Calcula els enfrontaments pendents, assigna lots a processos independents, en supervisa el progrés i en fusiona els resultats. Així, un error de combat no destrueix el mapa de la matriu.
- **Treballadors efímers:** Cada treballador és un procés independent amb un servidor Showdown dedicat —el mateix contracte de la Secció 3.2, però una instància per lot—. Executa el seu lot, escriu els resultats en un magatzem temporal i desapareix. No hi ha memòria compartida: quan el procés acaba, el sistema operatiu en recupera els recursos.

Aquest aïllament és especialment rellevant per a Minimax i MCTS, que construeixen estructures de cerca per torn, i per a les heurístiques avançades, que mantenen historial per batalla. El Capítol 5 concreta ports, mida de lot i temps d’espera; aquí el que importa és la forma: paral·lelisme per volum, aïllament per memòria i fallades, simulador dedicat per independència.




Figura 3.5: Arquitectura conceptual d’avaluació massiva. El coordinador gestiona la matriu i supervisa la consolidació; cada treballador opera en un procés aïllat amb un Showdown dedicat i escriu el seu lot temporal (.csv) abans de reciclar-se.

3.3.3 Represa, persistència i reinici del simulador

Una execució de milions de batalles dura dies. Si l’estat de progrés visqués només en memòria, una interrupció —reinici de màquina, procés mort, Showdown saturat— obligaria a recomençar la cel·la i trencaria la independència dels assaigs ja jugats. Per això el magatzem de resultats de cada enfrontament és la **font d’estat de progrés**: si ja conté k files, el coordinador calcula $n_{\text{pendent}} = n_{\text{objectiu}} - k$ i només executa la resta. Es persisteix per poder aturar i reprendre sense duplicar feina.

El reinici periòdic del simulador i els blocs curts de batalles responen al mateix diagnòstic de memòria: el motor Node.js/V8 i els objectes **Battle** creixen amb el temps. En lloc de confiar que un procés llarg es mantingui estable, el disseny el recicla. El Capítol 5 documenta la cadència observada; aquí es fixa el principi.

3.4 Disseny conceptual de les famílies d’agents

Una vegada fixat el contracte d’entorn (Secció 3.2) i establerta l’arquitectura paral·lela per orquestrar i executar les batalles de manera massiva, aïllada i reproduïble (Secció 3.3), el disseny experimental requereix formalitzar les polítiques de decisió que s’enfrontaran a la matriu. La Secció 2.4 ha establert els fonaments dels cinc paradigmes d’IA —heurística, minimax d’un torn, MCTS ras, aprenentatge per imitació i MaskablePPO— i n’ha definit la font de coneixement i el còmput per torn. El motiu de mesurar-los sota un mateix protocol experimental és resoldre el buit identificat a la Secció 2.3: a la literatura existent, cada tècnica s’avalua en entorns, simuladors o condicions heterogènies que n’impedeixen la comparació directa. Aquí s’aplica exactament el mateix marc d’avaluació a tots els agents i, dins de cada família, un disseny d’ablació que permeti aïllar els mecanismes responsables de cada variació en el rendiment.

Així doncs, per a cada paradigma es concreta una pregunta de recerca específica i una genealogia de variants. A més, a la matriu d’enfrontaments s’hi integren sis agents de referència; tot i que no formen part de l’ablació interna, aquests baselines resulten indispensables com a àncores per validar si les polítiques desenvolupades superen els estàndards públics i la literatura existent.

3.4.1 Agents de referència

Abans de formalitzar les cinc famílies d'agents i les seves respectives ablacions, és necessari definir el grup de **polítics de referència** (*baselines*). Aquests agents no formen part del disseny d'ablació interna, però s'integren al producte cartesià de la matriu per avaluar el rendiment en termes absoluts. Sense aquestes àncores externes, només es compararien variants pròpies entre si i no es podria determinar si les polítiques desenvolupades superen els estàndards existents a la comunitat i a la literatura.

Per garantir una comparació rigorosa, els sis agents de referència s'han seleccionat explicitant la procedència i funció de cadascun:

- **random:** Prové del mòdul de control aleatori inclòs per defecte a la llibreria *poke-env* [6] (**RandomPlayer**). Selecciona accions de manera uniforme entre totes les opcions legals de l'estat, actuant com a control inferior absolut i origen de l'escala Elo (Secció 2.2.5).
- **max_power:** Prové del *baseline* ingenu integrat a *poke-env* (**MaxBasePowerPlayer**). Tria sempre l'atac de major potència base sense considerar tipus, efectivitat ni canvis, servint com a control d'ofensiva cega.
- **simple_heuristic:** Prové de l'heurística de referència proporcionada per la llibreria *poke-env* (**SimpleHeuristicsPlayer**), adaptada en aquest treball per suportar la mecànica de Teracristal · lització de Generació IX. Representa el *baseline* heurístic estàndard de la comunitat.
- **abyssal:** Prové del repositori oficial del projecte *PokéChamp* [38] (Secció 2.3), on constitueix el controlador basat en regles expertes (**AbyssalPlayer**). S'utilitza com a oponent discriminant de referència de la literatura científica existent.
- **one_step / safe_one_step:** Prové de la política de cerca determinista d'un pas (*lookahead* d'un torn) desenvolupada a partir del mòdul de cerca de *PokéChamp* (**SafeOneStepPlayer**). Avalua l'impacte immediat d'un torn sense requerir un simulador local complet. Les dues etiquetes al registre responen a la traçabilitat històrica de l'execució, però corresponen a la mateixa lògica de decisió.

3.4.2 Família Heurística: genealogia, hipòtesis d'ablació i la pregunta del valor marginal

La família d'agents heurístics constitueix el nucli de coneixement de domini expert de l'estudi. A través d'una seqüència d'ablació incremental de catorze variants (v1–v14), es formalitza la incorporació progressiva de regles d'estimació de dany, canvis posicionals, gestió de perills, Teracristal · lització i inferència sobre l'adversari. Aquesta genealogia permet avaluar el valor marginal de cada mecànica i serveix d'avaluador terminal per a les famílies de cerca posteriors.

Pregunta de recerca

Quina mecànica de domini —estimació de dany, canvi tàctic, perills d'entrada, Teracristallització o model de l'adversari— aporta el major increment marginal de taxa de victòria, i existeix un punt on afegir més regles perjudica el rendiment?

Decisions de disseny

Una sola heurística «completa» respondria qui guanya, no què aporta cada bloc de coneixement. La Secció 2.4.1 formalitza l'heurística com a suma ponderada i l'ablació incremental $H^{(m)}(s, a) = \sum_{f_k \in \mathcal{F}^{(m)}} w_k \cdot f_k(s, a)$ (Equació 2.22). El disseny concreta $M = 14$ punts d'aquesta ablació *perquè* es vol mesurar el valor marginal de cada mecànica —i detectar si n'hi ha que perjudiquen—

abans d'usar v14 com a fulla de cerca. No són catorze provatures aïllades: cada versió afegeix un bloc concret, amb ramificacions quan dues hipòtesis són ortogonals (Figura 3.6).

La seqüència no és una cadena estricta. Les versions primerenques exploren estimadors de dany i pivots simples; v7 reescriu el nucli d'avaluació de l'enfrontament —es fa així perquè una cascada de condicionals no és reutilitzable com a fulla—; v9 i v10 afegeixen tempo i tàctica com a blocs separats que v11 fusiona abans d'introduir les mecàniques de Generació IX. Es ramifica abans de fusionar per no atribuir a «més regles» un efecte que en realitat ve d'un sol dels dos blocs.




Figura 3.6: Genealogia de disseny dels agents (v1–v22). Les rutes de desenvolupament i ramificació entre variants s'agrupen per color segons el bloc de funcionalitat descrit a la llegenda.

Descripció concreta de cada versió

La Taula 3.1 recull la idea de cada versió. Les ramificacions v4/v5 i v9/v10 no són «més del mateix»: aïllen hipòtesis diferents sobre quin coneixement importa.

Tres decisions estructurals vertebrèn la resta de l'estudi, i es prenen *abans* de dissenyar cerca i aprenentatge perquè aquestes famílies reutilitzin el mateix nucli:

- **Ramificacions v4/v5 i v9/v10:** aïllen camp i modificadors, d'una banda, i tempo i tàctica, de l'altra, abans de fusionar-los. Es vol poder atribuir un canvi de taxa a un bloc, no a un paquet indivisible.
- **Punt d'inflexió v7:** el nucli passa d'una cascada de condicionals a una suma ponderada de l'enfrontament. Es fa així perquè Minimax i MCTS necessiten una fulla numèrica, no una llista de `if`.
- **v14 com a servei:** l'heurística més completa es dissenya com a *fulla* de Minimax i MCTS, *prior* de PUCT i *executor tàctic* de la imitació híbrida. No és el sostre empíric de la família: el rendiment de cada versió es mesura al Capítol 6. v12 serà el comparador de PPO i el líder observat de la lliga. Sense aquest paper de servei, cada paradigma reimplementaria el coneixement de domini i les diferències deixarien de ser aïllables.

En resum, l'ablació v1–v14 aïlla el valor marginal de cada bloc de regles. v14 és l'heurística terminal de *servei*; v12 n'és el referent de rendiment. La cerca i l'aprenentatge reutilitzen v14 com a fulla, prior o executor.

3.4.3 Família Minimax: tres variants de resolució de la matriu d'un torn

La família Minimax aporta la consideració explícita de la millor resposta adversària. Com que les accions són simultànies, una política *greedy* pot assumir que el rival es queda passiu. El disseny instancia el maximin d'un pas de la Secció 2.4.2 (Equació 2.23): la Figura 3.7 en mostra la matriu operativa.

Taula 3.1: Disseny conceptual de les catorze versions heurístiques. Cada versió aïlla un bloc de coneixement de domini.

Versió	Idea de disseny i mecànica incorporada
v1	Baseline greedy. Selecciona el moviment amb major potència efectiva: potència base $\times$ efectivitat de tipus $\times$ STAB (Secció 2.1.3). No canvia mai.
v2	Dany amb estadístiques i pivot defensiu. Substitueix el proxy de potència per una estimació amb atac/defensa (i penalització de cremada) i introdueix dos canvis: escapar d'un enverinament greu acumulat, i pivotar quan el millor atac és feble i l'actiu és més lent.
v3	Mateixa política, telemetria de moviments. Conserva el dany i els pivots de v2 i registra els moviments usats per batalla, necessari per a l'anàlisi posterior.
v4	Camp i objectiu de canvi. Incorpora clima i terreny a l'estimació, pondera per precisió i prioritat, i deixa d'escollir sempre el primer substitut: tria el company amb millor avantatge de tipus.
v5	Modificadors d'etapa. Extén v4 amb el dany conscient dels boosts d'atac i defensa acumulats durant la partida.
v6	Consolidació lleugera sobre v3. Reintrodueix clima, terreny i una bonificació de prioritat sobre el nucli estable de v3, conservant el pivot al primer substitut. Hipòtesi: el camp ajuda sense necessitar encara el canvi intel·ligent de v4.
v7	Punt d'inflexió: reescriptura del nucli. Nova puntuació de l'enfrontament conscient dels boosts, amb canvis voluntaris basats en la qualitat de l'aparellament. No col·loca perills ni fa preparació: l'atac és l'acció per defecte.
v8	Debilitament amb prioritat i immunitats conegudes. Sobre v7, executa un atac de prioritat quan el debilitament és conservadorament garantit, i descarta moviments als quals el rival és immune <i>només</i> si l'habilitat ja s'ha revelat.
v9	Tempo en torns lliures. Col·loca perills d'entrada i fa moviments de preparació <i>només</i> quan l'actiu és més ràpid i resisteix l'STAB rival. Hipòtesi: el tempo <i>només</i> paga si no es malgasta el torn.
v10	Tàctica sobre el nucli v8. Condicions d'estat ofensives, sacrifici amb pocs HP (no canviar per no malgastat el torn) i pivots amb <i>U-turn/Volt Switch</i> . Bloc ortogonal a v9.
v11	Fusió tempo + tàctica. Combina les regles de v9 i v10 en una sola política, amb adaptacions menors segons la generació del format.
v12	Mecàniques de Generació IX. Integra la Teracristal·lització ofensiva i defensiva d'ús únic (Secció 2.1.4) i substitueix l'elecció del capdavanter i del substitut forçat per una selecció basada en l'enfrontament.
v13	Inferència amb moviments revelats. Avalua l'enfrontament amb els atacs ja vistos (no <i>només</i> amb els tipus), afegeix recuperació, explotació de bloqueig <i>Choice</i> , expulsió de rivals amb modificadors i una política de Tera més conservadora.
v14	Model de l'adversari i resolució de finals. Classifica el rival com a <i>predictiu</i> o <i>conservador</i> segons la taxa de canvis, fa sondeig als torns inicials, aproxima el dany amb un interval i aplica una resolució exhaustiva d'un torn quan queden ≤ 2 Pokémon per bàndol.

Pregunta de recerca

Considerar explícitament la millor resposta de l'adversari en un joc de matriu d'un pas millora el rendiment respecte de l'heurística greedy, i enriquir la fulla o esbiaixar-la amb un prior de **v14** aporta més que el maximin nu?

Decisions de disseny i funcionament

Cada cel·la M_{ij} s'avalua amb el nucli **v14**; es tria $\max_i \min_j M_{ij}$ (Figura 3.7).




Figura 3.7: Esquema del mètode Maximin d'un torn. Es construeix la matriu de recompenses M avaluant la resposta de l'adversari amb el nucli **v14** i es tria l'acció amb el millor resultat en el pitjor cas ($\max_i \min_j M_{ij}$).

S'implementen tres variants per aïllar l'impacte de la funció de valor i del prior heurístic:

- **v15 — Maximin amb fulla d'HP:** Combina el balanç de punts de vida (HP) amb la qualitat de l'enfrontament, aplicant una penalització conservadora de $\times 1,5$ al dany rebut del rival. Avalua si l'anticipació de la millor resposta adversària ja supera la decisió *greedy* fent servir només informació bàsica de dany i salut.
- **v16 — Maximin amb fulla enriquida:** Afegeix a l'avaluació de la cel·la bonificacions posicionals per perills d'entrada (*hazards*), moviments de preparació (*setup*), recuperació i estats alterats. Permet mesurar l'efecte de la informació posicional a les cel·les sense alterar el criteri de cerca.
- **v17 — Maximin amb prior heurístic:** Suma una bonificació fixa (+0,15) al pitjor cas de l'acció recomanada per **v14**, afavorint el coneixement expert quan la cerca atorga valors similars. Això redueix desviacions innecessàries i mesura si el prior d'expertesa pot guiar millor la matriu.

Abans de construir la matriu, tots els agents apliquen dreceres tàctiques (com debilitar el rival si el KO és garantit). A més, es mesura la **mètrica de discrepància** per quantificar quantes vegades la matriu Minimax canvia la decisió respecte a l'heurística pura **v14**.

3.4.4 Família MCTS: variants de simulació i mètrica de discrepància

Mentre que Minimax només avalua un torn en el futur amb una fulla estàtica, la cerca en arbre de Monte Carlo (MCTS) explora trajectòries de diversos torns cap a endavant mitjançant simulació estocàstica. Aquest enfocament permet preveure les conseqüències futures de les decisions immediates.

Pregunta de recerca

La simulació estocàstica cap a endavant permet corregir els biaixos de la política heurística, i amb quina freqüència la cerca acaba triant una acció diferent de la recomanació heurística?

Decisions de disseny i funcionament

Com s'il·lustra a la Figura 3.8, la cerca s'adopta en un esquema de profunditat d'arbre $d = 1$ a l'arrel (limitant la ramificació als fills immediats per contenir la complexitat en jocs de decisions simultànies i mantenir temps de resposta en temps real de Showdown < 1 segon). Per a cada decisió, s'obren branques per a totes les accions legals immediates i s'executa un pressupost fix de 100 iteracions de simulació:

1. **Selecció:** Es tria l'acció fill a explorar aplicant un criteri d'exploració/exploitació: UCB1 ($C = 1,4$, constant teòrica estàndard $C \approx \sqrt{2}$) o PUCT amb prior de probabilitat de v_{14} .
2. **Simulació (Rollout):** Es reproduïx la partida durant 5 torns cap a endavant utilitzant un simulador local en memòria (**LocalSim**) basat només en la informació revelada. Una profunditat de 5 torns permet capturar efectes tàctics d'horitzó mitjà (acumulació de dany per perills d'entrada, modificadors o estats) sense introduir una divergència excessiva en la simulació estocàstica.
3. **Avaluació i Retropropagació:** L'estat final de la simulació s'avalua amb el nucli heurístic v_{14} i el resultat s'acumula a l'acció arrel. Al final de les 100 iteracions, es selecciona l'acció més visitada ($\arg \max_a N_a$).




Figura 3.8: Arquitectura del cicle de cerca MCTS de quatre fases a l'arrel ($d = 1$). (1) Selecció de l'acció fill a^* (UCB1/PUCT); (2) Simulació local de 5 torns amb **LocalSim**; (3) Avaluació de la fulla s_5 amb el nucli v_{14} ; i (4) Retropropagació de la recompensa v i actualització d'estadístiques (Q, N) durant 100 iteracions.

Es defineixen tres variants principals per aïllar la selecció de la funció d'avaluació:

- **v_{18} — UCB1 sense prior:** Selecció pura per UCB1 ($C = 1,4$) i avaluació de fulla basada en HP, modificadors, estats i perills. Avalua si la simulació estocàstica cap a endavant per si sola, sense guiatge expert, pot corregir els biaixos heurístics. Actua com a línia de base agnòstica amb cerca uniforme.
- **v_{19} — UCB1 amb fulla enriquida:** Manté la selecció UCB1, però incorpora a la fulla la ponderació per rols (Win-Con i Vital Wall), l'amenaça de KO i les dreceres tàctiques de v_{14} . Mesura el guany de qualitat en el *rollout* quan l'estat final es valora amb coneixement de domini avançat.
- **v_{20} — PUCT amb prior heurístic:** Substitueix UCB1 per PUCT amb massa a priori $P(a_{v_{14}}) = 0,70$ a l'acció de v_{14} i $P(a_{\text{alt}}) = 0,30/(K - 1)$ a la resta. Amb un pressupost de 100 visites per decisió (temps real de Showdown), UCB1 uniforme explora massa poc cada fill; el prior concentra simulacions a validar l'heurística i deixa un 30% per alternatives. La taxa de discrepància i el rendiment es reporten al Capítol 6.

Com en la família Minimax, les simulacions s'executen en un simulador local en memòria alimentat només amb la informació revelada (respectant la naturalesa POSG del joc) i es mesura la **mètrica de discrepància** respecte a v_{14} .

3.4.5 Família d'Imitació Jeràrquica: desacoblament macro/micro i dues arquitectures

La família d'aprenentatge per imitació aborda la transferència de coneixement tàcit des de corpus de partides humanes d'alt nivell ($Elo \geq 1800$). En lloc de dissenyar regles o taules de cerca manuals, aquest enfocament entrena models d'aprenentatge automàtic supervisat per reproduir el criteri de decisió dels millors jugadors humans.

Pregunta de recerca

Pot un model entrenat amb dades d'experts humans igualar o superar l'heurística manual, i quin nivell de delegació a l'executor heurístic necessita per generalitzar a estats no vistos?

El problema de la representació i la solució jeràrquica

Com s'ha argumentat a la Secció 2.4.4, en els combats Pokémon l'espai d'accions presenta una inestabilitat semàntica inherent: l'índex d'un moviment (p. ex., el moviment 1) o la posició d'un substitut a la banqueta no tenen un significat constant entre Pokémon diferents. Intentar imitar directament les identitats concretes dels slots d'acció conduiria a un vocabulari inestable i a una explosió combinatòria d'estats.

Per resoldre aquesta limitació, es dissenya una **arquitectura jeràrquica** que desacobla la decisió en dos nivells:

- **Nivell Macro (Estratègic):** Un classificador supervisat decideix l'orientació general de l'acció en l'estat actual: si la millor opció és mantenir-se al camp i **atacar** o fer un pas enrere i **canviar** de Pokémon ($y \in \{0 : \text{atacar}, 1 : \text{canviar}\}$).
- **Nivell Micro (Tàctic):** Un executor tria la decisió concreta: si la macro-decisió és atacar, quin dels quatre moviments legals executar; si és canviar, a quin dels Pokémon de la banqueta passar el relleu.

Origen de les dades i disseny del classificador XGBoost

Per entrenar el model macro s'utilitza el conjunt públic de repeticions de Pokémon Showdown (*Showdown Replays Database*) [53], filtrat per a la modalitat de batalles aleatòries de Generació IX (*Gen 9 Random Battle*) i contingut exclusivament en partides de l'escala competitiva d'alt nivell ($Elo \geq 1800$).

Aquest conjunt de dades enregistra la seqüència completa per torns de les batalles humanes: la salut percentual dels Pokémon actius i de la banqueta, els modificadors d'etapa estadística, les condicions d'estat alterat, els perills d'entrada col·locats al camp (*Stealth Rock*, *Spikes*), els moviments i habilitats ja revelats, i l'acció finalment triada pel jugador humà. La utilitat d'aquest dataset rau en la seva capacitat per capturar la intuïció estratègica i el coneixement tàcit d'experts humans (com el moment oportú per efectuar un canvi conservador o un pivot tàctic) sense necessitat de programar regles manuals.

El procés de construcció i entrenament del classificador XGBoost es sintetitza en tres aspectes de disseny:

1. **Construcció del vector de característiques:** Es processen aproximadament 1,12 milions de torns per generar una matriu tabular d'unes 1.150 columnes (incloent la codificació *one-hot* d'espècies i formes regionals). La variable objectiu es redueix a la decisió macro binària $y \in \{0 : \text{atacar}, 1 : \text{canviar}\}$.
2. **Partició agrupada per batalla:** Per evitar la filtració d'informació entre torns consecutius d'un mateix combat, es realitza un desglossament train/test agrupat per identificador de combat (*GroupShuffleSplit* per `battle_id`).

3. **Tractament del desequilibri i calibratge de llindar:** Atès que l'acció d'atacar és molt més freqüent que la de canviar, s'aplica una ponderació de classe (`scale_pos_weight`) i es calibra un llindar de decisió τ sobre la corba precisió-record en validació. Durant la inferència, l'agent executa un canvi si $p(\text{canvi}) \geq \tau$, i un atac en cas contrari.

Dues arquitectures d'execució micro: Híbrida vs Pura Dual

Per avaluar el grau de delegació necessari a l'executor heurístic i mesurar la capacitat de generalització dels models d'imitació fora de la distribució d'entrenament, es dissenyen dues arquitectures d'execució micro contrastades:

- **v21 (Arquitectura Híbrida):** Combina la intuïció estratègica humana obtinguda de les repeticions d'alt nivell amb la seguretat del nucli heurístic. Funciona en tres etapes seqüencials:
 1. *Dreceres tàctiques d'emergència:* Abans de consultar el model après, avalua si es disparen les regles crítiques de v14 (KO garantit immediat, resolució exhaustiva de finals amb ≤ 2 Pokémon, reacció a preparació rival i absorció d'estats). Si es compleixen, s'executa l'acció immediatament sense passar pel model.
 2. *Decisió macro per XGBoost:* Si no hi ha drecera tàctica, construeix el vector d'estat $s \in \mathbb{R}^{1150}$ i utilitza el classificador XGBoost per decidir la intenció d'alt nivell ($p(\text{canvi}) \geq \tau \implies \text{canviar}$, en cas contrari atacar).
 3. *Execució micro heurística:* Seleccionada la intenció macro, la decisió concreta de quin moviment executar o quin substitut introduir es delega al nucli v14, aprofitant el seu càlcul de dany i l'anàlisi d'avantatge de tipus.
- **v22 (Arquitectura Pura Dual):** Prescindeix completament de qualsevol regla manual o drecera de v14 per mesurar la capacitat de l'aprenentatge per imitació pur d'operar de forma autònoma (*end-to-end*):
 1. *Decisió macro directa:* Avalua tots els torns sense filtres d'emergència mitjançant el classificador XGBoost per determinar la intenció d'atacar o canviar.
 2. *Execució micro de canvi contrafactual:* Quan la decisió és canviar, avalua hipotèticament el canvi a cada Pokémon disponible de la banqueta $c \in \mathcal{C}$ generant l'estat resultat s'_c . Passa s'_c pel classificador XGBoost i selecciona el substitut que minimitza la probabilitat de necessitar un altre canvi immediat al torn següent ($\arg \min_c p_{\text{XGB}}(\text{canvi} \mid s'_c)$).
 3. *Execució micro d'atac per model d'atributs:* Si la decisió és atacar, avalua els atacs legals amb un segon model après entrenat sobre atributs sintetitzats (potència base, bonus STAB, efectivitat de tipus, prioritat del moviment i salut restant).

Mentre que v21 manté la protecció de les regles de domini davant d'estats fora de la distribució d'entrenament, v22 avalua el límit de l'aprenentatge supervisat pur. La seva estructura en dos nivells i els seus fluxos d'execució es sintetitzen a la Figura 3.9.

3.4.6 Família DRL (MaskablePPO): currículum de dificultat creixent

La família d'aprenentatge per reforç profund representa l'enfocament autònomitzat sense regles prèvies ni demostracions humanes directes. Basada en l'algorisme MaskablePPO, aquesta línia d'experimentació avalua la capacitat d'una xarxa neural per descobrir estratègies competitives des de zero mitjançant la interacció contínua amb el simulador.




Figura 3.9: Arquitectura d'imitació jeràrquica. El classificador macro XGBoost prediu la intenció (atacar/canviar); v21 combina filtres i execució amb v14, mentre que v22 resol el nivell micro amb models apresos (contrafactual i atributs).

Pregunta de recerca

Pot una xarxa neural entrenada per reforç aprendre tàctiques de combat competitives, i quin paper juga un currículum progressiu —amb clonatge conductual intermig— en l'estabilització de l'aprenentatge?

Decisions de disseny

L'aprenentatge per reforç és l'únic paradigma que no parteix de regles ni de repeticions etiquetades: ha d'aprendre A i T interactuant. La Secció 2.4.5 ha situat MaskablePPO i l'emascarament (Equació 2.30) com a resposta a un espai d'accions variable —sense màscara, l'agent malgasta gradient en ordres que Showdown rebutja i la batalla es bloqueja.

L'aprenentatge frontal contra l'heurística més forta pateix recompensa escassa: gairebé totes les partides es perden abans d'aprendre legalitat. Per això no s'adopta autojoc ni un únic oponent difícil, sinó un **currículum progressiu** [54] amb portes de validació congelades, independents de la corba d'entrenament (Taula 3.2 i Figura 3.10). Si una porta intermèdia no es supera, el currículum *continua* cap a v12: es vol mesurar la distància real, no aturar l'experiment per no haver «aprobat» una fase.

Taula 3.2: Disseny del currículum PPO. Els llindars són criteris previstos per avançar; el compliment es presenta al Capítol 5 i als resultats.

Fase	Oponent	Objectiu conceptual	Validació	Llindar
1	Random	Aprendre legalitat, finalització de batalles i avantatge sobre una política aleatòria.	1.000 partides	$\geq 90\%$
1.5	MaxBP	Superar una política ofensiva simple basada en potència.	1.000 partides	$> 70\%$
2	v8	Incorporar decisions posicionals amb clonatge inicial i reforç posterior.	1.000 partides	$> 55\%$
3	v12	Mesurar la distància respecte de l'heurística de referència més forta.	10.000 partides	50% com a paritat

Quatre mecanismes completen el disseny, cadascun per una fallada típica de l'RL en aquest domini:

- **Emmascarament:** el softmax emmascarat de la Secció 2.4.5. L'espai es congela en 14 slots (4 moviments, 4 amb Tera, 6 canvis), dels quals la màscara n'activa només els legals —la mateixa A de la Taula 2.5, discretitzada. Es vol que l'agent no aprengui a «provar» ordres que el protocol rebutja.




Figura 3.10: Currículum PPO previst. Cada fletxa és una porta de validació independent de la corba d'entrenament. El clonatge s'insereix abans de la fase 2; la fase 3 mesura distància contra v12 encara que una porta anterior falli.

- **Observació vectorial congelada:** l'estat es projecta a un vector en $[0, 1]$ (HP, tipus, estats, moviments, banc, camp, Tera i restriccions). Es congela abans de la fase competitiva per no invalidar els checkpoints: canviar Ω a mig currículum faria incomparables les fases.
- **Inicialització guiada:** abans de la fase 2, clonatge conductual sobre un professor de dificultat intermèdia (v8, no v12). Un expert massa fort fa més difícil tant el clonatge com el reforç posterior; v8 ja sap canviar sense ser encara el sostre heurístic.
- **Avaluació fora de la matriu:** l'agent s'avalua contra v12 —l'heurística de millor rendiment observat, no v14— en un experiment separat. Entrena contra oponents del currículum; incloure'l a la matriu de 28 agents distorsionaria les comparacions entre paradigmes no especialitzats contra un rival concret, i barrejaria un entrenament on-policy amb una avaluació off-policy.

La recompensa d'entrenament combina un premi de partida amb senyals densos (debilitaments, HP, modificadors, estats, perills i un cost per pas), d'acord amb el *reward shaping* esmentat a la Taula 2.5: sense senyal intermedi, el crèdit d'una victòria després de 40 torns és massa espars. L'avaluació final ignora aquesta funció i només compta victòries, per no confondre l'objectiu intern amb la mètrica de l'estudi.

3.5 Contracte de comparació i espais d'observació

La tupla POSG de la Taula 2.5, introduïda a la Secció 2.2.2, ja defineix format, accions i observació parcial. Això no n'hi ha prou per comparar: dos agents podrien rebre o_i equivalents i, tot i així, jugar amb espais interns incompatibles, un sol seient o telemetries diferents. El disseny afegeix tres regles perquè aquella tupla es tradueixi en comparacions justes:

- El mateix conjunt d'accions que accepta el simulador per a tots els agents. El que canvia és la *representació interna* (argmax, matriu, fills UCB, classificador o enter emmascarat), no l'espai legal. Es vol que una derrota no es pugui atribuir a «no poder canviar» si l'oponent sí que podia.
- Enfrontament en ambdues orientacions de seient. El protocol de Showdown distingeix p1 i p2; sense recíprocs, un biaix de posició es confondria amb habilitat.
- La mateixa telemetria per partida, independentment del paradigma, de manera que els 784 fitxers es puguin concatenar. Es vol un sol esquema d'anàlisi, no cinc.

La Taula 3.3 resumeix com cada família projecta l'observació i l'acció sobre aquest contracte comú: el Showdown és idèntic; canvia només com es representa o_i a dins.

3.6 Matriu experimental i nivells mostrals

Es vol un n prou gran perquè les diferències de taxa no siguin soroll de la tirada de dany ni de l'equip aleatori (Secció 2.1.9), i prou petit perquè l'MCTS càpiga en calendari. A la Secció 2.2.5

Taula 3.3: Com cada paradigma representa observació i acció. El contracte extern (Showdown) és el mateix; canvia la representació interna.

Paradigma	Observació interna	Acció interna
Heurístiques / minimax	Objectes Battle de <i>poke-env</i> : actiu, banc, camp i historial revelat.	Argmax sobre moviments, canvis i Tera com a modificador.
MCTS ras	El mateix, més un estat determinat per a LocalSim .	UCB/PUCT sobre els fills de l'arrel; s'envia l'acció més visitada.
Imitació	1.150 característiques tabulars per a atacar/canviar. v21 reutilitza l'objecte Battle de v14 ; v22 reconstrueix el vector per a cada candidat.	Macro binària + executor heurístic (v21) o model d'atributs i canvi contrafactual (v22).
PPO	Vector de 328 (o 346 a la prova interrompuda) floats en $[0, 1]$.	Enter $0 \dots 13$ emmascarat.

s'ha derivat que, tractant cada batalla com un assaig de Bernoulli, el marge d'error al 95% és de $\pm 0,98$ pp amb $n = 10.000$ i de $\pm 3,10$ pp amb $n = 1.000$. El disseny assigna aquests pisos al cost de cada paradigma —no un n únic «per simetria»—:

1. **Prova de fum** ($n = 100$): comprovació de funcionament i persistència ($\pm 9,80$ pp). No entra a les conclusions: només vàlida que el contracte de la Secció 3.2 no es bloqueja.
2. **Validació i cerca** ($n = 1.000$): cel·les on intervé MCTS, i portes intermèdies del currículum PPO ($\pm 3,10$ pp). L'MCTS no pot pagar 10.000 partides per cel·la sense trencar l'arquitectura de la Secció 3.3.
3. **Avaluació final** ($n = 10.000$): cel·les de la matriu principal i avaluació PPO contra **v12** ($\pm 0,98$ pp). És el pis amb què es discuteixen les hipòtesis d'ablació.

Taula 3.4: Precisió aproximada al 95% en el cas de màxima variància ($p = 0,5$). La segona columna és el marge d'una proporció; la tercera, el marge de la diferència entre dues proporcions independents amb el mateix n . Són càlculs de planificació, no una anàlisi de potència.

n	Marge d'una TV	Marge d'una diferència	Ús en aquest TFM
100	$\pm 9,80$ pp	$\pm 13,86$ pp	Prova de funcionament
1.000	$\pm 3,10$ pp	$\pm 4,38$ pp	Cel·les amb MCTS i validació PPO
5.000	$\pm 1,39$ pp	$\pm 1,96$ pp	No utilitzat
10.000	$\pm 0,98$ pp	$\pm 1,39$ pp	Cel·la final per defecte
20.000	$\pm 0,69$ pp	$\pm 0,98$ pp	No utilitzat

La matriu (Taula 3.5) és dirigida de $28 \times 28 = 784$ cel·les: 6 referències, 14 heurístiques, 3 Minimax, 3 MCTS i 2 d'imitació. Es fa dirigida — A vs B separat de B vs A — pel biaix de seient. L'execució equival a més de **6,4 milions de batalles** dirigides. El PPO queda fora d'aquesta matriu i s'avalua contra **v12**, pels motius de la Secció 3.4.6.

3.6.1 Orientacions recíproques, autojoc i escala Bradley–Terry

Per controlar un possible biaix de seient, es generen de manera independent A vs B i B vs A . La coherència es comprova amb taxes recíproques entorn del 100% i autojoc entorn del 50%: si l'autojoc s'allunya del 50%, el protocol o el seient estan trencats. Sobre la matriu s'ajusta el model Bradley–Terry de la Secció 2.2.5, ancorat a Random = 1000, per sintetitzar les 784 cel·les en una escala unidimensional de força relativa: sense aquesta síntesi, comparar 28 agents exigiria llegir tota la matriu a ull, si bé la seva interpretació requereix cautela davant d'asimetries mostrals com les de l'MCTS.

Taula 3.5: Famílies d’agents del disseny experimental. La llista completa de 28 identificadors es reutilitza als resultats (Taula 6.1). El PPO queda fora d’aquesta matriu.

Família	Identificadors	n	Funció
Referències	<code>random</code> , <code>max_power</code> , <code>one_step</code> , <code>safe_one_step</code> , <code>abyssal</code> , <code>simple_heuristic</code>	10.000	Controls i oponents de currículum.
Heurístiques	<code>v1–v14</code>	10.000	Ablació de coneixement.
Minimax	<code>v15–v17</code>	10.000	Cerca analítica d’un torn sobre <code>v14</code> .
MCTS ras	<code>v18–v20</code>	1.000	Simulació rasa; el cost limita n .
Imitació	<code>v21</code> , <code>v22</code>	10.000	Política humana d’alt nivell i executor.
PPO	model A (MaskablePPO)	10.000 vs <code>v12</code>	Experiment separat, no fila de la matriu.

3.7 Mètriques de rendiment i telemetria d’execució

La mera taxa de victòries permet establir una jerarquia de rendiment, però no aporta informació sobre els mecanismes subjacents que expliquen el comportament de cada agent. Per obrir aquesta “caixa negra”, es dissenya una arquitectura de telemetria diagnòstica que enregistra, a nivell de partida i de torn, els esdeveniments de combat i les decisions internes de cada paradigma.

3.7.1 Mètrica primària: taxa de victòries i model Bradley–Terry

La mètrica primària d’avaluació és la taxa de victòries (WR) obtinguda en cada cel · la de la matriu d’avaluació, acompanyada del seu interval de confiança de Wilson al 95% (Equació 2.15). Atès que el valor d’una taxa de victòries depèn fortament de la dificultat del rival (p. ex., un 98% contra l’agent aleatori no permet diferenciar polítiques avançades, mentre que un 58% contra `v12` representa un domini rellevant), les taxes es sintetitzen mitjançant el model de preferències parelles de Bradley–Terry (Secció 2.2.5), col · lapsant la matriu en una escala de força unidimensional ancorada a $\text{Random} = 1000$.

3.7.2 Mètriques secundàries i capa d’intercepció de telemetria (StatsBattle)

Per capturar el detall d’allò que passa durant cada enfrontament sense alterar la lògica del simulador ni reduir el rendiment de l’execució en paral · lel, es dissenya un mòdul especialitzat d’intercepció de telemetria (StatsBattle) incorporat a cada treballador (*worker*). Aquest mòdul sobrescriu la classe base de combat de *poke-env* i llegeix directament el flux de línies del protocol WebSocket del servidor Pokémon Showdown (`parse_message` i `switch`).

Aquesta capa de telemetria permet caçar i estructurar automàticament en el fitxer de resultats CSV les següents categories de mètriques secundàries:

1. Dinàmica de combat i pressió ofensiva:

- *Torns totals* i durada de la partida.
- *Salut percentual restant* (HP_{us} vs HP_{opp}) i nombre de Pokémon debilitats, permetent distingir victòries per domini ofensiu de guerres de desgast extrem.

2. Mobilitat i caracterització de canvis:

- *Canvis voluntaris vs forçats*: El mòdul intercepta els missatges de protocol per diferenciar quan un agent realitza un canvi estratègic voluntari de quan es veu obligat a canviar per debilitament del seu Pokémon o per efectes de moviments de *phazing* (com *Roar*, *Whirlwind* o *Dragon Tail*, detectats via la línia de protocol **drag**). Aquesta distinció és clau per separar el pivot tàctic del canvi de pànic.

3. Freqüències de moviments i esdeveniments de combat:

- *Comptador de moviments executats*: Es registra l'ús individual de cada moviment (**move_stats_us/opp**) per analitzar la diversitat de repertori i detectar moviments dominants.
- *Factors d'atzar (RNG)*: S'intercepten els esdeveniments de cops crítics (**-crit**), fallades de precisió (**-miss**) i cops molt efectius (**-supereffective**) per avaluar l'impacte de la variància a curt termini.

4. Activació de regles de domini i ablació heurística:

- Registre de l'activació de blocs d'ablació: col · locació i eliminació de perills d'entrada (*Stealth Rock*, *Spikes*), execució de moviments d'amplificació de noves estadístiques (*setup*), comprovació de KO garantits, ús de Teracristal · lització, protectors de bucles infinits (**loop_guards**) i resolució de finals (**endgame_solves**).

5. Diagnòstic intern de paradigmes avançats:

- *Imitació Jeràrquica (XGBoost)*: Registre de la probabilitat acumulada $p(\text{canvi})$ i de les decisions macro adoptades (**xgb_switches** vs **xgb_stays**).
- *Cerca (Minimax / MCTS)*: Enregistrament de les vegades que el mòdul de cerca modifica l'acció suggerida per l'heurística base (**search_switches**, **search_moves**) i la mètrica de discrepància.
- *Robustesa i errors*: Comptador de decisions per defecte (**fallback_moves**) o moviments no permesos (**error_moves**) per garantir que la política no cau en accions degenerades.

Aquest conjunt integrat de telemetria garanteix que cada cel · la de la matriu d'experiments no només produeixi un percentatge de victòries, sinó també una signatura conductual completa diagnòstica de l'agent.

3.8 Protocols d'avaluació especials i abast

A banda de la matriu d'avaluació creuada principal de 28×28 cel · les entre polítiques deterministes, heurístiques i de cerca, determinats paradigmes i entorns requereixen protocols d'experimentació dedicats. Aquesta secció estableix les condicions d'avaluació específiques per a la integració exploratòria d'agents basats en models de llenguatge (LLM), la validació del model de reforç profund (MaskablePPO) sobre el seu currículum i el desplegament de prova en la classificació pública oficial.

3.8.1 Integració exploratòria d'agents LLM

Els agents basats en models de llenguatge de gran escala (LLM), com **PokéChamp** i **PokéLL-Mon** (revisats a la Secció 2.3), s'inclouen com una exploració conceptual per avaluar la capacitat del raonament en llenguatge natural (*Chain-of-Thought*, CoT) en la presa de decisions en temps real. Aquests agents serialitzen l'estat observable de la batalla (Pokémon actius, banqueta,

moviments revelats i taula d'efectivitats) en un prompt textual i deleguen l'elecció de l'acció a un model generatiu.

Des del punt de vista del disseny experimental, la integració dels LLM s'estableix com un **estudi exploratori de viabilitat** i no com una fila de la matriu principal d'avaluació creuada per dues raons de disseny:

1. **Asimetria de la latència de decisió:** La generació autoregressiva d'un LLM requereix diversos segons o minuts per torn, a diferència de les respostes en mil·lisegons de les heurístiques o la cerca rasa. Això introdueix un desfasament en entorns de temps real a Showdown.
2. **Incompatibilitat de pressupost de volum:** Executar la matriu massiva ($n = 10.000$ partides per cel·la) amb agents generatius és inabastable sota un pressupost de temps i còmput homogeni.

Per tant, l'abast dels LLMs es restringeix a validar la compatibilitat de l'arquitectura i analitzar el cost temporal per decisió, mentre que la comparació competitiva rigorosa del benchmark es reserva per a les 28 polítiques de les famílies anteriors.

3.8.2 Avaluació dedicada de MaskablePPO

L'agent MaskablePPO no s'inclou com una fila addicional de la matriu d'avaluació creuada, sinó que s'avalua mitjançant un experiment dedicat contra **v12** amb els pesos de la xarxa congelats en finalitzar el currículum. Aquest disseny respon a l'alineació amb la darrera porta del currículum (Taula 3.2) i a l'aïllament del biaix d'entrenament ja argumentats a la Secció 3.4.6.

3.8.3 Avaluació en la classificació pública i coordinació amb desenvolupadors

La matriu principal avalua els agents en un entorn controlat entre bots i equips aleatoris. Per aportar validesa externa, l'heurística terminal de servei **v14** —no **v12**— es desplega a la classificació pública oficial de Pokémon Showdown (*ladder*) contra jugadors humans: és la política amb el conjunt de regles més complet i ja instrumentada com a executor, i per tant la més adequada per a una prova oberta, independentment del rànquing intern de la lliga.

A fi d'assegurar un desplegament ètic i conforme a la normativa de la plataforma, es va establir contacte directe amb l'equip de desenvolupadors oficials de Pokémon Showdown i Smogon mitjançant els seus servidors de Discord (*Showdown! Coding i Smogon Development*). Les consultes amb l'equip tècnic (com ara el desenvolupador `_iforgetwhyimhere`) van permetre confirmar aspectes clau de la infraestructura:

- **Absència de registre formal per a bots de batalla:** El rang *Global Bot* s'assigna exclusivament a xatbots de moderació amb permisos HTML, mentre que els agents de batalla operen sota el mateix protocol de connexió WebSocket que els usuaris estàndard.
- **Gestió de la taxa de connexió:** La plataforma aplica un control automàtic de freqüència (*rate-limiting* de 12 partides cada 3 minuts) per evitar la saturació del servidor, sense aplicar restriccions permanents d'IP per activitat continuada de combat.
- **Integritat de les estadístiques de l'escala:** Pokémon Showdown disposa de mecanismes automàtics per filtrar el tràfic de bots del càlcul de les estadístiques oficials d'ús del *metagame*, garantint que l'avaluació de l'agent no alterés les dades públiques.

Aquesta coordinació prèvia va validar la viabilitat del protocol d'avaluació pública, adaptant la velocitat d'execució de l'agent a les restriccions del servidor i garantint la reproductibilitat del desplegament en entorns reals.

3.9 Amenaces a la validesa i reproductibilitat

El disseny anterior introdueix compromisos que cal declarar, no amagar:

- **Comparabilitat computacional:** cada paradigma opera sota un pressupost diferent. L'MCTS utilitza $n = 1.000$ per cel · la. Les comparacions mesuren sistemes complets sota aquestes restriccions, no un empat a temps de CPU —empatar-los hauria fet inviable la matriu.
- **Selecció de variants:** avaluar només la millor versió d'una família afavoriria el màxim mostral; es documenta tota l'ablació.
- **Multiplicitat:** davant de 784 cel · les, l'anàlisi es basa en la consistència dels intervals de Wilson i la magnitud de l'efecte, no en p-valors aïllats.
- **Desajust de simuladors (MCTS):** el rollout local no és el motor autoritatiu. El disseny el tracta com a font d'error coneguda, conseqüència de respectar el POSG.
- **Reproductibilitat:** es fixen la versió de Showdown, els repositoris de Random Battle i els artefactes de pesos, perquè el contracte de la Secció 3.2 no depengui d'un servidor públic canviant.

3.10 Síntesi i continuïtat

El capítol ha fixat *què* es mesura i *per què* es mesura així: un sol àrbitre Showdown i una sola traducció *poke-env*; una arquitectura paral · lela de treballadors efímers; cinc famílies amb ablació interna; una matriu 28×28 amb n adaptat al cost. El Capítol 4 descriu l'entorn de còmput, xarxa i monitoratge que fa viable aquesta execució. El Capítol 5 mostra com aquest disseny es converteix en mòduls, scripts d'entrenament i un connector amb la classificació pública. El Capítol 6 n'analitza els resultats.

Capítol 4

Entorn de desenvolupament i infraestructura de còmput

El Capítol 3 exigeix centenars de cel·les independents, motors V8 reciclables i execucions de dies. Aquest capítol documenta l'entorn que fa viable aquella execució —maquinari, xarxa, monitoratge, dependències i organització— i sobre el qual el Capítol 5 implementa coordinador, agents i connector amb el *ladder*. El coordinador mateix es descriu allà; aquí es fixa on i amb quins recursos corre.

Cal distingir dos volums. La **matriu dirigida** de 28 agents suma **6,4 milions** de batalles (6.409.000). El **còmput total** —proves, altres formats, entrenament PPO, repeticions i execucions de diagnòstic— s'aproxima a **52,7 milions** de batalles. Les dues xifres no són intercanviables: la primera és l'experiment; la segona, el cost de còmput acumulat.

4.1 Organització del projecte i gestió amb Kanban

El desenvolupament del projecte s'ha organitzat mitjançant una metodologia àgil basada en un tauler **Kanban**, dividit en sis seccions funcionals per controlar l'abast i prioritzar el treball:

- ***Aim of the study***: Defineix els objectius principals, hipòtesis de recerca i el disseny dels 5 paradigmes.
- ***Tentative (If we have time)***: Línies d'investigació secundàries o exploratòries (com els agents LLM i proves multigeneracionals).
- ***To Do (Icebox/later)***: Idees i tasques congelades a llarg termini per evitar la dispersió de l'abast (*scope creep*).
- ***To Do***: Tasques pendents immediates i prioritzades de codi, simulació o redacció.
- ***In Progress***: Treball actiu en desenvolupament, entrenament PPO o execució de la matriu.
- ***Done***: Mòduls finalitzats, simulacions executades, dades validades i seccions redactades.

Aquesta estructura ha permès controlar l'abast (heurístiques, cerca, imitació, PPO, LLM i redacció) i traçar-lo amb el repositori (Secció 4.3).

4.2 Evolució de l'arquitectura

4.2.1 Fase 1: prototipatge en portàtil

El desenvolupament inicial, la construcció de les primeres heurístiques (v1–v6) i la redacció de la memòria es van dur a terme en un portàtil:

- **Processador (CPU):** Intel Core Ultra 7 155H (16 nuclis / 22 fils).
- **Memòria RAM:** 16 GB —suficient per a prototipatge, insuficient per a múltiples instàncies de Showdown en paral·lel.
- **Emmagatzematge:** SSD NVMe d'1 TB per a data/.

Aquesta fase va identificar el coll d'ampolla de RAM i va motivar les neteges amb `gc.collect()`, els lots continguts i el reinici periòdic de Node.js ja fixats com a principi al Capítol 3.

4.2.2 Fase 2: estació de treball

Els experiments finals i la matriu s'executen en una torre configurada per a càrrega sostinguda:

- **Processador (CPU):** AMD Ryzen 7 5700X3D (8 nuclis / 16 fils, 96 MB L3 3D V-Cache), adequat a simulació de partides i a arbres Minimax/MCTS.
- **Refrigeració:** dissipador d'aire Noctua; la CPU es manté per sota de 65°C sota càrrega contínua, que és el pressupost tèrmic del dimoni de la Secció 4.5.
- **Memòria RAM:** 32 GB DDR4 en doble canal, necessaris per a vuit instàncies de Showdown, estructures de cerca i conjunts tabulars.
- **Targeta gràfica (GPU):** NVIDIA GeForce RTX 2080 (8 GB VRAM), per a MaskablePPO (CUDA/PyTorch) i inferència local d'LLM.
- **Emmagatzematge:** SSD NVMe PCIe 4.0 d'1 TB per a telemetria i CSV concurrents, amb unitats auxiliars per a còpies de seguretat.

La configuració habitual utilitza vuit instàncies de Showdown (ports 8000–8007), cadascuna amb 15–25 batalles asíncrones. Les cel·les heurístiques es completen molt més ràpidament que les d'MCTS; aquesta asimetria de cost és la raó empírica dels $n = 10.000$ i $n = 1.000$ de la Secció 3.6. L'avaluació PPO contra v12 també utilitza vuit ports.

4.3 Control de versions, traçabilitat i mètriques del programari

Tota l'evolució del projecte s'ha gestionat de manera rigorosa mitjançant el sistema de control de versions **Git** allotjat a la plataforma **GitHub**. Per garantir una traçabilitat clara entre el desenvolupament tècnic i la redacció de la memòria, s'ha aplicat una política estructurada de missatges de confirmació (*Conventional Commits*):

- **Desenvolupament de codi:** Commits amb prefixos funcionals com **feat:** (noves heurístiques, mòduls de cerca o integracions), **fix:** (correccions de telemetria o concurrència), **refactor:** (reestructuració de mòduls i agents), **test:** (validacions i *smoke tests*) i **infra:** (scripts de supervisió i seguretat).
- **Redacció acadèmica:** Commits prefixats estrictament amb **report:** o **docs:** per identificar i aïllar les iteracions en el text de la memòria, generació de figures i taules comparatives.

Com s'il·lustra a la Figura 4.1, el desenvolupament ha mantingut un ritme sostingut al llarg de **115 commits** distribuïts en **51 dies d'activitat intensa**, reflectint les fases successives d'implementació d'heurístiques, integració de cerca adversarial (minimax i MCTS), entrenament de xarxes neuronals PPO i avaluació massiva de la matriu.

Pel que fa a la dimensió del codi font, el directori principal `src/` comprèn un total de **297 fitxers**, dels quals destaquen **153 fitxers de codi i scripts actius**:




Figura 4.1: Calendari d'activitat i mapa de calor de *commits* a GitHub des de l'inici del projecte (14/02/2026) fins a la versió final (25/08/2026).

- **Mòduls Python (.py):** 119 fitxers amb **24.635 línies** de codi font que implementen els agents, l'arquitectura de combat, les 14 versions heurístiques, els arbres de cerca, els entorns Gymnasium i el coordinador concurrent.
- **Quaderns d'anàlisi (.ipynb):** 16 *notebooks* Jupyter interactius amb **14.896 línies** (en format estructurat) per a l'anàlisi exploratòria de dades (EDA), calibratge i validació estadística dels paradigmes.
- **Scripts d'automatització (.sh):** 18 scripts Bash amb **2.563 línies** dedicats al llançament distribuït, reinici de servidors Showdown, telemetria amb Telegram i seguretat del sistema.
- **Documentació tècnica i configuració (.md, .json):** 55 fitxers amb 4.986 línies de guies tècniques, protocols d'execució i esquemes d'estat.

Aquesta base de codi suma més de **42.000 línies** desenvolupades per a aquest treball. Les mètriques documenten l'abast del programari; no substitueixen l'avaluació empírica del Capítol 6.

4.4 Accés remot i continuïtat

L'accés remot entre el portàtil i l'estació de treball s'ha configurat mitjançant una xarxa privada virtual basada en **Tailscale** (protocol *WireGuard*), combinada amb sessions persistents de **tmux**. Aquesta configuració permet desenvolupar des del portàtil i mantenir execucions 24/7 a la torre sense exposar SSH a Internet. Els detalls de configuració es recullen a l'Annex A.1.

4.5 Bot de Telegram i monitoratge de seguretat

L'execució sostinguda —6,4 milions de batalles a la matriu, de l'ordre de 52,7 milions de còmput total— exigeix supervisió sense una sessió SSH permanent. El sistema de monitoratge es compon d'un bot de Telegram amb dues peces complementàries: un dimoni de seguretat (`src/p00_core/scripts/seguretat_tfm.sh`) que vigila temperatures, memòria i processos, i el llançador de la matriu que emet notificacions de cicle de vida i recupera lots bloquejats (materialitzat al Capítol 5). El mòbil exposa progrés i temperatures, permet pausar o reprendre la matriu i, si cal, dispara l'apagat tèrmic o el reinici de Showdown sense SSH. Aquesta capa és el que ha fet viable l'execució 24/7. Els detalls de configuració, llindars i comandes es recullen a l'Annex A.1.

4.6 Dependències

El gestor de paquets és **uv** amb Python **3.12** i `pyproject.toml`. Node.js [55] construeix Pokémon Showdown. Resum:

- **Nucli de combat:** `poke-env` ≥ 0.11 , < 0.12 [6]; Node.js [55] per a Showdown.
- **Dades / estadística:** numpy [56], pandas [57], polars [58], scipy [59].
- **ML tabular:** scikit-learn [60], XGBoost [49], Hugging Face Datasets [61].
- **Visualització i notebooks:** matplotlib [62], seaborn [63], ipykernel, nbconvert.
- **Utilitats:** tqdm, tabulate, orjson, requests, websockets.
- **Aprenentatge per reforç (extra rl / gpu):** Gymnasium [64], Stable-Baselines3 [65], sb3-contrib (MaskablePPO) [66], PyTorch [67] i TensorBoard [68].
- **LLM / Pokechamp (extra pokechamp):** Ollama [69], transformers, openai / anthropic / google-genai (backends opcionals), rich.
- **Qualitat:** Ruff (format + lint), ty (tipus).
- **Sistema:** Git/GitHub, tmux, Tailscale, Telegram Bot API, $\text{\LaTeX}$ (report/).

El fork `pokechamp/` s'incorpora al `sys.path` dels processos que necessiten `LocalSim` o `Abyssal`. Les dades completes de la matriu i els pesos PPO són artefactes voluminosos i no tots queden versionats al repositori; per reproduir els resultats cal conservar-los juntament amb el codi.

4.6.1 Congelació de versions i integració dels tres repositoris clau

El projecte s'articula entorn de tres repositoris base: el motor de simulació oficial **Pokémon Showdown** (Node.js), el marc de connexió ***poke-env*** (Python, sèrie 0.11.x) i l'entorn de cerca/simulació local ***PokéChamp*** (`pokechamp/`). Tots tres es van fixar en revisions concretes des de l'inici de l'experimentació —congelació indispensable per a la reproductibilitat— i es van integrar directament com a directoris locals al repositori principal per permetre pegats i assegurar portabilitat entre equips. Els detalls d'aquesta integració es recullen a l'Annex A.1.

4.7 Ecosistema de redacció i documentació en $\text{\LaTeX}$

La memòria s'ha redactat en $\text{\LaTeX}$ per cinc motius operatius: (1) notació matemàtica densa (POSG, $\hat{A}_t$, $\mathcal{L}^{\text{CLIP}}$, intervals de Wilson) via AMS- $\text{\LaTeX}$; (2) capítols i taules modulares (`\include`, `tables/`); (3) traçabilitat línia a línia amb Git, coherent amb la Secció 4.3; (4) gestió bibliogràfica (BibTeX/`natbib`) i referències creuades (`hyperref`); (5) maquetació estable en un document llarg. No és part de l'experiment; és l'eina amb què se'n documenta el disseny i els resultats.

4.8 Anàlisi de cost econòmic i pressupost de recursos

L'avaluació econòmica d'un projecte d'investigació aplicada i enginyeria de dades ha d'anar més enllà dels costos materials immediats. En un Treball de Final de Màster d'aquest abast, cal distingir dues dimensions complementàries:

1. **Costos de recursos humans (capital humà):** El temps de desenvolupament, recerca, modelització, experimentació i redacció invertit per l'equip de treball, valorat segons les tarifes de mercat vigents a Espanya per a perfils especialitzats en Ciència de Dades.
2. **Costos operatius directes (infraestructura, maquinari i energia):** Les despeses materials associades a l'execució ininterrompuda dels experiments sobre més de 52,7 milions de batalles, el maquinari emprat i les llicències de programari.

4.8.1 Estimació de dedicació de l'equip i costos de personal

L'equip humà responsable de l'execució del projecte es compon de tres perfils diferenciats:

- **Investigador Principal / Desenvolupador (Gerard Pascual Fontanilles — Perfil Junior Data Scientist):** Responsable directe de la implementació de la base de codi (`src/`, més de 42.000 línies), recollida i neteja de dades, anàlisi exploratòria (EDA), disseny de les 14 heurístiques i els agents de cerca (Minimax, MCTS), entrenament de models (XGBoost, MaskablePPO), orquestració d'infraestructura i redacció completa de la memòria.
- **Coordinadora del TFM / Ponent Oficial (Laura Serra Roig — Perfil Senior Data Scientist / Coordinadora Acadèmica):** Responsable de la ponència oficial del Treball de Final de Màster i coordinació institucional de l'assignatura; va contribuir en la concepció de la idea fundacional del treball, l'orientació sobre l'enfocament i directrius del TFM, i la revisió final global de la memòria prèvia a la presentació davant del tribunal.
- **Director Tècnic del Treball / Tutor Metodològic (Jordi Peralta Dolz — Perfil Senior Data Scientist):** Responsable de la direcció tècnica i supervisió pràctica continuada del projecte, orientació en la formulació teòrica (POSG i POMDP), assessorament en el disseny experimental i inferència estadística (Bradley–Terry, Wilson), revisió crítica continuada i validació de les implementacions.

Estudi salarial de mercat a Espanya (2026)

D'acord amb els estudis del mercat laboral tecnològic a Espanya (guies salarials sectorials de consultores com Michael Page [70] i Hays [71]):

- **Junior Data Scientist (0–2 anys d'experiència):** La forquilla salarial de mercat se situa entre 28.000 € i 35.000 € bruts anuals. S'adopta una retribució bruta de referència de **32.000 €/any**. Considerant el Conveni Col·lectiu d'Empreses de Consultoria i Tecnologies de la Informació (1.760 hores laborables anuals), s'obté un salari brut horari de **18,18 €/h**. Computant les cotitzacions a la Seguretat Social a càrrec de l'empresa ($\approx 31,5\%$, cost anual d'empresa de ≈ 42.080 €), la tarifa horària d'imputació empresarial és de **24,00 €/h**.
- **Senior Data Scientist / Direcció i Coordinació (> 6 anys d'experiència):** La banda salarial de mercat oscil·la entre 60.000 € i 80.000 € bruts anuals. S'estableix una retribució mitjana de referència de **68.000 €/any**, equivalent a un salari brut horari de **38,64 €/h**. Amb les quotes patronals corresponents (aplicant el topall de base màxima de cotització a Espanya, cost empresa de ≈ 88.000 €/any), la tarifa horària d'imputació a projecte és de **50,00 €/h**.

Imputació d'hores per fase de treball

El còmput d'hores reflecteix les 27 setmanes de calendari compreses entre el 14 de febrer i el 20 d'agost de 2026 (**115 commits i 51 dies d'activitat intensa** acreditats a Git, Secció 4.3). L'esforç s'imputa directament a les fases de treball ja detallades en els capítols anteriors:

- **Recerca teòrica i concepció (Research):** 80 h totals (60 h Junior, 15 h Jordi Peralta, 5 h Laura Serra) per a la concepció de la idea fundacional, l'estudi de POSG/POMDP i la literatura existent (Capítol 2).
- **Enginyeria de dades (Data):** 78 h totals (70 h Junior, 8 h Jordi Peralta) per a l'adquisició i preparació del conjunt de repeticions d'alt nivell Elo 1800+ (Capítol 3).
- **Anàlisi exploratòria i telemetria (EDA):** 75 h totals (65 h Junior, 10 h Jordi Peralta) per als 16 quaderns d'EDA i l'especificació de les 70 columnes de telemetria (StatsBattle, Secció 3.7).

- **Modelització d'agents (*Modeling*):** 208 h totals (190 h Junior, 18 h Jordi Peralta) que concentren la implementació de les 14 heurístiques, minimax, MCTS, XGBoost i MaskablePPO (Capítols 3 i 5).
- **Infraestructura i MLOps (*Infrastructure*):** 97 h totals (90 h Junior, 7 h Jordi Peralta) per a l'arquitectura concurrent, VPN i el bot de monitoratge tèrmic (Capítol 4).
- **Avaluació experimental (*Evaluation*):** 55 h totals (45 h Junior, 10 h Jordi Peralta) per a l'execució de la matriu de 28 agents i l'ajust de l'escala Bradley–Terry (Capítol 6).
- **Redacció, coordinació i revisió de la memòria (*Redaction*):** 167 h totals (120 h Junior, 22 h Jordi Peralta, 25 h Laura Serra) per a la resolució de consultes estructurals, orientació acadèmica continuada, redacció tècnica en L^AT_EX i revisió final de la memòria (Secció 4.7).

La Taula 4.1 en sintetitza la dedicació total (760 h: 640 h Junior i 120 h Senior) i el cost econòmic imputat.

Taula 4.1: Desglossament d'hores de treball i costos laborals de l'equip per fase del projecte.

Fase de treball	Jr. (h)	Jordi (h)	Laura (h)	Total (h)	Brut (€)	Empresa (€)
Recerca teòrica (<i>Research</i>)	60	15	5	80	1.863,60	2.440,00
Enginyeria de dades (<i>Data</i>)	70	8	0	78	1.581,72	2.080,00
Anàlisi exploratòria (<i>EDA</i>)	65	10	0	75	1.568,10	2.060,00
Modelització d'agents (<i>Modeling</i>)	190	18	0	208	4.149,72	5.460,00
Infraestructura i MLOps (<i>Infrastr.</i>)	90	7	0	97	1.906,68	2.510,00
Avaluació i estadística (<i>Evaluation</i>)	45	10	0	55	1.204,50	1.580,00
Redacció i coordinació (<i>Redaction</i>)	120	22	25	167	3.997,68	5.230,00
Total Dedicació	640	90	30	760	16.272,00	21.360,00

4.8.2 Costos directes d'infraestructura, maquinari i energia

A diferència de les hores d'equip, el cost *marginal* directe del treball en infraestructura es va contenir gràcies a l'ús d'equips preexistents, programari lliure i autoconsum elèctric solar. Cal, tanmateix, incloure l'amortització del maquinari per reflectir el cost real dels recursos emprats. Els costos directes es resumeixen en cinc eixos principals:

1. **Amortització del maquinari (188,46 €):** Tant el portàtil inicial com l'estació de treball són equips de propietat personal preexistents del desenvolupador. No s'ha realitzat cap adquisició dedicada, però cal imputar la depreciació proporcional al temps d'ús del projecte. L'estació de treball (valor estimat de 1.500 €, vida útil de 5 anys) i el portàtil (valor estimat de 1.200 €, vida útil de 5 anys) s'amortitzen linealment. Considerant 6,5 mesos d'ús efectiu del projecte (febrer–agost 2026), la fracció imputable és:
 - Estació de treball: $1.500 \times \frac{6,5}{60} = 162,50$ €.
 - Portàtil (ús parcial, fase 1): $1.200 \times \frac{2}{60} = 40,00$ €.
 - Total amortització: **202,50 €**. S'arrodoneix a **188,46 €** descomptant el mes d'agost del portàtil (ja no emprat per a experimentació).

2. **Temps d'execució i consum energètic ($\approx 5,85$ €):** L'estació de treball va funcionar de manera continuada 24/7 durant 4 setmanes, acumulant **684,89 hores de còmput continu de màquina** (471,38 h per a la matriu final Gen 9 i 213,66 h per a la resta de dades) sobre més de **52,7 milions de batalles**:
 - **Autoconsum solar diürn:** Durant les hores de sol, la instal·lació de plaques solars domèstiques va cobrir la demanda de la torre amb energia renovable.
 - **Consum nocturn i mode terminal:** Durant la nit, el còmput va requerir subministrament convencional (potència mitjana de 135 W, 92,5 kWh totals, aproximadament un 50% de consum nocturn a la tarifa de 0,126561 €/kWh), sumant un cost directe de **5,85 €**. L'estació es va executar en mode terminal (*headless*) via `tmux` per minimitzar el consum.
3. **Models de llenguatge i eines d'IA (0,00 €):** Les proves amb LLMs es van executar 100% localment amb **Ollama**, i l'ús d'eines basades en IA (Cursor, PyCharm, Antigravity) es va realitzar mitjançant llicències d'estudiant/pro sense cap despesa econòmica.
4. **Programari i comunicacions (0,00 €):** Totes les eines de la cadena de valor (Showdown, *poke-env*, Tailscale, Telegram Bot API i L^AT_EX) són de codi obert (*open-source*) o en modalitat gratuïta.

Taula 4.2: Resum dels costos directes materials i d'infraestructura del TFM.

Concepte	Estratègia d'optimització / Font	Cost Directe (€)
Amortització maquinari	Depreciació lineal proporcional (estació 1.500 € + portàtil 1.200 €, 5 anys)	188,46
Consum energètic 24/7	684,89 h efectives (471,38 h Gen 9 + 213,66 h resta; 0,126561 €/kWh)	5,85
Inferència d'LLMs	Execució local amb Ollama i llicències d'estudiant (Cursor/PyCharm)	0,00
Eines i Infraestructura	Programari de codi obert (<i>open-source</i>) i serveis gratuïts	0,00
Cost Directe Material		194,31

4.8.3 Pressupost econòmic total consolidat

La integració dels costos de personal i dels costos materials permet quantificar el pressupost global del Treball de Final de Màster, presentat a la Taula 4.3.

Com es desprèn de l'anàlisi econòmica consolidada, el cost de personal representa el **99,1%** del valor total del projecte (**21.360,00 €** en cost d'empresa imputat o **16.272,00 €** en retribució bruta directa). La despesa material directa —incloent-hi l'amortització proporcional del maquinari i el consum elèctric— ascendeix a **194,31 €**, xifra que confirma la viabilitat d'executar un projecte d'alta intensitat computacional amb una inversió de capital continguda gràcies a l'ús d'equips preexistents i programari lliure.

Taula 4.3: Pressupost econòmic global consolidat del TFM.

Partida pressupostària	Descripció / Desglossament	Cost Brut (€)	Cost Imputat (€)
Recursos Humans (Junior)	640 h d'investigació i enginyeria (Gerard Pascual Fontanilles)	11.635,20	15.360,00
Recursos Humans (Senior)	90 h de direcció tècnica i supervisió (Jordi Peralta Dolz)	3.477,60	4.500,00
Recursos Humans (Senior)	30 h de ponència oficial i coordinació (Laura Serra Roig)	1.159,20	1.500,00
Consum Elèctric (Còmput 24/7)	684,89 h de màquina (92,5 kWh xarxa nocturna + solar diürn)	5,85	5,85
Amortització Maquinari	Depreciació lineal estació + portàtil (6,5 mesos / 5 anys)	188,46	188,46
Programari i Llicències	Entorn <i>open-source</i> (Showdown, <i>poke-env</i> , L ^A T _E X)	0,00	0,00
Cost Total del Projecte		16.466,31	21.554,31

Capítol 5

Implementació dels cinc paradigmes

Aquest capítol materialitza el disseny del Capítol 3 sobre l'entorn del Capítol 4. No es reobre el POSG, l'ablació ni el protocol mostral: aquí es documenten directoris, classes, ports, hiperparàmetres i artefactes. El contracte d'observació (Secció 3.2), el coordinador/treballadors (Secció 3.3) i el paper de v14 com a heurística de *servei* —fulla, prior i executor; v12 com a referent de rendiment— es donen per fixats (Secció 3.4). El repositori segueix el mateix desacoblament: un nucli compartit i un mòdul per paradigma.

5.1 Mapa del programari

El nucli p00_core implementa el gestor (Secció 3.1) i el model coordinador/treballadors (Secció 3.3) sobre els vuit Showdown de la Secció 4. Els directoris p01–p05 afegeixen només la política (Figura 5.1):

- `src/p00_core/engine/`: `benchmark.py` (coordinador) i `worker.py` (procés efímer).
- `src/p00_core/scripts/`: `run_paradigm_comparison_10k.sh` (llançador de la matriu) i `seguretats_tfm.sh` (dimoni Telegram, Secció 4.5).
- `src/p00_core/core/`: `BaseHeuristicv1`, `AgentFactory` (àlies `HeuristicFactory`) i l'estimador de dany compartit.
- `src/p01_heuristics/agents/internal/`: `v1.py–v14.py`.
- `src/p03_minmax/`: `v15–v17`.
- `src/p04_mcts/`: `v18–v20`; `LocalSim` via el fork `pokechamp/`.
- `src/p02_imitation_learning/`: `dataset` → característiques → `XGBoost` → `v21/v22`.
- `src/p05_ppo_drl/`: entorn `Gymnasium`, vectorització, clonatge i `MaskablePPO` (fora de la matriu).
- `src/p00_core/online_bot/`: connector de v14 amb el *ladder* públic.
- `src/p00_core/reporting/`: mapa de calor, Elo Bradley–Terry i informes per família que llegeix el Capítol 6.

5.2 Motor de batalla i capa d'integració

El contracte de la Secció 3.2 —l'agent només veu l'observació estructurada i retorna una acció legal— es concreta en versions i arrencada.




Figura 5.1: Mapa modular del repositori. `p00_core` centralitza simulació i persistència; Minimax, MCTS i imitació reutilitzen `v14` (`p01`); PPO i el *ladder* públic disposen d'entorns d'execució dedicats.

5.2.1 Servidor local de Pokémon Showdown

El coordinador no arrenca Node a mà: `restart_servers_async` de `benchmark.py` fa `kill` dels processos Showdown i crida `src/p00_core/scripts/launch_custom_servers.sh` amb el nombre de ports i el port base (8000). Aquest script llança

```
node pokemon-showdown/pokemon-showdown start --port P --no-security
```

només als ports que encara no accepten TCP, de manera que una avaluació PPO i una cel·la de la matriu no es maten mutuament. L'opció `-no-security` elimina l'autenticació local. El llançador de la matriu demana vuit instàncies (8000–8007). `start_fixed_servers.sh` (sis ports) és un auxiliar de desenvolupament, no el camí de la matriu.

5.2.2 Versions i forks de *poke-env*

El projecte fixa *poke-env* a la sèrie 0.11.x: tota la matriu es va executar amb aquesta API. El fork `pokechamp/` s'afegeix només als processos que necessiten Abyssal, agents de llenguatge o `LocalSim`. L'estat real de la partida continua vivint al servidor Showdown; `LocalSim` només s'utilitza dins de les simulacions de l'MCTS, tal com preveu el disseny de determinització de la Secció 3.4.

5.3 Arquitectura coordinador–processos de treball

El model conceptual —coordinador que no juga, treballadors efímers, CSV com a font de progrés, Showdown dedicat— és el de la Secció 3.3 (Figura 3.5). Aquí es fixen fitxers, context d'execució i constants.

El prototip `core/battle_manager.py` valida el cicle de la Figura 3.4 en un sol procés. La matriu el substitueix per `benchmark.py` + `worker.py`: el primer calcula n_{to_run} , administra la cua de ports i fusiona CSV; el segon executa un lot i desapareix. El context és `multiprocessing` `spawn`, de manera que no s'hereten bucles asincronitzats ni connexions WebSocket.




Figura 5.2: Cicle d'execució de la matriu. El traç discontinu indica la represa incremental: el coordinador llegeix les files ja existents al CSV final i només programa les batalles pendents.

Constants per cel·la les fixa el llançador (Secció 5.3.3): vuit ports; concurrència 25 o 15; temps d'espera $\max(7200, 40 \cdot n_{batch})$ s; `-restart-every 20` (el defecte del motor és 3). Cada treballador escriu blocs de 25 batalles, crida `reset_battles()` i `gc.collect()`, i no toca el

CSV final. Les notes de desenvolupament situen les heurístiques a 0,01–0,1 s/partida i l'MCTS a 2–6 s, d'acord amb el pressupost de la Secció 3.6.




Figura 5.3: Monitoratge durant una execució al prototip de 16 GB. La memòria creix mentre s'acumulen batalles i cau després de reiniciar processos.

5.3.1 Esquema CSV: captura, escriptura i columnes per família

La telemetria de la Secció 3.7 no es desa com un esquema diferent per agent. `worker.py` fixa **70 columnes** (`fieldnames`) i, després de cada lot, recorre `player._battles`, descarta partides no acabades i construeix un diccionari per batalla. `csv.DictWriter` afegeix les files al CSV temporal del port; el coordinador les fusiona al CSV final. El mateix esquema s'escriu per a **tots** els 28 agents: si un camp no aplica, `getattr(..., {}).get(battle_id, 0)` retorna zero. Així `pandas/polars` concatenen els 784 fitxers sense forats d'esquema, i un zero és informatiu (l'agent no té aquell mòdul), no un valor perdut.

Tres fonts alimenten cada fila (Figura 5.4):

1. **Objecte Battle / StatsBattle:** resultat (`won`, `turns`), HP i membres (denominador fix 6, perquè l'equip rival ocult no s'ha vist sencer), equips serialitzats, condicions de camp, Tera, canvis voluntaris/forçats, crítics, fallades, super-efectius i `move_stats` (`nom:compte` separat per `|`).
2. **Diccionaris de l'agent *us* i de l'oponent:** `_total_decisions_by_battle`, `_fallback_moves`, `_error_moves` i, si la classe els defineix, comptadors de paradigma.
3. **Identificadors de lot:** `battle_id` (`p{port}_{uuid}_{tag}`), `format`, etiquetes `heuristic/opponent` i `timestamp`.

Els lots són de 25 partides (heurístiques/IL/baselines) o de 5 (minimax/MCTS), amb temps d'espera 180 s o 300 s. Després d'escriure, `reset_battles()` i `gc.collect()` eviten reescriure la mateixa batalla al lot següent.

La Teracristal·lització s'extreu amb `getattr` (`terastallized` o `_terastallized`). El disseny de `StatsBattle` és el de la Secció 3.7: es substitueix `Player._create_battle` perquè cada sala intercepti `|-crit|`, `|-miss|`, `|-supereffective|` i `|drag|`; `switch` distingeix canvi voluntari, forçat per debilitament i forçat per phazing.




Figura 5.4: Captura i consolidació de la telemetria per partida. Les tres fonts s’integren en un esquema rígid de 70 columnes per garantir la compatibilitat amb eines d’anàlisi columnar.

Taula 5.1: Qui omple cada bloc de columnes. La columna existeix sempre; el valor no nul només on s’indica.

Columnes	Omplertes per
won, turns, HP, equips, Tera, canvis, RNG, move_stats	Tots els agents (via StatsBattle / Battle).
decisions, fallback_moves, error_moves	Subclasses de BaseHeuristic1v1; baselines poke-env queden a 0.
hazard_sets, setup_uses, ko_checks, matchup_switches	A partir de v7/v9, que incrementen els diccionaris a _select_action. v1–v6: 0.
search_diff, search_moves, search_switches, endgame_solves	v15–v20 (i endgame_solves també a v14/v21 si el solver dispara).
xgb_switches, xgb_stays, xgb_prob_sum, loop_guards	v21 i v22.
ko_guards	v21 (drecera de KO abans d’XGBoost).

5.3.2 De la matriu a les figures

El Capítol 6 no llegeix els 784 CSV a mà. `src/p00_core/reporting/plots/generate_heatmap.py` construeix el mapa de calor dirigit amb els prefixos (H)/(MM)/(MCT)/(IL)/(B). `src/p00_core/reporting/elo/elo_ranking.py` ajusta el Bradley–Terry de la Secció 2.2.5 per regressió logística sobre la matriu simetritzada, ancorada a `random = 1000`, i escriu `elo_summary.csv`. Els informes per família viuen a `src/p00_core/reporting/agents/` (heurístiques, minimax, MCTS, imitació) i alimenten les taules i figures del capítol de resultats. Un script històric d’18 agents (`calculate_all_metrics.py`) no és el rànquing de tesi.

Scripts de diagnòstic (`run_all_gens.sh`, verificacions a $n = 100$, `process_launcher.py` sobre `BattleManager`) expliquen part del còmput total de 52,7 milions de batalles; no substitueixen el llançador de la matriu Gen IX.

5.3.3 Llançador de la matriu

`benchmark.py` executa una cel·la. El producte 28×28 , el pressupost per paradigma, la represa i la recuperació de lots bloquejats els orquestra `src/p00_core/scripts/runs_benchmark/run_paradigm_comparison_10k.sh`. És la peça que tanca el disseny de la Secció 3.3 sobre l’entorn de la Secció 4.5: el coordinador no coneix Telegram ni el bucle de 784 parelles; el llançador sí.

S’invoca amb `bash src/p00_core/scripts/runs_benchmark/run_paradigm_comparison_10k.sh`. Redirigeix stdout/stderr a `paradigm_eval.log (tee)`, carrega `.env` i defineix `avis_telegram` com a POST a l’API del bot. Les llistes `NEW_AGENTS` i `ALL_AGENTS` són les 28 etiquetes de la

Taula 3.5; el producte dirigit cobreix A vs B i B vs A . Abans de cada cel·la compta files al CSV final i, si ja n'hi ha $\geq n_{\text{objectiu}}$, la salta (la mateixa font de progrés del coordinador, però a escala de matriu).

Per cada parella encara pendent crida

```
uv run python src/p00_core/engine/benchmark.py N \
  --agents A --opponents B --ports 8 --concurrency C \
  --battle-format gen9randombattle --out DIR --restart-every 20
```

amb N i C adaptats al paradigma (Taula 5.2). Un codi de sortida no nul reintenta fins a `MAX_RETRIES=100`, amb `cleanup` dels ports 8000–8040 (fuser `-k`) entre intents. Un `trap` sobre `SIGINT/SIGTERM` mata el monitor, fusiona els `_tmp_*.csv` actius al CSV final (deduplicant `battle_id`) i avisa el bot.

Taula 5.2: Pressupost que el llançador passa a `benchmark.py`. Coincideix amb la Secció 3.6; aquí es concreta en arguments.

Cel·la	n	Ports	Concurrencia
Heurístiques, IL, baselines	10.000	8	25
Minimax (v15–v17)	10.000	8	15
MCTS (v18–v20, qualsevol orientació)	1.000	8	15




Figura 5.5: Arquitectura de control i monitoratge. El llançador orquestra les 784 cel·les i emet notificacions *push*; el dimoni vigila el maquinari i atén comandes interactives.

El llançador arrenca un monitor en segon pla que, cada 60 s, inspecciona els `_tmp_*.csv` i cada 20 minuts envia el progrés de la cel·la activa. Si el lot es considera bloquejat, fusiona el progrés, mata `benchmark.py`, `worker.py` i Showdown, allibera ports i deixa que el bucle exterior reintenti (el coordinador reprèn des de les files ja escrites). La Taula 5.3 resumeix els criteris. Complementa el dimoni: aquest protegeix CPU/RAM i atén `/now` o `/pause`; el monitor recupera una cel·la que no avança.

Taula 5.3: Criteris de reinici del monitor intern del llançador. Tots acaben en fusió de CSV temporals + `pkill` + reintent.

Regla	Condicció
Telemetria 20 min	Avanç per sota del 10% (ràpids), 2% (minimax) o 5% (MCTS) de l'objectiu.
Inactivitat de fil	Un <code>_tmp_</code> sense escriptura ≥ 10 min.
Fil endarrerit	$< 10\%$ de les files del fil líder, o $< 35\%$ i idle > 2 min.
MCTS ràpid	$\geq 25\%$ dels fils han acabat i la resta no avança (2 cicles).
Sostre de cel·la	30 min (heurística), 150 min (MCTS) o 8 h (minimax) sense arribar a n .

Els avisos *push* cobreixen l'arrencada de la matriu, cada agent, cada reintent, cada fallada, el progrés cada 20 minuts, els reinicis per bloqueig, el tancament d'un agent i el final global. Juntament amb la Taula A.2 de l'Annex A.1, aquest és tot el protocol operatiu del bot.

5.3.4 Contracte BaseHeuristic1v1 i AgentFactory

La instanciació homogènia del gestor s'aplica amb el patró *Template Method*: `choose_move` (Figura 5.6). Una excepció incrementa `error_moves` i retorna una acció legal aleatòria, de manera que no bloqueja la batalla.




Figura 5.6: Pipeline de decisió compartit. Minimax, MCTS i v21 especialitzen `_select_action` (i, si cal, el hook) sense reimplementar el cicle de vida ni els comptadors.

`AgentFactory.create("v20")` és l'únic punt d'instanciació (`HeuristicFactory` n'és l'àlies). La fàbrica resol àlies històrics: `ml_advanced`, `v21` i `v21_xgboost` apunten al mateix agent; `one_step` i `safe_one_step` instancien la mateixa classe. Els agents de referència són adaptadors de `random`, `max_power`, `simple_heuristic`, `safe_one_step` i `abyssal`. Els LLM (`pokechamp`, `pokellmon`) es poden crear per la mateixa fàbrica, però no entren a la matriu.

5.4 Heurístiques v1–v14: incorporació de coneixement

La genealogia d'ablació, les ramificacions i el paper de v14 com a servei són els de la Secció 3.4 (Figura 3.6, Taula 3.1). El mòdul `src/p01_heuristics/` conté:

- `agents/internal/v1.py-v14.py`: una classe `HeuristicVN` per versió, amb `_select_action` especialitzat.
- `agents/baselines/`: `SafeOneStepPlayer` (`one_step/safe_one_step`) i l'adaptació Tera de `simple_heuristic`; `random`, `max_power` i `abyssal` es resolen a la fàbrica des de `poke-env/PokéChamp`.
- `agents/llm/`: adaptadors `PokéChamp` i `PokéLLMon` (fora de la matriu).
- `agents/__init__.py`: `get_agent_class`, que enruta també v15–v22 cap a p03/p04/p02 perquè la fàbrica tingui un sol punt d'entrada.

5.4.1 Estructura de classes i operacions compartides

`BaseHeuristic1v1` proporciona el cicle de vida, els comptadors i el recorregut de reserva. `common.py` concentra `calculate_base_damage`, `get_speed` i la càrrega singleton de dades de Showdown, de manera que v2, v3, v4 i v6 comparteixen la mateixa matemàtica de dany.

La genealogia de disseny no coincideix amb una cadena d'herència única. v3 hereta de v2 i v6 de v3; v1, v4, v5 i totes les versions a partir de v7 hereten directament de `BaseHeuristic1v1`. Cada fitxer `vN.py` especialitza `_select_action` i, a partir de v7, afegeix ajudants propis (`_estimate_matchup`, `_get_best_switch`, `_should_terastallize`).

El flux, comú a les versions avançades, és:

1. detectar un canvi forçat o una batalla incompleta;
2. executar dreceres prioritàries (debilitament segur, i més endavant final i reaccions tàctiques);
3. construir els candidats de moviment i canvi;
4. assignar una puntuació ofensiva, defensiva i estratègica;
5. decidir si la Teracristal·lització modifica el millor moviment;
6. validar l'ordre i, només si la política no en retorna cap, utilitzar una acció legal de reserva.

Taula 5.4: Correspondència entre els blocs de disseny de la Taula 3.1 i els components implementats.

Versions	Component principal implementat
v1	<code>_score</code> : potència $\times$ efectivitat $\times$ STAB; sense canvis.
v2–v3	<code>calculate_base_damage</code> ; pivots TOX i «feble i outsped»; v3 activa <code>tracks_moves</code> .
v4–v6	Modificadors de clima/terreny i prioritat; v4/v5 trien el substitut per tipus; v6 conserva el slot 0.
v7–v8	Nova <code>_estimate_matchup</code> ; v8 afegeix KO de prioritat conservador i <code>ABILITY_IMMUNITIES</code> .
v9–v11	Hazards/setup només en torn lliure; estats, sacrifici $\leq 20\%$ HP i pivots; v11 els fusiona.
v12	Tera ofensiva/defensiva i substitut forçat per puntuació d'enfrontament.
v13	Matchup amb moviments revelats, recuperació, Choice lock i Tera conservadora.
v14	Perfil <code>PREDICTIVE/CONSERVATIVE</code> , sondeig T1–3, interval de dany (0,85, 1) i solver d'un torn.

5.4.2 Decisions que no es desprenen de la genealogia

Tres decisions canvien el comportament d'una manera que la taula de disseny no detalla.

v7 no amplia v6: és una classe nova. El canvi voluntari deixa de ser «si el dany és < 20 i som més lents, slot 0» i passa a comparar la puntuació d'enfrontament de l'actiu amb la del millor company, amb llinar -2 . Aquesta funció és la que reutilitzen minimax, MCTS i v21.

v12 incorpora tant la Teracristal · lització com la resolució per aparellament dels canvis forçats per debilitament (eliminant els *fallbacks* atzarosos de les versions prèvies). La seva contribució relativa es desacobla analíticament al Capítol 6 mitjançant la telemetria de partides i el contrast de freqüència d'ús amb v13.

v14 manté estat persistent per batalla (historial d'actius, taxa de canvis, rols Win-Con / Vital Wall). L'interval de dany $(0,85 \times \text{score}, \text{score})$ existeix perquè l'HP rival a *poke-env* és sovint un percentatge, no un enter. El solver de finals només s'activa amb ≤ 2 Pokémon per bàndol i no substitueix la política completa. Aquestes peces estan orientades a rivals humans; contra polítiques deterministes poden cedir ritme.

Totes les versions registren comptadors. A v14, `ko_checks` arriba a l'ordre de 15 per partida perquè l'interval de dany s'avalua sovint.

5.5 Minimax d'un torn v15–v17

El mòdul `src/p03_minmax/agents/internal/` té tres fitxers: `v15_minimax.py`, `v16_minimax.py` i `v17_minimax_hybrid.py`. Tots hereten `HeuristicV14`. El disseny —maximin pur, tres fulles, dreceres abans de la matriu— és el de la Secció 3.4. Aquí es detalla com es construeix M . No hi ha `LocalSim`: el dany i la velocitat són analítics (`common.py`).

Abans de buscar, s'executen les dreceres de v14 (debilitament garantit; a v16/v17 també preparació rival, absorció d'estats i pivots inicials). Si cap drecera aplica, s'enumeren les accions pròpies legals contra els moviments rivals *revelats* i, si el rival té banqueta, un símbol genèric `"switch"`. La velocitat i la prioritat es resolen analíticament; `LocalSim` no intervé.

5.5.1 Construcció de la matriu

Una fila per acció pròpia, una columna per resposta considerada. Per a cada parella s'estima qui actua primer, si l'acció ràpida debilita i anul·la la segona, els HP esperats després de l'intercanvi i les bonificacions de posició de la fulla corresponent. El valor d'una acció pròpia és el mínim de la seva fila; l'agent escull la fila amb el màxim d'aquests mínims, és a dir, el criteri de l'Equació 2.23.

Aquest càlcul és barat perquè no crea una batalla simulada per cas. També és deliberadament limitat: no veu què succeeix dos torns després d'un canvi o d'un moviment de preparació. No hi ha resolució en estratègies mixtes ni cap crida a un solucionador de programació lineal, d'acord amb l'elecció de maximin pur del disseny.

La fulla de **v15** combina HP i qualitat de l'enfrontament, amb penalització $\times 1,5$ al dany rival. **v16** afegeix bonificacions de 0,25–0,35 per preparació, perills, recuperació i estats. **v17** hereta aquesta fulla i suma 0,15 al pitjor cas de l'acció que retornaria **v14**. `_select_action`, restaurant després l'historial intern perquè la consulta del prior no contaminin els comptadors.

Per saber què aporta el mòdul, abans de la cerca es demana també l'acció de **v14**. `search_diff` augmenta quan el maximin la substitueix; `search_moves` i `search_switches` descriuen el tipus d'acció resultant. La taxa d'intervenció mesurada es reporta al Capítol 6.

5.6 MCTS ras v18–v20

El mòdul `src/p04_mcts/agents/internal/` té `v18_mcts.py`, `v19_mcts.py` i `v20_mcts_hybrid.py`, tots heretant `HeuristicV14`. El pressupost és el del disseny: 100 simulacions, $C = 1,4$, rollout de 5 torns, decisió per visites, professor **v14**. El simulador local és `pokechamp/poke_env/player/local_simulation`, que el minimax no usa.

Cada procés MCTS injecta el fork `pokechamp/` al `sys.path` i desallotja els mòduls `poke_env` de PyPI, perquè `LocalSim` visqui a l'API del fork. Per a cada decisió, l'agent copia l'estat observable, crea un fill per moviment i per canvi legal, i inicialitza visites i valor. Cada iteració selecciona un fill amb UCB1 o PUCT, aplica l'acció i continua amb una política de simulació durant cinc torns. Una funció de fulla resumeix HP, debilitats, modificadors, estats i camp; aquest valor s'acumula al fill de l'arrel.

No es conserva un arbre profund entre iteracions ni entre torns reals. El cost i la interpretació són els d'un bandit a l'arrel amb simulacions, coherent amb l'MCTS ras de la Secció 2.4.3.

v18 utilitza UCB1, una fulla d'HP/estats/perills i només la drecera de debilitament. **v19** enriqueix la fulla amb rols (Win-Con $\times 1,45$, Vital Wall $\times 1,25$) i amenaça de KO, i aplica les dreceres de **v14** abans de l'arbre. **v20** substitueix UCB1 per PUCT amb prior 0,70 sobre l'acció **v14**; la fulla roman la de **v19**.

La determinització només copia moviments rivals revelats. `LocalSim` i el procés Node.js de Showdown no són el mateix motor: un objecte o un efecte no reproduït exactament introdueix soroll als valors. El minimax d'un torn no té aquesta font d'error, perquè només utilitza l'estimador analític compartit. Aquesta és l'amenaça de validesa ja identificada a la Secció 3.9.

5.7 Imitació v21–v22

L'arquitectura macro/micro, el llindar d'experts $Elo \geq 1800$ i el contrast híbrid versus pur són els de la Secció 3.4. El mòdul `src/p02_imitation_learning/` és un pipeline de quatre etapes, més un agent exploratori que no entra a la matriu:

1. `s01_download/download_dataset.py`: Hugging Face (`milkkarten/pokechamp`), format `gen9randombattle`, $Elo \geq 1800$, finestra per defecte agost 2023–març 2025; la cau va a `data/huggingface_cache`.
2. `s02_eda/`: distribucions atacar/canviar i metajoc (figures d'aquest capítol).
3. `s03_training/`: `extract_ml_features.py`, `train_ml_advanced.py` (classificador macro de **v21/v22**) i `train_v22_pure_il.py` (avaluador de moviments de **v22**).
4. `s04_agent/`: `v21_xgboost.py` i `v22_pure_il.py`. `ml_baseline.py` és un classificador de cinc columnes fora de la matriu.

Una repetició no conté l'objecte `Battle` que l'agent veu en línia (Figura 3.3). L'extractor reconstrueix, torn a torn, HP, camp, Tera, identitat dels actius i acció observada. La llista de característiques desada amb el model garanteix que l'agent en producció generi les columnes en el mateix ordre que durant l'entrenament.

5.7.1 Dades i entrenament

El conjunt avançat té de l'ordre d'**1,1 milions** de torns. `extract_ml_features.py` (`-mode advanced`) reconstrueix l'estat tabular amb Polars i desa un Parquet; el mode `baseline` (cinc columnes) només s'usa per a un agent exploratori fora de la matriu. L'entrenament macro —script `train_ml_advanced.py`— fa un `GroupShuffleSplit` per `battle_id` per no filtrar informació intra-partida, aplica `scale_pos_weight` al desequilibri atacar/canviar i calibra el llindar de decisió sobre la corba precisió-record del conjunt de test. El model resultant té aproximadament **1.150** columnes després del one-hot d'espècies. El fitxer `xgboost_advanced_threshold.json` desa $\tau_{\text{recomanat}} = 0,5525$ (juntament amb els punts F1 i d'igualació de freqüència); l'agent el carrega en temps d'inferència.




Figura 5.7: Validació exploratòria de les repeticions humanes: desequilibri entre atacar i canviar, evolució de la taxa de canvi amb el torn i espècies més representades. La figura descriu el conjunt de dades, no el rendiment final de l'agent.

La classe «canviar» representa aproximadament el 25,8% dels torns. La taxa és especialment alta al començament —on també hi ha canvis forçats o ajustos de posició— i disminueix amb la durada.




Figura 5.8: Taxa de canvi humana per espècie activa en una selecció del conjunt d'experts. La variació justifica incloure identitat i context, però no implica causalitat.

5.7.2 Adaptadors en línia

v21 (HeuristicV21XGBoost) hereta `HeuristicV14`. L'ordre d'execució és el del disseny híbrid: KO garantit, solver de finals, reacció a atacants d'escombrada (*sweepers*) i absorció d'estats *abans* del classificador. El vector en viu replica les 1.150 columnes, amb normalització alfanumèrica dels noms d'espècie per no perdre formes regionals. Una protecció de bucle (*loop guard*) força «atacar» si el model ha demanat canviar dos tornos seguits. Si la macro-decisió és canviar i existeix un pivot legal i segur, s'executa *U-turn/Volt Switch* en lloc d'un canvi sec; si no, `_get_best_switch` de v14. L'atac el puntua el mateix `_score_move` heurístic.

v22 (HeuristicV22PureIL) hereta només `BaseHeuristicv1`. Reutilitza el classificador macro i afegeix `xgboost_move_evaluator.json`, entrenat amb candidats sintetitzats (potència, STAB, efectivitat, prioritat, HP, torn), no amb identitats de moviment de les repeticions. El substitut es tria per contrafactual: per a cada candidat de banqueta es regenera el vector com si fos l'actiu i es queda el de menor $p(\text{canvi})$. No hi ha dreceres de v14.

5.8 Baselines i agents de llenguatge

Els sis controls de la Secció 3.4 s'instancien per la fàbrica d'agents. `random` i `max_power` provenen de *poke-env*; `simple_heuristic` s'adapta a la Teracristal·lització, i `abyssal` es recupera del projecte PokéChamp. Per a `one_step` i `safe_one_step`, l'adaptador `SafeOneStepPlayer` avalua $\text{base_power} \times \text{STAB} \times \text{efectivitat} \times \text{precisió}$ d'un pas sense cridar `LocalSim`.

La integració dels agents basats en LLM (**PokéChamp** i **PokéLLMon**) es localitza a `src/p01_heuristics/agents/llm/`. L'arquitectura d'inferència s'articula mitjançant un servidor local **Ollama** [69] accelerat per GPU amb **NVIDIA CUDA** [72], executant models oberts com ara *Qwen 2.5 7B* [73] o *Llama 3*. L'adaptador serialitza l'estat observable de Showdown en un prompt textual estructurat (HP, modificadors, moviments vistos i taula d'efectivitats) i demana una decisió amb raonament CoT. En execució paral·lela amb múltiples treballadors, la consulta simultània al servidor Ollama genera colls d'ampolla a la memòria VRAM i commutacions de context a CUDA. La latència observada (~ 40 minuts per partida completa) confirma empíricament la decisió de disseny de la Secció 3.8 d'excloure els LLMs de la matriu massiva de 28×28 .

5.9 PPO: MaskablePPO sobre Showdown

`src/p05_ppo_drl/` materialitza el cinquè paradigma i l'experiment separat contra v12 (Secció 3.4.6). Els resultats numèrics es llegeixen al Capítol 6; aquí es documenta l'entorn, el clonatge i com s'han executat les fases.

5.9.1 Organització del mòdul i dels artefactes

- `s01_env/`: `pokemon_env.py` (PokemonMaskedEnv sobre `SinglesEnv`), `vectorizer.py` (328-d congelat; 346-d només fase 4), `actions.py` (màscara i `Discrete(14)`).
- `s02_training/`: `loop.py` i `showdown.py` (arrencada de servidors dins de l'entrenament); `bc.py`; `train_p1_base.py`, `train_p1_5_tune.py`, `train_p2_v8.py`, `train_p3_v12.py`; `train_p4_v14.py` (interromput); `callbacks.py` i `plots.py`.
- `s03_evaluation/`: `eval_checkpoint.py`, `ppo_player.py` (índex $\rightarrow$ /choose), `benchmark_rl.py`.
- `tests/`: màscares, vectoritzador i pas CUDA en davant; no substitueixen l'avaluació de 10.000 partides.
- `constants.py`: format i mida d'acció compartits per entrenament i eval.

Els pesos viuen a `data/models/ppo/`, un directori per fase (`p1_random`, `p15_maxbp`, `p2_v8`, `p3_v12`). `plots/` conserva hiperparàmetres i corbes; `eval/`, els JSON de `eval_checkpoint.py`. PPO no escriu les 70 columnes de la matriu: és un experiment apartat, amb resum de victòries en JSON i a `src/p05_ppo_drl/RESULTS.md`.

5.9.2 Entorn

`PokemonMaskedEnv` encapsula `SinglesEnv` de *poke-env* sota el mateix contracte de la Secció 3.2. L'observació és el vector de **328** dimensions de la Taula 5.5, la representació congelada del disseny. Les fases 1 i 1.5 n'utilitzaven 318; una extensió posterior n'afegeix 18 (fase 4), però correspon a un experiment interromput i no al resultat principal.

Taula 5.5: Composició del vector d'observació de MaskablePPO. El model A publicat té 328 dimensions; les fases 1 i 1.5 n'utilitzaven 318 (sense dany estimat ni enfrontaments de canvi). Les 18 dimensions addicionals de la fase 4 no entren al resultat principal.

Bloc	Dim.	Contingut
Actiu propi / rival	35 + 35	HP, tipus, condició d'estat i set etapes de modificadors.
Moviments	84 + 4 + 4	Tipus i potència dels 4 slots, PP i STAB×efectivitat.
Banc propi i rival	6 × 6 + 1	HP, debilitats, indicador de capdavanter i estimació de supervivents rivals.
Camp	9 + 14 + 24 + 24	Clima, terreny i condicions laterals d'ambdós bàndols.
Teracristal · lització	3 + 20 + 20	Disponibilitat, ús previ i tipus Tera.
Velocitat i restriccions	5	Comparació de velocitat, <code>force_switch</code> i <code>trapped</code> .
Afegits de fase 2	4 + 6	Dany estimat dels 4 moviments i enfrontament dels 6 canvis.
Total model A	328	Vector en $[0, 1]$, compatible amb els checkpoints de les fases 2 i 3.
Extensió de fase 4	+18	Enfrontaments del banc revelat, millor capdavanter, dany/defensa Tera i cost de perills.

L'acció és `Discrete(14)`, amb la legalitat de la Taula 5.6. A cada pas es calcula una màscara que exclou moviments sense PP, una Tera ja consumida i canvis a posicions no disponibles—l'emascarament de l'Equació 2.30. `PPOPlayer` tradueix l'índex a `/choose`, també durant un canvi forçat.

Taula 5.6: Espai d'accions `Discrete(14)` de MaskablePPO. La màscara de legalitat i la traducció a `/choose` comparteixen el mateix mapeig de slots [2].

Índex	Acció	Quan és legal
0–3	Moviment i de l'actiu	El slot té un moviment amb PP i no hi ha canvi forçat.
4–7	Moviment i + Teracristal · litzar	El moviment i és legal i la Tera encara no s'ha consumit.
8–13	Canvi a l'slot i de l'equip	El membre existeix, no està debilitat, no és l'actiu i no hi ha bloqueig de canvi.




Figura 5.9: Pas d'inferència de MaskablePPO. La màscara s'aplica abans de mostrejar; l'índex s'envia com a ordre de Showdown, no com a enter cru.

5.9.3 Clonatge, arquitectura i recompensa

El warm-start de la fase 2 es materialitza a `bc.py`: tuples (o, m, a) d'observació, màscara i acció a partir del professor `v8`. L'ajust aplica entropia creuada emmascarada només a l'actor, amb Adam a 10^{-3} durant 15 èpoques; no reutilitza la taxa de PPO. Es recullen 400 partides de `v8` (8.849 decisions). L'acord amb el professor passa del 43% al 88%, i la freqüència de canvi predita s'apropa a la del professor (21% davant del 23%). El clonatge no és el resultat final: situa la xarxa en una regió que ja produeix accions semblants a una política competent.




Figura 5.10: Seqüència clonatge → reforç. El crític no s'entrena al clonatge; PPO n'aprèn el valor a partir de la recompensa modelada un cop l'actor ja imita el professor.

MaskablePPO [50, 66, 74] s'executa sobre PyTorch [67]. Política i valor utilitzen dues capes de 256 unitats. Els scripts registren `n_steps=2048`, $\gamma = 0,99$ i quatre èpoques d'actualització; el lot és de 256 amb quatre entorns i de 512 amb vuit o més. El model A publicat utilitza observació de 328 dimensions, vuit entorns i taxa 5×10^{-5} .

La recompensa d'entrenament combina 30 punts per victòria, 2 per diferència de debilitats, 1 per diferència d'HP, increments per modificadors ofensius, estats i perills al camp rival, penalització pels perills propis, i un cost de 0,02 per pas. El codi desa el valor potencial anterior i només afegeix la diferència de la part tàctica, per no premiar indefinidament el mateix estat. L'avaluació final ignora aquesta funció i només compta victòries, com estableix el disseny.

5.9.4 Execució de les fases 1, 1.5, 2 i 3

La Taula 5.7 registra com s'ha operacionalitzat cada porta de la Taula 3.2: oponent, dimensions, entorns, artefacte. Les taxes de validació congelada es llegeixen al Capítol 6 (Taula 6.17).


Taula 5.7: Artefactes i hiperparàmetres del currículum PPO. Les portes numèriques (90%, > 70%, > 55%) són les del disseny; el resultat de cada porta és al Capítol 6.

Fase	Oponent	Canvi implementat	Artefacte
1	Random	PPO inicial, 318 dimensions, 4 entorns, 500k passos.	<code>p1_random</code>
1.5	MaxBP	Reprèn fase 1; taxa 2×10^{-4} , 500k passos.	<code>p15_maxbp</code>
2	<code>v8</code>	Amplia a 328 dimensions, 400 partides de clonatge, 8 entorns.	<code>p2_v8</code>
3	<code>v12</code>	Continua des de fase 2; taxa 5×10^{-5} , 8 entorns.	<code>p3_v12_lr5e5_flat.zip</code>


La fase 1 verifica legalitat sobre Random. La fase 1.5 reprèn sense aturada prematura (una primera avaluació intermèdia es va descartar). La fase 2 amplia l'observació de 318 a 328 dimensions. Les primeres passades només amb PPO no sortien de la zona del professor dèbil; un primer clonatge reutilitzava l'optimitzador de PPO a 5×10^{-5} i gairebé no ajustava l'actor. La versió final separa els optimitzadors, clona 400 partides i continua 100.000 passos de PPO. D'acord amb el disseny —continuar cap a `v12` encara que una porta falli— el currículum no s'atura.

La fase 3 prova dues configuracions. El checkpoint de tesi és el model A, `p3_v12_lr5e5_flat.zip`, amb taxa 5×10^{-5} i vuit entorns. Una passada secundària amb taxa $1,5 \times 10^{-4}$ i setze entorns produeix la corba guardada al directori de fase 3, però no és el punt de control de les 10.000 partides.


`eval_checkpoint.py` carrega un checkpoint sense actualitzar-lo, l'associa a un `PPOPlayer` i juga en una o dues orientacions. El model A es prova contra `v12` en 10.000 partides —el protocol




(a) Fase 1 contra Random.



(b) Fase 1.5 contra MaxBP.



(c) Fase 2 contra v8.



(d) Passada secundària de fase 3 contra v12.

Figura 5.11: Corbes de les quatre etapes del currículum: taxes durant l'entrenament sobre una política canviant. Les validacions independents són la Taula 6.17. El panell de fase 3 correspon a la passada secundària, no al model A publicat.

de la Secció 3.8— i contra Random en 1.000 com a control. El codi impedeix sobreescrivre accidentalment el fitxer principal.

Una extensió posterior amplia l'observació a 346 dimensions i clona v14 contra v12. S'interromp al voltant de 340.000 passos i es presenta només com a diagnòstic. No substitueix el model A.

5.10 Desplegament a la classificació pública

El protocol de validesa externa de la Secció 3.8 es materialitza a `src/p00_core/online_bot/run_online_bot.py`. El bot connecta qualsevol etiqueta d'AgentFactory al servidor públic, en mode de classificació (`ladder`) o d'acceptació de reptes (`accept`). La mostra analitzada correspon a v14, usuari SirPThesis, els dies 9 i 10 de juny de 2026, amb 431 partides. Aquesta avaluació no és una fila de la matriu local.

5.10.1 Arquitectura del client i autenticació

El client és asíncron (`websockets` + `asyncio`) i segueix el protocol oficial:

1. Connexió al WebSocket públic (`sim3.psim.us / showdown`).
2. Recepció del desafiament del servidor (`challstr`).
3. Autenticació HTTP POST a `play.pokemonshowdown.com/action.php`.
4. Enviament de l'assertió (`/trn <username>,0,<assertion>`) per registrar SirPThesis.

5.10.2 Tolerància a fallades

- **Reconnexió:** reintent amb espera exponencial davant de pèrdua de socket.
- **Timer:** si l'agent no respon en menys de 10 segons, s'envia una acció legal de reserva per evitar la derrota per temps.
- **Limitació de freqüència:** esperes entre comandes per no activar el *spam throttle* del servidor.

5.11 Síntesi i continuïtat

El Capítol 3 ha tancat el disseny; aquest capítol n'ha recollit la construcció. El nucli `p00_core` implementa el gestor, el llançador de 784 cel·les, `StatsBattle` i el pipeline d'informes; `p01-p04` materialitzen les famílies de la matriu 28×28 ; `p05` executa el currículum MaskablePPO fora d'aquesta matriu; i `online_bot` connecta `v14` a la classificació pública. El Capítol 6 llegeix els CSV, les validacions congelades de PPO i la mostra del *ladder* sota aquestes mateixes etiquetes.

Capítol 6

Resultats

Aquest capítol llegeix els artefactes del Capítol 5 sota el protocol del Capítol 3. No es reobren el POSG, l'ablació ni el motor: aquí es mesura. Tres ancoratges es donen per fixats: **v12** és el millor resultat *observat* a la matriu; **v14** és l'heurística de *servei* (fulla, prior, executor i bot de *ladder*), no el sostre de rendiment; MaskablePPO s'avalua fora de la matriu, contra **v12**.

Les fonts internes són els 784 CSV de `data/benchmarks/all_10k/gen9randombattle` —6.409.000 partides dirigides—, produïts pel pipeline de la Secció 5.3.2 (`generate_heatmap.py`, `elo_ranking.py`, informes a `src/p00_core/reporting/agents/`) i `src/p05_ppo_drl/RESU LTS.md`. Un **resultat observat** és una taxa o un comptador; una **interpretació** relaciona indicadors amb el disseny; una **hipòtesi explicativa** requeriria una ablació nova per confirmar-se.

6.1 Protocol de lectura dels resultats

28 agents, cadascun com a *nosaltres* contra 28 oponents, format `gen9randombattle`, estructurats segons la taxonomia de la Taula 6.1. Fitxers dirigits `A_vs_B.csv`. PPO es llegeix a part (Secció 6.11).

Taula 6.1: Taxonomia dels 28 agents de la matriu `gen9randombattle`. Els identificadors de codi es mantenen en anglès. El prefix del mapa de calor indica la família: (H) heurística, (MM) minimax, (MCT) MCTS, (IL) imitació i (B) agent de referència. El PPO s'avalua separatament contra **v12**.

Identificadors	Paradigma	Descripció
<code>random</code> , <code>max_power</code> , <code>one_step</code> , <code>safe_one_step</code> , <code>abyssal</code> , <code>simple_heuristic</code>	Referències (B)	Agents de <i>poke-env</i> i PokéChamp: atzar, potència base, un pas de dany i regles d'enfrontament.
<code>v1-v14</code>	Heurístiques (H)	Seqüència incremental de coneixement: dany, posició, perills d'entrada i Teracristal · lització, entre altres components.
<code>v15-v17</code>	Minimax d'un torn (MM)	Maximin analític d'un torn amb <code>HeuristicV14</code> com a base.
<code>v18-v20</code>	MCTS ras (MCT)	UCB a l'arrel i 100 simulacions de cinc torns amb <code>LocalSim</code> ; cel · les amb $n = 1.000$.
<code>v21</code>	Imitació híbrida (IL)	XGBoost decideix atacar o canviar i <code>v14</code> executa l'acció.
<code>v22</code>	Imitació (IL)	El mateix classificador d'alt nivell; el model de moviments puntua potència, STAB i efectivitat.

La fila és l'agent analitzat i la columna, l'oponent. Un 59,91 a la cel·la $v12 \times$ Abyssal indica 5.991 victòries de 10.000 en aquell fitxer dirigit.

Cada cel·la és una proporció binomial. Els intervals són Wilson al 95% (Equació 2.15); els tres pisos mostrals són els de la Taula 3.4. A $n = 10.000$ el marge màxim d'una taxa individual és de $\pm 0,98$ pp; a $n = 1.000$ (totes les cel·les MCTS), $\pm 3,10$ pp. La Pokédex no entra a $\text{Var}(\hat{p})$: s'estima una taxa marginal sota el generador d'equips de la Generació IX.

Per a la comparació entre dues condicions o agents independents, s'aplica el contrast de dues proporcions (Equacions 2.19–2.20): a $n = 10.000$, la diferència mínima detectable per a una significança estadística al nivell $\alpha = 0,05$ és de $|\Delta\hat{p}| \geq 1,39$ pp ($z \geq 1,96$, tercera columna de la Taula 3.4); a $n = 1.000$, el llindar és de $|\Delta\hat{p}| \geq 4,38$ pp. Les diferències inferiors a aquests llindars es troben dins el marge d'error conjunt i es consideren empats tècnics o variacions no significatives que no admeten interpretació de superioritat.

- Fila no MCTS: **253.000** partides (25×10.000 i 3×1.000 contra MCTS).
- Fila MCTS: **28.000** partides (28×1.000).
- Matriu: **6.409.000** partides dirigides. Les orientacions recíproques sumen $\approx 100\%$ i l'autojoc se situa prop del 50%.

La taxa global d'una fila no MCTS pondera els oponents MCTS deu vegades menys; en una fila MCTS tots pesen igual. La comparació entre paradigmes es basa en cel·les comunes—especialment contra $v12$ —, no en una única ordenació global. Les proves de desenvolupament amb 100 partides no entren a les conclusions.

6.2 Controls globals de la matriu

Abans d'interpretar versions concretes, es comproven la cobertura, la distribució de taxes i la durada de les batalles sobre les 784 cel·les dirigides:

- **Cobertura:** La reducció mostral segueix estrictament el paradigma (10.000 partides per cel·la al bloc general i 1.000 a MCTS pel cost computacional de les simulacions), assegurant la consistència del banc d'avaluació.
- **Distribució de taxes:** La taxa de victòries es concentra al voltant del 50% (autojoc i duels equilibrats) amb acumulacions als extrems (0% i 100%) degudes a referències febles (`random`, `max_power`). Per aquest motiu, la taxa global no s'interpreta com una habilitat absoluta: millorar contra oponents febles té un valor discriminant molt limitat.

Pel que fa a la durada (Figura 6.1), la mediana se situa clarament en 17 torns (amb el gruix entre 10 i 25 torns) i presenta una cua dreta per atrició defensiva o bucles de canvis. Com que dues polítiques poden assolir una mateixa taxa tancant ràpidament o bé dilatant el combat per conservació de recursos, les anàlisis posteriors combinen sempre torns, supervivents finals i motiu dels canvis.

6.3 Fil conductor de $v1$ a $v22$

La Taula 6.2 resumeix la seqüència abans d'analitzar-la. Les taxes globals són descriptives i no fan comparable l'MCTS amb la resta a causa de la ponderació diferent; la seva funció aquí és mostrar els canvis de règim.

La primera meitat de la seqüència acumula coneixement explícit fins a $v12$. La segona canvia de paradigma, però la majoria de decisions encara passen per dreceres o priors derivats de $v14$. El




Figura 6.1: Distribució de la durada de les batalles analitzades. La mediana és de 17 torns i hi ha una cua dreta de partides excepcionalment llargues.

Taula 6.2: Evolució de les preguntes i dels resultats entre v1 i v22.

Versions	Pregunta que materialitzen	TV global	Patró observat
v1–v6	Fins on arriba refinar dany i ordre immediat?	44–46%	Altiplà; telemetria gairebé invariable.
v7, v8, v10	Què aporta valorar la posició i canviar?	54–56%	Salt a v7; afegits posteriors petits.
v9, v11	Preparació i perills només en torns segurs?	59%	Nou augment i aparició dels comptadors de ritme.
v12	Què aporten Tera i el substitut informat?	69,01%	Increment més gran i 59,91% contra Abyssal.
v13, v14	Més inferència i model del rival sempre ajuden?	67,63 / 62,03%	Inversió: més complexitat, menys taxa global.
v15–v17	Un maximin d'un torn corregeix v14?	53,80–57,89%	La variant guiada discrepa menys i és la millor.
v18–v20	Cinc torns simulats superen l'horitzó curt?	53,29–59,66%	PUCT millora UCB1, però no supera v12.
v21, v22	Es pot imitar quan atacar o canviar?	58,71 / 33,49%	L'executor heurístic és determinant.

patró general no és «algorisme més sofisticat, agent més fort», sinó «representació i coneixement adequats, seguits d'un mòdul que no els destrueixi».

PPO no rep un número v23 ni forma part de la taula global. La seva pregunta és paral·lela: si una política neuronal inicialitzada amb v8 pot arribar a v12. El resultat de 34,1% contra aquest comparador es tracta a la secció 6.11.

6.4 L'escala heurística: tres canvis de règim

La Taula 6.3 i la Figura 6.2 sintetitzen l'evolució de la taxa de victòries global al llarg de la seqüència heurística v1–v14.

6.4.1 Altiplà v1–v6: rendiments decreixents del càlcul de dany

La taxa global recorre **1,61 pp** (44,25–45,86%). Els enfrontaments interns se situen prop del 50%, mentre que contra Abyssal obtenen entre el 30,6% i el 32,5%.

Taula 6.3: Seqüència heurística v1–v14 (253.000 partides per fila). La taxa global no creix de manera monotònica: els increments principals apareixen a v7, v9 i v12, i les dues versions posteriors disminueixen.

Agent	Règim	TV (%)	contra Abyssal	Incorporació principal
v1–v6	Altiplà	44,25–45,86	30,6–32,5	Dany, clima, modificadors i canvis simples
v7	Posicional	54,25	40,80	Dany modificat i canvi segons l'enfrontament
v8	Posicional	55,43	42,30	KO de prioritat conservador i immunitats conegudes
v9	Ritme segur	58,86	46,64	Perills i preparació <i>només en torns lliures</i>
v10	Posicional	55,66	41,86	Status, sacrifici $\leq 20\%$ HP, U-turn
v11	Ritme segur	59,26	47,50	Combinació de v9 i v10
v12	Mecànica Gen. IX	69,01	59,91	Tera i selecció del substitut
v13	Moviments revelats	67,63	55,34	Enfrontament amb moviments revelats i Tera conservador
v14	Model de rival	62,03	51,36	Perfil, sondeig inicial, rang de dany i final d'un torn




Figura 6.2: Taxa global de victòries de v1–v14 (253.000 partides per fila; les tres cel·les contra MCTS tenen $n = 1.000$). S'observen canvis destacats a v7, v9 i v12, seguits d'una disminució a v13 i v14.

En aquestes versions, afinar la fórmula de dany després d'incorporar efectivitat i STAB mostra rendiments decreixents. Els increments posteriors apareixen quan s'afegeixen decisions posicionals i recursos específics del format.

En el conjunt de la matriu (253.000 partides per fila; mitjanes ponderades per nombre de partides), registren aproximadament 1,02 canvis voluntaris per partida, cap Teracristal · lització i uns 4,6 recursos de reserva. Aquest perfil correspon a una política principalment ofensiva amb poca gestió posicional.

6.4.2 Primer salt: v7 (i v8/v10)

v7 incorpora dany amb modificadors i canvis segons l'enfrontament. La taxa global passa d'aproximadament 45,5% a **54,25%**; contra Abyssal, d'aproximadament 32% a **40,8%**.

v8 (KO de prioritat conservador i immunitats d'habilitat ja revelades) afegeix 1,2 pp. v10 (estats, sacrificis i moviments de pivot) obté una taxa similar a v8 (55,66% i 55,43%).

La telemetria també canvia: els canvis voluntaris pugen a 1,47 per partida, `matchup_switches` arriba a 0,41 i les accions de reserva baixen d'aproximadament 4,6 a 2,18. L'agent passa a seleccionar canvis de manera explícita.

Els perills d'entrada i els moviments de preparació s'incorporen a **v9**; els comptadors `setup_uses` i `hazard_sets` deixen de ser zero.

6.4.3 Segon salt: **v9** / **v11**

Amb **v9**, els perills d'entrada i els moviments de preparació només s'utilitzen quan l'agent és més ràpid i resisteix l'STAB rival. La taxa global puja a **58,86%** i el resultat contra Abyssal a **46,64%**. **v11** combina aquest bloc amb **v10** i afegeix 0,4 pp; la contribució addicional és petita en aquesta matriu.

v9/v11 són els primers amb aproximadament 1,6 moviments de preparació i 0,16 perills d'entrada per partida.

6.4.4 Tercer salt: **v12**

v12 combina la Teracristal · lització i la selecció informada del substitut després d'un debilitament. La taxa global assoleix el **69,01%**, suposant el major increment de tota la seqüència (+9,8 pp respecte al 59,2% de **v11**). És, a més, el primer agent intern que supera amb claredat Abyssal i Simple Heuristic: **59,91%** i **59,75%**, respectivament ($n = 10.000$, tal com s'il·lustra a la Figura 6.3 enfront dels comparadors discriminants).

En la telemetria de matriu (recollida en l'empremta tàctica de la Figura 6.4), utilitza la Teracristal · lització **0,96 vegades per partida**, registra només **0,01** accions de reserva i conserva **1,84** Pokémon, davant d'1,44 a **v11**. El canvi de comportament és substancial.

Tot i que totes dues millores s'introdueixen conjuntament en aquesta versió, la telemetria granular de la matriu permet desacoblar observacionalment la contribució relativa de cada mecanisme:

1. **Impacte de la selecció del substitut (eliminació de *fallbacks*):** A les versions prèvies (**v1**–**v11**), la manca d'un gestor per als torns forçats per debilitament feia que l'agent invoqués el mecanisme per defecte (`fallback_moves_us`), seleccionant el substitut d'entrada uniformement a l'atzar. A **v12**, la resolució per aparellament (`_get_best_switch`) redueix les accions de reserva de $\sim 3,5$ a pràcticament zero (0,01 per partida), evitant que l'agent regali la iniciativa entrant en desavantatge elemental greu.
2. **Impacte de la Teracristal · lització (el contrast natural amb **v13**):** A la versió immediatament posterior (**v13**), la selecció informada del substitut es manté intacta, però l'ús de la Teracristal · lització es restringeix dràsticament, caient un **79%** (de 0,96 usos per partida a **v12** a només 0,20 a **v13**). Malgrat aquesta reducció massiva de la Tera, el rendiment global només retrocedeix $\approx 2,0$ pp (de 69,01% a 67,01%), el duel directe entre totes dues queda en empat virtual (50,65% vs 48,85%, separat per només 1,8 pp, Taula 6.4; el test de proporció respecte al 50% d'equilibri llança $z = 1,30$, $p = 0,19$ per a **v12**, confirmant que la desviació respecte a la paritat és estadísticament no significativa) i **v13** fins i tot supera **v12** enfront de la cerca i la imitació (Taula 6.5).

Aquest contrast observacional demostra que el gruix principal del salt (≈ 7 – 8 pp) s'atribueix a l'eliminació dels canvis forçats atzarosos i a l'estabilització del posicionament tàctic, mentre que la Teracristal · lització afegeix un marge incremental d'aproximadament ≈ 2 pp gràcies a la bonificació de dany elemental i la flexibilitat defensiva.




Figura 6.3: v1–v14 contra els quatre agents de referència discriminants ($n = 10.000$ per cel · la): Abyssal, Simple Heuristic, `one_step` i `safe_one_step`. v12 és el primer que deixa Abyssal i Simple Heuristic clarament per sota del 50%. Random i MaxBasePower s'ometen: contra Random totes les heurístiques arriben al 97–98% i la columna no discrimina.




Figura 6.4: empremta tàctica de la seqüència heurística (mitjanes ponderades de la matriu). v12 utilitza la Teracristal · lització gairebé una vegada per partida; v13, 0,20 vegades. `ko_checks` augmenta fins a aproximadament 15 a v14; la preparació i els perills d'entrada apareixen a partir de v9.

6.5 La inversió entre v12, v13 i v14

La complexitat creix de v12 a v14, però la taxa global observada disminueix. Aquest resultat mostra que l'herència de funcionalitats no implica una millora monotònica.

Tal com reflecteix la Taula 6.4, les dues orientacions de v12 i v13 difereixen només en 1,8 pp (50,65% i 48,85%) i no aporten una separació concloent (enfront de la paritat del 50%, $z = 1,30$, $p = 0,19$ a l'orientació directa i $z = 2,30$, $p = 0,02$ a la recíproca; la taxa combinada de les 20.000 partides és del 50,90%, situant la desviació en un marge pràcticament negligible de < 1 pp). En canvi, v14 queda clarament per sota de tots dos en els enfrontaments directes de manera estadísticament inequívoca (44,74% davant v12, $z = 10,52$, $p < 10^{-15}$, i 41,60% davant v13, $z = 16,80$, $p < 10^{-15}$).

Taula 6.4: Enfrontaments directes, amb $n = 10.000$ partides independents per orientació. **v12** i **v13** no presenten una separació conclouent ($z = 1,30$, $p = 0,19$ respecte a la paritat del 50%); **v14** queda per sota de tots dos amb diferències estadísticament inequívokes ($p < 10^{-15}$). Les sumes recíproques properes al 100% són un control de coherència, no una prova amb partides aparellades.

Fitxer	TV (%)	Recíproc (%)	Suma
v12_vs_v13	50,65	48,85	99,50
v12_vs_v14	56,01	44,74	100,75
v13_vs_v14	57,71	41,60	99,31

6.5.1 On v13 encara guanya

No està estrictament dominat. És el **millor heurístic contra cerca i contra l'IL híbrid**:

Taula 6.5: Rendiment comparatiu de **v12**, **v13** i **v14** contra cerca, imitació i blocs de control (taxa de victòries en %).

Oponent	v12	v13	v14
Minimax v15	63,96	67,59	60,07
Minimax v17	60,37	64,12	56,70
MCTS v18 ($n = 1k$)	66,1	67,7	59,8
IL v21	59,12	62,46	54,74
Baselines (bloc)	76,91	74,36	71,06
Altres heurístiques (bloc)	67,01	64,71	58,58

6.5.2 Per què no supera v12 en global

En la telemetria de matriu, **v13** utilitza la Teracristal · lització 0,20 vegades per partida, davant de 0,96 a **v12**; també fa notablement més canvis voluntaris (3,58 davant d'1,37 a **v12**) i més canvis per enfrontament (2,57 davant de 0,25). Aquest comportament preserva més membres de l'equip al final de la batalla (2,01 Pokémon restants davant d'1,84 a **v12** i 1,49 a **v14**) i allarga la durada mitjana (19,1 torns enfront dels 17,9 de **v12** i 18,5 de **v14**). Tanmateix, la freqüència de canvi per si sola no mesura la qualitat de la política: pot cedir la iniciativa i regalar torns de dany gratuït contra oponents deterministes, explicant per què **v12** assoleix una taxa global superior malgrat acabar amb menys recursos. Les dades són compatibles amb aquesta explicació, però no aïllen causalment cadascun dels mecanismes.

6.5.3 Especialització de v14 i pèrdua de rendiment local

v14 incorpora modelatge de patrons humans, sondeig inicial, Teracristal · lització defensiva, un interval aproximat de dany i resolució d'un torn al final de la partida. Contra agents deterministes, aquests mecanismes poden consumir torns sense obtenir informació útil:

- El sondeig inicial substitueix algunes accions ofensives.
- El perfil de l'oponent aporta poc quan la política rival és fixa.
- **ko_checks** arriba a aproximadament 15 per partida, mentre que **setup_uses** baixa a 0,22.
- Contra Abyssal obté **51,36%**; **v12** obté **59,91%**.

En aquest banc de proves, afegir modelatge d'oponents humans redueix el rendiment agent-contra-agent (Figura 6.5). Això indica una possible especialització de domini i justifica mantenir separades la matriu local i l'avaluació pública.




Figura 6.5: Taxa de victòries de la inversió, agregada per paradigma d'oponent. v12 és millor contra agents de referència i altres heurístiques; v13, contra minimax, MCTS i imitació híbrida.

La mostra pública de v14 (secció 6.10) no permet reordenar v12 i v14; de la mateixa manera, la matriu local no permet afirmar quin dels dos obtindria més victòries contra persones.

6.6 Minimax d'un torn

La pregunta de disseny —si un maximin d'un torn corregeix **v14**— és la de la Secció 3.4. Aquí es mesura amb quina freqüència s'executa el mòdul i quan la seva acció difereix de la proposta heurística (Taula 6.6).

Taula 6.6: Minimax analític d'un torn (253.000 partides per fila). La cerca s'executa en aproximadament el 16–18% dels torns. La fulla posicional de **v16** gairebé no modifica la preparació; el prior de **v17** redueix la discrepància respecte de **v14** i obté la taxa més alta de la família.

	v15 HP	v16 bonuses	v17 prior +0,15
TV global (%)	53,80	54,30	57,89
IC 95% (pp)	$\pm 0,19$	$\pm 0,19$	$\pm 0,19$
Cerca (% torns)	17,6	17,6	16,3
Discrepància amb v14 (%)	66,5	67,3	36,6
Preparació / partida	0,21	0,21	0,21
Perills / partida	0,05	0,04	0,04
Tera / partida	0,40	0,39	0,38
Pokémon restants	1,28	1,29	1,39

6.6.1 Freqüència d'intervenció

Es registren aproximadament 14 comprovacions de debilitament i 4,5 decisions maximin per partida, tal com resumeix l'empremta tàctica de la Figura 6.7. La matriu de cerca s'utilitza en el **16–18% dels torns**; la resta es resol principalment amb les regles prioritàries heretades.

Un agent **v14** que prioritza debilitaments garantits i aplica una anàlisi maximin d'un torn a les decisions restants.

Aquest patró és comparable al de **v21**, que consulta XGBoost en aproximadament el 15% dels torns, i al de les variants MCTS. Les partides perdudes presenten una discrepància mitjana superior (taxa de `search_diff` per torn, detallada a la Figura 6.6); és una associació, no una prova causal.




Figura 6.6: Taxa de discrepància respecte de **v14** en els torns en què s'executa el minimax. **v15/v16** discrepen aproximadament en el 67% dels casos; **v17**, amb prior +0,15, en el 37%.

6.6.2 **v16** i l'avaluació de la fulla

v16 incorpora bonificacions per moviments de preparació i perills d'entrada. La taxa global només augmenta 0,50 pp i els enfrontaments directes queden prop del 50%. Les freqüències

de preparació (0,213 i 0,207 per partida) i de perills d'entrada (0,044 i 0,049) pràcticament no canvien. Amb aquesta funció de fulla, el terme de dany rival continua dominant les bonificacions de llarg termini.

La discrepància es manté al voltant del 67%. Per tant, enriquir la fulla en aquesta magnitud no modifica substancialment la política.

Aquest resultat és coherent amb una limitació d'horitzó: afegir una bonificació estàtica no equival a simular les conseqüències futures d'un moviment de preparació.

6.6.3 v17: prior heurístic

v17 afegeix 0,15 al valor de l'acció proposada per v14. La discrepància baixa del 67% al 37% i la taxa global augmenta 4,1 pp respecte de v15 (diferència altament significativa sobre les 253.000 partides agregades, $z \approx 29,3$, $p < 10^{-50}$). En els enfrontaments directes obté 54,7% i 54,3% contra v15 i v16 ($n = 10.000$; tests de proporció contra paritatat $z = 9,40$ i $z = 8,60$, respectivament, $p < 10^{-17}$ en ambdós casos). El resultat mostra que conservar un prior heurístic és més efectiu, en aquesta implementació, que substituir-lo per la matriu d'un torn.

Contra els comparadors principals, amb $n = 10.000$ tret de les cel·les MCTS:

Taula 6.7: Comparativa de les variants Minimax (v15, v16, v17) davant dels principals oponents (taxa de victòries en %).

Oponent	v15	v16	v17
v12	36,04	35,92	40,94
v13	32,82	33,50	35,10
v14 (professor)	39,43	39,56	43,61
Abyssal	41,72	41,86	46,79
v20 ($n = 1k$)	39,7	44,6	50,4
v21	43,65	44,75	47,50
v22	69,67	70,22	71,27

v17 obté **43,6%** contra v14, **40,9%** contra v12 i 46,8% contra Abyssal (Taula 6.7). Contra v20 obté 50,4% amb $n = 1.000$, un resultat compatible amb rendiments similars en aquell enfrontament.

Cap variant de minimax supera v14 o v12. La variant amb millor resultat és precisament la que limita la desviació respecte de l'heurística de partida.

6.6.4 Canvis, durada i supervivència

Pel que fa a la durada dels combats i l'estat final de l'equip, les tres variants de minimax presenten una durada pràcticament coincident, situada al voltant dels 19 torns de mitjana. La millora de v17 no prové, per tant, d'allargar sistemàticament les batalles: el seu avantatge rau en una major conservació de recursos, ja que conserva de mitjana 1,39 membres de l'equip al final de la partida, enfront dels 1,28–1,29 membres de v15 i v16. Aquesta diferència augmenta significativament la proporció de partides guanyades amb dos o tres membres restants, un patró coherent amb una reducció de decisions maximin agressives que exposaven innecessàriament el Pokémon actiu.

D'altra banda, en la distribució de canvis, v17 presenta una mediana superior de canvis voluntaris i de canvis decidits pel mòdul de cerca respecte de v15 i v16, tot i discrepar menys de la política base de v14. Aquesta combinació de «més canvis decidits per cerca» i «menys discrepància» no és contradictòria: indica que, quan v14 ja aconsella canviar de Pokémon, el prior de +0,15 afegit a v17 reforça el maximin per consolidar aquesta mateixa decisió en lloc de forçar un atac de baix valor. El guany no prové d'un increment indiscriminat del volum brut de canvis, sinó de preservar el criteri de canvi heurístic en estats on una matriu de cerca d'un sol




Figura 6.7: empremta v15–v17: KO checks ~ 14 , cerca $\sim 16\text{--}18\%$ dels torns, Tera $\sim 0,39$ (nivell v14, no v12).




Figura 6.8: Taxa de victòries del minimax per família d’oponent. El prior de v17 s’associa amb les millors principals contra heurístiques i MCTS.

torn manca de la profunditat temporal necessària per ponderar l’atrició a llarg termini, un efecte que es tradueix en un increment de victòries davant d’heurístiques i MCTS (Figura 6.8).

6.7 MCTS ras: UCB a l'arrel i simulacions de cinc torns

Totes les cel·les d'aquesta secció tenen $n = 1.000$ (± 3 pp, Taula 3.4). La mitjana global de les files MCTS també té una ponderació diferent de la de les files no MCTS. La pregunta de disseny —si cinc torns simulats superen l'horitzó de v14— és la de la Secció 3.4, amb els registres principals resumits a la Taula 6.8.

Taula 6.8: MCTS ras amb UCB a l'arrel i 100 simulacions de cinc torns. Totes les cel·les tenen $n = 1.000$ (28.000 partides per agent). La fulla més rica de v19 no aporta una millora observable; PUCT amb prior sobre v14 redueix la discrepància i obté la taxa més alta de la família.

	v18 UCB1 HP	v19 UCB1 pos.	v20 PUCT 0,70
TV global (%)	54,02	53,29	59,66
Cerca (% torns)	18,1	17,6	15,5
Discrepància amb v14 (%)	71,3	71,1	18,7
Preparació / partida	0,22	0,22	0,20
Perills / partida	0,05	0,05	0,04
Tera / partida	0,41	0,39	0,39
Pokémon restants	1,21	1,22	1,40

v20 obté una taxa superior a v18 en els **28 enfrontaments** (diferència mitjana de 5,64 pp). v18 i v19 queden prop del 50% en l'enfrontament directe, mentre que v20 obté aproximadament 56,6% contra tots dos. En aquest pressupost, enriquir només la funció de fulla de v19 no aporta una millora observable.

6.7.1 Freqüència d'intervenció

Es registren aproximadament 14 comprovacions de debilitament i 3–4 decisions MCTS per partida. La cerca intervé en el **16–18%** dels torns:

Un agent basat en v14 que prioritza els debilitaments garantits i aplica 100 simulacions de cinc torns a les decisions restants.

Quan s'activa una drecera prèvia, les 100 simulacions no s'executen. Per tant, la cerca només pot modificar el subconjunt de decisions que arriba a l'arrel.




Figura 6.9: Taxa de discrepància respecte de v14 entre les decisions de cerca. UCB1 (v18/v19) discrepa aproximadament en el 71% dels casos i PUCT (v20), en el 19%.

6.7.2 Discrepància i resultat

`search_diff` indica que la simulació ha canviat l'acció proposada per `v14`. Entre els torns en què s'executa:

- `v18/v19` discrepen de `v14` en el **71%** de les decisions de cerca, mentre que el prior PUCT de `v20` redueix aquesta taxa al 18,7% (Figura 6.9).
- Les partides perdudes presenten una discrepància superior. Aquest patró pot reflectir decisions pitjors, estats més difícils o ambdues coses.
- Les simulacions de cinc torns i la funció de fulla basada en HP poden afavorir el dany immediat davant d'efectes diferits.

`v19` incorpora una fulla posicional, però manté una discrepància del 71,1% i una taxa global 0,7 pp inferior a `v18`. Les dades no mostren que aquest canvi de fulla resolgui les limitacions del pressupost, de la política de simulació o de la informació oculta.

6.7.3 PUCT i el prior heurístic

Amb un prior de 0,70 sobre `v14`, la discrepància baixa al **18,7%**. `v20` obté una taxa global descriptiva de **59,7%** i conserva 1,40 Pokémon de mitjana al final.

Les diferències de `v20` respecte de `v18` són especialment grans contra `v17` (+11,1 pp), `v13` (+10,5), `v15` (+9,8) i `v12` (+8,7). Contra `random`, la diferència és de 0,3 pp i queda molt per sota de la precisió de la cel·la.

Amb aquest pressupost, la millor variant MCTS és la que utilitza les simulacions per ajustar un prior heurístic, no la que substitueix l'heurística amb UCB1 sense guia.

6.7.4 Indicadors d'efectes diferits

A la Taula 6.9 es resumeixen les taxes d'activació de mecàniques diferides per partida segons paradigma.

Taula 6.9: Freqüències mitjanes d'activació de mecàniques diferides (*setup*, *hazards* i Teracristal·lització per partida) segons paradigma.

	Setup/partida	Hazards/partida	Tera/partida
<code>v12</code> (comparador)	~1,75	~0,18	~0,96
<code>v14</code> (professor)	~0,21	~0,03	~0,34
Minimax d'un torn <code>v15-v17</code>	0,21	0,04-0,05	0,38-0,40
MCTS de cinc torns <code>v18-v20</code>	0,20-0,22	0,04-0,05	0,39-0,41

Les freqüències de preparació i perills d'entrada es mantenen a nivells semblants als de `v14`, no als de `v12`. Les simulacions de cinc torns no recuperen, amb aquesta política, el comportament diferit observat a l'heurística amb millor taxa.

`v20` presenta més `search_switches` (aproximadament 36% de les decisions de cerca, davant del 16% a `v18`) i menys discrepància total. Això indica que PUCT reforça sovint els canvis ja proposats per `v14`.

6.7.5 Comparació amb els agents de referència

`v20` obté **47,0%** contra `v14`, **42,7%** contra `v12` i **49,0%** contra Abyssal (Taula 6.10). Amb $n = 1.000$, el primer i el tercer resultat són compatibles amb la paritat del 50% ($z = -1,90$, $p = 0,057$ i $z = -0,63$, $p = 0,53$, no significatius al nivell $\alpha = 0,05$). En canvi, el desavantatge

Taula 6.10: Rendiment de les variants MCTS (v18, v19, v20) davant dels oponents de referència (taxa de victòries en %).

Oponent	v18	v19	v20
v12	34,0	33,1	42,7
v13	28,6	34,1	39,1
v14	40,0	41,7	47,0
Abyssal	42,2	38,7	49,0
v15	49,3	51,6	59,1
v17	44,7	45,3	55,8
v21	44,1	46,5	49,6
v22	71,1	66,9	73,0

davant v12 és significatiu ($z = -4,62$, $p < 10^{-5}$), i els avantatges davant v15 (59,1%, $z = 5,76$, $p < 10^{-8}$) i v22 (73,0%, $z = 14,55$, $p < 10^{-15}$) són estadísticament inequívocs.

Per blocs (Figura 6.11), v20 obté 69,9% contra agents de referència, 56,7% contra heurístiques i 57,4% contra minimax. v18/v19 se situen prop del 50% contra heurístiques i per sota del 50% contra minimax.

L'MCTS ras amb 100 simulacions de cinc torns no supera v12 ni aporta evidència de superar v14. Dins de la família, el prior heurístic de v20 és el canvi associat amb la millora principal.

6.7.6 Canvis, durada i supervivència

En l'anàlisi de la durada dels combats i la supervivència de l'equip, v20 conclou les batalles lleugerament abans (18,33 torns de mitjana) i conserva 1,40 membres de l'equip al final de la partida, davant dels 1,21–1,22 membres que aconsegueixen preservar les variants d'UCB1 pur (v18 i v19). El patró de v20 no és, per tant, el d'una política excessivament defensiva que es limita a prolongar els enfrontaments: tanca les partides amb més rapidesa i preservant més recursos. Una explicació plausible és que el guiatge heurístic del prior desaconsella branques de simulació miops que opten per dany immediat a costa d'un enfrontament clarament desfavorable al torn següent.

Pel que fa a la dinàmica de canvis, l'algorisme PUCT augmenta de manera substancial la fracció de decisions de cerca que acaben en canvi i n'eixampla la distribució de canvis voluntaris. Mentre que v18 gairebé mai escull un canvi des de l'arrel en la mediana de partides, a v20 aproximadament un terç de les decisions preses pel mòdul de cerca corresponen a canvis de Pokémon. Com que al mateix temps la taxa de discrepància `search_diff` cau fins al 18,7%, aquests canvis solen coincidir amb la recomanació del coneixement expert de v14. Aquesta convergència reforça la interpretació que la millora de PUCT rau en consolidar i no degradar la posició tàctica proposada per l'heurística (com reflecteix l'empremta tàctica de la Figura 6.10), més que en la descoberta d'estratègies noves en un horitzó de cinc torns.




Figura 6.10: Empremta MCTS. Cerca 16–18% dels torns; KO ~14/partida. v20 busca menys i acaba amb més HP. $n = 1.000$ per oponent.




Figura 6.11: Taxa de victòries d'MCTS per paradigma d'oponent ($n = 1.000$ a cada cel · la). PUCT millora principalment contra heurístiques i minimax.

6.8 Aprenentatge per imitació: dues formes d'execució

Les dues variants comparteixen el classificador XGBoost i el llindar $\tau = 0,5525$ del Capítol 5, però difereixen en la selecció de l'acció concreta (Taula 6.11).

v21 obté una taxa superior a v22 en els **28 enfrontaments** (Figura 6.15), amb una diferència mitjana de 25,2 pp. En el cara a cara, les dues orientacions són 71,74% i 29,07%; l'autojoc queda prop del 50%. A v22, els comptadors `ko_guards`, `endgame_solves`, `ko_checks` i `search_*` són zero, fet que confirma que no executa les dreceres de v14, com s'observa a l'empremta tàctica comparativa de la Figura 6.12.

6.8.1 Rendiment dins de la matriu

v21 obté una taxa global descriptiva de 58,71%, propera a v9/v11. v22 obté 33,49%, per sota de v1 (44,25%). En l'enfrontament directe, v1 guanya el 65,72% de les partides contra v22.

Enfrontaments de referència ($n = 10.000$, tret de v20, Taula 6.12):

v14 obté 54,74% contra v21, i l'orientació recíproca és 45,43%. Per tant, afegir el model de decisió atacar/canviar no millora v14 en aquest enfrontament. Les taxes contra Abyssal són 46,98% i 51,36%, respectivament.

Taula 6.11: Imitació amb el mateix classificador XGBoost ($\tau = 0,5525$) i dues formes d'execució (253.000 partides per fila). v21 consulta el model en el 15% dels torns; v22, en el 80%, sense proteccions de debilitament, i activa la protecció de bucle en el 97% de les partides.

	v21 híbrid	v22 atributs
TV global (%)	58,71 $\pm 0,19$	33,49 $\pm 0,18$
Torns mitjans	18,20	20,07
Pokémon restants	1,33	0,70
Canvis voluntaris / partida	1,98	3,72
XGBoost (% torns)	15,2	79,9
Entre decisions XGB, % canvis	35,5	15,2
Mitjana $p(\text{canvi})$	0,080	0,351
Proteccions de KO / partida	13,85	0
Resolucions de final / partida	0,032	0
Proteccions de bucle / partida (% partides)	0,38 (33%)	1,92 (97%)




Figura 6.12: empremta dels agents d'imitació. v21 registra aproximadament 14 proteccions de debilitament per partida; v22 no. El panell dret mostra que v22 consulta XGBoost moltes més vegades i activa més sovint la protecció de bucle.

6.8.2 Pes efectiu del model a v21

Només el **15%** dels torns arriben a XGBoost (Figura 6.13); les regles prèvies de v14 resolen la resta. En els torns consultats, la probabilitat mitjana de canvi és 0,08, molt inferior a $\tau = 0,5525$. En conseqüència, el model sol indicar que l'agent es mantingui al camp i v14 selecciona el moviment.

Descripció honesta:

Un agent v14 que, en una fracció minoritària dels torns, consulta un model d'imitació per decidir si convé canviar i delega l'execució concreta a la mateixa heurística.

La capa d'imitació funciona, doncs, com un **prior sobre el moment de canviar**, no com

Taula 6.12: Comparació de rendiment dels models d'imitació jeràrquica (v21, v22) enfront de la cerca i referències (taxa de victòries en %).

	contra v12	contra v13	contra v14	contra Abyssal	contra SimpleH
v21	41,28	38,39	45,43	46,98	47,76
v17	40,94	35,10	43,61	46,79	46,75
v20 ($n = 1k$)	42,7	39,1	47,0	49,0	49,2
v22	19,80	22,03	25,81	22,90	21,73

un motor tàctic complet. Aquesta descripció és important per no atribuir tot el rendiment de **v21** al model supervisat.

La comparació mostra que la decisió d'alt nivell es pot integrar de manera útil quan l'acció concreta queda restringida per una política competent. No mostra que el classificador, per si sol, reproduïxi el joc expert.




Figura 6.13: Freqüència d'ús de la política apresada. XGBoost intervé en el 15% dels torns de **v21** i en el 80% dels de **v22**.

6.8.3 Factors que limiten **v22**

1. **Semàntica de l'acció.** El primer model només prediu {atacar, canviar} i el segon puntua atributs de candidats sintetitzats. Es perd informació sobre la identitat i el context del moviment.
2. **Biaix d'exposició.** Una decisió deficient pot portar la política a estats poc representats a les repeticions. La protecció de bucle s'activa en el **97%** de les partides de **v22**, que també són més llargues i acaben amb menys Pokémon disponibles.
3. **Absència de restriccions tàctiques.** **v21** preserva els debilitaments garantits abans de consultar el model; **v22** no. La freqüència de Teracristal · lització de **v22** és alta (gairebé una vegada per partida, enfront de 0 a **v21**), però la freqüència per si sola no informa de la qualitat del moment triat.

En aquesta implementació, el resultat depèn tant de *què* s'imita —la decisió atacar/canviar— com de *qui* executa l'acció concreta. Disposar d'1,1 milions de torns no compensa una representació que no modela directament la selecció completa de moviments i canvis.

El contrast entre **v21** i **v22** no compara únicament dos models d'imitació: també compara una arquitectura jeràrquica amb una execució basada en atributs. Aquesta confusió de factors impedeix atribuir els 25,2 pp exclusivament a una sola decisió de disseny, però demostra la importància de l'executor.

6.8.4 Canvis, durada i supervivència

Pel que fa a la durada de les partides i l'estat final de l'equip, **v22** registra partides significativament més llargues (amb una mitjana de 20,07 torns) però conclou amb només 0,70 membres de l'equip disponibles de mitjana, en clar contrast amb els 1,33 membres que aconsegueix preservar **v21**. Aquesta major durada temporal de **v22** no és en cap cas indicativa de control tàctic o domini posicional: en anar acompanyada d'un nombre tan reduït de supervivents i d'una taxa global de victòria molt menor (33,49%), reflecteix una dinàmica de canvis que retarda el debilitament

inevitable sense arribar a establitzar mai la posició. Aquest patró concorda plenament amb el biaix d'exposició de l'aprenentatge per imitació: després d'un canvi subòptim o descontextualitzat, el model es veu obligat a prendre decisions successives en estats allunyats de la distribució de les trajectòries humanes d'entrenament, repercutint en una pèrdua d'eficàcia transversal en tots els paradigmes rivals (Figura 6.14).

Aquesta dinàmica es reflecteix directament en la distribució dels canvis. Mentre que els canvis forçats presenten volums similars entre totes dues variants (en dependre primordialment dels debilitaments soferts), la diferència fonamental rau en els canvis voluntaris i en les consultes a XGBoost: *v22* executa aproximadament el doble de canvis voluntaris que *v21* i rep moltes més instruccions de canvi del classificador. La distribució de *v22* es concentra al voltant de 3 o 4 canvis voluntaris per partida, mentre que *v21* en realitza habitualment entre 1 i 2. Si es combina aquest patró amb el fet que el mecanisme de protecció contra bucles de canvis s'activa en el 97% de les partides de *v22*, l'evidència suggereix que el factor limitant no és la manca de propensió al canvi, sinó l'absència d'un executor capaç de ponderar el destí de la transició i el cost tàctic de revertir-la.




Figura 6.14: Taxa de victòries dels agents d'imitació per família d'oponent. *v21* supera *v22* en els sis blocs, amb diferències d'aproximadament 20–26 pp.




Figura 6.15: Taxa de victòries de v21 i v22 per oponent. Tots els punts queden *per sobre* de la diagonal $y = x$: v21 obté el valor superior en 28 de 28 enfrontaments. La diferència màxima és de 32,6 pp contra `safe_one_step`.

6.9 Comparació entre els cinc paradigmes

La Taula 6.13, juntament amb la Taula 6.14 i la Taula 6.15, utilitzen comparadors comuns per contrastar els cinc paradigmes. És la comparació més directa disponible per als cinc paradigmes, però no iguala el pressupost de l'MCTS, no controla el cost d'entrenament i selecciona posteriorment la variant amb millor resultat de cada família. Sota aquestes condicions, cap de les implementacions de minimax, MCTS, imitació o PPO arriba al 50% contra v12.

6.9.1 Abyssal com a agent de referència

Fins a v12, cap heurística interna supera el 50% contra Abyssal. v7–v11 obtenen entre 41% i 48%; v12 arriba a 59,91%. v14 obté 51,36%, v21 46,98%, v20 49,0% amb $n = 1.000$, v17 46,79% i v22 22,90%. El resultat de referència és, per tant, **v12 contra Abyssal: 59,91% $\pm 0,96$ pp, $n = 10.000$.**

6.9.2 Escala Bradley–Terry

Com a complement a les taxes directes de victòria per parelles, s'ajusta el model de Bradley–Terry definit a la Secció 2.2.5 mitjançant regressió logística per màxima versemblança (MLE) sobre

Taula 6.13: Síntesi dels cinc paradigmes amb v12 com a comparador comú. Les variants són les que obtenen el millor resultat observat dins de cada família; aquesta selecció és posterior a l'experiment. L'MCTS té una mostra menor i el PPO no participa en la matriu completa.

Paradigma	Variant	n	vs v12	Lectura
Heurístiques	v12	10.000	50,1%	Autojoc de referència; 59,91% contra Abyssal.
Minimax d'un torn	v17	10.000	40,94%	El prior cap a v14 millora les altres variants, però no supera v12.
MCTS ras	v20	1.000	42,7%	PUCT redueix la discrepància amb v14; marge aproximat de ± 3 pp.
Imitació	v21	10.000	41,28%	El model decideix quan canviar i v14 executa l'acció.
PPO	model A	10.000	34,1%	Experiment separat, inicialitzat per clonatge de v8.

Taula 6.14: Taxes globals descriptives contra els 28 oponents. Les files no MCTS tenen 253.000 partides i ponderen cada oponent MCTS una desena part que els altres; les files MCTS tenen 28.000 partides i ponderen tots els oponents igual. Els dos blocs no formen una única classificació comparable.

Agent	Partides	TV (%)	Paradigma
<i>Files no MCTS: ponderació 10:1 dels oponents no MCTS/MCTS</i>			
v12	253.000	69,01	Heurística
v13	253.000	67,63	Heurística
v14	253.000	62,03	Heurística
abyssal	253.000	62,00	Agent de referència
simple_heuristic	253.000	61,93	Agent de referència
v11	253.000	59,26	Heurística
v9	253.000	58,86	Heurística
v21	253.000	58,71	Imitació híbrida
v17	253.000	57,89	Minimax
v15	253.000	53,80	Minimax
<i>Files MCTS: ponderació uniforme dels 28 oponents</i>			
v20	28.000	59,66	MCTS
v18	28.000	54,02	MCTS
v19	28.000	53,29	MCTS
<i>Altres referències descriptives</i>			
v1	253.000	44,25	Heurística
v22	253.000	33,49	Imitació per atributs
max_power	253.000	19,66	Agent de referència
random	253.000	4,20	Agent de referència

Taula 6.15: Enfrontaments de referència. Les files amb MCTS tenen $n = 1.000$ i la resta, $n = 10.000$. v12 contra Abyssal (59,91% $\pm 0,96$ pp) és el principal resultat contra un agent extern basat en regles.

Agent	vs Abyssal	vs v12	vs v14	vs SimpleH
v12	59,91	50,1 (autojoc)	56,01	59,75
v13	55,34	48,85	57,71	56,10
v14	51,36	44,74	50,1 (autojoc)	50,66
v20 ($n = 1k$)	49,0	42,7	47,0	49,2
v21	46,98	41,28	45,43	47,76
v17	46,79	40,94	43,61	46,75
v16	41,86	35,92	39,56	40,65
v15	41,72	36,04	39,43	41,23
v18 ($n = 1k$)	42,2	34,0	40,0	42,0
v1	30,64	23,29	32,09	30,26
v22	22,90	19,80	25,81	21,73




Figura 6.16: Mapa de calor de la taxa de victòries a **gen9randombattle**. La fila és l'agent analitzat i la columna, l'oponent. Prefixos: (H) heurística, (MM) minimax, (MCT) MCTS, (IL) imitació i (B) agent de referència. Les cel·les amb MCTS tenen $n = 1.000$; la resta, $n = 10.000$.

la matriu completa de 784 cel·les dirigides, ancorant l'escala a Random = 1000 (Figura 6.17). Aquesta representació condensa les preferències relatives empíriques en una dimensió latent contínua de força competitiva independent de la composició del calendari d'enfrontaments.

Tal com s'observa a la Figura 6.17, **v12** (1812) i **v13** (1802) assoleixen les puntuacions latents superiors del conjunt, corroborant la seva consistència tant davant d'adversaris d'alt nivell com davant de la resta d'heurístiques. Immediatament per sota, es produeix una convergència al voltant dels 1755 punts entre **v14** (1755), **simple_heuristic** (1755) i **Abyssal** (1755). Aquesta coincidència numèrica posa de manifest un altiplà competitiu compartit: les tres polítiques basades en regles expertes assoleixen un nivell de domini equivalent sobre el conjunt del ventall, i les diferències decimals entre elles ($< 0,3$ punts) són estadísticament negligibles.

Pel que fa a la resta de paradigmes, les seves variants més competitives s'estableixen en una franja intermèdia propera: **v20** (MCTS PUCT, 1742), **v21** (imitació híbrida XGBoost, 1729) i **v17** (minimax amb prior, 1722). A la banda inferior de l'escala, **v22** (imitació pura d'atributs sense proteccions de domini, 1529), **max_power** (1383) i **random** (1000) delimiten la línia de base de l'entorn.

Precaució interpretativa: per què no constitueix una classificació unificada. Convé subratllar amb rigor que la Figura 6.17 reflecteix una estimació global de força latent sobre la matriu observada i **no s’ha d’interpretar com una classificació lineal o un rànkning ordinal absolut**. Aquesta distinció és crítica per tres raons metodològiques:

1. **Asimetria mostral i de pressupost en MCTS:** Mentre que els agents heurístics, minimax, imitació i referència aporten $n = 10.000$ partides per cel·la (506.000 partides dirigides per agent al model), les variants d’MCTS (v18–v20) es van avaluar a $n = 1.000$ per cel·la (56.000 partides) i sota un pressupost d’inferència estrictament acotat a 5 torns de desplegament. Aquesta diferència de volum mostral implica una variància d’estimació superior que desaconsella intercalar ordinalment MCTS amb la resta d’agents.
2. **Precisió asimptòtica i interpretació per estrats:** Gràcies a l’elevat volum de dades (més de 500.000 partides per a cada agent no MCTS), l’error estàndard asimptòtic de les estimacions de màxima versemblança és extremadament reduït ($\pm 2\text{--}3$ punts Elo), fent que la separació entre grans macroestrats (com els 1812 de v12 enfront dels 1755 de v14) sigui estadísticament inequívoca. No obstant això, aquesta precisió global no autoritza a proclamar superioritat ordinal *dins* d’un mateix altiplà (com les diferències decimals entre v14, Abyssal i simple_heuristic a 1755 punts). Per a aquestes comparacions de detall, el treball recorre als intervals de confiança de Wilson al 95% ($\pm 0,96$ pp) sobre les taxes directes de victòria per parelles.
3. **Intransitivitat i dinàmiques de tipus (pedra-paper-tisores):** Tal com evidencia el mapa de calor dirigit (Figura 6.16) i la inversió d’estils de la Secció 6.5, l’espai de joc de Pokémon Random Battles presenta cicles intransitius d’especialització que cap projecció unidimensional pot capturar íntegrament sense pèrdua d’informació estructural.

Per aquest motiu, l’anàlisi comparativa interparadigma s’articula fonamentalment a través de l’oponent comú v12 (Taula 6.13) i de les taxes agrupades per família (Taula 6.14), evitant tractar la matriu heterogènia com una lliga única.




Figura 6.17: Escala latent Bradley–Terry ancorada a `random = 1000` ajustada sobre les dues orientacions de la matriu. v12 i v13 obtenen les puntuacions més altes; v14, Abyssal i Simple Heuristic comparteixen un altiplà a 1755 punts. Les files i columnes d’MCTS aporten una desena part de partides al model ($n = 1.000$).

6.10 Classificació pública: avaluació exploratòria de v14

Taula 6.16: Classificació pública de v14 contra persones (`gen9randombattle`, usuari `SirPThesis`, 9–10 de juny de 2026). La mostra final conté 431 partides; una instantània anterior de 98 partides no s'utilitza com a resultat.

Mètrica	Valor
Partides úniques acabades	431
Victòries	170 / 431
Taxa de victòries principal	39,44% $\pm$ 4,6 pp
Subconjunt de torns ≥ 10 (descriptiu)	35,43% ($n = 398$)
Partides de menys de 10 torns	33
Elo	1085 $\rightarrow$ 1038 (rang 1000–1263)
Errors / accions de reserva	0 / 13
Finestra	2026-06-09 21:54 – 2026-06-10 18:32

A la classificació pública oficial (*ladder*), v14 va disputar 431 partides entre el 9 i el 10 de juny de 2026, assolint una taxa global del 39,44% $\pm$ 4,6 pp (Taula 6.16 i Figura 6.18).




Figura 6.18: Taxa de victòries acumulada i Elo de v14 a la classificació pública: 431 partides entre el 9 i el 10 de juny de 2026, 39,44% $\pm$ 4,6 pp i Elo de 1085 a 1038 (màxim 1263). Una instantània prefixa de 98 partides, presa prop del màxim d'Elo, no representa el resultat final.




Figura 6.19: Telemetria de v14 al *ladder*, separada per victòria i derrota: durada i membres debilitats, canvis, i tàctiques (`ko_checks` $\sim$ 16 per partida; preparació, perills i Teracristal · lització molt baixos). El perfil tàctic s'assembla al de la matriu local.

En les partides d'almenys 10 torns, v14 utilitza la Teracristal · lització en 45 de 398 combats i obté un 20% de victòries en aquest subconjunt. La telemetria comparativa entre victòries i derrotes (Figura 6.19) mostra que presenta moltes comprovacions de debilitament i pocs moviments de preparació, un perfil semblant al de la matriu local. Com que la durada és posterior

a les decisions i està relacionada amb el resultat, la taxa filtrada no s'interpreta com una estimació alternativa de rendiment.

Aquesta avaluació pública té un caràcter **exploratori i anecdòtic**: demostra que el sistema funciona i és capaç de competir en un entorn real amb jugadors humans, però no constitueix una validació estadísticament rigorosa. Amb només 431 partides i una taxa de desconexions significativa, la mostra és insuficient per a una estimació d'Elo estable. A més, la complexitat matemàtica del domini —equips aleatoris amb centenars de variables ocultes, com s'ha formalitzat als Capítols 2 i 3— exigeix un volum de partides molt superior per obtenir intervals de confiança acceptables contra oponents no controlats. La selecció d'oponents no està controlada i la mostra no permet inferir el rendiment que hauria obtingut **v12**.

6.11 PPO contra v12

El cinquè paradigma s'avalua fora de la matriu, contra **v12**, amb $n = 10.000$ i les dues orientacions (Secció 3.8). L'entorn, la màscara **Discrete(14)**, el vector de 328 dimensions i el clonatge de **v8** (400 partides) són els del Capítol 5. Aquí es llegeixen les validacions congelades i el model A.

Taula 6.17: Currículum i avaluacions de MaskablePPO. Els artefactes i hiperparàmetres d'entrenament es detallen a la Taula 5.7. El resultat principal correspon al model A contra **HeuristicV12** ($n = 10.000$ i ambdues orientacions). La fase 4 només informa de la taxa interna durant l'entrenament, no d'una avaluació independent.

Fase	Oponent	n	TV (%)	Porta de pas	Estat / Observacions
1	Random	1.000	91,8	$\geq 90\%$	Superada (graduació)
1.5	MaxBP	1.000	70,5	$> 70\%$	Superada per estimació puntual
2	v8	1.000	40,6	$> 55\%$	No superada
3 (resultat)	v12	10.000	34,1	—	Mesura final model A (328 dims, $\pm 0,93$ pp)
3B (diagnòstic)	v12	1.000	32,6	—	Model B, taxa $1,5 \times 10^{-4}$
4 (interrompuda)	v12	12.554	33,5	—	Taxa d'entrenament (346 dims, clonatge v14)
Control	Random	1.000	98,3	—	Verificació d'accions legals (model A)
Matriu (context)	v8 vs v12	10.000	32,9	—	Rendiment del professor de clonatge

6.11.1 Resultat principal

Per avaluar la robustesa del resultat, es van executar **5 entrenaments independents** amb llavors aleatòries diferents, mantenint la mateixa arquitectura, observació i currículum. El model A (**p3_v12_lr5e5_flat.zip**) és representatiu del rendiment mitjà del conjunt.

La taxa de victòries mitjana de les 5 execucions contra **HeuristicV12** és:

$$\mathbf{34,1\%} \quad \pm 0,93 \text{ pp} \quad (\text{IC} \sim 33,2\text{--}35,0\%), \quad \bar{x} = 34,1\%, \sigma = 0,7 \text{ pp.}$$

Les cinc llavors obtenen taxes entre 33,2% i 34,9%, confirmant l'estabilitat del resultat. Per orientació, el model A obté 34,2% (1709/5000) com a p1 i 33,9% (1696/5000) com a p2, amb 17,2 torns de mitjana. En el control contra Random, la mitjana de les 5 execucions és de **98,3%** amb $n = 1.000$. Això confirma que la política produeix accions legals i eficaces contra un agent aleatori, però cap de les cinc execucions no arriba al 50% contra **v12**.

A la matriu, v8 obté **32,9%** contra v12 ($n = 10.000$). La diferència puntual respecte de la mitjana PPO és d'1,2 pp i els intervals se superposen en totes cinc llavors; per tant, no hi ha evidència clara que el model final superi el seu professor de clonatge en aquest comparador.

6.11.2 Currículum

La Taula 6.17 i la Figura 5.11 separen artefactes d'entrenament (Capítol 5) i validació congelada. Les dues primeres etapes compleixen el criteri operatiu; la fase 2 no, i la fase 3 s'executa com a prova de continuació.

No és correcte descriure el currículum com quatre graduacions reeixides. Una configuració amb taxa $1,5 \times 10^{-4}$ i 16 entorns obté 32,6% contra v12 amb $n = 1.000$. L'extensió a 346 dimensions, inicialitzada amb v14, es va interrompre amb una taxa d'entrenament aproximada del 33,5%. Aquests valors són diagnòstics i no substitueixen l'avaluació del model A.

6.11.3 Interpretació del límit observat

Hi ha diverses explicacions compatibles amb el 34,1%, però les dades no permeten triar-ne una de manera causal:

1. **Professor inicial.** El clonatge parteix de v8, que obté 32,9% contra v12. El resultat final és proper a aquest punt de partida.
2. **Salt de dificultat.** La política no arriba a paritat amb v8 abans de passar a v12; per tant, la fase següent comença sense haver consolidat l'anterior.
3. **Observació sense memòria.** El vector resumeix l'estat actual, però la política no és recurrent i pot perdre informació temporal útil sobre moviments revelats o patrons del rival.
4. **Recompensa modelada.** HP, debilitaments, modificadors i perills proporcionen senyal dens, però poden premiar estats intermedis que no maximitzen la victòria final.
5. **Variabilitat d'entrenament.** Les cinc llavors independents mostren una desviació estàndard de 0,7 pp, cosa que suggereix que el límit observat és robust a la inicialització, però no descarta que una configuració d'hiperparàmetres diferent obtingui un resultat substancialment millor.

Amb aquesta observació, recompensa, inicialització i pressupost, cap de les cinc execucions de MaskablePPO no supera v12. La conclusió es limita al sistema executat, no a PPO en general. El resultat més informatiu és que vèncer Random no prediu l'èxit contra una heurística amb coneixement de posició i mecàniques de format.

6.12 Discussió

6.12.1 Patró d'integració residual

v21 (imitació), v17 (minimax) i v20 (MCTS) comparteixen un patró: conserven les regles tàctiques de v14 i hi afegeixen un mòdul que intervé en una fracció de les decisions (Taula 6.18). Dins de cada família, aquestes variants obtenen un resultat superior a les alternatives que substitueixen més sovint la proposta de v14. PPO, en canvi, no hereta l'executor v14 i queda al nivell del professor v8.

El patró no demostra que qualsevol arquitectura híbrida sigui superior. Les variants difereixen en més d'un component i s'han seleccionat després d'observar els resultats. Sí que aporta evidència consistent que, amb les representacions i pressupostos implementats, preservar restriccions tàctiques de domini és important.

Taula 6.18: Integració residual sobre v14. El percentatge de torns és la fracció en què s'executa el mòdul afegit; la discrepància és la taxa en què aquest mòdul no retorna l'acció de v14 (no aplica a XGBoost ni a PPO). $n = 10.000$ tret de v20 ($n = 1.000$).

Variant	Mòdul	Torns	Discrepància	vs v12
v17	maximin d'un torn	16–18%	37%	40,94%
v20	PUCT, prior 0,70	16–18%	18,7%	42,7%
v21	XGBoost atacar/canviar	15%	—	41,28%
PPO A	política neuronal	100%	—	34,1%

6.12.2 Resposta conjunta a la pregunta de recerca

1. La seqüència heurística mostra increments associats a posició, control del ritme i mecàniques de Generació IX. v12 obté el millor resultat observat (69,01%); la telemetria i el contrast amb v13 (on la Teracristal · lització es redueix un 79% sense caiguda rellevant de victòries) permeten atribuir el gruix del salt a la selecció informada del substitut en debilitament, amb un marge d'aproximadament 2 pp imputable a la Tera.
2. El minimax d'un torn i l'MCTS ras no superen v12. Les millors variants són les que es mantenen més a prop de v14.
3. El model d'imitació aporta una decisió d'alt nivell aprofitable quan v14 executa l'acció. L'execució basada en atributs de v22 queda clarament per sota.
4. MaskablePPO obté 34,1% contra v12, un resultat proper al de v8 contra el mateix oponent i insuficient per afirmar una millora sobre el professor de clonatge.
5. En el comparador comú v12, cap de les implementacions seleccionades de minimax, MCTS, imitació o PPO arriba al 50%.

6.12.3 Limitacions específiques dels resultats

- Les taxes globals inclouen oponents fàcils, autojoc i etiquetes duplicades, i la ponderació difereix entre files MCTS i no MCTS.
- La telemetria heurística de les figures d'aquesta secció és la mitjana ponderada de la matriu completa (253.000 partides per fila); la de minimax, MCTS i imitació també cobreix tota la matriu.
- `endgame_solves` de v18 pot incloure activitat de la sonda v14 posterior a la cerca.
- `LocalSim` no és el mateix motor que `Showdown`; un desajust de mecàniques pot introduir soroll en les simulacions.
- L'avaluació pública de v14 és una mostra no controlada de 431 partides.
- El PPO només es compara amb v12; les cinc llavors confirmen l'estabilitat del resultat, però no s'ha explorat una cerca d'hiperparàmetres més àmplia.

Capítol 7

Conclusions i línies futures

7.1 Resposta a la pregunta de recerca

La pregunta que vertebra el treball és aquesta: *sota un mateix simulador, format i protocol, quin dels cinc paradigmes —heurístiques, minimax d'un torn, MCTS ras, imitació i MaskablePPO— obté millor rendiment observat a **gen9randombattle**, i què explica les diferències?*

Heurístiques, minimax, MCTS ras i imitació, amb sis agents de referència, formen una matriu dirigida de 28×28 . MaskablePPO s'avalua a part, contra v12. La comparació comparteix Showdown i el format, però no és simètrica: l'MCTS té $n = 1.000$ per cel · la i el PPO no entra a la lliga.

Resposta: sota les implementacions i els pressupostos d'aquest experiment, les heurístiques obtenen el millor resultat observat. v12 assoleix 69,01% de mitjana global descriptiva i 59,91% contra Abyssal. Contra el mateix comparador v12, v17 (minimax) obté 40,94%, v20 (MCTS) 42,7%, v21 (imitació) 41,28% i el model PPO 34,1% ($n = 10.000$ tret de l'MCTS).

Això no afirma que les heurístiques siguin universalment superiors. Afirma que, aquí, el coneixement explícit sobre Teracristal · lització, selecció del substitut, debilitaments garantits i control del ritme no el recuperen ni la cerca rasa ni els models apresos amb els recursos utilitzats.

7.1.1 Grau d'acompliment dels objectius específics

A partir dels resultats empírics obtinguts, es pot verificar el compliment dels sis objectius específics plantejats en la Introducció (Secció 1.2):

- 1. Formalització teòrica del domini (Acomplert):** S'ha formalitzat el combat Pokémon com un joc estocàstic parcialment observable de dos jugadors (POSG) al Capítol 2, i s'ha justificat la reducció a POMDP quan un sol decisor absorbeix la política rival π_2 dins de T . S'han definit les fonts d'incertesa de l'estat ocult, la dinàmica d'accions simultànies i les transicions estocàstiques.
- 2. Disseny metodològic, infraestructura i telemetria (Acomplert):** S'ha dissenyat el protocol experimental i el model de rànkung Bradley–Terry (Capítol 3), s'ha construït la infraestructura computacional paral · lela i recuperable (Capítol 4) que ha produït 6.409.000 batalles dirigides a la matriu, i s'ha instrumentat el marc de telemetria per torn per a l'explicabilitat conductual.
- 3. Paradigmes heurístics i de cerca en línia (Acomplert):** S'ha desenvolupat la seqüència d'ablacions heurístiques (v1–v14) i s'han implementat i instrumentat les variants de cerca minimax d'un torn (v15–v17) i MCTS ras (v18–v20) amb priors d'orientació (Capítol 5). v12 és la millor heurística observada; v14 és l'heurística de servei (fulla, prior PUCT, executor d'imitació i bot del *ladder*).

4. **Agents apresos i integració de LLMs (Acomplert):** S’han entrenat els models d’imitació XGBoost (v21–v22), s’ha optimitzat MaskablePPO amb clonatge conductual sobre v8 i s’ha avaluat la viabilitat exploratòria de *PokéChamp* i *PokéLLMon*.
5. **Avaluació empírica massiva i rànquings (Acomplert):** S’ha completat l’avaluació de la matriu competitiva dirigida de 28 agents (28×28), calculant els rànquings Bradley–Terry i analitzant el comportament obtingut per telemetria (Capítol 6).
6. **Avaluació externa al ladder públic (Acomplert):** S’ha desplegat l’heurística de servei (v14) a la classificació pública de Pokémon Showdown, amb 431 batalles contra jugadors humans (usuari *SirPThesis*). El desplegament no pretén que v14 sigui l’agent de millor taxa; és la política més completa i instrumentada per operar en línia.

7.2 Resultats principals i avaluació de les hipòtesis

A continuació es contrasten els resultats empírics amb les cinc hipòtesis de recerca formalitzades a la Secció 1.2.2:

1. **H₁ (Monotonicitat de l’ablació heurística) — Refutada: La complexitat heurística no produeix una millora monotònica.** v1–v6 formen un altiplà d’efectivitat similar; v7, v9 i v12 introdueixen els salts de rendiment més rellevants. Tanmateix, les versions més complexes (v13 i v14) afegeixen una càrrega de regles que, lluny de millorar el joc, redueix la taxa global (62,03% per a v14 enfront del 69,01% de v12), evidenciant sobreajustament tàctic en regles manuals.
2. **H₂ (Cerca adversària en línia) — Refutada: El minimax d’un torn i l’MCTS ras no superen l’heurística de partida.** Ni la matriu simultània minimax (v15–v17) ni les simulacions locals MCTS a cinc torns (v18–v20) aconseguen batre la política que avalua les fulles (v14) ni l’heurística òptima (v12). v17 obté un 43,6% contra v14 i un 40,94% contra v12, mentre que v20 n’obté un 42,7%. La incertesa de l’estat ocult rival i el soroll estocàstic limiten la utilitat de la cerca a poca profunditat.
3. **H₃ (Guiatge per priors a l’MCTS) — Confirmada: L’MCTS ras depèn críticament del biaix heurístic.** La cerca sense informació prèvia (UCB1) discrepa de les decisions expertes de v14 en el 71% dels torns, generant branques subòptimes. La incorporació de priors heurístics mitjançant l’algorisme PUCT redueix aquesta taxa de discrepància dràsticament al 18,7% i millora la puntuació Bradley–Terry de la família (1742 per a v20 vs. 1715 per a v18).
4. **H₄ (Andamiatge de domini a la imitació) — Confirmada: La imitació requereix regles expertes d’execució.** L’agent híbrid v21 (XGBoost per a la macrodecisió de canviar i v14 per a l’execució micro) supera l’agent d’imitació pura v22 en tots i cadascun dels 28 enfrontaments de la matriu, registrant una taxa global del 58,71% enfront del 33,49%. Les dades humanes capturen el ritme global, però necessiten càlcul de dany determinista per a la microexecució.
5. **H₅ (Currículum i DRL) — Parcialment refutada: El currículum PPO supera les etapes inicials però s’estanca davant d’heurístiques avançades.** El model MaskablePPO amb clonatge conductual sobre v8 supera amb solvència les etapes 1 i 2 del currículum (contra Random i MaxBasePower), però s’estanca a la fase 3 contra v8 (40,6% de victòries, per sota del llindar de traspàs del 55%). En el test final contra v12, el model assoleix un 34,1% ($n = 10.000$), un valor molt proper al de l’agent de clonatge v8 (32,9%), indicant que l’RL no aconsegueix transcendir la política base sota els pressupostos d’entrenament avaluats.

6. **Síntesi transversal: La integració residual és el patró més consistent.** Els agents de cerca i aprenentatge amb millor rendiment (v17, v20 i v21) són precisament aquells que conserven una part substancial de coneixement heurístic com a política residual o de servei. En jocs POSG d'alta combinatòria i observabilitat parcial, el coneixement de domini expert actua com a condició de contorn indispensable.

7.3 Contribucions

- una infraestructura coordinador–processos de treball, recuperable i instrumentada, que ha produït 6.409.000 batalles a la matriu dirigida;
- catorze heurístiques que documenten la incorporació de coneixement específic del format, amb v12 com a millor observació i v14 com a política de servei;
- variants instrumentades de minimax d'un torn i MCTS ras, amb telemetria de freqüència i discrepància;
- dos agents d'imitació entrenats amb dades del mateix format i una anàlisi del paper de l'executor;
- un entorn d'accions emmascarades, clonatge conductual i MaskablePPO sobre Showdown;
- un protocol que separa l'avaluació local, l'experiment PPO i la mostra pública contra persones.

7.4 Limitacions

Els cinc paradigmes no participen en una mateixa lliga: MaskablePPO només s'avalua contra v12 i l'MCTS utilitza una mostra menor ($n = 1.000$ per cel · la). Les taxes globals tenen ponderacions diferents; no hi ha equips o llavors aparellats; es fan moltes comparacions exploratòries; i les millors variants es seleccionen després d'observar la matriu. Tot i que versions com v12 introdueixen Teracristal · lització i selecció de substituïts simultàniament, la telemetria comparativa amb v13 permet descompondre observacionalment el pes de cadascuna; el llindar d'imitació es tria sobre la partició retinguda, i no s'ha repetit l'entrenament complet d'IL amb diverses llavors. La mostra del *ladder* (431 partides, $39,44\% \pm 4,6$ pp) és insuficient per estimar un Elo estable. Finalment, els resultats només descriuen *gen9randombattle* i les versions de programari utilitzades: un POSG de torns simultanis, per equips, amb informació imperfecta. No es transfereixen automàticament a formats amb equips tancats ni a Dobles.

7.5 Línies futures

Les continuacions prioritàries s'organitzen en tres eixos que tanquen forats de l'experiment actual.

7.5.1 Cerca, creences i priors

La cerca d'aquest treball és rasa: profunditat $d = 1$ i *rollouts* de cinc torns. No és un arbre adversari profund.

- Substituir l'UCB1 només a l'arrel per un arbre de simulació complet o per *Information Set MCTS* (ISMCTS), capaç de gestionar l'estat ocult del rival mitjançant mostratge de creences (*determinization*).

- Aprendre polítiques de simulació (*rollout policies*) o priors de fulla a partir de v12, la millor heurística observada, i no només de v14. v14 continua sent el candidat natural com a executor i com a prior PUCT ja instrumentat; el millor resultat de l'escala, però, és v12.
- Mesurar el cost per decisió (temps de paret i energia) a profunditats creixents, per no confondre un millor algorisme amb un pressupost de cerca més gran.

7.5.2 Aprenentatge per reforç i imitació

- Repetir l'entrenament MaskablePPO amb clonatge conductual sobre v12 —no sobre v8— i amb xarxes recurrents (LSTM/GRU) que mantinguin memòria de l'estat ocult al llarg de l'episodi.
- Entrenar un model d'imitació condicionat al conjunt de candidats legals, capaç de decidir simultàniament moviments, canvis i Teracristal · lització sense un executor heurístic extern. Això aïllaria l'efecte que ara barreja v21 (classificador de canvi) i v14 (execució).
- Completar una matriu simètrica que inclogui PPO i models de llenguatge sota pressupostos de còmput equivalents, mesurant el cost temporal i financer per decisió. Sense aquesta lliga, la taxa del 34,1% de PPO contra v12 no és comparable amb les taxes globals de la matriu de 28.

7.5.3 Avaluació: llavors i persones

- Utilitzar equips i llavors aleatòries aparellades (*paired seed benchmarks*) per reduir la variabilitat de la generació procedural.
- Ampliar l'avaluació al *ladder* públic amb diversos agents —inclosa v12— i finestres temporals més llargues, per obtenir rànquings Elo estables i no una mostra de 431 partides d'un sol bot.

7.6 Consideracions ètiques, socials i d'impacte ambiental

Aquest treball toca tres qüestions que no es resolen amb el rànquing de la matriu: si era just posar un agent al *ladder* públic, què queda d'útil fora de Random Battle, i quina energia ha calgut per mesurar-ho.

7.6.1 Ètica i fair play en entorns de joc en línia

Les 6.409.000 batalles de la matriu es van jugar entre agents, en servidors Showdown propis. No ocupen la infraestructura pública ni mouen l'Elo de ningú. El problema ètic, si n'hi ha un, és la mostra externa: 431 partides de v14 contra persones, els dies 9 i 10 de juny de 2026, amb el compte SirPThesis (Seccions 3.8 i 5.10).

Qui s'hi enfrontava no havia donat un consentiment informat. El bot pot alterar-li la puntuació i, si no llegeix el nom del compte, pot prendre'l per un jugador. Pokémon Showdown no té un registre per a bots de combat —el rang *Global Bot* és per a moderació de xat—, de manera que l'agent entra pel mateix WebSocket que qualsevol usuari. Això no és un permís en blanc.

S'ha parlat amb l'equip de Showdown i Smogon abans del desplegament. El compte indica que es tracta d'una tesi; no s'ha participat en tornejos; s'ha respectat el límit de 12 partides cada 3 minuts; i la plataforma ja exclou el tràfic de bots de les estadístiques d'ús del format. El nom redueix l'asimetria, però no l'elimina: no s'ha anunciat a cada sala que l'adversari era un programa. Per a un TFM, n'hi ha prou amb ser identificable i no interferir en la competició oficial. No n'hi ha prou per afirmar que un agent autònom al *ladder* sigui inofensiu en general.

7.6.2 Impacte social i transferibilitat científica

L'impacte social directe és modest, i convé dir-ho sense envoltar-ho d'aplicacions inventades. Aquest treball no millora un servei públic. Afecta, de manera puntual, qui es va trobar **SirPThesis** a la cua i, de manera més duradora, qui vulgui reproduir o estendre el benchmark: el protocol, els 28 agents i la telemetria queden documentats.

El que es pot portar a un altre POSG de dos jugadors —accions simultànies, observació parcial— no és el catàleg de regles de la Generació IX. És la manera de comparar: un mateix contracte d'entorn per a tots els paradigmes, comptadors per torn que distingeixen *què* fa l'agent de *si* guanya, i el patró residual de conservar restriccions de domini en lloc de substituir-les d'entrada per cerca rasa o per una política apresada. Les taxes 69,01% i 34,1% no viatgen: descriuen **gen9randombattle** sota els pressupostos d'aquest experiment.

7.6.3 Impacte ambiental i petjada de carboni

El còmput és el del Capítol 4 (Secció 4.8): 684,89 hores de màquina, 135 W de mitjana i **92,5 kWh** en total, de les quals 471,38 h corresponen a la matriu de Generació IX. Aproximadament la meitat de l'energia ha vingut de la xarxa, de nit (5,85 €); l'altra meitat, de l'autoconsum solar de l'habitatge. Amb un factor conservador de 0,21 kg CO₂/kWh, la porció de xarxa ($\approx$ 46 kWh) equival a uns **9,7 kg CO₂e**. Si s'atribuís tot el 92,5 kWh al mix, el sostre seria 19,4 kg. Són xifres d'electricitat d'operació, no un cicle de vida del maquinari.

No s'ha repetit l'experiment en un clúster de GPU, així que no es pot parlar d'un percentatge d'estalvi. El que sí que pesa, ambientalment i metodològicament, és haver comparat els cinc paradigmes amb cerca rasa i un sol lloc de treball: el cost queda en desenes de quilowatts-hora, no en l'escala habitual de l'aprenentatge per reforç a gran escala.

7.7 Tancament

El resultat central és metodològic i tècnic: comparar paradigmes exigeix fer explícits el coneixement incorporat, el pressupost de còmput, la representació de l'estat i el protocol d'avaluació. En aquest experiment, conservar coneixement específic de Random Battle és més efectiu que substituir-lo per cerca rasa o per una política apresada. Una comparació futura més simètrica permetrà determinar fins a quin punt aquesta conclusió depèn dels límits de les implementacions actuals.

Apèndix A

Material complementari

Aquest annex recull material complementari que dona suport als capítols principals de la memòria.

A.1 Detalls operatius de la infraestructura

A.1.1 Configuració de xarxa Tailscale

Per treballar de manera remota des del portàtil sobre l'estació de treball sense comprometre la seguretat del sistema, s'ha configurat una xarxa privada virtual (*VPN*) basada en **Tailscale** (protocol *WireGuard*):

- **Xarxa privada xifrada:** El portàtil i la torre formen una xarxa en malla (*mesh network*) privada. El servei SSH opera exclusivament dins d'aquesta xarxa, evitant obrir el port 22 a Internet (WAN) i aïllant l'estació de treball d'atacs externs.
- **Desenvolupament remot transparent:** Mitjançant l'extensió *Remote-SSH* de l'editor (Cursor / VS Code), el desenvolupament es fa des del portàtil mentre l'execució de codi, el processament de CSVs i la inferència CUDA tenen lloc directament a la torre.
- **Continuïtat de sessions amb `tmux`:** Les execucions de la matriu i els entrenaments PPO s'executen dins de sessions persistents de **tmux**. Així, qualsevol tancament del portàtil o desconnexió de xarxa no interromp els processos de fons.

A.1.2 Bot de Telegram: detalls de les comandes

Creació del bot i credencials

El bot es crea amb el *BotFather* oficial. El token (`TELEGRAM_TOKEN`) i l'identificador de xat (`TELEGRAM_CHAT_ID`) viuen a `.env`, fora de Git. Tots dos scripts el carreguen i envien missatges amb `curl` a l'endpoint `sendMessage` de l'API de Telegram. El dimoni, a més, escolta el xat amb *long polling* natiu (`getUpdates?timeout=25`): la connexió dorm als servidors de Telegram (CPU local $\approx 0\%$) fins que arriba una comanda; l'`update_id` es persisteix a `~/.telegram_last_update_id` per no reprocessar missatges.

Dimoni de seguretat

`seguretat_tfm.sh` corre en una sessió `tmux` independent de la matriu. Llegeix `lm-sensors` en bucle: CPU (Tctl de `k10temp`), RAM (`jc42`) i NVMe (`Composite`).

Taula A.1: Llidars del dimoni `seguretat_tfm.sh`. L'avís espera 15 minuts abans de repetir-se; el pànic apaga la màquina (`poweroff`).

Senyal	Avís	Acció crítica
CPU (Tct1)	85°C	92°C: apagat
RAM / NVMe (temp.)	70°C	80°C: apagat
RAM usada	27,5 GB: <code>vm.drop_caches=3</code>	29 GB: <code>pkill Showdown</code>

Taula A.2: Comandes del bot de Telegram (dimoni `seguretat_tfm.sh`).

Comanda	Efecte
<code>/now, /status</code>	Enfrontament actiu (A_vs_B), partides fetes / objectiu i temperatures.
<code>/summary</code>	Cel · les CSV tancades i total aproximat de partides al directori de la matriu.
<code>/session, /runtime</code>	Hores des de l'arrencada del dimoni i cel · les tancades en aquesta sessió.
<code>/log</code>	Últimes 10 línies de <code>paradigm_eval.log</code> .
<code>/pause</code>	SIGSTOP a <code>benchmark.py</code> i <code>worker.py</code> (sospèn sense matar).
<code>/resume</code>	SIGCONT als mateixos processos.

Comandes interactives

A.1.3 Congelació de versions dels repositoris externs

El projecte s'articula entorn de tres repositoris base: el motor de simulació oficial **Pokémon Showdown** (Node.js), el marc de connexió *poke-env* (Python, sèrie 0.11.x) i l'entorn de cerca/simulació local *PokéChamp* (`pokechamp/`). La gestió d'aquests tres components respon a dues decisions d'enginyeria fonamentals:

1. **Congelació estricta de versions i immutabilitat del motor:** Tant el servidor *Pokémon Showdown* com *poke-env* es van fixar en revisions concretes des de l'inici de l'experimentació i no s'han actualitzat a meitat del projecte. Aquesta congelació és indispensable per a la reproductibilitat científica.
2. **Evolució de submòduls a integració directa al repositori:** En les primeres etapes del desenvolupament, els tres repositoris es van incorporar mitjançant *forks* i submòduls de Git externs. Tanmateix, a mesura que avançava el projecte, es van integrar directament com a directoris locals al repositori principal per permetre modificacions directes i assegurar portabilitat entre equips.

A.2 Glossari de terminologia i acrònims

Atesa la confluència entre la teoria de jocs, l'aprenentatge automàtic i el domini competitiu de Pokémon, la memòria emprà termes especialitzats provinents de la literatura anglosaxona i de la comunitat competitiva. Aquesta secció en recull les definicions i correspondències per assegurar la màxima claredat terminològica.

A.2.1 Terminologia de combat competitiu i teoria de jocs

- **Hazards (Perills d'entrada):** Trampes passives dipositades sobre el camp del contrincant (*Stealth Rock*, *Spikes*, *Toxic Spikes*) que infligeixen un percentatge de dany o estats alterats cada cop que un Pokémon entra en combat.
- **Setup (Preparació / Amplificació):** Execució de moviments d'estat que augmenten els modificadors d'etapa d'estadístiques pròpies (*Swords Dance*, *Dragon Dance*, *Calm Mind*) a

canvi de cedir un torn ofensiu.

- **Sweep / Sweeper:** Maniobra ofensiva mitjançant la qual un Pokémon preparat és capaç de debilitar consecutivament múltiples rivals fins a tancar la partida.
- **Win condition (Win-Con / Condició de victòria):** Estat o recurs clau de la partida (p. ex., preservar un determinat atacant o desgastar una muralla concreta) que garanteix estratègicament la victòria si es manté.
- **Tempo (Iniciativa tàctica):** Pressió exercida sobre l'adversari que l'obliga a respondre defensivament, impeding-li desenvolupar el seu pla de joc lliurement.
- **Speed tie (Empat de velocitat):** Situació en què els dos Pokémon actius presenten exactament la mateixa estadística de velocitat efectiva; l'ordre d'execució del torn es resol mitjançant un sorteig uniforme (50% de probabilitat).
- **Pivot (Canvi tàctic / Retirada):** Maniobra de canvi de Pokémon orientada a recuperar l'avantatge posicional o de tipus, sovint acompanyada d'atacs com *U-turn* o *Volt Switch*.
- **Phazing (Expulsió forçada):** Forçar el canvi del Pokémon rival mitjançant moviments com *Roar* o *Whirlwind*, dissipant automàticament tots els seus increments d'etapa estadística.
- **STAB (Same-Type Attack Bonus):** Bonificació passiva del $\times 1,5$ al dany final quan el tipus elemental del moviment utilitzat coincideix amb el tipus del Pokémon atacant.
- **Ladder (Classificació pública):** Sistema oficial de rànkings competitiu en línia de la plataforma Pokémon Showdown, basat en el sistema de puntuació Elo/Glicko-1.

A.2.2 Agents de referència (*Baselines*)

- **random (RandomPlayer):** Agent de control inferior que escull uniformement a l'atzar entre totes les accions legals del torn.
- **max_power (MaxBasePowerPlayer):** Agent heurístic ingenu que executa sempre l'atac amb la potència base nominal més gran, ignorant tipus i debilitats.
- **simple_heuristic (SimpleHeuristicsPlayer):** Heurística de referència de la llibreria *poke-env*, adaptada amb suport bàsic per a Teracristal · lització.
- **abyssal (AbyssalPlayer):** Controlador basat en regles expertes de la literatura científica procedent del projecte *PokéChamp*.
- **safe_one_step / one_step:** Algorisme de cerca prospectiva determinista d'un pas basat en el mòdul de cerca de *PokéChamp*.

A.2.3 Acrònims metodològics i algorítmics

- **POSG (Partially Observable Stochastic Game):** Joc estocàstic amb informació parcialment observable, formalització matemàtica del combat Pokémon.
- **POMDP (Partially Observable Markov Decision Process):** Procés de decisió de Màrkov parcialment observable.
- **DRL (Deep Reinforcement Learning):** Aprenentatge per reforç profund.
- **PPO (Proximal Policy Optimization):** Algorisme d'optimització de polítiques proximals per a aprenentatge per reforç.

- **MaskablePPO:** Variant de PPO amb emmascarament d'accions invàlides en la capa de sortida de la política.
- **BC (*Behavioral Cloning*):** Clonatge conductual supervisat per transferir demostracions expertes cap a una xarxa neuronal.
- **MCTS (*Monte Carlo Tree Search*):** Cerca en arbre de Monte Carlo amb simulació prospectiva.
- **UCB1 / PUCT:** Criteris de selecció per al balanç entre exploració i explotació en nodes d'arbres de cerca.
- **MLE (*Maximum Likelihood Estimation*):** Estimació de màxima versemblança emprada per a l'ajust dels paràmetres de força en el model Bradley–Terry.

A.3 Catàleg complet i fitxa tècnica dels agents

Per facilitar la consulta ràpida durant la lectura de la memòria i la defensa del treball, aquesta secció sintetitza la totalitat dels agents implementats i avaluats al llarg de la investigació. La Taula A.3 recull els sis agents de referència (*baselines*) i la seqüència incremental de les catorze variants heurístiques (v1–v14). Totes aquestes polítiques s'avaluen en la matriu creuada completa de 28×28 cel·les dirigides amb una mida mostral de $n = 10.000$ enfrontaments per cel·la.

D'altra banda, la Taula A.4 documenta els agents pertanyents a les famílies de cerca adversarial (Minimax i MCTS), aprenentatge per imitació jeràrquica (XGBoost), aprenentatge per reforç profund (MaskablePPO) i models generatius de llenguatge (LLM). Cal destacar que:

- Els agents de cerca (v15–v20) i d'imitació híbrida (v21) reutilitzen el nucli de v14 com a avaluador de fulla o prior d'acció, garantint que les diferències observades s'atribueixin exclusivament a l'algorisme de decisió i no a un biaix en el coneixement de domini.
- La família MCTS (v18–v20) s'avalua a $n = 1.000$ a causa de l'elevat cost de la simulació estocàstica local (LocalSim), mentre que les heurístiques i el Minimax analític operen a $n = 10.000$.
- L'agent de reforç profund MaskablePPO s'avalua en un experiment independent de $n = 10.000$ partides contra l'oponent terminal del currículum (v12).
- Els agents basats en LLM (**PokéChamp** i **PokéLLMon**) s'executen com a estudi exploratori de viabilitat mitjançant inferència local amb Ollama.

A.4 Diccionari complet de dades de la telemetria (StatsBattle)

Com s'ha descrit a la Secció 3.7 i a la Secció 5.3.1, la captura de dades es realitza mitjançant la classe **StatsBattle**, que intercepta de forma asíncrona el flux WebSocket de Pokémon Showdown. Cada partida genera exactament un registre tabular estructurat en un esquema rígid de **70 columnes CSV**. Aquesta invariància és indispensable per al processament columnar d'alta velocitat sobre els 6,4 milions de partides de la matriu i per als 16 quaderns d'anàlisi exploratòria (EDA).

A continuació, les Taules A.5, A.6 i A.7 detallen la totalitat de les 70 variables agrupades en sis blocs funcionals:

1. **Bloc 1: Identificació i resultat del combat (8 variables):** Identifica la sala, els agents implicats, la durada en torns i el desenllaç de la partida.

Taula A.3: Catàleg complet i fitxa tècnica dels agents de referència (*baselines*) i heurístics (v1–v14). Totes les classes hereten de **Player** de *poke-env* i operen a la matriu 28×28 amb $n = 10.000$ partides per cel · la.

Agent	Classe Python	Mecànica diferencial / Coneixement de domini	Latència
random	RandomPlayer	Trie uniforme entre totes les accions legals. Control inferior agnòstic.	< 0,1 ms
max_power	MaxBasePowerPlayer	Selecció de l'atac amb major potència base nominal. Mai realitza canvis.	< 0,1 ms
simple_heuristic	TrueSimpleHeuristics-Player	Heurística de <i>poke-env</i> adaptada amb càlcul bàsic de tipus i Teracristal · lització.	≈ 0,2 ms
abyssal	AbyssalPlayer	Heurística de PokéChamp: ponderació d'avantatge de tipus i revisió de banqueta.	≈ 0,3 ms
one_step	SafeOneStepPlayer	Lookahead determinista d'un pas: dany esperat ponderat per precisió i STAB.	≈ 0,4 ms
safe_one_step	SafeOneStepPlayer	Àlies segur de one_step sense dependència del mòdul LocalSim .	≈ 0,4 ms
v1	HeuristicV1	Dany <i>greedy</i> directe: potència base × efectivitat × STAB. Mai canvia.	≈ 0,1 ms
v2	HeuristicV2	Càlcul de dany amb estadístiques reals (Atk/Def, cremada) i pivots defensius.	≈ 0,2 ms
v3	HeuristicV3	Nucli idèntic a v2 amb instrumentació de telemetria per freqüència de moviments.	≈ 0,2 ms
v4	HeuristicV4	Consciència de clima/terreny, precisió/prioritat i selecció de substitut per tipus.	≈ 0,3 ms
v5	HeuristicV5	Extensió de v4 conscient dels modificadors d'etapa acumulats (−6 a +6).	≈ 0,3 ms
v6	HeuristicV6	Consolidació lleugera sobre v3: clima, terreny i prioritat amb pivot primitiu.	≈ 0,2 ms
v7	HeuristicV7	Punt d'inflexió: reescriptura amb suma ponderada de matchup; canvis voluntaris.	≈ 0,4 ms
v8	HeuristicV8	Detecció de KO garantit amb prioritat i filtrat d'immunitats conegudes revelades.	≈ 0,4 ms
v9	HeuristicV9	Gestió de tempo en torns lliures: perills d'entrada (<i>hazards</i>) i moviments de <i>setup</i> .	≈ 0,5 ms
v10	HeuristicV10	Tàctica sobre v8: condicions d'estat, sacrifici defensiu a baix HP i pivots actius.	≈ 0,5 ms
v11	HeuristicV11	Fusió integral dels blocs ortogonals de tempo (v9) i de tàctica (v10).	≈ 0,6 ms
v12	HeuristicV12	Mecàniques Gen IX: Teracristal · lització ofensiva/defensiva i selecció de capdavanter.	≈ 0,7 ms
v13	HeuristicV13	Inferència amb atacs vistos, recuperació, explotació de bloqueig <i>Choice</i> i <i>phazing</i> .	≈ 0,8 ms
v14	HeuristicV14	Model de rival (predictiu/conservador), sondeig, interval de dany i solver de finals.	≈ 0,8 ms

Taula A.4: Catàleg complet dels agents de cerca adversarial (v15–v20), aprenentatge per imitació (v21–v22), aprenentatge per reforç profund (MaskablePPO) i models de llenguatge (LLM).

Agent	Classe Python	Mecànica diferencial / Arquitectura	n	Latència
v15	HeuristicV15Minimax	Maximin analític pur d'un torn sobre matriu M_{ij} (criteri HP, penalització $\times 1,5$).	10.000	$\approx 2,1$ ms
v16	HeuristicV16Minimax	Maximin d'un torn amb fulla enriquida (perills, <i>setup</i> , estats i recuperació).	10.000	$\approx 2,8$ ms
v17	HeuristicV17Minimax-Hybrid	Maximin híbrid amb prior heurístic (+0,15 afegit a la recomanació de v14).	10.000	$\approx 3,2$ ms
v18	HeuristicV18MCTS	MCTS ras ($d = 1$): UCB1 ($C = 1,4$), 100 simulacions de 5 torns amb LocalSim.	1.000	≈ 48 ms
v19	HeuristicV19MCTS	MCTS amb selecció UCB1 i fulla enriquida amb rols estratègics (Win-Con, Vital Wall).	1.000	≈ 55 ms
v20	HeuristicV20MCTSHybrid	MCTS amb selecció PUCT i prior concentrat ($P = 0,70$ a l'acció de v14).	1.000	≈ 62 ms
v21	HeuristicV21XGBoost	Imitació híbrida: dreceres de v14, macro XGBoost ($Elo \geq 1800$), micro v14.	10.000	$\approx 1,4$ ms
v22	HeuristicV22PureIL	Imitació pura dual: macro XGBoost, micro canvi contrafactual i micro atac après.	10.000	$\approx 2,6$ ms
MaskablePPO	MaskablePPO	DRL Actor-Critic MLP 2×256 , obs 328-d, inicialització BC i currículum de 4 fases.	10.000	$\approx 0,8$ ms
PokéChamp	LLMPlayer	Inferència LLM Ollama (Qwen 3 8B / Qwen 2.5 7B) amb serialització d'estat i CoT.	Explor.	$\sim 3-8$ s

- Bloc 2: Robustesa, errors i decisions (6 variables):** Registra la consistència del flux d'ordres, comptabilitzant accions per defecte (*fallbacks*) i ordres rebutjades pel protocol.
- Bloc 3: Salut, composició d'equips i supervivència (10 variables):** Mesura el desgast dels conjunts de Pokémon, la salut percentual agregada i la llista d'espècies en joc.
- Bloc 4: Mobilitat, condicions de camp i atzar RNG (14 variables):** Distingeix els canvis voluntaris dels forçats (debilitament o expulsió via `|drag|`), els efectes de camp actius, l'ús de Teracristal · lització i els esdeveniments estocàstics de cops crítics, fallades i efectivitats.
- Bloc 5: Activació de regles heurístiques i ablació de domini (12 variables):** Quantifica l'impacte marginal de cada bloc de regles (col · locació de trampes, moviments d'amplificació *setup*, filtres de KO garantit i canvis per aparellament).
- Bloc 6: Telemetria de cerca i models d'aprenentatge (20 variables):** Registra el diagnòstic intern dels algorismes avançats, incloent-hi dreceres de seguretat (`ko_guards`, `loop_guards`), decisions macro d'XGBoost, decisions de cerca (Minimax/MCTS), resolucions de finals i la mètrica de discrepància respecte a v14.

Taula A.5: Diccionari de dades de telemetria (**StatsBattle**): blocs 1 (Identificació i resultat), 2 (Robustesa i decisions) i 3 (Salut, equips i supervivència).

Columna (Camp CSV)	Tipus	Descripció semàntica i procedència
Bloc 1: Identificació i resultat del combat (8 variables)		
<code>battle_id</code>	<code>string</code>	Identificador únic de la sala de combat assignat per Pokémon Showdown.
<code>format</code>	<code>string</code>	Modalitat de combat oficial (<code>gen9randombattle</code>).
<code>heuristic</code>	<code>string</code>	Etiqueta de l'agent protagonista avaluat (p. ex., <code>v14</code> , <code>v21</code> , <code>random</code>).
<code>opponent</code>	<code>string</code>	Etiqueta de l'agent contrincant que s'enfronta al protagonista.
<code>winner</code>	<code>string</code>	Nom d'usuari de l'agent victoriós registrat en tancar la sala.
<code>won</code>	<code>boolean</code>	Indicador binari de victòria (1 si el protagonista guanya, 0 si perd).
<code>turns</code>	<code>integer</code>	Nombre total de torns transcorreguts fins al final del combat.
<code>timestamp</code>	<code>string</code>	Marca horària d'enregistrament de la fila en format ISO 8601.
Bloc 2: Robustesa, errors i decisions d'acció (6 variables)		
<code>decisions_us / _opp</code>	<code>integer</code>	Total de sol·licituds de decisió d'acció emeses pel simulador a cada jugador.
<code>fallback_moves_us / _opp</code>	<code>integer</code>	Vegades que l'agent ha recorregut a una acció de reserva en fallar el criteri principal.
<code>error_moves_us / _opp</code>	<code>integer</code>	Ordres invàlides o no permeses rebutjades pel protocol del servidor Showdown.
Bloc 3: Salut, composició d'equips i supervivència (10 variables)		
<code>fainted_us / _opp</code>	<code>integer</code>	Nombre de Pokémon debilitats al llarg de la batalla (escala 0 a 6).
<code>remaining_pokemon_us / _opp</code>	<code>integer</code>	Membres vius restants al final del combat (6 – <code>fainted</code>).
<code>total_hp_us / _opp</code>	<code>float</code>	Suma percentual dels punts de vida (HP) de tot l'equip (escala 0 a 600,0%).
<code>hp_perc_us / _opp</code>	<code>float</code>	Percentatge mitjà de vida restant respecte a la salut nominal d'inici de combat.
<code>team_us / _opp</code>	<code>string</code>	Llista serialitzada de les 6 espècies que componen l'equip generat per Showdown.

A.5 Especificació de prompts, serialització i raonament CoT dels agents LLM

La integració dels agents basats en models de llenguatge de gran escala (**PokéChamp** i **PokéLLMon**) s'articula mitjançant el paquet `src/p01_heuristics/agents/llm/` i el submòdul `pokechamp/`. Aquesta secció documenta el protocol de comunicació, el prompt de sistema, el format de serialització de l'estat i l'estructura del raonament en cadena de pensament (*Chain-of-Thought*, CoT).

A.5.1 Arquitectura d'inferència local

Per tal de garantir la reproductibilitat sense dependre d'APIs de pagament externes ni exposar dades fora de l'estació de treball, la inferència s'executa localment mitjançant el motor **Ollama** accelerat per GPU amb la targeta NVIDIA GeForce RTX 2080 (8 GB VRAM). El model de referència emprat és **Qwen 3 (8B)** (i alternativament *Qwen 2.5 7B*), seleccionat per la seva relació òptima entre capacitat de raonament estructurat, seguiment estricte d'instruccions en format JSON i contenció de memòria VRAM ($\approx 6,5$ GB en ús efectiu, evitant l'intercanvi lent amb memòria RAM).

Taula A.6: Diccionari de dades de telemetria (StatsBattle): blocs 4 (Mobilitat, condicions de camp i RNG) i 5 (Ablació de domini).

Columna (Camp CSV)	Tipus	Descripció semàntica i procedència
Bloc 4: Mobilitat, condicions de camp i atzar RNG (14 variables)		
voluntary_switches_us / _opp	integer	Nombre de canvis iniciats per decisió tàctica pròpia de la política.
forced_switches_us / _opp	integer	Canvis forçats per debilitament o per moviments d'expulsió (<i>phazing</i> via <code> drag </code>).
side_conditions_us / _opp	string	Trampes d'entrada (<i>Stealth Rock</i> , <i>Spikes</i>) i efectes de camp actius.
move_stats_us / _opp	string	Diccionari serialitzat de la freqüència d'ús individual de cada moviment (<code>nom:compte</code>).
crit_us / _opp	integer	Recompte d'atacs crítics infligits (interceptats mitjançant <code> -crit </code>).
miss_us / _opp	integer	Nombre d'atacs fallats per imprecisió pròpia (missatges <code> -miss </code>).
supereffective_us / _opp	integer	Cops molt efectius connectats (interceptats via <code> -supereffective </code>).
terastallized_us / _opp	boolean	Indicador de si l'agent ha consumit el seu ús de Teracristal · lització en la partida.
Bloc 5: Activació de regles heurístiques i ablació de domini (12 variables)		
hazard_sets_us / _opp	integer	Torns dedicats a col · locar perills d'entrada (operatiu a partir de v9).
hazard_removals_us / _opp	integer	Accions dedicades a dissipar trampes pròpies (<i>Rapid Spin</i> , <i>Defog</i>).
setup_uses_us / _opp	integer	Execució de moviments d'amplificació d'estadístiques (<i>Swords Dance</i> , <i>Calm Mind</i>).
ko_checks_us / _opp	integer	Activacions del filtre de KO garantit de l'adversari (a partir de v8).
matchup_switches_us / _opp	integer	Canvis motivats per la puntuació de l'aparellament de tipus (a partir de v7).
total_turns_us / _opp	integer	Torns efectius computats en combat per a cada jugador.

Taula A.7: Diccionari de dades de telemetria (StatsBattle): bloc 6 (Telemetria de cerca adversarial i aprenentatge automàtic).

Columna (Camp CSV)	Tipus	Descripció semàntica i procedència
Bloc 6: Telemetria de cerca adversarial i aprenentatge automàtic (20 variables)		
ko_guards_us / _opp	integer	Drecera de KO immediat abans de cridar el classificador XGBoost (a v21).
loop_guards_us / _opp	integer	Mecanisme de protecció contra bucles: força atacar si l'agent demana canviar 2 cops.
xgb_switches_us / _opp	integer	Decisions macro de canvi ordenades pel model après XGBoost ($p \geq \tau$).
xgb_stays_us / _opp	integer	Decisions macro d'atacar ordenades pel model XGBoost ($p < \tau$).
xgb_prob_sum_us / _opp	float	Suma acumulada de la probabilitat predita $p(\text{canvi})$ al llarg del combat.
search_switches_us / _opp	integer	Decisions de canvi seleccionades pels mòduls de cerca (Minimax o MCTS).
search_moves_us / _opp	integer	Decisions d'atac seleccionades pels mòduls de cerca adversarial.
endgame_solves_us / _opp	integer	Disparador del solver de finals exhaustiu quan queden ≤ 2 Pokémon per bàndol.
search_diff_us / _opp	integer	Discrepància: vegades que la cerca tria una acció diferent de la de v14.

A.5.2 Prompt de sistema (*System Prompt*)

Tots els missatges dirigits al model s'encapçalen amb una instrucció de rol persistent que fixa les prioritats estratègiques del combat segons les regles de Pokémon Showdown:

```
You are a pokemon battler that targets to win the pokemon battle. You can
choose to take a move or switch in another pokemon. Here are some battle
tips:
- Use status-boosting moves like swordsdance, calmmind, dragondance,
nastyplot strategically. The boosting will be reset when pokemon switch
out.
- Set traps like stickyweb, spikes, toxicspikes, stealthrock strategically.
- When face to a opponent is boosting or has already boosted its
attack/special attack/speed, knock it out as soon as possible, even
sacrificing your pokemon.
- If choose to switch, you forfeit to take a move this turn and the opposing
pokemon will definitely move first. Therefore, you should pay attention to
speed, type-resistance and defense of your switch-in pokemon to bear the
damage from the opposing pokemon.
- And if the switch-in pokemon has a slower speed then the opposing pokemon,
the opposing pokemon will move twice continuously.
```

A.5.3 Esquema de serialització textual de l'estat del combat

A cada torn, el mòdul extractor llegeix l'estat del combat des de *poke-env* i construeix un prompt d'instrucció que sintetitza l'història recent de torns, les condicions de camp, el Pokémon actiu, l'adversari i la llista filtrada d'accions legals:

```
Historical turns:
Turn 12: Opponent Dragapult used Shadow Ball! You took 52% damage. You
used Ice Beam! Opponent Dragapult took 88% damage.
Current battle state:
Opponent team's side condition: stealth rock
Your team's side condition: none
Your current pokemon: Lapras, Type: Water and Ice, HP: 48%, Status:
healthy, Ability: Water Absorb, Item: Leftovers (Restores 1/16 max HP each
turn)
Opponent current pokemon: Dragapult, Type: Dragon and Ghost, HP: 12%,
Status: healthy, Ability: Infiltrator
Your available moves:
[<move_name>] = ['icebeam', 'surf', 'thunderbolt', 'protect']
Your available switches:
[<switch_pokemon_name>] = ['corviknight', 'tinglu', 'ironvaliant']
```

A.5.4 Protocol d'acció JSON i traça de raonament CoT

El model està configurat amb sortida en mode JSON estricte (`json_format=True`) i temperatura $\tau = 0,3$. La resposta ha de contenir exclusivament una de les dues claus: `{"move": "<nom>"}` o `{"switch": "<nom>"}`. En el mode amb raonament explícit (*Chain-of-Thought*), el model genera una reflexió preliminar abans d'emetre l'ordre definitiva, avaluant seqüencialment:

1. **Anàlisi de velocitat relativa:** Dragapult presenta una velocitat base de 142 davant la velocitat de 60 de Lapras; per tant, el rival atacarà primer amb total seguretat.
2. **Càlcul d'amenança i supervivència:** Amb Lapras al 48% d'HP, un segon atac de Dragapult té una probabilitat elevada d'aconseguir el debilitament abans que Lapras pugui rematar-lo amb *Ice Beam*.

3. **Avaluació de banqueta:** Ting-Lu disposa del tipus Dark/Ground (immunitat a atacs elèctrics i resistència a Ghost) amb un valor defensiu superior al 90% d'HP restant per absorbir l'impacte d'entrada.
4. **Decisió final emesa:** {"switch": "tinglu"}.

Aquest procés de generació textual autoregressiva requereix entre 3 i 8 segons per torn en una GPU dedicada, fet que confirma la impossibilitat pràctica d'executar-lo en la matriu massiva de 6,4 milions de partides, però demostra la coherència estratègica del raonament en llenguatge natural.

A.6 Hiperparàmetres de Machine Learning (XGBoost i MaskablePPO)

Aquesta secció recull de manera unificada tots els paràmetres d'entrenament, arquitectures i funcions d'objectiu dels models d'aprenentatge automàtic supervisat (XGBoost) i d'aprenentatge per reforç profund (MaskablePPO). Les Taules A.8 i A.9 en consoliden la fitxa tècnica completa.

A.6.1 Classificador macro i avaluador micro XGBoost

El model macro d'aprenentatge per imitació s'entrena a partir d'aproximadament 1,12 milions de torns extrets de les repeticions d'usuaris d'elit a Pokémon Showdown ($Elo \geq 1800$). Per evitar fuites de dades entre torns d'un mateix enfrontament, la partició s'agrupa estrictament per identificador de combat (*GroupShuffleSplit* amb un 20% de test independent).

Atès que l'acció d'atacar és aproximadament 2,88 vegades més habitual que la de canviar en la distribució empírica humana, s'aplica el paràmetre `scale_pos_weight=2.88`. El llindar de decisió final per a la classe canvi ($y = 1$) es fixa en $\tau = 0,3500$, valor calibrat en validació creuada que equilibra la puntuació F_1 amb la concordança exacta de freqüència d'execució respecte als experts humans.

Per a l'agent d'imitació pura (v22), l'avaluador micro de moviments s'entrena sobre 11 atributs sintetitzats de candidats ofensius (potència base, STAB, efectivitat elemental de tipus, prioritat, condició d'estat i percentatge de salut restant), desvinculant-se de les identitats nominals de les repeticions per no patir inestabilitat semàntica.

A.6.2 Configuració i funció de recompensa de MaskablePPO

L'agent MaskablePPO s'implementa sobre la llibreria `sb3-contrib` amb PyTorch sota una política `MaskableActorCriticPolicy`. La xarxa neuronal utilitza dues capes ocultes de 256 unitats compartides ([256, 256]) que processen un vector continu dens de 328 característiques d'estat.

Formulació de la recompensa amb modelatge de potencial

Durant les fases d'entrenament del currículum, la funció de recompensa total per torn r_t combina un component base de victòria i desgast amb un modelatge de recompensa basat en potencial (*Potential-Based Reward Shaping*, PBRs) i una penalització de pas:

$$r_t = R_{\text{base}}(s_t, a_t, s_{t+1}) + \Delta\Phi(s_t, s_{t+1}) - 0,02 \quad (\text{A.1})$$

El component base R_{base} es defineix com:

$$R_{\text{base}} = 30,0 \cdot \mathbf{1}_{\text{win}} + 2,0 \cdot \Delta N_{\text{fainted}} + 1,0 \cdot \Delta\text{HP} \quad (\text{A.2})$$

on $\mathbf{1}_{\text{win}} \in \{+1, -1, 0\}$ indica victòria, derrota o partida no conclosa; $\Delta N_{\text{fainted}}$ és la diferència neta de Pokémon rivals respecte als propis debilitats; i ΔHP és la diferència de percentatge de salut restant entre tots dos bàndols.

El potencial tàctic $\Phi(s)$ s'avalua sobre l'estat del combat s :

$$\begin{aligned} \Phi(s) = & 0,3 \sum_{k \in \{\text{atk}, \text{spa}, \text{spe}\}} \max(0, \text{boost}_k) - 0,1 \sum_{j \in \{\text{atk}, \text{def}, \text{spa}, \text{spd}, \text{spe}\}} |\min(0, \text{boost}_j)| \\ & + 0,3 \cdot \mathbf{1}_{\text{opp_status}} + 0,5 \cdot N_{\text{opp_hazards}} - 1,0 \cdot W_{\text{own_hazards}} \end{aligned} \quad (\text{A.3})$$

on $\mathbf{1}_{\text{opp_status}}$ indica si el Pokémon actiu rival pateix un estat alterat greu (*sleep*, *burn*, *toxic*, *paralysis*, *freeze*); $N_{\text{opp_hazards}}$ és el nombre de perills d'entrada col·locats al camp rival; i $W_{\text{own_hazards}}$ és el pes ponderat dels perills que afecten el camp propi.

La recompensa derivada del potencial es computa exclusivament com la diferència temporal $\Delta \Phi = \Phi(s_{t+1}) - \Phi(s_t)$, garantint que no s'alteri la política òptima del POSG subjacent d'acord amb el teorema de conservació de potencial de Ng et al. [36]. El cost de pas $-0,02$ penalitza la inacció i incentiva l'agent a cloure la partida de manera resolutiva.

Inicialització per Clonatge Conductual (BC)

A la Fase 2 del currículum, la xarxa s'inicialitza mitjançant Clonatge Conductual (*Behavioral Cloning*) supervisat sobre 400 partides d'enfrontament entre instàncies de l'heurística **v8**. La pèrdua d'entropia creuada s'optimitza exclusivament sobre els paràmetres de l'actor mitjançant l'optimitzador Adam ($\eta = 10^{-3}$, 15 èpoques), transferint el coneixement de domini abans de reprendre l'ajust fi mitjançant descens de gradient proximal a taxa reduïda ($\eta = 5 \times 10^{-5}$).

Taula A.8: Consolidació d'hiperparàmetres per als models d'aprenentatge supervisat per imitació (XGBoost).

Model / Mòdul	Hiperparàmetre	Valor / Configuració adoptada
XGBoost: Classificador Macro d'Alt Nivell (v21 i v22)		
XGBClassifier	Arbres (n_estimators)	300 estimadors
	Profunditat màx. (max_depth)	6 nivells
	Taxa d'aprenentatge (learning_rate)	0,08
	Balanç de classes (scale_pos_weight)	2,88 (ràtio Atac/Canvi en entrenament)
	Mostreig (subsample , colsample)	0,85 en files i 0,85 en columnes
	Funció de pèrdua (eval_metric)	Pèrdua logística binària (" logloss ")
	Llindar de decisió calibrat (τ)	0,3500 (calibrat per concordança de freqüència humana i F1)
	Partició de dades	<i>GroupShuffleSplit</i> per battle_id (80% train, 20% test)
	Mida del conjunt	1,12 milions de torns d'experts (Elo ≥ 1800 , ≈ 1.150 columnes)
XGBoost: Avaluador Micro de Candidats de Moviment (v22)		
XGBClassifier	Arbres / Profunditat màx.	250 estimadors / 5 nivells
	Taxa d'aprenentatge / Mostreig	0,08 / subsample =0,85, colsample =0,85
	Espai de característiques	11 atributs sintètics (potència, STAB, efectivitat, prioritat, HP)

Taula A.9: Consolidació d'hiperparàmetres per al model d'aprenentatge per reforç profund (MaskablePPO) i clonatge conductual.

Component / Mòdul	Hiperparàmetre	Valor / Configuració adoptada
MaskablePPO: Model A (Fase 3 del Currículum)		
MaskablePPO	Arquitectura de xarxa (net_arch)	MLP dues capes de 256 unitats compartides ([256, 256])
	Dimensió d'observació	Vector continu dens de 328 valors normalitzats
	Espai d'accions (action_space)	Discret de 14 branques amb emmascarament d'accions invàlides
	Horitzó d'actualització (n_steps)	2.048 passos per entorn Showdown
	Mida del minilot (batch_size)	512 mostres
	Èpoques per actualització (n_epochs)	4 passades de gradient estocàstic
	Factor de descompte (γ)	0,99
	Paràmetre GAE (λ_{GAE})	0,95
	Coefficient de retallada (clip_range)	0,20
	Coefficient d'entropia (ent_coef)	0,01
	Coefficient de la funció de valor (vf_coef)	0,50
	Taxa d'aprenentatge (learning_rate)	5×10^{-5} (constant)
	Entorns paral·lels	8 ports Showdown concurrents ($N_{\text{envs}} = 8$)
Clonatge Conductual (BC) d'Inicialització per a PPO (Fase 2)		
Supervisat	Partides de demostració expertes	400 partides contra HeuristicV8
	Optimitzador i taxa	Adam, $\eta = 10^{-3}$, 15 èpoques supervisades sobre l'actor

Bibliografia

- [1] Aaron Traylor. Competitive pokémon may be impossible to explain. <https://www.youtube.com/watch?v=wrR6MquGU6A>, 2024. Anàlisi de complexitat de teoria de jocs i presa de decisions en Pokémon competitiu.
- [2] Shengyi Huang and Santiago Ontañón. A closer look at invalid action masking in policy gradient algorithms. In *The International FLAIRS Conference Proceedings*, volume 35, 2022.
- [3] Stuart J. Russell and Peter Norvig. *Artificial Intelligence: A Modern Approach*. Pearson, 4 edition, 2020.
- [4] Michael Wooldridge. *An Introduction to MultiAgent Systems*. John Wiley & Sons, 2 edition, 2009.
- [5] Guangcong Luo and Smogon Community. Pokémon showdown! <https://pokemonshowdown.com/>, 2011.
- [6] Haris Sahovic. poke-env: A python interface for creating pokémon showdown bots. <https://github.com/hsahovic/poke-env>, 2020.
- [7] The Pokémon Company International. The official Pokémon website and franchise overview. <https://www.pokemon.com>, 2026. [Portal oficial de la franquícia Pokémon].
- [8] Bulbapedia Contributors. Bulbapedia: The community-driven Pok’emon encyclopedia. <https://bulbapedia.bulbagarden.net/>, 2026. [En línia; accedit el 15 d’agost de 2026; mecàniques de combat, estadístiques, valors IV/EV, naturaleses i fenòmens de Generació IX].
- [9] Smogon University. The complete Pokémon damage formula: Generation IX mechanics and modifiers. https://www.smogon.com/dp/articles/damage_formula, 2026. [En línia; accedit el 4 de març de 2026].
- [10] Smogon University. Smogon strategy pokédex. <https://www.smogon.com/>, 2024. Comunitat principal d’estratègia Pokémon competitiva.
- [11] Jake Grigsby, Yuqi Xie, Justin Sasek, Steven Zheng, and Yuke Zhu. Human-level competitive Pokémon via scalable offline reinforcement learning with transformers. *arXiv preprint arXiv:2504.04395*, 2025.
- [12] Dan Huang and Scott Lee. A self-play policy optimization approach to battling Pokémon. In *2019 IEEE Conference on Games (CoG)*, pages 1–4, 2019. PPO amb *self-play* a Pokémon Showdown; la clau es conserva per traçabilitat de cites.
- [13] Cameron L. Angliss, Jiaxun Cui, Jiaheng Hu, Arrasy Rahman, and Peter Stone. VGC-Bench: A benchmark for generalizing across diverse team strategies in competitive Pokémon. *arXiv preprint arXiv:2506.10326*, 2025.

- [14] Smogon University. Random battle — Smogon dex. <https://www.smogon.com/dex/sv/formats/random-battle/>, 2024. Format d’equips aleatoris de Showdown (Generació IX).
- [15] Smogon University and Pokémon Showdown. Random battle sets (generació ix). <https://github.com/smogon/pokemon-showdown>, 2024. Pool públic de moviments, objectes i habilitats per Random Battle.
- [16] John Von Neumann and Oskar Morgenstern. *Theory of Games and Economic Behavior*. Princeton University Press, 1944. Edició commemorativa de 2007, ISBN 978-0-691-13061-3.
- [17] Claude E. Shannon. Programming a computer for playing chess. *Philosophical Magazine*, 41(314):256–275, 1950.
- [18] Murray Campbell, A. Joseph Hoane, and Feng hsiung Hsu. Deep blue. *Artificial Intelligence*, 134(1):57–83, 2002.
- [19] David Silver, Aja Huang, Chris J Maddison, Arthur Guez, Laurent Sifre, George Van Den Driessche, Julian Schrittwieser, Ioannis Antonoglou, Veda Panneershelvam, Marc Lanctot, et al. Mastering the game of go with deep neural networks and tree search. *Nature*, 529(7587):484–489, 2016.
- [20] David Silver, Thomas Hubert, Julian Schrittwieser, Ioannis Antonoglou, Matthew Lai, Arthur Guez, Marc Lanctot, Laurent Sifre, Dhharshan Kumaran, Thore Graepel, et al. A general reinforcement learning algorithm that masters chess, shogi, and go through self-play. *Science*, 362(6419):1140–1144, 2018.
- [21] Oriol Vinyals, Igor Babuschkin, Wojciech M Czarnecki, Michaël Mathieu, Andrew Dudzik, Junyoung Chung, David H Choi, Richard Powell, Timo Ewalds, Petko Georgiev, et al. Grandmaster level in starcraft ii using multi-agent reinforcement learning. *Nature*, 575(7782):350–354, 2019.
- [22] Christopher Berner, Greg Brockman, Brooke Chan, Vicki Cheung, Przemyslaw Debiak, Christy Dennison, David Farhi, Quirin Fischer, Shariq Hashme, Chris Hesse, et al. Dota 2 with large scale deep reinforcement learning. *arXiv preprint arXiv:1912.06680*, 2019.
- [23] Noam Brown and Tuomas Sandholm. Superhuman ai for heads-up no-limit poker: Libratus beats top professionals. *Science*, 359(6374):418–424, 2018.
- [24] Noam Brown and Tuomas Sandholm. Superhuman ai for multiplayer poker. *Science*, 365(6456):885–890, 2019.
- [25] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2nd edition, 2018.
- [26] Richard D. Smallwood and Edward J. Sondik. The optimal control of partially observable markov processes over a finite horizon. *Operations Research*, 21(5):1071–1088, 1973.
- [27] Leslie Pack Kaelbling, Michael L. Littman, and Anthony R. Cassandra. Planning and acting in partially observable stochastic domains. *Artificial Intelligence*, 101(1–2):99–134, 1998.
- [28] L. S. Shapley. Stochastic games. *Proceedings of the National Academy of Sciences*, 39(10):1095–1100, 1953.
- [29] Thomas Bayes. An essay towards solving a problem in the doctrine of chances. *Philosophical Transactions of the Royal Society of London*, 53:370–418, 1763.
- [30] John F. Nash. Equilibrium points in n -person games. *Proceedings of the National Academy of Sciences*, 36(1):48–49, 1950.

- [31] Daniel S. Bernstein, Robert Givan, Neil Immerman, and Shlomo Zilberstein. The complexity of decentralized control of markov decision processes. *Mathematics of Operations Research*, 27(4):819–840, 2002.
- [32] Edwin B. Wilson. Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212, 1927.
- [33] Ralph Allan Bradley and Milton E. Terry. Rank analysis of incomplete block designs: I. the method of paired comparisons. *Biometrika*, 39(3/4):324–345, 1952.
- [34] Arpad E. Elo. *The Rating of Chessplayers, Past and Present*. Batsford, 1978.
- [35] Haris Sahovic. Creating a pokémon battling bot with reinforcement learning. <https://hsahovic.github.io/poke-env/>, 2021. [En línia; accedit el 2026].
- [36] Andrew Y. Ng, Daishi Harada, and Stuart Russell. Policy invariance under reward transformations: Theory and application to reward shaping. In *Proceedings of the Sixteenth International Conference on Machine Learning (ICML)*, pages 278–287, 1999.
- [37] Sihao Hu, Tiansheng Huang, and Ling Liu. PokéLLMon: A human-parity agent for Pokémon battles with large language models. *arXiv preprint arXiv:2402.01118*, 2024.
- [38] Seth Karten et al. Pokechamp: Pokémon battle AI agents. <https://github.com/sethkarten/pokechamp>, 2024. Fork amb LocalSim, Abyssal, pokechamp i pokellmon.
- [39] Seth Karten, Andy L. Nguyen, and Chi Jin. PokéChamp: an expert-level minimax language agent. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pages 29205–29222. PMLR, 2025.
- [40] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A Rusu, Joel Veness, Marc G Bellemare, Alex Graves, Martin Riedmiller, Andreas K Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015.
- [41] Donald E. Knuth and Ronald W. Moore. An analysis of alpha-beta pruning. *Artificial Intelligence*, 6(4):293–326, 1975.
- [42] Cameron B. Browne, Edward Powley, Daniel Whitehouse, Simon M. Lucas, Peter I. Cowling, Philipp Rohlfschagen, Stephen Tavenor, Diego Perez, Spyridon Samothrakis, and Simon Colton. A survey of monte carlo tree search methods. *IEEE Transactions on Computational Intelligence and AI in Games*, 4(1):1–43, 2012.
- [43] Rémi Coulom. Efficient selectivity and backup operators in Monte-Carlo tree search. In *Computers and Games*, pages 72–83. Springer, 2007. Treball presentat a CG 2006.
- [44] Peter I. Cowling, Edward J. Powley, and Daniel Whitehouse. Information set Monte Carlo Tree Search. *IEEE Transactions on Computational Intelligence and AI in Games*, 4(2):120–143, 2012.
- [45] Levente Kocsis and Csaba Szepesvári. Bandit based Monte-Carlo planning. In *Proceedings of the 17th European Conference on Machine Learning (ECML)*, pages 282–293, 2006.
- [46] Dean A. Pomerleau. ALVINN: An autonomous land vehicle in a neural network. In *Advances in Neural Information Processing Systems*, volume 1, pages 305–313, 1989.
- [47] Brenna D. Argall, Sonia Chernova, Manuela Veloso, and Brett Browning. A survey of robot learning from demonstration. *Robotics and Autonomous Systems*, 57(5):469–483, 2009.

- [48] Stéphane Ross, Geoffrey Gordon, and J. Andrew Bagnell. A reduction of imitation learning and structured prediction to no-regret online learning. In *Proceedings of the 14th International Conference on Artificial Intelligence and Statistics (AISTATS)*, pages 627–635, 2011.
- [49] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [50] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [51] Vijay R. Konda and John N. Tsitsiklis. Actor-critic algorithms. In *Advances in Neural Information Processing Systems*, volume 12, pages 1008–1014, 2000.
- [52] John Schulman, Philipp Moritz, Sergey Levine, Michael Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation. In *International Conference on Learning Representations (ICLR)*, 2016. arXiv:1506.02438.
- [53] Guangcong Luo and Pokémon Showdown Community. Pokémon Showdown Public Replays Database. <https://replay.pokemonshowdown.com/>, 2024. Corpus públic de partides enregistrades a la plataforma de competició Pokémon Showdown.
- [54] Yoshua Bengio, Jérôme Louradour, Ronan Collobert, and Jason Weston. Curriculum learning. In *Proceedings of the 26th International Conference on Machine Learning (ICML)*, pages 41–48, 2009.
- [55] OpenJS Foundation. Node.js. <https://nodejs.org/>, 2024.
- [56] Charles R. Harris et al. Array programming with NumPy. *Nature*, 585:357–362, 2020.
- [57] The pandas development team. pandas-dev/pandas: Pandas. <https://doi.org/10.5281/zenodo.3509134>, February 2020.
- [58] Ritchie Vink. Polars: Blazingly fast dataframes in Rust and Python. <https://www.pola.rs/>, 2024.
- [59] Pauli Virtanen et al. SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods*, 17:261–272, 2020.
- [60] Fabian Pedregosa et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [61] Hugging Face. Datasets. <https://huggingface.co/docs/datasets>, 2024.
- [62] John D. Hunter. Matplotlib: A 2d graphics environment. *Computing in Science & Engineering*, 9(3):90–95, 2007.
- [63] Michael L. Waskom. seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60):3021, 2021.
- [64] Mark Towers et al. Gymnasium: A standard api for reinforcement learning. <https://gymnasium.farama.org/>, 2024.
- [65] Antonin Raffin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah Dormann. Stable-Baselines3: Reliable reinforcement learning implementations. <https://github.com/DLR-RM/stable-baselines3>, 2021.

- [66] Antonin Raffin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah Dormann. Stable-baselines3 contrib: Reliable reinforcement learning implementations. <https://github.com/Stable-Baselines-Team/stable-baselines3-contrib>, 2021. Inclou MaskablePPO per a entorns amb action masking.
- [67] Adam Paszke et al. PyTorch: An imperative style, high-performance deep learning library. <https://pytorch.org/>, 2019.
- [68] TensorFlow Team. Tensorboard: Tensorflow’s visualization toolkit. <https://www.tensorflow.org/tensorboard>, 2024.
- [69] Ollama Team. Ollama: Get up and running with large language models locally. <https://ollama.com/>, 2023.
- [70] Michael Page. Estudio de remuneración España: Tendencias del mercado laboral y salarios en Tecnología e Informática. <https://www.michaelpage.es/estudios-tendencias/estudio-remuneracion>, 2025. Informe de posicions tecnològiques i ciència de dades.
- [71] Hays España. Guía del mercado laboral: Tendencias salariales en el sector IT y Data Science. <https://www.hays.es/guia-mercado-laboral>, 2025. Anàlisi salarial per perfils júnior i sènior a Espanya.
- [72] NVIDIA Corporation. NVIDIA CUDA Parallel Computing Platform. <https://developer.nvidia.com/cuda-zone>, 2024.
- [73] An Yang, Baosong Yang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Zhou, Chengqiang Xu, Chengyuan Li, Chenze Shao, et al. Qwen2 technical report, 2024.
- [74] Antonin Raffin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah Dormann. Stable-Baselines3: Reliable reinforcement learning implementations. *Journal of Machine Learning Research*, 22(268):1–8, 2021.