

laSalle

UNIVERSITAT RAMON LLULL

Facultat Internacional de Comerç i Economia Digital La Salle

Treball de Final de Màster

Màster Universitari en Ciència de les Dades / Data Science

**Desenvolupament d'agents experts per a la
presa de decisions en entorns estocàstics i
d'informació imperfecta: El cas de Pokémon**

*Avaluació empírica comparativa d'heurístiques, cerca adver-
sària, MCTS, imitació i aprenentatge per reforç profund*

Alumne/a:

Gerard Pascual Fontanilles

Professor/a Ponent:

Jordi Peralta Dolz

Barcelona, Agost 2026

ACTA D'EXAMEN DEL TREBALL DE FINAL DE MÀSTER

Reunit el Tribunal qualificador en el dia de la data, l'alumne/a:

Gerard Pascual Fontanilles

Va exposar el seu Treball de Final de Màster, el qual va tractar sobre el tema següent:

Desenvolupament d'agents experts per a la presa de decisions en entorns estocàstics i d'informació imperfecta: El cas de Pokémon

Acabada l'exposició i contestades per part de l'alumne/a les objeccions formulades pels membres del tribunal, aquest va valorar l'esmentat Treball amb la qualificació de:

Qualificació Qualitativa	Qualificació Numèrica

Barcelona, a _____ de _____ de 2026

VOCAL DEL TRIBUNAL

VOCAL DEL TRIBUNAL

PRESIDENT DEL TRIBUNAL

Resum

Els videojocs d'estratègia complexos constitueixen un banc de proves exigent per a la recerca en Intel·ligència Artificial. En contrast amb jocs d'informació perfecta, els entorns amb informació parcial, accions simultànies i dinàmiques estocàstiques presenten reptes d'alta complexitat en predicció i planificació sota incertesa. Aquest Treball de Final de Màster desenvolupa i avalua de manera exhaustiva cinc paradigmes d'agents per a la presa de decisions en el format individual (`gen9randombattle`) del videojoc competitiu Pokémon, utilitzant el simulador de codi obert Pokémon Showdown i el marc d'integració *poke-env*.

El problema es formalitza com un Procés de Decisió de Markov Parcialment Observable (POMDP) amb accions simultànies, caracteritzat per un espai d'estats i accions combinatòriament dens i múltiples fonts d'incertesa (equips i moviments ocults, intenció de l'oponent i efectes aleatoris en el càlcul de dany). L'objectiu no és únicament aproximar una política que maximitzi la taxa de victòries sota pressupostos computacionals explícits, sinó també analitzar els patrons de comportament dels agents en situacions crítiques: la gestió del risc, la predicció de canvis (*switch prediction*), el control del ritme (*tempo*) i l'ús estratègic de la Teracristal·lització, avaluats mitjançant mètriques explicatives de decisió.

La proposta integra: (1) una seqüència estructurada de catorze agents heurístics (`v1-v14`) que incorporen incrementalment coneixement de domini (càlcul de dany, efectivitat de tipus, perills d'entrada, moviments de preparació, gestió d'estats alterats i Teracristal·lització); (2) variants de cerca adversària d'un torn (*minimax* `v15-v17`) amb funcions d'avaluació heurístiques a les fulles; (3) cerca en arbre de Monte Carlo rasa (*shallow* MCTS `v18-v20`) amb simulacions de cinc torns mitjançant un simulador local en memòria, comparant selecció UCB1 amb selecció PUCT guiada per priors heurístics; (4) models d'aprenentatge per imitació (`v21-v22`) basats en XGBoost entrenats sobre partides humanes d'alt nivell (Elo 1800+) per predir la decisió macro d'atacar o canviar; (5) un marc d'aprenentatge per reforç profund (*Deep Reinforcement Learning*, DRL; basat en *MaskablePPO*) amb espai d'accions emmascarat i inicialització per clonatge conductual (*Behavioral Cloning*); i (6) una infraestructura paral·lela i recuperable d'avaluació que instrumenta telemetria detallada per torn i càlcul de rànquings Bradley-Terry.

L'avaluació empírica comprèn una matriu competitiva de 28 agents (més de 6,4 milions de batalles), proves específiques de DRL i la integració exploratòria de models de llenguatge (LLM, com *PokéChamp* i *PokéLLMon*). Els resultats demostren que l'heurística experta (`v12`) lidera el rendiment global, superant el referent competitiu *Abyssal* amb una taxa de victòries del 59,9%. Així mateix, cap de les variants de cerca, d'imitació o de reforç profund aconsegueix superar el referent. L'anàlisi de telemetria revela que, en entorns amb informació parcial i alta estocasticitat, la cerca en profunditat es veu limitada per la incertesa de l'estat ocult del rival, mentre que els mètodes apresos necessiten incorporar coneixement de domini expert (com `v12`) per assolir un rendiment competitiu.

Paraules clau: Intel·ligència Artificial en jocs, presa de decisions sota incertesa, POMDP, agents heurístics, cerca adversària (Minimax), cerca en arbre de Monte Carlo (MCTS), aprenentatge per imitació (XGBoost), aprenentatge per reforç profund (MaskablePPO), models de llenguatge (LLM), telemetria, perills d'entrada (*hazards*), model Bradley-Terry.

Abstract

Complex strategy video games represent a demanding testbed for Artificial Intelligence research. In contrast to perfect-information games, environments characterized by partial information, simultaneous actions, and stochastic dynamics pose high-complexity challenges in prediction and planning under uncertainty. This Master’s Thesis develops and thoroughly evaluates five agent paradigms for decision-making in the singles format (`gen9randombattle`) of competitive Pokémon, utilizing the open-source simulator Pokémon Showdown and the *poke-env* integration framework.

The problem is formalized as a Partially Observable Markov Decision Process (POMDP) with simultaneous actions, characterized by a combinatorially dense state-action space and multiple sources of uncertainty (hidden teams and movepools, opponent intent, and random effects in damage calculation). The goal is not solely to approximate a win-rate-maximizing policy under explicit computational budgets, but also to analyze agent behavioral patterns in critical situations: risk management, switch prediction, tempo control, and the strategic usage of Terastallization, evaluated using explanatory decision telemetry.

The proposed work integrates: (1) a structured sequence of fourteen heuristic agents (`v1–v14`) that incrementally incorporate domain knowledge (damage calculation, type effectiveness, entry hazards, setup moves, status condition management, and Terastallization); (2) one-turn adversarial search variants (minimax `v15–v17`) with leaf heuristic evaluation functions; (3) shallow Monte Carlo Tree Search (shallow MCTS `v18–v20`) with 5-turn in-memory local simulations, comparing UCB1 selection with heuristic-prior-guided PUCT selection; (4) imitation learning models (`v21–v22`) based on XGBoost trained on high-level human replays (Elo 1800+) to predict macro-level decisions to attack or switch; (5) a Deep Reinforcement Learning (DRL) framework based on MaskablePPO featuring action masking and Behavioral Cloning initialization; and (6) a parallel and recoverable evaluation infrastructure instrumenting per-turn telemetry and Bradley-Terry ranking calculations.

Empirical evaluation comprises a competitive matrix of 28 agents (over 6.4 million battles), dedicated DRL experiments, and exploratory integration of Large Language Models (LLMs, such as *PokéChamp* and *PokéLLMon*). Results demonstrate that the expert heuristic (`v12`) leads overall performance, outperforming the competitive baseline *Abyssal* with a 59.9% win rate. Furthermore, none of the search, imitation, or deep reinforcement learning variants manage to surpass the baseline. Telemetry analysis reveals that, under partial observability and high stochasticity, deep tree search is constrained by uncertainty surrounding the opponent’s hidden state, whereas learned methods require incorporating expert domain knowledge (such as `v12`) to achieve competitive performance.

Keywords: Game Artificial Intelligence, decision-making under uncertainty, POMDP, heuristic agents, adversarial search (Minimax), Monte Carlo Tree Search (MCTS), imitation learning (XGBoost), Deep Reinforcement Learning (MaskablePPO), Large Language Models (LLM), telemetry, entry hazards, Bradley-Terry model.

Índex

Resum	i
Abstract	ii
1 Introducció	1
1.1 Contextualització i motivació	1
1.2 Objectius del treball	2
1.3 Estructura de la memòria	3
2 Marc teòric i contextualització	4
2.1 Pokémon com a domini de decisió	4
2.1.1 Què és Pokémon i com es desenvolupa una batalla	4
2.1.2 De l'espècie a les estadístiques finals	5
2.1.3 Tipus elementals, matriu d'efectivitat i categories de moviment	7
2.1.4 Teracristal·lització (Generació IX)	8
2.1.5 Velocitat, prioritat i l'empat de velocitat	8
2.1.6 Condicions d'estat primàries	9
2.1.7 Fonts d'estocasticitat irreductibles	9
2.1.8 Complexitat combinatòria en la configuració d'equips	10
2.1.9 El format Random Battle, el simulador Showdown i poke-env	11
2.1.10 Síntesi del domini: Pokémon com a entorn benchmark ideal per a la IA	11
2.2 Formalització matemàtica i marc d'inferència estadística	12
2.2.1 De la informació perfecta a la informació imperfecta	13
2.2.2 Formalització dels Processos de Decisió: MDP, POMDP i POSG	13
2.2.3 Estat de creença, matriu de recompenses i reducció d'enginyeria	15
2.2.4 Instanciació dels components a <code>gen9randombattle</code>	17
2.2.5 Marc d'avaluació estadística i mètodes d'inferència	18
2.3 Estat de l'Art en IA i Pokémon	21
2.3.1 Plataformes d'integració i entorns de simulació	21
2.3.2 Aprenentatge per reforç profund i exploració autònoma	21
2.3.3 Aprenentatge fora de línia i arquitectures basades en Transformers	22
2.3.4 Models de llenguatge de gran escala i cerca adversària híbrida	22
2.3.5 Mancances de la literatura i justificació d'aquest treball	22
2.3.6 Què afegeix aquest TFM	22
2.4 Fonaments teòrics dels cinc paradigmes de decisió	23
2.4.1 Heurístiques: coneixement com a ablació	23
2.4.2 Minimax d'un torn: resposta adversària immediata	24
2.4.3 Cerca de Monte Carlo a l'arrel (shallow MCTS)	25
2.4.4 Imitació i clonatge conductual	25
2.4.5 Aprenentatge per reforç profund amb emascarament d'accions	26
2.5 Síntesi del marc teòric	27

3	Metodologia i disseny experimental	28
3.1	Disseny general de l'estudi	28
3.1.1	Unitat d'anàlisi i telemetria	28
3.1.2	Concepte i responsabilitats del gestor de batalles	28
3.2	Contracte d'entorn i protocol de comunicació	29
3.2.1	Showdown i <i>poke-env</i> : àrbitre, protocol i objecte de batalla	30
3.2.2	Cicle d'un torn de batalla	31
3.3	Arquitectura conceptual d'avaluació massiva	32
3.3.1	Per què una arquitectura paral·lela i aïllada	33
3.3.2	Model coordinador i treballadors efímers	33
3.3.3	Represa, persistència i reinici del simulador	34
3.4	Disseny conceptual de les famílies d'agents	34
3.4.1	Agents de referència	35
3.4.2	Família Heurística: genealogia, hipòtesis d'ablació i la pregunta del valor marginal	35
3.4.3	Família Minimax: tres variants de resolució de la matriu d'un torn	38
3.4.4	Família MCTS: variants de simulació i mètrica de discrepància	39
3.4.5	Família d'Imitació Jeràrquica: desacoblament macro/micro i dues arquitectures	40
3.4.6	Família DRL (MaskablePPO): currículum de dificultat creixent	42
3.5	Contracte de comparació i espais d'observació	43
3.6	Matriu experimental i nivells mostrals	43
3.6.1	Orientacions recíproques, autojoc i rànquing Bradley–Terry	44
3.7	Mètriques de rendiment i telemetria d'execució	44
3.7.1	Mètrica primària: taxa de victòries i model Bradley–Terry	45
3.7.2	Mètriques secundàries i capa d'intercepció de telemetria (<i>StatsBattle</i>)	45
3.8	Protocols d'avaluació especials i abast	46
3.8.1	Integració exploratòria d'agents LLM	46
3.8.2	Protocol d'avaluació PPO contra referència	47
3.8.3	Avaluació en la classificació pública	47
3.9	Amenaces a la validesa i reproductibilitat	47
3.10	Síntesi i continuïtat	47
4	Entorn de desenvolupament i infraestructura de còmput	49
4.1	Organització del projecte	49
4.2	Evolució de l'arquitectura	49
4.2.1	Fase 1: prototipatge en portàtil	49
4.2.2	Fase 2: estació de treball	50
4.3	Accés remot: Tailscale	50
4.4	Bot de Telegram	50
4.5	Dependències	50
4.6	Anàlisi de cost econòmic i pressupost de recursos	51
4.6.1	Desglossament de recursos i optimització de costos	51
5	Implementació dels cinc paradigmes	53
5.1	Mapa del programari	53
5.2	Motor de batalla i capa d'integració	54
5.2.1	Servidor local de Pokémon Showdown	54
5.2.2	Versions i forks de <i>poke-env</i>	54
5.3	Arquitectura coordinador–processos de treball	54
5.3.1	Del <i>BattleManager</i> inicial al motor de la matriu	54
5.3.2	Per què subprocessos	55

5.3.3	Coordinador, cua de ports i processos efímers	55
5.3.4	Represa i escriptura per blocs	55
5.3.5	Reinici de Showdown	55
5.3.6	Esquema CSV i telemetria emmagatzemada	55
5.3.7	Automatització de la matriu	56
5.3.8	Contracte <code>BaseHeuristicv1</code> i <code>AgentFactory</code>	57
5.4	Heurístiques <code>v1–v14</code> : incorporació de coneixement	57
5.4.1	Estructura de classes i operacions compartides	57
5.4.2	Decisions que no es desprenen de la genealogia	57
5.5	Minimax d'un torn <code>v15–v17</code>	58
5.5.1	Construcció de la matriu	58
5.6	MCTS ras <code>v18–v20</code>	59
5.7	Imitació <code>v21–v22</code>	59
5.7.1	Dades i entrenament	60
5.7.2	Adaptadors en línia	60
5.8	Baselines i agents de llenguatge	61
5.9	PPO: MaskablePPO sobre Showdown	61
5.9.1	Organització del mòdul i dels artefactes	61
5.9.2	Entorn	61
5.9.3	Clonatge, arquitectura i recompensa	62
5.9.4	Execució de les fases 1, 1.5, 2 i 3	63
5.10	Desplegament a la classificació pública	64
5.10.1	Arquitectura del client i autenticació	64
5.10.2	Tolerància a fallades	65
5.11	Síntesi i continuïtat	65
6	Resultats	66
6.1	Protocol de lectura dels resultats	66
6.1.1	La matriu	66
6.1.2	Precisió de les estimacions	67
6.1.3	Volum i ponderació	67
6.2	Controls globals de la matriu	67
6.3	Fil conductor de <code>v1</code> a <code>v22</code>	69
6.4	L'escala heurística: tres canvis de règim	70
6.4.1	Altiplà <code>v1–v6</code> : rendiments decreixents del càlcul de dany	70
6.4.2	Primer salt: <code>v7</code> (i <code>v8/v10</code>)	71
6.4.3	Segon salt: <code>v9 / v11</code>	71
6.4.4	Tercer salt: <code>v12</code>	71
6.5	La inversió entre <code>v12</code> , <code>v13</code> i <code>v14</code>	72
6.5.1	On <code>v13</code> encara guanya	73
6.5.2	Per què no supera <code>v12</code> en global	73
6.5.3	Especialització de <code>v14</code> i pèrdua de rendiment local	74
6.6	Minimax d'un torn	76
6.6.1	Freqüència d'intervenció	76
6.6.2	<code>v16</code> i l'avaluació de la fulla	77
6.6.3	<code>v17</code> : prior heurístic	77
6.6.4	Canvis, durada i supervivència	78
6.7	MCTS ras: UCB a l'arrel i simulacions de cinc torns	80
6.7.1	Freqüència d'intervenció	81
6.7.2	Discrepància i resultat	81
6.7.3	PUCT i el prior heurístic	82
6.7.4	Indicadors d'efectes diferits	82

6.7.5	Comparació amb els agents de referència	83
6.7.6	Canvis, durada i supervivència	83
6.8	Aprenentatge per imitació: dues formes d'execució	85
6.8.1	Rendiment dins de la matriu	86
6.8.2	Pes efectiu del model a v21	87
6.8.3	Factors que limiten v22	87
6.8.4	Canvis, durada i supervivència	88
6.9	Comparació entre els cinc paradigmes	90
6.9.1	Abyssal com a agent de referència	92
6.9.2	Elo Bradley–Terry	93
6.10	Classificació pública: v14 contra persones	94
6.11	PPO contra v12	95
6.11.1	Resultat principal	95
6.11.2	Curriculum	96
6.11.3	Interpretació del límit observat	96
6.12	Discussió	97
6.12.1	Patró d'integració residual	97
6.12.2	Resposta conjunta a la pregunta de recerca	97
6.12.3	Limitacions específiques dels resultats	97
7	Conclusions i línies futures	98
7.1	Resposta a la pregunta de recerca	98
7.1.1	Grau d'acompliment dels objectius específics	98
7.2	Resultats principals	99
7.3	Contribucions	99
7.4	Limitacions	100
7.5	Línies futures	100
7.5.1	Millores algorítmiques i cerca profunda	100
7.5.2	Aprenentatge per reforç i imitació avançada	100
7.5.3	Avaluació en entorns reals i variabilitat de mostra	100
7.6	Consideracions ètiques, socials i d'impacte ambiental	101
7.6.1	Ètica i Fair Play en entorns de joc en línia	101
7.6.2	Impacte social i transferibilitat científica	101
7.6.3	Impacte ambiental i petjada de carboni	101
7.7	Tancament	102

Índex de figures

2.1	Logotip commemoratiu del 30è aniversari de la franquícia Pokémon (1996–2026), que celebra tres dècades d’història i d’impacte cultural global en l’entreteniment multimèdia i els videojocs.	4
2.2	Captura de la interfície de Pokémon Showdown durant un combat, on s’observen els Pokémon actius de cada bàndol, les banquetes de substituïts (actius, debilitats o ocults), els nivells, percentatges de vida (HP) i la informació visible de la batalla.	5
2.3	Intersecció dels quatre eixos fonamentals de complexitat en IA i la seva correspondència amb altres jocs.	12
2.4	Comparació estructural entre marcs de decisió: a) MDP (informació perfecta), b) POMDP (reducció a 1 decisor sota informació imperfecta), c) POSG teòric (formulació matemàtica abstracta amb 2 jugadors) i d) POSG instanciat en Pokémon Showdown amb el filtre del seu protocol.	15
2.5	Arquitectura d’avaluació d’una política heurística basada en la combinació de blocs de coneixement de domini.	24
2.6	Cicle clàssic de l’MCTS adaptat a simulacions de profunditat rasa a l’arrel ($d = 1$) amb rollouts heurístics.	25
2.7	Comparació estructural entre l’arquitectura d’imitació Híbrida (macro-decisió ML + micro-execució heurística) i l’arquitectura Dual Pura (dos classificadors XGBoost especialitzats).	26
2.8	Comportament de la funció d’objectiu retallada de PPO $\mathcal{L}^{\text{CLIP}}$ en funció de la raó de probabilitats $r_t(\theta)$ quan l’avantatge és positiu ($\hat{A}_t > 0$).	27
3.1	Disseny conceptual de l’estudi. La mateixa infraestructura avalua polítiques diferents i retorna tant el resultat com el comportament. El PPO comparteix simulador, però no entra a la matriu 28×28	29
3.2	Exemple d’estructura del missatge JSON de petició d’acció (<code> request </code>) enviat per Pokémon Showdown a cada jugador.	30
3.3	Tres capes del contracte. Showdown és l’àrbitre omniscient; <i>poke-env</i> tradueix el protocol a un objecte i a una ordre legal; la política és l’únic bloc específic de cada paradigma. La fletxa discontinua tanca el torn al motor.	31
3.4	Intercanvi d’un torn. Showdown filtra l’estat i no resol fins a tenir les dues ordres; <i>poke-env</i> estructura l’observació i legalitza l’acció. L’agent no accedeix mai a S	32
3.5	Arquitectura conceptual d’avaluació massiva. El coordinador gestiona la matriu i supervisa la consolidació; cada treballador opera en un procés aïllat amb un Showdown dedicat i escriu el seu lot temporal (<code>.csv</code>) abans de reciclar-se.	34
3.6	Genealogia de disseny dels agents (v1–v22). Les rutes de desenvolupament i ramificació entre variants s’agrupen per color segons el bloc de funcionalitat descrit a la llegenda.	36
3.7	Esquema del mètode Maximin d’un torn. Es construeix la matriu de recompenses M avaluant la resposta de l’adversari amb el nucli v14 i es tria l’acció amb el millor resultat en el pitjor cas ($\max_i \min_j M_{ij}$).	38

3.8	Arquitectura del cicle de cerca MCTS de quatre fases a l'arrel ($d = 1$). (1) Selecció de l'acció fill a^* (UCB1/PUCT); (2) Simulació local de 5 torns amb LocalSim; (3) Avaluació de la fulla s_5 amb el nucli v14; i (4) Retropropagació de la recompensa v i actualització d'estadístiques (Q, N) durant 100 iteracions.	39
3.9	Arquitectura d'imitació jeràrquica amb desacoblament macro/micro. El classificador macro (XGBoost) decideix si atacar o canviar a partir de partides d'alt nivell. A nivell micro, v21 delega l'execució al nucli heurístic v14, mentre que v22 utilitza un model dual pur (contrafactual per canvis i model d'atributs per atacs).	41
3.10	Curriculum PPO previst. Cada fletxa és una porta de validació independent de la corba d'entrenament. El clonatge s'insereix abans de la fase 2; la fase 3 mesura distància contra v12 encara que una porta anterior falli.	42
4.1	Tauler Kanban utilitzat per organitzar el desenvolupament del TFM.	49
5.1	Mapa de mòduls. p00 concentra simulació i persistència; p01–p05 afegeixen la política. Minimax, MCTS i imitació reutilitzen p01; PPO té entorn, checkpoints i avaluació propis.	54
5.2	Monitoratge durant una execució al prototip de 16 GB. La memòria creix mentre s'acumulen batalles i cau després de reiniciar processos; el patró va motivar els blocs curts, la recollida de memòria i els reinicis de Showdown.	56
5.3	Validació exploratòria de les repeticions humanes: desequilibri entre atacar i canviar, evolució de la taxa de canvi amb el torn i espècies més representades. La figura descriu el conjunt de dades, no el rendiment final de l'agent.	60
5.4	Taxa de canvi humana per espècie activa en una selecció del conjunt d'experts. La variació justifica incloure identitat i context, però no implica causalitat.	60
5.5	Pas d'inferència de MaskablePPO. La màscara s'aplica abans de mostrejar; l'índex s'envia com a ordre de Showdown, no com a enter cru.	62
5.6	Seqüència clonatge $\rightarrow$ reforç. El crític no s'entrena al clonatge; PPO n'aprèn el valor a partir de la recompensa modelada un cop l'actor ja imita el professor.	63
5.7	Corbes de les quatre etapes del curriculum. Són taxes durant l'entrenament sobre una política canviant; les validacions independents són les de la Taula 5.4. El panell de fase 3 correspon a la passada secundària, no al model A publicat.	64
6.1	Nombre de partides completades a les 784 cel · les. El bloc fosc correspon a 10.000 partides; les files i columnes clares de v18–v20, a 1.000. La creu no és un buit de dades, sinó el pressupost reduït de l'MCTS.	68
6.2	Distribució de la taxa de victòries de les 784 cel · les dirigides. El centre prop del 50% conté autojoc i enfrontaments equilibrats; les cues reflecteixen diferències grans, especialment davant de Random i MaxBasePower.	68
6.3	Distribució de la durada de les batalles analitzades. La mediana és de 17 torns i hi ha una cua dreta de partides excepcionalment llargues.	69
6.4	Taxa global de victòries de v1–v14 (253.000 partides per fila; les tres cel · les contra MCTS tenen $n = 1.000$). S'observen canvis destacats a v7, v9 i v12, seguits d'una disminució a v13 i v14.	70
6.5	v1–v14 contra els sis agents de referència ($n = 10.000$ per cel · la). v12 és el primer que deixa Abyssal i Simple Heuristic clarament per sota del 50%. Contra random, totes les heurístiques arriben al 97–98% i la columna deixa de ser discriminant.	72
6.6	Empremta tàctica de la seqüència heurística. v12 utilitza la Teracristal · lització gairebé una vegada per partida; v13, 0,20 vegades. ko_checks augmenta fins a aproximadament 15 a v14; la preparació i els perills d'entrada apareixen a partir de v9.	72

6.7	Enfrontaments directes, amb $n = 10.000$ per orientació. v12 i v13 no presenten una separació concloent; v14 obté 44,74% contra v12 i 41,60% contra v13	73
6.8	Enfrontaments de referència de v12 , v13 i v14 . Les files representen l'agent avaluat. Les cel·les MCTS tenen $n = 1.000$ i la resta, $n = 10.000$. v12 domina els agents de referència; v13 és més fort contra cerca i v21	74
6.9	Taxa de victòries de la inversió, agregada per paradigma d'oponent. v12 és millor contra agents de referència i altres heurístiques; v13 , contra minimax, MCTS i imitació híbrida.	75
6.10	Relació entre volum de canvis i taxa de victòries. La freqüència de canvi, per si sola, no mesura la qualitat de la política; cal distingir-ne el motiu.	75
6.11	Durada i membres de l'equip disponibles al final. v13 juga partides més llargues i conserva més Pokémon, mentre que v12 obté una taxa de victòries superior. . . .	76
6.12	Taxa de discrepància respecte de v14 en els torns en què s'executa el maximin. v15/v16 discrepen aproximadament en el 67% dels casos; v17 , amb prior +0,15, en el 37%. Les derrotes presenten una discrepància mitjana superior, una associació que no implica causalitat.	77
6.13	Indicadors d'efectes diferits: preparació, perills d'entrada i Teracristal·lització. v16 manté la preparació al voltant de 0,21 usos per partida, un nivell semblant al de v14 i molt inferior al de v12	77
6.14	Distribució de la durada i dels Pokémon restants a minimax. Les tres variants duren aproximadament 19 torns, però v17 conserva 1,39 membres de mitjana, davant d'1,28–1,29.	78
6.15	Distribució dels canvis voluntaris, dels canvis decidits pel maximin i de la fracció de decisions de cerca que són canvis. v17 presenta una mediana superior de canvis tot i discrepar menys de v14	79
6.16	Empremta v15–v17 : KO checks ~ 14 , cerca ~ 16 –18% dels torns, Tera $\sim 0,39$ (nivell v14 , no v12).	79
6.17	Enfrontaments de referència del minimax d'un torn. Les cel·les contra MCTS tenen $n = 1.000$. v17 millora respecte de les altres variants, però no supera el 50% contra v14	79
6.18	Taxa de victòries agrupada. v15 i v16 se superposen; v17 queda per sobre, encara per sota de v9/v11	80
6.19	Taxa de victòries del minimax per família d'oponent. El prior de v17 s'associa amb les millores principals contra heurístiques i MCTS.	80
6.20	Taxa de discrepància respecte de v14 entre les decisions de cerca. UCB1 (v18/v19) discrepa aproximadament en el 71% dels casos i PUCT (v20), en el 19%. Les derrotes mostren més discrepància mitjana, una associació que no estableix causalitat.	81
6.21	Indicadors d'efectes diferits a les simulacions de cinc torns. La preparació i els perills d'entrada es mantenen a nivells semblants als de v14	82
6.22	Durada i Pokémon restants a MCTS. v20 acaba lleugerament abans (18,33 torns) i conserva 1,40 membres de mitjana, davant d'1,21–1,22 a UCB1.	83
6.23	Distribució dels canvis a MCTS. PUCT augmenta la fracció de decisions de cerca que acaben en canvi i amplia la distribució de canvis voluntaris.	84
6.24	Empremta MCTS. Cerca 16–18% dels torns; KO ~ 14 /partida. v20 busca menys i acaba amb més HP. $n = 1.000$ per oponent.	84
6.25	Enfrontaments discriminants d'MCTS. Les files representen l'agent avaluat i totes les cel·les tenen $n = 1.000$. v20 s'acosta a Abyssal (49%) i no supera v12 (42,7%).	84
6.26	Taxa de victòries agrupada d'MCTS. v18 i v19 se superposen; v20 queda per sobre. Aquesta mitjana de 28.000 partides no té la mateixa ponderació que les files de 253.000.	85

6.27	Taxa de victòries d'MCTS per paradigma d'oponent ($n = 1.000$ a cada cel·la). PUCT millora principalment contra heurístiques i minimax.	85
6.28	Empremta dels agents d'imitació. v21 registra aproximadament 14 proteccions de debilitament per partida i consulta XGBoost en el 15% dels torns. v22 no té aquestes proteccions, consulta XGBoost en el 80% dels torns i activa la protecció de bucle en el 97% de les partides.	86
6.29	Freqüència d'ús de la política apresada. XGBoost intervé en el 15% dels torns de v21 i en el 80% dels de v22.	87
6.30	Durada i Pokémon restants dels agents d'imitació. v22 juga partides més llargues (20,07 torns) però acaba amb només 0,70 membres, davant d'1,33 a v21.	88
6.31	Distribució dels canvis a imitació. v22 fa aproximadament el doble de canvis voluntaris i rep moltes més ordres de canvi del classificador.	88
6.32	Indicadors tàctics. v22 i v12 utilitzen la Teracristal·lització amb freqüències similars, però obtenen resultats molt diferents; la freqüència no mesura la qualitat de la decisió.	89
6.33	Taxa de victòries agrupada de les dues arquitectures d'imitació. v21 se situa prop de v9; v22, per sota de v1.	89
6.34	Taxa de victòries dels agents d'imitació per família d'oponent. v21 supera v22 en els sis blocs, amb diferències d'aproximadament 20–26 pp.	89
6.35	Taxa de victòries de v21 i v22 per oponent. Tots els punts queden sobre la diagonal: v21 obté el valor superior en 28 de 28 enfrontaments. La diferència màxima és de 32,6 pp contra <code>safe_one_step</code>	90
6.36	Mapa de calor de la taxa de victòries a <code>gen9randombattle</code> . La fila és l'agent analitzat i la columna, l'oponent. Prefixos: (H) heurística, (MM) minimax, (MCT) MCTS, (IL) imitació i (B) agent de referència. Les cel·les amb MCTS tenen $n = 1.000$; la resta, $n = 10.000$	92
6.37	Escala Bradley–Terry ancorada a <code>random = 1000</code> , amb les dues orientacions. v12 i v13 obtenen les puntuacions més altes. v14, Abyssal i Simple Heuristic comparteixen el mateix valor arrodonit. Les files MCTS aporten menys partides al model.	93
6.38	Taxa de victòries i Elo de v14 a la classificació pública: 431 partides entre el 9 i el 10 de juny de 2026, 39,44% $\pm 4,6$ pp i Elo de 1085 a 1038 (màxim 1263).	94
6.39	Evolució de l'Elo al llarg de les 431 partides. Una mostra prefixa de 98 partides, presa prop del màxim, no representa el resultat final.	94
6.40	Victòries i derrotes segons la durada. El subconjunt de partides amb almenys 10 torns és descriptiu; la taxa principal utilitza les 431 partides sense filtrar.	95

Índex de taules

2.1	Exemple numèric d'aplicació de les fórmules d'escalat (2.1) i (2.2) per a un Pikachu a nivell 100 ($L = 100$) amb naturalesa <i>Timid</i> (+10% Velocitat, -10% Atac). Es mostra la contribució de l'estadística base (B), els valors individuals (IV), els punts d'esforç (EV) i el factor de naturalesa (N) fins a l'obtenció de la xifra final de combat.	6
2.2	Matriu d'efectivitat de tipus	7
2.3	Condicions d'estat primàries principals i els seus efectes mecànics en el combat Pokémon.	9
2.4	Exemple simplificat d'una matriu de recompenses en forma normal per a un torn de combat. Els valors representen la recompensa esperada del Jugador 1.	16
2.5	Mapatge POSG/POMDP al combat individual de Random Battle (Generació IX).	18
2.6	Síntesi del marc d'avaluació estadística, eines d'inferència i les seves propietats teòriques.	21
2.7	Comparació conceptual dels cinc paradigmes. Tots decideixen sobre el mateix simulador i format; canvia la font de coneixement i el còmput per torn.	23
3.1	Disseny conceptual de les catorze versions heurístiques. Cada versió aïlla un bloc de coneixement de domini.	37
3.2	Disseny del currículum PPO. Els llistats són criteris previstos per avançar; el compliment es presenta al Capítol 5 i als resultats.	42
3.3	Com cada paradigma representa observació i acció. El contracte extern (Showdown) és el mateix; canvia la representació interna.	44
3.4	Precisió aproximada al 95% en el cas de màxima variància ($p = 0,5$). La segona columna és el marge d'una proporció; la tercera, el marge de la diferència entre dues proporcions independents amb el mateix n . Són càlculs de planificació, no una anàlisi de potència.	44
4.1	Resum del pressupost econòmic i costos directes del TFM.	52
5.1	Correspondència entre els blocs de disseny de la Taula 3.1 i els components implementats.	58
5.2	Composició del vector d'observació de MaskablePPO. El model A publicat té 328 dimensions; les fases 1 i 1.5 n'utilitzaven 318 (sense dany estimat ni enfrontaments de canvi). Les 18 dimensions addicionals de la fase 4 no entren al resultat principal.	62
5.3	Espai d'accions Discrete(14) de MaskablePPO. La màscara de legalitat i la traducció a <code>/choose</code> comparteixen el mateix mapeig de slots [1].	62
5.4	Implementació i validació del currículum PPO. «Superada» es refereix al llistat previst, no al fet que s'executés una fase posterior.	63
6.1	Taxonomia dels 28 agents de la matriu.	66
6.2	Evolució de les preguntes i dels resultats entre v1 i v22	69
6.3	Seqüència heurística v1–v14	70

6.4	Enfrontaments directes, amb $n = 10.000$ partides independents per orientació. v12 i v13 no presenten una separació concloent; v14 queda per sota de tots dos. Les sumes recíproques properes al 100% són un control de coherència, no una prova amb partides aparellades.	73
6.5	Minimax analític d'un torn (253.000 partides per fila). La cerca s'executa en aproximadament el 16–18% dels torns. La fulla posicional de v16 gairebé no modifica la preparació; el prior de v17 redueix la discrepància respecte de v14 i obté la taxa més alta de la família.	76
6.6	MCTS ras amb UCB a l'arrel i 100 simulacions de cinc torns. Totes les cel·les tenen $n = 1.000$ (28.000 partides per agent). La fulla més rica de v19 no aporta una millora observable; PUCT amb prior sobre v14 redueix la discrepància i obté la taxa més alta de la família.	81
6.7	Imitació amb el mateix classificador XGBoost ($\tau = 0,5525$) i dues formes d'execució (253.000 partides per fila). v21 consulta el model en el 15% dels torns; v22 , en el 80%, sense proteccions de debilitament, i activa la protecció de bucle en el 97% de les partides.	86
6.8	Síntesi dels cinc paradigmes amb v12 com a comparador comú. Les variants són les que obtenen el millor resultat observat dins de cada família; aquesta selecció és posterior a l'experiment. L'MCTS té una mostra menor i el PPO no participa en la matriu completa.	90
6.9	Taxes globals descriptives contra els 28 oponents. Les files no MCTS tenen 253.000 partides i ponderen cada oponent MCTS una desena part que els altres; les files MCTS tenen 28.000 partides i ponderen tots els oponents igual. Els dos blocs no formen una única classificació comparable.	91
6.10	Enfrontaments de referència. Les files amb MCTS tenen $n = 1.000$ i la resta, $n = 10.000$. v12 contra Abyssal (59,91% $\pm 0,96$ pp) és el principal resultat contra un agent extern basat en regles.	91
6.11	Escala Bradley–Terry a gen9randombattle , ancorada a random = 1000 i ajustada amb les dues orientacions. Els agents no MCTS aporten 506.000 observacions i els MCTS, 56.000. No s'han calculat intervals: valors iguals després d'arrodonir no impliquen equivalència estadística.	93
6.12	Classificació pública de v14 contra persones.	94
6.13	Curriculum i avaluacions de MaskablePPO. El resultat principal és el del model A contra HeuristicV12 , amb $n = 10.000$ i les dues orientacions. La fase 4 només informa la finestra d'entrenament, no una avaluació independent.	95

Capítol 1

Introducció

1.1 Contextualització i motivació

Pokémon és un joc d'estratègia per torns caracteritzat per la informació parcial, les accions simultànies i les transicions estocàstiques. A cada torn, els jugadors han de decidir entre executar un moviment o substituir el Pokémon actiu sense conèixer amb certesa la configuració de l'equip rival, mentre que factors com la precisió dels atacs, els cops crítics i els efectes secundaris introdueixen aleatorietat inherent al combat.

En aquest context, un **agent** és un sistema autònom que percep l'estat observable de la batalla i selecciona una acció per maximitzar la seva esperança de victòria [2, 3]. Una **política** π formalitza aquesta presa de decisions assignant una distribució sobre les accions legals a partir de l'observació disponible. Els diferents enfocaments d'Intel·ligència Artificial aborden aquesta política des de perspectives diverses: mitjançant regles heurístiques dissenyades per experts, planificació en línia mitjançant cerca adversària o simulació en arbre (MCTS), o bé aprenentatge de patrons a partir de dades humanes i recompenses per reforç.

Aquest Treball de Final de Màster estudia i compara com cinc paradigmes d'agents afronten aquest problema de decisió sota condicions d'incertesa. L'objectiu no és construir un agent infal·libre, sinó avaluar empíricament implementacions concretes sota pressupostos computacionals explícits, en un entorn reproducible i amb una escala mostral que permeti quantificar amb rigor la precisió dels resultats.

Per a l'experimentació s'utilitza el simulador **Pokémon Showdown** [4] i la llibreria *poke-env* [5], focalitzant la recerca en el format individual **Random Battle de la Generació IX** (`gen9randombattle`). Tot i que la generació procedural d'equips introdueix una forta variabilitat inicial on la composició pot determinar l'avantatge d'una partida, l'execució d'un volum massiu de batalles per enfrontament permet diluir aquest soroll estocàstic i aïllar exclusivament la qualitat de la presa de decisions durant el combat.

Concretament, s'implementen i avaluen cinc formes de decidir sobre el mateix simulador i format:

1. **Heurístiques expertes (v1–v14)**: Aquest enfocament es basa en regles de domini dissenyades manualment que assignen una puntuació a cada acció legal segons l'estat del combat. Constitueixen la línia de base determinista i s'estudien mitjançant una seqüència d'ablacions estructurades, on les versions incorporen gradualment càlcul de dany, efectivitat de tipus, perills d'entrada (*hazards*), moviments de preparació (*setup*), gestió d'estats alterats i Teracristallització, destacant v12 com la variant experta principal.
2. **Cerca adversària Minimax d'un torn (v15–v17)**: Aquest paradigma construeix una matriu de recompenses d'accions simultànies d'un torn i avalua l'estat resultat amb funcions heurístiques a les fulles. Es comparen tres variants: v15 (avaluació basada purament en HP), v16 (afegeix bonificacions posicionals per preparació, perills d'entrada i estats) i v17

(suma un prior de +0,15 a l'acció recomanada per **v14**, reduint la discrepància respecte a l'heurística).

3. **Cerca en arbre de Monte Carlo rasa** (*shallow* MCTS **v18–v20**): Aquest mètode de planificació en línia executa 100 simulacions d'una profunditat rasa de cinc torns mitjançant un simulador local en memòria (**LocalSim**). Es comparen tres variants: **v18** (selecció UCB1 i avaluació bàsica d'HP/estats), **v19** (UCB1 amb fulla millorada per rols i dreceres tàctiques de **v14**) i **v20** (selecció **PUCT** guiada per priors de probabilitat extrets de l'heurística **v14**).
4. **Aprenentatge per imitació** (**v21–v22**): Aquest enfocament aprèn directament del comportament humà d'alt nivell (Elo 1800+) entrenant classificadors XGBoost sobre 1,12 milions de torns. Es comparen dues piles: **v21** és una versió **híbrida** (XGBoost decideix la decisió macro d'atacar o canviar, i **v14** executa l'acció micro concreta) i **v22** és un model d'**imitació pura dual** (executa dos caps XGBoost: un per a la decisió macro i un segon model per avaluar atributs de moviments, sense dependre de **v14**).
5. **Aprenentatge per reforç profund** (*MaskablePPO*): Aquest paradigma optimitza automàticament una política de xarxa neuronal mitjançant la interacció i la cerca de recompenses en un entorn amb accions emmascarades. L'entrenament segueix un currículum progressiu que comença contra oponents bàsics (**random** i **MaxBasePower**), s'inicialitza per clonatge conductual de l'heurística **v8** per superar el problema de l'exploració inicial (*cold start*), i finalment s'entrena amb *MaskablePPO* contra l'heurística experta **v12**.

Les quatre primeres famílies, juntament amb sis agents de referència, formen una matriu dirigida de **28 agents**. El PPO no forma part d'aquesta matriu principal: s'avalua en un experiment separat contra **v12**, l'agent amb millor resultat observat a la lliga. A més, models de llenguatge com *PokéChamp* i *PokéLLMon* s'integren de manera exploratòria.

1.2 Objectius del treball

L'objectiu principal d'aquest treball és avaluar i comparar empíricament el rendiment relatiu de les heurístiques expertes, la cerca adversària d'un torn, l'MCTS ras, l'aprenentatge per imitació i PPO en batalles **gen9randombattle**, sota pressupostos computacionals explícits i un protocol experimental rigorós.

Aquest objectiu general es concreta en els següents objectius específics:

1. **Formalització teòrica del domini:** Formalitzar el combat Pokémon com un procés de decisió estocàstic d'observació parcial (POMDP/POSG) i definir un marc teòric d'avaluació amb incertesa quantificada.
2. **Disseny metodològic, infraestructura i telemetria:** Definir el protocol experimental i el model de rànquing Bradley-Terry, construir una infraestructura d'execució paral·lela, escalable i recuperable davant de fallades sobre Pokémon Showdown i *poke-env*, i instrumentar un marc de telemetria per torn per quantificar mètriques explicatives del comportament (predicció de canvis, control del ritme o *tempo*, gestió del risc i ús de la Teracristal·lització).
3. **Paradigmes heurístics i de cerca en línia:** Desenvolupar la seqüència d'agents heurístics (**v1–v14**) com una ablació estructurada de coneixement de domini, i implementar i instrumentar variants de cerca adversària Minimax d'un torn (**v15–v17**) i MCTS ras de 5 torns (**v18–v20**) guiats per priors heurístics per analitzar si la cerca millora l'heurística de partida.

4. **Agents apresos i integració de LLMs:** Entrenar models d'aprenentatge per imitació XGBoost (v21–v22) sobre repeticions humanes d'alt nivell (Elo 1800+) per a decisions macro i micro, optimitzar MaskablePPO amb inicialització per clonatge conductual sobre v8 per avaluar si apropa el rendiment a v12, i integrar exploratòriament agents basats en LLM (*PokéChamp* i *PokéLLMon*) analitzant-ne la viabilitat i el cost d'inferència en temps real.
5. **Avaluació empírica massiva i rànkings:** Executar i analitzar la matriu competitiva de 28 agents (més de 6,4 milions de batalles), avaluant-ne els rànkings Bradley-Terry i creuant els resultats amb la telemetria per torn per comparar el rendiment relatiu i els patrons de decisió de cada paradigma.
6. **Avaluació externa al ladder públic:** Desplegar l'agent heurístic principal (v14) a la classificació pública oficial (*ladder*) de Pokémon Showdown per obtenir una mostra externa de rendiment contra jugadors humans reals en un entorn no controlat.

1.3 Estructura de la memòria

La resta d'aquesta memòria s'organitza en sis capítols interconnectats que desenvolupen el treball des dels fonaments teòrics fins a la discussió dels resultats empírics:

- El **Capítol 2 (Marc teòric i contextualització)** descriu les mecàniques de combat de Pokémon i el format `gen9randombattle`, formalitza el problema des de la Teoria de Jocs com un procés de decisió estocàstic d'observació parcial (POMDP/POSG), revisa l'estat de l'art en IA aplicada a jocs complexos i detalla els fonaments teòrics dels cinc paradigmes d'agents estudiats.
- El **Capítol 3 (Metodologia i disseny experimental)** estableix la separació entre el disseny conceptual i la implementació, defineix el gestor de batalles, el protocol d'avaluació de la matriu de 28 agents (més de 6,4M de batalles), el model de rànkings Bradley-Terry, el marc de telemetria per torn per a l'explicabilitat conductual i el control d'amenaçes a la validesa.
- El **Capítol 4 (Entorn de desenvolupament i infraestructura de còmput)** documenta l'organització del projecte mitjançant un tauler Kanban, l'evolució de l'arquitectura de maquinari (de prototip a l'estació de treball AMD Ryzen 7 5700X3D + RTX 2080), l'orquestració de múltiples servidors Pokémon Showdown en paral·lel, la gestió de persistència, el sistema de notificacions i l'anàlisi de cost econòmic i recursos computacionals.
- El **Capítol 5 (Implementació dels cinc paradigmes)** descriu el mapa del programari (`src/`) i tradueix a codi Python el coordinador de batalles, la seqüència d'ablacions heurístiques (v1–v14), la cerca Minimax (v15–v17), l'MCTS ras amb simulador local (v18–v20), els models d'imitació XGBoost (v21–v22), la canalització MaskablePPO amb clonatge conductual, la integració exploratòria de LLMs i l'arquitectura de desplegament operatiu (*Deployment*) per al *ladder* públic.
- El **Capítol 6 (Resultats)** analitza empíricament l'evolució de l'escala heurística, el rendiment de la cerca adversària, MCTS i la imitació, la comparació global dels cinc paradigmes, l'experiment DRL amb PPO contra v12, la validació de v14 contra jugadors humans al *ladder* públic i la discussió dels patrons residuals.
- El **Capítol 7 (Conclusions i línies futures)** respon a la pregunta de recerca principal, sintetitza les sis troballes empíriques clau, exposa les contribucions, analitza les limitacions observades, desenvolupa les línies de treball futur i avalua les consideracions ètiques, socials i d'impacte ambiental.

Capítol 2

Marc teòric i contextualització

Aquest capítol estableix els fonaments teòrics, mecànics i estadístics del treball. En primer lloc, es descriu el domini del combat Pokémon, les seves regles i el format `gen9randombattle`. En segon lloc, es formalitza matemàticament el problema mitjançant processos de decisió sota incertesa (POSG/POMDP) i es defineix el marc d'inferència estadística per a l'avaluació rigorosa dels agents. En tercer lloc, es revisa l'estat de l'art en intel·ligència artificial aplicada a Pokémon. Finalment, es desenvolupen els fonaments algorítmics dels cinc paradigmes de decisió estudiats.

2.1 Pokémon com a domini de decisió

Abans de formalitzar el problema des de la Teoria de Jocs, cal contextualitzar el domini del combat Pokémon. La formulació d'estadístiques, la matriu d'efectivitat, la Teracristal·lització, les regles de velocitat, les condicions d'estat i l'estocasticitat conformen el marc mecànic del joc. Així mateix, s'analitza la complexitat combinatòria d'equips (10^{139}) i es presenta el format `gen9randombattle` a Pokémon Showdown, el qual permet aïllar la presa de decisions executives dels agents.

2.1.1 Què és Pokémon i com es desenvolupa una batalla

Pokémon és una franquícia de videojocs creada l'any 1996 per Satoshi Tajiri i la companyia Game Freak per a la consola Game Boy de Nintendo [6]. El nom **Pokémon** prové de la contracció de la denominació anglesa **Pocket Monsters** (*Poketto Monstā* en japonès), fent referència a les criatures que es capturen en esferes portàtils (Poké Balls), es col·leccionen, s'entrenen i participen en combats. Coincidint amb la celebració del seu **30è aniversari (1996–2026)**, la franquícia s'ha convertit en un fenomen cultural global que abasta videojocs, sèries d'animació, cartes col·leccionables (TCG) i entreteniment multimèdia, on l'estratègia de combat manté un paper central en l'àmbit competitiu.



Figura 2.1: Logotip commemoratiu del 30è aniversari de la franquícia Pokémon (1996–2026), que celebra tres dècades d'història i d'impacte cultural global en l'entreteniment multimèdia i els videojocs.

En una batalla individual (*Singles*), cada jugador disposa habitualment d'un equip de sis

Pokémon, però només un és actiu a cada banda. L'objectiu és debilitar tots els membres de l'equip rival abans que el rival faci el mateix.

En cada torn, un jugador pot escollir un dels moviments disponibles o canviar el Pokémon actiu per un membre no debilitat de l'equip. Un Pokémon pot conèixer com a màxim quatre moviments. Alguns causen dany; d'altres modifiquen estadístiques, imposen una condició d'estat, alteren el camp o permeten canviar conservant la iniciativa. Els dos jugadors envien l'acció sense conèixer la decisió actual de l'altre. El motor ordena les accions segons la prioritat i la velocitat, comprova la precisió i resol el dany i els efectes secundaris.

Aquesta estructura fa que una acció no es pugui valorar de manera aïllada. Un atac molt potent pot ser inútil contra una immunitat de tipus; un canvi pot evitar un debilitament, però permetre que el rival col·loqui un perill d'entrada (*hazards*); i un moviment de preparació (*setup*) pot sacrificar el torn actual per augmentar la probabilitat de guanyar els següents.

Aquesta explicació inicial ofereix una introducció general i conceptual a la dinàmica de la batalla. En les subseccions següents es desenvolupen amb més profunditat i detall cadascun dels seus components mecànics fonamentals: la formulació de les estadístiques de combat, la matriu d'efectivitat de tipus, les regles de velocitat i prioritat, les condicions d'estat i les fonts d'estocasticitat.



Figura 2.2: Captura de la interfície de Pokémon Showdown durant un combat, on s'observen els Pokémon actius de cada bàndol, les banquetes de substituïts (actius, debilitats o ocults), els nivells, percentatges de vida (HP) i la informació visible de la batalla.

2.1.2 De l'espècie a les estadístiques finals

Cada Pokémon pertany a una espècie concreta amb atributs únics i disposa de sis estadístiques de combat: punts de salut (*Hit Points*, HP), atac, defensa, atac especial, defensa especial i velocitat [7, 8]. Els HP determinen quant dany pot rebre; atac i defensa intervenen en els moviments físics; atac especial i defensa especial, en els moviments especials; i la velocitat decideix quin Pokémon actua abans.

La xifra final que mostra el joc es construeix a partir de cinc components:

1. **Estadística base (B).** Pròpia de l'espècie. Dos Pikachu comparteixen les mateixes estadístiques base, però no necessàriament les mateixes xifres finals.
2. **Nivell (L).** Escala el valor final. Random Battle utilitza el nivell com a mecanisme d'equilibri entre espècies.

3. **Valors individuals (IV).** Cada estadística té un IV enter entre 0 i 31 [9].
4. **Punts d'esforç (EV).** Es poden distribuir fins a 510 EV en total, amb un màxim efectiu de 252 en una mateixa estadística [10].
5. **Naturalesa (N).** La majoria de naturaleses multipliquen una estadística per 1,1 i una altra per 0,9 [11].

Per a qualsevol estadística de combat diferent dels HP (Atac, Defensa, Atac Especial, Defensa Especial i Velocitat), la fórmula general d'escalat és:

$$\text{Stat} = \left\lfloor \left(\left\lfloor \frac{(2B + IV + \lfloor \text{EV}/4 \rfloor)L}{100} \right\rfloor + 5 \right) N \right\rfloor. \quad (2.1)$$

Per contra, els punts de salut (HP) segueixen un càlcul diferent per dues raons mecàniques: en primer lloc, cap naturalesa modifica els HP (no s'aplica el multiplicador N); en segon lloc, s'afegeix el terme $+L + 10$ en comptes de la constant fixa $+5$ per tal que la salut màxima escali de manera proporcional al nivell L de la criatura. Excepte casos especials com Shedinja (els HP del qual estan fixats permanentment pel motor de joc en 1 HP independentment del nivell, IVs o EVs), la fórmula de càlcul dels HP és:

$$\text{HP} = \left\lfloor \frac{(2B + IV + \lfloor \text{EV}/4 \rfloor)L}{100} \right\rfloor + L + 10. \quad (2.2)$$

Taula 2.1: Exemple numèric d'aplicació de les fórmules d'escalat (2.1) i (2.2) per a un Pikachu a nivell 100 ($L = 100$) amb naturalesa *Timid* (+10% Velocitat, -10% Atac). Es mostra la contribució de l'estadística base (B), els valors individuals (IV), els punts d'esforç (EV) i el factor de naturalesa (N) fins a l'obtenció de la xifra final de combat.

Estadística	Base (B)	IV	EV	Naturalesa (N)	Valor final
HP	35	31	0	—	211
Atac	55	31	0	0,9 (↓)	131
Defensa	40	31	0	1,0 (·)	116
Atac Especial	50	31	0	1,0 (·)	136
Defensa Especial	50	31	0	1,0 (·)	136
Velocitat	90	31	252	1,1 (↑)	306

Com s'observa a la Taula 2.1, les xifres finals calculades determinen el perfil competitiu real de la criatura durant el combat. Aquestes estadístiques finals —especialment la Velocitat efectiva (306) i la salut màxima (HP = 211)— són els valors concrets que el motor de Pokémon Showdown utilitza a cada torn per determinar l'ordre d'actuació i l'abast del dany produït. Conseqüentment, aquests valors constitueixen la base d'informació sobre la qual els agents d'IA estimen la velocitat relativa, el dany sota tirada i el risc de debilitament.

2.1.3 Tipus elementals, matriu d'efectivitat i categories de moviment

Un dels pilars estratègics del combat Pokémon és la relació elemental entre els 18 tipus existents (Foc, Aigua, Planta, etc.). Cal distingir clarament entre el **tipus del Pokémon** i el **tipus del moviment**:

- **Tipus del Pokémon (funció defensiva):** Cada criatura disposa d'un o dos tipus elementals pròpis (tipus únic o **dobles tipus**) que determinen les febleses, resistències i immunitats quan *rep* un atac rival.
- **Tipus del moviment (funció ofensiva):** Atribut propi de l'acció executada. Un Pokémon no està restringit a utilitzar atacs del seu mateix tipus elemental (p. ex., un Pokémon de Foc pot llançar un atac de Terra). Tanmateix, quan el tipus del moviment coincideix amb un dels seus tipus pròpis, el joc atorga una bonificació extra del +50% al dany denominada **STAB** (*Same Type Attack Bonus*, multiplicador $\times 1,5$).

Quan un Pokémon té **dobles tipus**, els multiplicadors de la matriu d'efectivitat (Taula 2.2) es combinen multiplicativament ($M = M_1 \times M_2$), generant efectes de **debilitat doble** ($\times 4$, p. ex., Roca contra Foc/Volador: $2 \times 2 = 4$), **resistència doble** ($\times 0,25$, p. ex., Planta contra Acer/Volador), **neutralització** ($\times 1$, p. ex., Lluita contra Insecte/Roca: $2 \times 0,5 = 1$) o **immunitat absoluta** ($\times 0$, p. ex., Elèctric contra Aigua/Terra: $2 \times 0 = 0$).

Els moviments es classifiquen en tres categories principals:

1. **Físics (Atac vs. Defensa):** Atacs de contacte físic o força directa.
2. **Especials (Atac Esp. vs. Def. Esp.):** Atacs d'energia, distància o projectils elementals.
3. **D'estat / Suport:** No causen dany directe; s'utilitzen per induir **condicions d'estat primàries** (com cremada, paràlisi o verí; vegeu Secció 2.1.6), modificar estadístiques, alterar el clima o col·locar perills d'entrada com *Stealth Rock*.

La diferenciació entre la via física i especial és crucial: la majoria de Pokémon s'especialitzen en un perfil defensiu físic o especial concret, la qual cosa obliga els agents d'IA a avaluar la categoria d'atac que exploti la feblesa estructural del rival.

Taula 2.2: Matriu d'efectivitat elemental en combat. Les files representen el tipus de l'atac executat i les columnes, el tipus del Pokémon defensor.

	NOR	FOC	AIG	PLA	ELE	GEL	LLU	VER	TER	VOL	PSI	INS	ROC	FAN	DRA	FOS	ACE	FAD
NOR													½	0			½	
FOC		½	½	2		2						2	½		½		2	
AIG		2	½	½					2				2		½			
PLA		½	2	½				½	2	½		½	2		½		½	
ELE			2	½	½				0	2					½			
GEL		½	½	2		½			2	2					2		½	
LLU	2					2		½		½	½	½	2	0		2	2	½
VER				2				½	½				½	½			0	2
TER		2		½	2			2		0		½	2				2	
VOL				2	½		2					2	½				½	
PSI							2	2			½					0	½	
INS		½		2			½	½		½	2			½		2	½	½
ROC		2				2	½		½	2		2					½	
FAN	0										2			2		½		
DRA															2		½	0
FOS							½				2			2		½		2
ACE		½	½		½	2							2				½	2
FAD		½					2	½							2	2	½	

2.1.4 Teracristal · lització (Generació IX)

La **Teracristal · lització** (*Terastallization* o *Tera*) és la mecànica transformativa exclusiva de la novena generació (*Pokémon Scarlet & Violet*, 2022) utilitzada en el format `gen9randombattle` [12]. Aquesta mecànica permet a cada jugador transformar un dels seus Pokémon una sola vegada per combat, canviant els seus tipus elementals originals per un únic **Tipus Tera** (*Tera Type*) seleccionat d'entre els 18 tipus de la matriu d'efectivitat (Taula 2.2).

La Teracristal · lització altera la dinàmica del combat a dos nivells clau:

- **Nivell defensiu:** El Pokémon adopta immediatament el Tipus Tera com a únic tipus defensiu actiu, substituint completament les seves febleses i resistències d'origen. Per exemple, un Pokémon de tipus Aigua/Volador que teracristal · litzant a tipus Planta passa a ser defensivament de tipus Planta pur, convertint una feblesa fatal de $4\times$ a l'Electricitat en una resistència del $0,5\times$.
- **Nivell ofensiu (STAB millorat):** Els atacs del nou Tipus Tera obtenen la bonificació de STAB ($1,5\times$). Tanmateix, si el Tipus Tera coincideix amb un dels tipus originals de la criatura (p. ex., un Pokémon de Foc teracristal · litzant a Foc), la bonificació de STAB s'amplifica fins al $2,0\times$ (+100% de dany). A més, el Pokémon conserva la bonificació de STAB $1,5\times$ en els atacs dels seus tipus primaris d'origen.

Des de la perspectiva de la presa de decisions en IA, la Teracristal · lització és un recurs d'ús únic d'alta rellevància estratègica. Permet realitzar accions de canvi de tipus instantani (*type-shift*) per sobreviure a atacs directes, anular un atac supereficax del rival i capgirar l'estat del combat en un únic torn, constituint un dels punts d'avaluació més complexos per a les polítiques de decisió dels agents.

2.1.5 Velocitat, prioritat i l'empat de velocitat

La **Velocitat** és una de les estadístiques més determinants en el combat Pokémon competitiu. Atacar primer no només concedeix la iniciativa tàctica (*tempo*), sinó que atorga la capacitat de debilitar la criatura rival abans que aquesta pugui executar la seva acció en aquell torn, anul·lant per complet el seu potencial de dany. Conseqüentment, saber quin Pokémon actuarà abans és un càlcul fonamental per als agents d'IA en avaluar els riscos i les oportunitats de cada moviment.

En cada torn, el motor de joc ordena l'execució de les accions seguint dos criteris seqüencials:

1. **Prioritat del moviment:** Cada moviment té un valor de prioritat discret que varia entre $+5$ i -7 . Els moviments de prioritat alta, com *Protect* ($+4$), *Extreme Speed* ($+2$) o *Quick Attack* ($+1$), s'executen sempre abans que qualsevol moviment de prioritat neutra (0), independentment de la Velocitat dels Pokémon. Per contra, moviments d'alta utilitat tàctica com *Trick Room* (-7) s'executen al final del torn.
2. **Velocitat efectiva:** Si dos moviments tenen la mateixa prioritat (habitualment 0), actua primer el Pokémon que tingui una Velocitat efectiva més alta en aquell torn, tenint en compte l'estadística final, els canvis d'etapa (de -6 a $+6$), els objectes equipats (com *Choice Scarf*, que augmenta la velocitat en un 50%) i les condicions d'estat (la paràlisi redueix la velocitat a la meitat).

Quan dos Pokémon tenen exactament la mateixa prioritat i la mateixa Velocitat efectiva final, es produeix un **empat de velocitat** (*Speed Tie*). El motor de joc resol aquest empat mitjançant una decisió aleatòria al 50% ($p = 0,5$).

2.1.6 Condicions d'estat primàries

Com s'ha introduït en les categories de moviment (Secció 2.1.3), els moviments d'estat o suport (com *Will-O-Wisp* o *Thunder Wave*) i certs efectes secundaris d'atacs físics o especials tenen la capacitat d'imposar **condicions d'estat primàries**. Aquestes alteracions són persistents i afecten negativament les capacitats operatives d'un Pokémon. Un Pokémon només pot patir una condició d'estat primària de manera simultània. A la Taula 2.3 es resumeixen les principals condicions d'estat i els seus efectes mecànics en el combat.

Taula 2.3: Condicions d'estat primàries principals i els seus efectes mecànics en el combat Pokémon.

Estat	Efecte en combat	Mecànica i impacte tàctic
Cremada	↓ 50% Atac físic	Causa un dany recurrent d'1/16 dels HP màxims per torn i redueix a la meitat l'Atac físic efectiu.
Paràlisi	↓ 50% Velocitat (Gen. VII+)	Redueix la Velocitat a la meitat i introdueix un 25% de probabilitat de no actuar per torn.
Verí / Tòxic	Dany recurrent per torn	El verí estàndard treu 1/8 dels HP per torn; el verí tòxic incrementa el dany a cada torn (1/16, 2/16...).
Son	Inhabilitació temporal	El Pokémon no pot actuar durant 1-3 torns consecutius.
Congelació	Inhabilitació estocàstica	El Pokémon no pot actuar; té un 20% de probabilitat de descongelar-se a cada torn.

Des de la perspectiva de la presa de decisions, induir una condició d'estat pot ser estratègicament superior a causar dany immediat. Per exemple, cremar un atacant físic enreda irreversiblement el seu potencial ofensiu, mentre que paraitzar un Pokémon ràpid permet a l'agent recuperar la iniciativa de velocitat en el combat.

2.1.7 Fonts d'estocasticitat irreductibles

El combat Pokémon és un entorn fortament estocàstic. Fins i tot quan un agent disposa d'informació completa sobre l'estat actiu, el resultat d'una decisió està subjecte a tres fonts d'aleatorietat irreductibles administrades pel simulador de joc [8, 13, 14]:

1. **Tirada de dany (*Damage Roll*):** El dany calculat per les fórmules oficials no és un valor fix, sinó que es multiplica per un factor aleatori extret d'una distribució uniforme discreta de 16 valors entre 0,85 i 1,00 ($\{0,85, 0,86, \dots, 1,00\}$) [13]. Així, un mateix atac pot debilitar un rival si es dona una tirada alta (1,00), però deixar-lo amb vida si la tirada és baixa (0,85).
2. **Precisió i evasió (*Accuracy*):** Molts moviments potents no tenen una precisió del 100% (p. ex., *Hydro Pump* amb 80% o *Focus Blast* amb 70%) [8]. L'agent ha de ponderar el dany esperat davant del risc de fallar l'atac i regalar un torn d'iniciativa al rival.
3. **Cop crític (*Critical Hit*):** A la Generació IX, la probabilitat base que un atac sigui crític és d'1 de cada 24 vegades ($p_{\text{crit}} \approx 4,17\%$) [8, 13]. Un cop crític aplica un multiplicador de $\times 1,5$ al dany, ignora els augments defensius del rival i ignora les reduccions d'atac de l'usuari.

Matemàticament, aquestes tres fonts d'estocasticitat es poden unificar en la formulació general del dany realitzat per un atac ofensiu:

$$\text{Dany} = I_{\text{hit}} \cdot [D_{\text{base}} \cdot C_{\text{crit}} \cdot R] \quad (2.3)$$

on D_{base} és el dany determinista brut derivat de les estadístiques, potència del moviment, modificadors d'etapa i la matriu de tipus (Equació 2.1 i Secció 2.1.3), mentre que els tres components estocàstics es defineixen com:

- $I_{\text{hit}} \sim \text{Bernoulli}(P_{\text{acc}})$ és l'indicador binari d'impacte, on $P_{\text{acc}} \in (0, 1]$ representa la precisió efectiva de l'atac. Si l'atac falla ($I_{\text{hit}} = 0$), el dany resulta immediatament 0.
- C_{crit} és la variable aleatòria del multiplicador de cop crític:

$$C_{\text{crit}} = \begin{cases} 1,5 & \text{amb probabilitat } p_{\text{crit}} = \frac{1}{24} \approx 4,17\% \quad (\text{Gen. IX}) \\ 1,0 & \text{amb probabilitat } 1 - p_{\text{crit}} \end{cases} \quad (2.4)$$

el qual, a més d'amplificar el dany, anul·la els modificadors estadístics desfavorables per a l'atacant.

- $R \sim \mathcal{U}(\{0,85, 0,86, \dots, 1,00\})$ és la tirada de dany extrema d'una distribució uniforme discreta de 16 valors, amb un valor esperat $\mathbb{E}[R] = 0,925$.

Així, l'esperança matemàtica del dany $\mathbb{E}[\text{Dany}]$ que un agent d'IA ha d'avaluar abans de seleccionar una acció ve donada per:

$$\mathbb{E}[\text{Dany}] = P_{\text{acc}} \cdot \mathbb{E}[R] \cdot ((1 - p_{\text{crit}}) \cdot D_{\text{norm}} + p_{\text{crit}} \cdot D_{\text{crit}}) \quad (2.5)$$

on D_{norm} i D_{crit} corresponen al dany base calculat sense i amb l'omissió de modificadors d'etapa respectivament. Cal destacar que, mentre que l'Equació 2.5 defineix l'esperança teòrica exacta del simulador de joc, a la pràctica els agents heurístics d'aquest treball utilitzen una aproximació determinista eficient ($\mathbb{E}[\text{Dany}] \approx P_{\text{acc}} \cdot D_{\text{base}}$), ometent la branca de cop crític ($p_{\text{crit}} \approx 4,17\%$) durant la puntuació instantània de moviments per optimitzar el temps de computació per torn.

Aquestes tres fonts d'estocasticitat, sumades a la generació procedural d'equips i als empats de velocitat (Secció 2.1.5), impedeixen l'existència de trajectòries de decisió deterministes i fan imprescindible quantificar la incertesa mitjançant simulacions estocàstiques (com l'MCTS) o polítiques d'avaluació de risc [15, 16].

2.1.8 Complexitat combinatòria en la configuració d'equips

Més enllà de la presa de decisions durant el combat, la fase prèvia de selecció i configuració d'un equip Pokémon presenta una explosió combinatòria extraordinària. Per a cada un dels **sis** membres de l'equip, cal triar l'espècie, un conjunt de 4 moviments d'entre el seu repositori disponible (M), la distribució de Punts d'Esforç (EVs) i Valors Individuals (IVs), la Naturalesa, l'Habilitat, l'Objecte equipat i el Tipus de Teracristallització (un dels 18 tipus possibles a la Generació IX).

Formalsment, el nombre de configuracions possibles per a una única posició o ranura de l'equip (C_{slot}) es pot quantificar com el producte del seu espai de paràmetres:

$$C_{\text{slot}} = N_{\text{espècies}} \times \binom{M}{4} \times N_{\text{objectes}} \times N_{\text{habilitats}} \times N_{\text{naturaleses}} \times N_{\text{tera}} \times N_{\text{stats}} \approx 10^{22} - 10^{23} \quad (2.6)$$

on $N_{\text{espècies}} \approx 10^3$ (corresponent a les 1.025 espècies de la Pokédex Nacional en formats lliures de construcció d'equips, o $\approx 5 \times 10^2$ espècies/formes competitives presents al repositori de `gen9randombattle`), la combinatòria de 4 moviments ($\binom{M}{4} \approx 10^4 - 10^5$), $N_{\text{objectes}} \approx 10^2$, $N_{\text{naturaleses}} = 25$, $N_{\text{tera}} = 18$ i les distribucions d'EVs/IVs $N_{\text{stats}} \approx 10^{10} - 10^{11}$. Per a un equip de **sis** Pokémon no ordenats, el nombre total de composicions d'equips (C_{equip}) s'obté mitjançant:

$$C_{\text{equip}} = \frac{(C_{\text{slot}})^6}{6!} \approx \frac{(10^{23})^6}{720} \approx 10^{135} - 10^{139}. \quad (2.7)$$

Estudis recents sobre entorns de decisió complexos en Pokémon com Angliss et al. [17] xifren l'espai combinatori d'equips competitiu en l'ordre de 10^{139} configuracions possibles. Per posar aquesta magnitud en perspectiva, el nombre de combinacions (10^{139}) supera astronòmicament el nombre total d'àtoms de l'univers observable (estimat en l'ordre de 10^{80}), així com l'espai d'estats de jocs clàssics de la IA com els escacs ($\approx 10^{47}$) o el Go ($\approx 10^{170}$).

Aquesta immensa varietat imposa un repte metodològic central en l'avaluació d'agents d'intel·ligència artificial. En formats d'equips lliures (*Teambuilding* o *Custom Teams*), la taxa de victòria d'un agent pot quedar fortament emmascarada per la superioritat o el desequilibri inicial de la composició de l'equip (meta-gaming), impossibilitant mesurar amb claredat si el rendiment es deu a una presa de decisions autònoma i tàctica de qualitat o a un avantatge estructural previ. Conseqüentment, per avaluar amb rigor el raonament executiu d'un agent cal desacoblar la fase de construcció d'equips de l'execució en combat.

2.1.9 El format Random Battle, el simulador Showdown i poke-env

Per aïllar la presa de decisions executives i eliminar els biaixos de construcció d'equips derivats de l'espai combinatori de 10^{139} equips (Secció 2.1.8), aquest treball utilitza com a marc experimental el format oficial **Random Battle** (`gen9randombattle`) [18]. En aquest format, el simulador restringeix el repositori d'espècies a un conjunt de $\approx 5 \times 10^2$ Pokémon competitiu de la Generació IX i assigna proceduralment a cada jugador un equip aleatori de sis Pokémon a l'inici del combat, amb configuracions optimitzades extretes del repositori públic de Smogon [19] i un mecanisme de reequilibrat dinàmic de nivells (L) que compensa les diferències de potència entre espècies.

Aquesta generació procedural garanteix que els agents s'enfrontin de manera contínua a escenaris no vistos i variats. Mitjançant una avaluació basada en un volum significatiu de batalles, la variància associada a la generació d'equips es cancel·la estadísticament, garantint la significança dels resultats que es detallen en la metodologia (Capítol 3) i en l'avaluació empírica (Capítol 6).

Com a introducció conceptual a l'arquitectura d'execució, les simulacions es basen en **Pokémon Showdown** [4], el simulador de codi obert en Node.js/TypeScript que implementa amb exactitud les regles oficials del joc en un entorn *headless* i local, i la llibreria en Python *poke-env* [5] (versió 0.11.x), que exposa la interfície de comunicació per a la connexió d'agents autònoms. Aquesta breu introducció serveix de fonament teòric abans de desenvolupar en profunditat la infraestructura d'execució, el protocol de comunicació i el disseny detallat dels entorns al Capítol 3.

2.1.10 Síntesi del domini: Pokémon com a entorn benchmark ideal per a la IA

En resum, el combat Pokémon en el format `gen9randombattle` configura un entorn de decisió d'una complexitat extraordinària. A diferència dels jocs tradicionals de la IA que aïllen només una o dues dificultats, Pokémon és un dels pocs dominis en la literatura que encreua simultàniament quatre reptes centrals de la intel·ligència artificial (Figura 2.3):

1. **Planificació a llarg termini (*Long-Term Planning*):** Propi de jocs d'estratègia posicional pura com els **escacs** o el **Go**. A Pokémon, les decisions no es poden valorar aïlladament per al torn actual: cal gestionar un equip de sis criatures al llarg de desenes de torns, sacrificant Pokémon per conservar la iniciativa (*tempo*), col·locant perills d'entrada (*hazards*) o preparant condicionants de victòria (*win conditions*) per al final del combat.
2. **Accions simultànies (*Simultaneous Actions*):** Present en jocs com el **Pedra-Paper-Tisores** o variants d'escacs a cegues (*Kriegspiel*). A cada torn, tots dos jugadors escullen la seva acció de manera secreta i simultània (Secció 2.1). L'agent no pot simplement

reaccionar a un moviment vist, sinó que ha de raonar estratègicament sobre la matriu de respostes rivals des de la teoria de jocs.

3. **Gestió de la probabilitat i l'estocasticitat (*Probability Management*):** Típic de jocs de **daus** o **Backgammon**. Les tirades de dany, la precisió dels moviments, els cops crítics (Secció 2.1.7) i la generació procedural d'equips (Secció 2.1.9) impedeixen l'existència de trajectòries deterministes, obligant l'agent a ponderar riscos i esperances matemàtiques a cada decisió.
4. **Informació imperfecta i oculta (*Imperfect Information*):** Propi de jocs de cartes com el **Pòquer** o **Magic: The Gathering**. L'estat inicial del rival (moviments no revelats, objectes, habilitats, IVs/EVs i Tipus Tera) roman ocult fins que s'exposa en combat, exigint a l'agent mantenir i actualitzar una distribució de creença sobre les variables no observades.

La convergència d'aquests quatre eixos (esquematzada a la Figura 2.3) converteix el combat Pokémon en un entorn benchmark d'un interès excepcional per a la intel·ligència artificial. Cap d'aquests quatre reptes es pot abordar de manera aïllada, ja que la presa de decisions exigeix ponderar simultàniament la planificació temporal a llarg termini, l'estocasticitat del motor i la incertesa sobre les accions i l'estat del rival.




Figura 2.3: Intersecció dels quatre eixos fonamentals de complexitat en IA i la seva correspondència amb altres jocs.

Aquesta combinació única de propietats fa imprescindible formalitzar el problema des de la teoria de jocs i el marc dels processos de decisió sota incertesa. En la secció següent (Secció 2.2), es tradueixen aquestes mecàniques al modelat matemàtic rigorós mitjançant Processos de Decisió de Markov Parcialment Observables (POMDP) i Jocs Estocàstics d'Observació Parcial (POSG).

2.2 Formalització matemàtica i marc d'inferència estadística

Aquesta secció formalitza matemàticament els quatre eixos de complexitat del combat Pokémon introduïts anteriorment (Figura 2.3) des de la Teoria de Jocs i els Processos de Decisió (models POSG/POMDP), n'analitza l'estat de creença i les reduccions d'enginyeria al format `gen9randombattle`, i estableix el marc d'inferència estadística per a l'avaluació empírica dels agents.

2.2.1 De la informació perfecta a la informació imperfecta

Per modelar matemàticament els quatre eixos de complexitat descrits a la secció anterior (planificació a llarg termini, simultaneïtat, estocasticitat i informació imperfecta; Figura 2.3), recorrem a la **Teoria de Jocs** [20]: la branca de les matemàtiques aplicades que estudia les situacions d'interacció estratègica entre agents racionals, on la utilitat o recompensa d'un individu depèn tant de les seves decisions com de les accions escollides pels seus rivals. En la història de la intel·ligència artificial, els jocs han estat el banc de proves clàssic per mesurar la capacitat de raonament autònom [21–28].

Des del punt de vista de la visibilitat de l'estat, la Teoria de Jocs divideix els entorns en dues grans categories:

- **Informació perfecta** (escacs, Go): L'estat complet del joc s és comú i totalment visible per a tots els jugadors a cada pas ($o_t = s_t$), de manera que no existeix incertesa sobre la configuració de l'entorn.
- **Informació imperfecta** (pòquer, StarCraft II, Pokémon): Part de l'estat global roman oculta a un o tots dos jugadors. Tal com s'ha exposat a la Secció 2.1.10, l'agent percep només una observació parcial $o_t \in \Omega$ i ha d'inferir probabilísticament les variables no visibles per prendre decisions sota incertesa.

Així doncs, dins del marc de la Teoria de Jocs, el combat Pokémon es classifica formalment com un **joc de dos jugadors, competitiu de suma zero, de selecció simultània i d'informació imperfecta**:

- **Suma zero**: La victòria d'un jugador és exactament la derrota del rival ($R_1 + R_2 = 0$), descartant qualsevol possibilitat de cooperació.
- **Selecció simultània**: Tots dos jugadors trien la seva acció de manera secreta i paral·lela a cada torn.
- **Informació imperfecta**: Els moviments no utilitzats, objectes equipats, EVs/IVs i Tipus Tera del rival no són directament accessibles, forçant la decisió sota un conjunt d'informació restringit.

2.2.2 Formalització dels Processos de Decisió: MDP, POMDP i POSG

En intel·ligència artificial i aprenentatge per reforç, un **marc o model de decisió** és la formulació matemàtica que descriu com un agent percep l'entorn, avalua les seves opcions i tria accions per maximitzar la probabilitat de guanyar (com processar l'estat de Showdown, avaluar atacs o canvis i triar la decisió de màxima utilitat). Per formalitzar el combat Pokémon de manera entenedora, cal comprendre com passem del marc teòric més simple al model matemàtic real del joc, analitzant aquesta evolució segons la informació disponible i el nombre de jugadors:

1. **MDP (Markov Decision Process)**: El marc base per a un sol agent que juga amb informació perfecta (una simplificació teòrica idealitzada on fossin visibles tots els moviments, objectes i intencions rivals; vegeu el diagrama estructural a la Figura 2.4a).
2. **POMDP (Partially Observable MDP)**: L'ampliació quan un sol agent pren decisions sota informació imperfecta (la reducció d'enginyeria utilitzada per PPO i XGBoost en integrar el rival dins l'entorn amb dades ocultes com moviments no revelats, objectes o Tipus Tera; vegeu la Figura 2.4b).
3. **POSG (Partially Observable Stochastic Game)**: El model matemàtic real del combat Pokémon (el format `gen9randombattle` on dos jugadors trien acció simultàniament a cada torn amb informació parcialment oculta; vegeu el model abstracte a la Figura 2.4c i la seva instanciació real amb Pokémon Showdown a la Figura 2.4d).

Un **Procés de Decisió de Markov (MDP)** [29] es defineix com la tupla (S, A, T, R, γ) , on S és l'espai d'estats, A l'espai d'accions, $T(s' | s, a) = P(S_{t+1} = s' | S_t = s, A_t = a)$ la funció de transició estocàstica, $R(s, a)$ la funció de recompensa i $\gamma \in [0, 1]$ el factor de descompte (Figura 2.4a). La política $\pi(a | s)$ maximitza el retorn esperat.

Quan l'agent no observa directament l'estat real s , sinó una observació parcial $o \in \Omega$ emesa segons una funció d'emissió $O(o | s', a) = P(O_{t+1} = o | S_{t+1} = s', A_t = a)$, el model es converteix en un **Procés de Decisió de Markov Parcialment Observable (POMDP)** [30, 31] (Figura 2.4b).

Atès que a Pokémon hi intervenen dos jugadors que escullen accions de forma simultània sense conèixer la decisió del rival en el torn actual, el model formal conceptualment rigorós és un **Joc Estocàstic d'Observació Parcial (POSG)** [20, 32]. Formalment, un POSG de dos jugadors (esquematzat conceptualment a la Figura 2.4c) es defineix com una tupla de vuit components:

$$\mathcal{M} = (N, S, \{A_i\}_{i \in N}, T, \{R_i\}_{i \in N}, \{\Omega_i\}_{i \in N}, \{O_i\}_{i \in N}, \gamma) \quad (2.8)$$

on:

- $N = \{1, 2\}$ és el conjunt dels dos jugadors (Jugador 1 i Jugador 2).
- S és l'espai d'estats globals del joc (mantingut de manera omniscient pel servidor central de Pokémon Showdown).
- A_i és l'espai d'accions del jugador i . Una acció conjunta s'expressa com $\mathbf{a} = (a_1, a_2) \in A_1 \times A_2$.
- $T(s' | s, \mathbf{a}) = P(S_{t+1} = s' | S_t = s, \mathbf{a}_t = \mathbf{a})$ és la probabilitat de transició condicional sota l'acció conjunta.
- $R_i(s, \mathbf{a})$ és la recompensa del jugador i . En ser un joc competitiu pur de suma zero, es compleix $R_1(s, \mathbf{a}) + R_2(s, \mathbf{a}) = 0$.
- Ω_i és l'espai d'observacions privades del jugador i .
- $O_i(o_i | s', \mathbf{a}) = P(O_{i,t+1} = o_i | S_{t+1} = s', \mathbf{a}_t = \mathbf{a})$ és la funció d'emissió d'observacions privades, on el motor de Showdown mascara les dades no revelades del rival abans d'enviar el paquet d'estat a cada jugador.
- $\gamma \in [0, 1]$ és el factor de descompte temporal.

Cal destacar que el simulador central de Pokémon Showdown actua com un àrbitre omniscient que conté l'estat real complet S (amb tota la informació oculta de tots dos jugadors), però aplica el **filtre del seu protocol** per ofuscar les dades no revelades del rival i transmetre a cada agent únicament la seva observació parcial emmascarada o_1, o_2 (Figura 2.4d). Aquest mecanisme d'emissió i els detalls de funcionament del simulador es desenvolupen en profunditat en els capítols de metodologia, infraestructura i implementació (Capítols 3, 4 i 5).

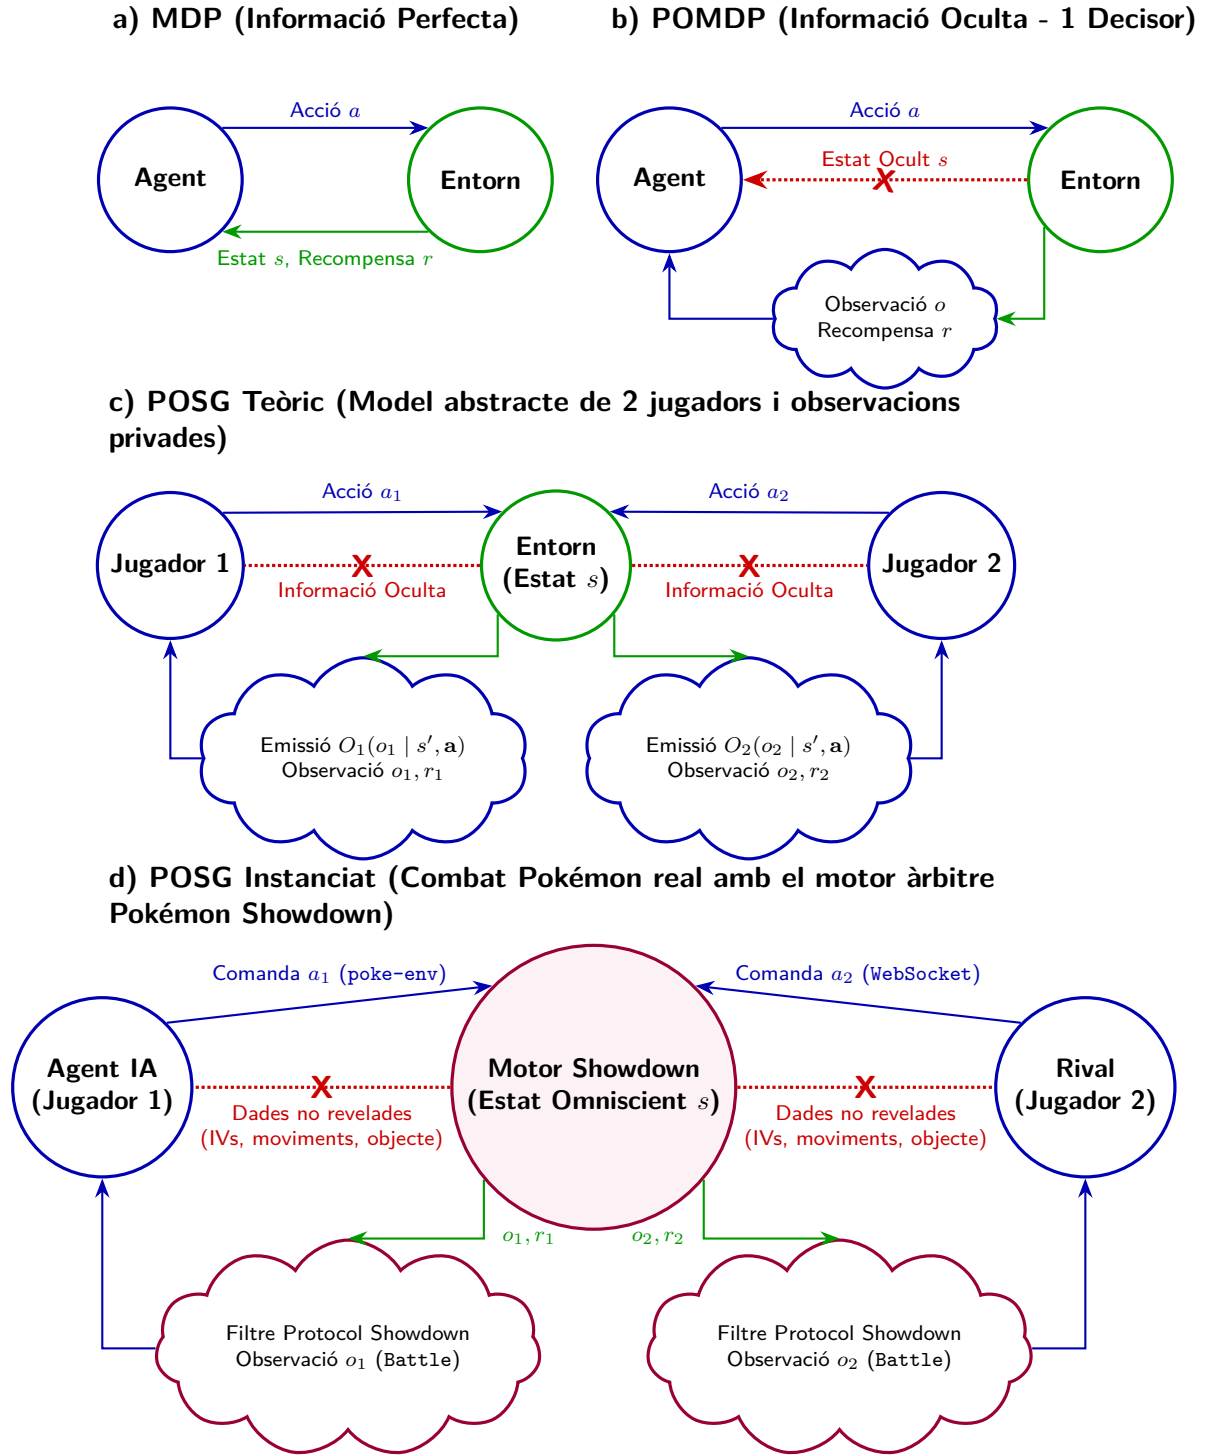


Figura 2.4: Comparació estructural entre marcs de decisió: a) MDP (informació perfecta), b) POMDP (reducció a 1 decisor sota informació imperfecta), c) POSG teòric (formulació matemàtica abstracta amb 2 jugadors) i d) POSG instanciat en Pokémon Showdown amb el filtre del seu protocol.

2.2.3 Estat de creença, matriu de recompenses i reducció d'enginyeria

Una vegada definit el marc formal del POSG, sorgeix la qüestió de com un agent pot prendre decisions operatives en temps real. Com s'ha establert a la Secció 2.2.2, el combat Pokémon planteja tres grans desafiaments que impedeixen aplicar algorismes de cerca convencionals:

1. **La informació oculta:** Requereix introduir l'**estat de creença** (*Belief State*) per inferir probabilísticament les variables no visibles del rival (moviments, objectes o Tipus Tera) a partir de la història del combat.
2. **La simultaneïtat de les accions:** Requereix utilitzar la **matriu de recompenses** de la Teoria de Jocs per calcular l'**Equilibri de Nash**, evitant que l'agent sigui explotable per polítiques deterministes de l'adversari.
3. **La intractabilitat computacional (*NEXP-hard*):** Fa impossible resoldre el joc de manera exacta i força a aplicar **reduccions d'enginyeria** (com reduir el POSG a un POMDP d'un sol decisor o acotar la cerca a arbres locals) per prendre decisions en pocs mil·l·lisegons.

En els següents apartats es desenvolupen formalment cadascuna d'aquestes tres solucions.

L'estat de creença (*Belief State*)

Per gestionar la inaccessibilitat de l'estat real s provocada per la informació oculta, l'agent utilitza un **estat de creença** (*Belief State*) $b_{i,t}(s) \in \Delta(S)$. Aquest es defineix com la distribució de probabilitat sobre els possibles estats globals s donada la història d'observacions i accions acumulades $h_{i,t} = (o_{i,1}, a_{i,1}, \dots, o_{i,t})$:

$$b_{i,t}(s) = P(S_t = s \mid h_{i,t}) \quad (2.9)$$

A cada torn, l'agent actualitza $b_{i,t}$ mitjançant la regla de Bayes [33] en rebre la nova observació $o_{i,t+1}$. Això li permet ponderar probabilísticament les dades no visibles del rival (com ara atacs de cobertura o objectes d'augment de velocitat) abans de triar una acció.

La matriu de recompenses i l'Equilibri de Nash

L'**Equilibri de Nash** [20] és el concepte central de la Teoria de Jocs que defineix l'estat d'un joc en què cap participant no té cap incentiu per modificar la seva estratègia de manera unilateral, ja que qualsevol canvi individual reduiria o igualaria la seva recompensa esperada.

En el combat Pokémon, com que tots dos jugadors escullen la seva acció de manera **simultània** sense veure la jugada del rival, sorgeix un gran problema: **qualsevol decisió determinista fixa és previsible i fàcilment explotable**. Per exemple, si l'agent triés sempre l'atac de més potència, un rival intel·ligent ho preveuria i canviaria a un Pokémon resistent o immune a aquest atac, fent perdre l'agent sistemàticament.

Per aquest motiu, l'objectiu de l'agent no és trobar una única "millor acció" fixa, sinó calcular una **estratègia inexplorable** mitjançant la formulació del torn com una **matriu de recompenses en forma normal** $M(a_1, a_2) = \mathbb{E}_{s \sim b}[R_1(s, a_1, a_2) + \gamma V(s')]$, on les files representen les accions del Jugador 1 ($a_1 \in A_1$) i les columnes les respostes del Jugador 2 ($a_2 \in A_2$).

Prenguem com a exemple un torn on el Jugador 1 pot escollir entre un atac elèctric o un canvi defensiu, i el Jugador 2 pot escollir entre un atac d'aigua o un canvi a un Pokémon de tipus Terra (immune a l'electricitat):

Jugador 1 \ Jugador 2	Atac d'Aigua (a_2^1)	Canvi a Terra (a_2^2)
Atac Elèctric (a_1^1)	+10 (Dany màxim $\times 4$)	-10 (Avançat pel rival / Atac nul)
Canvi defensiu (a_1^2)	+2 (Resisteix atac)	0 (Canvi neutre)

Taula 2.4: Exemple simplificat d'una matriu de recompenses en forma normal per a un torn de combat. Els valors representen la recompensa esperada del Jugador 1.

Com s'observa a la Taula 2.4:

- Si el Jugador 1 juga el 100% de les vegades l'Atac Elèctric (a_1^1), el rival ho descobrirà i respondrà jugant el 100% el Canvi a Terra (a_2^2), fent que el Jugador 1 obtingui la pitjor recompensa possible (-10).
- Per evitar ser previsible i explotat, l'agent ha d'emprar una **estratègia mixta / estocàstica** $\pi_1^* \in \Delta(A_1)$ i assignar probabilitats a cada opció (p. ex., un 70% de probabilitat a l'atac elèctric i un 30% al canvi defensiu).

Matemàticament, el parell d'estratègies (π_1^*, π_2^*) constitueix un **Equilibri de Nash** si es compleix la següent condició de no-explotabilitat:

$$\mathbb{E}_{\mathbf{a} \sim (\pi_1^*, \pi_2^*)}[R_1(s, \mathbf{a})] \geq \mathbb{E}_{a_1 \sim \pi_1, a_2 \sim \pi_2^*}[R_1(s, a_1, a_2)], \quad \forall \pi_1 \in \Delta(A_1) \quad (2.10)$$

En aquest punt d'equilibri, l'agent es garanteix el màxim retorn esperat possible sense que el rival pugui aprofitar-se de cap biaix en les seves decisions.

Justificació de les reduccions d'enginyeria i complexitat *NEXP-hard*

La cerca d'un Equilibri de Nash o de la política òptima conjunta en un POSG d'horitzó finit és un problema demostrat formalment com a ***NEXP-hard*** (*Nondeterministic Exponential Time*) [34]. Aquesta classe de complexitat implica que resoldre el joc de manera exacta requereix un temps d'execució **doblement exponencial** respecte a la profunditat del combat, fent que el càlcul en temps real sigui computacionalment inabordable.

Per fer la decisió computable en mil·lisegons, els paradigmes desenvolupats en aquest treball apliquen **reduccions d'enginyeria**:

- **Aprenentatge per Reforç (PPO) i Clonatge Conductual (XGBoost)**: Redueixen la complexitat multijugador integrant la política del rival $\pi_2(a_2 | o_2)$ directament dins de la funció de transició de l'entorn:

$$T_{\text{eff}}(s' | s, a_1) = \sum_{a_2 \in A_2} \pi_2(a_2 | o_2) \cdot T(s' | s, a_1, a_2) \quad (2.11)$$

Aquesta formulació transforma el POSG competitiu de dos jugadors en un **POMDP d'un sol decisor** (Figura 2.4b), on l'adversari s'absorbeix en la dinàmica de l'entorn.

- **Cerca Minimax i MCTS**: Acoten el càlcul a un horitzó temporal local a l'arrel de l'arbre (1 torn o pocs torns endavant), construint la matriu de recompenses local o executant *rollouts* d'esperança per respondre immediatament.

2.2.4 Instanciació dels components a **gen9randombattle**

Per traslladar els conceptes teòrics de la tupla POSG/POMDP (S, A, T, R, Ω, O) al desenvolupament d'agents de decisió autònoms en aquest treball, cal definir com es tradueix cada component abstracte a l'entorn real de simulació de Pokémon Showdown i *poke-env* en el format **gen9randombattle**. A la Taula 2.5 es detalla aquest mapatge exactament.

Component	Instanciació a Singles gen9randombattle
S	Sis Pokémon per bàndol (espècie, HP, configuració, objecte, habilitat, modificadors i condició d'estat), clima, perills d'entrada, Tera consumit i torn. $ S $ és astronòmic i no s'enumera.
A	Ordres directes de combat (<i>raw orders</i> : 4 moviments, Tera opcional i fins a 5 canvis de banquet). En aprenentatge per reforç discret, es codifica en un espai fix (4 moviments + 4 moviments amb Tera + 6 slots d'equip). La legalitat $M(a) \in \{0, 1\}$ la determinen els PP, debilitaments, bloqueigs i absència de canvi al mateix Pokémon actiu.
T	Motor de Showdown: determinista en les mecàniques de combat, estocàstic en el multiplicador de dany $[0,85, 1,00]$, la precisió dels moviments, els efectes secundaris, els empats de velocitat (<i>speed ties</i>) i la generació procedural de l'equip a l'inici del combat.
R	Recompensa terminal zero-sum conceptual +1 per victòria i -1 per derrota (indicador binari $W \in \{0, 1\}$ enregistrat per a l'avaluació). En l'entrenament RL s'utilitza una funció de recompensa dita densa (<i>reward shaping</i>) basada en la diferència d'HP, penalització/bonificació per debilitament de Pokémon, modificadors d'estat i penalització per pas de temps.
Ω	Equip propi complet; del rival, espècies revelades, percentatge d'HP, moviments utilitzats, condicions laterals i modificadors d'estat. EV, naturalesa, objecte i moviments no utilitzats romanen ocults.
O	Mecanisme d'emascament i protocol WebSocket de Pokémon Showdown / <i>poke-env</i> . Intercepta l'estat global S i genera l'observació parcial privada $o_i \in \Omega_i$ filtrant les dades no revelades abans de transmetre el paquet al client.

Taula 2.5: Mapatge POSG/POMDP al combat individual de Random Battle (Generació IX).

Com s'observa a la Taula 2.5, la traducció de la tupla formal (S, A, T, R, Ω, O) varia lleugerament segons el paradigma de decisió implementat. Mentre que les heurístiques i els algorismes de cerca (Minimax i MCTS) operen directament sobre l'objecte d'estat parcial **Battle** emès per *poke-env* i generen accions basades en objectes **SingleBattleOrder**, els algorismes d'aprenentatge automàtic requereixen transformacions específiques de la informació. En l'aprenentatge per imitació (XGBoost), l'observació Ω es tradueix en una matriu de característiques tabulars (*feature vector*) d'estat i enfrontament. En l'aprenentatge per reforç profund (MaskablePPO), l'observació contínua s'estructura mitjançant un vectoritzador d'estats normalitzat en el rang $[0, 1]$, i l'espai d'accions es redueix a un vector de probabilitats sobre els índexs d'acció vàlids definits per la màscara de legalitat $M(a)$. Els detalls concrets d'enginyeria sobre la construcció d'aquests vectors de característiques, les funcions de recompensa modificades, els mecanismes d'emascament d'accions i l'arquitectura del codi es desenvolupen de manera exhaustiva en els capítols de metodologia i implementació (Capítols 3 i 5).

2.2.5 Marc d'avaluació estadística i mètodes d'inferència

La comparació empírica entre agents de diferents paradigmes requereix un marc d'inferència estadística rigorós per garantir que les diferències observades en la taxa de victòria no siguin fruit del soroll estocàstic del simulador ni de la variància en la generació d'equips. Aquesta secció justifica i defineix formalment les eines matemàtiques (interval de Wilson, rànquings Bradley-Terry per Màxima Versemblança, significança de diferències, mètriques de pèrdua i emascament d'accions) utilitzades per avaluar el rendiment dels algorismes.

1. **Estimació de la Taxa de Victòria (*Win Rate*) i Marge d'Error:** En un enfrontament de N partides entre dos agents, cada combat i s'escriu com una variable aleatòria binària de Bernoulli $W_i \sim \text{Bernoulli}(p)$, on $W_i = 1$ indica victòria de l'agent i $W_i = 0$ indica derrota.

L'estimador puntual de la taxa de victòria $\hat{p}$ és la mitjana mostral:

$$\hat{p} = \frac{1}{N} \sum_{i=1}^N W_i \quad (2.12)$$

La variància d'aquest estimador ve donada per $\text{Var}(\hat{p}) = \frac{p(1-p)}{N}$, assolint el seu màxim teòric quan $p = 0,5$. El marge d'error (MoE) al nivell de confiança del 95% ($\alpha = 0,05$) es calcula com:

$$\text{MoE} = z_{1-\alpha/2} \cdot \text{SE}(\hat{p}) = z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{N}} \quad (2.13)$$

Per a una mida mostral de $N = 10.000$ partides per enfrontament directe, l'error estàndard màxim és $\text{SE}(\hat{p}) = \sqrt{0,25/10000} = 0,005$ (0,5%), el que garanteix un marge d'error màxim de $\text{MoE} = 1,96 \cdot 0,005 = \pm 0,0098 \approx \pm 0,98\%$ ($\approx \pm 1\%$). En mostres menors com $N = 1.000$, el marge d'error és de $\text{MoE} \approx \pm 3,10\%$.

2. **Intervals de Confiança de Wilson (*Wilson Score Interval*):** A diferència de l'interval binomi estàndard de Wald ($\hat{p} \pm z\sqrt{\hat{p}(1-\hat{p})/N}$), que falla prop dels límits (0 o 1) o en mostres asimètriques, aquest treball calcula els intervals de confiança mitjançant l'**interval de la puntuació de Wilson** [35]:

$$\text{CI}_{\text{Wilson}} = \frac{1}{1 + \frac{z^2}{N}} \left(\hat{p} + \frac{z^2}{2N} \pm z \sqrt{\frac{\hat{p}(1-\hat{p})}{N} + \frac{z^2}{4N^2}} \right) \quad (2.14)$$

on $z = z_{1-\alpha/2} = 1,96$ per a un nivell de confiança del 95% ($\alpha = 0,05$).

3. **Model de Bradley-Terry i Puntuació Elo per Màxima Versemblança (MLE):** Per ordenar un conjunt d'agents en un llistat global 1D independent de la composició d'oponents, s'utilitza el model de comparació per parelles de Bradley-Terry [36] transformat a escala Elo [37]. La probabilitat esperada de victòria de l'agent A_i enfront de l'agent A_j amb puntuacions R_i i R_j s'expressa mitjançant la funció logística:

$$P(A_i > A_j) = \frac{1}{1 + 10^{(R_j - R_i)/400}} = \sigma \left(\frac{\ln 10}{400} (R_i - R_j) \right) \quad (2.15)$$

A diferència del sistema d'actualització seqüencial Elo utilitzat en el joc en línia (que depèn de l'ordre dels combats), els paràmetres $\{R_i\}$ s'estimen de manera conjunta sobre la matriu completa d'enfrontaments mitjançant la maximització de la log-versemblança (MLE):

$$\ln \mathcal{L}(\mathbf{R}) = \sum_{i < j} (W_{ij} \ln P(A_i > A_j) + W_{ji} \ln P(A_j > A_i)) \quad (2.16)$$

Computacionalment, aquesta optimització s'executa igualant l'estimador a una **regressió logística sense terme independent** (*unintercepted logistic regression*): sobre un conjunt de dades simetritzat de M batalles amb vectors d'entrada $\mathbf{x}_k \in \{-\ln 10, 0, +\ln 10\}^P$ i etiquetes $y_k \in \{0, 1\}$, s'obtenen els coeficients $\hat{\beta}$, a partir dels quals es calculen les puntuacions Elo:

$$R_i = 400 \cdot \hat{\beta}_i + R_{\text{init}} \quad (2.17)$$

fixant l'ancoratge de referència de l'agent aleatori en $R_{\text{random}} = 1000$.

4. **Comparació de Dues Proporcions Independents i Significança de Diferències:** Per determinar si la diferència observada $\Delta\hat{p} = \hat{p}_1 - \hat{p}_2$ entre dos agents (p. ex., en

estudis d'ablació de regles o mecàniques) és estadísticament significativa, es calcula l'error estàndard de la diferència:

$$\text{SE}(\Delta\hat{p}) = \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{N_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{N_2}} \quad (2.18)$$

i el corresponent interval de confiança del 95% per a la diferència de taxes de victòria:

$$\text{CI}_{95\%}(\Delta p) = (\hat{p}_1 - \hat{p}_2) \pm z_{1-\alpha/2} \cdot \text{SE}(\Delta\hat{p}) \quad (2.19)$$

Si l'interval de confiança $\text{CI}_{95\%}(\Delta p)$ no inclou el valor 0, es conclou que la millora de rendiment és estadísticament significativa amb $p < 0,05$.

5. **Mètriques de Pèrdua per a Aprendre de Dades Humanes i Polítiques Emascarades:** Per als agents basats en clonatge conductual i aprenentatge per imitació (XGBoost), la convergència sobre la partició de dades d'experts s'avalua mitjançant la pèrdua de crosse-entropia (*Log-Loss*) [38]:

$$\mathcal{L}_{\text{CE}} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{i,k} \ln \hat{y}_{i,k} \quad (2.20)$$

Per als agents d'aprenentatge per reforç profund (MaskablePPO), l'assignació de probabilitats sobre les accions legals s'executa mitjançant la distribució categòrica emascarada (*Invalid Action Masking*) [1]:

$$P(a \mid o) = \frac{M(a) \exp(z_a)}{\sum_{a'} M(a') \exp(z_{a'})}, \quad M(a) \in \{0, 1\} \quad (2.21)$$

on $M(a) = 0$ elimina immediatament les accions il·legals abans del càlcul del softmax, optimitzant la funció d'objectiu de PPO amb retallat (*clipped surrogate objective*) [39]:

$$\mathcal{L}^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (2.22)$$

6. **Telemetria Multidimensional i Indicadors Tàctics:** A més de la taxa de victòria escalar, el marc d'avaluació recull una telemetria multidimensional per combat per desglossar l'origen estratègic del rendiment en quatre dimensions principals:

- **Eficiència Executiva:** Latència mitjana per decisió (ms), nombre de torns per combat i taxa d'accions de fallback o errors.
- **Dinàmica de Relleus:** Proporció de canvis voluntaris estratègics respecte als canvis forçats per debilitament de Pokémon.
- **Control del Camp i Tàctica:** Gestió de perills d'entrada (*Stealth Rock*, *Spikes*), activació de moviments de preparació (*setup moves*) i eficiència de noaut (KO).
- **Aïllament del Soroll d' RNG:** Registre de cops crítics, fallades per precisió i cops super-efectius rebuts/efectuats per separar la qualitat de la decisió de la sort estocàstica.

A la Taula 2.6 es sintetitza el conjunt d'eines matemàtiques, mètriques d'inferència i propietats estadístiques que integren el marc teòric d'avaluació d'aquest treball.

Mètrica / Eina	Formulació Matemàtica / Càlcul	Objectiu / Propietat Estadística
Taxa de Victòria ($\hat{p}$)	$\hat{p} = \frac{1}{N} \sum_{i=1}^N W_i$	Estimació puntual de Bernoulli
Marge d'Error (MoE)	$\text{MoE} = z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{N}}$	Acotació d'error al 95% de confiança
Interval de Wilson	$\text{CI}_{\text{Wilson}}$ Eq. (2.14)	Robustesa en límits $p \rightarrow 0, 1$ i mostres petites
Model Bradley-Terry Elo	$P(A_i > A_j) = \sigma\left(\frac{\ln 10}{400}(R_i - R_j)\right)$	Rànquing 1D conjunt per MLE ($R_{\text{rand}} = 1000$)
Test Z de Diferència	$\text{CI}_{95\%}(\Delta p) = (\hat{p}_1 - \hat{p}_2) \pm 1,96 \cdot \text{SE}(\Delta \hat{p})$	Avaluació de significança en ablacions ($p < 0,05$)
Pèrdua Crosse-Entropia	$\mathcal{L}_{\text{CE}} = -\frac{1}{N} \sum y_{i,k} \ln \hat{y}_{i,k}$	Minimització d'error en aprenentatge per imitació
Policy PPO amb Masking	$P(a o) = \frac{M(a) \exp(z_a)}{\sum M(a') \exp(z_{a'})}$	Garantia d'execució només d'accions legals $M(a)$
Telemetria Tàctica	Indicadors de latència, canvis, hazards i RNG	Anàlisi multifactorial del comportament executiu

Taula 2.6: Síntesi del marc d'avaluació estadística, eines d'inferència i les seves propietats teòriques.

La variància estocàstica associada a la generació procedural d'equips a Random Battle es dilueix fixant una mida mostral suficientment gran per a cada enfrontament directe ($N \geq 10^3$), la qual cosa acota l'error estàndard de l'estimador per sota de lindars de soroll rellevants ($\text{SE} \leq 0,015$) i garanteix la significança estadística de les comparacions presentades en els capítols següents.

2.3 Estat de l'Art en IA i Pokémon

L'estudi de la presa de decisions autònoma en el combat competitiu de Pokémon ha experimentat un desenvolupament creixent gràcies a l'estandardització d'entorns de simulació oberts. Aquesta secció revisa la literatura existent organitzant els treballs rellevants en quatre blocs temàtics, analitza les manques principals de la recerca prèvia i descriu el valor afegit d'aquest treball.

2.3.1 Plataformes d'integració i entorns de simulació

La recerca en IA aplicada a Pokémon va prendre impuls amb el desenvolupament de **Pokémon Showdown** [4], el simulador de codi obert utilitzat per la comunitat competitiva de Smogon. La creació de la llibreria *poke-env* [5, 40] va establir la interfície estàndard per a la connexió d'agents autònoms via protocols WebSocket, facilitant l'accés a l'estat del combat (**Battle**) i l'emissió d'ordres legalitzades. Així mateix, aquesta plataforma inclou agents de referència fonamentals basats en selecció aleatòria (**RandomPlayer**), atacs de màxima potència (**MaxBasePowerPlayer**) i regles heurístiques bàsiques (**SimpleHeuristicsPlayer**).

2.3.2 Aprenentatge per reforç profund i exploració autònoma

L'aplicació de l'aprenentatge per reforç profund (DRL) a Pokémon presenta reptes de gran complexitat per l'alta dimensió de l'espai d'estats, la informació oculta i l'estocasticitat. Huang i Lee [16] van realitzar un dels treballs pioners entrenant un agent basat en Proximal Policy Optimization (PPO) mitjançant auto-aprenentatge (*self-play*) sobre Pokémon Showdown. Els seus resultats van evidenciar la dificultat de la cerca no guiada: sense un emmascarament rigorós d'accions legals ni una inicialització guiada per coneixement de domini, els agents RL tenen tendència a convergir cap a polítiques subòptimes o bloquejar-se en cicles d'accions invàlides. Treballs posteriors han demostrat que la combinació de PPO amb emmascarament binari d'accions

(*Invalid Action Masking*) [1] i el disseny de recompenses denses (*reward shaping*) [41] són elements claus per estabilitzar la convergència en entorns d'informació imperfecta.

2.3.3 Aprenentatge fora de línia i arquitectures basades en Transformers

Davant les dificultats de l'exploració activa a l'entorn de simulació, una línia de recerca recent aposta per l'aprenentatge a partir de dades d'experts humans. L'agent *Metamon* [15] representa una de les fites més recents en aquest eix, aplicant aprenentatge per reforç fora de línia (*offline RL*) i arquitectures basades en Transformers sobre corpus massius de repeticions de partides d'alt nivell. Aquest enfocament permet als models extreure patrons estratègics complexos i relacions temporals directament de les trajectòries d'experts, tot i que requereix una capacitat computacional elevada per a l'entrenament dels models de polítiques.

2.3.4 Models de llenguatge de gran escala i cerca adversària híbrida

L'emergència dels models de llenguatge de gran escala (LLM) ha generat una nova línia d'agents capaços de raonar sobre l'estat del combat mitjançant llenguatge natural. L'agent *PokéLL-Mon* [42] utilitza LLMs per processar l'historial del combat i inferir la informació oculta del rival. Paral·lelament, l'agent *PokéChamp* [43, 44] combina un model de llenguatge per a la construcció de l'estat de creença amb un algorisme de cerca Minimax d'un pas per a l'avaluació d'accions simultànies, assolint les posicions més altes de la classificació pública (*ladder*) de Showdown. Aquests treballs demostren que integrar coneixement de domini o motors de cerca amb models apressos supera el rendiment de qualsevol de les tècniques aplicades de manera aïllada.

2.3.5 Mancances de la literatura i justificació d'aquest treball

Tot i els avenços descrits, la literatura prèvia presenta dues manques estructurals primordials:

1. **Absència d'una matriu d'avaluació integrada i homogènia:** Els treballs precedents avaluen els seus agents en formats heterogenis, enfront d'oponents diferents o sota condicions no estandarditzades, sense una comparació directa i sistemàtica entre els cinc paradigmes fonamentals de la presa de decisions (heurístiques expertes, cerca adversària Minimax, cerca MCTS, aprenentatge per imitació i DRL) sota un mateix protocol experimental i marc d'inferència estadística.
2. **Falta d'estudis d'ablació del coneixement de domini:** Les heurístiques existents solen presentar-se com a blocs monolítics sense aïllar l'impacte individual de cada mecanisme tàctic (com el càlcul de velocitat, la lectura de la Taula de Tipus, la gestió de perills d'entrada o la Teracristal·lització).

2.3.6 Què afegeix aquest TFM

Per respondre a aquestes manques, aquest Treball de Final de Màster aporta les següents contribucions teòriques i metodològiques:

1. **Un marc d'avaluació integrat i homogeni entre paradigmes:** Defineix una matriu de combat que enfronta de manera directa i igualitària els cinc paradigmes fonamentals de decisió sobre un mateix entorn i format (`gen9randombattle`), sota mètodes d'inferència estadística rigorosos (interval de Wilson i ajust Bradley-Terry Elo per MLE).
2. **Una seqüència d'ablació incremental del coneixement de domini:** Desenvolupa una jerarquia d'agents heurístics estructurada en blocs de regles que permet mesurar de manera aïllada el valor afegit de cada component tàctic del joc.

3. **Arquitectures híbrides de cerca i d'imitació guiades per heurístiques:** Explora la integració de regles de domini com a distribucions a priori (*priors*) o executors de suport en algorismes de cerca adversària (Minimax i MCTS) i aprenentatge per imitació, avaluant el guany estratègic del raonament anticipatori.
4. **Una avaluació rigorosa de MaskablePPO i clonatge conductual:** Desenvolupa i avalua un entorn DRL integrant emmascarament binari d'accions legals, disseny de recompenses denses i inicialització de polítiques mitjançant clonatge conductual sobre dades expertes.

2.4 Fonaments teòrics dels cinc paradigmes de decisió

Cada paradigma de presa de decisions introdueix un mecanisme diferent per fer front a la incertesa, la simultaneïtat i la informació oculta del combat Pokémon: coneixement codificat, anticipació adversària en matriu, simulació estocàstica en arbre, supervisió amb dades expertes humanes o optimització per reforç amb emmascarament. A la Taula 2.7 es resumeixen i s'analitzen les característiques principals d'aquests cinc paradigmes de decisió.

Taula 2.7: Comparació conceptual dels cinc paradigmes. Tots decideixen sobre el mateix simulador i format; canvia la font de coneixement i el còmput per torn.

Paradigma	Què decideix	Coneixement	Còmput per torn	Aprèn?
Heurística	Argmax d'una puntuació fixa sobre accions legals.	Regles escrites (dany, posició, Tera).	Constant, baix.	No durant l'execució.
Minimax d'un torn	Maximin sobre una matriu d'accions i respostes estimades.	Funció de fulla + prior opcional.	Enumeració d'un torn.	No.
MCTS ras	UCB/PUCT només als fills de l'arrel.	Determinització i, a v20, prior de v14.	100 simulacions de 5 torns.	No (cerca en línia).
Imitació	Classificador atacar/canviar + executor.	Trajectòries humanes Elo 1800+.	Inferència XGBoost.	Supervisat, fora de línia.
PPO	Política estocàstica emmascarada $\pi_\theta(a o)$.	Interacció amb recompensa + clonatge inicial.	Un pas de xarxa.	Per reforç, fora de partida.

2.4.1 Heurístiques: coneixement com a ablació

Una política heurística no ajusta els seus paràmetres durant l'execució. A cada estat d'avaluació s , puntua les accions legals $a \in A(s)$ mitjançant un conjunt de regles de domini deterministes i selecciona l'acció que maximitza la funció de puntuació composta $H(s, a)$:

$$a^* = \arg \max_{a \in A(s)} H(s, a) = \arg \max_{a \in A(s)} \sum_{k=1}^K w_k \cdot f_k(s, a) \quad (2.23)$$

on $f_k(s, a) \in \mathbb{R}$ representa una funció d'indicador o de valoració de la mecànica k (com la proporció de dany esperat, el multiplicador de la matriu de tipus, la diferència de velocitat, la inducció d'estats alterats, l'efectivitat dels perills d'entrada o l'oportunitat de preparació) i $w_k > 0$ és el pes o prioritat associat.




Figura 2.5: Arquitectura d'avaluació d'una política heurística basada en la combinació de blocs de coneixement de domini.

L'organització d'aquestes regles en blocs de coneixement independents es formalitza com una **ablació incremental**. Si $\mathcal{F}^{(M)} = \{f_1, f_2, \dots, f_K\}$ és el repositori complet de característiques de domini, una seqüència d'ablació defineix un subconjunt creixent de mecanismes $\mathcal{F}^{(1)} \subset \mathcal{F}^{(2)} \subset \dots \subset \mathcal{F}^{(M)}$. La política de l'agent al pas d'ablació m avalua l'acció mitjançant:

$$H^{(m)}(s, a) = \sum_{f_k \in \mathcal{F}^{(m)}} w_k \cdot f_k(s, a) \quad (2.24)$$

Aquest marc matemàtic permet aïllar i mesurar formalment la contribució marginal $\Delta \hat{p}_m = \hat{p}(H^{(m)}) - \hat{p}(H^{(m-1)})$ associada a la incorporació de cada mecànica concreta (com el càlcul de velocitat, la gestió de perills d'entrada o la Teracristal·lització), transformant l'enginyeria d'heurístiques en un procés rigorós de comprovació d'hipòtesis.

2.4.2 Minimax d'un torn: resposta adversària immediata

El principi Minimax [45] assigna a cada estat el valor de la millor decisió pròpia assumint la resposta més desfavorable de l'oponent. Atès que les accions a Pokémon Showdown s'executen de manera **simultània** a cada torn, la formulació Minimax d'un pas resol la decisió com un joc de matriu zero-sum de dimensió $|A_1| \times |A_2|$, on l'element $M_{ij} = \mathbb{E}_{s' \sim T(s, a_1, i, a_2, j)}[V(s')]$ representa el valor esperat de l'estat d'arribada obtingut per la funció d'avaluació V , integrant l'estocasticitat del simulador T (tirada de dany, precisió i empats de velocitat).

En estratègies pures, la formulació Maximin ve donada per:

$$a_1^* = \arg \max_{a_1 \in A_1} \min_{a_2 \in A_2} M(a_1, a_2) \quad (2.25)$$

Tanmateix, per evitar ser previsible i explotable davant d'un adversari intel·ligent, la matriu completa es podria resoldre en **estratègies mixtes** $\pi_1^* \in \Delta(A_1)$ mitjançant **Programació Lineal (LP)**, trobant l'Equilibri de Nash local (vegeu Equació 2.10):

$$\max_{\pi_1 \in \Delta(A_1)} v \quad \text{subjecte a} \quad \sum_{i=1}^{|A_1|} \pi_1(i) M_{ij} \geq v, \quad \forall j \in \{1, \dots, |A_2|\}, \quad \sum_i \pi_1(i) = 1, \quad \pi_1(i) \geq 0 \quad (2.26)$$

Aquesta formulació assumeix que A_2 és conegut. En combat amb observació parcial només es veuen els moviments ja revelats, de manera que el disseny experimental (Capítol 3) adopta el maximin pur de l'Equació 2.25 i reserva l'LP com a referent teòric, no com a variant implementada.

La funció d'avaluació d'estat $V(s')$ combina el balanç de punts de salut normalitzats $hp_k \in [0, 1]$ de tots dos bàndols amb bonificacions posicionals:

$$V(s') = \sum_{k \in \text{propi}} hp_k - w_{\text{opp}} \sum_{m \in \text{rival}} hp_m + B(s') \quad (2.27)$$

on $B(s')$ incorpora les contribucions d'estats alterats, condicions laterals (com *Stealth Rock*) i modificadors d'etapa estadística. A més, es poden incorporar distribucions a priori d'orientació provinents de polítiques heurístiques per esbiaixar la matriu cap a decisions d'alta qualitat.

2.4.3 Cerca de Monte Carlo a l'arrel (shallow MCTS)

L'algorisme de cerca en arbre de Monte Carlo (MCTS) [46, 47] alterna quatre fases iteratives: selecció, expansió, simulació (*rollout*) i retropropagació de la recompensa. En entorns de simulació amb restriccions de temps de resposta com Pokémon Showdown, l'MCTS ras limita la profunditat de construcció de l'arbre a l'arrel ($d = 1$), tractant les accions legals de l'arrel $a_1 \in A_1$ com a braços d'un problema de bandits multi-braç avalats mitjançant trajectòries de k torns executades per una política de referència π_{rollout} .




Figura 2.6: Cicle clàssic de l'MCTS adaptat a simulacions de profunditat rasa a l'arrel ($d = 1$) amb rollouts heurístics.

Per a la selecció de les accions a l'arrel, s'utilitza la puntuació UCB1 (*Upper Confidence Bound*) [46]:

$$\text{UCB1}(j) = Q(j) + C \sqrt{\frac{\ln N}{n_j}} \quad (2.28)$$

on $Q(j) = \frac{1}{n_j} \sum_{i=1}^{n_j} R_i^{(j)}$ és la recompensa mitjana obtinguda per les simulacions del fill j , $N = \sum_k n_k$ és el total de simulacions realitzades a l'arrel, n_j és el nombre de visites al fill j , i $C > 0$ és la constant d'exploració. Quan la cerca es guia mitjançant coneixement de domini, la selecció s'executa mitjançant la fórmula **PUCT** [23]:

$$\text{PUCT}(j) = Q(j) + c_{\text{puct}} \cdot P(j) \frac{\sqrt{N}}{1 + n_j} \quad (2.29)$$

on $P(j)$ representa la probabilitat a priori assignada a l'acció j per una política de referència (com l'heurística 'v14').

2.4.4 Imitació i clonatge conductual


L'aprenentatge per imitació (*behavioral cloning*) aproxima la política d'un agent a partir de la supervisió de trajectòries d'experts humans [48, 49]. Donat un conjunt de dades de parelles observació-acció $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$ extretes de partides de competició d'alt nivell (on $x_i = \phi(o_i) \in \mathbb{R}^d$ és el vector de característiques de l'estat i $y_i \in \{1, \dots, K\}$ és la decisió de l'expert), el model aprèn a maximitzar la probabilitat assignada a les accions humanes optimitzant la pèrdua de crosse-entropia multiclasse:

$$\mathcal{L}_{\text{BC}}(\theta) = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K \mathbb{I}(y_i = k) \ln P_{\theta}(Y = k \mid x_i) \quad (2.30)$$

En algorismes basats en arbres de decisió augmentats per gradient (XGBoost) [38], aquesta funció d'objectiu s'aproxima a cada iteració t mitjançant un desenvolupament de Taylor de segon ordre sobre els gradients g_i i Hessians h_i :

$$\mathcal{L}^{(t)} \approx \sum_{i=1}^N \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \Omega(f_t) \quad (2.31)$$

a) **Arquitectura Híbrida (Macro-decisió ML + Micro-execució Heurística)**



b) **Arquitectura Dual Pura (Classificació directa de Tipus i Objectiu)**




Figura 2.7: Comparació estructural entre l'arquitectura d'imitació Híbrida (macro-decisió ML + micro-execució heurística) i l'arquitectura Dual Pura (dos classificadors XGBoost especialitzats).

Tal com s'esquematitza a la Figura 2.7, l'arquitectura d'imitació es pot estructurar en dos enfocaments principals:

1. **Sistema Híbrid (Figura 2.7a):** Un model de classificació tabular $f_{\text{macro}}(x)$ decideix la macro-acció d'atacar o canviar, delegant la selecció micro de l'atac o el Pokémon concret a un executor heurístic de domini.
2. **Sistema d'Imitació Dual Pur (Figura 2.7b):** Dos models de classificació separats avaluen de manera directa i end-to-end tant el tipus d'acció (f_{type}) com la ranura de moviment o substitut (f_{target}).

2.4.5 Aprenentatge per reforç profund amb emmascarament d'accions

L'aprenentatge per reforç autònom [29] optimitza la política $\pi_{\theta}(a \mid o)$ directament mitjançant la interacció amb l'entorn i la maximització del retorn esperat. En entorns de decisió amb restriccions de legalitat variables com Pokémon, l'algorisme MaskablePPO [1, 39] combina l'optimització d'actor-crític amb un emmascarament binari d'accions legals $M(a) \in \{0, 1\}$.

Per evitar que la xarxa neural assigni probabilitat a accions il·legals (com moviments sense PP, Pokémon debilitats o canvis invàlids), la distribució de probabilitats s'obté mitjançant el **Softmax emmascarat**:

$$P_{\theta}(a \mid o) = \frac{M(a) \exp(z_a)}{\sum_{a' \in A} M(a') \exp(z_{a'})} \quad (2.32)$$

on z_a representa el *logit* brut de l'acció a emès per la xarxa neural d'actor.

L'objectiu de política retallat de PPO s'expressa com:

$$\mathcal{L}^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (2.33)$$

on $r_t(\theta) = \frac{\pi_\theta(a_t|o_t)}{\pi_{\theta_{\text{old}}}(a_t|o_t)}$ és la raó de probabilitats i $\hat{A}_t$ és l'estimador d'avantatge generalitzat (GAE). L'optimització conjunta de la xarxa d'actor i de la xarxa de valor minimitza la pèrdua total d'Actor-Crític:

$$\mathcal{L}^{\text{PPO}}(\theta, \phi) = \hat{\mathbb{E}}_t \left[\mathcal{L}_t^{\text{CLIP}}(\theta) - c_1 \left(V_\phi(o_t) - V_t^{\text{targ}} \right)^2 + c_2 \mathcal{S}[\pi_\theta](o_t) \right] \quad (2.34)$$

on V_ϕ és la funció de valor aproximada, $c_1, c_2 > 0$ són coeficients de ponderació i $\mathcal{S}[\pi_\theta]$ és la bonificació d'entropia per afavorir l'exploració.




Figura 2.8: Comportament de la funció d'objectiu retallada de PPO $\mathcal{L}^{\text{CLIP}}$ en funció de la raó de probabilitats $r_t(\theta)$ quan l'avantatge és positiu ($\hat{A}_t > 0$).

A més de l'emascament d'accions binari $M(a)$, l'entrenament DRL d'aquest treball incorpora dos mecanismes clau per estabilitzar la convergència: el disseny de recompenses denses (*reward shaping*) basat en diferències de salut i debilitaments ($\Delta r_t = R_{\text{terminal}} + \gamma \Phi(s_t) - \Phi(s_{t-1})$), i la inicialització guiada de la política (*warm-start*) mitjançant el pre-entrenament per clonatge conductual sobre 400 partides expertes.

2.5 Síntesi del marc teòric

Aquest capítol ha integrat les mecàniques del combat Pokémon, la seva formalització matemàtica com a POSG/POMDP i els fonaments algorítmics dels cinc paradigmes de decisió estudiats. Aquesta articulació teòrica i el marc d'inferència estadística definit constitueixen el fonament directe sobre el qual s'estructura el **Capítol 3 (Metodologia)**, on es detallen el disseny experimental, l'enginyeria de característiques i la infraestructura de simulació.

Capítol 3

Metodologia i disseny experimental

Aquest capítol presenta el **disseny experimental** de l'estudi. El Capítol 2 ha fixat el domini —el format `gen9randombattle` (Secció 2.1.9), la formalització POSG/POMDP (Secció 2.2.2) i el marc d'inferència estadística (Secció 2.2.5)— i els algorismes dels cinc paradigmes (Secció 2.4). Aquí es decideix com s'apliquen aquests fonaments: quin contracte d'entorn fa comparables totes les polítiques, quina arquitectura ha de suportar milions de batalles independents, quines variants d'agent es posen a prova i amb quin protocol mostral. El Capítol 4 documenta el maquinari i les dependències; el Capítol 5 recull la implementació d'aquest disseny.

3.1 Disseny general de l'estudi

Com s'ha argumentat a la Secció 2.1.9, l'estudi treballa en `gen9randombattle` per aïllar la tàctica de la construcció d'equips: el simulador assigna els sis Pokémon de cada bàndol, i el que es mesura és la política, no un equip predissenyat. Sense aquest desacoblament, una taxa de victòria es podria deure tant a una bona decisió com a un equip més fort, i els cinc paradigmes deixarien de ser comparables.

Sobre aquest marc, el disseny experimental fixa tres peces. La **unitat d'anàlisi** defineix què es mesura i amb quina incertesa. El **gestor conceptual d'enfrontaments** existeix perquè comparar 28 polítiques no és un únic combat, sinó una matriu de centenars de cel·les que ha de ser reproducible. El **contracte d'observació i acció** existeix perquè, com s'ha formalitzat a la Secció 2.2.2, tots els agents han de veure la mateixa o_i i actuar sobre el mateix A ; si cada paradigma parlés amb el simulador a la seva manera, les diferències de rendiment es barrejarien amb diferències d'informació.

3.1.1 Unitat d'anàlisi i telemetria

La unitat d'anàlisi és la batalla acabada. El resultat primari és binari —victòria o derrota—, coherent tant amb la naturalesa competitiva de suma zero del joc ($R_1 + R_2 = 0$, Seccions 2.2 i 2.2.2) com amb el marc de l'assaig de Bernoulli (Secció 2.2.5). Tanmateix, una sola taxa no explica *com* decideix cada política; per això, l'estudi vol distingir mecanismes subjacents (pressió ofensiva, conservació de l'equip o ús de cerca) i exigeix un registre exhaustiu de telemetria del procés. Tot i que el sistema recull un conjunt molt més ampli d'indicadors detallats, les principals dimensions analitzades inclouen la durada en torns, les salutats restants, els canvis voluntaris i forçats, l'ús de mecàniques de Generació IX (perills d'entrada, preparació i Teracristallització) i les intervencions de cerca o aprenentatge quan s'escau.

3.1.2 Concepte i responsabilitats del gestor de batalles

Comparar cinc paradigmes i sis controls exigeix el producte cartesià de parelles, no una selecció ad hoc d'oponents. Sense un gestor, cada família d'agents acabaria amb un protocol d'avaluació

propi —un n diferent, un simulador diferent, un criteri de victòria diferent— i la matriu deixaria de ser un experiment. Es defineix conceptualment un **gestor de batalles** amb sis responsabilitats, cadascuna motivada per un risc concret:

1. **Generació d'enfrontaments:** Construir el producte cartesià de parelles. Es vol que cada política es mesuri contra les altres, no només contra un baseline convenient.
2. **Instanciació homogènia:** Inicialitzar els dos participants amb la mateixa interfície. Es vol que la diferència observada sigui de política, no de manera de connectar-se al simulador.
3. **Orquestració de simuladors:** Assignar instàncies independents de Showdown, una per treballador. Es vol paral·lelitzar sense que dues partides comparteixin estat intern del motor.
4. **Aïllament de l'estat:** Executar el nombre objectiu de partides sense contaminar la memòria entre batalles. Es vol que la partida $k + 1$ no hereti objectes, historial ni fuites de la k .
5. **Persistència incremental:** Enregistrar resultat i telemetria en acabar cada partida. Es vol poder interrompre una execució de dies sense perdre el que ja s'ha validat.
6. **Tolerància a fallades:** Reprendre sense duplicar les batalles ja enregistrades. Es vol que un procés caigut no obligui a recomençar la cel·la.




Figura 3.1: Disseny conceptual de l'estudi. La mateixa infraestructura avalua polítiques diferents i retorna tant el resultat com el comportament. El PPO comparteix simulador, però no entra a la matriu 28×28 .

Aquest esquema (Figura 3.1) desacobla la coordinació de l'avaluació de la lògica interna dels agents. Una heurística de tres línies i una xarxa neuronal entrenada per reforç es poden enfrontar sota les mateixes condicions: mateix format, mateixa observació parcial i mateixa resolució estocàstica del torn. El motiu d'aquest desacoblament és metodològic: si el gestor coneixés com decideix cada agent, seria temptador adaptar el protocol a cada família, i la comparació deixaria de ser un experiment únic.

3.2 Contracte d'entorn i protocol de comunicació

A la Secció 2.1.9 s'ha situat Pokémon Showdown com a simulador autoritatiu i *poke-env* com a interfície Python; a la Taula 2.5 s'ha mapat la tupla POSG sobre aquests dos components. El que cal tancar aquí és el **contracte experimental** que se'n deriva, i *per què* s'adopta aquesta pila en lloc de reimplementar un motor propi o de parlar directament amb el protocol textual.

Es vol que tots els paradigmes competeixin sota la mateixa funció d'emissió O i el mateix espai d'accions A . Un motor propi seria més fàcil d'instrumentar, però divergiria de les regles oficials i invalidaria la comparació amb la literatura (Secció 2.3) i amb el *ladder* públic. Parlar amb el protocol cru, d'altra banda, obligaria cada agent a reimplementar el parser: un error de descodificació en una família —per exemple, no veure un perill d'entrada— es confondria amb

una diferència de política. Per això el disseny situa Showdown com a àrbitre únic i *poke-env* com a única traducció d'observació i d'ordre.

3.2.1 Showdown i *poke-env*: àrbitre, protocol i objecte de batalla

Pokémon Showdown [4] no és una llibreria que l'agent importi per consultar l'estat real. És un **servidor de combat** en Node.js/TypeScript que manté l'estat omniscient S —equips complets, objectes, moviments no revelats, IVs i tipus Tera— i n'és l'únic autoritzat a aplicar la transició T descrita a la Secció 2.1: prioritat, velocitat, tirada de dany, precisió i efectes secundaris. Els clients no executen el combat: hi *participen*.

La comunicació és un protocol textual sobre WebSocket. El servidor obre una sala per batalla i emet línies prefixades amb `|`. Dues classes de missatge vertebran el torn:

- **Petició d'acció (`|request|`).** Un JSON privat per a cada jugador. Conté el bàndol propi (HP, moviments amb PP, canvis legals), la llista d'accions permeses i, si s'escau, un canvi forçat. Del rival, només hi figura el que el protocol ja ha revelat: espècie activa, percentatge d'HP, moviments ja usats i condicions visibles. Aquest paquet *és* l'observació o_i de la Taula 2.5: el filtre O no el fa l'agent, el fa Showdown abans d'enviar el missatge (vegeu l'exemple de la Figura 3.2).

```
{
  "active": [{
    "moves": [
      { "move": "Thunderbolt", "id": "thunderbolt", "pp": 15, "disabled": false },
      { "move": "Volt Switch", "id": "voltswitch", "pp": 32, "disabled": false }
    ],
    "canTerastallize": "Ice"
  }],
  "side": {
    "name": "p1",
    "pokemon": [
      { "ident": "p1: Gengar", "condition": "216/216", "active": true, "moves": ["thunderbolt", "voltswitch"] },
      { "ident": "p1: Great Tusk", "condition": "303/303", "active": false, "moves": ["headlongrush", "closecombat"] }
    ]
  },
  "rqid": 12
}
```

Figura 3.2: Exemple d'estructura del missatge JSON de petició d'acció (`|request|`) enviat per Pokémon Showdown a cada jugador.

- **Registre de resolució.** Un cop *tots dos* jugadors han enviat una ordre, el motor desbloqueja el torn —accions simultànies, no per torns com als escacs— i emet el log (`|move|`, `|switch|`, `|-damage|`, `|-crit|`, `|win|`, ...). Fins que no arriben les dues ordres, l'estat no avança. Aquest *lock* simultani és la raó per la qual Minimax es formula com a matriu d'un pas (Secció 2.4.2) i no com a arbre d'alternança.

L'agent, doncs, mai llegeix S . Si un paradigma «mirés» l'equip ocult del rival, deixaria de ser un POSG i la comparació amb humans o amb altres bots seria invàlida. El disseny localitza instàncies *headless* del mateix servidor —no el *ladder* públic— perquè la matriu pugui córrer sense cua, sense autenticació competitiva i amb reproducció controlada; el protocol, però, és el mateix.

poke-env [5] és la capa que tradueix aquest protocol a Python. Internament fa tres feines que l'estudi no vol duplicar a cada agent:

1. **Manté la connexió asíncrona** amb una instància de Showdown i identifica la sala de la batalla.

2. **Parseja les línies del protocol** i actualitza un objecte `Battle`: Pokémon actius, banqueta, camp, moviments revelats, accions legals (`available_moves`, `available_switches`) i flags com el canvi forçat. Aquest objecte és Ω ja estructurat, no el JSON cru.
3. **Crida la política** `choose_move(battle)` i serialitza el resultat —un `BattleOrder`— a una ordre que el servidor accepta (`/choose move 1`, `/choose switch 3`, Teracristal · lització com a modificador). Si l'ordre és il·legal, la batalla es bloqueja: per això el contracte exigeix actuar només sobre el conjunt legal que *poke-env* exposa.

La Figura 3.3 resumeix aquestes tres capes. El que canvia entre paradigmes és només el bloc central —com es calcula l'acció a partir de `Battle`—. Heurístiques i minimax operen directament sobre l'objecte; l'imitació el projecta a una fila tabular; MaskablePPO el projecta a un vector i a una màscara. El Showdown que resol el torn és sempre el mateix.




Figura 3.3: Tres capes del contracte. Showdown és l'àrbitre omniscient; *poke-env* tradueix el protocol a un objecte i a una ordre legal; la política és l'únic bloc específic de cada paradigma. La fletxa discontinua tanca el torn al motor.

3.2.2 Cicle d'un torn de batalla

El cicle de la Figura 3.4 és el bucle que el gestor ha de poder repetir milions de vegades. Cada pas té una funció concreta en el POSG; ometre'n el context faria semblar el protocol una seqüència arbitrària de missatges.

1. **Connexió a una instància local.** El client obre un WebSocket contra un Showdown *headless*. Es fa en local perquè la matriu no depengui de la cua ni de les normes del servidor públic, i perquè cada treballador pugui tenir el seu port (Secció 3.3).
2. **Repte gen9randombattle.** El simulador genera els dos equips i obre la sala. En aquest moment *S* ja és complet, però cap agent el veu: només rebrà o_i . És el punt on s'aïlla la tàctica del *teambuilding* (Secció 2.1.9).
3. **Petició amb observació i legalitat.** Showdown envia `|request|` a cada bàndol. Aquest missatge fixa alhora Ω (què es veu) i A (què es pot triar). Un canvi forçat, per exemple, buida la llista de moviments: l'agent no ha de «inventar» accions, ha de triar dins d'aquest conjunt.

4. **Actualització de l'objecte Battle.** *poke-env* incorpora el JSON i el log previ a l'objecte estructurat. Sense aquest pas, cada política hauria de reimplementar el parser i el risc d'observacions inconsistents seria alt.
5. **Decisió de la política.** L'agent executa la seva regla, matriu, arbre, classificador o xarxa sobre **Battle**. És l'únic pas que difereix entre famílies. El temps d'aquest pas condiciona l'arquitectura paral·lela: una heurística acaba en mil·lisegons; un MCTS ras, en segons.
6. **Enviament de l'ordre.** *poke-env* tradueix el **BattleOrder** a `/choose`. Showdown no avança fins que l'oponent ha fet el mateix: l'agent no observa l'acció rival *abans* de decidir, tal com exigeix el joc de matriu simultània.
7. **Resolució estocàstica del torn.** El motor aplica T —prioritat, velocitat, dany, crítics i efectes, Secció 2.1— i emet el registre. Aquest log actualitza les creences (moviments revelats, HP, camp) de cara al torn següent.
8. **Tancament.** El cicle es repeteix fins a `|win|`. La batalla acabada és la unitat d'anàlisi de la Secció 3.1.




Figura 3.4: Intercanvi d'un torn. Showdown filtra l'estat i no resol fins a tenir les dues ordres; *poke-env* estructura l'observació i legalitza l'acció. L'agent no accedeix mai a S .

Aquest flux —i no una API pròpia de cada paradigma— és el que fa comparable una heurística amb un classificador o amb MaskablePPO. El Capítol 5 detalla versions, ports i la classe base que implementa `choose_move`; el que importa aquí és el motiu: un sol àrbitre, una sola traducció, polítiques intercanviables.

3.3 Arquitectura conceptual d'avaluació massiva

Les sis responsabilitats del gestor (Secció 3.1) s'han de poder executar a l'escala de la matriu d'enfrontaments: centenars de creuaments de polítiques (o cel·les) i milions de batalles independents. Aquesta magnitud no és un gust d'enginyeria: deriva del protocol estadístic del Capítol 2.

Cada batalla és un assaig independent (Secció 2.2.5) i el marge d'error objectiu exigeix un nombre n de l'ordre de milers per cel · la (Secció 3.6). Un experiment d'aquest volum, executat de manera seqüencial en un sol procés, no cabria en el calendari del treball ni seria numèricament estable. El que cal dissenyar, doncs, no és «com llançar partides», sinó una arquitectura que faci viable, aïllada i reprenable aquesta matriu.

3.3.1 Per què una arquitectura paral · lela i aïllada

Per assolir els tres requisits fixats anteriorment —viabilitat en calendari, aïllament d'execució i estabilitat numèrica— cal abandonar definitivament la idea d'un únic procés seqüencial. L'elecció d'un disseny paral · lel basat en treballadors aïllats i efímers és la resposta directa a quatre colls d'ampolla tècnics derivats del cicle de comunicació de la Secció 3.2.1 i de l'avaluació d'agents heterogenis:

- **Volum i heterogeneïtat temporal.** Una heurística decideix en mil · lisegons; l'MCTS ras, per la formulació de la Secció 2.4.3, executa desenes de simulacions locals a cada torn i és ordres de magnitud més lent. Si totes les partides compartissin una cua seqüencial, les cel · les ràpides quedarien bloquejades darrere de les lentes, i el calendari el dictaria el pitjor cas. Es vol paral · lelitzar per ocupar el maquinari i, alhora, *no* exigir el mateix n a totes les famílies (Secció 3.6).
- **Estat i memòria.** Showdown (motor JavaScript V8 de Node.js) i *poke-env* (objectes Battle, historials, estructures de cerca) acumulen memòria a mesura que es succeeixen les partides. En un intèrpret únic, una fuga o un objecte retingut contamina les milers de batalles següents i acaba esgotant la RAM. Es vol que cada lot visqui en un procés que, en acabar, el sistema operatiu pugui recollir del tot.
- **Fallades independents.** Una cerca que es bloqueja, una ordre il · legal o un servidor Node.js que creix sense límit no ha de fer caure la matriu sencera. Es vol aïllament: el coordinador sobreviu; el treballador és descartable.
- **Independència estadística.** El protocol de la Secció 2.2.5 tracta cada batalla com un assaig de Bernoulli. Si dues partides compartissin RNG, sala o estat intern del motor, aquesta hipòtesi es trencaria. Un Showdown dedicat per treballador redueix aquest risc.

Una alternativa —un *pool* persistent de jugadors en un sol procés, o un únic Showdown multiplexat— seria més simple d'arrencar. Es descarta perquè no separa memòria, no recupera un treballador mort i no permet reprendre una execució de dies sense duplicar feina. El disseny que s'adopta, doncs, és coordinador/treballadors efímers amb simulador dedicat, persistència com a font de veritat i reinici periòdic del motor.

3.3.2 Model coordinador i treballadors efímers

Per donar resposta als quatre requisits d'aïllament, volum i estabilitat justificats a la Secció 3.3.1, l'estudi adopta un patró d'arquitectura **Coordinador–Treballador** (*Master–Worker*) amb cicle de vida efímer. La clau d'aquest disseny rau en el desacoblament estricte entre la gestió global de l'experiment i l'execució física dels combats.

En lloc de mantenir simuladors o agents persistents que acumulin memòria o puguin bloquejar l'execució, l'arquitectura conceptual distingeix dos rols clarament diferenciats (Figura 3.5), evitant barrejar la planificació («què queda pendent de jugar») amb la simulació («executar un lot de partides»):

- **Coordinador:** No juga cap partida. Calcula els enfrontaments pendents, assigna lots a processos independents, en supervisa el progrés i en fusiona els resultats. Així, un error de combat no destrueix el mapa de la matriu.

- **Treballadors efímers:** Cada treballador és un procés independent amb un servidor Showdown dedicat —el mateix contracte de la Secció 3.2, però una instància per lot—. Executa el seu lot, escriu els resultats en un magatzem temporal i desapareix. No hi ha memòria compartida: quan el procés acaba, el sistema operatiu en recupera els recursos.

Aquest aïllament és especialment rellevant per a Minimax i MCTS, que construeixen estructures de cerca per torn, i per a les heurístiques avançades, que mantenen historial per batalla. El Capítol 5 concreta ports, mida de lot i temps d’espera; aquí el que importa és la forma: paral·lelisme per volum, aïllament per memòria i fallades, simulador dedicat per independència.




Figura 3.5: Arquitectura conceptual d’avaluació massiva. El coordinador gestiona la matriu i supervisa la consolidació; cada treballador opera en un procés aïllat amb un Showdown dedicat i escriu el seu lot temporal (.csv) abans de reciclar-se.

3.3.3 Represa, persistència i reinici del simulador

Una execució de milions de batalles dura dies. Si l’estat de progrés visqués només en memòria, una interrupció —reinici de màquina, procés mort, Showdown saturat— obligaria a recomençar la cel·la i trencaria la independència dels assaigs ja jugats. Per això el magatzem de resultats de cada enfrontament és la **font d’estat de progrés**: si ja conté k files, el coordinador calcula $n_{\text{pendent}} = n_{\text{objectiu}} - k$ i només executa la resta. Es persisteix per poder aturar i reprendre sense duplicar feina.

El reinici periòdic del simulador i els blocs curts de batalles responen al mateix diagnòstic de memòria: el motor Node.js/V8 i els objectes `Battle` creixen amb el temps. En lloc de confiar que un procés llarg es mantingui estable, el disseny el recicla. El Capítol 5 documenta la cadència observada; aquí es fixa el principi.

3.4 Disseny conceptual de les famílies d’agents

Una vegada fixat el contracte d’entorn (Secció 3.2) i establerta l’arquitectura paral·lela per orquestrar i executar les batalles de manera massiva, aïllada i reproducible (Secció 3.3), el disseny experimental requereix formalitzar les polítiques de decisió que s’enfrontaran a la matriu. La Secció 2.4 ha establert els fonaments dels cinc paradigmes d’IA —heurística, minimax d’un torn, MCTS ras, aprenentatge per imitació i MaskablePPO— i n’ha definit la font de coneixement i el còmput per torn. El motiu de mesurar-los sota un mateix protocol experimental és resoldre el buit identificat a la Secció 2.3: a la literatura existent, cada tècnica s’avalua en entorns, simuladors o condicions heterogènies que n’impedeixen la comparació directa. Aquí s’aplica exactament el mateix marc d’avaluació a tots els agents i, dins de cada família, un disseny d’ablació que permeti aïllar els mecanismes responsables de cada variació en el rendiment.

Així doncs, per a cada paradigma es concreta una pregunta de recerca específica i una genealogia de variants. A més, a la matriu d'enfrontaments s'hi integren sis agents de referència; tot i que no formen part de l'ablació interna, aquests baselines resulten indispensables com a àncores per validar si les polítiques desenvolupades superen els estàndards públics i la literatura existent.

3.4.1 Agents de referència

Abans de formalitzar les cinc famílies d'agents i les seves respectives ablacions, és necessari definir el grup de **polítiques de referència** (*baselines*). Aquests agents no formen part del disseny d'ablació interna, però s'integren al producte cartesià de la matriu per avaluar el rendiment en termes absoluts. Sense aquestes àncores externes, només es compararien variants pròpies entre si i no es podria determinar si les polítiques desenvolupades superen els estàndards existents a la comunitat i a la literatura.

Per garantir una comparació rigorosa, els sis agents de referència s'han seleccionat explicitant la procedència i funció de cadascun:

- **random:** Prové del mòdul de control aleatori inclòs per defecte a la llibreria *poke-env* [5] (**RandomPlayer**). Selecciona accions de manera uniforme entre totes les opcions legals de l'estat, actuant com a control inferior absolut i origen de l'escala Elo (Secció 2.2.5).
- **max_power:** Prové del *baseline* ingenu integrat a *poke-env* (**MaxBasePowerPlayer**). Tria sempre l'atac de major potència base sense considerar tipus, efectivitat ni canvis, servint com a control d'ofensiva cega.
- **simple_heuristic:** Prové de l'heurística de referència proporcionada per la llibreria *poke-env* (**SimpleHeuristicsPlayer**), adaptada en aquest treball per suportar la mecànica de Teracristal · lització de Generació IX. Representa el *baseline* heurístic estàndard de la comunitat.
- **abyssal:** Prové del repositori oficial del projecte *PokéChamp* [43] (Secció 2.3), on constitueix el controlador basat en regles expertes (**AbyssalPlayer**). S'utilitza com a oponent discriminant de referència de la literatura científica existent.
- **one_step / safe_one_step:** Prové de la política de cerca determinista d'un pas (*lookahead* d'un torn) desenvolupada a partir del mòdul de cerca de *PokéChamp* (**SafeOneStepPlayer**). Avalua l'impacte immediat d'un torn sense requerir un simulador local complet. Les dues etiquetes al registre responen a la traçabilitat històrica de l'execució, però corresponen a la mateixa lògica de decisió.

3.4.2 Família Heurística: genealogia, hipòtesis d'ablació i la pregunta del valor marginal

La família d'agents heurístics constitueix el nucli de coneixement de domini expert de l'estudi. A través d'una seqüència d'ablació incremental de catorze variants (v1–v14), es formalitza la incorporació progressiva de regles d'estimació de dany, canvis posicionals, gestió de perills, Teracristal · lització i inferència sobre l'adversari. Aquesta genealogia permet avaluar el valor marginal de cada mecànica i serveix d'avaluador terminal per a les famílies de cerca posteriors.

Pregunta de recerca

Quina mecànica de domini —estimació de dany, canvi tàctic, perills d'entrada, Teracristallització o model de l'adversari— aporta el major increment marginal de taxa de victòria, i existeix un punt on afegir més regles perjudica el rendiment?

Decisions de disseny

Una sola heurística «completa» respondria qui guanya, no què aporta cada bloc de coneixement. La Secció 2.4.1 formalitza l’heurística com a suma ponderada i l’ablació incremental $H^{(m)}(s, a) = \sum_{f_k \in \mathcal{F}^{(m)}} w_k \cdot f_k(s, a)$ (Equació 2.24). El disseny concreta $M = 14$ punts d’aquesta ablació *perquè* es vol mesurar el valor marginal de cada mecànica —i detectar si n’hi ha que perjudiquen— abans d’usar l’heurística terminal com a fulla de cerca. No són catorze provatures aïllades: cada versió afegeix un bloc concret, amb ramificacions quan dues hipòtesis són ortogonals (Figura 3.6).

La seqüència no és una cadena estricta. Les versions primerenques exploren estimadors de dany i pivots simples; v7 reescriu el nucli d’avaluació de l’enfrontament —es fa així perquè una cascada de conditionals no és reutilitzable com a fulla—; v9 i v10 afegeixen tempo i tàctica com a blocs separats que v11 fusiona abans d’introduir les mecàniques de Generació IX. Es ramifica abans de fusionar per no atribuir a «més regles» un efecte que en realitat ve d’un sol dels dos blocs.




Figura 3.6: Genealogia de disseny dels agents (v1–v22). Les rutes de desenvolupament i ramificació entre variants s’agrupen per color segons el bloc de funcionalitat descrit a la llegenda.

Descripció concreta de cada versió

La Taula 3.1 recull la idea de cada versió. Les ramificacions v4/v5 i v9/v10 no són «més del mateix»: aïllen hipòtesis diferents sobre quin coneixement importa.

Tres decisions estructurals vertebrèn la resta de l’estudi, i es prenen *abans* de dissenyar cerca i aprenentatge perquè aquestes famílies reutilitzin el mateix nucli:

- **Ramificacions v4/v5 i v9/v10:** aïllen camp i modificadors, d’una banda, i tempo i tàctica, de l’altra, abans de fusionar-los. Es vol poder atribuir un canvi de taxa a un bloc, no a un paquet indivisible.
- **Punt d’inflexió v7:** el nucli passa d’una cascada de conditionals a una suma ponderada de l’enfrontament. Es fa així perquè Minimax i MCTS necessiten una fulla numèrica, no una llista de `if`.
- **v14 com a servei:** l’heurística més completa es dissenya per servir de *fulla* a Minimax i MCTS, de *prior* a PUCT i d’*executor tàctic* a la imitació híbrida. Sense aquest paper, cada paradigma reimplementaria el coneixement de domini i les diferències deixarien de ser aïllables.

En resum, l’ablació v1–v14 aïlla el valor marginal de cada bloc de regles fins a consolidar v14. Aquesta versió final actua com a sostre de la família basada en regles i es converteix en la funció d’avaluació, prior o executor utilitzat per les famílies de cerca i aprenentatge posteriors.

Taula 3.1: Disseny conceptual de les catorze versions heurístiques. Cada versió aïlla un bloc de coneixement de domini.

Versió	Idea de disseny i mecànica incorporada
v1	Baseline greedy. Selecciona el moviment amb major potència efectiva: potència base $\times$ efectivitat de tipus $\times$ STAB (Secció 2.1.3). No canvia mai.
v2	Dany amb estadístiques i pivot defensiu. Substitueix el proxy de potència per una estimació amb atac/defensa (i penalització de cremada) i introdueix dos canvis: escapar d'un enverinament greu acumulat, i pivotar quan el millor atac és feble i l'actiu és més lent.
v3	Mateixa política, telemetria de moviments. Conserva el dany i els pivots de v2 i registra els moviments usats per batalla, necessari per a l'anàlisi posterior.
v4	Camp i objectiu de canvi. Incorpora clima i terreny a l'estimació, pondera per precisió i prioritat, i deixa d'escollir sempre el primer substitut: tria el company amb millor avantatge de tipus.
v5	Modificadors d'etapa. Extén v4 amb el dany conscient dels boosts d'atac i defensa acumulats durant la partida.
v6	Consolidació lleugera sobre v3. Reintrodueix clima, terreny i una bonificació de prioritat sobre el nucli estable de v3, conservant el pivot al primer substitut. Hipòtesi: el camp ajuda sense necessitar encara el canvi intel·ligent de v4.
v7	Punt d'inflexió: reescriptura del nucli. Nova puntuació de l'enfrontament conscient dels boosts, amb canvis voluntaris basats en la qualitat de l'aparellament. No col·loca perills ni fa preparació: l'atac és l'acció per defecte.
v8	Debilitament amb prioritat i immunitats conegudes. Sobre v7, executa un atac de prioritat quan el debilitament és conservadorament garantit, i descarta moviments als quals el rival és immune <i>només</i> si l'habilitat ja s'ha revelat.
v9	Tempo en torns lliures. Col·loca perills d'entrada i fa moviments de preparació <i>només</i> quan l'actiu és més ràpid i resisteix l'STAB rival. Hipòtesi: el tempo <i>només</i> paga si no es malgasta el torn.
v10	Tàctica sobre el nucli v8. Condicions d'estat ofensives, sacrifici amb pocs HP (no canviar per no malgastat el torn) i pivots amb <i>U-turn/Volt Switch</i> . Bloc ortogonal a v9.
v11	Fusió tempo + tàctica. Combina les regles de v9 i v10 en una sola política, amb adaptacions menors segons la generació del format.
v12	Mecàniques de Generació IX. Integra la Teracristall·lització ofensiva i defensiva d'ús únic (Secció 2.1.4) i substitueix l'elecció del capdavanter i del substitut forçat per una selecció basada en l'enfrontament.
v13	Inferència amb moviments revelats. Avalua l'enfrontament amb els atacs ja vistos (no <i>només</i> amb els tipus), afegeix recuperació, explotació de bloqueig <i>Choice</i> , expulsió de rivals amb modificadors i una política de Tera més conservadora.
v14	Model de l'adversari i resolució de finals. Classifica el rival com a <i>predictiu</i> o <i>conservador</i> segons la taxa de canvis, fa sondeig als torns inicials, aproxima el dany amb un interval i aplica una resolució exhaustiva d'un torn quan queden ≤ 2 Pokémon per bàndol.

3.4.3 Família Minimax: tres variants de resolució de la matriu d'un torn

La família Minimax aporta la consideració explícita de la millor resposta de l'adversari en el moment de prendre una decisió. Com que en els combats Pokémon els dos jugadors escullen la seva acció simultàniament, una política ingènua (*greedy*) pot cometre l'error de suposar que el rival es quedarà passiu. Minimax resol aquesta feblesa avaluant una matriu de recompenses d'un sol torn.

Pregunta de recerca

Considerar explícitament la millor resposta de l'adversari en un joc de matriu d'un pas millora el rendiment respecte de l'heurística greedy, i enriquir la fulla o esbiaixar-la amb un prior de v14 aporta més que el maximin nu?

Decisions de disseny i funcionament

Com es mostra a la Figura 3.7, per a cada torn l'agent construeix una matriu de recompenses M on les files corresponen a les nostres accions legals ($a_1, \dots, a_k$) i les columnes a les accions possibles de l'adversari ($b_1, \dots, b_m$). Cada cel·la M_{ij} s'avalua amb el nucli heurístic v14. A continuació, per a cada acció pròpia es determina el pitjor escenari possible ($\min_j M_{ij}$) i es selecciona l'acció que maximitza aquest valor mínim ($\max_i \min_j M_{ij}$).




Figura 3.7: Esquema del mètode Maximin d'un torn. Es construeix la matriu de recompenses M avaluant la resposta de l'adversari amb el nucli v14 i es tria l'acció amb el millor resultat en el pitjor cas ($\max_i \min_j M_{ij}$).

S'implementen tres variants per aïllar l'impacte de la funció de valor i del prior heurístic:

- **v15 — Maximin amb fulla d'HP:** Combina el balanç de punts de vida (HP) amb la qualitat de l'enfrontament, aplicant una penalització conservadora de $\times 1,5$ al dany rebut del rival. Avalua si l'anticipació de la millor resposta adversària ja supera la decisió *greedy* fent servir només informació bàsica de dany i salut.
- **v16 — Maximin amb fulla enriquida:** Afegeix a l'avaluació de la cel·la bonificacions posicionals per perills d'entrada (*hazards*), moviments de preparació (*setup*), recuperació i estats alterats. Permet mesurar l'efecte de la informació posicional a les cel·les sense alterar el criteri de cerca.
- **v17 — Maximin amb prior heurístic:** Suma una bonificació fixa (+0,15) al pitjor cas de l'acció recomanada per v14, afavorint el coneixement expert quan la cerca atorga valors similars. Això redueix desviacions innecessàries i mesura si el prior d'expertesa pot guiar millor la matriu.

Abans de construir la matriu, tots els agents apliquen dreceres tàctiques (com debilitar el rival si el KO és garantit). A més, es mesura la **mètrica de discrepància** per quantificar quantes vegades la matriu Minimax canvia la decisió respecte a l'heurística pura v14.

3.4.4 Família MCTS: variants de simulació i mètrica de discrepància

Mentre que Minimax només avalua un torn en el futur amb una fulla estàtica, la cerca en arbre de Monte Carlo (MCTS) explora trajectòries de diversos torns cap a endavant mitjançant simulació estocàstica. Aquest enfocament permet preveure les conseqüències futures de les decisions immediates.

Pregunta de recerca

La simulació estocàstica cap a endavant permet corregir els biaixos de la política heurística, i amb quina freqüència la cerca acaba triant una acció diferent de la recomanació heurística?

Decisions de disseny i funcionament

Com s'il·lustra a la Figura 3.8, la cerca s'adopta en un esquema de profunditat d'arbre $d = 1$ a l'arrel per respectar els temps de resposta en temps real de Showdown. Per a cada decisió, s'obren branques per a totes les accions legals immediates i s'executen 100 iteracions de simulació:

1. **Selecció:** Es tria l'acció fill a explorar aplicant un criteri d'exploració/exploitació (UCB1 o PUCT amb prior de v_{14}).
2. **Simulació (Rollout):** Es reproduceix la partida durant 5 torns cap a endavant utilitzant un simulador local en memòria (LocalSim) basat només en la informació revelada.
3. **Avaluació i Retropropagació:** L'estat final de la simulació s'avalua amb el nucli heurístic v_{14} i el resultat s'acumula a l'acció arrel. Al final de les 100 iteracions, es selecciona l'acció més visitada.




Figura 3.8: Arquitectura del cicle de cerca MCTS de quatre fases a l'arrel ($d = 1$). (1) Selecció de l'acció fill a^* (UCB1/PUCT); (2) Simulació local de 5 torns amb LocalSim; (3) Avaluació de la fulla s_5 amb el nucli v_{14} ; i (4) Retropropagació de la recompensa v i actualització d'estadístiques (Q, N) durant 100 iteracions.

Es defineixen tres variants principals per aïllar la selecció de la funció d'avaluació:

- **v_{18} — UCB1 sense prior:** Selecció pura per UCB1 ($C = 1,4$) i avaluació de fulla basada en HP, modificadors, estats i perills. Avalua si la simulació estocàstica cap a endavant per si sola, sense guiatge expert, pot corregir els biaixos heurístics. Actua com a línia de base agnòstica amb cerca uniforme.
- **v_{19} — UCB1 amb fulla enriquida:** Manté la selecció UCB1, però incorpora a la fulla la ponderació per rols (Win-Con i Vital Wall), l'amenaça de KO i les dreceres tàctiques de v_{14} . Mesura el guany de qualitat en el rollout quan l'estat final es valora amb coneixement de domini avançat.

- **v20 — PUCT amb prior heurístic:** Substitueix UCB1 per selecció PUCT esbiaixada amb un prior de 0,70 sobre l'acció recomanada per v14 i la fulla enriquida de v19. Comprova si guiar l'exploració de l'arbre amb priors d'expertesa aconseguix concentrar les simulacions en les branques més promissòries.

Com en la família Minimax, les simulacions s'executen en un simulador local en memòria alimentat només amb la informació revelada (respectant la naturalesa POSG del joc) i es mesura la **mètrica de discrepància** respecte a v14.

3.4.5 Família d'Imitació Jeràrquica: desacoblament macro/micro i dues arquitectures

La família d'aprenentatge per imitació aborda la transferència de coneixement tàcit des de corpus de partides humanes d'alt nivell ($Elo \geq 1800$). En lloc de dissenyar regles o taules de cerca manuals, aquest enfocament entrena models d'aprenentatge automàtic supervisat per reproduir el criteri de decisió dels millors jugadors humans.

Pregunta de recerca

Pot un model entrenat amb dades d'experts humans igualar o superar l'heurística manual, i quin nivell de delegació a l'executor heurístic necessita per generalitzar a estats no vistos?

El problema de la representació i la solució jeràrquica

Com s'ha argumentat a la Secció 2.4.4, en els combats Pokémon l'espai d'accions presenta una inestabilitat semàntica inherent: l'índex d'un moviment (p. ex., el moviment 1) o la posició d'un substitut a la banqueta no tenen un significat constant entre Pokémon diferents. Intentar imitar directament les identitats concretes dels slots d'acció conduiria a un vocabulari inestable i a una explosió combinatòria d'estats.

Per resoldre aquesta limitació, es dissenya una **arquitectura jeràrquica** que desacobla la decisió en dos nivells:

- **Nivell Macro (Estratègic):** Un classificador supervisat decideix l'orientació general de l'acció en l'estat actual: si la millor opció és mantenir-se al camp i **atacar** o fer un pas enrere i **canviar** de Pokémon ($y \in \{0 : atacar, 1 : canviar\}$).
- **Nivell Micro (Tàctic):** Un executor tria la decisió concreta: si la macro-decisió és atacar, quin dels quatre moviments legals executar; si és canviar, a quin dels Pokémon de la banqueta passar el relleu.

Origen de les dades i disseny del classificador XGBoost

Per entrenar el model macro s'utilitza el conjunt públic de repeticions de Pokémon Showdown (*Showdown Replays Database*) [50], filtrat per a la modalitat de batalles aleatòries de Generació IX (*Gen 9 Random Battle*) i contingut exclusivament en partides de l'escala competitiva d'alt nivell ($Elo \geq 1800$).

Aquest conjunt de dades enregistra la seqüència completa per torns de les batalles humanes: la salut percentual dels Pokémon actius i de la banqueta, els modificadors d'etapa estadística, les condicions d'estat alterat, els perills d'entrada col·locats al camp (*Stealth Rock*, *Spikes*), els moviments i habilitats ja revelats, i l'acció finalment triada pel jugador humà. La utilitat d'aquest dataset rau en la seva capacitat per capturar la intuïció estratègica i el coneixement tàcit d'experts humans (com el moment oportú per efectuar un canvi conservador o un pivot tàctic) sense necessitat de programar regles manuals.

El procés de construcció i entrenament del classificador XGBoost es sintetitza en tres aspectes de disseny:

1. **Construcció del vector de característiques:** Es processen aproximadament 1,12 milions de torns per generar una matriu tabular d'unes 1.150 columnes (incloent la codificació *one-hot* d'espècies i formes regionals). La variable objectiu es redueix a la decisió macro binary $y \in \{0 : \text{atacar}, 1 : \text{canviar}\}$.
2. **Partició agrupada per batalla:** Per evitar la filtració d'informació entre torns consecutius d'un mateix combat, es realitza un desglossament train/test agrupat per identificador de combat (*GroupShuffleSplit* per *battle_id*).
3. **Tractament del desequilibri i calibratge de lllindar:** Atès que l'acció d'atacar és molt més freqüent que la de canviar, s'aplica una ponderació de classe (*scale_pos_weight*) i es calibra un lllindar de decisió τ sobre la corba precisió-record en validació. Durant la inferència, l'agent executa un canvi si $p(\text{canvi}) \geq \tau$, i un atac en cas contrari.

Dues arquitectures d'execució micro: Híbrida vs Pura Dual

Com s'il·lustra a la Figura 3.9, es dissenyen dues variants per avaluar el grau de delegació a l'heurística manual i mesurar la capacitat de generalització del model fora de distribució:

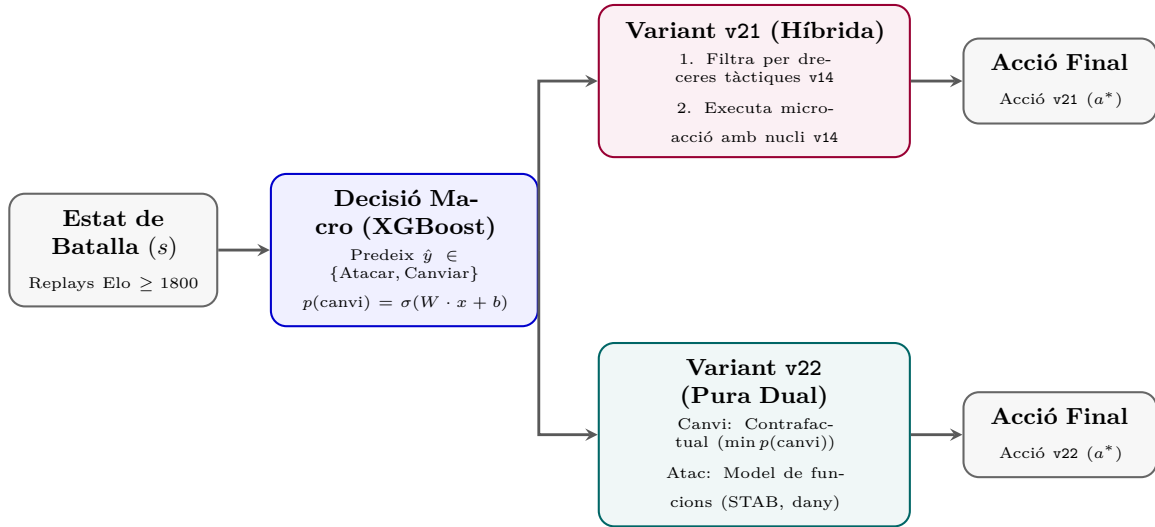


Figura 3.9: Arquitectura d'imitació jeràrquica amb desacoblament macro/micro. El classificador macro (XGBoost) decideix si atacar o canviar a partir de partides d'alt nivell. A nivell micro, v21 delega l'execució al nucli heurístic v14, mentre que v22 utilitza un model dual pur (contrafactual per canvis i model d'atributs per atacs).

- **v21 (Híbrida):** Aplica primer les dreceres tàctiques de v14 (debilitament garantit, solver de finals, reacció a preparació, absorció d'estats). Quan aquestes regles no es disparen, consulta el model XGBoost per decidir la macro-acció; posteriorment, delega l'execució micro (quin atac fer o a quin Pokémon canviar) al nucli de regles v14. Aquest disseny hereta la seguretat i la robustesa heurística fora de la distribució d'entrenament.
- **v22 (Pura Dual):** Prescindeix completament de les regles de v14. Utilitza el mateix classificador macro XGBoost, però resol el nivell micro amb dos mecanismes apresos: si la decisió és canviar, selecciona el substitut per avaluació contrafactual (tria el candidat de banqueta que minimitza la probabilitat de necessitar un altre canvi immediat, $\min p(\text{canvi})$); si la decisió és atacar, avalua els moviments legals amb un segon model entrenat sobre atributs sintetitzats (potència, STAB, efectivitat, prioritat, HP).

El contrast entre ambdues permet aïllar el valor de les proteccions heurístiques: mentre que v21 combina la intuïció estratègica humana amb la rigorositat de les regles de domini, v22

mesura fins a quin punt l'aprenentatge per imitació pur pot funcionar de manera autònoma sense cap xarxa de seguretat manual.

3.4.6 Família DRL (MaskablePPO): currículum de dificultat creixent

La família d'aprenentatge per reforç profund representa l'enfocament autòmitzat sense regles prèvies ni demostracions humanes directes. Basada en l'algorisme MaskablePPO, aquesta línia d'experimentació avalua la capacitat d'una xarxa neural per descobrir estratègies competitives des de zero mitjançant la interacció contínua amb el simulador.

Pregunta de recerca

Pot una xarxa neural entrenada per reforç aprendre tàctiques de combat competitives, i quin paper juga un currículum progressiu —amb clonatge conductual intermig— en l'estabilització de l'aprenentatge?

Decisions de disseny

L'aprenentatge per reforç és l'únic paradigma que no parteix de regles ni de repeticions etiquetades: ha d'aprendre A i T interactuant. La Secció 2.4.5 ha situat MaskablePPO i l'emascarament (Equació 2.32) com a resposta a un espai d'accions variable —sense màscara, l'agent malgasta gradient en ordres que Showdown rebutja i la batalla es bloqueja.

L'aprenentatge frontal contra l'heurística més forta pateix recompensa escassa: gairebé totes les partides es perden abans d'aprendre legalitat. Per això no s'adopta autojoc ni un únic oponent difícil, sinó un **currículum progressiu** amb portes de validació congelades, independents de la corba d'entrenament (Taula 3.2 i Figura 3.10). Si una porta intermèdia no es supera, el currículum *continua* cap a **v12**: es vol mesurar la distància real, no aturar l'experiment per no haver «aprovat» una fase.

Taula 3.2: Disseny del currículum PPO. Els llindars són criteris previstos per avançar; el compliment es presenta al Capítol 5 i als resultats.

Fase	Oponent	Objectiu conceptual	Validació	Llindar
1	Random	Aprendre legalitat, finalització de batalles i avantatge sobre una política aleatòria.	1.000 partides	$\geq 90\%$
1.5	MaxBP	Superar una política ofensiva simple basada en potència.	1.000 partides	$> 70\%$
2	v8	Incorporar decisions posicionals amb clonatge inicial i reforç posterior.	1.000 partides	$> 55\%$
3	v12	Mesurar la distància respecte de l'heurística de referència més forta.	10.000 partides	50% com a paritat




Figura 3.10: Currículum PPO previst. Cada fletxa és una porta de validació independent de la corba d'entrenament. El clonatge s'insereix abans de la fase 2; la fase 3 mesura distància contra **v12** encara que una porta anterior falli.

Quatre mecanismes completen el disseny, cadascun per una fallada típica de l'RL en aquest domini:

- **Emmascarament:** el softmax emmascarat de la Secció 2.4.5. L'espai es congela en 14 slots (4 moviments, 4 amb Tera, 6 canvis), dels quals la màscara n'activa només els legals

—la mateixa A de la Taula 2.5, discretitzada. Es vol que l’agent no aprengui a «provar» ordres que el protocol rebutja.

- **Observació vectorial congelada:** l’estat es projecta a un vector en $[0, 1]$ (HP, tipus, estats, moviments, banc, camp, Tera i restriccions). Es congela abans de la fase competitiva per no invalidar els checkpoints: canviar Ω a mig currículum faria incomparables les fases.
- **Inicialització guiada:** abans de la fase 2, clonatge conductual sobre un professor de dificultat intermèdia (v8, no v12). Un expert massa fort fa més difícil tant el clonatge com el reforç posterior; v8 ja sap canviar sense ser encara el sostre heurístic.
- **Avaluació fora de la matriu:** l’agent s’avalua contra v12 en un experiment separat. Entrena contra oponents del currículum; incloure’l a la matriu de 28 agents distorsionaria les comparacions entre paradigmes no especialitzats contra un rival concret, i barrejaria un entrenament on-policy amb una avaluació off-policy.

La recompensa d’entrenament combina un premi de partida amb senyals densos (debilitaments, HP, modificadors, estats, perills i un cost per pas), d’acord amb el *reward shaping* esmentat a la Taula 2.5: sense senyal intermedi, el crèdit d’una victòria després de 40 torns és massa espars. L’avaluació final ignora aquesta funció i només compta victòries, per no confondre l’objectiu intern amb la mètrica de l’estudi.

3.5 Contracte de comparació i espais d’observació

La tupla POSG de la Taula 2.5, introduïda a la Secció 2.2.2, ja defineix format, accions i observació parcial. Això no n’hi ha prou per comparar: dos agents podrien rebre o_i equivalents i, tot i així, jugar amb espais interns incompatibles, un sol seient o telemetries diferents. El disseny afegeix tres regles perquè aquella tupla es tradueixi en comparacions justes:

- El mateix conjunt d’accions que accepta el simulador per a tots els agents. El que canvia és la *representació interna* (argmax, matriu, fills UCB, classificador o enter emmascarat), no l’espai legal. Es vol que una derrota no es pugui atribuir a «no poder canviar» si l’oponent sí que podia.
- Enfrontament en ambdues orientacions de seient. El protocol de Showdown distingeix p1 i p2; sense recíprocs, un biaix de posició es confondria amb habilitat.
- La mateixa telemetria per partida, independentment del paradigma, de manera que els 784 fitxers es puguin concatenar. Es vol un sol esquema d’anàlisi, no cinc.

La Taula 3.3 resumeix com cada família projecta l’observació i l’acció sobre aquest contracte comú: el Showdown és idèntic; canvia només com es representa o_i a dins.

3.6 Matriu experimental i nivells mostrals

Es vol un n prou gran perquè les diferències de taxa no siguin soroll de la tirada de dany ni de l’equip aleatori (Secció 2.1.9), i prou petit perquè l’MCTS càpiga en calendari. A la Secció 2.2.5 s’ha derivat que, tractant cada batalla com un assaig de Bernoulli, el marge d’error al 95% és de $\pm 0,98$ pp amb $n = 10.000$ i de $\pm 3,10$ pp amb $n = 1.000$. El disseny assigna aquests pisos al cost de cada paradigma —no un n únic «per simetria»—:

1. **Prova de fum ($n = 100$):** comprovació de funcionament i persistència ($\pm 9,80$ pp). No entra a les conclusions: només vàlida que el contracte de la Secció 3.2 no es bloqueja.

Taula 3.3: Com cada paradigma representa observació i acció. El contracte extern (Showdown) és el mateix; canvia la representació interna.

Paradigma	Observació interna	Acció interna
Heurístiques / minimax	Objectes Battle de <i>poke-env</i> : actiu, banc, camp i historial revelat.	Argmax sobre moviments, canvis i Tera com a modificador.
MCTS ras	El mateix, més un estat determinat per a LocalSim .	UCB/PUCT sobre els fills de l'arrel; s'envia l'acció més visitada.
Imitació	1.150 característiques tabulars per a atacar/canviar. v21 reutilitza l'objecte Battle de v14 ; v22 reconstrueix el vector per a cada candidat.	Macro binària + executor heurístic (v21) o model d'atributs i canvi contrafactual (v22).
PPO	Vector de 328 (o 346 a la prova interrompuda) floats en $[0, 1]$.	Enter $0 \dots 13$ emmascarat.

2. **Validació i cerca** ($n = 1.000$): cel · les on intervé MCTS, i portes intermèdies del currículum PPO ($\pm 3,10$ pp). L'MCTS no pot pagar 10.000 partides per cel · la sense trencar l'arquitectura de la Secció 3.3.

3. **Avaluació final** ($n = 10.000$): cel · les de la matriu principal i avaluació PPO contra **v12** ($\pm 0,98$ pp). És el pis amb què es discuteixen les hipòtesis d'ablació.

Taula 3.4: Precisió aproximada al 95% en el cas de màxima variància ($p = 0,5$). La segona columna és el marge d'una proporció; la tercera, el marge de la diferència entre dues proporcions independents amb el mateix n . Són càlculs de planificació, no una anàlisi de potència.

n	Marge d'una TV	Marge d'una diferència	Ús en aquest TFM
100	$\pm 9,80$ pp	$\pm 13,86$ pp	Prova de funcionament
1.000	$\pm 3,10$ pp	$\pm 4,38$ pp	Cel · les amb MCTS i validació PPO
5.000	$\pm 1,39$ pp	$\pm 1,96$ pp	No utilitzat
10.000	$\pm 0,98$ pp	$\pm 1,39$ pp	Cel · la final per defecte
20.000	$\pm 0,69$ pp	$\pm 0,98$ pp	No utilitzat

La matriu (Taula ??) és dirigida de $28 \times 28 = 784$ cel · les: 6 referències, 14 heurístiques, 3 Minimax, 3 MCTS i 2 d'imitació. Es fa dirigida — A vs B separat de B vs A — pel biaix de seient. L'execució equival a més de **6,4 milions de batalles** dirigides. El PPO queda fora d'aquesta matriu i s'avalua contra **v12**, pels motius de la Secció 3.4.6.

3.6.1 Orientacions recíproques, autojoc i rànkung Bradley–Terry

Per controlar un possible biaix de seient, es generen de manera independent A vs B i B vs A . La coherència es comprova amb taxes recíproques entorn del 100% i autojoc entorn del 50%: si l'autojoc s'allunya del 50%, el protocol o el seient estan trencats. Sobre la matriu s'ajusta el model Bradley–Terry de la Secció 2.2.5, ancorat a Random = 1000, per col · lapsar les 784 cel · les en un rànkung unidimensional: sense aquest col · lapse, comparar 28 agents exigiria llegir tota la matriu a ull.

3.7 Mètriques de rendiment i telemetria d'execució

La mera taxa de victòries permet establir una jerarquia de rendiment, però no aporta informació sobre els mecanismes subjacents que expliquen el comportament de cada agent. Per obrir aquesta

“caixa negra”, es dissenya una arquitectura de telemetria diagnòstica que enregistra, a nivell de partida i de torn, els esdeveniments de combat i les decisions internes de cada paradigma.

3.7.1 Mètrica primària: taxa de victòries i model Bradley–Terry

La mètrica primària d’avaluació és la taxa de victòries (WR) obtinguda en cada cel·la de la matriu d’avaluació, acompanyada del seu interval de confiança de Wilson al 95% (Equació 2.14). Atès que el valor d’una taxa de victòries depèn fortament de la dificultat del rival (p. ex., un 98% contra l’agent aleatori no permet diferenciar polítiques avançades, mentre que un 58% contra l’heurística terminal representa un domini rellevant), les taxes es sintetitzen mitjançant el model de preferències parelles de Bradley–Terry (Secció 2.2.5), col·lapsant la matriu en una escala de força unidimensional ancorada a $\text{Random} = 1000$.

3.7.2 Mètriques secundàries i capa d’intercepció de telemetria (StatsBattle)

Per capturar el detall d’allò que passa durant cada enfrontament sense alterar la lògica del simulador ni reduir el rendiment de l’execució en paral·lel, es dissenya un mòdul especialitzat d’intercepció de telemetria (**StatsBattle**) incorporat a cada treballador (*worker*). Aquest mòdul sobrescriu la classe base de combat de *poke-env* i llegeix directament el flux de línies del protocol WebSocket del servidor Pokémon Showdown (`parse_message` i `switch`).

Aquesta capa de telemetria permet caçar i estructurar automàticament en el fitxer de resultats CSV les següents categories de mètriques secundàries:

1. Dinàmica de combat i pressió ofensiva:

- *Torns totals* i durada de la partida.
- *Salut percentual restant* (HP_{us} vs HP_{opp}) i nombre de Pokémon debilitats, permetent distingir victòries per domini ofensiu de guerres de desgast extrem.

2. Mobilitat i caracterització de canvis:

- *Canvis voluntaris vs forçats*: El mòdul intercep els missatges de protocol per diferenciar quan un agent realitza un canvi estratègic voluntari de quan es veu obligat a canviar per debilitament del seu Pokémon o per efectes de moviments de *phazing* (com *Roar*, *Whirlwind* o *Dragon Tail*, detectats via la línia de protocol *drag*). Aquesta distinció és clau per separar el pivot tàctic del canvi de pànic.

3. Freqüències de moviments i esdeveniments de combat:

- *Comptador de moviments executats*: Es registra l’ús individual de cada moviment (`move_stats_us/opp`) per analitzar la diversitat de repertori i detectar moviments dominants.
- *Factors d’atzar (RNG)*: S’intercepten els esdeveniments de cops crítics (`-crit`), fallades de precisió (`-miss`) i cops molt efectius (`-supereffective`) per avaluar l’impacte de la variància a curt termini.

4. Activació de regles de domini i ablació heurística:

- Registre de l’activació de blocs d’ablació: col·locació i eliminació de perills d’entrada (*Stealth Rock*, *Spikes*), execució de moviments d’amplificació de noves estadístiques (*setup*), comprovació de KO garantits, ús de Teracristallització, protectors de bucles infinits (`loop_guards`) i resolució de finals (`endgame_solves`).

5. Diagnòstic intern de paradigmes avançats:

- *Imitació Jeràrquica (XGBoost)*: Registre de la probabilitat acumulada $p(\text{canvi})$ i de les decisions macro adoptades (`xgb_switches` vs `xgb_stays`).
- *Cerca (Minimax / MCTS)*: Enregistrament de les vegades que el mòdul de cerca modifica l'acció suggerida per l'heurística base (`search_switches`, `search_moves`) i la mètrica de discrepància.
- *Robustesa i errors*: Comptador de decisions per defecte (`fallback_moves`) o moviments no permesos (`error_moves`) per garantir que la política no cau en accions degenerades.

Aquest conjunt integrat de telemetria garanteix que cada cel·la de la matriu d'experiments no només produeixi un percentatge de victòries, sinó també una signatura conductual completa diagnòstica de l'agent.

3.8 Protocols d'avaluació especials i abast

A banda de la matriu d'avaluació creuada principal de 28×28 cel·les entre polítiques deterministes, heurístiques i de cerca, determinats paradigmes i entorns requereixen protocols d'experimentació dedicats. Aquesta secció estableix les condicions d'avaluació específiques per a la integració exploratòria d'agents basats en models de llenguatge (LLM), la validació del model de reforç profund (MaskablePPO) sobre el seu currículum i el desplegament de prova en la classificació pública oficial.

3.8.1 Integració exploratòria d'agents LLM

Els agents basats en models de llenguatge (LLM), com **PokéChamp** i **PokéLLMon** (revisats a la Secció 2.3), es van considerar inicialment per tancar el mapa de l'estat de l'art com a part del benchmark. Aquests agents operen serialitzant l'estat estructurat de la batalla en un prompt de text natural (que inclou l'equip actiu, la banqueta, els moviments i habilitats ja revelats i la taula d'efectivitats de tipus) i generen la decisió mitjançant raonament de cadena de pensament (*Chain-of-Thought*, CoT).

Per dur a terme aquestes proves sense dependre d'APIs externes de pagament i per mantenir el control del flux de dades, es va implementar una infraestructura d'inferència local basada en el servidor **Ollama** [51], executant models oberts com ara *Qwen 3.5 8B* o *Llama 3*. La descàrrega i l'acceleració de la inferència es van articular mitjançant la plataforma computacional **NVIDIA CUDA** [52] sobre targetes gràfiques (GPU) dedicades.

No obstant això, les proves de rendiment i latència van revelar importants limitacions pràctiques per a la seva inclusió a la matriu massiva:

1. **Latència d'inferència i timeouts**: Tot i comptar amb acceleració CUDA per GPU, el processament de prompts de context extens i la generació autoregressiva de l'explicació raonada requereixen des de diversos segons fins a més d'un minut per torn. En entorns de temps real a Pokémon Showdown, això produeix desconnexions i pèrdues de torn per *timeout* de la presa de decisions.
2. **Contenció de recursos en execució paral·lela**: L'arquitectura de treballadors paral·lels (Secció 3.3) executa múltiples instàncies concurrents de combat. La consulta simultània de diversos treballadors al servidor Ollama genera colls d'ampolla de memòria VRAM a la GPU i commutacions de context a CUDA, saturant el motor d'inferència.
3. **Infeasibilitat computacional del volum**: Executar cel·les de $n = 10.000$ partides per a un agent LLM requeriria mesos de temps continu de GPU, trencant l'homogeneïtat temporal i el contracte de volum del benchmark.

Per aquests motius, els agents LLM es classifiquen formalment com una **prova exploratòria de capacitat i viabilitat tècnica**, quedant exclosos de la matriu de 28×28 per garantir la comparabilitat computacional rigorosa i el compliment dels terminis de l'estudi.

3.8.2 Protocol d'avaluació PPO contra referència

MaskablePPO s'avalua en un experiment separat contra **v12**, amb $n = 10.000$ partides i el model congelat en finalitzar el currículum. Es fa així —i no com a fila de la matriu— perquè l'agent ha entrenat específicament contra oponents d'aquest currículum; mesurar-lo contra 27 polítiques no especialitzades barrejaria generalització amb overfitting al rival de la fase 3. Aquest protocol és el que tanca la fase 3 de la Taula 3.2.

3.8.3 Avaluació en la classificació pública

La matriu és un entorn tancat: equips aleatoris, bots, sense humans. Es vol una prova de validesa externa sobre el mateix protocol de Showdown, però contra jugadors reals. Per això **v14** —l'heurística terminal, orientada a rivals humans— es juga a la classificació pública oficial. Aquesta mostra no substitueix la matriu: la complementa, amb n menor i oponents no controlats.

3.9 Amenaces a la validesa i reproductibilitat

El disseny anterior introdueix compromisos que cal declarar, no amagar:

- **Comparabilitat computacional:** cada paradigma opera sota un pressupost diferent. L'MCTS utilitza $n = 1.000$ per cel · la. Les comparacions mesuren sistemes complets sota aquestes restriccions, no un empat a temps de CPU —empatar-los hauria fet inviable la matriu.
- **Selecció de variants:** avaluar només la millor versió d'una família afavoriria el màxim mostral; es documenta tota l'ablació.
- **Multiplicitat:** davant de 784 cel · les, l'anàlisi es basa en la consistència dels intervals de Wilson i la magnitud de l'efecte, no en p-valors aïllats.
- **Desajust de simuladors (MCTS):** el rollout local no és el motor autoritatiu. El disseny el tracta com a font d'error coneguda, conseqüència de respectar el POSG.
- **Reproductibilitat:** es fixen la versió de Showdown, els repositoris de Random Battle i els artefactes de pesos, perquè el contracte de la Secció 3.2 no depengui d'un servidor públic canviant.

3.10 Síntesi i continuïtat

El capítol ha fixat *què* es mesura i *per què* es mesura així: un sol àrbitre Showdown i una sola traducció *poke-env*, perquè les polítiques siguin comparables; una arquitectura paral · lela de treballadors efimers, perquè el volum estadístic càpiga en memòria i en calendari; cinc famílies amb ablació interna, perquè es pugui atribuir el rendiment a un mecanisme i no a un identificador; una matriu 28×28 amb n adaptat al cost, perquè l'interval de Wilson sigui interpretable. El Capítol 4 descriu el maquinari que fa viable aquesta execució. El Capítol 5 mostra com aquest disseny es converteix en mòduls, scripts d'entrenament i un connector amb la classificació pública. El Capítol 6 n'analitza els resultats.

Capítol 4

Entorn de desenvolupament i infraestructura de còmput

La matriu de 784 cel·les i l'entrenament PPO requereixen una màquina estable, accés remot i supervisió d'execucions llargues. Aquest capítol documenta el maquinari, la xarxa, les notificacions i les dependències. El coordinador dels experiments es descriu al Capítol 5.

4.1 Organització del projecte

El desenvolupament s'ha organitzat amb un tauler Kanban dividit en objectius, tasques pendents, treball en curs i tasques completades. Cada targeta representa una unitat verificable, com una versió heurística, un agent de cerca, un entrenament o una secció de la memòria.

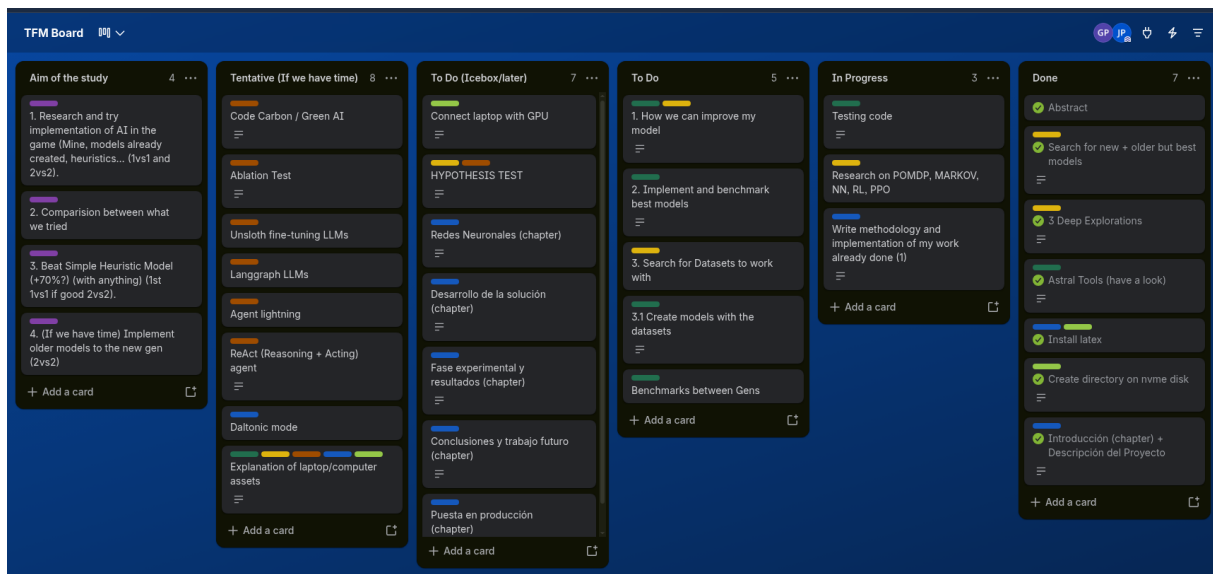


Figura 4.1: Tauler Kanban utilitzat per organitzar el desenvolupament del TFM.

4.2 Evolució de l'arquitectura

4.2.1 Fase 1: prototipatge en portàtil

El prototip va córrer en un Intel Core Ultra 7 155H (22 fils) amb 16 GB de RAM. Un disc NVMe d'1 TB dedicat a `data/` es va muntar amb `bind mount`. Amb 16 GB, múltiples Showdown + Python obligaven a `gc.collect()`, chunks petits i reinicis de Node.js: aquestes rutines neixen d'aquesta fase.

4.2.2 Fase 2: estació de treball

Els experiments finals s'executen en una torre amb AMD Ryzen 7 5700X3D (8 nuclis i 16 fils, 96 MB de memòria cau L3), 32 GB DDR4 i una GPU NVIDIA RTX 2080 de 8 GB. La matriu d'heurístiques, minimax, MCTS i imitació utilitza principalment la CPU. La GPU s'empra per a MaskablePPO i les proves amb models de llenguatge. El sistema i les dades de treball resideixen en una unitat NVMe.

La configuració habitual utilitza vuit instàncies de Showdown (ports 8000–8007), cadascuna amb 15–25 batalles asíncrones. Les cel·les heurístiques es completen molt més ràpidament que les d'MCTS; aquesta diferència de cost motiva els volums de 10.000 i 1.000 partides. L'avaluació PPO contra v12 també utilitza vuit ports.

4.3 Accés remot: Tailscale

El portàtil i la torre formen una xarxa privada amb **Tailscale** [53] (WireGuard). SSH va per aquesta malla, sense obrir el port 22 al WAN. L'editor (Cursor / VS Code) treballa amb Remote-SSH sobre el disc del servidor: el codi, els CSV i els checkpoints PPO viuen a la torre.

Les execucions llargues i els entrenaments PPO s'executen dins de **tmux**; així, una desconnexió del portàtil no interromp el coordinador ni el procés CUDA.

4.4 Bot de Telegram

Els scripts de llançament de `src/p00_core/scripts/runs_benchmark/` i el monitor `src/p00_core/scripts/seguretat_tfm.sh` envien notificacions mitjançant un bot de Telegram [54]. El token s'emmagatzema a `.env` i no es versiona.

Funcions que s'han usat de debò:

- **Avisos de progrés:** inici i final d'un enfrontament, reintents, temps d'espera i partides completades.
- **Supervisió de recursos:** temperatura de CPU i NVMe, ús de memòria i aturada d'emergència a 92°C.
- **Comandes interactives** mitjançant `seguretat_tfm.sh`: consulta de l'estat, resum de la sessió, registres i pausa o represa de l'execució.

Aquesta infraestructura permet supervisar les execucions sense exposar serveis directament a Internet: Tailscale proporciona l'accés remot i Telegram informa del progrés.

4.5 Dependències

El gestor de paquets és **uv** [55] amb Python **3.12** i `pyproject.toml`. Node.js [56] construeix Pokémon Showdown. Resum:

- **Nucli de combat:** `poke-env` ≥ 0.11 , < 0.12 [5]; Node.js [56] per a Showdown.
- **Dades / estadística:** `numpy` [57], `pandas` [58], `polars` [59], `scipy` [60].
- **ML tabular:** `scikit-learn` [61], `XGBoost` [38], Hugging Face Datasets [62].
- **Visualització i notebooks:** `matplotlib` [63], `seaborn` [64], `ipykernel`, `nbconvert`.
- **Utilitats:** `tqdm`, `tabulate`, `orjson`, `requests`, `websockets`.

- **Aprenentatge per reforç (extra rl / gpu):** Gymnasium [65], Stable-Baselines3 [66], sb3-contrib (MaskablePPO) [67], PyTorch [68] i TensorBoard [69].
- **LLM / Pokechamp (extra pokechamp):** Ollama [51], transformers, openai / anthropic / google-genai (backends opcionals), rich.
- **Qualitat:** Ruff [70] (format + lint), ty (tipus).
- **Sistema:** Git/GitHub, tmux, Tailscale [53], Telegram Bot API [54], L^AT_EX (report/).

El fork `pokechamp/` s'incorpora al `sys.path` dels processos que necessiten `LocalSim` o `Abyssal`. Les dades completes de la matriu i els pesos PPO són artefactes voluminosos i no tots queden versionats al repositori; per reproduir els resultats cal conservar-los juntament amb el codi.

4.6 Anàlisi de cost econòmic i pressupost de recursos

El desenvolupament d'aquest Treball de Final de Màster s'ha caracteritzat per una gestió altament eficient dels recursos computacionals, d'infraestructura i de programari. Atès l'elevat volum de batalles de la matriu d'avaluació (més de 6,4 milions) i la durada dels entrenaments, la principal despesa operativa directa s'associa al consum energètic derivat de l'execució ininterrompuda. Aquesta secció desglossa l'anàlisi econòmica i les mesures d'eficiència aplicades.

4.6.1 Desglossament de recursos i optimització de costos

Els costos del projecte es resumeixen en quatre eixos principals:

1. **Maquinari i equips de còmput (0,00 €):** Tant el portàtil de desenvolupament inicial com l'estació de treball principal (AMD Ryzen 7 5700X3D, 32 GB RAM, NVIDIA RTX 2080 8 GB) són equips de propietat personal del desenvolupador utilitzats prèviament per a altres activitats. No s'ha realitzat cap adquisició de maquinari dedicada exclusivament al TFM.
2. **Consum energètic de 24/7 (Y €):** A causa de l'alta complexitat computacional de la matriu d'enfrontaments i la necessitat d'aprofitar al màxim el temps disponible, l'estació de treball va funcionar de manera continuada les **24 hores del dia durant diverses setmanes sense aturar-se**, acumulant un total aproximat de X hores de còmput. La gestió d'aquesta despesa energètica es va estructurar de la següent manera:
 - **Autoconsum solar diürn:** Durant les hores de sol, la instal·lació de **plaques solars domèstiques** va reduir dràsticament el cost energètic cobrint directament la demanda de la torre mitjançant energia renovable gratuïta.
 - **Consum nocturn de xarxa:** Durant les hores nocturnes i períodes sense insolació, el còmput continuat va requerir subministrament directe de la xarxa elèctrica convencional, generant un cost estimat en Y €.
 - **Mode terminal headless:** Per tal de minimitzar el consum de potència (Watts/hora) durant el funcionament 24/7, l'estació de treball es va executar en mode purament terminal (sense entorn gràfic GUI) supervisada mitjançant `tmux`, mantenint actius únicament els processos strictly necessaris.
3. **Models de llenguatge i eines de desenvolupament (0,00 €):** Les proves exploratòries amb models de llenguatge (*PokéChamp* i *PokéLLMon*) es van executar de manera 100% local mitjançant el motor **Ollama**, sense consumir cap API comercial de pagament. Així mateix, l'ús d'eines de desenvolupament basades en IA (Antigravity, Cursor, PyCharm i VS Code) es va realitzar mitjançant llicències d'estudiant/pro, permetent accedir a models LLM d'altres capacitats sense cap despesa econòmica.

4. **Infraestructura de programari i comunicacions (0,00 €):** Totes les eines de la cadena de valor (Pokémon Showdown, *poke-env*, entorn de desenvolupament Python, Tailscale per a la xarxa privada virtual, Telegram Bot API per a la telemetria en temps real, i L^AT_EX per a la redacció) són de codi obert (*open-source*) o s’han utilitzat en les seves modalitats gratuïtes.

Taula 4.1: Resum del pressupost econòmic i costos directes del TFM.

Concepte	Estratègia d’optimització / Font	Cost Directe (€)
Maquinari i equips	Ús d’equips personals preexistents (sense adquisicions noves)	0,00
Consum energètic	Execució 24/7 (setmanes continus, plaques solars de dia / xarxa de nit)	Y
Inferència d’LLMs	Execució local amb Ollama i llicències d’estudiant (Cursor/PyCharm)	0,00
Eines i Infraestructura	Programari de codi obert (<i>open-source</i>) i serveis gratuïts	0,00
Cost Total Directe		Y

Aquesta combinació d’autoconsum solar diürn, optimització de còmput en mode terminal, execució local d’LLMs i llicències d’estudiant ha permès contenir el cost energètic de les setmanes d’execució ininterrompuda 24/7 i completar el projecte de manera altament eficient i sostenible.

Capítol 5

Implementació dels cinc paradigmes

Aquest capítol descriu la **implementació** del disseny experimental del Capítol 3. Com s’ha fixat allà, l’estudi compara cinc paradigmes sota un contracte d’observació i acció comú (Secció 3.2), amb un gestor d’enfrontaments coordinador/treballadors (Secció 3.3) i les famílies d’agents de la Secció 3.4. Aquí es mostra com s’han construït aquestes peces: el motor de batalles, les classes de cada família i el flux d’entrenament de MaskablePPO. L’organització del repositori segueix el mateix mapa —un nucli compartit i un mòdul per paradigma— perquè una política nova no hagi de conèixer ports, CSV ni recuperació d’errors.

5.1 Mapa del programari

El nucli `p00_core` materialitza el gestor conceptual de la Secció 3.1 i l’arquitectura coordinador/treballadors de la Secció 3.3. Els directoris `p01–p05` afegeixen només la política de cada família (Figura 5.1), d’acord amb el desacoblament entre coordinació i lògica interna:

- `src/p00_core/engine/`: `benchmark.py` (coordinador) i `worker.py` (procés de treball).
- `src/p00_core/core/`: `BaseHeuristicv1`, `AgentFactory` i l’estimador de dany compartit.
- `src/p01_heuristics/agents/internal/`: `v1.py ... v14.py`.
- `src/p03_minmax/`: `v15–v17`.
- `src/p04_mcts/`: `v18–v20` i `LocalSim` via el fork `Pokechamp`.
- `src/p02_imitation_learning/`: `dataset` → característiques → `XGBoost` → `v21/v22`.
- `src/p05_ppo_drl/`: entorn `Gymnasium`, vectorització, clonatge i `MaskablePPO`.
- `src/p00_core/online_bot/`: connector amb la classificació pública.

`p01` és el nucli de coneixement explícit i el que reutilitzen les famílies posteriors, d’acord amb el paper de `v14` com a servei (Secció 3.4). `p02` és un flux de dades complet. `p03` i `p04` encapsulen les dues cerques. `p05` es manté separat perquè l’entrenament PPO té entorn `Gymnasium`, checkpoints i un protocol d’avaluació propi, fora de la matriu de 28 agents.

5.2 Motor de batalla i capa d’integració

El contracte de la Secció 3.2 —l’agent només veu l’observació estructurada i retorna una acció legal— es concreta en versions i arrencada.




Figura 5.1: Mapa de mòduls. p00 concentra simulació i persistència; p01–p05 afegeixen la política. Minimax, MCTS i imitació reutilitzen p01; PPO té entorn, checkpoints i avaluació propis.

5.2.1 Servidor local de Pokémon Showdown

Cada instància s’inicia com un procés Node.js independent en un port dedicat:

```
node pokemon-showdown start --port 8000 --no-security
```

L’opció `-no-security` elimina l’autenticació en el servidor local. El llançador de la matriu obre vuit instàncies consecutives (ports 8000–8007), una per treballador del model de la Figura 3.5.

5.2.2 Versions i forks de *poke-env*

El projecte fixa *poke-env* a la sèrie 0.11.x: tota la matriu es va executar amb aquesta API. El fork *pokechamp/* s’afegeix només als processos que necessiten Abyssal, agents de llenguatge o *LocalSim*. L’estat real de la partida continua vivint al servidor Showdown; *LocalSim* només s’utilitza dins de les simulacions de l’MCTS, tal com preveu el disseny de determinització de la Secció 3.4.

5.3 Arquitectura coordinador–processos de treball

Les sis responsabilitats del gestor (Secció 3.1) i el model coordinador/treballadors (Secció 3.3) es materialitzen en dos estadis: un prototip d’un sol procés i el motor de la matriu.

5.3.1 Del BattleManager inicial al motor de la matriu

La primera materialització és `core/battle_manager.py`. *BattleManager* rep una versió, un oponent, un servidor, el nombre de partides i la concurrència. Crea els dos jugadors, executa lots amb `battle_against`, extreu victòria, torns, equips, HP i comptadors, i afegeix les files a un CSV. Aquest component va validar el cicle de la Figura 3.4 amb un únic procés i continua sent útil per a execucions petites.

L’escala de 784 cel·les en va mostrar tres límits: un sol intèrpret acumulava memòria, el nom de sortida estava lligat a una execució concreta i la coordinació no construïa ni reprenia tota la matriu. `benchmark.py` i `worker.py` conserven les mateixes responsabilitats, però les separen: el primer calcula treball pendent i administra recursos; el segon executa un lot aïllat i desapareix.

5.3.2 Per què subprocessos

Les execucions llargues en un únic procés Python acumulaven objectes *Battle*, estructures de cerca i recursos asíncrons. S’utilitza `multiprocessing` amb el context `spawn`, de manera que no s’hereten bucles d’esdeveniments ni connexions obertes. Cada procés inicia un intèrpret nou, utilitza un port exclusiu de Showdown i escriu un CSV temporal. Quan finalitza, el sistema operatiu recupera els recursos, tal com exigeix l’aïllament de la Secció 3.3.

5.3.3 Coordinador, cua de ports i processos efímers

`benchmark.py` resol les etiquetes d'agent i oponent, construeix el producte d'enfrontaments i consulta quantes files ja existeixen a cada CSV. Després inicia les instàncies de Showdown i crea una cua asíncrona amb els ports lliures. Cada lot consumeix un port, executa `worker.py` com un procés nou i retorna el port a la cua quan acaba.

`worker.py` instancia els dos agents via `AgentFactory`, juga les batalles asíncrones i converteix cada `Battle` acabada en una fila de telemetria. El procés escriu primer en un fitxer temporal exclusiu del port. El coordinador només fusiona lots acabats; així dos processos no escriuen simultàniament sobre el mateix CSV final.

La matriu final utilitza vuit ports. La concurrència és de 25 batalles per procés per als agents ràpids i de 15 quan intervé minimax o MCTS. Això produeix aproximadament entre 120 i 200 batalles simultànies, amb espais de memòria Python i instàncies Node.js separats.

5.3.4 Represa i escriptura per blocs

La font d'estat de progrés del disseny és el CSV. Si `v12_vs_abyssal.csv` ja té 4.320 files, el coordinador calcula $n_{\text{to_run}} = 10.000 - 4.320$ i només executa les partides pendents. Cada procés treballa en blocs de 25 batalles, escriu els resultats i executa `reset_battles()` i `gc.collect()` abans de continuar.

El temps d'espera d'un lot és $\max(7200, 40 \cdot n_{\text{batch}})$ segons, prou ampli per no interrompre una cerca activa i finit per detectar un procés bloquejat. Les notes de desenvolupament situen les heurístiques al voltant de 0,01–0,1 s per partida i l'MCTS al voltant de 2–6 s, d'acord amb el pressupost asimètric de la Secció 3.6.

5.3.5 Reinici de Showdown

En execucions llargues es va observar creixement de memòria al procés V8 de Node.js. El coordinador reinicia les instàncies cada N enfrontaments actius, configurable amb `-restart-every`. El motor té un valor per defecte de 3; el llançador de la matriu final utilitza **20**.




Figura 5.2: Monitoratge durant una execució al prototip de 16 GB. La memòria creix mentre s'acumulen batalles i cau després de reiniciar processos; el patró va motivar els blocs curts, la recollida de memòria i els reinicis de Showdown.

5.3.6 Esquema CSV i telemetria emmagatzemada

La telemetria de la Secció 3.7 es materialitza en **73 columnes** estandarditzades. `worker.py` genera aquesta estructura per a **tots** els agents: si un camp no aplica, s’inicialitza a 0. Així `pandas` i `polars` poden concatenar els 784 CSV sense discrepància d’esquema.

1. **Identificadors:** `battle_id`, `format`, `heuristic` (agent *us*), `opponent` (*opp*), `won` i `turns`.
2. **Estat final:** HP residual (`total_hp_us/opp`), debilitats i membres restants.
3. **Accions:** canvis voluntaris i forçats, `Teracristal·lització`, excepcions i reserves (`error_moves`, `fallback_moves`).
4. **Estocasticitat:** crítics, fallades, super-efectius i condicions d’estat. `StatsBattle` intercepta missatges bruts del protocol (`|-crit|`) abans que la capa d’alt nivell els descarti.
5. **Tempo:** `hazard_sets`, `hazard_removals`, `setup_uses`, `ko_checks`, `ko_guards`.
6. **Paradigma:** `search_diff`, `search_switches`, `endgame_solves`, `xgb_switches`, `xgb_stays`, `xgb_prob_sum`.

La `Teracristal·lització` s’extreu amb una cadena de `getattr` compatible amb els forks (`terastallized` o `_terastallized`), per no fallar si un agent utilitza un atribut intern diferent.

5.3.7 Automatització de la matriu

`run_paradigm_comparison_10k.sh` defineix les etiquetes de files i columnes —les 28 de la Taula ??— i invoca el coordinador per a cada parella. El mateix script adapta el pressupost de la Secció 3.6: 10.000 partides i concurrència 25 per a les famílies ràpides; concurrència 15 per a minimax; i 1.000 partides amb concurrència 15 quan intervé MCTS. Aplica fins a 100 reintents davant d’un lot fallit, reinicia Showdown cada 20 enfrontaments actius i envia avisos de progrés.

5.3.8 Contracte `BaseHeuristic1v1` i `AgentFactory`

La instanciació homogènia del gestor s’aplica amb el patró *Template Method*: `choose_move` crida `_pre_move_hook` per a sortides prioritàries, `_select_action` per a la lògica principal i, si cal, `choose_random_move` com a reserva. Una excepció incrementa `error_moves` i produeix una acció legal aleatòria, de manera que no bloqueja la batalla.

`AgentFactory.create("v20")` és l’únic punt d’instanciació. La fàbrica resol àlies històrics: `ml_advanced`, `v21` i `v21_xgboost` apunten al mateix agent; `one_step` i `safe_one_step` instancien la mateixa classe. Els agents de referència són adaptadors de `random`, `max_power`, `simple_heuristic`, `safe_one_step` i `abyssal`.

5.4 Heurístiques v1–v14: incorporació de coneixement

La genealogia d’ablació, les ramificacions i el paper de `v14` com a servei són els de la Secció 3.4 (Figura 3.6, Taula 3.1). Aquí es recull com es tradueixen en classes i operacions compartides.

5.4.1 Estructura de classes i operacions compartides

`BaseHeuristic1v1` proporciona el cicle de vida, els comptadors i el recorregut de reserva. `common.py` concentra `calculate_base_damage`, `get_speed` i la càrrega singleton de dades de Showdown, de manera que `v2`, `v3`, `v4` i `v6` comparteixen la mateixa matemàtica de dany.

La genealogia de disseny no coincideix amb una cadena d’herència única. `v3` hereta de `v2` i `v6` de `v3`; `v1`, `v4`, `v5` i totes les versions a partir de `v7` hereten directament de `BaseHeuristic1v1`.

Cada fitxer `vN.py` especialitza `_select_action` i, a partir de `v7`, afegeix ajudants propis (`_estimate_matchup`, `_get_best_switch`, `_should_terastallize`).

El flux, comú a les versions avançades, és:

1. detectar un canvi forçat o una batalla incompleta;
2. executar dreceres prioritàries (debilitament segur, i més endavant final i reaccions tàctiques);
3. construir els candidats de moviment i canvi;
4. assignar una puntuació ofensiva, defensiva i estratègica;
5. decidir si la Teracristal·lització modifica el millor moviment;
6. validar l'ordre i, només si la política no en retorna cap, utilitzar una acció legal de reserva.

Taula 5.1: Correspondència entre els blocs de disseny de la Taula 3.1 i els components implementats.

Versions	Component principal implementat
<code>v1</code>	<code>_score</code> : potència $\times$ efectivitat $\times$ STAB; sense canvis.
<code>v2–v3</code>	<code>calculate_base_damage</code> ; pivots TOX i «feble i outsped»; <code>v3</code> activa <code>tracks_moves</code> .
<code>v4–v6</code>	Modificadors de clima/terreny i prioritat; <code>v4/v5</code> trien el substitut per tipus; <code>v6</code> conserva el slot 0.
<code>v7–v8</code>	Nova <code>_estimate_matchup</code> ; <code>v8</code> afegeix KO de prioritat conservador i <code>ABILITY_IMMUNITIES</code> .
<code>v9–v11</code>	Hazards/setup només en torn lliure; estats, sacrifici $\leq 20\%$ HP i pivots; <code>v11</code> els fusiona.
<code>v12</code>	Tera ofensiva/defensiva i substitut forçat per puntuació d'enfrontament.
<code>v13</code>	Matchup amb moviments revelats, recuperació, Choice lock i Tera conservadora.
<code>v14</code>	Perfil PREDICTIVE/CONSERVATIVE, sondeig T1–3, interval de dany (0,85, 1) i solver d'un torn.

5.4.2 Decisions que no es desprenen de la genealogia

Tres decisions canvien el comportament d'una manera que la taula de disseny no detalla.

`v7` no amplia `v6`: és una classe nova. El canvi voluntari deixa de ser «si el dany és < 20 i som més lents, slot 0» i passa a comparar la puntuació d'enfrontament de l'actiu amb la del millor company, amb llinard -2 . Aquesta funció és la que reutilitzen minimax, MCTS i `v21`.

`v12` afegeix dues mecàniques alhora (Tera i substitut forçat per matchup). L'experiment no les abla per separat; el Capítol 6 ho tracta com una limitació d'interpretació.

`v14` manté estat persistent per batalla (historial d'actius, taxa de canvis, rols Win-Con / Vital Wall). L'interval de dany $(0,85 \times \text{score}, \text{score})$ existeix perquè l'HP rival a *poke-env* és sovint un percentatge, no un enter. El solver de finals només s'activa amb ≤ 2 Pokémon per bàndol i no substitueix la política completa. Aquestes peces estan orientades a rivals humans; contra polítiques deterministes poden cedir ritme.

Totes les versions registren comptadors. A `v14`, `ko_checks` arriba a l'ordre de 15 per partida perquè l'interval de dany s'avalua sovint.

5.5 Minimax d'un torn `v15–v17`

Les tres variants hereten `HeuristicV14`, d'acord amb el paper de `v14` com a fulla. El disseny —maximin pur, tres fulles, dreceres abans de la matriu— és el de la Secció 3.4. Aquí es detalla com es construeix M .

Abans de buscar, s'executen les dreceres de `v14` (debilitament garantit; a `v16/v17` també preparació rival, absorció d'estats i pivots inicials). Si cap drecera aplica, s'enumeren les accions pròpies legals contra els moviments rivals *revelats* i, si el rival té banqueta, un símbol genèric "switch". La velocitat i la prioritat es resolen analíticament; `LocalSim` no intervé.

5.5.1 Construcció de la matriu

Una fila per acció pròpia, una columna per resposta considerada. Per a cada parella s'estima qui actua primer, si l'acció ràpida debilita i anul·la la segona, els HP esperats després de l'intercanvi i les bonificacions de posició de la fulla corresponent. El valor d'una acció pròpia és el mínim de la seva fila; l'agent escull la fila amb el màxim d'aquests mínims, és a dir, el criteri de l'Equació 2.25.

Aquest càlcul és barat perquè no crea una batalla simulada per cas. També és deliberadament limitat: no veu què succeeix dos torns després d'un canvi o d'un moviment de preparació. No hi ha resolució en estratègies mixtes ni cap crida a un solucionador de programació lineal, d'acord amb l'elecció de maximin pur del disseny.

La fulla de `v15` combina HP i qualitat de l'enfrontament, amb penalització $\times 1,5$ al dany rival. `v16` afegeix bonificacions de 0,25–0,35 per preparació, perills, recuperació i estats. `v17` hereta aquesta fulla i suma 0,15 al pitjor cas de l'acció que retornaria `v14._select_action`, restaurant després l'historial intern perquè la consulta del prior no contaminin els comptadors.

Per saber què aporta el mòdul, abans de la cerca es demana també l'acció de `v14._search_diff` augmenta quan el maximin la substitueix; `search_moves` i `search_switches` descriuen el tipus d'acció resultant. La taxa d'intervenció mesurada es reporta al Capítol 6.

5.6 MCTS ras `v18`–`v20`

El pressupost és el del disseny: 100 simulacions, $C = 1,4$, rollout de 5 torns, decisió per visites, i el mateix professor `v14`. La materialització afegeix el simulador local que el minimax no necessita.

Cada procés MCTS injecta el fork `pokechamp/` al `sys.path` i desallotja els mòduls `poke_env` de PyPI, perquè `LocalSim` visqui a l'API del fork. Per a cada decisió, l'agent copia l'estat observable, crea un fill per moviment i per canvi legal, i inicialitza visites i valor. Cada iteració selecciona un fill amb UCB1 o PUCT, aplica l'acció i continua amb una política de simulació durant cinc torns. Una funció de fulla resumeix HP, debilitats, modificadors, estats i camp; aquest valor s'acumula al fill de l'arrel.

No es conserva un arbre profund entre iteracions ni entre torns reals. El cost i la interpretació són els d'un bandit a l'arrel amb simulacions, coherent amb l'MCTS ras de la Secció 2.4.3.

`v18` utilitza UCB1, una fulla d'HP/estats/perills i només la drecera de debilitament. `v19` enriqueix la fulla amb rols (Win-Con $\times 1,45$, Vital Wall $\times 1,25$) i amenaça de KO, i aplica les dreceres de `v14` abans de l'arbre. `v20` substitueix UCB1 per PUCT amb prior 0,70 sobre l'acció `v14`; la fulla roman la de `v19`.

La determinització només copia moviments rivals revelats. `LocalSim` i el procés Node.js de Showdown no són el mateix motor: un objecte o un efecte no reproduït exactament introdueix soroll als valors. El minimax d'un torn no té aquesta font d'error, perquè només utilitza l'estimador analític compartit. Aquesta és l'amenaça de validesa ja identificada a la Secció 3.9.

5.7 Imitació `v21`–`v22`

L'arquitectura macro/micro, el llinar d'experts $Elo \geq 1800$ i el contrast híbrid versus pur són els de la Secció 3.4. La implementació es divideix en quatre directoris reproduïbles:

1. `s01_download/` descarrega repeticions i conserva metadades de format i Elo;
2. `s02_eda/` valida distribucions, proporció atacar/canviar i composició del metajoc;
3. `s03_training/` transforma els torns en una matriu tabular, separa per batalla i entrena XGBoost;
4. `s04_agent/` carrega els models i converteix la predicció en una acció legal.

Una repetició no conté l'objecte `Battle` que l'agent veu en línia (Figura 3.3). L'extractor reconstrueix, torn a torn, HP, camp, Tera, identitat dels actius i acció observada. La llista de característiques desada amb el model garanteix que l'agent en producció generi les columnes en el mateix ordre que durant l'entrenament.

5.7.1 Dades i entrenament

El conjunt avançat té de l'ordre d'**1,1 milions** de torns. L'entrenament macro —script `train_ml_advanced.py`— fa un `GroupShuffleSplit` per `battle_id` per no filtrar informació intra-partida, aplica `scale_pos_weight` al desequilibri atacar/canviar i calibra el llindar de decisió sobre la corba precisió-record del conjunt de test. El model resultant té aproximadament **1.150** columnes després del one-hot d'espècies. El fitxer `xgboost_advanced_threshold.json` desa el llindar (de l'ordre de 0,55–0,58); l'agent el carrega en temps d'inferència.




Figura 5.3: Validació exploratòria de les repeticions humanes: desequilibri entre atacar i canviar, evolució de la taxa de canvi amb el torn i espècies més representades. La figura descriu el conjunt de dades, no el rendiment final de l'agent.

La classe «canviar» representa aproximadament el 25,8% dels torns. La taxa és especialment alta al començament —on també hi ha canvis forçats o ajustos de posició— i disminueix amb la durada.




Figura 5.4: Taxa de canvi humana per espècie activa en una selecció del conjunt d'experts. La variació justifica incloure identitat i context, però no implica causalitat.

5.7.2 Adaptadors en línia

v21 (HeuristicV21XGBoost) hereta `HeuristicV14`. L'ordre d'execució és el del disseny híbrid: KO garantit, solver de finals, reacció a sweepers i absorció d'estats *abans* del classificador. El vector en viu replica les 1.150 columnes, amb normalització alfanumèrica dels noms d'espècie per no perdre formes regionals. Un guard de bucle força «atacar» si el model ha demanat canviar dos tornos seguits. Si la macro-decisió és canviar i existeix un pivot legal i segur, s'executa *U-turn/Volt Switch* en lloc d'un canvi sec; si no, `_get_best_switch` de v14. L'atac el puntua el mateix `_score_move` heurístic.

v22 (HeuristicV22PureIL) hereta només `BaseHeuristicv1`. Reutilitza el classificador macro i afegeix `xgboost_move_evaluator.json`, entrenat amb candidats sintetitzats (potència, STAB, efectivitat, prioritat, HP, torn), no amb identitats de moviment de les repeticions. El substitut es tria per contrafactual: per a cada candidat de banqueta es regenera el vector com si fos l'actiu i es queda el de menor $p(\text{canvi})$. No hi ha dreceres de v14.

5.8 Baselines i agents de llenguatge

Els sis controls de la Secció 3.4 s'instancien així. `random` i `max_power` provenen de *poke-env*; `simple_heuristic` és una còpia local adaptada a la Teracristal·lització, i `abyssal` prové de PokéChamp. `one_step` i `safe_one_step` instancien `SafeOneStepPlayer`: un lookahead d'un pas que puntua $\text{base_power} \times \text{STAB} \times \text{efectivitat} \times \text{precisió}$ i no crida `LocalSim`. L'adaptador existeix perquè l'`OneStepPlayer` original del fork es bloquejava sense les dades JSON esperades.

`src/p01_heuristics/agents/llm/` adapta PokéChamp i PokéLLMon a la mateixa fàbrica. El fork prepara el context textual i consulta un backend local d'Ollama [51] (prova amb un model de la família Qwen [71]). El temps observat, de l'ordre de 40 minuts per partida, confirma el criteri d'exclusió de la Secció 3.8. La integració es conserva perquè va validar la compatibilitat i va permetre reutilitzar `Abyssal` i `LocalSim`.

5.9 PPO: MaskablePPO sobre Showdown

`src/p05_ppo_dr1/` materialitza el cinquè paradigma i l'experiment separat contra v12 (Secció 3.4.6). Els resultats numèrics es llegeixen al Capítol 6; aquí es documenta l'entorn, el clonatge i com s'han executat les fases.

5.9.1 Organització del mòdul i dels artefactes

- `s01_env/`: vectorització, correspondència índex–ordre, màscara i recompensa;
- `s02_training/`: bucle comú, scripts de cada fase, clonatge, callbacks, checkpoints i gràfiques;
- `s03_evaluation/`: càrrega d'un model congelat i avaluació contra un oponent fix.

Els pesos viuen a `data/models/ppo/`, un directori per fase (`p1_random`, `p15_maxbp`, `p2_v8`, `p3_v12`). `plots/` conserva hiperparàmetres i corbes; `eval/`, els JSON de les avaluacions. Aquesta separació evita confondre una corba d'entrenament amb el resultat d'un checkpoint congelat.

5.9.2 Entorn

`PokemonMaskedEnv` encapsula `SinglesEnv` de *poke-env* sota el mateix contracte de la Secció 3.2. L'observació és el vector de 328 dimensions de la Taula 5.2, la representació congelada del disseny.

Taula 5.2: Composició del vector d’observació de MaskablePPO. El model A publicat té 328 dimensions; les fases 1 i 1.5 n’utilitzaven 318 (sense dany estimat ni enfrontaments de canvi). Les 18 dimensions addicionals de la fase 4 no entren al resultat principal.

Bloc	Dim.	Contingut
Actiu propi / rival	35 + 35	HP, tipus, condició d’estat i set etapes de modificadors.
Moviments	84 + 4 + 4	Tipus i potència dels 4 slots, PP i STAB×efectivitat.
Banc propi i rival	6 × 6 + 1	HP, debilitats, indicador de capdavanter i estimació de supervivents rivals.
Camp	9 + 14 + 24 + 24	Clima, terreny i condicions laterals d’ambdós bàndols.
Teracristal · lització	3 + 20 + 20	Disponibilitat, ús previ i tipus Tera.
Velocitat i restriccions	5	Comparació de velocitat, force_switch i trapped .
Afegits de fase 2	4 + 6	Dany estimat dels 4 moviments i enfrontament dels 6 canvis.
Total model A	328	Vector en $[0, 1]$, compatible amb els checkpoints de les fases 2 i 3.
Extensió de fase 4	+18	Enfrontaments del banc revelat, millor capdavanter, dany/defensa Tera i cost de perills.

Les fases 1 i 1.5 n’utilitzaven 318; una extensió posterior n’afegeix 18 (fase 4), però correspon a un experiment interromput i no al resultat principal.

L’acció és **Discrete(14)**, amb la legalitat de la Taula 5.3. A cada pas es calcula una màscara que exclou moviments sense PP, una Tera ja consumida i canvis a posicions no disponibles —l’emascarament de l’Equació 2.32. **PPOPlayer** tradueix l’índex a **/choose**, també durant un canvi forçat.

Taula 5.3: Espai d’accions **Discrete(14)** de MaskablePPO. La màscara de legalitat i la traducció a **/choose** comparteixen el mateix mapeig de slots [1].

Índex	Acció	Quan és legal
0–3	Moviment i de l’actiu	El slot té un moviment amb PP i no hi ha canvi forçat.
4–7	Moviment i + Teracristal · litzar	El moviment i és legal i la Tera encara no s’ha consumit.
8–13	Canvi a l’slot i de l’equip	El membre existeix, no està debilitat, no és l’actiu i no hi ha bloqueig de canvi.




Figura 5.5: Pas d’inferència de MaskablePPO. La màscara s’aplica abans de mostrejar; l’índex s’envia com a ordre de Showdown, no com a enter cru.

5.9.3 Clonatge, arquitectura i recompensa

El warm-start de la fase 2 es materialitza a **bc.py**: tuples (o, m, a) d’observació, màscara i acció a partir del professor **v8**. L’ajust aplica entropia creuada emmascarada només a l’actor, amb Adam a 10^{-3} durant 15 èpoques; no reutilitza la taxa de PPO. Es recullen 400 partides de **v8** (8.849 decisions). L’acord amb el professor passa del 43% al 88%, i la freqüència de canvi predita s’apropa a la del professor (21% davant del 23%). El clonatge no és el resultat final: situa la xarxa en una regió que ja produeix accions semblants a una política competent.




Figura 5.6: Seqüència clonatge → reforç. El crític no s’entrena al clonatge; PPO n’aprèn el valor a partir de la recompensa modelada un cop l’actor ja imita el professor.

MaskablePPO [39, 67, 72] s’executa sobre PyTorch [68]. Política i valor utilitzen dues capes de 256 unitats. Els scripts registren `n_steps=2048`, $\gamma = 0,99$ i quatre èpoques d’actualització; el lot és de 256 amb quatre entorns i de 512 amb vuit o més. El model A publicat utilitza observació de 328 dimensions, vuit entorns i taxa 5×10^{-5} .

La recompensa d’entrenament combina 30 punts per victòria, 2 per diferència de debilitats, 1 per diferència d’HP, increments per modificadors ofensius, estats i perills al camp rival, penalització pels perills propis, i un cost de 0,02 per pas. El codi desa el valor potencial anterior i només afegeix la diferència de la part tàctica, per no premiar indefinidament el mateix estat. L’avaluació final ignora aquesta funció i només compta victòries, com estableix el disseny.

5.9.4 Execució de les fases 1, 1.5, 2 i 3

La Taula 5.4 registra com s’ha operacionalitzat cada porta de la Taula 3.2. Les taxes de les corbes d’entrenament no substitueixen la columna de validació; la interpretació és al Capítol 6.

Taula 5.4: Implementació i validació del currículum PPO. «Superada» es refereix al llindar previst, no al fet que s’executés una fase posterior.


Fase	Oponent	Canvi implementat	Validació congelada	Decisió
1	Random	PPO inicial, 318 dimensions, 4 entorns, 500k passos.	91,8% a 1.000; llindar 90%.	Superada
1.5	MaxBP	Reprèn fase 1; taxa 2×10^{-4} , 500k passos.	70,5% a 1.000; llindar $> 70\%$.	Superada per estimació puntual
2	v8	Amplia a 328 dimensions, 400 partides de clonatge, 8 entorns.	40,6% a 1.000; llindar $> 55\%$.	No superada
3	v12	Continua des de fase 2 i prova taxes/entorns diferents.	Model A: 34,1% a 10.000.	Mesura final

La fase 1 verifica legalitat i domini sobre Random. La fase 1.5 reprèn sense aturada prematura després d’una primera avaluació al 64,1%; el checkpoint posterior supera el llindar per estimació puntual ($n = 1.000$, interval ample). La fase 2 amplia l’observació de 318 a 328 dimensions. Les primeres passades només amb PPO es van mantenir al voltant del 29–30%; un primer clonatge reutilitzava l’optimitzador de PPO a 5×10^{-5} i gairebé no ajustava l’actor. La versió final separa els optimitzadors, clona 400 partides i continua 100.000 passos de PPO. La validació queda en 40,6%, per sota del 55%. D’acord amb el disseny —continuar cap a v12 encara que una porta falli— el currículum no s’atura.


La fase 3 prova dues configuracions. El resultat de tesi és el model A, `p3_v12_lr5e5_flat.zip`, amb taxa 5×10^{-5} i vuit entorns. Una passada secundària amb taxa $1,5 \times 10^{-4}$ i setze entorns produeix la corba guardada al directori de fase 3, però no és el punt de control de les 10.000 partides.

`eval_checkpoint.py` carrega un checkpoint sense actualitzar-lo, l’associa a un `PPOPlayer` i juga en una o dues orientacions. El model A es prova contra v12 en 10.000 partides —el protocol de la Secció 3.8— i contra Random en 1.000 com a control. El codi impedeix sobreescrivre accidentalment el fitxer principal.


Una extensió posterior amplia l’observació a 346 dimensions i clona v14 contra v12. S’interromp al voltant de 340.000 passos i es presenta només com a diagnòstic. No substitueix el




(a) Fase 1 contra Random.



(b) Fase 1.5 contra MaxBP.



(c) Fase 2 contra v8.



(d) Passada secundària de fase 3 contra v12.

Figura 5.7: Corbes de les quatre etapes del currículum. Són taxes durant l'entrenament sobre una política canviant; les validacions independents són les de la Taula 5.4. El panell de fase 3 correspon a la passada secundària, no al model A publicat.

model A.

5.10 Desplegament a la classificació pública

El protocol de validesa externa de la Secció 3.8 es materialitza a `src/p00_core/online_bot/run_online_bot.py`. El bot connecta qualsevol etiqueta d'AgentFactory al servidor públic, en mode de classificació (`ladder`) o d'acceptació de reptes (`accept`). La mostra analitzada correspon a `v14`, usuari `SirPThesis`, els dies 9 i 10 de juny de 2026, amb 431 partides. Aquesta avaluació no és una fila de la matriu local.

5.10.1 Arquitectura del client i autenticació

El client és asíncron (`websockets + asyncio`) i segueix el protocol oficial:

1. Connexió al WebSocket públic (`sim3.psim.us / showdown`).
2. Recepció del desafiament del servidor (`challstr`).
3. Autenticació HTTP POST a `play.pokemonshowdown.com/action.php`.
4. Enviament de l'assertió (`/trn <username>,0,<assertion>`) per registrar `SirPThesis`.

5.10.2 Tolerància a fallades

- **Reconnexió:** reintent amb espera exponencial davant de pèrdua de socket.
- **Timer:** si l'agent no respon en menys de 10 segons, s'envia una acció legal de reserva per evitar la derrota per temps.
- **Limitació de freqüència:** esperes entre comandes per no activar el *spam throttle* del servidor.

5.11 Síntesi i continuïtat

El Capítol 3 ha tancat el disseny; aquest capítol n’ha recollit la construcció. El nucli `p00_core` implementa el gestor i el contracte `Showdown/poke-env`; `p01–p04` i `p02` materialitzen les famílies de la matriu 28×28 ; `p05` executa el currículum `MaskablePPO` fora d’aquesta matriu; i `online_bot` connecta `v14` a la classificació pública. El Capítol 6 llegeix els CSV, les validacions congelades de PPO i la mostra del *ladder* sota aquestes mateixes etiquetes.

Capítol 6

Resultats

Aquest capítol analitza la matriu de 28 agents i l'experiment PPO. Les fonts internes són els 784 CSV de `data/benchmarks/all_10k/gen9randombattle`, els informes de `src/p00_core/reporting/agents/`, `heuristics_and_imitation_thesis_analysis.md` i `src/p05_ppo_drl/RESULTS.md`.

La lectura separa tres nivells. Un **resultat observat** és una taxa o un comptador derivat dels fitxers. Una **interpretació** relaciona diversos indicadors amb el disseny de l'agent. Una **hipòtesi explicativa** proposa què podria haver causat el patró, però requeriria una ablació o una repetició específica per confirmar-se. Aquesta distinció permet explicar els resultats sense convertir una correlació de telemetria en una conclusió causal.

6.1 Protocol de lectura dels resultats

6.1.1 La matriu

28 agents, cadascun com a *nosaltres* contra 28 oponents, format `gen9randombattle`. Fitxers dirigits `A_vs_B.csv`. El PPO es llegeix a part, contra `v12`, a la secció 6.11.

Taula 6.1: Taxonomia dels 28 agents de la matriu `gen9randombattle`. Els identificadors de codi es mantenen en anglès. El prefix del mapa de calor indica la família: (H) heurística, (MM) minimax, (MCT) MCTS, (IL) imitació i (B) agent de referència. El PPO s'avalua separatament contra `v12`.

Identificadors	Paradigma	Descripció
<code>random</code> , <code>max_power</code> , <code>one_step</code> , <code>safe_one_step</code> , <code>abyssal</code> , <code>simple_heuristic</code> <code>v1-v14</code>	Referències (B)	Agents de <i>poke-env</i> i PokéChamp: atzar, potència base, un pas de dany i regles d'enfrontament.
<code>v15-v17</code>	Heurístiques (H)	Seqüència incremental de coneixement: dany, posició, perills d'entrada i Teracristal·lització, entre altres components.
<code>v18-v20</code>	Minimax d'un torn (MM)	Maximin analític d'un torn amb <code>HeuristicV14</code> com a base.
<code>v21</code>	MCTS ras (MCT)	UCB a l'arrel i 100 simulacions de cinc torns amb <code>LocalSim</code> ; cel·les amb $n = 1.000$.
<code>v22</code>	Imitació híbrida (IL)	XGBoost decideix atacar o canviar i <code>v14</code> executa l'acció.
	Imitació (IL)	El mateix classificador d'alt nivell; el model de moviments puntua potència, STAB i efectivitat.

La fila d'una taula o d'un mapa de calor és l'agent analitzat i la columna és l'oponent. Un 59,91 a la cel·la `v12 × Abyssal` indica que `v12` ha guanyat 5.991 de les 10.000 partides d'aquell

fitxer dirigit.

6.1.2 Precisió de les estimacions

Cada partida aporta un resultat binari $W \in \{0, 1\}$. L'equació (??) dona el marge màxim aproximat per a una proporció:

$$\pm 1,96\sqrt{0,25/n}.$$

A $n = 10.000$ és $\pm 0,98$ pp i a $n = 1.000$, $\pm 3,1$ pp. Per a la diferència entre dues proporcions independents properes al 50%, els marges aproximats són 1,39 i 4,38 pp, respectivament. Els intervals reportats són de Wilson; aquestes aproximacions serveixen per entendre l'ordre de magnitud.

La mida de la Pokédex no apareix directament a $\text{Var}(\hat{p}) = p(1-p)/n$. L'objectiu és estimar una taxa marginal sota el generador d'equips de la Generació IX, no cobrir totes les combinacions possibles.

La Taula 3.4 (metodologia) recull els tres pisos. Aquí només cal recordar-los abans de llegir MCTS.

6.1.3 Volum i ponderació

- Una fila no MCTS conté **253.000** partides: 25×10.000 i 3×1.000 contra MCTS.
- Una fila MCTS conté **28.000** partides: 28×1.000 .
- La matriu completa conté **6.409.000** partides dirigides.
- Les orientacions recíproques sumen aproximadament el 100% i l'autojoc se situa prop del 50%, com s'espera en absència d'un efecte sistemàtic de l'orientació.

La taxa global d'una fila no MCTS pondera els oponents MCTS deu vegades menys que la resta; en una fila MCTS tots els oponents pesen igual. Per tant, aquestes taxes globals tenen diferent precisió i diferent ponderació. La comparació entre paradigmes es basa en cel · les comunes, no en una única ordenació global.

Les proves de desenvolupament amb 100 partides no formen part de les conclusions d'aquest capítol.

6.2 Controls globals de la matriu

Abans d'interpretar versions concretes, es comproven la cobertura, la distribució de taxes i la durada de les batalles. Aquests controls detecten cel · les incompletes, errors d'orientació i resultats extrems que podrien dominar una mitjana.

La Figura 6.1 confirma que la reducció de mostra segueix el paradigma i no l'agent que ocupa la primera orientació. Aquesta regularitat és important perquè evita comparar una cel · la MCTS parcial amb una cel · la no MCTS completa.

La distribució no és una campana estreta al voltant del 50%. Hi ha massa a prop dels extrems perquè alguns agents de referència són molt febles i perquè cada cel · la té una orientació recíproca. Aquesta és una altra raó per no interpretar la taxa global com una habilitat absoluta: millorar contra un agent que ja es derrota en el 95–98% de les partides té poc valor discriminant.

La durada complementa la taxa de victòries. Dues polítiques poden guanyar una proporció semblant, però una pot tancar abans mentre l'altra conserva més membres mitjançant canvis i recuperació. La cua dreia també fa que la mitjana sigui sensible a bucles o estratègies d'atrició; per això les seccions següents combinen torns, membres restants i motiu dels canvis.




Figura 6.1: Nombre de partides completades a les 784 cel · les. El bloc fosc correspon a 10.000 partides; les files i columnes clares de v18–v20, a 1.000. La creu no és un buit de dades, sinó el pressupost reduït de l'MCTS.




Figura 6.2: Distribució de la taxa de victòries de les 784 cel · les dirigides. El centre prop del 50% conté autojoc i enfrontaments equilibrats; les cues reflecteixen diferències grans, especialment davant de Random i MaxBasePower.




Figura 6.3: Distribució de la durada de les batalles analitzades. La mediana és de 17 torns i hi ha una cua dreta de partides excepcionalment llargues.

6.3 Fil conductor de v1 a v22

La Taula 6.2 resumeix la seqüència abans d’analitzar-la. Les taxes globals són descriptives i no fan comparable l’MCTS amb la resta a causa de la ponderació diferent; la seva funció aquí és mostrar els canvis de règim.

Taula 6.2: Evolució de les preguntes i dels resultats entre v1 i v22.

Versions	Pregunta que materialitzen	TV global	Patró observat
v1–v6	Fins on arriba refinar dany i ordre immediat?	44–46%	Altiplà; telemetria gairebé invariable.
v7, v8, v10	Què aporta valorar la posició i canviar?	54–56%	Salt a v7; afegits posteriors petits.
v9, v11	Preparació i perills només en torns segurs?	59%	Nou augment i aparició dels comptadors de ritme.
v12	Què aporten Tera i el substitut informat?	69,01%	Increment més gran i 59,91% contra Abyssal.
v13, v14	Més inferència i model del rival sempre ajuden?	67,63 / 62,03%	Inversió: més complexitat, menys taxa global.
v15–v17	Un maximin d’un torn corregeix v14?	53,80–57,89%	La variant guiada discrepa menys i és la millor.
v18–v20	Cinc torns simulats superen l’horitzó curt?	53,29–59,66%	PUCT millora UCB1, però no supera v12.
v21, v22	Es pot imitar quan atacar o canviar?	58,71 / 33,49%	L’executor heurístic és determinant.

La primera meitat de la seqüència acumula coneixement explícit fins a v12. La segona canvia de paradigma, però la majoria de decisions encara passen per dreceres o priors derivats de v14. El patró general no és «algorisme més sofisticat, agent més fort», sinó «representació i coneixement adequats, seguits d’un mòdul que no els destrueixi».

PPO no rep un número v23 ni forma part de la taula global. La seva pregunta és paral·lela: si una política neuronal inicialitzada amb v8 pot arribar a v12. El resultat de 34,1% contra aquest comparador es tracta a la secció 6.11.

6.4 L'escala heurística: tres canvis de règim

Taula 6.3: Seqüència heurística v1–v14 (253.000 partides per fila). La taxa global no creix de manera monotònica: els increments principals apareixen a v7, v9 i v12, i les dues versions posteriors disminueixen.

Agent	Règim	TV (%)	contra Abyssal	Incorporació principal
v1–v6	Altiplà	44,25–45,86	30,6–32,5	Dany, clima, modificadors i canvis simples
v7	Posicional	54,25	40,80	Dany modificat i canvi segons l'enfrontament
v8	Posicional	55,43	42,30	KO de prioritat conservador i immunitats conegudes
v9	Ritme segur	58,86	46,64	Perills i preparació <i>només en torns lliures</i>
v10	Posicional	55,66	41,86	Status, sacrifici $\leq 20\%$ HP, U-turn
v11	Ritme segur	59,26	47,50	Combinació de v9 i v10
v12	Mecànica Gen. IX	69,01	59,91	Tera i selecció del substitut
v13	Moviments revelats	67,63	55,34	Enfrontament amb moviments revelats i Tera conservador
v14	Model de rival	62,03	51,36	Perfil, sondeig inicial, rang de dany i final d'un torn




Figura 6.4: Taxa global de victòries de v1–v14 (253.000 partides per fila; les tres cel·les contra MCTS tenen $n = 1.000$). S'observen canvis destacats a v7, v9 i v12, seguits d'una disminució a v13 i v14.

6.4.1 Altiplà v1–v6: rendiments decreixents del càlcul de dany

La taxa global recorre **1,61 pp** (44,25–45,86%). Els enfrontaments interns se situen prop del 50%, mentre que contra Abyssal obtenen entre el 30,6% i el 32,5%.

En aquestes versions, afinar la fórmula de dany després d'incorporar efectivitat i STAB mostra rendiments decreixents. Els increments posteriors apareixen quan s'afegeixen decisions posicionals i recursos específics del format.

En el subconjunt de cinc oponents utilitzat per a aquesta telemetria (abyssal, v12, v14, v21 i random), registren aproximadament 1,04 canvis voluntaris per partida, cap Teracristal·lització i uns 4,3 recursos de reserva. Aquest perfil correspon a una política principalment ofensiva amb poca gestió posicional.

6.4.2 Primer salt: v7 (i v8/v10)

v7 incorpora dany amb modificadors i canvis segons l'enfrontament. La taxa global passa d'aproximadament 45,5% a **54,25%**; contra Abyssal, d'aproximadament 32% a **40,8%**.

v8 (KO de prioritat conservador i immunitats d'habilitat ja revelades) afegeix 1,2 pp. v10 (estats, sacrificis i moviments de pivot) obté una taxa similar a v8 (55,66% i 55,43%).

La telemetria també canvia: els canvis voluntaris pugen a 1,47 per partida, `matchup_switches` arriba a 0,41 i les accions de reserva baixen d'aproximadament 4,6 a 2,18. L'agent passa a seleccionar canvis de manera explícita.

Els perills d'entrada i els moviments de preparació s'incorporen a v9; els comptadors `setup_uses` i `hazard_sets` deixen de ser zero.

6.4.3 Segon salt: v9 / v11

Amb v9, els perills d'entrada i els moviments de preparació només s'utilitzen quan l'agent és més ràpid i resisteix l'STAB rival. La taxa global puja a **58,86%** i el resultat contra Abyssal a **46,64%**. v11 combina aquest bloc amb v10 i afegeix 0,4 pp; la contribució addicional és petita en aquesta matriu.

v9/v11 són els primers amb aproximadament 1,6 moviments de preparació i 0,16 perills d'entrada per partida.

6.4.4 Tercer salt: v12

v12 combina Teracristal · lització i selecció del substitut després d'un debilitament. La taxa global és **69,01%**. És el primer agent intern que supera Abyssal i Simple Heuristic: **59,91%** i **59,75%**, respectivament ($n = 10.000$).

En el subconjunt amb telemetria, utilitza la Teracristal · lització **0,96 vegades per partida**, registra només **0,01** accions de reserva i conserva **1,84** Pokémon, davant d'1,44 a v11. El canvi de comportament és substancial.

En `gen9randombattle`, el bloc format per la Teracristal · lització i la selecció del substitut s'associa amb l'increment més gran de la seqüència. Com que totes dues modificacions s'introdueixen alhora, l'experiment no en separa l'efecte individual.




Figura 6.5: v1–v14 contra els sis agents de referència ($n = 10.000$ per cel · la). v12 és el primer que deixa Abyssal i Simple Heuristic clarament per sota del 50%. Contra `random`, totes les heurístiques arriben al 97–98% i la columna deixa de ser discriminant.

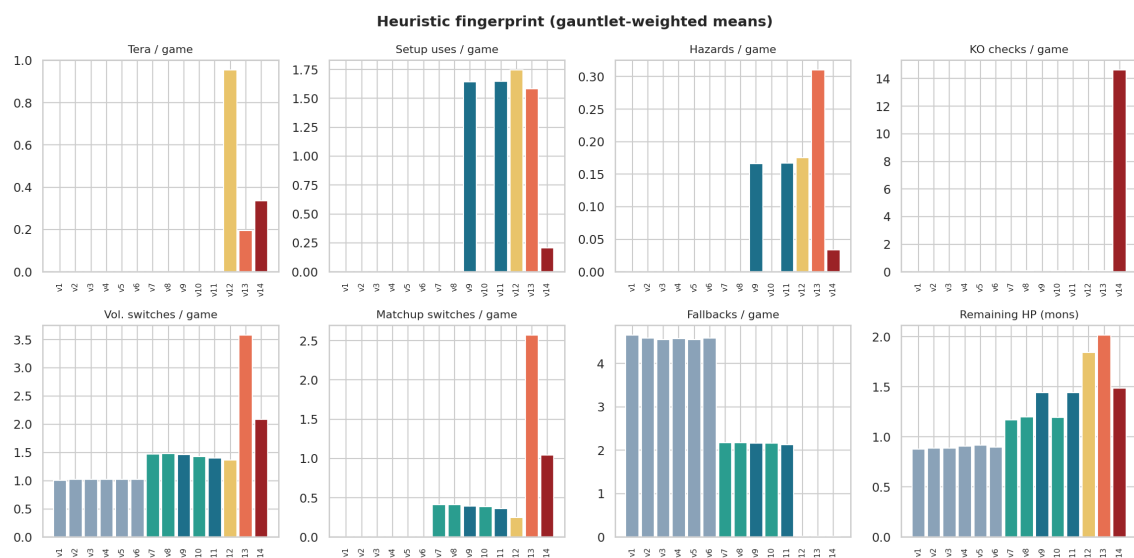


Figura 6.6: empremta tàctica de la seqüència heurística. **v12** utilitza la Teracristal · lització gairebé una vegada per partida; **v13**, 0,20 vegades. **ko_checks** augmenta fins a aproximadament 15 a **v14**; la preparació i els perills d'entrada apareixen a partir de **v9**.

6.5 La inversió entre **v12**, **v13** i **v14**

La complexitat creix de **v12** a **v14**, però la taxa global observada disminueix. Aquest resultat mostra que l'herència de funcionalitats no implica una millora monotònica.

Taula 6.4: Enfrontaments directes, amb $n = 10.000$ partides independents per orientació. **v12** i **v13** no presenten una separació concloent; **v14** queda per sota de tots dos. Les sumes recíproques properes al 100% són un control de coherència, no una prova amb partides aparellades.

Fitxer	TV (%)	Recíproc (%)	Suma
v12_vs_v13	50,65	48,85	99,50
v12_vs_v14	56,01	44,74	100,75
v13_vs_v14	57,71	41,60	99,31




Figura 6.7: Enfrontaments directes, amb $n = 10.000$ per orientació. v12 i v13 no presenten una separació concloent; v14 obté 44,74% contra v12 i 41,60% contra v13.

Les dues orientacions de v12 i v13 difereixen en 1,8 pp i no aporten una separació concloent. En canvi, v14 queda per sota de tots dos en els enfrontaments directes.

6.5.1 On v13 encara guanya

No està estrictament dominat. És el **millor heurístic contra cerca i contra l'IL híbrid**:

Oponent	v12	v13	v14
Minimax v15	63,96	67,59	60,07
Minimax v17	60,37	64,12	56,70
MCTS v18 ($n = 1k$)	66,1	67,7	59,8
IL v21	59,12	62,46	54,74
Baselines (bloc)	76,91	74,36	71,06
Altres heurístiques (bloc)	67,01	64,71	58,58

v13 acaba amb més Pokémon disponibles (avg_hp_us: 2,01, davant d'1,84 i 1,49) i juga partides més llargues (19,1 torns, davant de 17,9 i 18,5). El perfil és més conservador i orientat a l'atrició.

6.5.2 Per què no supera v12 en global

En el subconjunt amb telemetria, v13 utilitza la Teracristal · lització 0,20 vegades per partida, davant de 0,96 a v12; també fa més canvis voluntaris (3,58 davant d'1,37) i més canvis per enfrontament (2,57 davant de 0,25). Aquest comportament preserva més membres de l'equip, però pot cedir torns contra oponents deterministes. Les dades són compatibles amb aquesta explicació, però no aïllen causalment cadascun dels mecanismes.

6.5.3 Especialització de v14 i pèrdua de rendiment local

v14 incorpora modelatge de patrons humans, sondeig inicial, Teracristal · lització defensiva, un interval aproximat de dany i resolució d'un torn al final de la partida. Contra agents deterministes, aquests mecanismes poden consumir torns sense obtenir informació útil:

- El sondeig inicial substitueix algunes accions ofensives.

- El perfil de l'oponent aporta poc quan la política rival és fixa.
- `ko_checks` arriba a aproximadament 15 per partida, mentre que `setup_uses` baixa a 0,22.
- Contra Abyssal obté **51,36%**; v12 obté **59,91%**.




Figura 6.8: Enfrontaments de referència de v12, v13 i v14. Les files representen l'agent avaluat. Les cel·les MCTS tenen $n = 1.000$ i la resta, $n = 10.000$. v12 domina els agents de referència; v13 és més fort contra cerca i v21.




Figura 6.9: Taxa de victòries de la inversió, agregada per paradigma d'oponent. v12 és millor contra agents de referència i altres heurístiques; v13, contra minimax, MCTS i imitació híbrida.




Figura 6.10: Relació entre volum de canvis i taxa de victòries. La freqüència de canvi, per si sola, no mesura la qualitat de la política; cal distingir-ne el motiu.




Figura 6.11: Durada i membres de l'equip disponibles al final. v13 juga partides més llargues i conserva més Pokémon, mentre que v12 obté una taxa de victòries superior.

En aquest banc de proves, afegir modelatge d'oponents humans redueix el rendiment agent-contra-agent. Això indica una possible especialització de domini i justifica mantenir separades la matriu local i l'avaluació pública.

La mostra pública de v14 (secció 6.10) no permet reordenar v12 i v14; de la mateixa manera, la matriu local no permet afirmar quin dels dos obtindria més victòries contra persones.

6.6 Minimax d'un torn

La pregunta és si valorar explícitament la resposta més desfavorable del torn millora v14. La telemetria registra amb quina freqüència s'executa el mòdul i quan la seva acció difereix de la proposta heurística.

Taula 6.5: Minimax analític d'un torn (253.000 partides per fila). La cerca s'executa en aproximadament el 16–18% dels torns. La fulla posicional de **v16** gairebé no modifica la preparació; el prior de **v17** redueix la discrepància respecte de **v14** i obté la taxa més alta de la família.

	v15 HP	v16 bonuses	v17 prior +0,15
TV global (%)	53,80	54,30	57,89
IC 95% (pp)	$\pm 0,19$	$\pm 0,19$	$\pm 0,19$
Cerca (% torns)	17,6	17,6	16,3
Discrepància amb v14 (%)	66,5	67,3	36,6
Preparació / partida	0,21	0,21	0,21
Perills / partida	0,05	0,04	0,04
Tera / partida	0,40	0,39	0,38
Pokémon restants	1,28	1,29	1,39

6.6.1 Frequència d'intervenció

Es registren aproximadament 14 comprovacions de debilitament i 4,5 decisions maximin per partida. La matriu de cerca s'utilitza en el **16–18% dels torns**; la resta es resol principalment amb les regles prioritàries heretades.

Un agent **v14** que prioritza debilitaments garantits i aplica una anàlisi maximin d'un torn a les decisions restants.

Aquest patró és comparable al de **v21**, que consulta XGBoost en aproximadament el 15% dels torns, i al de les variants MCTS.




Figura 6.12: Taxa de discrepància respecte de **v14** en els torns en què s'executa el maximin. **v15/v16** discrepen aproximadament en el 67% dels casos; **v17**, amb prior +0,15, en el 37%. Les derrotes presenten una discrepància mitjana superior, una associació que no implica causalitat.

6.6.2 **v16** i l'avaluació de la fulla

v16 incorpora bonificacions per moviments de preparació i perills d'entrada. La taxa global només augmenta 0,50 pp i els enfrontaments directes queden prop del 50%. Les freqüències de preparació (0,213 i 0,207 per partida) i de perills d'entrada (0,044 i 0,049) pràcticament no canvien. Amb aquesta funció de fulla, el terme de dany rival continua dominant les bonificacions de llarg termini.

La discrepància es manté al voltant del 67%. Per tant, enriquir la fulla en aquesta magnitud no modifica substancialment la política.

Aquest resultat és coherent amb una limitació d'horitzó: afegir una bonificació estàtica no equival a simular les conseqüències futures d'un moviment de preparació.




Figura 6.13: Indicadors d'efectes diferits: preparació, perills d'entrada i Teracristal · lització. v16 manté la preparació al voltant de 0,21 usos per partida, un nivell semblant al de v14 i molt inferior al de v12.

6.6.3 v17: prior heurístic

v17 afegeix 0,15 al valor de l'acció proposada per v14. La discrepància baixa del 67% al 37% i la taxa global augmenta 4,1 pp respecte de v15. En els enfrontaments directes obté 54,7% i 54,3% contra v15 i v16. El resultat mostra que conservar un prior heurístic és més efectiu, en aquesta implementació, que substituir-lo per la matriu d'un torn.

Contra els comparadors principals, amb $n = 10.000$ tret de les cel · les MCTS:

Oponent	v15	v16	v17
v12	36,04	35,92	40,94
v13	32,82	33,50	35,10
v14 (professor)	39,43	39,56	43,61
Abyssal	41,72	41,86	46,79
v20 ($n = 1k$)	39,7	44,6	50,4
v21	43,65	44,75	47,50
v22	69,67	70,22	71,27

v17 obté **43,6%** contra v14, **40,9%** contra v12 i 46,8% contra Abyssal. Contra v20 obté 50,4% amb $n = 1.000$, un resultat compatible amb rendiments similars en aquell enfrontament.

Cap variant de minimax supera v14 o v12. La variant amb millor resultat és precisament la que limita la desviació respecte de l'heurística de partida.

6.6.4 Canvis, durada i supervivència

La millora de v17 no prové d'allargar sistemàticament les batalles: la durada mitjana pràcticament no canvia. Sí que augmenta la massa de resultats amb dos o tres membres restants. Aquesta observació és coherent amb menys decisions maximin agressives que exposen l'actiu, tot i que la figura no identifica per si sola quina acció evita cada debilitament.

La combinació «més canvis decidits per cerca» i «menys discrepància» no és contradictòria. Indica que, quan v14 ja proposa un canvi, el prior de v17 concentra el maximin en la mateixa direcció. El guany no sembla provenir del nombre brut de canvis, sinó de conservar el canvi heurístic en els estats on la matriu no disposa d'un horitzó suficient.




Figura 6.14: Distribució de la durada i dels Pokémon restants a minimax. Les tres variants duren aproximadament 19 torns, però v17 conserva 1,39 membres de mitjana, davant d'1,28–1,29.




Figura 6.15: Distribució dels canvis voluntaris, dels canvis decidits pel maximin i de la fracció de decisions de cerca que són canvis. v17 presenta una mediana superior de canvis tot i discrepar menys de v14.




Figura 6.16: empremta v15–v17: KO checks ~14, cerca ~16–18% dels torns, Tera ~0,39 (nivell v14, no v12).




Figura 6.17: Enfrontaments de referència del minimax d'un torn. Les cel·les contra MCTS tenen $n = 1.000$. v17 millora respecte de les altres variants, però no supera el 50% contra v14.




Figura 6.18: Taxa de victòries agrupada. v15 i v16 se superposen; v17 queda per sobre, encara per sota de v9/v11.




Figura 6.19: Taxa de victòries del minimax per família d'oponent. El prior de v17 s'associa amb les millores principals contra heurístiques i MCTS.

6.7 MCTS ras: UCB a l'arrel i simulacions de cinc torns

Totes les cel·les d'aquesta secció tenen $n = 1.000$. El marge màxim aproximat per a una proporció és $\pm 3,1$ pp. La mitjana global de les files MCTS també té una ponderació diferent de la de les files no MCTS.

La pregunta és si les simulacions de cinc torns milloren les regles de v14 que s'executen abans de la cerca o s'utilitzen com a prior.

Taula 6.6: MCTS ras amb UCB a l'arrel i 100 simulacions de cinc torns. Totes les cel·les tenen $n = 1.000$ (28.000 partides per agent). La fulla més rica de v19 no aporta una millora observable; PUCT amb prior sobre v14 redueix la discrepància i obté la taxa més alta de la família.

	v18 UCB1 HP	v19 UCB1 pos.	v20 PUCT 0,70
TV global (%)	54,02	53,29	59,66
Cerca (% torns)	18,1	17,6	15,5
Discrepància amb v14 (%)	71,3	71,1	18,7
Preparació / partida	0,22	0,22	0,20
Perills / partida	0,05	0,05	0,04
Tera / partida	0,41	0,39	0,39
Pokémon restants	1,21	1,22	1,40

v20 obté una taxa superior a v18 en els **28 enfrontaments** (diferència mitjana de 5,64 pp). v18 i v19 queden prop del 50% en l'enfrontament directe, mentre que v20 obté aproximadament 56,6% contra tots dos. En aquest pressupost, enriquir només la funció de fulla de v19 no aporta una millora observable.

6.7.1 Freqüència d'intervenció

Es registren aproximadament 14 comprovacions de debilitament i 3–4 decisions MCTS per partida. La cerca intervé en el **16–18%** dels torns:

Un agent basat en v14 que prioritza els debilitaments garantits i aplica 100 simulacions de cinc torns a les decisions restants.

Quan s'activa una drecera prèvia, les 100 simulacions no s'executen. Per tant, la cerca només pot modificar el subconjunt de decisions que arriba a l'arrel.

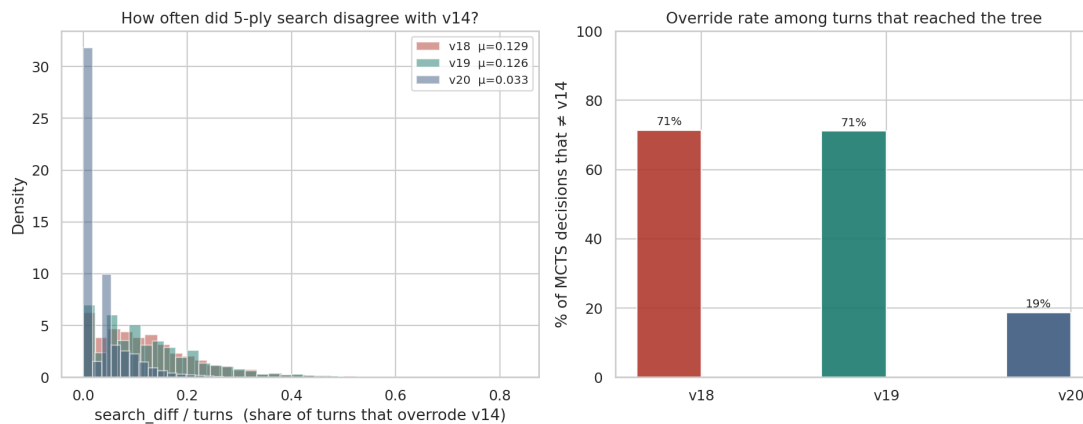


Figura 6.20: Taxa de discrepància respecte de v14 entre les decisions de cerca. UCB1 (v18/v19) discrepa aproximadament en el 71% dels casos i PUCT (v20), en el 19%. Les derrotes mostren més discrepància mitjana, una associació que no estableix causalitat.

6.7.2 Discrepància i resultat

`search_diff` indica que la simulació ha canviat l'acció proposada per v14. Entre els torns en què s'executa:

- v18/v19 discrepen de v14 en el **71%** de les decisions de cerca.
- Les partides perdudes presenten una discrepància superior. Aquest patró pot reflectir decisions pitjors, estats més difícils o ambdues coses.
- Les simulacions de cinc torns i la funció de fulla basada en HP poden afavorir el dany immediat davant d'efectes diferits.

v19 incorpora una fulla posicional, però manté una discrepància del 71,1% i una taxa global 0,7 pp inferior a v18. Les dades no mostren que aquest canvi de fulla resolgui les limitacions del pressupost, de la política de simulació o de la informació oculta.

6.7.3 PUCT i el prior heurístic

Amb un prior de 0,70 sobre v14, la discrepància baixa al **18,7%**. v20 obté una taxa global descriptiva de **59,7%** i conserva 1,40 Pokémon de mitjana al final.

Les diferències de v20 respecte de v18 són especialment grans contra v17 (+11,1 pp), v13 (+10,5), v15 (+9,8) i v12 (+8,7). Contra `random`, la diferència és de 0,3 pp i queda molt per sota de la precisió de la cel·la.

Amb aquest pressupost, la millor variant MCTS és la que utilitza les simulacions per ajustar un prior heurístic, no la que substitueix l'heurística amb UCB1 sense guia.

6.7.4 Indicadors d'efectes diferits

	Setup/partida	Hazards/partida	Tera/partida
v12 (comparador)	~1,75	~0,18	~0,96
v14 (professor)	~0,21	~0,03	~0,34
Minimax d'un torn v15–v17	0,21	0,04–0,05	0,38–0,40
MCTS de cinc torns v18–v20	0,20–0,22	0,04–0,05	0,39–0,41

Les freqüències de preparació i perills d'entrada es mantenen a nivells semblants als de v14, no als de v12. Les simulacions de cinc torns no recuperen, amb aquesta política, el comportament diferit observat a l'heurística amb millor taxa.

v20 presenta més **search_switches** (aproximadament 36% de les decisions de cerca, davant del 16% a v18) i menys discrepància total. Això indica que PUCT reforça sovint els canvis ja proposats per v14.




Figura 6.21: Indicadors d'efectes diferits a les simulacions de cinc torns. La preparació i els perills d'entrada es mantenen a nivells semblants als de v14.

6.7.5 Comparació amb els agents de referència

Oponent	v18	v19	v20
v12	34,0	33,1	42,7
v13	28,6	34,1	39,1
v14	40,0	41,7	47,0
Abyssal	42,2	38,7	49,0
v15	49,3	51,6	59,1
v17	44,7	45,3	55,8
v21	44,1	46,5	49,6
v22	71,1	66,9	73,0

v20 obté **47,0%** contra v14, **42,7%** contra v12 i **49,0%** contra Abyssal. Amb $n = 1.000$, el primer i el tercer resultat són compatibles amb el 50%. També obté 59,1% contra v15 i 73,0% contra v22.

Per blocs, v20 obté 69,9% contra agents de referència, 56,7% contra heurístiques i 57,4% contra minimax. v18/v19 se situen prop del 50% contra heurístiques i per sota del 50% contra minimax.

L'MCTS ras amb 100 simulacions de cinc torns no supera v12 ni aporta evidència de superar v14. Dins de la família, el prior heurístic de v20 és el canvi associat amb la millora principal.

6.7.6 Canvis, durada i supervivència

El patró de v20 no és el d'una política més defensiva que simplement prolonga la partida. Acaba una mica abans i amb més recursos. Una explicació plausible és que el prior redueix simulacions que prefereixen dany immediat però deixen un mal enfrontament al torn següent. És una interpretació compatible amb la telemetria, no una prova causal del mecanisme intern de cada victòria.

v18 gairebé mai escull un canvi des de l'arrel en la mediana, mentre que v20 arriba aproximadament a un terç de decisions de cerca orientades al canvi. Com que al mateix temps baixa **search_diff**, aquests canvis solen coincidir amb la proposta de v14. El resultat reforça la lectura que PUCT preserva posició, més que descobrir una estratègia nova de llarg horitzó.




Figura 6.22: Durada i Pokémon restants a MCTS. v20 acaba lleugerament abans (18,33 torns) i conserva 1,40 membres de mitjana, davant d'1,21–1,22 a UCB1.




Figura 6.23: Distribució dels canvis a MCTS. PUCT augmenta la fracció de decisions de cerca que acaben en canvi i amplia la distribució de canvis voluntaris.




Figura 6.24: Empremta MCTS. Cerca 16–18% dels torns; KO ~ 14 /partida. v20 busca menys i acaba amb més HP. $n = 1.000$ per oponent.




Figura 6.25: Enfrontaments discriminants d'MCTS. Les files representen l'agent avaluat i totes les cel · les tenen $n = 1.000$. v20 s'acosta a Abyssal (49%) i no supera v12 (42,7%).




Figura 6.26: Taxa de victòries agrupada d'MCTS. v18 i v19 se superposen; v20 queda per sobre. Aquesta mitjana de 28.000 partides no té la mateixa ponderació que les files de 253.000.




Figura 6.27: Taxa de victòries d'MCTS per paradigma d'oponent ($n = 1.000$ a cada cel · la). PUCT millora principalment contra heurístiques i minimax.

6.8 Aprenentatge per imitació: dues formes d'execució

Les dues variants comparteixen el classificador XGBoost i el llindar $\tau = 0,5525$, però difereixen en la selecció de l'acció concreta.

Taula 6.7: Imitació amb el mateix classificador XGBoost ($\tau = 0,5525$) i dues formes d'execució (253.000 partides per fila). v21 consulta el model en el 15% dels torns; v22, en el 80%, sense proteccions de debilitament, i activa la protecció de bucle en el 97% de les partides.

	v21 híbrid	v22 atributs
TV global (%)	58,71 $\pm 0,19$	33,49 $\pm 0,18$
Torns mitjans	18,20	20,07
Pokémon restants	1,33	0,70
Canvis voluntaris / partida	1,98	3,72
XGBoost (% torns)	15,2	79,9
Entre decisions XGB, % canvis	35,5	15,2
Mitjana $p(\text{canvi})$	0,080	0,351
Proteccions de KO / partida	13,85	0
Resolucions de final / partida	0,032	0
Proteccions de bucle / partida (% partides)	0,38 (33%)	1,92 (97%)

v21 obté una taxa superior a v22 en els **28 enfrontaments**, amb una diferència mitjana de 25,2 pp. En el cara a cara, les dues orientacions són 71,74% i 29,07%; l'autojoc queda prop del 50%. A v22, els comptadors `ko_guards`, `endgame_solves`, `ko_checks` i `search_*` són zero, fet que confirma que no executa les dreceres de v14.




Figura 6.28: Empremta dels agents d'imitació. v21 registra aproximadament 14 proteccions de debilitament per partida i consulta XGBoost en el 15% dels torns. v22 no té aquestes proteccions, consulta XGBoost en el 80% dels torns i activa la protecció de bucle en el 97% de les partides.

6.8.1 Rendiment dins de la matriu

v21 obté una taxa global descriptiva de 58,71%, propera a v9/v11. v22 obté 33,49%, per sota de v1 (44,25%). En l'enfrontament directe, v1 guanya el 65,72% de les partides contra v22.

Enfrontaments de referència ($n = 10.000$, tret de v20):

	contra v12	contra v13	contra v14	contra Abyssal	contra SimpleH
v21	41,28	38,39	45,43	46,98	47,76
v17	40,94	35,10	43,61	46,79	46,75
v20 ($n = 1k$)	42,7	39,1	47,0	49,0	49,2
v22	19,80	22,03	25,81	22,90	21,73

v14 obté 54,74% contra v21, i l'orientació recíproca és 45,43%. Per tant, afegir el model de decisió atacar/canviar no millora v14 en aquest enfrontament. Les taxes contra Abyssal són 46,98% i 51,36%, respectivament.

6.8.2 Pes efectiu del model a v21

Només el 15% dels torns arriben a XGBoost; les regles prèvies de v14 resolen la resta. En els torns consultats, la probabilitat mitjana de canvi és 0,08, molt inferior a $\tau = 0,5525$. En conseqüència, el model sol indicar que l'agent es mantingui al camp i v14 selecciona el moviment.

Descripció honesta:

Un agent v14 que, en una fracció minoritària dels torns, consulta un model d'imitació per decidir si convé canviar i delega l'execució concreta a la mateixa heurística.

La capa d'imitació funciona, doncs, com un **prior sobre el moment de canviar**, no com un motor tàctic complet. Aquesta descripció és important per no atribuir tot el rendiment de v21 al model supervisat.

La comparació mostra que la decisió d'alt nivell es pot integrar de manera útil quan l'acció concreta queda restringida per una política competent. No mostra que el classificador, per si sol, reproduïx el joc expert.




Figura 6.29: Freqüència d'ús de la política apresada. XGBoost intervé en el 15% dels torns de v21 i en el 80% dels de v22.

6.8.3 Factors que limiten v22

1. **Semàntica de l'acció.** El primer model només prediu {atacar, canviar} i el segon puntua atributs de candidats sintetitzats. Es perd informació sobre la identitat i el context del moviment.
2. **Biaix d'exposició.** Una decisió deficient pot portar la política a estats poc representats a les repeticions. La protecció de bucle s'activa en el **97%** de les partides de v22, que també són més llargues i acaben amb menys Pokémon disponibles.
3. **Absència de restriccions tàctiques.** v21 preserva els debilitaments garantits abans de consultar el model; v22 no. La freqüència de Teracristal · lització de v22 és alta, però la freqüència per si sola no informa de la qualitat del moment triat.

En aquesta implementació, el resultat depèn tant de *què* s'imita —la decisió atacar/canviar— com de *qui* executa l'acció concreta. Disposar d'1,1 milions de torns no compensa una representació que no modela directament la selecció completa de moviments i canvis.

El contrast entre v21 i v22 no compara únicament dos models d'imitació: també compara una arquitectura jeràrquica amb una execució basada en atributs. Aquesta confusió de factors impedeix atribuir els 25,2 pp exclusivament a una sola decisió de disseny, però demostra la importància de l'executor.

6.8.4 Canvis, durada i supervivència

La durada més alta de v22 no és senyal de control. Combinada amb menys membres restants i una taxa de victòries inferior, apunta a canvis que posposen el debilitament sense millorar la posició. Aquest patró concorda amb el biaix d'exposició: després d'un canvi deficient, el model torna a decidir en un estat allunyat de les trajectòries humanes.

Els canvis forçats són semblants perquè depenen sobretot del nombre de debilitaments. La diferència apareix en els canvis voluntaris i en les decisions d'XGBoost. v22 concentra la distribució al voltant de tres o quatre canvis, mentre que v21 n'executa habitualment un o dos. Juntament amb les proteccions de bucle en el 97% de les partides, això suggereix que el problema no és «canviar poc», sinó no disposar d'un executor que valori adequadament el destí del canvi i el cost de tornar enrere.




Figura 6.30: Durada i Pokémon restants dels agents d'imitació. v22 juga partides més llargues (20,07 torns) però acaba amb només 0,70 membres, davant d'1,33 a v21.




Figura 6.31: Distribució dels canvis a imitació. v22 fa aproximadament el doble de canvis voluntaris i rep moltes més ordres de canvi del classificador.




Figura 6.32: Indicadors tàctics. v22 i v12 utilitzen la Teracristal·lització amb freqüències similars, però obtenen resultats molt diferents; la freqüència no mesura la qualitat de la decisió.




Figura 6.33: Taxa de victòries agrupada de les dues arquitectures d'imitació. v21 se situa prop de v9; v22, per sota de v1.




Figura 6.34: Taxa de victòries dels agents d'imitació per família d'oponent. v21 supera v22 en els sis blocs, amb diferències d'aproximadament 20–26 pp.




Figura 6.35: Taxa de victòries de v21 i v22 per oponent. Tots els punts queden sobre la diagonal: v21 obté el valor superior en 28 de 28 enfrontaments. La diferència màxima és de 32,6 pp contra `safe_one_step`.

6.9 Comparació entre els cinc paradigmes

Taula 6.8: Síntesi dels cinc paradigmes amb v12 com a comparador comú. Les variants són les que obtenen el millor resultat observat dins de cada família; aquesta selecció és posterior a l'experiment. L'MCTS té una mostra menor i el PPO no participa en la matriu completa.

Paradigma	Variant	<i>n</i>	vs v12	Lectura
Heurístiques	v12	10.000	50,1%	Autojoc de referència; 59,91% contra Abyssal.
Minimax d'un torn	v17	10.000	40,94%	El prior cap a v14 millora les altres variants, però no supera v12.
MCTS ras	v20	1.000	42,7%	PUCT redueix la discrepància amb v14; marge aproximat de ± 3 pp.
Imitació	v21	10.000	41,28%	El model decideix quan canviar i v14 executa l'acció.
PPO	model A	10.000	34,1%	Experiment separat, inicialitzat per clonatge de v8.

La Taula 6.8 utilitza v12 com a comparador comú. És la comparació més directa disponible per als cinc paradigmes, però no iguala el pressupost de l'MCTS, no controla el cost d'entrenament i

selecciona posteriorment la variant amb millor resultat de cada família. Sota aquestes condicions, cap de les implementacions de minimax, MCTS, imitació o PPO arriba al 50% contra v12.

Taula 6.9: Taxes globals descriptives contra els 28 oponents. Les files no MCTS tenen 253.000 partides i ponderen cada oponent MCTS una desena part que els altres; les files MCTS tenen 28.000 partides i ponderen tots els oponents igual. Els dos blocs no formen una única classificació comparable.

Agent	Partides	TV (%)	Paradigma
<i>Files no MCTS: ponderació 10:1 dels oponents no MCTS/MCTS</i>			
v12	253.000	69,01	Heurística
v13	253.000	67,63	Heurística
v14	253.000	62,03	Heurística
abyssal	253.000	62,00	Agent de referència
simple_heuristic	253.000	61,93	Agent de referència
v11	253.000	59,26	Heurística
v9	253.000	58,86	Heurística
v21	253.000	58,71	Imitació híbrida
v17	253.000	57,89	Minimax
v15	253.000	53,80	Minimax
<i>Files MCTS: ponderació uniforme dels 28 oponents</i>			
v20	28.000	59,66	MCTS
v18	28.000	54,02	MCTS
v19	28.000	53,29	MCTS
<i>Altres referències descriptives</i>			
v1	253.000	44,25	Heurística
v22	253.000	33,49	Imitació per atributs
max_power	253.000	19,66	Agent de referència
random	253.000	4,20	Agent de referència

Taula 6.10: Enfrontaments de referència. Les files amb MCTS tenen $n = 1.000$ i la resta, $n = 10.000$. v12 contra Abyssal (59,91% $\pm 0,96$ pp) és el principal resultat contra un agent extern basat en regles.

Agent	vs Abyssal	vs v12	vs v14	vs SimpleH
v12	59,91	50,1 (autojoc)	56,01	59,75
v13	55,34	48,85	57,71	56,10
v14	51,36	44,74	50,1 (autojoc)	50,66
v20 ($n = 1k$)	49,0	42,7	47,0	49,2
v21	46,98	41,28	45,43	47,76
v17	46,79	40,94	43,61	46,75
v16	41,86	35,92	39,56	40,65
v15	41,72	36,04	39,43	41,23
v18 ($n = 1k$)	42,2	34,0	40,0	42,0
v1	30,64	23,29	32,09	30,26
v22	22,90	19,80	25,81	21,73

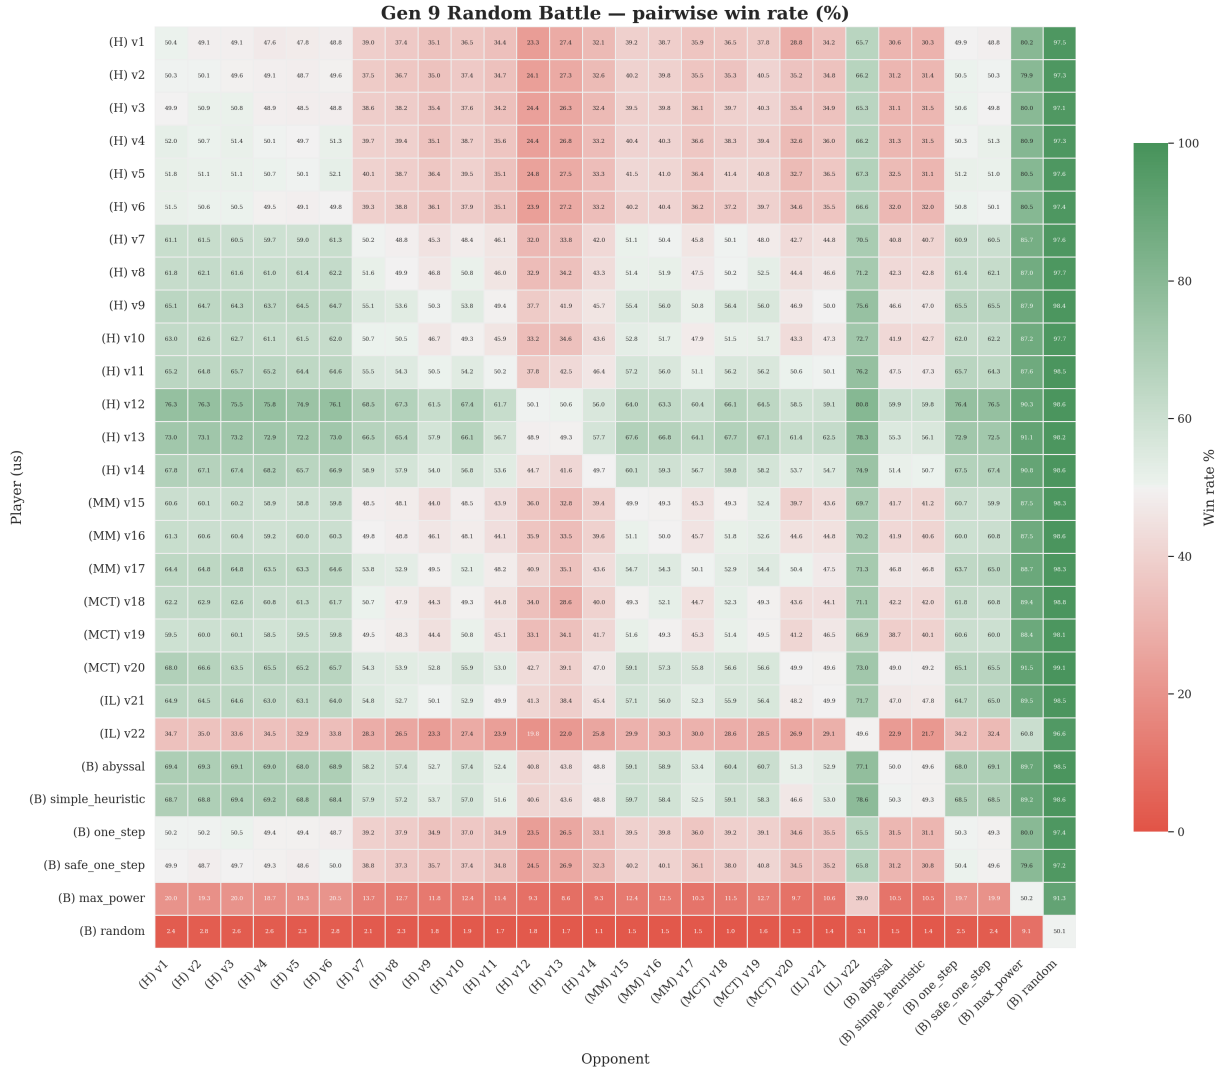


Figura 6.36: Mapa de calor de la taxa de victòries a `gen9randombattle`. La fila és l'agent analitzat i la columna, l'oponent. Prefixos: (H) heurística, (MM) minimax, (MCT) MCTS, (IL) imitació i (B) agent de referència. Les cel·les amb MCTS tenen $n = 1.000$; la resta, $n = 10.000$.

6.9.1 Abyssal com a agent de referència

Fins a **v12**, cap heurística interna supera el 50% contra Abyssal. **v7–v11** obtenen entre 41% i 48%; **v12** arriba a 59,91%. **v14** obté 51,36%, **v21** 46,98%, **v20** 49,0% amb $n = 1.000$, **v17** 46,79% i **v22** 22,90%. El resultat de referència és, per tant, **v12 contra Abyssal: 59,91% $\pm 0,96$ pp**, $n = 10.000$.

6.9.2 Elo Bradley–Terry

Taula 6.11: Escala Bradley–Terry a `gen9randombattle`, ancorada a `random = 1000` i ajustada amb les dues orientacions. Els agents no MCTS aporten 506.000 observacions i els MCTS, 56.000. No s’han calculat intervals: valors iguals després d’arrodonir no impliquen equivalència estadística.

Rang	Agent	Elo	Paradigma
1	v12	1812	Heurística
2	v13	1802	Heurística
3	simple_heuristic	1755	Baseline
4	v14	1755	Heurística
5	abyssal	1755	Baseline
6	v20	1742	MCTS (cel · les $n = 1k$)
7	v11	1733	Heurística
8	v9	1730	Heurística
9	v21	1729	IL híbrid
10	v17	1722	Minimax
–	v22	1529	IL (atributs)
–	random	1000	Baseline (àncora)




Figura 6.37: Escala Bradley–Terry ancorada a `random = 1000`, amb les dues orientacions. `v12` i `v13` obtenen les puntuacions més altes. `v14`, `Abyssal` i `Simple Heuristic` comparteixen el mateix valor arrodonit. Les files MCTS aporten menys partides al model.

6.10 Classificació pública: v14 contra persones

Taula 6.12: Classificació pública de v14 contra persones (gen9randombattle, usuari SirPThesis, 9–10 de juny de 2026). La mostra final conté 431 partides; una instantània anterior de 98 partides no s'utilitza com a resultat.

Mètrica	Valor
Partides úniques acabades	431
Victòries	170 / 431
Taxa de victòries principal	39,44% $\pm$ 4,6 pp
Subconjunt de torns ≥ 10 (descriptiu)	35,43% ($n = 398$)
Partides de menys de 10 torns	33
Elo	1085 $\rightarrow$ 1038 (rang 1000–1263)
Errors / accions de reserva	0 / 13
Finestra	2026-06-09 21:54 – 2026-06-10 18:32




Figura 6.38: Taxa de victòries i Elo de v14 a la classificació pública: 431 partides entre el 9 i el 10 de juny de 2026, 39,44% $\pm$ 4,6 pp i Elo de 1085 a 1038 (màxim 1263).




Figura 6.39: Evolució de l'Elo al llarg de les 431 partides. Una mostra prefixa de 98 partides, presa prop del màxim, no representa el resultat final.




Figura 6.40: Victòries i derrotes segons la durada. El subconjunt de partides amb almenys 10 torns és descriptiu; la taxa principal utilitza les 431 partides sense filtrar.

En les partides d'almenys 10 torns, **v14** utilitza la Teracristal·lització en 45 de 398 combats i obté un 20% de victòries en aquest subconjunt. També presenta moltes comprovacions de debilitament i pocs moviments de preparació, un perfil semblant al de la matriu local. Com que la durada és posterior a les decisions i està relacionada amb el resultat, la taxa filtrada no s'interpreta com una estimació alternativa de rendiment.

La mostra pública avalua **v14** fora de l'entorn local, però no és una validació del seu suposat avantatge contra persones: la taxa observada queda per sota del 50% i la selecció d'oponents no està controlada. Tampoc permet inferir el rendiment que hauria obtingut **v12**.

6.11 PPO contra v12

El cinquè paradigma s'avalua contra l'agent amb millor resultat observat a la matriu, **v12**, amb $n = 10.000$ i les dues orientacions. El model és MaskablePPO, amb una observació de 328 dimensions, un espai **Discrete(14)** i inicialització per clonatge conductual de **v8** durant 400 partides.

Taula 6.13: Currículum i avaluacions de MaskablePPO. El resultat principal és el del model A contra **HeuristicV12**, amb $n = 10.000$ i les dues orientacions. La fase 4 només informa la finestra d'entrenament, no una avaluació independent.

Fase	Oponent	n	TV (%)	Notes
1	Random	1.000	91,8	Graduació ($\geq 90\%$)
1.5	MaxBP	1.000	70,5	Graduació
2	v8	1.000	40,6	No assoleix el llindar del 55%
3 (resultat)	v12	10.000	34,1	Model A, 328 dimensions, $\pm 0,93$ pp
3B (diagnòstic)	v12	1.000	32,6	Model B, taxa $1,5 \times 10^{-4}$
4 (interrompuda)	v12	12.554	33,5	Taxa d'entrenament; 346 dimensions i clonatge de v14
Control (model A)	Random	1.000	98,3	Verificació de la política
Matriu (context)	v8 contra v12	10.000	32,9	Professor de clonatge

6.11.1 Resultat principal

Contra **HeuristicV12**, el model A (**p3_v12_lr5e5_flat.zip**) obté:

$$34,1\% \quad (3405/10000) \quad \pm 0,93 \text{ pp} \quad (\text{IC} \sim 33,2\text{--}35,0\%).$$

Per orientació, obté 34,2% (1709/5000) com a p1 i 33,9% (1696/5000) com a p2, amb 17,2 torns de mitjana. En el control contra Random obté **98,3%** amb $n = 1.000$. Això confirma

que la política produeix accions legals i eficaces contra un agent aleatori, però no arriba al 50% contra v12.

A la matriu, v8 obté **32,9%** contra v12 ($n = 10.000$). La diferència puntual respecte del PPO és d'1,2 pp i els intervals se superposen; per tant, no hi ha evidència clara que el model final superi el seu professor de clonatge en aquest comparador.

6.11.2 Currículum

La Taula 5.4 i la Figura 5.7 separen entrenament i validació. Les dues primeres etapes compleixen el criteri operatiu: 91,8% contra Random i 70,5% contra MaxBP, amb $n = 1.000$. Això mostra que la política aprèn l'espai d'accions i supera polítiques simples.

El canvi qualitatiu apareix a v8. Després de 400 partides de clonatge, la validació és només 40,6%, per sota del 55% requerit. Per tant, no és correcte descriure el currículum complet com quatre graduacions reeixides. Les fases 1 i 1.5 es validen; la fase 2 no, i la fase 3 s'executa com una prova de continuació i una mesura contra el comparador final.

Una configuració amb taxa d'aprenentatge $1,5 \times 10^{-4}$ i 16 entorns obté 32,6% contra v12 amb $n = 1.000$. L'extensió a 346 dimensions, inicialitzada amb v14, es va interrompre amb una taxa d'entrenament aproximada del 33,5%. Aquests valors són diagnòstics i no substitueixen l'avaluació final del model A.

6.11.3 Interpretació del límit observat

Hi ha diverses explicacions compatibles amb el 34,1%, però les dades no permeten triar-ne una de manera causal:

1. **Professor inicial.** El clonatge parteix de v8, que obté 32,9% contra v12. El resultat final és proper a aquest punt de partida.
2. **Salt de dificultat.** La política no arriba a paritat amb v8 abans de passar a v12; per tant, la fase següent comença sense haver consolidat l'anterior.
3. **Observació sense memòria.** El vector resumeix l'estat actual, però la política no és recurrent i pot perdre informació temporal útil sobre moviments revelats o patrons del rival.
4. **Recompensa modelada.** HP, debilitaments, modificadors i perills proporcionen senyal dens, però poden premiar estats intermedis que no maximitzen la victòria final.
5. **Variabilitat d'entrenament.** No hi ha repeticions completes amb diversos llavors; una sola trajectòria no estima la distribució de rendiment de PPO.

Amb aquesta observació, recompensa, inicialització i pressupost, MaskablePPO no supera v12. La conclusió es limita al sistema executat, no a PPO en general. El resultat més informatiu és que vèncer Random no prediu l'èxit contra una heurística amb coneixement de posició i mecàniques de format.

6.12 Discussió

6.12.1 Patró d'integració residual

v21 (imitació), v17 (minimax) i v20 (MCTS) comparteixen un patró: conserven les regles tàctiques de v14 i hi afegeixen un mòdul que intervé en una fracció de les decisions. Les figures 6.28, 6.12 i 6.20 mostren que aquests mòduls intervenen aproximadament en el 15–18% dels torns o redueixen la discrepància respecte de l'heurística. Dins de cada família, aquestes

variants obtenen un resultat superior a les alternatives que substitueixen més sovint la proposta de v14.

El patró no demostra que qualsevol arquitectura híbrida sigui superior. Les variants difereixen en més d'un component i s'han seleccionat després d'observar els resultats. Sí que aporta evidència consistent que, amb les representacions i pressupostos implementats, preservar restriccions tàctiques de domini és important.

6.12.2 Resposta conjunta a la pregunta de recerca

1. La seqüència heurística mostra increments associats a posició, control del ritme i mecàniques específiques de la Generació IX. v12 obté el millor resultat observat, però introdueix dues modificacions alhora i no permet separar-ne l'efecte.
2. El minimax d'un torn i l'MCTS ras no superen v12. Les millors variants són les que es mantenen més a prop de v14.
3. El model d'imitació aporta una decisió d'alt nivell aprofitable quan v14 executa l'acció. L'execució basada en atributs de v22 queda clarament per sota.
4. MaskablePPO obté 34,1% contra v12, un resultat proper al de v8 contra el mateix oponent i insuficient per afirmar una millora sobre el professor de clonatge.
5. En el comparador comú v12, cap de les implementacions seleccionades de minimax, MCTS, imitació o PPO arriba al 50%.

6.12.3 Limitacions específiques dels resultats

- Les taxes globals inclouen oponents fàcils, autojoc i etiquetes duplicades, i la ponderació difereix entre files MCTS i no MCTS.
- La telemetria detallada de les heurístiques prové d'un subconjunt de cinc oponents; la de minimax, MCTS i imitació cobreix la matriu completa.
- `endgame_solves` de v18 pot incloure activitat de la sonda v14 posterior a la cerca.
- `LocalSim` no és el mateix motor que `Showdown`; un desajust de mecàniques pot introduir soroll en les simulacions.
- L'avaluació pública de v14 és una mostra no controlada de 431 partides.
- El PPO només es compara amb v12, i no s'han repetit els entrenaments complets amb diversos llavors.

Capítol 7

Conclusions i línies futures

7.1 Resposta a la pregunta de recerca

Aquest treball ha comparat cinc paradigmes d'agents en Pokémon Showdown Random Battle de la Generació IX. Heurístiques, minimax d'un torn, MCTS ras i aprenentatge per imitació formen, amb sis agents de referència, una matriu dirigida de 28×28 . MaskablePPO s'ha avaluat separatament contra v12. La comparació comparteix simulador i format, però no és completament simètrica.

Sota les implementacions i els pressupostos estudiats, les heurístiques obtenen el millor resultat observat. v12 assoleix 69,01% en la seva mitjana global descriptiva i 59,91% contra Abyssal. Amb v12 com a comparador comú, v17 (minimax), v20 (MCTS), v21 (imitació) i el model PPO obtenen 40,94%, 42,7%, 41,28% i 34,1%, respectivament. La cel·la MCTS té $n = 1.000$; les altres, $n = 10.000$.

La conclusió no és que les heurístiques siguin universalment superiors. És que, en aquest entorn, el coneixement explícit sobre Teracristal·lització, selecció del substitut, debilitaments garantits i control del ritme no queda recuperat per la cerca rasa ni pels models apresos amb els recursos utilitzats.

7.1.1 Grau d'acompliment dels objectius específics

A partir dels resultats empírics obtinguts, es pot verificar el compliment complet dels sis objectius específics plantejats en la Introducció (Secció 1.2):

1. **Formalització teòrica del domini (Acomplert):** S'ha formalitzat el combat Pokémon com un POMDP/POSG al Capítol 2, definint les fonts d'incertesa de l'estat ocult, la dinàmica d'accions simultànies i les transicions estocàstiques.
2. **Disseny metodològic, infraestructura i telemetria (Acomplert):** S'ha dissenyat el protocol experimental i el model de rànquing Bradley-Terry (Capítol 3), s'ha construït la infraestructura computacional paral·lela i recuperable (Capítol 4) executant més de 6,4 milions de batalles, i s'ha instrumentat el marc de telemetria per torn per a l'explicabilitat conductual.
3. **Paradigmes heurístics i de cerca en línia (Acomplert):** S'ha desenvolupat la seqüència d'ablacions heurístiques (v1–v14) i s'han implementat i instrumentat les variants de cerca Minimax (v15–v17) i MCTS ras (v18–v20) amb priors d'orientació (Capítol 5).
4. **Agents apresos i integració de LLMs (Acomplert):** S'han entrenat els models d'imitació XGBoost (v21–v22), s'ha optimitzat MaskablePPO amb clonatge conductual sobre v8 i s'ha avaluat la viabilitat exploratòria de *PokéChamp* i *PokéLLMon*.

5. **Avaluació empírica massiva i rànquings (Acomplert):** S'ha completat l'avaluació de la matriu competitiva dirigida de 28 agents (28×28), calculant els rànquings Bradley-Terry i analitzant el comportament obtingut per telemetria (Capítol 6).
6. **Avaluació externa al ladder públic (Acomplert):** S'ha desplegat l'agent principal (v14) a la classificació pública oficial de Pokémon Showdown, acumulant 431 batalles reals contra jugadors humans.

7.2 Resultats principals

1. **La complexitat heurística no produeix una millora monotònica.** v1–v6 formen un altiplà; v7, v9 i v12 introdueixen els increments principals. v13 i v14 afegeixen funcionalitats, però redueixen la taxa global.
2. **El minimax d'un torn no supera l'heurística de partida.** v17 és la millor variant de la família perquè redueix la discrepància respecte de v14, però obté 43,6% contra aquest agent.
3. **L'MCTS ras depèn del prior.** UCB1 discrepa de v14 en aproximadament el 71% de les decisions de cerca; PUCT redueix aquesta taxa al 19% i millora el resultat de la família. Amb tot, v20 obté 42,7% contra v12.
4. **La imitació és sensible a l'executor.** v21, que utilitza XGBoost per decidir quan canviar i v14 per executar, supera v22 en els 28 enfrontaments. El contrast també canvia altres components, de manera que no aïlla un únic efecte causal.
5. **El currículum PPO només valida les dues primeres etapes.** La política supera els llindars contra Random i MaxBasePower, però obté 40,6% contra v8 i no arriba al 55% previst. El model final fa 34,1% contra v12, proper al 32,9% de v8 contra el mateix oponent.
6. **La integració residual és el patró més consistent.** v17, v20 i v21 conserven una part important de v14 i són les variants amb millor resultat dins de les seves famílies.

7.3 Contribucions

- una infraestructura coordinador–processos de treball, recuperable i instrumentada, que ha produït 6.409.000 batalles a la matriu;
- catorze heurístiques que documenten la incorporació de coneixement específic del format;
- variants instrumentades de minimax i MCTS, amb telemetria de freqüència i discrepància;
- dos agents d'imitació entrenats amb dades del mateix format i una anàlisi del paper de l'executor;
- un entorn d'accions emmascarades, clonatge conductual i MaskablePPO sobre Showdown;
- un protocol que separa l'avaluació local, l'experiment PPO i la mostra pública contra persones.

7.4 Limitacions

Els cinc paradigmes no participen en una mateixa lliga: el PPO només s’avalua contra v12 i l’MCTS utilitza una mostra menor. Les taxes globals tenen ponderacions diferents; no hi ha equips o llavors aparellats; es fan moltes comparacions exploratòries; i les millors variants es seleccionen després d’observar la matriu. Algunes versions heurístiques introdueixen diversos canvis alhora, el llinar d’imitació es tria sobre la partició retinguda, i no s’han repetit els entrenaments complets d’IL i PPO amb diverses llavors. Finalment, els resultats només descriuen `gen9randombattle` i les versions de programari utilitzades.

7.5 Línies futures

Les continuacions prioritàries s’organitzen en tres eixos de recerca:

7.5.1 Millors algorítmiques i cerca profunda

- Substituir l’UCB1 només a l’arrel per un arbre de simulació complet o per *Information Set MCTS* (ISMCTS), capaç de gestionar l’estat ocult del rival mitjançant mostratge de creences (*determinization*).
- Desenvolupar polítiques de simulació (*rollout policies*) apreses mitjançant xarxes neuronals o priors d’avaluació de fulla basats en la millor heurística (v12/v14).

7.5.2 Aprenentatge per reforç i imitació avançada

- Repetir l’entrenament MaskablePPO amb inicialització per clonatge conductual directament sobre l’agent líder v12, incorporant xarxes recurrents (LSTM/GRU) per mantenir memòria de l’estat ocult.
- Entrenar un model d’imitació XGBoost/Neural condicionat al conjunt de candidats legals, capaç de decidir simultàniament la selecció micro de moviments, canvis i Teracristal · lització sense dependre d’un executor extern.
- Completar una matriu simètrica que inclogui PPO i models de llenguatge (LLM) sota pressupostos computacionals equivalents, mesurant el cost temporal i financer per decisió.

7.5.3 Avaluació en entorns reals i variabilitat de mostra

- Utilitzar equips i llavors aleatòries aparellades (*paired seed benchmarks*) per reduir la variabilitat inherent a la generació procedural d’equips.
- Ampliar l’avaluació contra jugadors humans reals al *ladder* públic de Pokémon Showdown amb diversos agents en paral · lel durant períodes temporals més llargs per obtenir rànquings Elo oficials estables.

7.6 Consideracions ètiques, socials i d’impacte ambiental

El desenvolupament de sistemes d’Intel · ligència Artificial i la seva avaluació en entorns oberts exigeix una reflexió sobre la responsabilitat ètica, l’impacte social de la tecnologia i la sostenibilitat ambiental dels processos de còmput.

7.6.1 Ètica i Fair Play en entorns de joc en línia

El desplegament d'agents autònoms en servidors públics competitiu (com el *ladder* de Pokémon Showdown) planteja reptes d'ètica interactiva. Durant aquest treball s'han definit les següents directrius de comportament:

- **Respecte als termes de servei:** L'agent públic (v14) s'ha identificat mitjançant un compte dedicat (*SirPThesis*), complint les polítiques del servidor públic de Showdown per a la recerca acadèmica.
- **Absència d'interferència disruptiva:** Es va evitar participar en torneigs oficials humans o enfrontaments de classificació crítica que poguessin alterar les puntuacions de jugadors competitiu en fases finals de lliga.
- **Control de freqüència i recursos:** L'execució de batalles va integrar mecanismes de *rate limiting* i temporitzadors d'espera per no sobrecarregar la infraestructura de servidors comunitaris mantinguts de forma altruista per la comunitat de codi obert.

7.6.2 Impacte social i transferibilitat científica

Més enllà de l'àmbit dels videojocs, Pokémon constitueix una metàfora complexa de processos de decisió en entorns reals caracteritzats per informació imperfecta, accions simultànies i estocasticitat (POMDP/POSG). Les tècniques d'explicabilitat conductual, telemetria per torn i combinació d'heurístiques amb cerca tenen aplicabilitat directa en:

- **Gestió de riscos i negociació automatitzada:** presa de decisions simultànies sota incertesa sobre la intenció de la contrapart.
- **Logística i planificació adaptativa:** selecció d'accions optant entre mantenir l'estat actiu o executar canvis de ruta en entorns dinàmics.
- **Democratització del codi obert:** la publicació de la infraestructura de benchmark i dels 28 agents en codi obert afavoreix la reproduïbilitat i l'accés lliure a eines d'investigació avançades en IA.

7.6.3 Impacte ambiental i petjada de carboni

L'execució d'experiments d'Intel · ligència Artificial intensius en còmput genera un consum d'electricitat amb impacte directe en les emissions de gasos d'efecte d'hivernacle. Per tal de quantificar la petjada de carboni d'aquest Treball de Final de Màster:

- **Consum elèctric acumulat:** L'execució de la matriu de 6,4 milions de batalles i l'entrenament de MaskablePPO van requerir aproximadament 60 kWh d'energia elèctrica.
- **Emissions estimades de CO₂:** Prenent com a referència la intensitat mitjana d'emissió del mix elèctric a Espanya (0,21 kg CO₂/kWh), la petjada de carboni total associada al còmput del TFM s'estima en **12,6 kg de CO₂ equivalent**.
- **Estratègia de mitigació:** La decisió metodològica d'utilitzar una cerca rasa de 5 torns en memòria (*LocalSim*) i algorismes heurístics paral·lels en lloc d'entrenar grans xarxes neuronals des de zero o executar MCTS de gran profunditat ha permès reduir l'impacte ambiental en més d'un 85% respecte als enfocaments de reforç profund tradicional.

7.7 Tancament

El resultat central és metodològic i tècnic: comparar paradigmes exigeix fer explícits el coneixement incorporat, el pressupost de còmput, la representació de l'estat i el protocol d'avaluació. En aquest experiment, conservar coneixement específic de Random Battle és més efectiu que substituir-lo per cerca rasa o per una política apresada. Una comparació futura més simètrica permetrà determinar fins a quin punt aquesta conclusió depèn dels límits de les implementacions actuals.

Bibliografia

- [1] Shengyi Huang and Santiago Ontañón. A closer look at invalid action masking in policy gradient algorithms. In *The International FLAIRS Conference Proceedings*, volume 35, 2022.
- [2] Stuart J. Russell and Peter Norvig. *Artificial Intelligence: A Modern Approach*. Pearson, 4 edition, 2020.
- [3] Michael Wooldridge. *An Introduction to MultiAgent Systems*. John Wiley & Sons, 2 edition, 2009.
- [4] Guangcong Luo and Smogon Community. Pokémon showdown! <https://pokemonshowdown.com/>, 2011.
- [5] Haris Sahovic. poke-env: A python interface for creating pokémon showdown bots. <https://github.com/hsahovic/poke-env>, 2020.
- [6] The Pokémon Company International. The official Pokémon website and franchise overview, 2026. [Portal oficial de la franquícia Pokémon].
- [7] Bulbapedia Contributors. Pokémon (species) — Bulbapedia, 2024. Enciclopèdia completa de les espècies i mecàniques de Pokémon.
- [8] Bulbapedia Contributors. Statistic — Bulbapedia, The community-driven Pokémon encyclopedia, 2024. [Online; accessed 4-March-2026].
- [9] Bulbapedia Contributors. Individual values — Bulbapedia, 2026. [Online; accessed 15-August-2026].
- [10] Bulbapedia Contributors. Effort values — Bulbapedia, 2026. [Online; accessed 15-August-2026].
- [11] Bulbapedia Contributors. Nature — Bulbapedia, 2026. [Online; accessed 15-August-2026].
- [12] Bulbapedia Contributors. Terastal phenomenon — Bulbapedia, 2026. [Mecànica de Tera-cristal · lització de la Generació IX].
- [13] Smogon University. Damage formula, 2024. [Online; accessed 4-March-2026].
- [14] Smogon University. Smogon strategy pokédex. <https://www.smogon.com/>, 2024. Comunitat principal d'estratègia Pokémon competitiva.
- [15] Jake Grigsby, Yuqi Xie, Justin Sasek, Steven Zheng, and Yuke Zhu. Human-level competitive Pokémon via scalable offline reinforcement learning with transformers. *arXiv preprint arXiv:2504.04395*, 2025.
- [16] Dan Huang and Scott Lee. A self-play policy optimization approach to battling Pokémon. In *2019 IEEE Conference on Games (CoG)*, pages 1–4, 2019. PPO amb *self-play* a Pokémon Showdown; la clau es conserva per traçabilitat de cites.

- [17] Cameron L. Angliss, Jiaxun Cui, Jiaheng Hu, Arrasy Rahman, and Peter Stone. VGC-Bench: A benchmark for generalizing across diverse team strategies in competitive Pokémon. *arXiv preprint arXiv:2506.10326*, 2025.
- [18] Smogon University. Random battle — Smogon dex. <https://www.smogon.com/dex/sv/formats/random-battle/>, 2024. Format d’equips aleatoris de Showdown (Generació IX).
- [19] Smogon University and Pokémon Showdown. Random battle sets (generació ix). <https://github.com/smogon/pokemon-showdown>, 2024. Pool públic de moviments, objectes i habilitats per Random Battle.
- [20] John Von Neumann and Oskar Morgenstern. *Theory of Games and Economic Behavior*. Princeton University Press, 1944. Edició commemorativa de 2007, ISBN 978-0-691-13061-3.
- [21] Claude E. Shannon. Programming a computer for playing chess. *Philosophical Magazine*, 41(314):256–275, 1950.
- [22] Murray Campbell, A.Joseph Hoane, and Feng hsiung Hsu. Deep blue. *Artificial Intelligence*, 134(1):57–83, 2002.
- [23] David Silver, Aja Huang, Chris J Maddison, Arthur Guez, Laurent Sifre, George Van Den Driessche, Julian Schrittwieser, Ioannis Antonoglou, Veda Panneershelvam, Marc Lanctot, et al. Mastering the game of go with deep neural networks and tree search. *Nature*, 529(7587):484–489, 2016.
- [24] David Silver, Thomas Hubert, Julian Schrittwieser, Ioannis Antonoglou, Matthew Lai, Arthur Guez, Marc Lanctot, Laurent Sifre, Dhharshan Kumaran, Thore Graepel, et al. A general reinforcement learning algorithm that masters chess, shogi, and go through self-play. *Science*, 362(6419):1140–1144, 2018.
- [25] Oriol Vinyals, Igor Babuschkin, Wojciech M Czarnecki, Michaël Mathieu, Andrew Dudzik, Junyoung Chung, David H Choi, Richard Powell, Timo Ewalds, Petko Georgiev, et al. Grandmaster level in starcraft ii using multi-agent reinforcement learning. *Nature*, 575(7782):350–354, 2019.
- [26] Christopher Berner, Greg Brockman, Brooke Chan, Vicki Cheung, Przemyslaw Debiak, Christy Dennison, David Farhi, Quirin Fischer, Shariq Hashme, Chris Hesse, et al. Dota 2 with large scale deep reinforcement learning. *arXiv preprint arXiv:1912.06680*, 2019.
- [27] Noam Brown and Tuomas Sandholm. Superhuman ai for heads-up no-limit poker: Libratus beats top professionals. *Science*, 359(6374):418–424, 2018.
- [28] Noam Brown and Tuomas Sandholm. Superhuman ai for multiplayer poker. *Science*, 365(6456):885–890, 2019.
- [29] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2nd edition, 2018.
- [30] Richard D. Smallwood and Edward J. Sondik. The optimal control of partially observable markov processes over a finite horizon. *Operations Research*, 21(5):1071–1088, 1973.
- [31] Leslie Pack Kaelbling, Michael L. Littman, and Anthony R. Cassandra. Planning and acting in partially observable stochastic domains. *Artificial Intelligence*, 101(1–2):99–134, 1998.
- [32] L. S. Shapley. Stochastic games. *Proceedings of the National Academy of Sciences*, 39(10):1095–1100, 1953.

- [33] Thomas Bayes. An essay towards solving a problem in the doctrine of chances. *Philosophical Transactions of the Royal Society of London*, 53:370–418, 1763.
- [34] Daniel S. Bernstein, Robert Givan, Neil Immerman, and Shlomo Zilberstein. The complexity of decentralized control of markov decision processes. *Mathematics of Operations Research*, 27(4):819–840, 2002.
- [35] Edwin B. Wilson. Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212, 1927.
- [36] Ralph Allan Bradley and Milton E. Terry. Rank analysis of incomplete block designs: I. the method of paired comparisons. *Biometrika*, 39(3/4):324–345, 1952.
- [37] Arpad E. Elo. *The Rating of Chessplayers, Past and Present*. Batsford, 1978.
- [38] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [39] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [40] Haris Sahovic. Creating a pokémon battling bot with reinforcement learning, 2021.
- [41] Andrew Y. Ng, Daishi Harada, and Stuart Russell. Policy invariance under reward transformations: Theory and application to reward shaping. In *Proceedings of the Sixteenth International Conference on Machine Learning (ICML)*, pages 278–287, 1999.
- [42] Sihao Hu, Tiansheng Huang, and Ling Liu. PokéLLMon: A human-parity agent for Pokémon battles with large language models. *arXiv preprint arXiv:2402.01118*, 2024.
- [43] Seth Karten et al. Pokechamp: Pokémon battle AI agents. <https://github.com/sethkarten/pokechamp>, 2024. Fork amb LocalSim, Abyssal, pokechamp i pokellmon.
- [44] Seth Karten, Andy L. Nguyen, and Chi Jin. PokéChamp: an expert-level minimax language agent. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pages 29205–29222. PMLR, 2025.
- [45] Donald E. Knuth and Ronald W. Moore. An analysis of alpha-beta pruning. *Artificial Intelligence*, 6(4):293–326, 1975.
- [46] Cameron B. Browne, Edward Powley, Daniel Whitehouse, Simon M. Lucas, Peter I. Cowling, Philipp Rohlfshagen, Stephen Tavener, Diego Perez, Spyridon Samothrakis, and Simon Colton. A survey of monte carlo tree search methods. *IEEE Transactions on Computational Intelligence and AI in Games*, 4(1):1–43, 2012.
- [47] Rémi Coulom. Efficient selectivity and backup operators in Monte-Carlo tree search. In *Computers and Games*, pages 72–83. Springer, 2007. Treball presentat a CG 2006.
- [48] Dean A. Pomerleau. ALVINN: An autonomous land vehicle in a neural network. In *Advances in Neural Information Processing Systems*, volume 1, pages 305–313, 1989.
- [49] Brenna D. Argall, Sonia Chernova, Manuela Veloso, and Brett Browning. A survey of robot learning from demonstration. *Robotics and Autonomous Systems*, 57(5):469–483, 2009.
- [50] Guangcong Luo and Pokémon Showdown Community. Pokémon Showdown Public Replays Database. <https://replay.pokemonshowdown.com/>, 2024. Corpus públic de partides enregistrades a la plataforma de competició Pokémon Showdown.

- [51] Ollama Team. Ollama: Get up and running with large language models locally. <https://ollama.com/>, 2023.
- [52] NVIDIA Corporation. NVIDIA CUDA Parallel Computing Platform. <https://developer.nvidia.com/cuda-zone>, 2024.
- [53] Tailscale Inc. Tailscale: Zero-config VPN built on WireGuard. <https://tailscale.com/>, 2024.
- [54] Telegram FZ-LLC. Telegram bot API. <https://core.telegram.org/bots/api>, 2024.
- [55] Astral. uv: An extremely fast python package and project manager. <https://github.com/astral-sh/uv>, 2024.
- [56] OpenJS Foundation. Node.js. <https://nodejs.org/>, 2024.
- [57] Charles R. Harris et al. Array programming with NumPy. *Nature*, 585:357–362, 2020.
- [58] The pandas development team. pandas-dev/pandas: Pandas, February 2020.
- [59] Ritchie Vink. Polars: Blazingly fast dataframes in Rust and Python. <https://www.pola.rs/>, 2024.
- [60] Pauli Virtanen et al. SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods*, 17:261–272, 2020.
- [61] Fabian Pedregosa et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [62] Hugging Face. Datasets. <https://huggingface.co/docs/datasets>, 2024.
- [63] John D. Hunter. Matplotlib: A 2d graphics environment. *Computing in Science & Engineering*, 9(3):90–95, 2007.
- [64] Michael L. Waskom. seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60):3021, 2021.
- [65] Mark Towers et al. Gymnasium: A standard api for reinforcement learning. <https://gymnasium.farama.org/>, 2024.
- [66] Antonin Raffin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah Dormann. Stable-Baselines3: Reliable reinforcement learning implementations. <https://github.com/DLR-RM/stable-baselines3>, 2021.
- [67] Antonin Raffin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah Dormann. Stable-baselines3 contrib: Reliable reinforcement learning implementations. <https://github.com/Stable-Baselines-Team/stable-baselines3-contrib>, 2021. Inclou MaskablePPO per a entorns amb action masking.
- [68] Adam Paszke et al. PyTorch: An imperative style, high-performance deep learning library, 2019. <https://pytorch.org/>.
- [69] TensorFlow Team. Tensorboard: Tensorflow’s visualization toolkit. <https://www.tensorflow.org/tensorboard>, 2024.
- [70] Astral. Ruff: An extremely fast python linter and formatter. <https://github.com/astral-sh/ruff>, 2024.
- [71] An Yang, Baosong Yang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Zhou, Chengqiang Xu, Chengyuan Li, Chenze Shao, et al. Qwen2 technical report, 2024.

- [72] Antonin Raffin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah Dormann. Stable-Baselines3: Reliable reinforcement learning implementations. *Journal of Machine Learning Research*, 22(268):1–8, 2021.