

Comparació de paradigmes d'intel·ligència artificial en un joc
estocàstic d'observació parcial: heurístiques, cerca adversària i
aprenentatge per imitació a **gen9randombattle**

Gerard Pascual Fontanilles

Agost 2026

Índex

1	Introducció	4
1.1	Pregunta de recerca	4
1.2	Objectius	5
1.3	Contribucions	5
1.4	Estructura de la memòria	5
2	Marc Teòric i Contextualització	1
2.1	Contextualització de la IA en Jocs	1
2.1.1	Informació perfecta	1
2.1.2	Informació imperfecta i videojocs	1
2.1.3	MDP, POMDP i POSG	1
2.2	Pokémon: El Joc	3
2.2.1	Franquícia i formats	3
2.2.2	Estadístiques	3
2.2.3	Taula de tipus, STAB i categories	5
2.2.4	Velocitat i prioritat	5
2.2.5	Condicions d'estat	5
2.2.6	Estocasticitat	6
2.3	El Format d'Aquest TFM: <code>gen9randombattle</code>	6
2.3.1	Per què Singles Random Battle, i no VGC	6
2.3.2	Generació IX, no un escombrat de nou generacions	6
2.4	L'Entorn Virtual	6
2.4.1	Pokémon Showdown	7
2.4.2	<code>poke-env</code>	7
2.5	Quatre Paradigmes de Decisió (i un de futur)	7
2.5.1	Heurístiques: coneixement com a ablació	7
2.5.2	Minimax 1-ply: la resposta del rival, un torn	7
2.5.3	Information-Set MCTS	7
2.5.4	Imitació / clonatge conductual	8
2.5.5	PPO, com a rerefons (no avaluat aquí)	8
2.6	Estat de l'Art: IA i Pokémon	8
2.6.1	Què no cobria la literatura, i què cobreix aquest TFM	8
2.7	Justificació	9
2.8	Síntesi	9
3	Metodologia: Disseny Experimental	10
3.1	Entorn de Simulació	10
3.1.1	Arquitectura client-servidor de Pokémon Showdown	10
3.1.2	<code>poke-env</code>	11
3.1.3	Què observa l'agent	12
3.1.4	Per què cal paral·lelisme	12

3.2	Per què 10.000 partides (i per què 1.000 per a MCTS)	12
3.2.1	Cada batalla és un Bernoulli	12
3.2.2	El Pokédex no entra a la variància	13
3.2.3	Tres nivells, i només dos entren als Resultats	13
3.2.4	El gauntlet real: 784 CSV	14
3.2.5	Recíprocs i autojoc	14
3.2.6	El WR global no és un Elo humà	14
3.2.7	Ladder humana	14
3.3	Espais formals en Singles	14
3.4	Mètriques	15
3.4.1	Primària: taxa de victòries	15
3.4.2	Secundàries (telemetria)	15
3.4.3	Elo Bradley–Terry	15
3.5	Disseny dels experiments	15
3.6	Fases de desenvolupament (el que s’ha mesurat)	16
4	Entorn de Desenvolupament i Infraestructura de Computació	17
4.1	Evolució de l’arquitectura	17
4.1.1	Fase 1: prototipatge en portàtil	17
4.1.2	Fase 2: workstation	17
4.2	Dependències: uv	17
4.3	Accés remot	18
4.4	Control de versions i qualitat	18
5	Implementació: De l’Orquestrador a les Quatre Famílies	19
5.1	Mapa de software	19
5.2	Arquitectura Master–Worker	19
5.2.1	Per què subprocessos	19
5.2.2	Resume i chunks	20
5.2.3	Reinici de Showdown	20
5.2.4	Esquema CSV	20
5.2.5	Contracte <code>BaseHeuristicv1</code>	21
5.3	Heurístiques <code>v1–v14</code> : ablació de coneixement	21
5.4	Minimax 1-ply <code>v15–v17</code>	22
5.5	IS-MCTS <code>v18–v20</code>	22
5.6	Imitació <code>v21–v22</code>	23
5.6.1	Dades	23
5.6.2	Cap macro	23
5.6.3	Dues piles	23
5.7	Baselines	23
5.8	Bot en línia	23
5.9	PPO (framework, no experiment d’aquesta memòria)	24
6	Resultats	25
6.1	Protocol: com es llegeix un nombre	25
6.1.1	La matriu	25
6.1.2	Per què 10.000, amb fórmula	26
6.1.3	El que el disc conté de veritat	26
6.2	L’escala heurística: tres salts	26
6.2.1	Altiplà <code>v1–v6</code> : el dany no n’hi ha prou	27
6.2.2	Primer salt: <code>v7</code> (i <code>v8/v10</code>)	27
6.2.3	Segon salt: <code>v9</code> / <code>v11</code>	27

6.2.4	Tercer salt: v_{12}	27
6.3	La inversió: $v_{12} \geq v_{13} > v_{14}$	28
6.3.1	On v_{13} encara guanya	29
6.3.2	Per què no supera v_{12} en global	29
6.3.3	Per què v_{14} perd bot-contra-bot (i per què no és un fracàs)	30
6.4	Minimax 1-ply: la resposta del rival, un torn	31
6.4.1	La cerca gairebé no corre	32
6.4.2	$v_{16} \approx v_{15}$: decorar la fulla no allarga l'horitzó	32
6.4.3	v_{17} : l'únic upgrade 1-ply	33
6.5	IS-MCTS: cinc torns de lookahead són un backup	35
6.5.1	Altra vegada: la cerca gairebé no corre	35
6.5.2	Override correlaciona amb perdre	36
6.5.3	PUCT funciona discrepant menys, no veient més lluny	36
6.5.4	Cinc torns golosos no compren el futur	36
6.5.5	Vs el sostre ($n = 1.000$, $IC \sim \pm 3$ pp)	37
6.6	Imitació: el mateix expert, dues execucions	39
6.6.1	On s'asseguren a l'escala	40
6.6.2	v_{21} encara és, sobretot, una heurística	40
6.6.3	Per què falla v_{22} : tres raons estructurals, no «XGBoost és dolent»	41
6.7	Rànquing entre paradigmes	44
6.7.1	Abyssal és el regle extern	45
6.7.2	Elo Bradley–Terry	46
6.8	Ladder pública: v_{14} contra humans	47
6.9	Discussió	48
6.9.1	La moral jeràrquica, tres vegades	48
6.9.2	En aquest POSG, el coneixement supera el clonatge i el lookahead ras	48
6.9.3	El que no es reivindica	48
6.9.4	Limitacions que afecten la lectura	49
7	Conclusions i Treball Futur	50
7.1	El que aquest TFM ha mesurat	50
7.2	Respostes a la pregunta de recerca	50
7.3	Contribucions	50
7.4	Treball futur: PPO contra v_{12}	51
7.5	Tancament	51

Capítol 1

Introducció

La recerca en intel·ligència artificial aplicada a jocs ha passat dels clàssics d'informació perfecta —escacs, Go— a entorns on l'estat no és tot visible i el resultat d'una acció no és determinista. Pokémon, simulat amb precisió de motor a Pokémon Showdown [17] i exposat a Python via *poke-env* [23], concentra aquests dos ingredients: informació oculta (moviments, objecte, habilitat i banc del rival) i estocasticitat de combat (rolls de dany, precisió, crítics, empats de velocitat). El problema no és un MDP clàssic observable; és un **joc estocàstic d'observació parcial** (POSG), proper a un POMDP [27, 14] de dos jugadors a suma zero [32].

Aquest Treball de Final de Màster és un estudi de **comparació de paradigmes**, no un intent de «resoldre Pokémon» ni de construir l'agent més fort possible contra humans. El format és **exclusivament Singles gen9randombattle**. El competitiu oficial de Dobles (VGC) queda fora d'abast —es va eliminar del pla del projecte— i no ocupa cap capítol d'aquesta memòria. Un sol format, un sol simulador, la mateixa matriu d'oponents: la diferència entre agents s'ha d'atribuir a la política, no a un canvi de metagame.

1.1 Pregunta de recerca

La pregunta operativa és:

*En un POSG com **gen9randombattle**, quin paradigma de decisió s'acosta més al sostre de coneixement d'una heurística forta: regles explícites, cerca adversària d'un torn, cerca de Monte Carlo a diversos torns, o clonatge d'experts humans?*

«Sostre de coneixement» no vol dir «el millor agent concebible». Vol dir el millor agent d'aquesta escala heurística, mesurat a la mateixa bateria bot-contra-bot. El gauntlet de 28 agents respon amb un rànquing, no amb una demostració d'optimalitat.

Quatre paradigmes estan mesurats de cap a cap:

1. **Heurístiques v1–v14**: ablació per construcció. Cada versió afegeix una peça que un expert humà anomenaria (dany, hazards, Tera, predicció de set, Yomi).
2. **Minimax 1-ply v15–v17**: maximin analític sobre la resposta predita del rival, sense simulador intern.
3. **Information-Set MCTS v18–v20**: 100 determinacions $\times$ 5 torns de LocalSim.
4. **Imitació v21–v22**: el mateix classificador XGBoost de macro (mou vs canvia), dues piles d'execució (híbrid amb v14 vs clon pur).

El cinquè paradigma, **PPO / MaskablePPO (v23+)**, té framework al repositori (`src/p05_ppo_dr1/`) i **no** entra en aquesta matriu. S'avaluarà a part, gairebé segur *només contra v12* —el sostre bot-contra-bot—, no contra els 28 agents. Aquesta memòria el tracta com a treball futur.

1.2 Objectius

- Formalitzar `gen9randombattle` com a POSG i justificar per què la mida del Pokédex *no* entra a la variància d'una taxa de victòries binomial.
- Construir i documentar una infraestructura de simulació paral·lela (Showdown local + workers aïllats) capaç de 10.000 partides per cel·la.
- Desenvolupar l'escala heurística `v1-v14` com a ablació de coneixement, no com a catorze bots intercanviables.
- Implementar cerca 1-ply i IS-MCTS *a sobre* de `v14`, amb telemetria de si la cerca s'executa i de si discrepa de l'expert.
- Entrenar un macro d'imitació sobre replays humans Elo 1800+ del *mateix* format, i contrastar híbrid vs clon pur.
- Publicar una matriu 28×28 amb protocol honest: $n = 10.000$ per defecte, $n = 1.000$ quan intervé MCTS, ladder humana de `v14` com a validació ecològica (no com a substitut del round-robin).

1.3 Contribucions

1. **Protocol estadístic explícit.** Cada partida és un Bernoulli. Es deriva l'IC del 95%, es justifica $n = 10.000$ com a nivell de tesi ($\pm 0,98$ pp) i $n = 1.000$ com a nivell de validació ($\pm 3,1$ pp), i es documenta per què MCTS no puja a 10k. El nombre de Pokémon de la generació no hi entra.
2. **Escala d'ablació heurística amb tres salts i una inversió.** El dany extra no guanya Random Battles (`v1-v6` $\approx 44-46\%$). La posició (`v7`) i el tempo (`v9`) sí. Les mecàniques natives de Gen 9 (`v12`: Tera, lead de preview, switch-in) són el salt gros: 69,01% global, 59,91% vs Abyssal. La genealogia deia `v14` $\supset$ `v13` $\supset$ `v12`; el gauntlet diu el contrari. Això no és un bug: `v14` està dissenyat per humans.
3. **Mesura de la cerca com a residual, no com a política.** Tant el minimax com l'MCTS s'executen en $\sim 16-18\%$ dels torns (la resta són dreceres de KO). La taxa de *override* de `v14` predice qui guanya: 67% / 71% als no constrenyits, 37% / 19% als híbrids.
4. **Contrast híbrid vs pur en imitació.** El mateix model, el mateix llindar $\tau = 0,5525$. Conservar `v14` dona un jugador de nivell `v9/v11` (58,71%). Treure'l cau per sota de `v1` (33,49%).
5. **Moral jeràrquica transversal.** Apareix tres vegades. El residual que substitueix l'expert perd; el que el conserva és l'única millora; cap no supera `v12`.

No és una contribució d'aquesta passada presentar PPO com a experiment acabat, ni presentar Dobles/VGC com a part del corpus, ni citar 98 partides / 40,8% / Elo 1151 com a mostra final de ladder.

1.4 Estructura de la memòria

- El **Capítol 2** situa el POSG, les mecàniques de Singles que defineixen S , A i Ω , i els quatre paradigmes (heurística, minimax, IS-MCTS, imitació). El RL/PPO s'hi explica com a rerefons del treball futur, no com a resultat.

- El **Capítol 3** descriu Showdown, poke-env, la matriu 28×28 , i —amb fórmula i taula— per què 10.000 i 1.000 partides no són intercanviables.
- El **Capítol 4** documenta el maquinari i el flux de treball remot.
- El **Capítol 5** detalla l'orquestrador master-worker, l'escala v1-v14, el maximin 1-ply, l'IS-MCTS i els dos agents IL.
- El **Capítol 6** és el cos empíric: protocol, escala heurística, inversió, minimax, MCTS, IL, heatmap, Elo, ladder, discussió.
- El **Capítol 7** resumeix el que es pot afirmar i el que queda per PPO vs v12.

Resum

Els jocs d'informació imperfecta i dinàmica estocàstica són un banc de proves natural per comparar paradigmes de presa de decisions. Aquest Treball de Final de Màster no construeix «el millor bot de Pokémon del món», ni pretén resoldre el format oficial de Dobles (VGC): el treball és **exclusivament Singles** al format **gen9randombattle** de Pokémon Showdown. El Dobles es va descartar com a fora d'abast. La pregunta és quina família de polítiques s'acosta més al sostre de coneixement d'una heurística forta en un joc estocàstic parcialment observable (POSG): regles explícites, cerca adversària d'un torn, cerca de Monte Carlo a cinc torns, o clonatge d'experts humans.

S'avaluen 28 agents en una matriu dirigida 28×28 (784 fitxers CSV). Cada batalla és un assaig de Bernoulli. Amb $n = 10.000$ partides per cel·la, l'interval del 95% en el cas $p = 0,5$ és $\pm 0,98$ punts percentuals i es detecten buits $\gtrsim 2$ pp. Qualsevol cel·la on intervé Information-Set MCTS (v18–v20) es queda en $n = 1.000$ ($\pm 3,1$ pp) perquè 100 rollouts de LocalSim per decisió són ordres de magnitud més lents. El PPO (v23+) existeix com a framework i **no** forma part d'aquest gauntlet; es reserva a una avaluació posterior, gairebé segur només contra v12.

El resultat central és no lineal. L'escala heurística v1–v14 té tres salts (posició, tempo, mecàniques de Gen 9) i una inversió: $v12 (69,01\%) \geq v13 (67,63\%) > v14 (62,03\%)$ sobre 253.000 partides. v12 és el primer agent intern que supera Abyssal (59,91%, $n = 10.000$). Ni el minimax 1-ply, ni l'IS-MCTS 5-ply, ni l'imitació superen aquest sostre. En cada família apareix la mateixa moral jeràrquica: el residual que *substitueix* v14 (v15/v16, v18/v19, v22) el sobreescrui i perd més; l'híbrid que el *conserva* (v17, v20, v21) és l'única variant que mou la taxa de victòries — i encara s'asseu al nivell v9/v11. La ladder pública de v14 contra humans (431 partides, 39,44% $\pm 4,6$ pp) valida ecològicament l'agent orientat a persones; no inverteix el rànquing bot-contra-bot.

Paraules clau: POSG, heurístiques, minimax 1-ply, Information-Set MCTS, aprenentatge per imitació, **gen9randombattle**, Pokémon Showdown.

Capítol 2

Marc Teòric i Contextualització

Aquest capítol estableix els fonaments necessaris per llegir la comparació de paradigmes. S'introdueix la IA en jocs, es formalitza Pokémon Singles com a POSG, es detallen les mecàniques que defineixen els espais S , A i Ω , es presenta el format `gen9randombattle` —l'únic d'aquest TFM—, es revisen heurístiques, minimax, IS-MCTS i imitació, i es posiciona el treball respecte la literatura. El Reinforcement Learning (PPO) s'explica com a rerefons del treball futur: el framework existeix, l'experiment no forma part del gauntlet d'aquesta memòria.

2.1 Contextualització de la IA en Jocs

2.1.1 Informació perfecta

Els jocs han estat el banc de proves clàssic de la IA. En informació perfecta, tot l'estat és visible. **Deep Blue** (IBM, 1997) va derrotar Kasparov amb Minimax i esporgada alfa-beta [8, 15]. **AlphaGo** [26] i **AlphaZero** [25] van combinar MCTS [5] amb xarxes neuronals i *self-play* per superar el factor de ramificació del Go (~ 250 moviments legals per torn davant ~ 35 als escacs).

2.1.2 Informació imperfecta i videojocs

El salt posterior és a entorns amb estat ocult, accions simultànies i horitzons llargs. **AlphaStar** [31] va assolir Gran Mestre a *StarCraft II*. **OpenAI Five** [2] va cooperar en *Dota 2*. En pòquer, **Libratus** [3] i **Pluribus** [4] van superar professionals en *No-Limit Texas Hold'em*, on les cartes ocultes són l'estratègia.

La distinció operativa:

- **Informació perfecta** (escacs, Go): l'estat complet és comú. La incertesa, si n'hi ha, és només sobre el que farà l'oponent.
- **Informació imperfecta** (pòquer, StarCraft, Pokémon): part de l'estat roman oculta. Cal un *belief* sobre sets, objectes i banc.

Si, a més, $T(s' | s, a)$ no és determinista —rolls de dany, precisió, crítics— l'entorn és **estocàstic**. La combinació és el que fa Pokémon un laboratori, no un trencaclosques resoluble per força bruta.

2.1.3 MDP, POMDP i POSG

Un MDP [30] és la tupla (S, A, T, R, γ) : estats, accions, transició, recompensa i descompte. La política $\pi(a | s)$ maximitza el retorn esperat. Si l'agent no observa s sinó una observació $o \in \Omega$ via $O(o | s', a)$, el model és un POMDP [27, 14]: cal un *belief state*.

Una batalla de Pokémon de dos jugadors no és un POMDP d'un sol agent contra la natura. L'oponent també tria accions, sovint alhora. El marc més honest és un **joc estocàstic d'observació parcial** (POSG): dos jugadors, transicions estocàstiques, observacions privades, suma zero al terminal (un guanya, l'altre perd; els empats són rareses de timer que el protocol de Showdown resol). En la pràctica, cada agent tracta l'oponent com a part de T i manté un belief sobre el set rival. Això és el que fan les heurístiques amb la base de sets de Showdown, el minimax amb respostes predites, i l'MCTS amb determinització.

La Figura 2.1 recorda la diferència MDP / POMDP. El POSG afegeix el segon decisor.




Figura 2.1: MDP (esquerra) versus POMDP (dreta). En Pokémon Singles l'agent no veu s complet —moviments, objecte, EVs, banc— i l'oponent decideix alhora: POSG, no control òptim d'un sol agent.

Instanciació a `gen9randombattle`

Component	Instanciació a <code>Singles gen9randombattle</code>
S	Sis Pokémon per bàndol (espècie, HP, set, objecte, habilitat, boosts, status), clima, hazards, Tera gastat, torn. $ S $ és astronòmic; no el cobrim.
A	Fins a 4 moviments + fins a 5 canvis, opcionalment amb Teracristal·lització. $ A \leq 9$ per torn, dinàmic (PP, faint, Choice lock, encore).
T	Motor de Showdown: dany amb roll $[0,85,1,00]$, STAB, Taula de Tipus, prioritat, velocitat, secundaris.
R	+1 victòria, 0 derrota (o Bernoulli $W \in \{0,1\}$). Sense reward shaping en el gauntlet bot-contra-bot: la mètrica és la taxa de victòries.
Ω	Equip propi complet; rival: espècie i HP% dels revelats, moviments ja usats, side conditions. EVs, Nature, objecte i moviments no revelats ocults. En Random Battle el <i>pool</i> de sets és conegut a priori, cosa que fa el belief tractable.

Taula 2.1: Mapatge POSG/POMDP a `Singles gen9randombattle`. El TFM no estudia Dobles: $|A|$ no és el producte cartesià de dues unitats.

2.2 Pokémon: El Joc

Abans dels algorismes cal el domini. Les regles de combat —stats, tipus, velocitat, status, atzar— són S , A i Ω .

2.2.1 Franquícia i formats

Pokémon [6] és una franquícia de batalles per torns (Figura 2.2). Hi ha dos formats principals de combat: **Singles** (un Pokémon actiu per bàndol) i **Doubles** (dos). El circuit oficial VGC és Dobles. **Aquest TFM és Singles `gen9randombattle` i prou**; el Dobles es va descartar del pla i no s’hi justifica en pàgines.



Figura 2.2: Logotip commemoratiu del 30è aniversari de la franquícia Pokémon.

2.2.2 Estadístiques

Sis stats: HP, Atac, Defensa, Atac Especial, Defensa Especial, Velocitat. La Figura 2.3 mostra Pikachu com a exemple ofensiu i fràgil.



Figura 2.3: Estadístiques base de Pikachu: velocitat i atac especial alts, defenses baixes.

Tres modificadors, tots **ocults** per a l'oponent en un combat:

1. **IVs** $\in [0, 31]$. En competitiu solen ser 31.
2. **EVs**: 510 punts, màxim 252 per stat. Defineixen el rol (sweeper, tank, scarfer).
3. **Nature**: +10% / -10% en un parell de stats.

	Base	IVs	EVs	Total
HP	35	1	83	201
Attack	55	1	122	146
Defense	40	1	59	100
Sp. Atk	50	1	171	148
Sp. Def	50	1	67	122
Speed	90	1	142	221

Nature: Hardy
 Ability: (other)
 Item: (none)
 Status: Healthy

Current HP: 201 / 201 (100%) Dynamax

Figura 2.4: IVs, EVs i Nature sobre les stats base.

Fórmules oficials [7], amb L el nivell:

$$\text{Stat} = \left\lfloor \left(\frac{(2 \times \text{Base} + \text{IV} + \lfloor \text{EV}/4 \rfloor) \times L}{100} + 5 \right) \times \text{Nature} \right\rfloor \quad (2.1)$$

$$HP = \left\lfloor \frac{(2 \times \text{Base} + IV + \lfloor EV/4 \rfloor) \times L}{100} \right\rfloor + L + 10 \quad (2.2)$$

A Showdown Random Battle els Pokémon arriben amb un set del servidor (nivell, EVs, moviments) ja fixat. L'agent no construeix l'equip: el *juga*.

2.2.3 Taula de tipus, STAB i categories

Divuit tipus, matriu de multiplicadors $\times 2$, $\times 1/2$, $\times 0$ (Taula 2.2). El doble tipus combina factors ($\times 4$ o $\times 0,25$). STAB (*Same Type Attack Bonus*) és $\times 1,5$ si l'atac coincideix amb un tipus de l'usuari.

Taula 2.2: Matriu de la Taula de Tipus (Gen. VI–IX). Files = tipus de l'atac, columnes = tipus del defensor. **2** = Super Effective ($\times 2$), **½** = Not Very Effective ($\times 0,5$), **0** = Immunitat ($\times 0$), buit = Neutral ($\times 1$).

	NOR	FOC	AIG	PLA	ELE	GEL	LLU	VER	TER	VOL	PSI	INS	ROC	FAN	DRA	FOS	ACE	FAD
NOR													½	0			½	
FOC		½	½	2		2						2	½		½		2	
AIG		2	½	½					2				2		½			
PLA		½	2	½				½	2	½		½	2		½		½	
ELE			2	½	½				0	2					½			
GEL		½	½	2		½			2	2					2		½	
LLU	2					2		½		½	½	½	2	0		2	2	½
VER				2				½	½				½	½			0	2
TER		2		½	2			2		0		½	2				2	
VOL				2	½		2					2	½				½	
PSI							2	2			½					0	½	
INS		½		2			½	½		½	2			½		2	½	½
ROC		2				2	½		½	2		2					½	
FAN	0										2			2		½		
DRA															2		½	0
FOS							½				2			2		½		½
ACE		½	½		½	2							2				½	2
FAD		½					2	½							2	2	½	

Categories: físic (Atac vs Defensa), especial (Atac Esp. vs Defensa Esp.), status (sense dany directe: hazards, boosts, Protect, Toxic).

2.2.4 Velocitat i prioritat

Sense modificadors, ataca primer qui té més Velocitat. La **prioritat** del moviment (de -7 a $+5$) sobreesciu la velocitat: *Protect* ($+4$) va gairebé sempre primer; *Trick Room* (-7) va últim i inverteix l'ordre durant cinc torns. Un empat de velocitat és una moneda $1/2$. Les heurístiques i el minimax resolen velocitat i prioritat de forma analítica; l'MCTS ho mostreja al rollout.

2.2.5 Condicions d'estat

Estat	Efecte	Mecànica
Burn	↓ 50% Atac físic	1/16 HP per torn.
Paralysis	↓ 50% Velocitat (Gen 7+)	25% de no actuar.
Poison / Toxic	—	1/8 per torn, o dany creixent.
Sleep	—	1–3 torns sense actuar.
Freeze	—	Sense actuar; 20% de desgel per torn.

Taula 2.3: Status principals. Un agent pot preferir cremar un físic abans que atacar.

2.2.6 Estocasticitat

Tres fonts que cap política elimina:

1. **Damage roll** uniforme en $[0,85,1,00]$: un KO «segur» al roll alt pot fallar al baix. **v14** calcula 16 rolls per decidir si un KO és garantit.
2. **Accuracy**: *Hydro Pump* té 80%. L'esperança no és el dany nominal.
3. **Crític** base $1/24$, $\times 1,5$ i ignora boosts defensius [28].

Això és el motiu pel qual $n = 100$ partides no és un resultat: la variància per partida és alta, i la mètrica que agrega tot és el Bernoulli de victòria.

2.3 El Format d'Aquest TFM: **gen9randombattle**

2.3.1 Per què Singles Random Battle, i no VGC

VGC és el circuit oficial: Dobles, Bring 6 / Pick 4, teambuilding, regulacions per temporada. És un POSG encara més dur ($|A|$ combinatori, Protect, atacs spread). **No és el corpus d'aquesta tesi.** El pla del projecte va eliminar les heurístiques de Dobles com a fora d'abast. Un format, una pregunta, una matriu.

gen9randombattle (Smogon / Showdown) assigna a cada jugador un equip aleatori de sis Pokémon del pool de la Generació IX, amb sets (moviments, objecte, habilitat, Tera) trets d'una base pública. Propietats útils per a recerca:

- **Sense teambuilding.** L'habilitat que es mesura és la decisió en combat, no la construcció d'equip. Dos agents reben equips comparables en llei; amb n gran, l'avantatge d'equip s'atenuï.
- **Team preview.** Es veuen les sis espècies rivals abans del torn 1. **v12** ordena el lead per matchup mitjà; els baselines d'Abyssal no.
- **Sets d'un pool conegut.** El belief és una mescla sobre files de `sets.json`, no sobre tot l'espai OU. Això fa viable la predicció de **v13** i la determinització de l'MCTS.
- **Teracristal · lització** (Gen 9): un cop per batalla, canvi de tipus. És la mecànica que **v1–v11** no tenen i que **v12** usa gairebé cada partida.
- **Ladder pública.** El mateix format es juga contra humans a `play.pokemons showdown.com`. **v14** s'hi ha connectat (Capítol 6); això no substitueix el round-robin.

El metagame OU de Smogon [29] és un altre joc (equips portats, stall, weather). Entrenar imitació en OU i avaluar en Random Battle va ser un error de pipeline (WR de l'ordre del 2%); el dataset d'aquest TFM és Elo 1800+ del *mateix* format.

2.3.2 Generació IX, no un escombrat de nou generacions

El repositori *pot* llançar `gen1randombattle ... gen9randombattle`. El gauntlet publicat aquí és **Gen 9**. La mida del pool (151 vs 1.025 espècies) no canvia la fórmula $\text{Var}(\hat{p}) = p(1-p)/n$. Mantenir el mateix n entre gens seria una elecció metodològica, no un requisit de cobertura combinatòria. No es reivindica un resultat cross-generacional en aquesta memòria.

2.4 L'Entorn Virtual

La consola no és instrumentable. La comunitat ha construït Showdown i poke-env.

2.4.1 Pokémon Showdown

Showdown [17] replica el motor oficial (dany, tipus, items, habilitats) en Node.js/TypeScript, validat durant anys per Smogon. Per a aquest TFM:

1. Precisió de mecàniques: T no l’hem reescrit.
2. Mode *headless* local, moltes instàncies, ports 8000+.
3. El mateix servidor serveix ladder pública i el gauntlet local.

2.4.2 poke-env

poke-env [23] tradueix el WebSocket a objectes Python (`Battle`, `Pokemon`, `Move`) i exposa `Player.choose_move`. El pin del projecte és **0.11.x**: milions de partides hi han corregut; 0.15 trenca l’API. Pokechamp porta un fork més antic amb `LocalSim`, necessari per a l’MCTS. El Capítol 3 detalla el protocol; el Capítol 5, l’orquestrador.

2.5 Quatre Paradigmes de Decisió (i un de futur)

La tesi compara polítiques, no «si la IA funciona». Cada família té una hipòtesi falsable.

2.5.1 Heurístiques: coneixement com a ablació

Una heurística no aprèn. A cada decisió puntua accions legals amb una fórmula fixa i tria l’argmax. L’escala $v1-v14$ és una **ablació per construcció**: si afegir hazards mou el WR i afegir un decimal extra a la fórmula de dany no, el coneixement útil és posicional, no aritmètic. Això és el que un sol «bot expert» no permetria dir.

L’herència no és una cadena única (Capítol 5): $v1-v3-v6$ és dany i pivot; $v7$ reescriu l’estratègia; $v12$ afegeix Gen 9; $v14$ afegeix modelatge d’humans. La genealogia $v14 \supset v13 \supset v12$ és de *codi*, no de WR.

2.5.2 Minimax 1-ply: la resposta del rival, un torn

Minimax [15] assigna a cada estat el valor maximin. En Pokémon les accions són *simultànies*: el model honest d’un torn és una matriu $|A_{me}| \times |A_{opp}|$, no un arbre d’alternança perfecta. Amb $|A| \leq 9$, la matriu té ≤ 81 cel·les. A 2-ply serien $81^2 = 6561$ i el calculador de 16 rolls de $v14$ esclata el temps de torn (Capítol 5). Per això $v15-v17$ són **1-ply** i analítics: dany exacte, velocitat i KO resolts sense `LocalSim`. La fulla és aversió al risc

$$V = HP_{me} - 1,5 HP_{opp} + \text{bonificacions}. \quad (2.3)$$

El factor 1,5 sobre el dany rival és una hipòtesi, no un teorema: els resultats mostren que domina els bonuses de setup de $v16$.

Limitació estructural. Un horitzó d’un torn no valora Dragon Dance ni Stealth Rock. Posar +0,3 a la fulla no allarga l’horitzó; només decora el maximin.

2.5.3 Information-Set MCTS

MCTS [5] mostreja en lloc d’enumerar. Les quatre fases clàssiques —selecció (UCB1 o PUCT), expansió, simulació, retropropagació— s’apliquen aquí a un **conjunt d’informació** [10]: cada simulació *determiniza* el rival (set de la DB de Showdown compatible amb el revelat) i fa un rollout de 5 torns amb `LocalSim`. El fill arrel amb més visites és l’acció.

UCB1:

$$\text{UCB1}(j) = \bar{X}_j + C \sqrt{\frac{\ln N}{n_j}}, \quad C = 1,4. \quad (2.4)$$

PUCT (com AlphaGo) afegeix un prior $\pi(a)$ —aquí, 0,70 sobre l’acció de v14 a v20— que concentra les 100 visites.

La hipòtesi de l’MCTS era: cinc torns de lookahead valoren payoffs retardats que l’1-ply no veu. La telemetria (Capítol 6) la falsifica a aquest pressupost: setup i hazards queden a nivell v14, no v12.

2.5.4 Imitació / clonatge conductual

L’aprenentatge supervisat sobre traces d’experts (*behavioral cloning*) estima $\pi_E(a \mid o)$. El problema clàssic és el **biaix d’exposició**: una acció fora del suport de π_E porta a estats que l’expert no va visitar, i l’error es compon [21]. En Pokémon s’hi afegeix un problema de **semàntica d’acció**: el slot 0 no és una classe estable (Stealth Rock en un lead, Hydro Pump en el següent). Per això el cap d’aquest TFM predice només {move, switch}, no l’índex del moviment.

XGBoost [9] és el classificador: 1.150 features, $\sim 1,12$ milions de torns Elo 1800+, `GroupShuffleSplit` per `battle_id`. El llindar calibrat és $\tau = 0,5525$. v21 executa amb v14; v22 executa amb un segon XGBoost i un banc contrafactual. Sense v22 no es pot dir que l’híbrid sigui necessari; sense v21 no es pot dir que el timing humà serveixi de res.

El `ml_baseline` de tres features i execució uniforme **no** és al gauntlet: era el diagnòstic que «predir mou/canvia i després triar a l’atzar» cau a $\sim 8\text{--}16\%$ WR.

2.5.5 PPO, com a rerefons (no avaluat aquí)

El Reinforcement Learning [30] aprèn π per interacció. PPO [24] recorre l’objectiu amb *clipping*

$$L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right], \quad (2.5)$$

útil en entorns estocàstics on un crític afortunat no ha de destruir la política. L’*action masking* [13, 20] anul·la logits il·legals. El *reward shaping* [19] i el currículum [1] són l’estàndard per recompenses terminals escasses.

Tot això és al repositori (v23+, Gymnasium, MaskablePPO). **No hi ha nombres de PPO en aquesta memòria.** L’avaluació prevista és separada i, gairebé segur, només contra v12. DQN [18] i els LLM [33] es mencionen com a context, no com a agents del gauntlet. Pokechamp [16] aporta Abyssal i LocalSim, no un agent LLM a la matriu de 28.

2.6 Estat de l’Art: IA i Pokémon

poke-env [23, 22] va obrir el domini a Gym. Els primers bots són heurístics; la llibreria porta `RandomPlayer`, `MaxBasePowerPlayer` i `SimpleHeuristicsPlayer`. Smogon [29] és el corpus expert de metagame i calculadores de dany.

Huang et al. [12] entrenen DQN amb atenció sobre Showdown. Pokechamp [16] (ICML 2025) combina LLM i minimax d’un pas i situa agents de llenguatge al nivell expert en Singles; el cost d’inferència els fa inviables com a cel·la de 10.000 partides en aquest projecte. El pòquer [3, 4] i StarCraft [31] informen la gestió d’informació oculta, no es transfereixen com a codi.

2.6.1 Què no cobria la literatura, i què cobreix aquest TFM

1. **Una matriu comuna de paradigmes a n de tesi.** Heurística, 1-ply, IS-MCTS i IL, mateixos oponents, 10k/1k documentats, telemetria d’override. No un xampió aïllat.

2. **Ablació de coneixement, no un únic expert.** Catorze versions per dir *quina* regla mou el WR.
3. **Híbrid vs pur** en cerca i en imitació, amb el mateix professor v14.

No es reivindica haver resolt Dobles, ni haver publicat PPO, ni haver superat humans a la ladder (el pilot de v14 és 39,4%).

2.7 Justificació

Pokémon Singles Random Battle concentra, en un motor obert:

- Estocasticitat irreducible (roll, accuracy, crític, speed tie).
- Informació oculta amb un pool de sets *conegut* (belief tractable).
- Decisions simultànies.
- $|A|$ discret i emmascarable (≤ 9).
- Suma zero al terminal.
- Ladder humana al mateix format.

L'objectiu no és un bot imbatible. És mesurar, amb n honest, si la cerca poc profunda i el clonatge de macros humans superen —o ni tan sols igualen— una heurística que ja sap fer KO, Tera i switch-in. El capítol de resultats respon: no ho fan, tret que es quedin a prop de v14; i ni així arriben a v12.

2.8 Síntesi

S'ha fixat el marc: POSG, Singles **gen9randombattle**, quatre paradigmes mesurats i PPO com a continuació. Les mecàniques de tipus, velocitat i atzar defineixen per què la mètrica és un Bernoulli i per què calen 10.000 partides. El capítol següent tradueix això a protocol: Showdown, workers, n , recíprocs i Elo.

Capítol 3

Metodologia: Disseny Experimental

Aquest capítol fixa l'entorn, la matriu, les mètriques i —amb fórmula, no amb una cita d'una línia— per què el gauntlet usa 10.000 partides per cel·la i 1.000 quan intervé MCTS. Sense aquest protocol, els nombres del Capítol 6 no es poden llegir.

3.1 Entorn de Simulació

3.1.1 Arquitectura client-servidor de Pokémon Showdown

Showdown [17] és una aplicació Node.js amb protocol WebSocket. En recerca s'executa localment:

```
node pokemon-showdown start --port 8000 --no-security
```

`--no-security` desactiva autenticació. Cada instància ocupa un port TCP i guarda l'estat de les batalles en RAM. Els missatges són text amb delimitador `|`:

```
|move|p1a: Pikachu|Thunderbolt|p2a: Gyarados  
|-damage|p2a: Gyarados|23/100  
|-supereffective|p2a: Gyarados  
|turn|5
```

El missatge crític per a l'agent és `|request|`, un JSON amb moviments legals, PP, stats *pròpies* i HP. Les stats i l'objecte del rival **no** hi són: això és $\Omega \subset S$.

L'agent respon amb `/choose move 1`, `/choose switch 4` o `/choose move 1 terastallize`. El servidor resol el torn de forma atòmica (prioritat, velocitat, dany, secundaris) i emet el log.

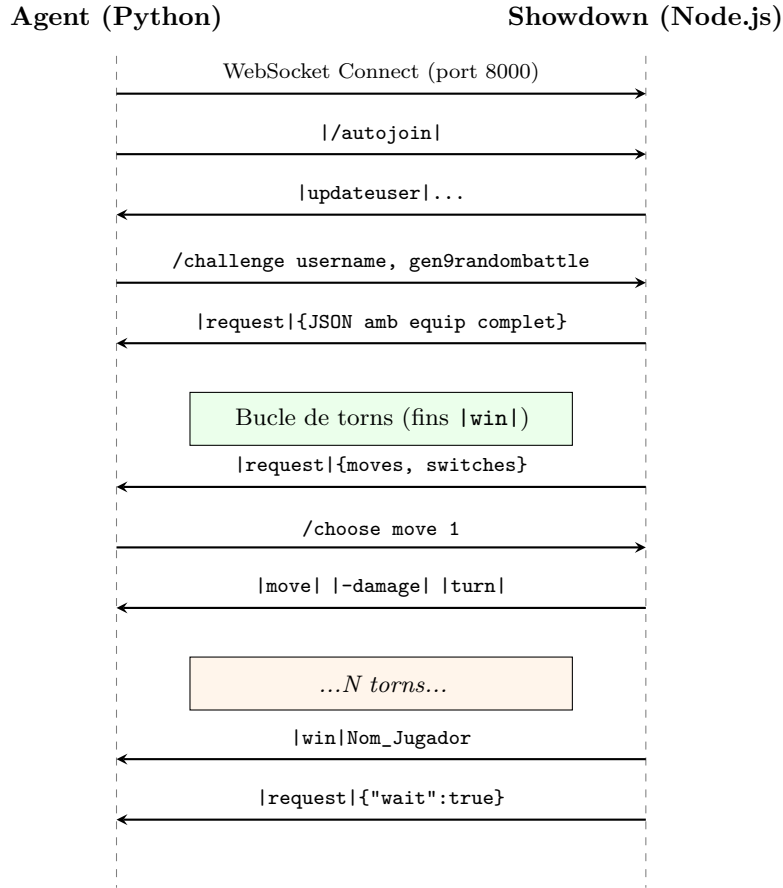


Figura 3.1: Protocol WebSocket d'una batalla local. L'estat viu a la RAM del procés Node.js; el servidor és determinista donats inputs i llavor RNG.

Latència típica d'un torn heurístic en local: < 5 ms. MCTS, amb 100 LocalSim, és un altre ordre de magnitud (secció 3.2).

3.1.2 poke-env

poke-env [23] encapsula el protocol. El desenvolupador implementa `choose_move(battle)`. Internament: `parser` $\rightarrow$ objecte `Battle` $\rightarrow$ ordre `/choose ...`.

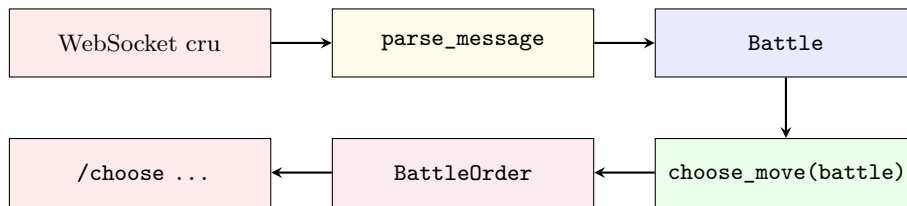


Figura 3.2: Pipeline intern de poke-env.

Concurrencia: `asyncio` i `max_concurrent_battles`. Pin **0.11.x**. El fork de Pokechamp s'injecta només quan cal LocalSim (MCTS); el motor de mecàniques continua sent el Node.js de Showdown. `strict_battle_tracking=False` evita que un desajust de protocol mati un worker de 10k.

3.1.3 Què observa l'agent

Visible	Detall
Equip propi	HP, stats, item, ability, boosts, PP, status.
Rival actiu	Espècie, HP%, tipus, moviments <i>ja usats</i> , status visible.
Preview	Les sis espècies rivals (no el set).
Camp	Clima, terreny, hazards, pantalles, Trick Room.
Ocult	EVs/IVs/Nature rivals, item i ability fins que es revelen, moviments no usats, ordre exacte del banc.

Taula 3.1: Observació per torn. El pool de sets de Random Battle redueix l'ocult a una mescla discreta, no a OU lliure.

3.1.4 Per què cal paral·lelisme

Un sol procés Node.js satura cap a 20–30 batalles simultànies i acumula memòria (V8 no allibera del tot l'*old generation*). El patró és **master-worker**: N servidors, N subprocessos Python, ports exclusius, CSV a disc cada chunk. Detall al Capítol 5.




Figura 3.3: Master-worker: aïllament de procés, un Showdown per worker, persistència incremental.

3.2 Per què 10.000 partides (i per què 1.000 per a MCTS)

Aquesta secció és el cor metodològic. No n'hi ha prou amb «hem fet moltes partides». Cal dir què es pot afirmar i què és soroll.

3.2.1 Cada batalla és un Bernoulli

El resultat que entra al WR és binari: $W_i \in \{0, 1\}$, victòria de l'agent fila. Sigui $p = \mathbb{E}[W]$. L'estimador $\hat{p} = n^{-1} \sum W_i$ té

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n} \leq \frac{1}{4n}. \quad (3.1)$$

L'interval de Wald al 95% és

$$\hat{p} \pm 1,96 \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}. \quad (3.2)$$

El cas pitjor (màxima variància) és $p = 0,5$:

$$1,96 \sqrt{\frac{0,25}{n}}. \quad (3.3)$$

Substitució directa:

- $n = 10.000$: $1,96 \sqrt{0,25/10.000} = 1,96 \times 0,005 = 0,0098 \rightarrow \pm 0,98$ punts percentuals.

- $n = 1.000$: $1,96\sqrt{0,25/1.000} \approx 0,0310 \rightarrow \pm 3,10$ pp.
- $n = 100$: $\approx \pm 10$ pp.

Taula 3.2: Amplada de l'interval de confiança del 95% per a una proporció binomial en el cas pitjor ($p = 0,5$). Fórmula: $\pm 1,96\sqrt{0,25/n}$. El llindar de detecció és l'ordre de magnitud de la diferència que es pot distingir de manera fiable entre dos agents independents.

n (partides)	IC 95%	Detecta buits $\gtrsim$	Ús en aquest TFM
100	± 10 pp	20 pp	Prova de fum (desenvolupament); mai un resultat.
1.000	$\pm 3,10$ pp	6 pp	Nivell de validació. Totes les cel·les amb v18/v19/v20.
5.000	$\pm 1,39$ pp	2,8 pp	(no usat)
10.000	$\pm 0,98$ pp	2 pp	Nivell de publicació. Cel·la per defecte del gauntlet.
20.000	$\pm 0,69$ pp	1,4 pp	(no usat; cost doble per un guany marginal)

Un buit observat de 2 pp entre dos agents independents a 10k és de l'ordre de dos errors estàndard: detectable. El mateix buit a 1k està *dins* de l'IC. Un buit de 1 pp a 10k (p. ex. v1 vs v2) és compatible amb igualtat; que siguin equivalents és un resultat, no un fracàs del protocol.

Per a una taxa global sobre 253.000 partides, Wilson / Wald dona $\approx \pm 0,19$ pp. Això fa visibles salts de 0,5 pp (com v16 vs v15) que *no* importen tàcticament. El text distingeix «detectable a 253k» de «rellevant».

3.2.2 El Pokédex no entra a la variància

La intuïció «Gen 9 té 1.025 Pokémon, calen més partides que a Gen 1» és falsa per a un WR. $\text{Var}(\hat{p})$ depèn de p i n , no de $|Pokedex|$, no del nombre de sets, no de si hi ha Tera. L'espai d'equips $C(n, 6)$ és

$$\text{Gen 1: } \sim 1,5 \times 10^{10} \quad \cdot \quad \text{Gen 9: } \sim 1,6 \times 10^{15}.$$

Ni 10.000 ni 253.000 «cobreixen» l'espai. No ho pretén. El que es cobreix és l'esperança de W sota la llei amb què Showdown mostreja equips i RNG. La llei dels grans nombres i el TCL garanteixen la convergència de $\hat{p}$, no un cens de combinacions.

Les fonts de variància per partida —equip, crit, miss, speed tie, roll— queden absorbides pel Bernoulli. No cal modelar-les una a una per declarar un IC sobre el WR.

El mateix n a totes les generacions seria una elecció de *comparabilitat*, no de cobertura. Aquest TFM publica Gen 9.

3.2.3 Tres nivells, i només dos entren als Resultats

Durant el desenvolupament s'ha usat una escala de tres pisos. **Només el segon i el tercer apareixen com a nombres de tesi**, i el segon amb l'etiqueta explícita de validació.

Prova de fum ($n = 100$). Comprova que el codi no peti, que Tera dispari, que el WR no és 5% per un bug. IC ± 10 pp. Una anècdota de «v13 va fer 9/10 contra v12» **no és un resultat**. El gauntlet la desmenteix (48,85%). El text la cita només com a advertiment.

Validació ($n = 1.000$). IC $\pm 3,1$ pp; detecta buits $\gtrsim 6$ pp. És el pis de l'MCTS. No és el pis de publicació per a una disputa de 2 pp.

Tesi ($n = 10.000$). IC $\pm 0,98$ pp; detecta $\gtrsim 2$ pp. Cel·la per defecte.

3.2.4 El gauntlet real: 784 CSV

Directori canònic: `data/benchmarks/all_10k/gen9randombattle`.

- 28 agents (Taula 6.1 al capítol de resultats): 6 baselines, v1–v14, v15–v17, v18–v20, v21, v22.
- Matriu dirigida $28 \times 28 = 784$ fitxers `{agent}_vs_{opponent}.csv`. Fila = *nosaltres* (heuristic al CSV).
- **Cel · la per defecte: 10.000 partides.**
- **Excepció: si qualsevol dels dos bàndols és v18, v19 o v20, $n = 1.000$.** Motiu: IS-MCTS fa 100 rollouts de 5 torns per decisió de cerca. El cost per partida és d'un a dos ordres per sobre d'una heurística. 1.000 és el pis de validació, no una «10k a mitges».
- Pool per a heurística / minimax / IL com a nosaltres: $25 \times 10.000 + 3 \times 1.000 = \mathbf{253.000}$ partides. IC global $\approx \pm 0,19$ pp; IC d'una cel · la 10k $\pm 0,98$ pp.
- Pool MCTS com a nosaltres: $28 \times 1.000 = \mathbf{28.000}$. IC global $\approx \pm 0,58$ pp; IC de cel · la $\pm 3,1$ pp. Un buit < 3 pp en una cel · la MCTS és soroll.

Prohibició metodològica. No es mesclen un WR global de 28k (MCTS) i un de 253k (resta) com si fossin la mateixa estimació. Per ordenar v20 contra v17 es llegeix la *cel · la* (v17 vs v20 = 50,4% a 1k; v20 vs v17 = 55,8% a 1k; IC $\pm 3,1$). El rànding global és una brúixola, no un veredict de 0,8 pp.

3.2.5 Recíprocs i autojoc

Pokémon no és simètric en seient (preview, RNG, qui és **p1**). Per això existeixen **A_vs_B.csv** i **B_vs_A.csv** independents. La suma de WR ha de ser $\sim 100\%$ (típicament 99,3–100,9). L'autojoc ha de ser $\sim 50\%$ (49,3–50,5 a les heurístiques). Si fallés, el seient o el CSV estarien trencats. Al gauntlet, no fallen.

3.2.6 El WR global no és un Elo humà

La mitjana sobre 28 oponents **inclou random i max_power**. Tothom hi té un 90–98%. El 69% de v12 no és «nivell humà 69%». Les comparacions que discriminen són: vs Abyssal, vs Simple Heuristic, vs v12/v13/v14, vs v21. L'Elo Bradley–Terry (secció 3.4) repondrà per qualitat d'oponent; encara així, **random** hi és l'àncora 1000, no un jugador de ladder.

3.2.7 Ladder humana

Protocol separat, no una fila de la matriu. v14 a la ladder pública, 431 partides, Capítol 6. $n = 431$ té IC $\pm 4,6$ pp: serveix per dir «no som al 50% contra humans», no per invertir v12 vs v14.

3.3 Espais formals en Singles

$|A| \leq 9$ per torn, dinàmic. No hi ha producte cartesià de Dobles. L'observació és el JSON de **request** més l'historial de moviments revelats. El vector de 238 dimensions del wrapper PPO existeix al framework i **no** s'usa al gauntlet d'aquesta memòria: els agents mesurats decideixen sobre l'objecte **Battle** o sobre 1.150 features tabulars (IL).

3.4 Mètriques

3.4.1 Primària: taxa de victòries

$\widehat{WR} = \hat{p}$. Interpretació qualitativa *només* després de l'IC:

- $\sim 50\%$ a 10k: no hi ha avantatge detectable.
- 55–60% vs un baseline fort (Abyssal): avantatge real.
- 98% vs **random**: no informa de res entre experts.
- 100%: impossible sota rolls de dany.

3.4.2 Secundàries (telemetry)

El CSV de batalla porta identitat, HP final, canvis voluntaris vs forçats, crits/miss/SE, i comptadors de paradigma:

- Heurístiques: `hazard_sets`, `setup_uses`, `ko_checks`, `matchup_switches`, `terastallized`.
Forat d'esquema: `setup/hazards` queden a 0 per a v7/v8/v10; no s'interpreta com a «mai posen roques».
- Cerca: `search_moves`, `search_switches`, `search_diff` (l'acció jugada $\neq$ la sonda v14). La taxa d'*override* és `search_diff/(search_moves + search_switches)` entre els torns que la cerca ha disparat.
- IL: `xgb_stays`, `xgb_switches`, `ko_guards`, `loop_guards`.

Aquestes columnes són el que permet dir «la cerca només corre el 16% dels torns» en lloc de «és un agent de cerca».

3.4.3 Elo Bradley–Terry

No és l'Elo de ladder de Showdown. És un model de força sobre la matriu dirigida, àncora **random** = 1000, ambdós seients [11]. MCTS hi té menys partides (56k vs 506k). És un resum, no una substitució de les cel·les.

3.5 Disseny dels experiments

La taxonomia completa dels 28 agents (IDs, paradigma, una frase) és la Taula 6.1 al capítol de resultats. Format únic: `gen9randombattle`. Sense Dobles. Sense PPO a la matriu.

Cada parella (A, B) genera dos fitxers. Equips aleatoris del servidor. Ordre de seient fixat pel nom del fitxer, no barrejant A i B al mateix CSV.

Baselines: **random** (sòl), **max_power** (golós), **one_step/safe_one_step** (dany d'un pas; el «safe» evita el penjament de LocalSim de Pokechamp), **abyssal** i **simple_heuristic** (el rival publicat de regles; en aquest gauntlet queden empatats amb v14 a l'Elo).

No s'inclouen agents LLM al round-robin: la latència d'Ollama trenca el pressupost de 10k.

PPO: fora. La comparació futura prevista és contra v12, el sostre bot-contra-bot, no contra els 28.

3.6 Fases de desenvolupament (el que s'ha mesurat)

1. Heurístiques v1–v14 com a ablació.
2. Minimax 1-ply v15–v17 sobre v14.
3. IS-MCTS v18–v20, mateix professor, $n = 1.000$.
4. IL v21–v22, mateix macro, dues execucions.
5. Ladder v14 vs humans (pilot).

El capítol d'implementació tradueix cada fase a codi. El de resultats no torna a explicar el protocol sencer, però **recorda** $n = 1.000$ **cada cop que apareix MCTS**.

Capítol 4

Entorn de Desenvolupament i Infraestructura de Computació

El gauntlet de 784 cel·les, amb 10.000 partides a la majoria, no es pot executar en un portàtil sense disciplina de memòria i de processos. Aquest capítol documenta el maquinari i el flux de treball. L'orquestrador en si és al Capítol 5.

4.1 Evolució de l'arquitectura

4.1.1 Fase 1: prototipatge en portàtil

El prototip va córrer en un Intel Core Ultra 7 155H (22 fils) amb 16 GB de RAM. Un disc NVMe d'1 TB dedicat a `data/` es va muntar amb *bind mount* (no un symlink, que Git tracta malament). Amb 16 GB, múltiples Showdown + Python obligaven a `gc.collect()`, chunks petits i reinicis de Node.js: aquestes rutines neixen d'aquesta fase, no d'una abstracció.

4.1.2 Fase 2: workstation

L'execució de tesi corre en torre: AMD Ryzen 7 5700X3D (8 nuclis / 16 fils, 96 MB L3), 32 GB DDR4, GPU NVIDIA RTX 2080 (8 GB). La GPU **no** intervé al gauntlet heurística / minimax / MCTS / IL: tot és CPU. La 2080 queda per al PPO futur i, si es volgués, per a LLM. Refrigeració de torre i SAI permeten nits senceres de benchmark. Tot el sistema viu en un NVMe, sense bind mount.

Configuració típica del gauntlet: 8 instàncies Showdown (ports 8000–8007) $\times$ 15–25 batalles asyncio $\approx$ 120–200 combats simultanis. Les heurístiques acaben una cel·la de 10k en minuts; MCTS, amb el mateix hardware, obliga $n = 1.000$.

4.2 Dependències: uv

El gestor `uv` i `pyproject.toml` segmenten extras:

- `nucli`: `poke-env==0.11.x`, `pandas`, `xgboost`;
- `r1`: `Gymnasium`, `Stable-Baselines3` (PPO futur);
- `gpu`: `PyTorch CUDA (cu124)` al servidor, índex CPU al portàtil;
- `pokechamp`: pont cap al fork amb `LocalSim`.

No s'actualitza `poke-env` a 0.15 a mitja tesi: el gauntlet s'ha mesurat a 0.11.

4.3 Accés remot

Tailscale SSH (WireGuard) entre portàtil i torre, sense obrir el port 22 al WAN. L'editor treballa amb Remote-SSH sobre el disc del servidor. Les nits de 10k corren dins **tmux**: una desconnexió no mata el master.

Un script de monitoratge (**seguretat_tfm.sh**) segueix temperatura (aturada d'emergència a 92°C) i RAM (flush de page cache cap a 27,5 GB). No és part de la contribució científica; és el que ha permès acabar 253.000 partides per agent sense fondre el node.

4.4 Control de versions i qualitat

Git/GitHub per al codi. Les dades de benchmark (**data/benchmarks/all_10k/**) no es commiten senceres. Ruff formata i bota; **ty** comprova tipus. La memòria es compila amb LaTeX al mateix arbre (**report/**).

Capítol 5

Implementació: De l'Orquestrador a les Quatre Famílies

Aquest capítol tradueix la metodologia a programari. Primer l'orquestrador que fa possible $n = 10.000$. Després cada paradigma tal com està al repositori —no tal com el README de capçalera el va etiquetar a vegades malament. PPO es descriu com a framework, sense resultats.

5.1 Mapa de software

- `src/p00_core/engine/`: `benchmark.py` (master), `worker.py` (subprocess).
- `src/p00_core/core/`: `BaseHeuristic1v1`, `AgentFactory`, matemàtica compartida.
- `src/p01_heuristics/agents/internal/`: `v1.py ... v14.py`.
- `src/p03_minmax/`: `v15–v17`.
- `src/p04_mcts/`: `v18–v20`, `LocalSim` via fork `Pokechamp`.
- `src/p02_imitation_learning/`: `dataset` → `features` → `XGBoost` → `v21/v22`.
- `src/p05_ppo_drl/`: `Gymnasium` + `MaskablePPO` (**no avaluat** en aquesta memòria).
- `src/p00_core/online_bot/`: hook a la ladder pública.

No hi ha mòdul de Dobles a la memòria. El que en quedava al pla es va eliminar com a fora d'abast.

5.2 Arquitectura Master–Worker

5.2.1 Per què subprocessos

Simular milers de batalles en un sol procés Python acumula objectes `Battle`, arbres de cerca i fils de `asyncio`. El GIL impedeix paral·lelisme CPU real amb threads. `fork()` copia l'event loop i mort en deadlock. La solució és `multiprocessing` amb context `spawn`: cada worker és un intèrpret nou, un port Showdown exclusiu, un CSV temporal, i en sortir el SO reclama la RAM.




Figura 5.1: Master-worker del gauntlet. Sense memòria compartida entre workers.

5.2.2 Resume i chunks

Si `v12_vs_abyssal.csv` ja té 4.320 files, el master calcula $n_{to_run} = 10.000 - 4.320$ i continua. No hi ha flag `-resume`: la veritat és el CSV. Cada worker juga chunks de 25, escriu, crida `reset_battles()` i `gc.collect()`. Sense això, 10k batalles en un procés superen 2 GB; amb chunks, $\sim 200\text{--}400$ MB.

Timeouts: el cost varia tres ordres (heurística $\sim 0,01\text{--}0,1$ s/partida; MCTS $\sim 2\text{--}4$ s). El timeout de batch és $\max(7200, 40 \cdot n_{batch})$ segons, per no matar un worker d'MCTS viu ni esperar eternament un penjament.

5.2.3 Reinici de Showdown

V8 fragmenta l'*old generation*. Empíricament, després de milers de batalles el procés Node creix de ~ 80 MB a > 400 MB i la latència puja. El master fa `pkill` + relançament cada N matchups actius (`-restart-every`, defecte 3). Cost ~ 17 s de downtime, negligible en una nit.

5.2.4 Esquema CSV

Cada fila és una batalla. Identitat (`battle_id`, `format`, `heuristic`, `opponent`, `won`, `turns`), qualitat de decisió (`fallbacks`, `errors`), HP i fainted, canvis voluntaris/forçats, RNG (`crit`, `miss`, `SE`), i telemetria de paradigma (`search_diff`, `xgb_stays`, `ko_guards`, `terastallized`, ...). `StatsBattle` intercepta `|-crit|` i companyia abans que `poke-env` les descarti. Els agents no cal que sàpiguen que existeix.

La Figura 5.2 (de la fase de Singles) mostra el perfil de dents de serra: pujada durant un matchup, caiguda al reinici.




Figura 5.2: RAM durant un benchmark de Singles. Les dents de serra són reinicis de Showdown + GC, no un memory leak «resolt» a mà dins el worker.

5.2.5 Contracte BaseHeuristic1v1

Patró Template Method: `choose_move` crida `_pre_move_hook` (sortida primerenca: KO), `_select_action` (lògica) i, si cal, `choose_random_move` (fallback). Una excepció no gela la batalla: es compta `error_moves` i es juga atzar. Tots els agents interns hereten d'aquí, inclosos minimax, MCTS i IL.

`AgentFactory.create("v20")` és l'únic punt d'instanciació. Baselines: wrappers locals de `random`, `max_power`, `simple_heuristic` (còpia amb Tera, perquè el SimpleHeuristics de poke-env no n'havia), `safe_one_step` (reimplementació sense LocalSim per evitar penjades), i `abyssal` del fork Pokechamp.

5.3 Heurístiques v1–v14: ablació de coneixement

L'escala no és «catorze bots cada cop un xic millors». És un experiment: quina peça de coneixement mou el WR a Random Battle. La genealogia de *codi* (Figura conceptual) té branques: `v1`→`v2`→`v3`→`v6`; `v4/v5` a part; `v7` reescriu; `v8–v14` creixen d'aquest nucli estratègic. `v14` hereta `v13`, que hereta l'esperit de `v12`, no necessàriament el WR.

v1–v6 (altiplà de dany). `v1` maximitza $bp \times eff \times STAB$ i gairebé no canvia. `v2` afegeix stats i cremada. `v3` tracking de moviments i pivot (Toxic, outspeed). `v4/v5` clima, terrain, boosts. `v6` és un `v3` lleuger amb prioritat. El resultat empíric —tot el clúster a 44–46%— és la tesi d'aquesta fase: més fidelitat a la fórmula de dany no guanya Random Battles.

v7 (salt posicional). Reescriptura: hazards, setup, pre-check de KO, switch per puntuació de matchup (fórmula d'estil Abyssal). És el primer agent que *tria* canviar, no només desmaia.

v8 / v10. Meta: items (Life Orb, Choice), habilitats (Levitate, Flash Fire), pantalles, Trick Room. Status (Toxic, Will-O-Wisp, Thunder Wave), sacrifici $\leq 20\%$ HP (no gastar un torn per salvar un moribund), U-turn / Volt Switch. Increments reals i petits.

v9 / v11 (tempo). La regla que val més que tota la taula d'objectes de `v8`: hazards i setup **només en torn lliure** (outspeed i resist STAB rival). `v11` híbriditza `v9+v10` i a penes mou l'agulla.

v12 (Gen 9 jugada com a Gen 9). Tres peces natives del format:

1. Teracristal · lització ofensiva i defensiva.
2. Lead de `teampreview`: millor matchup mitjà contra les sis espècies conegudes.
3. Switch-in després de faint per matchup, no l'slot 0 (ni `choose_random_move`, que és el que fan Abyssal/SimpleHeuristic quan `active is None`).

A més conserva torns lliures, sack, pivots i KO. Empíricament és el sostre bot-contra-bot.

v13. Lazy-load de `sets.json`: predicció de moviments, item i ability. Matchup amb dany simulat, no només tipus. Choice-lock, phaze vs sweepers, recuperació < 60% HP, Tera conservador (no gastar-lo a < 30% HP ni en un status). Corregeix un fallback de switch-in de v12.

v14 (orientat a humans). Yomi 2: perfil PREDICTIVE vs CONSERVATIVE segons la taxa de canvis del rival. Scouting als torns 1–3 (Protect, U-turn, Knock Off). 16 rolls de dany per KO garantit. Solver 1-ply d'endgame quan queden ≤ 2 mons per bàndol. Tera defensiu de parany. Contra un bot determinista, scouting i Yomi són sovint *over-respect*: gasten tempo que v12 gasta atacant. Això és disseny, no un bug, i el gauntlet ho quantifica.

Tots registren comptadors. `ko_checks` explota a ~ 15 /partida a v14 perquè el calculador de 16 rolls dispara constantment.

5.4 Minimax 1-ply v15–v17

Els tres hereten **HeuristicV14**. Abans de la matriu: KO garantit (i, a v16/v17, stop de setup, absorb de status, U-turn primerenc). Si no hi ha dreuera, s'enumeren les accions pròpies contra les respostes *predites* del rival (moviments revelats, omplerts amb la DB de sets, més un switch hipotètic si el matchup és dolent). Velocitat i prioritat es resolen analíticament: si el ràpid KO, l'acció del lent és nul · la. **No hi ha LocalSim.**

Fulla de v15: HP i matchup després del torn, amb dany rival $\times 1,5$. v16 afegeix bonuses de setup / hazard / recuperació / status (0,25–0,35) —la hipòtesi de l'efecte horitzó «s'arregla a la fórmula». v17 és v16 més +0,15 al score worst-case de l'acció que hauria triat v14.

Per què no 2-ply: $9 \times 9 = 81$ cel · les a 1-ply, $81^2 = 6561$ a 2-ply, inassumible amb 16 rolls en Python dins el timer de Showdown. El README del repositori que anomena v16 «2-ply» és **incorrecte**; v16 és 1-ply amb fulla posicional.

Telemetria: `search_fire_rate`, `search_diff` (override de la sonda v14). Sense aquests camps es podria vendre l'agent com a «minimax cada torn». Amb ells, es veu que la matriu corre en el 16–18% dels torns.

5.5 IS-MCTS v18–v20

Mateix professor v14, mateix pressupost:

- 100 simulacions per torn de cerca, $C = 1,4$.
- Rollout de 5 torns amb **LocalSim** (Python in-process, fork Pokechamp; no el Node.js per cada pas).
- Cada simulació determina el rival amb la DB de sets.
- Fills arrel: moviments i canvis; es juga l'argmax de visites.

v18: UCB1, fulla HP/boosts/status/hazards, només KO abans de l'arbre. **v19:** UCB1, fulla amb rols i amenaça OHKO, i les dreceres tàctiques de **v14** *abans* de l'arbre. **v20:** **v19** + **PUCT** amb prior 0,70 sobre l'acció **v14**.

LocalSim $\neq$ Showdown. Un desajust de mecànica és soroll al backup d'UCB1 i una causa plausible de l'override-i-perdre de **v18/v19**. El minimax 1-ply **no** usa LocalSim: el seu override-i-perdre no es pot atribuir al simulador, sinó al maximin.

Etiqueta: **v18–v20** són MCTS, no IL. Documents vells del repositori que diuen el contrari es descarten.

5.6 Imitació **v21–v22**

5.6.1 Dades

Replays humans **gen9randombattle**, $\text{Elo} \geq 1800$, HuggingFace / Pokechamp, finestra 2023–2025. $\sim 1,12$ milions de torns. **GroupShuffleSplit** per **battle_id**: els torns d'una mateixa batalla no filtren al test. Desbalanceig move/switch $\approx 2,88$; **scale_pos_weight** ho compensa.

No és OU. El model antic entrenat en OU i avaluat en Random Battle ($\sim 2\%$ WR) era un mismatch de format, no una refutació de l'IL.

5.6.2 Cap macro

XGBoost, 1.150 features (HP, hazards, Tera flags, one-hot d'espècie activa, ...), $n_{\text{estimators}} = 200$, $\text{depth} = 6$, $\eta = 0,1$. Sortida: $p(\text{switch})$. Llindar calibrat $\tau = 0,5525$ (**xgboost_advanced_threshold.json**). Accuracy de classificació $\sim 65,5\%$, ROC-AUC $\sim 0,72$: n'hi ha prou per un prior de timing, no per un jugador.

5.6.3 Dues piles

v21 (HeuristicV21XGBoost). Hereta **v14**. Ordre: KO garantit $\rightarrow$ endgame ≤ 2 mons $\rightarrow$ setup/absorb $\rightarrow$ XGBoost. Si SWITCH: pivot o **_get_best_switch** de **v14**. Si MOVE: **_score_move** de **v14**. Guard de loop. Empíricament XGB dispara en el 15% dels torns.

v22 (HeuristicV22PureIL). Només **BaseHeuristicv1**. XGB primer. Switch: puntua cada mons del banc com si fos l'actiu i tria el de $p(\text{switch})$ mínima. Move: segon model **xgboost_move_evaluator.json** (atributs: power, STAB, eff, status, prioritat — no el nom del moviment). Zero KO guards. Loop guard gairebé sempre.

El README que intercanvia híbrid i pur és **incorrecte**. **v21** és l'híbrid; **v22** és el clon.

5.7 Baselines

random, max_power: poke-env. **simple_heuristic**: còpia local amb Tera. **abyssal**: Pokechamp. **one_step** i **safe_one_step** apunten al player matemàtic sense LocalSim. Abyssal i Simple Heuristic són, en aquest gauntlet, gairebé el mateix rival (Elo 1755 tots dos, empatats amb **v14**).

5.8 Bot en línia

run_online_bot.py connecta qualsevol etiqueta de l'**AgentFactory** al servidor públic. Mode ladder o accept. La mostra de tesi és **v14**, usuari **SirPThesis**, 9–10 de juny de 2026, 431 partides. No s'ha fet un ladder de **v12**: el protocol bot-contra-bot i el protocol humà es queden separats.

5.9 PPO (framework, no experiment d'aquesta memòria)

`src/p05_ppo_drl/` encapsula un `PokemonMaskedEnv` (accions 0–3 moviments, 4–9 switches), vectorització, MaskablePPO [20] i un currículum Random $\rightarrow$ MaxPower $\rightarrow$ SimpleHeuristic $\rightarrow$ gauntlet. Això documenta que el cinquè paradigma *es pot* entrenar sobre el mateix Showdown. **No s'hi reporta cap WR.** La comparació prevista és vs v12, a part, no una fila més de la matriu 28.

Capítol 6

Resultats

Aquest capítol llegeix la matriu acabada. Fonts: `data/benchmarks/all_10k/gen9randombattle` (784 CSV), les notes de família a `src/p00_core/reporting/agents/`, i l'argumentari `heuristics_and_imitation`. No es ressusciten els reports individuals `agents/v1-v14`: etiquetaven malament `v17` com a MCTS i `v19-v20` com a IL.

Un lector que no hagi obert cap notebook ha de poder seguir el protocol, la taxonomia, per què n canvia, i què fa cada paradigma de veritat —no el que el nom suggereix.

6.1 Protocol: com es llegeix un nombre

6.1.1 La matriu

28 agents, cadascun com a *nosaltres* contra 28 oponents, format `gen9randombattle`. Fitxers dirigits `A_vs_B.csv`. PPO no hi és. Dobles no hi és.

Taula 6.1: Taxonomia dels 28 agents del gauntlet `gen9randombattle`. Els identificadors es mantenen en anglès. El prefix de la figura de calor indica el paradigma: (H) heurística, (MM) minimax, (MCT) MCTS, (IL) imitació, (B) baseline.

IDs	Paradigma	Què és, en
<code>random, max_power, one_step, safe_one_step, abyssal, simple_heuristic</code>	Baselines (B)	Referents d'abstracció, potència bruta, matchup.
<code>v1-v14</code>	Heurístiques (H)	Escala d'abstracció, una peça de Yomi, ...).
<code>v15-v17</code>	Minimax 1-ply (MM)	Maximin anàlisi, LocalSim.
<code>v18-v20</code>	IS-MCTS (MCT)	100 simulacions, $n = 1.000$.
<code>v21</code>	IL híbrid (IL)	Macro XGB.
<code>v22</code>	IL pur (IL)	El mateix mètode.
<code>v23+</code>	PPO (fora del gauntlet)	Framework d'aquesta matriu.

La fila d'una taula o d'un heatmap és l'agent que decideix; la columna, l'oponent. Un 59,91 a la cel·la `v12 × Abyssal` vol dir: de 10.000 partides on `v12` era `heuristic` al CSV i `Abyssal` l'opponent, `v12` n'ha guanyat 5.991.

6.1.2 Per què 10.000, amb fórmula

Cada partida és un Bernoulli $W \in \{0, 1\}$. L'IC de Wald al 95%, cas $p = 0,5$, és l'equació (3.3) del Capítol 3:

$$\pm 1,96\sqrt{0,25/n}.$$

A $n = 10.000$ això és $\pm 0,98$ pp. És el pis on un buit de 2 pp (p. ex. 50 vs 52) es distingeix del soroll. A $n = 1.000$ és $\pm 3,1$ pp: calen buits de l'ordre de 6 pp. A $n = 100$ és ± 10 pp: una «victòria 9 de 10» no diu res.

La mida del Pokédex no apareix a $\text{Var}(\hat{p}) = p(1-p)/n$. No cobrim l'espai d'equips. El mateix n a totes les gens seria comparabilitat, no cens. Aquí, tot és Gen 9.

La Taula 3.2 (metodologia) recull els tres pisos. Aquí només cal recordar-los abans de llegir MCTS.

6.1.3 El que el disc conté de veritat

- Cel · la per defecte: **10.000** partides. Heurística, minimax i IL com a nosaltres: **253.000** partides ($25 \times 10k + 3 \times 1k$ contra MCTS). IC global Wilson $\approx \pm 0,19$ pp; IC d'una cel · la $10k \pm 0,98$ pp.
- Si un dels dos és v18, v19 o v20: **1.000** partides. Motiu: 100 rollouts de LocalSim per decisió de cerca. MCTS com a nosaltres: **28.000** partides. IC de cel · la $\pm 3,1$ pp. Un buit de 2 pp en una cel · la MCTS **no és un resultat**.
- Recíprocs A_vs_B i B_vs_A: la suma $\approx 100\%$. Autojoc $\approx 50\%$. Es compleix.

No es mescla un global de 28k amb un de 253k. Es comparen **cel · les**. El WR global serveix per ordenar a ull, sabent que **random** l'infla.

Les 100 partides de desenvolupament no entren en cap taula d'aquest capítol. L'anècdota «v13 va fer 90% vs v12 en 10 partides» es cita una vegada, com a contraexemple del protocol.

6.2 L'escala heurística: tres salts

Taula 6.2: Escala heurística v1–v14 (253.000 partides cadascuna). Tres salts discrets i una inversió: la genealogia deia $v14 \supset v13 \supset v12$; el gauntlet diu $v12 \geq v13 > v14$. Els comptadors `setup_uses/hazard_sets` són 0 per a v7/v8/v10 per un forat d'esquema, no perquè no posin roques.

Agent	Règim	WR (%)	vs Abyssal	Què s'hi afegeix
v1–v6	Altiplà	44,25–45,86	30,6–32,5	Dany, clima, boosts, pivot tòxic
v7	Posicional	54,25	40,80	Hazards, setup, KO, switch de matchup
v8	Posicional	55,43	42,30	Objectes, habilitats, pantalles, Trick Room
v9	Tempo segur	58,86	46,64	Hazards/setup <i>només en torns lliures</i>
v10	Posicional	55,66	41,86	Status, sacrifici $\leq 20\%$ HP, U-turn
v11	Tempo segur	59,26	47,50	Híbrid v9+v10
v12	Tera / preview	69,01	59,91	Tera + lead de preview + switch-in
v13	Predicció de set	67,63	55,34	Sets DB, Tera conservador, recuperació
v14	Yomi / scouting	62,03	51,36	Yomi, scouting T1–3, 16 rolls, endgame 1-ply




Figura 6.1: Taxa de victòries global de v1–v14 com a nosaltres (253.000 partides; les tres cel·les vs MCTS pesen 1k). Tres salts (v7, v9, v12) i una inversió (v12 ≥ v13 > v14). L’altiplà v1–v6 cap a 44–46% és pla de veritat, no una il·lusió d’escala.

6.2.1 Altiplà v1–v6: el dany no n’hi ha prou

El WR global recorre **1,61 pp** (44,25 → 45,86). Cara a cara, s’estan al 50% entre ells. Vs Abyssal queden al 30,6–32,5%: perden contra un one-step competent.

Tesi: un cop tens efectivitat de tipus, la fidelitat extra de la fórmula de dany té retorns decreixents. Random Battle es gana per *posició* —qui és al camp, quan es Tera, si hi ha hazards—, no per un estimador d’HP esperat un xic millor.

Al tall de cinc oponents (**abyssal**, v12, v14, v21, **random**) juguen el mateix joc: ~1,04 canvis voluntaris/partida, zero Tera, zero hazards/setup/KO logged, ~4,3 fallbacks. Són atacants golosos amb una via d’escape dèbil.

6.2.2 Primer salt: v7 (i v8/v10)

v7 reescriu: hazards, setup, KO, switch de matchup. WR 45,5% → **54,25%**. Vs Abyssal 32% → **40,8%**.

v8 (items, habilitats, pantalles, Trick Room) afegeix +1,2 pp: real, petit. v10 (status, sack, pivots) empat tècnic amb v8 (55,66 vs 55,43).

El comportament canvia: canvis voluntaris ~1,55, **matchup_switches** deixa de ser zero (~0,48), fallbacks 4,4 → 2,0. L’agent ara *tria* canviar.

Els comptadors **setup_uses/hazard_sets** són 0 per a v7/v8/v10 **per esquema**, no perquè no posin Stealth Rock. El salt de v9 en el comptador s’interpreta com «la porta de torn lliure fa el setup prou freqüent per mesurar-lo».

6.2.3 Segon salt: v9 / v11

Una sola restricció —hazards i setup només si outspeed i resist STAB— val més que la taula d’objectes de v8: **58,86%** global, **46,64%** vs Abyssal. v11 híbriditza i afegeix +0,4 pp. Un cop existeix el setup de tempo, status/sack/pivot a sobre és gairebé redundant *en aquest gauntlet*.

v9/v11 són els primers amb **setup_uses** ~1,6/partida i **hazard_sets** ~0,16.

6.2.4 Tercer salt: v12

Tera + lead de preview + switch-in per matchup. WR **69,01%**. Primer intern que supera **Abyssal** i **Simple Heuristic** a escala: **59,91%** / **59,75%** ($n = 10.000$, $IC \pm 0,96$). Vs **one_step** / **safe_one_step** salta de ~65% (v9/v11) a ~76,5%.

Al tall, Tera **0,95 / partida**: cristal · litza gairebé cada combat. Fallbacks **0,02**. HP restant propi, gauntlet: **1,84** mons vs 1,44 de v11. No és un pedaç cosmètic. És l'habilitat de format que v1–v11 no tenien.

Tesi: a `gen9randombattle`, Tera més switch-ins amb criteri és una regla més grossa que consciència d'objectes, status o una fórmula de dany més exacta. Qualsevol paradigma posterior que no sàpiga fer Tera ni triar leads juga amb una mà lligada.




Figura 6.2: v1–v14 vs els sis baselines ($n = 10.000$ per cel · la). v12 és el primer que deixa Abyssal i Simple Heuristic clarament per sota del 50% des de la fila. Vs `random tothom` està al 97–98%: aquesta columna no discrimina.

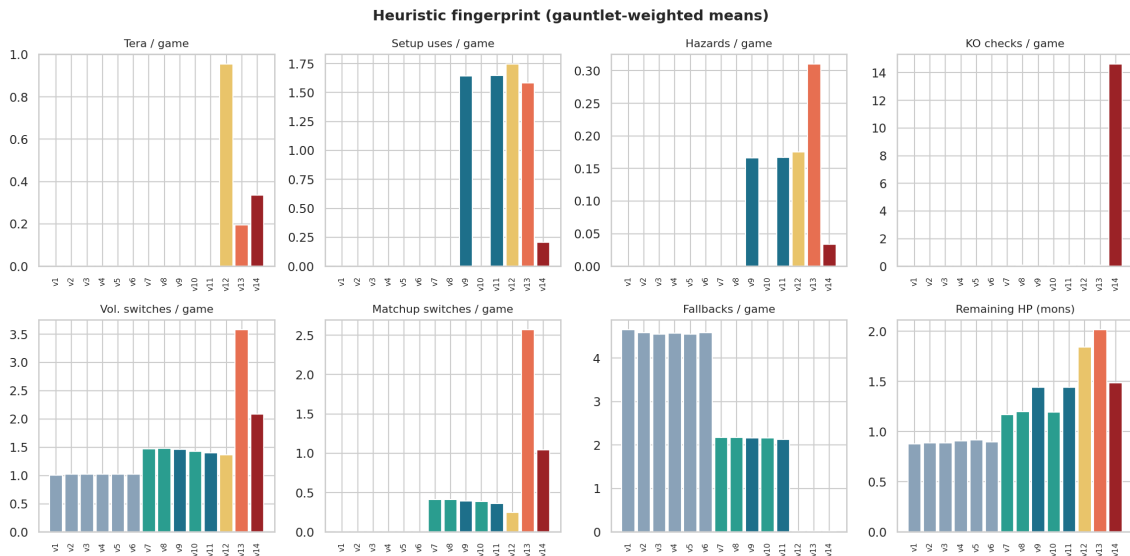


Figura 6.3: empremta tàctica de l'escala heurística. Tera gairebé 1/partida a v12; Tera conservador a v13 (0,20); ko_checks que exploten a v14 (~15/partida). Setup visible a v9/v11/v12/v13, no a v7 (forat d'esquema).

6.3 La inversió: $v12 \geq v13 > v14$

Aquest és el resultat que no s'ha d'allisar. El codi diu $v14 \supset v13 \supset v12$. El round-robin diu el contrari.

Taula 6.3: Cara a cara de la inversió, $n = 10.000$ partides independents cada sentit. v12 vs v13 és un llançament de moneda (buit de 1,8 pp, cada IC $\pm 0,98$). v14 perd clarament contra tots dos. Les sumes recíproques $\approx 100\%$ descarten un artefacte de seient.

Fitxer	WR (%)	Recíproc (%)	Suma
v12_vs_v13	50,65	48,85	99,50
v12_vs_v14	56,01	44,74	100,75
v13_vs_v14	57,71	41,60	99,31




Figura 6.4: Cara a cara de la inversió, $n = 10.000$ cada sentit. v12 vs v13 és un llançament de moneda (50,65 / 48,85). v14 perd 44,74 vs v12 i 41,60 vs v13. L'anècdota de 9/10 a $n = 10$ queda refutada.

v12 vs v13: buit 1,8 pp, cada IC $\pm 0,98$. Compatible amb un avantatge mínim de v12 o amb igualtat. v14 perd clarament.

6.3.1 On v13 encara guanya

No està estrictament dominat. És el **millor heurístic contra cerca i contra l'IL híbrid**:

Oponent	v12	v13	v14
Minimax v15	63,96	67,59	60,07
Minimax v17	60,37	64,12	56,70
MCTS v18 ($n = 1k$)	66,1	67,7	59,8
IL v21	59,12	62,46	54,74
Baselines (bloc)	76,91	74,36	71,06
Altres heurístiques (bloc)	67,01	64,71	58,58

v13 acaba amb més HP (avg_hp_us 2,01 vs 1,84 / 1,49) i partides més llargues (19,1 torns vs 17,9 / 18,5). És un jugador d'atrició i predicció.

6.3.2 Per què no supera v12 en global

Tera conservador: 0,19 /partida al tall vs 0,95 de v12. Canvis voluntaris 4,0 vs 1,5; matchup_switches salta a 3,0. La predicció de set compra HP contra cerca; contra altres heurístiques els canvis extra filtren tempo. El Tera golós i el switch-in simple de v12 exploten millor bots estàtics que no faran bluff.

6.3.3 Per què v14 perd bot-contra-bot (i per què no és un fracàs)

v14 es va construir per **humans**: Yomi, scouting T1–3, Tera parany, 16 rolls, endgame 1-ply. Contra una heurística això és sovint over-respect:

- El scouting gasta tornos que v12 gasta atacant.
- Perfilar un bot determinista és ajustar soroll.
- `ko_checks` ~ 15 /partida; `setup_uses` cau a 0,22: caça KO en lloc de construir.
- Vs Abyssal **51,36%**, llançament de moneda. v12 és **59,91%**.




Figura 6.5: Matchups clau de v12/v13/v14. Fila = nosaltres. Cel · les MCTS $n = 1.000$; resta $n = 10.000$. v12 domina baselines; v13 és més fort contra cerca i v21; v14 queda al mig-baix.




Figura 6.6: WR de l'inversió agregat per paradigma d'oponent. v12 millor contra baselines i altres heurístiques; v13 millor contra minimax, MCTS i IL híbrid.




Figura 6.7: Volum de canvis vs WR. **v13** canvia com un agent perdut i guanya com **v12**: el volum de switch no és habilitat. Sempre cal qui l’inicia (`matchup_switches` vs `faint` vs `loop guard`).




Figura 6.8: Durada i HP restant. **v13** juga més llarg i acaba amb més mons; **v12** tanca abans amb WR més alt. Atrició $\neq$ sostre.

Tesi: afegir maquinària de modelatge humà a una heurística *pot baixar* el WR bot-contra-bot. Això evidencia especialització, no un agent trencat. El protocol s’ha de quedar partit: round-robin per comparar paradigmes, ladder per la pretensió humana.

La ladder de **v14** (secció 6.8) **no** permet invertir **v12** vs **v14**. Tampoc el rànkning bot permet dir que **v12** batria més humans.

6.4 Minimax 1-ply: la resposta del rival, un torn

Pregunta: considerar la millor resposta d’aquest torn, supera l’expert d’un ply que ja viu dins de cada agent de cerca? Mateixa telemetria que MCTS: la cerca dispara? discrepa de **v14**? els que perden discrepen més?

Taula 6.4: Minimax analític d'1-ply (253.000 partides). La cerca s'executa en ~16–18% dels torns; la resta són drecceres de KO (~14 comprovacions/partida). La fulla posicional de v16 no puja els usos de setup (~0,21, com v14). Només el prior +0,15 de v17 mou la taxa de victòries.

	v15 HP	v16 bonuses	v17 prior +0,15
WR global (%)	53,80	54,30	57,89
IC 95% (pp)	±0,19	±0,19	±0,19
Cerca (% torns)	17,6	17,6	16,3
Override de v14 (%)	66,5	67,3	36,6
Setup / partida	0,21	0,21	0,21
Hazards / partida	0,05	0,04	0,04
Tera / partida	0,40	0,39	0,38
Mons restants (nosaltres)	1,28	1,29	1,39

6.4.1 La cerca gairebé no corre

~14 KO checks/partida vs ~4,5 decisions maximin. La matriu es consulta en el **16–18% dels torns**. Descripció honesta:

Un jugador v14 que prioritza el KO i, als torns residuals, puntua un torn analític contra respostes predites.

El mateix fet estructural que v21 (XGB al 15%) i v18–v20 (MCTS al 16–18%).




Figura 6.9: Figura clau. Taxa d'override de v14 entre els torns que la matriu 1-ply s'executa. v15/v16 sobreescrueixen ~67%; v17 (prior +0,15) baixa a ~37%. Els derrotats sobreescrueixen més que els guanyadors (search_diff/torn 0,13 vs 0,10 a v15/v16). 253.000 partides.

6.4.2 v16 ≈ v15: decorar la fulla no allarga l'horitzó

v16 havia de «posar setup i roques a l'avaluador». WR +0,50 **pp** (detectable a 253k, irrellevant). Cara a cara, moneda (49,28 / 51,14). Setup 0,213 vs 0,207; hazards 0,044 vs 0,049. Els bonuses 0,25–0,35 perden contra el terme $\times 1,5$ de dany rival: en un món maximin d'un torn, atacar supera ballar.

Override **67%** igual. La fulla no canvia *quan* la cerca discrepa, només l'àlgebra.

Tesi: l'efecte horitzó a 1-ply no és un bonus que falta. És l'objectiu maximin més un horitzó d'un torn. No es recupera el setup de torn lliure de v9 posant +0,3 a Dragon Dance dins una fulla que també multiplica el dany incoming per 1,5.




Figura 6.10: Proxies de «futur»: setup, hazards, Tera. v16 no puja el setup (~0,21, nivell v14, no v12 ~1,7). La hipòtesi «la fulla posicional valora payoffs retardats» queda refutada pels comptadors.

6.4.3 v17: l'únic upgrade 1-ply

+0,15 a l'acció de v14 després del maximin. Override **67%** → **37%**. WR +4,1 **pp** vs v15. Cara a cara 54,7% / 54,3% vs v15/v16 a 10k. El biaix és *més feble* que el prior PUCT 0,70 de v20 (override 19%), així que v17 encara discrepa en més d'un terç dels torns de cerca i s'asseu **per sota** de v20/v21 (57,9 vs 59,7 / 58,7). Direccionalment és el mateix híbrid.

Vs el sostre, $n = 10.000$ tret de MCTS:

Oponent	v15	v16	v17
v12	36,04	35,92	40,94
v13	32,82	33,50	35,10
v14 (professor)	39,43	39,56	43,61
Abyssal	41,72	41,86	46,79
v20 ($n = 1k$)	39,7	44,6	50,4
v21	43,65	44,75	47,50
v22	69,67	70,22	71,27

v17 vs v14 és **43,6%**: la cerca 1-ply **perd contra el seu professor** a 10k, no és una moneda. Vs v12 **40,9%**. Vs Abyssal 46,8%, lluny del 59,9% de v12. Vs v20 50,4% a 1k: els dos híbrids que es fien de v14 són intercanviables dins el soroll.

Tesi: mirar un torn endavant amb maximin de informació «completa» (sets predits) no supera v14, i posar bonuses de payoff retardat a la fulla no fa que valori el futur. L'únic 1-ply que es mou és el que se li diu que es quedi a prop de v14.




Figura 6.11: empremta v15–v17: KO checks ~14, cerca ~16–18% dels torns, Tera ~0,39 (nivell v14, no v12).




Figura 6.12: Matchups discriminants del 1-ply. Fila = nosaltres. MCTS $n = 1.000$. v17 millora vs Abyssal i vs v12 però no creua el 50% contra el professor.




Figura 6.13: WR agrupat. v15 i v16 superposats; v17 separat cap amunt, encara sota v9/v11.




Figura 6.14: WR 1-ply per paradigma d’oponent. El prior de v17 ajuda sobretot vs heurístiques i vs MCTS; vs IL pur tothom ja guanya.

6.5 IS-MCTS: cinc torns de lookahead són un backup

Recordatori: totes les cel·les d’aquesta secció tenen $n = 1.000$. IC $\approx \pm 3$ pp. El WR global 59,66% de v20 no es compara amb el 57,89% de v17 com si tinguessin el mateix error.

Pregunta: mirar 5 torns en futurs mostrejats, supera l’expert d’un ply que ja viu dins de cada MCTS?

Taula 6.5: IS-MCTS (100 simulacions $\times$ 5 torns de LocalSim). Totes les cel·les $n = 1.000$; 28.000 partides per agent; IC global $\approx \pm 0,58$ pp, IC per cel·la $\approx \pm 3,1$ pp. Una fulla més rica (v19) no ajuda. PUCT amb prior 0,70 sobre v14 (v20) és l’única millora, perquè discrepa *menys*.

	v18 UCB1 HP	v19 UCB1 pos.	v20 PUCT 0,70
WR global (%)	54,02	53,29	59,66
Cerca (% torns)	18,1	17,6	15,5
Override de v14 (%)	71,3	71,1	18,7
Setup / partida	0,22	0,22	0,20
Hazards / partida	0,05	0,05	0,04
Tera / partida	0,41	0,39	0,39
Mons restants (nosaltres)	1,21	1,22	1,40

v20 supera v18 en **28/28** matchups (mitjana +5,64 pp). Cara a cara a 1k: v18 vs v19 moneda (49,3 / 51,4); v20 vs tots dos $\sim 56,6\%$. Una fulla 5-ply més rica **no ha ajudat**.

6.5.1 Altra vegada: la cerca gairebé no corre

~ 14 KO/partida vs ~ 3 –4 decisions MCTS. Arbre en el **16–18%** dels torns:

Un jugador v14 que prioritza el KO i, als residuals, tira 100×5 -ply IS-MCTS.

El pressupost de 100 sims no té ocasió de valorar un Dragon Dance en un torn on existeix un KO, que és la majoria del mid-game.

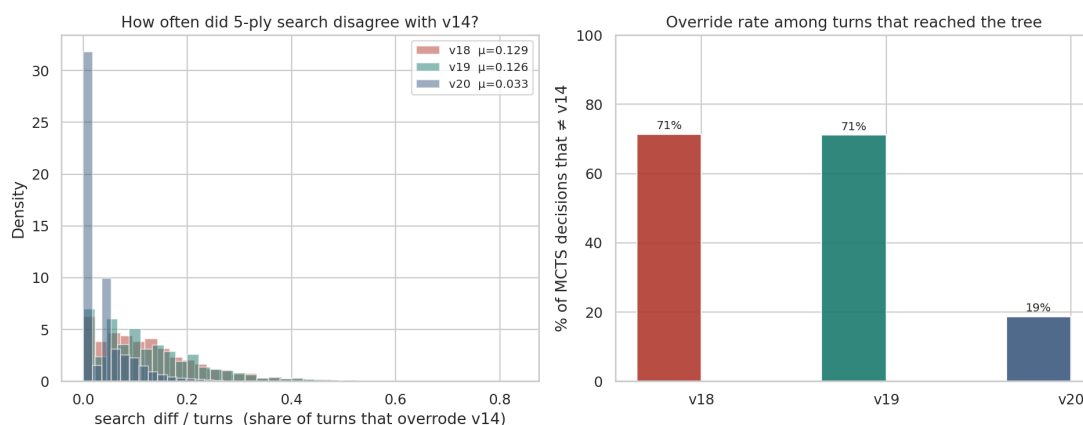


Figura 6.15: Figura clau. Override de v14 entre decisions d'arbre. UCB1 (v18/v19) $\sim 71\%$; PUCT (v20) $\sim 19\%$. Els derrotats sobreescrueixen més (search_diff/torn 0,15 vs 0,11): l'efecte horitzó al replay, no al comentari de l'algorisme. $n = 1.000$ per cel·la, 28.000 partides per agent.

6.5.2 Override correlaciona amb perdre

search_diff és la definició empírica de «el lookahead ha fet alguna cosa». Entre torns d'arbre:

- v18/v19 sobreescrueixen v14 en el **71%**. L'arbre no confirma l'expert: el substitueix.
- Els que perden sobreescrueixen més. El desacord extra no és «una línia millor»; s'associa a derrota.
- Un rollout golós de 5 torns amb fulla d'HP prefereix dany immediat i salta les regles de payoff retardat de v14 (conservar sweeper, torn de hazard, scouting).

v19 havia d'arreglar-ho amb fulla posicional. Override **71,1%**, WR **0,7 pp pitjor** que v18. La fulla no és el constraint vinculant. Ho és: 100 simulacions sorolloses a través d'un rollout golós en un arbre d'informació oculta enorme.

6.5.3 PUCT funciona discrepant menys, no veient més lluny

Prior 0,70 sobre v14. Override **18,7%**. WR **59,7%**, HP restant 1,40. Únic MCTS que entra a la conversa amb v9/v11/v21.

Els guanys PUCT vs v18 són exactament contra els agents de coneixement i de cerca que l'arbre lliure manegava malament: +11,1 pp vs v17, +10,5 vs v13, +9,8 vs v15, +8,7 vs v12. Vs random el buit és 0,3 pp: no hi havia res a arreglar.

Tesi: amb aquest pressupost, l'agent de cerca útil no és «MCTS en lloc de v14». És «v14, amb 100 simulacions permeses de reordenar aquest prior». La mateixa moral que v21. UCT sense guia és el v22 d'aquest paradigma: més pur, pitjor.

6.5.4 Cinc torns golosos no compren el futur

	Setup/partida	Hazards/partida	Tera/partida
v12 (sostre)	$\sim 1,73$	$\sim 0,18$	$\sim 0,95$
v14 (professor)	$\sim 0,22$	$\sim 0,03$	$\sim 0,31$
1-ply v15-v17	0,21	0,04-0,05	0,38-0,40
5-ply v18-v20	0,20-0,22	0,04-0,05	0,39-0,41

Setup i hazards queden a **nivell v14**, no v12. El problema d'horitzó que motivava MCTS sobre 1-ply **no el resol** 5 passos golosos de LocalSim. Una política de rollout que puntua

setup a 80 només si $HP > 75\%$ i hazards a 70 només als torns ≤ 3 continua sent una heurística rasa, executada dins l'arbre.

v20 té més **search_switches** (36% de les decisions d'arbre vs 14% a v18) amb *menys* **search_diff**: PUCT empeny visites cap al **switch de v14**, no n'inventa de llarg horitzó.




Figura 6.16: Proxies de futur a 5-ply. Setup/hazards nivell v14. Cinc torns de LocalSim no recuperen la política de v12. Cel · les $n = 1.000$.

6.5.5 Vs el sostre ($n = 1.000$, $IC \sim \pm 3$ pp)

Oponent	v18	v19	v20
v12	34,0	33,1	42,7
v13	28,6	34,1	39,1
v14	40,0	41,7	47,0
Abyssal	42,2	38,7	49,0
v15	49,3	51,6	59,1
v17	44,7	45,3	55,8
v21	44,1	46,5	49,6
v22	71,1	66,9	73,0

v20 vs v14: **47,0%**, moneda amb el professor. Vs v12: **42,7%**, sota el sostre. Vs Abyssal: **49,0%**, tornant a la moneda que v12 ja havia deixat (59,9% a 10k). Amb PUCT, el 5-ply supera l'1-ply no constrenyit (59,1% vs v15) i esclafen IL pur —el mateix patró que qualsevol heurística competent.

Blocs: v20 69,9% vs baselines, 56,7% vs heurístiques, 57,4% vs minimax. v18/v19 $\sim 50\%$ vs heurístiques i *sota* 50% vs minimax. Cerca 5-ply sense guia ni tan sols supera la cerca 1-ply.

Tesi: IS-MCTS a 100×5 torns golosos no supera v12 ni v14. Supera la cerca *sense guia* de la mateixa família, i només quan se li diu que es fii de l'heurística.




Figura 6.17: Empremta MCTS. Cerca 16–18% dels torns; KO ~ 14 /partida. v20 busca menys i acaba amb més HP. $n = 1.000$ per oponent.




Figura 6.18: Matchups discriminants MCTS. Fila = nosaltres, **totes** $n = 1.000$. v20 s'acosta a Abyssal (49%) i no creua v12 (42,7%).




Figura 6.19: WR agrupat MCTS. v18 i v19 superposats; v20 separat. No mesclar aquest global de 28k amb els 253k de la resta.




Figura 6.20: WR MCTS per paradigma d'oponent ($n = 1k$ a cada cel · la contribuent). PUCT ajuda vs heurístiques i vs minimax; vs IL pur ja es guanyava.

6.6 Imitació: el mateix expert, dues execucions

Mateix cap XGBoost, mateix $\tau = 0,5525$. Divergeixen després.

Taula 6.6: Imitació: el mateix macro XGBoost ($\tau = 0,5525$) i dues piles d'execució. 253.000 partides cadascuna. v21 pregunta el model en el 15% dels torns; v22 en el 80%, sense guards de KO, i dispara el loop-guard en el 97% de les partides.

	v21 híbrid	v22 pur
WR global (%)	58,71 $\pm 0,19$	33,49 $\pm 0,18$
Torns mitjans	18,20	20,07
Mons restants (nosaltres)	1,33	0,70
Canvis voluntaris / partida	1,98	3,72
XGBoost (% torns)	15,2	79,9
Entre decisions XGB, % SWITCH	35,5	15,2
Mitjana $p(\text{switch})$	0,080	0,351
KO guards / partida	13,85	0
Endgame solves / partida	0,032	0
Loop guards / partida (% partides)	0,38 (33%)	1,92 (97%)

v21 supera v22 en **28/28** (mitjana +25,2 pp). Cara a cara: 71,74 / 29,07 (suma 1,008). Autojoc 49,92 / 49,58. La puresa de v22 és exacta: `ko_guards`, `endgame_solves`, `ko_checks`, `search_*` són 0 al 100% de partides. No són la mateixa política amb una etiqueta diferent.




Figura 6.21: Figura clau. empremta IL. v21: ~14 KO guards/partida, XGB al 15% dels torns. v22: zero KO guards, XGB al 80%, loop guards 1,92/partida (97% dels combats). El contrast aïlla l'execució, no la qualitat de les dades.

6.6.1 On s'asseguren a l'escala

v21 58,71% $\approx$ v9/v11. v22 33,49%, **per sota de v1** (44,25%). v1 vs v22 = 65,72%: el clon pur no és «un expert feble»; és pitjor que bp $\times$ tipus $\times$ STAB golós.

Matchups que importen ($n = 10k$ tret de v20):

	vs v12	vs v13	vs v14	vs Abyssal	vs SimpleH
v21	41,28	38,39	45,43	46,98	47,76
v17	40,94	35,10	43,61	46,79	46,75
v20 ($n = 1k$)	42,7	39,1	47,0	49,0	49,2
v22	19,80	22,03	25,81	22,90	21,73

v14 vs v21 = 54,74% (recíproc 45,43). Empeltar un model de timing de switch **sobre v14 no supera v14**. Juga com un v14 un xic pitjor: 58,7 vs 62,0 global; 47,0 vs 51,4 vs Abyssal.

6.6.2 v21 encara és, sobretot, una heurística

Només el **15%** dels torns arriben a XGBoost. El 85% se'ls menja el camí de KO de v14 (ko_guards $\approx$ 14/partida). Als torns que sí arriben al model, $p(\text{switch})$ mitjana és 0,08, lluny de $\tau = 0,5525$: el macro diu gairebé sempre *queda't*, i v14 tria el moviment.

Descripció honesta:

Un v14 que, en la minoria de torns sense KO, pregunta a un clon humà si cal canviar, i tot i així executa amb v14.

Per això s'agrupa amb v9/v11 i no amb v12–v14 (Tera com v14, no com v12) i no pot batre el professor. La capa d'imitació és un **prior de timing de switch**, no un motor tàctic nou.

Això continua sent un resultat d'IL. El *quan canviar* expert és un senyal aprenable (v21 $\gg$ v22 $\gg$ ml_baseline). També és **més feble** que les taules de matchup de v14 en joc bot-contra-bot.




Figura 6.22: On dispara la política. v21: XGB residual (15%). v22: XGB és el camí per defecte (80%). Sense aquesta figura es podria vendre v21 com a «agent que juga com humans».

6.6.3 Per què falla v22: tres raons estructurals, no «XGBoost és dolent»

1. **Semàntica d'acció.** Un slot de Showdown no és una classe estable. El macro només predice {move, switch}. El segon model puntua atributs, no moviments amb nom. És un substitut amb pèrdua del calculador de v14. Els cops SE es queden similars (4,47 vs 4,16 /partida); el WR no, perquè l'ordre de KO i els switch-in dominen.
2. **Biaix d'exposició.** Un mal canvi posa v22 en un banc que l'expert no va ocupar; el macro contrafactual puntua aquest estat aliè; el loop guard dispara en el **97%** de partides (1,92 vs 0,38). La política lluita contra el propi distribution shift. Partides més llargues (20,1 vs 18,2) i **0,70** mons restants vs 1,33.
3. **Restriccions dures absents.** Els experts gairebé mai salten un KO garantit. v21 ho codifica *abans* de consultar el clon. v22 no. Tera 0,99/partida (sense disciplina, a diferència del 0,19 de v13): gasta el recurs d'una vegada per batalla com un script.

Tesi: l'IL en aquest domini està limitat per *què* es clona (macro mou/canvia) i per *qui* executa (heurística vs segon XGB), no per manca de dades. 1,1 milions de torns in-format arriben per un prior de switch. No arriben per substituir dany, KO i disciplina de Tera.

Una objecció de tribunal: «un IL de veritat hauria de triar el moviment, no cridar v14». La rèplica és a la taula: aquest agent és v22, i està dominat. El clonatge jeràrquic (macro de dades, micro d'un solver) és estàndard en control d'informació imperfecta. La contribució és la **mesura**: la jerarquia recupera un jugador nivell v9 i no recupera v12. El que falta és coneixement de format (Tera, preview, KO), que el macro de 1.150 features no havia de treure.




Figura 6.23: Proxies tàctics. v22 Tera gairebé cada partida (0,99) com v12 (0,95) i s'asseu a l'extrem oposat del rànkings: freqüència de Tera $\neq$ disciplina de Tera.




Figura 6.24: WR agrupat híbrid vs pur. v21 a la banda v9; v22 sota v1. 253.000 partides.




Figura 6.25: WR IL per paradigma d'oponent. v21 davant en 6/6 blocs (delta $\sim$ 20–26 pp). El buit és estructural, no un matchup aïllat.




Figura 6.26: WR de v21 vs v22 per oponent. Tots els punts sobre la diagonal: 28/28. El gap més gros és vs `safe_one_step` (+32,6 pp).

6.7 Rànquing entre paradigmes

Taula 6.7: Taxa de victòries global com a *nosaltres* contra els 28 oponents. Heurístiques, minimax i IL: 253.000 partides (25 oponents $\times$ 10.000 + 3 MCTS $\times$ 1.000). MCTS: 28.000 partides, totes les cel·les amb $n = 1.000$. No es poden comparar els dos globals com si tinguessin la mateixa precisió; per ordenar v20 contra v17 cal mirar cel·les de matchup. Font: `data/benchmarks/all_10k/gen9randombattle`.

Rang	Agent	Partides	WR (%)	Paradigma
1	v12	253.000	69,01	Heurística
2	v13	253.000	67,63	Heurística
3	v14	253.000	62,03	Heurística
4	abyssal	253.000	62,00	Baseline
5	simple_heuristic	253.000	61,93	Baseline
6	v20	28.000	59,66	MCTS (cel·les $n = 1k$)
7	v11	253.000	59,26	Heurística
8	v9	253.000	58,86	Heurística
9	v21	253.000	58,71	IL híbrid
10	v17	253.000	57,89	Minimax
11	v10	253.000	55,66	Heurística
12	v8	253.000	55,43	Heurística
13	v16	253.000	54,30	Minimax
14	v7	253.000	54,25	Heurística
15	v18	28.000	54,02	MCTS (cel·les $n = 1k$)
16	v15	253.000	53,80	Minimax
17	v19	28.000	53,29	MCTS (cel·les $n = 1k$)
–	v5	253.000	45,86	Heurística (altiplà)
–	v1	253.000	44,25	Heurística (altiplà)
–	v22	253.000	33,49	IL pur
–	max_power	253.000	19,66	Baseline
–	random	253.000	4,20	Baseline (àncora Elo = 1000)

Taula 6.8: Matchups discriminants. Fila = agent com a *nosaltres*. Cel·les amb v18/v19/v20: $n = 1.000$, IC 95% $\approx \pm 3,1$ pp. Resta: $n = 10.000$, IC 95% $\approx \pm 0,98$ pp. v12 vs Abyssal (59,91% $\pm$ 0,96, $n = 10.000$) és el nombre de referència per «hem superat el baseline publicat de regles».

Agent	vs Abyssal	vs v12	vs v14	vs SimpleH
v12	59,91	50,1 (self)	56,01	59,75
v13	55,34	48,85	57,71	56,10
v14	51,36	44,74	50,1 (self)	50,66
v20 ($n = 1k$)	49,0	42,7	47,0	49,2
v21	46,98	41,28	45,43	47,76
v17	46,79	40,94	43,61	46,75
v16	41,86	35,92	39,56	40,65
v15	41,72	36,04	39,43	41,23
v18 ($n = 1k$)	42,2	34,0	40,0	42,0
v1	30,64	23,29	32,09	30,26
v22	22,90	19,80	25,81	21,73

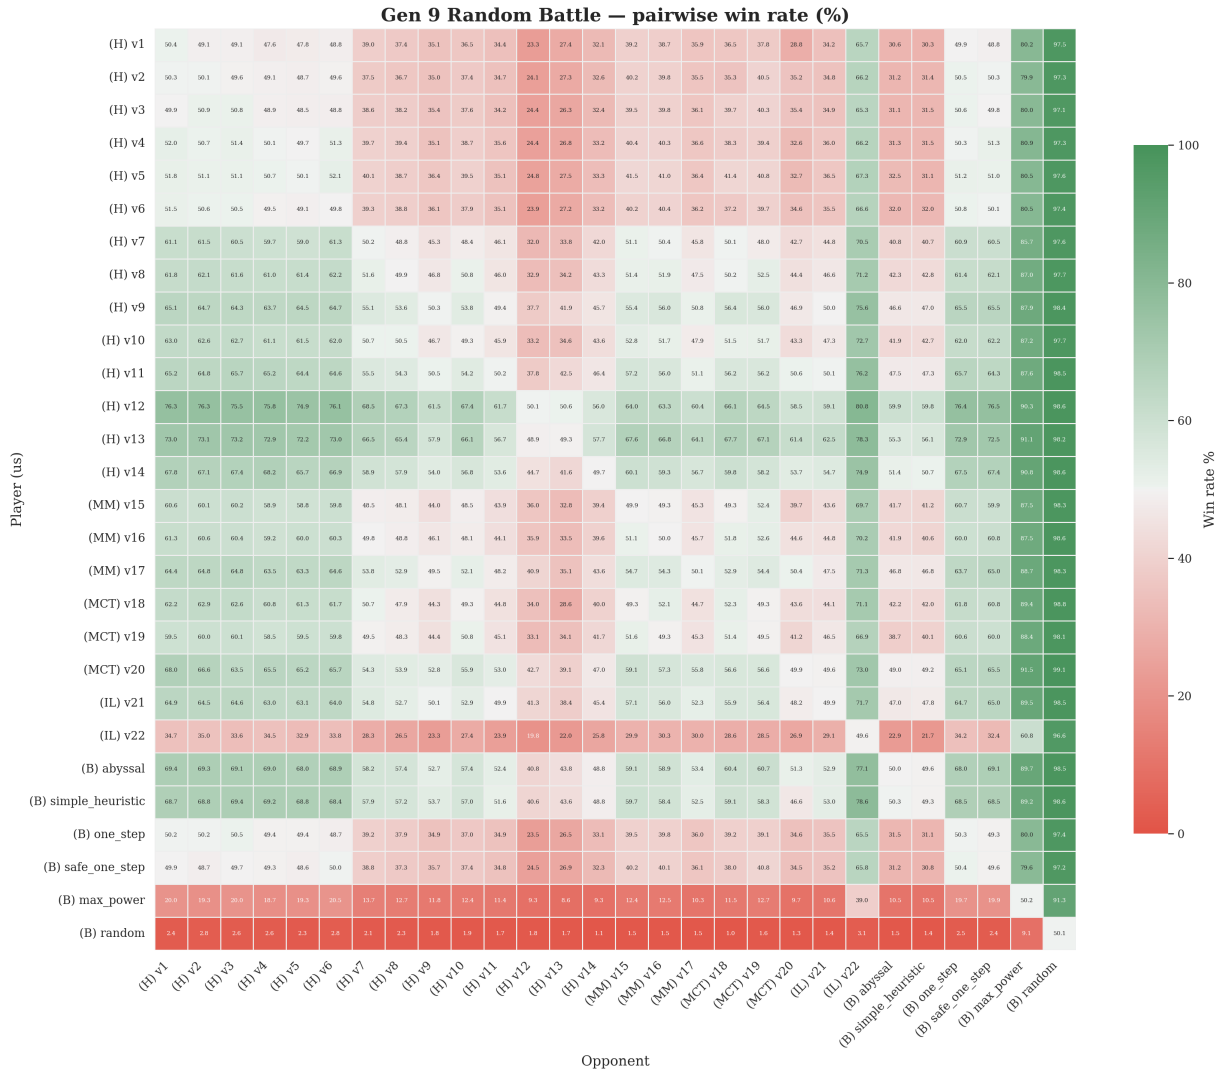


Figura 6.27: Heatmap de WR a `gen9randombattle`. Fila = nosaltres, columna = oponent. Prefixos: (H) v1–v14, (MM) v15–v17, (MCT) v18–v20, (IL) v21–v22, (B) baselines. Cel · les on intervén (MCT): $n = 1.000$; resta $n = 10.000$. La diagonal d’autojoc $\approx 50\%$. El bloc (H) v12/v13 és la franja més calenta; (IL) v22 la més freda després de `random/max_power`.

6.7.1 Abyssal és el regle extern

Fins v12, **cap** heurística interna no supera Abyssal. v7–v11 s’asseguren al 41–48%. v12 és el canvi de règim (59,9%). v14 torna a la moneda (51,4%). v21 per sota (47,0%). v20 moneda a 1k (49,0% $\pm 3,1$). v17 46,79% a 10k. v22 esclafat (22,9%). Si cal un sol nombre per «hem superat el baseline publicat de regles», continua sent **v12 vs Abyssal, 59,91% $\pm 0,96$, $n = 10.000$.**

6.7.2 Elo Bradley–Terry

Taula 6.9: Elo Bradley–Terry a `gen9randombattle`, àncora `random = 1000`, usant *ambdós* seients de cada fitxer dirigit. Agents no-MCTS: 506.000 partides al model; MCTS: 56.000 (28k com a nosaltres + 28k com a oponent). `v14` queda empatat amb `Abyssal` i `Simple Heuristic` (~ 1755): el mateix llançament de moneda ja vist a les cel·les de 10k.

Rang	Agent	Elo	Paradigma
1	<code>v12</code>	1812	Heurística
2	<code>v13</code>	1802	Heurística
3	<code>simple_heuristic</code>	1755	Baseline
4	<code>v14</code>	1755	Heurística
5	<code>abyssal</code>	1755	Baseline
6	<code>v20</code>	1742	MCTS (cel·les $n = 1k$)
7	<code>v11</code>	1733	Heurística
8	<code>v9</code>	1730	Heurística
9	<code>v21</code>	1729	IL híbrid
10	<code>v17</code>	1722	Minimax
–	<code>v22</code>	1529	IL pur
–	<code>random</code>	1000	Baseline (àncora)




Figura 6.28: Elo Bradley–Terry (àncora `random = 1000`), ambdós seients. `v12` i `v13` clars primers. `v14` empatat amb `Abyssal` i `Simple Heuristic` (~ 1755). `v20/v21/v17` segueixen, sota el sostre. MCTS té menys partides al model (56k vs 506k).

6.8 Ladder pública: v14 contra humans

Taula 6.10: Ladder pública de v14 contra humans (gen9randombattle, usuari SirPThesis, 9–10 de juny de 2026). Font: data/testing/logs/logs_v14_online/battle_history.csv. El snapshot del pla de juny (98 partides, 40,8%, Elo ~ 1151) és un *prefix* d'aquest mateix log, pres a prop del pic d'Elo: no és la mostra final.

Mètrica	Valor
Partides úniques acabades	431
Victòries	170 / 431
WR en brut	39,44% $\pm 4,6$ pp
Només torns ≥ 10 (taules tàctiques)	35,43% ($n = 398$)
Partides curtes (torns < 10)	33 (sobretot abandons; inflen el WR brut)
Elo	1085 $\rightarrow$ 1038 (rang 1000–1263)
Errors / fallbacks	0 / 13
Finestra	2026-06-09 21:54 – 2026-06-10 18:32




Figura 6.29: WR i Elo de v14 a la ladder, 431 partides (9–10 juny 2026). Headline: 39,44% $\pm 4,6$ pp, Elo 1085 $\rightarrow$ 1038 (pic 1263). El snapshot de 98 partides / 40,8% / Elo ~ 1151 del pla de juny és un prefix d'aquest log, pres a prop del pic: no és la mostra final.




Figura 6.30: Evolució de l'Elo al llarg de les 431 partides. El pic 1263 i la caiguda fins 1038 expliquen per què un tall a 98 partides enganya.




Figura 6.31: Victòries vs derrotes a la ladder. Torns ≥ 10 ($n = 398$, WR 35,43%) és per taules tàctiques; el titular és 431. Les 33 partides curtes (sobretot abandons) inflen el WR brut.

A partides amb torns ≥ 10 , v14 Tera en 45/398 i en guanya el 20%: Tera des de darrere, no l'opener cada partida de v12. KO checks alts (~ 16 /partida), setup quasi zero (0,03). La mateixa empremta que al gauntlet.

Com usar el nombre. Bot-contra-bot: v14 és tercer entre heurístiques (62% / 51% vs Abyssal) i v12 és primer (69% / 60%). La ladder **no inverteix** aquest rànquing. v14 es va construir per perfilar humans; la mostra diu que aquest disseny encara no és el 50% vs la ladder pública. No diu que v12 ho faria millor en línia.

6.9 Discussió

6.9.1 La moral jeràrquica, tres vegades

v21 (IL), v17 (1-ply) i v20 (MCTS) són la mateixa arquitectura amb roba diferent: **conservar KO i tàctica de v14, afegir un mòdul residual** (prior de switch XGB / biaix maximin +0,15 / arbre PUCT). Tots tres residuals desapareixen en el ~ 15 – 18% dels torns. Els germans més «purs» (v22, v15/v16, v18/v19) sobreescriven l'expert més i guanyen menys.

Les tres figures que ho ensenyen: 6.21, 6.9, 6.15.

El control a batre per a qualsevol paradigma posterior (MCTS més profund, PPO, LLM) continua sent v12/v13, no v14, no v17, no v20, no v21.

6.9.2 En aquest POSG, el coneixement supera el clonatge i el lookahead ras

1. El retorn del coneixement heurístic és **no lineal**: atiplà de dany, salts de posició i tempo, salt gros de mecàniques de format.
2. El sostre bot-contra-bot és v12, no v14. Les regles extra de modelatge humà poden fer mal contra bots deterministes.
3. L'imitació de timing macro és real i més feble que v12–v14. El clon pur, amb aquesta representació, és insuficient.
4. 1-ply no supera el professor. 5-ply IS-MCTS tampoc. Tots dos només es mouen quan se'ls obliga a quedar-se a prop de v14.
5. Cap híbrid (v17, v20, v21) no supera v12.

6.9.3 El que no es reivindica

- «v14 és la millor heurística.» És la millor *dissenyada per humans*; és tercera al round-robin.
- «v13 esclafa v12.» Fals a $n = 10.000$.

- «v21 juga com humans.» És v14 de KO primer amb un prior de switch al residual.
- «L'IL ha fallat.» L'híbrid és un jugador competent nivell v9. El pur ha fallat. Són frases distintes.
- «Minimax/MCTS miren endavant, per tant valoren setup.» Els comptadors ho refuten.
- «v20/v17 és un agent de cerca fort.» Cadascun és una cerca *esbiaixada a v14* forta. La cerca sense guia és una heurística mitjana.
- El WR global com a proxy d'Elo humà. *random* és a la mitjana.
- Mesclar 28k MCTS amb 253k sense dir-ho.
- 40,8% / Elo 1151 com a mostra final de ladder.
- Dobles/VGC com a contribució.
- PPO com a experiment acabat.

6.9.4 Limitacions que afecten la lectura

- El WR global ponderat inclou oponents fàcils. El rànding és robust (v12 primer vs Abyssal, vs heurístiques i en global); el 69% absolut no és un nivell real contra humans.
- Comptadors d'estratègia incomplets a v7/v8/v10 i als dos IL (*setup/hazards* a 0).
- El tall de telemetria de Tera/switch de les heurístiques a les seccions 3–4 de la nota d'anàlisi és cinc matchups, no 28. IL/minimax/MCTS sí que són gauntlet complet.
- *endgame_solves* de v18 està contaminat per la sonda v14 post-cerca. No es cita com a «v18 crida el solver».
- El clon no va tenir mai un cap de «quan fer Tera».
- LocalSim $\neq$ Showdown: soroll plausible a v18/v19. El 1-ply no té aquesta excusa.
- Ladder: 431 partides, pilot ecològic, no un paral·lel de la matriu 10k.

PPO es deixa per una passada separada, contra v12.

Capítol 7

Conclusions i Treball Futur

7.1 El que aquest TFM ha mesurat

S’ha comparat, en un sol format —Singles `gen9randombattle`—, quatre paradigmes de decisió sobre la mateixa matriu de 28 agents. El Dobles/VGC no forma part de la contribució. El PPO no forma part d’aquest gauntlet.

El protocol és tan part del resultat com el rànquing. Cada partida és un Bernoulli. A 10.000 jocs l’IC del 95% és $\pm 0,98$ pp; a 1.000, $\pm 3,1$ pp. MCTS es queda al pis de validació perquè 100 rollouts de `LocalSim` no caben en una nit de 10k. El Pokédex no entra a la variància. Els recíprocs sumen $\sim 100\%$. L’autojoc és $\sim 50\%$.

7.2 Respostes a la pregunta de recerca

En aquest POSG, **el coneixement heurístic té un sostre bot-contra-bot, i ni la cerca rasa ni el clonatge de macros humans el superen.**

1. **L’escala v1–v14 no és lineal.** Altiplà de dany (44–46%). Salt posicional v7 (+9 pp). Salt de tempo v9 (+4 pp). Salt de format v12 (+10 pp): Tera, preview, switch-in. v12 és el primer intern que supera Abyssal (59,91%, $n = 10.000$).
2. **Inversió.** v12 (69,01) $\geq$ v13 (67,63) $>$ v14 (62,03). v12 vs v13 és una moneda a 10k. v14 és l’agent orientat a humans, tercer al round-robin. La ladder (431 partides, 39,44% $\pm 4,6$ pp, Elo 1085 $\rightarrow$ 1038) valida ecològicament aquest disseny; no inverteix el rànquing.
3. **1-ply.** La matriu corre en el 16–18% dels torns. Override 67% (v15/v16) vs 37% (v17). La fulla posicional de v16 no puja el setup. v17 vs v14 = 43,6% a 10k.
4. **5-ply IS-MCTS** ($n = 1.000$). Override 71% (UCB1) vs 19% (PUCT). v19 no ajuda. v20 vs v12 = 42,7%; vs v14 = 47,0%. Setup/hazards nivell v14.
5. **IL.** Mateix XGB, $\tau = 0,5525$. v21 (15% dels torns, guarda v14): 58,71%, nivell v9. v22 (80%, zero KO): 33,49%, sota v1. v21 supera v22 28/28.
6. **Moral jeràrquica.** El residual que substitueix v14 perd. El que el conserva (v17, v20, v21) és l’única millora. **Cap no supera v12.**

7.3 Contribucions

Infraestructura master–worker capaç de 10k per cel · la; escala d’ablació heurística amb telemetria; cerca 1-ply i IS-MCTS instrumentades (override, no només WR); contrast híbrid vs pur en imitació sobre dades *in-format*; protocol honest 10k/1k i ladder com a canal separat.

7.4 Treball futur: PPO contra v12

El framework MaskablePPO existeix (v23+). L'experiment d'aquesta memòria no el cobreix. El pla és una avaluació **separada**, gairebé segur **només contra v12** —el sostre bot-contra-bot—, no contra la matriu de 28. Qualsevol WR de PPO que es publiqui haurà de dir n , l'oponent, i si el residual conserva o substitueix l'heurística: el gauntlet d'aquesta tesi diu que aquesta distinció pesa més que el nom del paradigma.

Altres extensions naturals, no fetes aquí: MCTS amb més simulacions o un rollout que no sigui golós; un cap d'IL que imiti Tera i KO com a accions de primera classe; un ladder de v12 (sense usar-lo per reescriure el rànquing bot). Cap d'aquestes línies reobre el Dobles.

7.5 Tancament

Random Battle de la Generació IX, vist de prop i amb n de tesi, no premia la puresa algorísmica. Premia saber qui ha de ser al camp, quan gastar el Tera, i no deixar escapar un KO. La cerca i l'imitació, a aquests pressupostos, només afegeixen quan se'ls impedeix oblidar-ho.

Bibliografia

- [1] Yoshua Bengio et al. “Curriculum Learning”. A: *Proceedings of the 26th International Conference on Machine Learning (ICML)*. 2009, pàg. 41 - 48. DOI: <https://doi.org/10.1145/1553374.1553380>.
- [2] Christopher Berner et al. “Dota 2 with Large Scale Deep Reinforcement Learning”. A: *arXiv preprint arXiv:1912.06680* (2019). DOI: <https://doi.org/10.48550/arXiv.1912.06680>.
- [3] Noam Brown i Tuomas Sandholm. “Superhuman AI for heads-up no-limit poker: Libratus beats top professionals”. A: *Science* 359.6374 (2018), pàg. 418 - 424. DOI: <https://doi.org/10.1126/science.aao1733>.
- [4] Noam Brown i Tuomas Sandholm. “Superhuman AI for multiplayer poker”. A: *Science* 365.6456 (2019), pàg. 885 - 890. DOI: <https://doi.org/10.1126/science.aay2400>.
- [5] Cameron B. Browne et al. “A Survey of Monte Carlo Tree Search Methods”. A: vol. 4. 1. 2012, pàg. 1 - 43. DOI: <https://doi.org/10.1109/TCIAIG.2012.2186810>.
- [6] Bulbapedia Contributors. *Pokémon (species) — Bulbapedia*. Enciclopèdia completa de la franquícia Pokémon. 2024. URL: [https://bulbapedia.bulbagarden.net/wiki/Pok%C3%A9mon_\(species\)](https://bulbapedia.bulbagarden.net/wiki/Pok%C3%A9mon_(species)).
- [7] Bulbapedia Contributors. *Statistic — Bulbapedia, The community-driven Pokémon encyclopedia*. [Online; accessed 4-March-2026]. 2024. URL: <https://bulbapedia.bulbagarden.net/wiki/Stat>.
- [8] Murray Campbell, A. Joseph Hoane i Feng hsiung Hsu. “Deep Blue”. A: *Artificial Intelligence* 134.1 (2002), pàg. 57 - 83. ISSN: 0004-3702. DOI: [https://doi.org/10.1016/S0004-3702\(01\)00129-1](https://doi.org/10.1016/S0004-3702(01)00129-1). URL: <https://www.sciencedirect.com/science/article/pii/S0004370201001291>.
- [9] Tianqi Chen i Carlos Guestrin. “XGBoost: A Scalable Tree Boosting System”. A: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, pàg. 785 - 794. DOI: <https://doi.org/10.1145/2939672.2939785>.
- [10] Peter I. Cowling, Edward J. Powley i Daniel Whitehouse. “Information Set Monte Carlo Tree Search”. A: *IEEE Transactions on Computational Intelligence and AI in Games* 4.2 (2012), pàg. 120 - 143. DOI: <https://doi.org/10.1109/TCIAIG.2012.2200894>.
- [11] Arpad E. Elo. *The Rating of Chessplayers, Past and Present*. Batsford, 1978.
- [12] Mon-Shu Huang et al. “Action Q-Transformer: Visual Explanation in Deep Reinforcement Learning with Encoder-Decoder Model for Pokémon Battle”. A: *Proceedings of the IEEE Conference on Games (CoG)*. 2023. DOI: <https://doi.org/10.1109/CoG57401.2023.10333246>.
- [13] Shengyi Huang i Santiago Ontañón. “A Closer Look at Invalid Action Masking in Policy Gradient Algorithms”. A: *The International FLAIRS Conference Proceedings*. Vol. 35. 2022. DOI: <https://doi.org/10.32473/flairs.v35i.130584>.

- [14] Leslie Pack Kaelbling, Michael L. Littman i Anthony R. Cassandra. “Planning and Acting in Partially Observable Stochastic Domains”. A: *Artificial Intelligence* 101.1–2 (1998), pàg. 99–134. DOI: [https://doi.org/10.1016/S0004-3702\(98\)00023-X](https://doi.org/10.1016/S0004-3702(98)00023-X).
- [15] Donald E. Knuth i Ronald W. Moore. “An analysis of alpha-beta pruning”. A: vol. 6. 4. Elsevier, 1975, pàg. 293–326. DOI: [https://doi.org/10.1016/0004-3702\(75\)90019-3](https://doi.org/10.1016/0004-3702(75)90019-3).
- [16] Champion Lee et al. *Pokechamp: A Collection of Pokémon Battle AI Agents*. <https://github.com/champion-lee/pokechamp>. Inclou agents basats en MCTS, Minimax, Xarxes Neuronals i heurístiques avançades. 2024.
- [17] Guangcong Luo i Smogon Community. *Pokémon Showdown!* <https://pokemonshowdown.com/>. 2011.
- [18] Volodymyr Mnih et al. “Human-level control through deep reinforcement learning”. A: *Nature* 518.7540 (2015), pàg. 529–533. DOI: <https://doi.org/10.1038/nature14236>.
- [19] Andrew Y. Ng, Daishi Harada i Stuart Russell. “Policy Invariance Under Reward Transformations: Theory and Application to Reward Shaping”. A: *Proceedings of the Sixteenth International Conference on Machine Learning (ICML)*. 1999, pàg. 278–287.
- [20] Antonin Raffin et al. *Stable-Baselines3 Contrib: Reliable Reinforcement Learning Implementations*. <https://github.com/Stable-Baselines-Team/stable-baselines3-contrib>. Inclou MaskablePPO per a entorns amb action masking. 2021.
- [21] Stéphane Ross, Geoffrey Gordon i J. Andrew Bagnell. “A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning”. A: *Proceedings of the 14th International Conference on Artificial Intelligence and Statistics (AISTATS)*. 2011, pàg. 627–635.
- [22] Haris Sahovic. *Creating a Pokémon battling bot with reinforcement learning*. 2021. URL: <https://hsahovic.github.io/poke-env/>.
- [23] Haris Sahovic. *poke-env: A Python Interface for Creating Pokémon Showdown Bots*. <https://github.com/hsahovic/poke-env>. 2020. URL: <https://github.com/hsahovic/poke-env>.
- [24] John Schulman et al. “Proximal Policy Optimization Algorithms”. A: *arXiv preprint arXiv:1707.06347* (2017). DOI: <https://doi.org/10.48550/arXiv.1707.06347>.
- [25] David Silver et al. “A general reinforcement learning algorithm that masters chess, shogi, and Go through self-play”. A: *Science* 362.6419 (2018), pàg. 1140–1144. DOI: <https://doi.org/10.1126/science.aar6404>.
- [26] David Silver et al. “Mastering the game of Go with deep neural networks and tree search”. A: *Nature* 529.7587 (2016), pàg. 484–489. DOI: <https://doi.org/10.1038/nature16961>.
- [27] Richard D. Smallwood i Edward J. Sondik. “The optimal control of partially observable Markov processes over a finite horizon”. A: *Operations Research* 21.5 (1973), pàg. 1071–1088. DOI: <https://doi.org/10.1287/opre.21.5.1071>.
- [28] Smogon University. *Damage Formula*. [Online; accessed 4-March-2026]. 2024. URL: https://www.smogon.com/dp/articles/damage_formula.
- [29] Smogon University. *Smogon Strategy Pokédex*. <https://www.smogon.com/>. Comunitat principal d’estratègia Pokémon competitiva. 2024.
- [30] Richard S. Sutton i Andrew G. Barto. *Reinforcement Learning: An Introduction*. 2nd. MIT Press, 2018. URL: <http://incompleteideas.net/book/the-book.html>.
- [31] Oriol Vinyals et al. “Grandmaster level in StarCraft II using multi-agent reinforcement learning”. A: *Nature* 575.7782 (2019), pàg. 350–354. DOI: <https://doi.org/10.1038/s41586-019-1724-z>.

- [32] John Von Neumann i Oskar Morgenstern. *Theory of Games and Economic Behavior*. Princeton University Press, 2007. URL: <https://press.princeton.edu/books/paperback/9780691130613/theory-of-games-and-economic-behavior>.
- [33] An Yang et al. *Qwen2 Technical Report*. 2024. arXiv: 2407.10671 [cs.CL].