

laSalle

UNIVERSITAT RAMON LLULL

Facultat Internacional de Comerç i Economia Digital La Salle

Treball de Final de Màster

Màster Universitari en Ciència de les Dades / Data Science

**Desenvolupament d'agents experts per a la
presa de decisions en entorns estocàstics i
d'informació imperfecta: El cas de Pokémon**

*Avaluació empírica comparativa d'heurístiques, cerca adver-
sària, MCTS, imitació i aprenentatge per reforç profund*

Alumne/a:

Gerard Pascual Fontanilles

Professor/a Ponent:

Jordi Peralta Dolz

Barcelona, Agost 2026

ACTA D'EXAMEN DEL TREBALL DE FINAL DE MÀSTER

Reunit el Tribunal qualificador en el dia de la data, l'alumne/a:

Gerard Pascual Fontanilles

Va exposar el seu Treball de Final de Màster, el qual va tractar sobre el tema següent:

Desenvolupament d'agents experts per a la presa de decisions en entorns estocàstics i d'informació imperfecta: El cas de Pokémon

Acabada l'exposició i contestades per part de l'alumne/a les objeccions formulades pels membres del tribunal, aquest va valorar l'esmentat Treball amb la qualificació de:

Qualificació Qualitativa	Qualificació Numèrica

Barcelona, a _____ de _____ de 2026

VOCAL DEL TRIBUNAL

VOCAL DEL TRIBUNAL

PRESIDENT DEL TRIBUNAL

Resum

Els videojocs d'estratègia complexos constitueixen un banc de proves exigent per a la recerca en Intel·ligència Artificial. En contrast amb jocs d'informació perfecta (com els escacs o el Go), els entorns amb informació parcial, accions simultànies i dinàmiques estocàstiques presenten reptes d'alta complexitat en predicció, modelització de l'oponent i planificació sota incertesa. Aquest Treball de Final de Màster desenvolupa, instrumenta i avalua de manera exhaustiva cinc paradigmes d'agents per a la presa de decisions en el format individual (`gen9randombattle`) del videojoc competitiu Pokémon, utilitzant el simulador de codi obert Pokémon Showdown i el marc d'integració *poke-env*.

El problema es formalitza com un Procés de Decisió de Markov Parcialment Observable (POMDP) amb accions simultànies, caracteritzat per un espai d'estats i accions combinatòriament dens i múltiples fonts d'incertesa (composicions d'equip i moviments ocults, predicció de canvis i efectes aleatoris en el càlcul de dany). L'objectiu no és únicament aproximar una política que maximitzi la taxa de victòries sota pressupostos computacionals explícits, sinó també analitzar i comprendre els patrons de comportament dels agents en situacions crítiques: la gestió del risc, la predicció de canvis (*switch prediction*), el control del ritme (*tempo*) i l'ús estratègic de la Teracristal·lització, avaluats mitjançant telemetria detallada per torn i mètriques explicatives de decisió.

La proposta integra: (1) una seqüència estructurada de catorze agents heurístics (`v1-v14`) que incorporen incrementalment coneixement de domini (càlcul de dany, efectivitat de tipus, perills d'entrada, moviments de preparació, gestió d'estats alterats i Teracristal·lització); (2) variants de cerca adversària d'un torn (*minimax* `v15-v17`) amb funcions d'avaluació heurístiques a les fulles; (3) cerca en arbre de Monte Carlo rasa (*shallow* MCTS `v18-v20`) amb simulacions de cinc torns mitjançant `LocalSim`, comparant selecció UCB1 amb selecció PUCT guiada per priors heurístics; (4) models d'aprenentatge per imitació (`v21-v22`) basats en XGBoost entrenats sobre partides humanes d'alt nivell (Elo 1800+) per predir la decisió macro d'atacar o canviar; (5) un marc d'aprenentatge per reforç profund (*MaskablePPO*) amb espai d'accions emmascarat i inicialització per clonatge conductual (*Behavioral Cloning*); i (6) una infraestructura paral·lela i recuperable d'avaluació que instrumenta telemetria per torn i càlcul de rànquings Bradley-Terry.

L'avaluació empírica comprèn una matriu competitiva de 28 agents (més de 6,4 milions de batalles), proves específiques de DRL i la integració de models LLM (*PokéChamp* i *PokéLLMon*). Els resultats demostren que l'heurística experta (`v12`) lidera el rendiment superant el referent competitiu *Abyssal*. Així mateix, l'anàlisi de telemetria revela que tant la cerca en arbre com els models apresos necessiten recolzar-se en el criteri heurístic de base per ser competitius en entorns amb informació parcial.

Paraules clau: Intel·ligència Artificial en jocs, presa de decisions sota incertesa, POMDP, Pokémon Showdown, agents heurístics, cerca adversària (Minimax), cerca en arbre de Monte Carlo (MCTS), aprenentatge per imitació (XGBoost), aprenentatge per reforç profund (MaskablePPO), models de llenguatge (LLM), telemetria, explicabilitat, model Bradley-Terry.

Índex

Resum	i
1 Introducció	1
1.1 Pregunta de recerca	1
1.2 Paradigmes estudiats	2
1.3 Objectius	2
1.4 Contribucions i abast	3
1.5 Estructura de la memòria	3
2 Marc teòric i contextualització	4
2.1 Contextualització de la IA en jocs	4
2.1.1 Informació perfecta	4
2.1.2 Informació imperfecta i videojocs	4
2.1.3 MDP, POMDP i POSG	4
2.2 Pokémon com a domini de decisió	5
2.2.1 Què és Pokémon i com es desenvolupa una batalla	7
2.2.2 De l'espècie a les estadístiques finals	7
2.2.3 Modificadors durant la batalla i informació visible	8
2.2.4 Taula de tipus, STAB i categories	9
2.2.5 Velocitat i prioritat	10
2.2.6 Condicions d'estat	10
2.2.7 Estocasticitat	10
2.3 El format Random Battle	11
2.3.1 Combat individual amb equips aleatoris	11
2.3.2 Generació IX	11
2.4 L'entorn virtual	11
2.4.1 Pokémon Showdown	11
2.4.2 poke-env	12
2.5 Cinc paradigmes de decisió	12
2.5.1 Heurístiques: coneixement com a ablació	12
2.5.2 Minimax d'un torn: resposta adversària immediata	12
2.5.3 Cerca de Monte Carlo a l'arrel	13
2.5.4 Imitació / clonatge conductual	13
2.5.5 PPO amb emmascarament d'accions	14
2.6 Estat de l'art: IA i Pokémon	15
2.6.1 Què afegeix aquest TFM	15
2.7 Justificació	15
2.8 Síntesi	15

3	Metodologia i disseny experimental	16
3.1	Disseny general de l'estudi	16
3.1.1	Aïllar la decisió durant el combat	16
3.1.2	Idea d'un gestor de batalles	16
3.2	Disseny incremental dels agents	17
3.2.1	Heurístiques com a seqüència d'hipòtesis	17
3.2.2	Minimax i MCTS com a extensió de la política base	18
3.2.3	Imitació jeràrquica	18
3.2.4	PPO com a currículum amb validacions	18
3.3	Contracte de comparació	19
3.4	Justificació de la mida mostral	19
3.4.1	Cada batalla és un Bernoulli	19
3.4.2	El Pokédex no entra a la variància	20
3.4.3	Tres nivells de mostra	20
3.4.4	Matriu experimental: 784 fitxers CSV	21
3.4.5	Orientacions recíproques i autojoc	22
3.4.6	La taxa global de victòries i l'Elo	22
3.4.7	Ladder humana	22
3.5	Espais formals	22
3.6	Mètriques	22
3.6.1	Mètrica primària: taxa de victòries	22
3.6.2	Mètriques secundàries i telemetria	23
3.6.3	Elo Bradley–Terry	23
3.7	Protocols específics i abast	23
3.7.1	Matriu de 28 agents	23
3.7.2	Agents LLM (PokéChamp i PokéLLMon)	23
3.7.3	PPO contra v12	24
3.8	Amenaces a la validesa i reproductibilitat	24
3.9	Fases de desenvolupament	25
4	Entorn de desenvolupament i infraestructura de còmput	26
4.1	Organització del projecte	26
4.2	Evolució de l'arquitectura	26
4.2.1	Fase 1: prototipatge en portàtil	26
4.2.2	Fase 2: estació de treball	27
4.3	Accés remot: Tailscale	27
4.4	Bot de Telegram	27
4.5	Dependències	27
5	Implementació dels cinc paradigmes	29
5.1	Mapa del programari	29
5.1.1	Com es reparteixen les responsabilitats	30
5.2	Motor de batalla i capa d'integració	30
5.2.1	Servidor local de Pokémon Showdown	30
5.2.2	Adaptació amb <i>poke-env</i>	30
5.3	Arquitectura coordinador–processos de treball	31
5.3.1	Del <code>BattleManager</code> inicial al motor de la matriu	31
5.3.2	Per què subprocessos	31
5.3.3	Coordinador, cua de ports i processos efímers	32
5.3.4	Represa i escriptura per blocs	32
5.3.5	Reinici de Showdown	32
5.3.6	Esquema CSV	32

5.3.7	Automatització de la matriu	32
5.3.8	Contracte BaseHeuristic1v1	33
5.4	Heurístiques v1–v14: incorporació de coneixement	33
5.4.1	Flux de decisió compartit	33
5.4.2	Evolució de les versions	34
5.5	Minimax d'un torn v15–v17	35
5.5.1	Construcció de la matriu d'un torn	35
5.6	MCTS ras v18–v20	35
5.6.1	Simulació local i actualització de l'arrel	36
5.7	Imitació v21–v22	36
5.7.1	Flux de dades	36
5.7.2	Dades	36
5.7.3	Decisió d'alt nivell	38
5.7.4	Dues piles	38
5.8	Baselines	38
5.8.1	Integració exploratòria d'agents de llenguatge	38
5.9	Bot en línia	38
5.10	PPO: MaskablePPO sobre Showdown	38
5.10.1	Organització del mòdul i dels artefactes	39
5.10.2	Entorn	39
5.10.3	Clonatge, arquitectura i recompensa	39
5.10.4	Execució de les fases 1, 1.5, 2 i 3	41
5.10.5	Avaluació i preservació del model principal	41
6	Resultats	44
6.1	Protocol de lectura dels resultats	44
6.1.1	La matriu	44
6.1.2	Precisió de les estimacions	45
6.1.3	Volum i ponderació	45
6.2	Controls globals de la matriu	45
6.3	Fil conductor de v1 a v22	47
6.4	L'escala heurística: tres canvis de règim	48
6.4.1	Altiplà v1–v6: rendiments decreixents del càlcul de dany	48
6.4.2	Primer salt: v7 (i v8/v10)	49
6.4.3	Segon salt: v9 / v11	49
6.4.4	Tercer salt: v12	49
6.5	La inversió entre v12, v13 i v14	50
6.5.1	On v13 encara guanya	51
6.5.2	Per què no supera v12 en global	51
6.5.3	Especialització de v14 i pèrdua de rendiment local	51
6.6	Minimax d'un torn	53
6.6.1	Freqüència d'intervenció	54
6.6.2	v16 i l'avaluació de la fulla	54
6.6.3	v17: prior heurístic	55
6.6.4	Canvis, durada i supervivència	55
6.7	MCTS ras: UCB a l'arrel i simulacions de cinc torns	58
6.7.1	Freqüència d'intervenció	58
6.7.2	Discrepància i resultat	59
6.7.3	PUCT i el prior heurístic	59
6.7.4	Indicadors d'efectes diferits	59
6.7.5	Comparació amb els agents de referència	60
6.7.6	Canvis, durada i supervivència	60

6.8	Aprenentatge per imitació: dues formes d'execució	63
6.8.1	Rendiment dins de la matriu	64
6.8.2	Pes efectiu del model a v_{21}	64
6.8.3	Factors que limiten v_{22}	65
6.8.4	Canvis, durada i supervivència	65
6.9	Comparació entre els cinc paradigmes	68
6.9.1	Abyssal com a agent de referència	70
6.9.2	Elo Bradley–Terry	71
6.10	Classificació pública: v_{14} contra persones	72
6.11	PPO contra v_{12}	73
6.11.1	Resultat principal	73
6.11.2	Curriculum	74
6.11.3	Interpretació del límit observat	74
6.12	Discussió	74
6.12.1	Patró d'integració residual	74
6.12.2	Resposta conjunta a la pregunta de recerca	75
6.12.3	Limitacions específiques dels resultats	75
7	Conclusions i línies futures	76
7.1	Resposta a la pregunta de recerca	76
7.2	Resultats principals	76
7.3	Contribucions	77
7.4	Limitacions	77
7.5	Línies futures	77
7.6	Tancament	78

Índex de figures

2.1	Diferència conceptual entre un MDP, un POMDP i un POSG. En el POMDP l'agent rep una observació parcial de l'estat. Una batalla Pokémon afegeix un segon decisor i, per tant, s'aproxima millor amb un POSG.	6
2.2	Estructura d'una batalla individual: un Pokémon actiu per bàndol i un banc de fins a cinc substituïts. Si el fitxer commemoratiu original és present al repositori, s'utilitza com a contextualització visual; si no, el esquema recull la mateixa informació estructural.	7
2.3	Valors finals de combat d'un Pikachu d'exemple. Si hi ha una captura al repositori, s'hi mostra la pantalla de resum; si no, les barres reproduïxen els totals de la Taula 2.3.	8
2.4	Construcció d'una estadística de combat. Si el calculador original és present, s'hi mostra com a captura; el diagrama recull els mateixos cinc components de les equacions (2.1)–(2.2).	9
2.5	Cicle clàssic de l'MCTS. La variant d'aquest treball omet l'expansió recursiva: les 100 visites es reparteixen entre les accions legals de l'arrel i cada simulació dura cinc torns.	13
2.6	Intuïció de l'objectiu retallat de PPO. Per a avantatges positius, una raó r_t massa gran deixa de contribuir un cop supera $1 + \epsilon$; simètricament, per a avantatges negatius es limita la caiguda per sota de $1 - \epsilon$	14
3.1	Disseny conceptual de l'estudi. La mateixa infraestructura avalua polítiques diferents i retorna dades tant del resultat com del comportament. El PPO comparteix simulador, però no entra a la matriu 28×28	17
3.2	Genealogia de disseny, no una ordenació de força. v7 reescriu el nucli; minimax, MCTS i imitació parteixen de v14 com a fulla, prior o executor. PPO clona v8 i s'avalua contra v12	17
3.3	Curriculum PPO previst. Cada fletxa és una porta de validació independent de la corba d'entrenament. La fase 2 no supera el llindar; la fase 3 es fa igualment com a mesura contra v12	19
4.1	Tauler Kanban utilitzat per organitzar el desenvolupament del TFM.	26
5.1	Mapa de mòduls. p00 aïlla simulació i persistència; p01 – p05 només afegeixen la política. Minimax, MCTS i imitació reutilitzen coneixement de p01 ; PPO té entorn, checkpoints i avaluació propis.	29
5.2	Intercanvi simplificat entre un agent i una instància local de Showdown.	30
5.3	Flux d'adaptació entre el protocol de Showdown i una política Python.	31
5.4	Arquitectura de la matriu experimental, sense memòria compartida entre processos de treball.	31

5.5	Monitoratge durant una execució al prototip de 16 GB. La memòria creix mentre s'acumulen batalles i cau després de reiniciar processos; el patró va motivar els blocs curts, la recollida de memòria i els reinicis de Showdown. Si la captura original no és al directori d'imatges, el diagrama recull el mateix patró de dent de serra.	33
5.6	Validació exploratòria de les repeticions humanes: desequilibri entre atacar i canviar, evolució de la taxa de canvi amb el torn i espècies més representades. La figura descriu el conjunt de dades, no el rendiment final de l'agent.	37
5.7	Taxa de canvi humana per espècie activa en una selecció del conjunt d'experts. La variació justifica incloure identitat i context, però no implica causalitat: espècie, rol, rival i estat de la partida estan correlacionats.	37
5.8	Pas d'inferència de MaskablePPO. La màscara s'aplica abans de mostrejar; l'índex no s'envia mai directament al servidor, sinó com a ordre de Showdown.	40
5.9	Seqüència clonatge → reforç. El crític no s'entrena al clonatge; PPO n'aprèn el valor a partir de la recompensa modelada un cop l'actor ja imita el professor. . .	40
5.10	Corbes de les quatre etapes del currículum. Són taxes durant l'entrenament sobre una política canviant; les validacions independents són les de la Taula 5.4. El panell de fase 3 correspon a la passada secundària, no al model A publicat. . . .	42
6.1	Nombre de partides completades a les 784 cel · les. El bloc fosc correspon a 10.000 partides; les files i columnes clares de v18–v20, a 1.000. La creu no és un buit de dades, sinó el pressupost reduït de l'MCTS.	46
6.2	Distribució de la taxa de victòries de les 784 cel · les dirigides. El centre prop del 50% conté autojoc i enfrontaments equilibrats; les cues reflecteixen diferències grans, especialment davant de Random i MaxBasePower.	46
6.3	Distribució de la durada de les batalles analitzades. La mediana és de 17 torns i hi ha una cua dreta de partides excepcionalment llargues.	47
6.4	Taxa global de victòries de v1–v14 (253.000 partides per fila; les tres cel · les contra MCTS tenen $n = 1.000$). S'observen canvis destacats a v7, v9 i v12, seguits d'una disminució a v13 i v14.	48
6.5	v1–v14 contra els sis agents de referència ($n = 10.000$ per cel · la). v12 és el primer que deixa Abyssal i Simple Heuristic clarament per sota del 50%. Contra random, totes les heurístiques arriben al 97–98% i la columna deixa de ser discriminant. .	49
6.6	Empremta tàctica de la seqüència heurística. v12 utilitza la Teracristal · lització gairebé una vegada per partida; v13, 0,20 vegades. ko_checks augmenta fins a aproximadament 15 a v14; la preparació i els perills d'entrada apareixen a partir de v9.	50
6.7	Enfrontaments directes, amb $n = 10.000$ per orientació. v12 i v13 no presenten una separació concloent; v14 obté 44,74% contra v12 i 41,60% contra v13.	51
6.8	Enfrontaments de referència de v12, v13 i v14. Les files representen l'agent avaluat. Les cel · les MCTS tenen $n = 1.000$ i la resta, $n = 10.000$. v12 domina els agents de referència; v13 és més fort contra cerca i v21.	52
6.9	Taxa de victòries de la inversió, agregada per paradigma d'oponent. v12 és millor contra agents de referència i altres heurístiques; v13, contra minimax, MCTS i imitació híbrida.	52
6.10	Relació entre volum de canvis i taxa de victòries. La freqüència de canvi, per si sola, no mesura la qualitat de la política; cal distingir-ne el motiu.	53
6.11	Durada i membres de l'equip disponibles al final. v13 juga partides més llargues i conserva més Pokémon, mentre que v12 obté una taxa de victòries superior. . . .	53

6.12	Taxa de discrepància respecte de v14 en els torns en què s'executa el maximin. v15/v16 discrepen aproximadament en el 67% dels casos; v17, amb prior +0,15, en el 37%. Les derrotes presenten una discrepància mitjana superior, una associació que no implica causalitat.	54
6.13	Indicadors d'efectes diferits: preparació, perills d'entrada i Teracristal · lització. v16 manté la preparació al voltant de 0,21 usos per partida, un nivell semblant al de v14 i molt inferior al de v12.	55
6.14	Distribució de la durada i dels Pokémon restants a minimax. Les tres variants duren aproximadament 19 torns, però v17 conserva 1,39 membres de mitjana, davant d'1,28–1,29.	56
6.15	Distribució dels canvis voluntaris, dels canvis decidits pel maximin i de la fracció de decisions de cerca que són canvis. v17 presenta una mediana superior de canvis tot i discrepar menys de v14.	56
6.16	Empremta v15–v17: KO checks ~14, cerca ~16–18% dels torns, Tera ~0,39 (nivell v14, no v12).	57
6.17	Enfrontaments de referència del minimax d'un torn. Les cel · les contra MCTS tenen $n = 1.000$. v17 millora respecte de les altres variants, però no supera el 50% contra v14.	57
6.18	Taxa de victòries agrupada. v15 i v16 se superposen; v17 queda per sobre, encara per sota de v9/v11.	57
6.19	Taxa de victòries del minimax per família d'oponent. El prior de v17 s'associa amb les millores principals contra heurístiques i MCTS.	58
6.20	Taxa de discrepància respecte de v14 entre les decisions de cerca. UCB1 (v18/v19) discrepa aproximadament en el 71% dels casos i PUCT (v20), en el 19%. Les derrotes mostren més discrepància mitjana, una associació que no estableix causalitat.	59
6.21	Indicadors d'efectes diferits a les simulacions de cinc torns. La preparació i els perills d'entrada es mantenen a nivells semblants als de v14.	60
6.22	Durada i Pokémon restants a MCTS. v20 acaba lleugerament abans (18,33 torns) i conserva 1,40 membres de mitjana, davant d'1,21–1,22 a UCB1.	61
6.23	Distribució dels canvis a MCTS. PUCT augmenta la fracció de decisions de cerca que acaben en canvi i amplia la distribució de canvis voluntaris.	61
6.24	Empremta MCTS. Cerca 16–18% dels torns; KO ~14/partida. v20 busca menys i acaba amb més HP. $n = 1.000$ per oponent.	62
6.25	Enfrontaments discriminants d'MCTS. Les files representen l'agent avaluat i totes les cel · les tenen $n = 1.000$. v20 s'acosta a Abyssal (49%) i no supera v12 (42,7%).	62
6.26	Taxa de victòries agrupada d'MCTS. v18 i v19 se superposen; v20 queda per sobre. Aquesta mitjana de 28.000 partides no té la mateixa ponderació que les files de 253.000.	62
6.27	Taxa de victòries d'MCTS per paradigma d'oponent ($n = 1.000$ a cada cel · la). PUCT millora principalment contra heurístiques i minimax.	63
6.28	Empremta dels agents d'imitació. v21 registra aproximadament 14 proteccions de debilitament per partida i consulta XGBoost en el 15% dels torns. v22 no té aquestes proteccions, consulta XGBoost en el 80% dels torns i activa la protecció de bucle en el 97% de les partides.	64
6.29	Freqüència d'ús de la política apresada. XGBoost intervé en el 15% dels torns de v21 i en el 80% dels de v22.	65
6.30	Durada i Pokémon restants dels agents d'imitació. v22 juga partides més llargues (20,07 torns) però acaba amb només 0,70 membres, davant d'1,33 a v21.	66
6.31	Distribució dels canvis a imitació. v22 fa aproximadament el doble de canvis voluntaris i rep moltes més ordres de canvi del classificador.	66

6.32	Indicadors tàctics. v22 i v12 utilitzen la Teracristal·lització amb freqüències similars, però obtenen resultats molt diferents; la freqüència no mesura la qualitat de la decisió.	67
6.33	Taxa de victòries agrupada de les dues arquitectures d'imitació. v21 se situa prop de v9 ; v22 , per sota de v1	67
6.34	Taxa de victòries dels agents d'imitació per família d'oponent. v21 supera v22 en els sis blocs, amb diferències d'aproximadament 20–26 pp.	67
6.35	Taxa de victòries de v21 i v22 per oponent. Tots els punts queden sobre la diagonal: v21 obté el valor superior en 28 de 28 enfrontaments. La diferència màxima és de 32,6 pp contra safe_one_step	68
6.36	Mapa de calor de la taxa de victòries a gen9randombattle . La fila és l'agent analitzat i la columna, l'oponent. Prefixos: (H) heurística, (MM) minimax, (MCT) MCTS, (IL) imitació i (B) agent de referència. Les cel·les amb MCTS tenen $n = 1.000$; la resta, $n = 10.000$	70
6.37	Escala Bradley–Terry ancorada a random = 1000, amb les dues orientacions. v12 i v13 obtenen les puntuacions més altes. v14 , Abyssal i Simple Heuristic comparteixen el mateix valor arrodonit. Les files MCTS aporten menys partides al model.	71
6.38	Taxa de victòries i Elo de v14 a la classificació pública: 431 partides entre el 9 i el 10 de juny de 2026, 39,44% $\pm 4,6$ pp i Elo de 1085 a 1038 (màxim 1263).	72
6.39	Evolució de l'Elo al llarg de les 431 partides. Una mostra prefixa de 98 partides, presa prop del màxim, no representa el resultat final.	72
6.40	Victòries i derrotes segons la durada. El subconjunt de partides amb almenys 10 torns és descriptiu; la taxa principal utilitza les 431 partides sense filtrar.	73

Índex de taules

2.1	Tres formalismes de decisió. Pokémon Singles combina observació parcial, un oponent i transicions aleatòries; el POSG n'és el model conceptual, però les implementacions n'aproximen només fragments.	5
2.2	Mapatge POSG/POMDP al combat individual de Random Battle (Generació IX). $ A $ és el de l'actiu: fins a quatre moviments i els canvis del banc.	5
2.3	Exemple numèric de la fórmula (2.1)–(2.2) per a Pikachu a nivell 100. Les bases són les de l'espècie [16]; IV, EV i naturalesa Timid (velocitat $\times 1,1$, atac $\times 0,9$) són una configuració il·lustrativa, no un set de Random Battle.	8
2.4	Matriu de tipus (generacions VI–IX). Les files representen el tipus de l'atac i les columnes, el tipus del defensor.  = supereficax ($\times 2$),  = poc eficaç ($\times 0,5$),  = immunitat, buit = efectivitat neutra.	10
2.5	Condicions d'estat principals. Una política pot preferir cremar un atacant físic abans que causar dany immediat.	10
2.6	Comparació conceptual dels cinc paradigmes. Tots decideixen sobre el mateix simulador i format; canvia la font de coneixement i el còmput per torn.	12
3.1	Disseny del currículum PPO. Els llinars són criteris previstos per avançar; el compliment real es presenta als capítols d'implementació i resultats.	18
3.2	Informació conceptual disponible per a la presa de decisions.	19
3.3	Precisió aproximada al 95% en el cas de màxima variància ($p = 0,5$). La segona columna és el marge d'una proporció; la tercera, el marge de la diferència entre dues proporcions independents amb el mateix n . Són càlculs de planificació, no una anàlisi de potència.	20
3.4	Famílies d'agents del disseny experimental. La llista completa de 28 identificadors es reutilitza als resultats (Taula 6.1). El PPO queda fora d'aquesta matriu. . . .	21
3.5	Com cada paradigma representa observació i acció. El contracte extern (Showdown) és el mateix; canvia la representació interna.	22
5.1	Correspondència entre les fases heurístiques i els components implementats. . . .	34
5.2	Composició del vector d'observació de MaskablePPO. El model A publicat té 328 dimensions; les fases 1 i 1.5 n'utilitzaven 318 (sense dany estimat ni enfrontaments de canvi). Les 18 dimensions addicionals de la fase 4 no entren al resultat principal. .	39
5.3	Espai d'accions Discrete(14) de MaskablePPO. La màscara de legalitat i la traducció a <code>/choose</code> comparteixen el mateix mapeig de slots [26].	40
5.4	Implementació i validació del currículum PPO. «Superada» es refereix al llinar previst, no al fet que s'executés una fase posterior.	41
6.1	Taxonomia dels 28 agents de la matriu.	44
6.2	Evolució de les preguntes i dels resultats entre v1 i v22	47
6.3	Seqüència heurística v1–v14	48

6.4	Enfrontaments directes, amb $n = 10.000$ partides independents per orientació. v12 i v13 no presenten una separació concloent; v14 queda per sota de tots dos. Les sumes recíproques properes al 100% són un control de coherència, no una prova amb partides aparellades.	50
6.5	Minimax analític d'un torn (253.000 partides per fila). La cerca s'executa en aproximadament el 16–18% dels torns. La fulla posicional de v16 gairebé no modifica la preparació; el prior de v17 redueix la discrepància respecte de v14 i obté la taxa més alta de la família.	54
6.6	MCTS ras amb UCB a l'arrel i 100 simulacions de cinc torns. Totes les cel·les tenen $n = 1.000$ (28.000 partides per agent). La fulla més rica de v19 no aporta una millora observable; PUCT amb prior sobre v14 redueix la discrepància i obté la taxa més alta de la família.	58
6.7	Imitació amb el mateix classificador XGBoost ($\tau = 0,5525$) i dues formes d'execució (253.000 partides per fila). v21 consulta el model en el 15% dels torns; v22 , en el 80%, sense proteccions de debilitament, i activa la protecció de bucle en el 97% de les partides.	63
6.8	Síntesi dels cinc paradigmes amb v12 com a comparador comú. Les variants són les que obtenen el millor resultat observat dins de cada família; aquesta selecció és posterior a l'experiment. L'MCTS té una mostra menor i el PPO no participa en la matriu completa.	68
6.9	Taxes globals descriptives contra els 28 oponents. Les files no MCTS tenen 253.000 partides i ponderen cada oponent MCTS una desena part que els altres; les files MCTS tenen 28.000 partides i ponderen tots els oponents igual. Els dos blocs no formen una única classificació comparable.	69
6.10	Enfrontaments de referència. Les files amb MCTS tenen $n = 1.000$ i la resta, $n = 10.000$. v12 contra Abyssal (59,91% $\pm 0,96$ pp) és el principal resultat contra un agent extern basat en regles.	69
6.11	Escala Bradley–Terry a gen9randombattle , ancorada a random = 1000 i ajustada amb les dues orientacions. Els agents no MCTS aporten 506.000 observacions i els MCTS, 56.000. No s'han calculat intervals: valors iguals després d'arrodonir no impliquen equivalència estadística.	71
6.12	Classificació pública de v14 contra persones.	72
6.13	Curriculum i avaluacions de MaskablePPO. El resultat principal és el del model A contra HeuristicV12 , amb $n = 10.000$ i les dues orientacions. La fase 4 només informa la finestra d'entrenament, no una avaluació independent.	73

Capítol 1

Introducció

Pokémon és un joc d'estratègia per torns caracteritzat per la informació parcial, les accions simultànies i les transicions estocàstiques. A cada torn, els jugadors han de decidir entre executar un moviment o substituir el Pokémon actiu sense conèixer amb certesa la configuració de l'equip rival, mentre que factors com la precisió dels atacs, els cops crítics i els efectes secundaris introdueixen aleatorietat inherent al combat.

En aquest context, un **agent** és un sistema autònom que percep l'estat observable de la batalla i selecciona una acció per maximitzar la seva esperança de victòria [49, 81]. Una **política** π formalitza aquesta presa de decisions assignant una distribució sobre les accions legals a partir de l'observació disponible. Els diferents enfocaments d'Intel·ligència Artificial aborden aquesta política des de perspectives diverses: mitjançant regles heurístiques dissenyades per experts, planificació en línia mitjançant cerca adversària o simulació en arbre (MCTS), o bé aprenentatge de patrons a partir de dades humanes i recompenses per reforç.

Aquest Treball de Final de Màster estudia i compara com cinc paradigmes d'agents afronten aquest problema de decisió sota condicions d'incertesa. L'objectiu no és construir un agent infal·lible, sinó avaluar empíricament implementacions concretes sota pressupostos computacionals explícits, en un entorn reproducible i amb una escala mostral que permeti quantificar amb rigor la precisió dels resultats.

Per a l'experimentació s'utilitza el simulador **Pokémon Showdown** [36] i la llibreria *poke-env* [51], focalitzant la recerca en el format individual **Random Battle de la Generació IX** (`gen9randombattle`), on la generació procedural d'equips permet aïllar exclusivament la qualitat de la presa de decisions durant el combat.

1.1 Pregunta de recerca

Quin rendiment relatiu obtenen les heurístiques, el minimax d'un torn, l'MCTS ras, l'aprenentatge per imitació i PPO en batalles `gen9randombattle`, sota els pressupostos de còmput i el protocol experimental d'aquest treball?

La pregunta general es concreta en quatre preguntes:

1. Quines incorporacions de coneixement expliquen els canvis de rendiment entre les catorze heurístiques?
2. La cerca adversària d'un torn o les simulacions Monte Carlo de cinc torns milloren l'heurística que utilitzen com a punt de partida?
3. Què aporta imitar la decisió humana d'atacar o canviar, i fins a quin punt el resultat depèn del mòdul que executa l'acció concreta?

4. Un agent MaskablePPO inicialitzat per clonatge conductual pot assolir el rendiment de l'heurística v12?

La comparació és principalment agent-contragent. L'avaluació de v14 a la classificació pública de Showdown és una mostra externa i separada; no s'utilitza per reordenar la matriu experimental.

1.2 Paradigmes estudiats

S'implementen cinc formes de decidir sobre el mateix simulador i format:

1. **Heurístiques** (v1–v14). Cada agent assigna una puntuació fixa a les accions legals. Les versions incorporen gradualment càlcul de dany, selecció per enfrontament, perills d'entrada, moviments de preparació i Teracristal·lització.
2. **Minimax d'un torn** (v15–v17). S'avalua una matriu maximin d'accions pròpies i respostes rivals estimades, amb una funció heurística a la fulla.
3. **Cerca Monte Carlo rasa** (v18–v20). S'aplica UCB o PUCT als fills de l'arrel i s'executen 100 simulacions de cinc torns amb LocalSim.
4. **Aprenentatge per imitació** (v21–v22). Un classificador XGBoost, entrenat amb repeticions de jugadors d'Elo 1800+, estima quan convé atacar o canviar. v21 delega l'acció concreta a v14; v22 utilitza un segon model basat en atributs dels moviments.
5. **Aprenentatge per reforç** (MaskablePPO). La política s'inicialitza mitjançant clonatge de v8 i continua l'entrenament contra v12, amb emmascarament de les accions il·legals.

Les quatre primeres famílies, juntament amb sis agents de referència, formen una matriu dirigida de **28 agents**. El PPO no forma part d'aquesta matriu: s'avalua en un experiment separat contra v12, l'agent amb millor resultat observat a la lliga. Aquesta asimetria es manté explícita en tota la memòria.

1.3 Objectius

- Formalitzar el combat com un joc estocàstic d'observació parcial i definir una mètrica amb incertesa quantificada.
- Construir una infraestructura de simulació paral·lela amb instàncies locals de Showdown i processos aïllats.
- Desenvolupar v1–v14 com una seqüència d'ablacions de coneixement, tot reconeixent que algunes versions introdueixen més d'un canvi.
- Implementar i instrumentar minimax d'un torn i MCTS ras sobre v14, inclosa la taxa de discrepància respecte de l'acció heurística.
- Entrenar un model d'imitació amb dades del mateix format i comparar una execució híbrida amb una execució principalment apresada.
- Entrenar MaskablePPO amb clonatge inicial i avaluar el model final contra v12.
- Analitzar la matriu 28×28 amb 10.000 partides per cel·la, excepte les cel·les amb MCTS, que en contenen 1.000.

1.4 Contribucions i abast

Les contribucions principals són una infraestructura d'avaluació recuperable i paral·lela; una matriu experimental amb telemetria per decisió; una seqüència de catorze agents heurístics; tres variants de minimax, tres d'MCTS i dues d'imitació; i una avaluació específica de PPO. PokéChamp i PokéLLMon s'han integrat de manera exploratòria, però no formen part de la comparació quantitativa perquè el temps d'inferència observat no permetia completar el mateix volum de partides.

Els resultats descriuen aquestes implementacions, aquest format i aquests pressupostos. No demostren la superioritat general d'un paradigma, ni equivalen a rendiment contra jugadors humans.

1.5 Estructura de la memòria

- El **Capítol 2** presenta el domini, la formalització i els cinc paradigmes.
- El **Capítol 3** defineix el protocol experimental, les mètriques i les amenaces a la validesa.
- El **Capítol 4** documenta l'entorn de còmput i les dependències.
- El **Capítol 5** descriu el coordinador, els processos de treball i les implementacions dels agents.
- El **Capítol 6** analitza la matriu, l'avaluació pública de v14 i l'experiment PPO.
- El **Capítol 7** sintetitza els resultats, les limitacions i les línies de continuació.

Capítol 2

Marc teòric i contextualització

Aquest capítol estableix els fonaments per llegir la comparació. S'introdueix la IA en jocs, es formalitza el combat Pokémon com a joc estocàstic d'observació parcial, es detallen les mecàniques que defineixen els espais S , A i Ω , es presenta el format Random Battle, i es revisen heurístiques, minimax, cerca de Monte Carlo, imitació i PPO.

2.1 Contextualització de la IA en jocs

2.1.1 Informació perfecta

Els jocs han estat el banc de proves clàssic de la IA, des del programa d'escacs de Shannon [55] fins a sistemes que aprenen per diferència temporal, com TD-Gammon [70]. En informació perfecta, tot l'estat és visible. **Deep Blue** (IBM, 1997) va derrotar Kasparov amb minimax i poda alfa-beta [17, 32]. **AlphaGo** [58] i **AlphaZero** [57] van combinar MCTS [11, 33, 19] amb xarxes neuronals [35] i *self-play* per superar el factor de ramificació del Go (~ 250 moviments legals per torn davant ~ 35 als escacs).

2.1.2 Informació imperfecta i videojocs

El salt posterior és a entorns amb estat ocult, accions simultànies i horitzons llargs, també en videojocs d'acció amb observació visual com l'Arcade Learning Environment [4]. **AlphaStar** [75] va assolir Gran Mestre a *StarCraft II*. **OpenAI Five** [6] va cooperar en *Dota 2*. En pòquer, **Libratus** [9] i **Pluribus** [10] van superar professionals en *No-Limit Texas Hold'em*, on les cartes ocultes són l'estratègia.

La distinció operativa:

- **Informació perfecta** (escacs, Go): l'estat complet és comú. La incertesa, si n'hi ha, és només sobre el que farà l'oponent.
- **Informació imperfecta** (pòquer, StarCraft, Pokémon): part de l'estat roman oculta. Cal mantenir una distribució de creença sobre configuracions, objectes i equip rival.

Si, a més, $T(s' \mid s, a)$ no és determinista —rolls de dany, precisió, crítics— l'entorn és **estocàstic**. La combinació és el que fa Pokémon un laboratori, no un trencaclosques resoluble per força bruta.

2.1.3 MDP, POMDP i POSG

Un MDP [66] és la tupla (S, A, T, R, γ) : estats, accions, transició, recompensa i descompte. La política $\pi(a \mid s)$ maximitza el retorn esperat. Si l'agent no observa s sinó una observació $o \in \Omega$ via $O(o \mid s', a)$, el model és un POMDP [59, 29] i cal un estat de creença.

Una batalla entre dos jugadors no és un POMDP d'un únic agent contra la natura: l'oponent també pren decisions i ambdós jugadors escullen l'acció del torn sense observar abans l'acció contrària. El model conceptual més adequat és un **joc estocàstic d'observació parcial** (POSG), hereu dels jocs estocàstics [56] i de la teoria de jocs de suma zero [77]: dos decisors, observacions privades, transicions aleatòries i recompensa terminal de suma zero. Les implementacions d'aquest treball no resolen el POSG complet. En fan aproximacions diferents: les heurístiques utilitzen la informació revelada, el minimax considera un conjunt limitat de respostes estimades i l'MCTS determina un estat plausible abans de simular.

Taula 2.1: Tres formalismes de decisió. Pokémon Singles combina observació parcial, un oponent i transicions aleatòries; el POSG n'és el model conceptual, però les implementacions n'aproximen només fragments.

	MDP	POMDP	POSG
Decisors	Un agent contra l'entorn.	Un agent; l'estat no és visible.	Dos o més agents amb objectius.
El que es veu	L'estat s .	Una observació o de s .	Observacions privades per jugador.
Incertesa	Només T si l'entorn és estocàstic.	T i l'estat ocult.	T , estat ocult i política rival.
Política	$\pi(a \mid s)$.	$\pi(a \mid b)$ sobre una creença b .	Estratègies (sovint d'equilibri).
Aquest TFM	Referència pedagògica.	Aproxima l'observació vectorial del PPO.	Model del combat a dos; no es resol exactament.

Instanciació a gen9randombattle

Component	Instanciació a Singles gen9randombattle
S	Sis Pokémon per bàndol (espècie, HP, configuració, objecte, habilitat, modificadors i condició d'estat), clima, perills d'entrada, Tera consumit i torn. $ S $ és astronòmic i no s'enumera.
A	Fins a quatre moviments, cinc canvis i la Teracristal·lització com a modificador. La legalitat depèn de PP, debilitaments i bloqueigs; el PPO ho codifica en 14 índexs.
T	Motor de Showdown: dany amb roll $[0,85, 1,00]$, STAB, Taula de Tipus, prioritat, velocitat, secundaris.
R	Recompensa terminal conceptual +1 per victòria i -1 per derrota. Per a l'avaluació s'enregistra l'indicador binari $W \in \{0, 1\}$ i se'n publica la mitjana.
Ω	Equip propi complet; del rival, espècies revelades, percentatge d'HP, moviments utilitzats i condicions laterals. EV, naturalesa, objecte i moviments no revelats romanen ocults.

Taula 2.2: Mapatge POSG/POMDP al combat individual de Random Battle (Generació IX). $|A|$ és el de l'actiu: fins a quatre moviments i els canvis del banc.

2.2 Pokémon com a domini de decisió

Abans dels algorismes cal descriure el domini. Les regles de combat —estadístiques, tipus, velocitat, condicions d'estat i aleatorietat— defineixen els espais S , A i Ω sobre els quals decideixen els agents.




Figura 2.1: Diferència conceptual entre un MDP, un POMDP i un POSG. En el POMDP l'agent rep una observació parcial de l'estat. Una batalla Pokémon afegeix un segon decisor i, per tant, s'aproxima millor amb un POSG.

2.2.1 Què és Pokémon i com es desenvolupa una batalla

Pokémon és una franquícia de videojocs centrada en criatures que es capturen, s'entrenen i participen en combats per torns [15]. En una batalla individual (*Singles*), cada jugador disposa habitualment d'un equip de sis Pokémon, però només un és actiu a cada banda. L'objectiu és debilitar tots els membres de l'equip rival abans que el rival faci el mateix.



Figura 2.2: Estructura d'una batalla individual: un Pokémon actiu per bàndol i un banc de fins a cinc substituïts. Si el fitxer commemoratiu original és present al repositori, s'utilitza com a contextualització visual; si no, el esquema recull la mateixa informació estructural.

En cada torn, un jugador pot escollir un dels moviments disponibles o canviar el Pokémon actiu per un membre no debilitat de l'equip. Un Pokémon pot conèixer com a màxim quatre moviments. Alguns causen dany; d'altres modifiquen estadístiques, imposen una condició d'estat, alteren el camp o permeten canviar conservant la iniciativa. Els dos jugadors envien l'acció sense conèixer la decisió actual de l'altre. El motor ordena les accions segons la prioritat i la velocitat, comprova la precisió i resol el dany i els efectes secundaris.

Aquesta estructura fa que una acció no es pugui valorar de manera aïllada. Un atac molt potent pot ser inútil contra una immunitat; un canvi pot evitar un debilitament, però permetre que el rival col·loqui un perill d'entrada; i un moviment de preparació pot sacrificar el torn actual per augmentar la probabilitat de guanyar els següents. Aquestes dependències expliquen per què el projecte evoluciona des d'un agent que només valora potència i tipus fins a agents que també consideren posició, recursos, resposta rival i conseqüències futures.

2.2.2 De l'espècie a les estadístiques finals

Cada Pokémon té sis estadístiques de combat: punts de salut (*Hit Points*, HP), atac, defensa, atac especial, defensa especial i velocitat [16]. Els HP determinen quant dany pot rebre; atac i defensa intervenen en els moviments físics; atac especial i defensa especial, en els moviments especials; i la velocitat ajuda a decidir quin Pokémon actua abans.

La xifra final que mostra el joc no depèn només de l'espècie. Es construeix a partir de cinc components:

1. **Estadística base (*B*).** És pròpia de l'espècie. Dos Pikachu comparteixen les mateixes estadístiques base, però no necessàriament les mateixes xifres finals.
2. **Nivell (*L*).** Escala el valor final. Random Battle també utilitza el nivell com a mecanisme d'equilibri entre espècies.
3. **Valors individuals (*IV*).** Cada estadística té un IV enter entre 0 i 31 [13]. Representa variació individual i pot aportar fins a 31 punts abans de l'escalat pel nivell.
4. **Punts d'esforç (*EV*).** Es poden distribuir fins a 510 EV en total, amb un màxim efectiu de 252 en una mateixa estadística [12]. La fórmula utilitza $\lfloor EV/4 \rfloor$; a nivell 100, cada quatre EV aporten un punt abans d'aplicar la naturalesa.

5. **Naturalesa (N).** La majoria de naturaleses multipliquen una estadística per 1,1 i una altra per 0,9; les naturaleses neutres utilitzen $N = 1$ [14].

Per a una estadística diferent dels HP, la fórmula general és:

$$\text{Stat} = \left\lfloor \left(\left\lfloor \frac{(2B + IV + \lfloor EV/4 \rfloor)L}{100} \right\rfloor + 5 \right) N \right\rfloor. \quad (2.1)$$

Per als HP, excepte casos especials com Shedinja:

$$\text{HP} = \left\lfloor \frac{(2B + IV + \lfloor EV/4 \rfloor)L}{100} \right\rfloor + L + 10. \quad (2.2)$$




Figura 2.3: Valors finals de combat d'un Pikachu d'exemple. Si hi ha una captura al repositori, s'hi mostra la pantalla de resum; si no, les barres reproduïxen els totals de la Taula 2.3.

Taula 2.3: Exemple numèric de la fórmula (2.1)–(2.2) per a Pikachu a nivell 100. Les bases són les de l'espècie [16]; IV, EV i naturalesa Timid (velocitat $\times 1,1$, atac $\times 0,9$) són una configuració il·lustrativa, no un set de Random Battle.

Estadística	Base B	IV	EV	N	Valor final
HP	35	31	0	—	211
Atac	55	31	0	0,9	131
Defensa	40	31	0	1,0	116
Atac especial	50	31	0	1,0	136
Defensa especial	50	31	0	1,0	136
Velocitat	90	31	252	1,1	306

La Figura 2.3 i la Taula 2.3 mostren valors finals, que són els que utilitza el motor durant el combat. La Figura 2.4 mostra, en canvi, com es combinen estadística base, IV, EV, nivell i naturalesa. Les dues il·lustracions no representen necessàriament el mateix Pikachu ni la mateixa distribució; precisament il·lustren que una mateixa espècie pot acabar amb valors finals diferents.

2.2.3 Modificadors durant la batalla i informació visible

Els valors anteriors defineixen les estadístiques inicials, però el combat hi aplica modificadors dinàmics. Moviments com *Swords Dance* o *Dragon Dance* augmenten etapes d'atac o velocitat;

Pokémon 1

Pikachu (Blank Set)

Type: Electric (none) [\(Smogon analysis\)](#)

Forme: Pikachu

Gender: Male

Level: 100

	Base	IVs	EVs	
HP	35	1	83	201
Attack	55	1	122	146 --
Defense	40	1	59	100 --
Sp. Atk	50	1	171	148 --
Sp. Def	50	1	67	122 --
Speed	90	1	142	221 --

Nature: Hardy

Ability: (other)

Item: (none)

Status: Healthy

Current HP: 201 / 201 (100 %) Dynamax

Figura 2.4: Construcció d'una estadística de combat. Si el calculador original és present, s'hi mostra com a captura; el diagrama recull els mateixos cinc components de les equacions (2.1)–(2.2).

d'altres les redueixen. Les etapes solen variar entre -6 i $+6$ i modifiquen temporalment el valor efectiu. Les condicions d'estat, els objectes, les habilitats, el clima i el terreny també poden alterar el dany o l'ordre d'acció.

A Random Battle, Showdown fixa el nivell, els EV, els IV, la naturalesa, els moviments, l'objecte i l'habilitat de cada membre. L'agent no construeix l'equip. Coneix la configuració pròpia, però del rival només observa allò que s'ha revelat. Aquesta diferència és decisiva:

- les heurístiques inicials utilitzen tipus, potència i estadístiques visibles per estimar dany;
- les versions intermèdies incorporen modificadors, velocitat, habilitats i objectes coneguts;
- v13 utilitza els moviments rivals revelats per refinar l'enfrontament;
- minimax i MCTS han de construir una resposta o una determinització amb informació incompleta;
- PPO rep una representació vectorial de la mateixa observació parcial, no l'estat intern complet de Showdown.

Per tant, entendre IV, EV i naturalesa no és només contextualització del joc. Explica per què dues criatures de la mateixa espècie poden tenir velocitats o rangs de dany diferents, per què una estimació pot ser incerta i per què els agents necessiten distingir entre informació pròpia exacta i informació rival inferida.

2.2.4 Taula de tipus, STAB i categories

Divuit tipus, matriu de multiplicadors $\times 2$, $\times 1/2$, $\times 0$ (Taula 2.4). El doble tipus combina factors ($\times 4$ o $\times 0,25$). STAB (*Same Type Attack Bonus*) és $\times 1,5$ si l'atac coincideix amb un tipus de l'usuari.

Taula 2.4: Matriu de tipus (generacions VI–IX). Les files representen el tipus de l'atac i les columnes, el tipus del defensor. **2** = supereficaz ($\times 2$), $\frac{1}{2}$ = poc eficaz ($\times 0,5$), **0** = immunitat, buit = efectivitat neutra.

	NOR	FOC	AIG	PLA	ELE	GEL	LLU	VER	TER	VOL	PSI	INS	ROC	FAN	DRA	FOS	ACE	FAD
NOR													$\frac{1}{2}$	0			$\frac{1}{2}$	
FOC		$\frac{1}{2}$	$\frac{1}{2}$	2		2						2	$\frac{1}{2}$		$\frac{1}{2}$		2	
AIG		2	$\frac{1}{2}$	$\frac{1}{2}$					2				2		$\frac{1}{2}$			
PLA		$\frac{1}{2}$	2	$\frac{1}{2}$				$\frac{1}{2}$	2	$\frac{1}{2}$		$\frac{1}{2}$	2		$\frac{1}{2}$		$\frac{1}{2}$	
ELE			2	$\frac{1}{2}$	$\frac{1}{2}$				0	2					$\frac{1}{2}$			
GEL		$\frac{1}{2}$	$\frac{1}{2}$	2		$\frac{1}{2}$			2	2					2		$\frac{1}{2}$	
LLU	2					2		$\frac{1}{2}$		$\frac{1}{2}$	$\frac{1}{2}$	$\frac{1}{2}$	2	0		2	2	$\frac{1}{2}$
VER				2				$\frac{1}{2}$	$\frac{1}{2}$				$\frac{1}{2}$	$\frac{1}{2}$			0	2
TER		2		$\frac{1}{2}$	2			2		0		$\frac{1}{2}$	2				2	
VOL				2	$\frac{1}{2}$		2					2	$\frac{1}{2}$				$\frac{1}{2}$	
PSI							2	2			$\frac{1}{2}$					0	$\frac{1}{2}$	
INS		$\frac{1}{2}$		2			$\frac{1}{2}$	$\frac{1}{2}$		$\frac{1}{2}$	2			$\frac{1}{2}$		2	$\frac{1}{2}$	$\frac{1}{2}$
ROC		2				2	$\frac{1}{2}$		$\frac{1}{2}$	2		2					$\frac{1}{2}$	
FAN	0										2			2		$\frac{1}{2}$		
DRA															2		$\frac{1}{2}$	0
FOS							$\frac{1}{2}$				2			2		$\frac{1}{2}$		$\frac{1}{2}$
ACE		$\frac{1}{2}$	$\frac{1}{2}$		$\frac{1}{2}$	2							2				$\frac{1}{2}$	2
FAD		$\frac{1}{2}$					2	$\frac{1}{2}$							2	2	$\frac{1}{2}$	

Els moviments poden ser físics (atac contra defensa), especials (atac especial contra defensa especial) o d'estat. Els darrers no causen necessàriament dany directe: poden crear perills d'entrada, modificar estadístiques o protegir.

2.2.5 Velocitat i prioritat

Sense modificadors, actua primer qui té més velocitat. La **prioritat** del moviment (de -7 a $+5$) preval sobre aquesta estadística: *Protect* ($+4$) s'executa abans que la majoria de moviments, mentre que *Trick Room* (-7) s'executa tard i inverteix l'ordre durant cinc torns. Un empat de velocitat es resol aleatòriament. Les heurístiques i el minimax ho aproximen analíticament; l'MCTS ho mostreja durant la simulació.

2.2.6 Condicions d'estat

Estat	Efecte	Mecànica
Cremada	$\downarrow$ 50% atac físic	1/16 dels HP per torn.
Paràlisi	$\downarrow$ 50% velocitat (Gen. VII+)	25% de probabilitat de no actuar.
Verí / tòxic	—	1/8 dels HP per torn, o dany creixent.
Son	—	1–3 torns sense actuar.
Congelació	—	No pot actuar; 20% de probabilitat de descongelar-se per torn.

Taula 2.5: Condicions d'estat principals. Una política pot preferir cremar un atacant físic abans que causar dany immediat.

2.2.7 Estocasticitat

Tres fonts que cap política elimina:

1. **Tirada de dany:** el motor mostreja uniformement un dels setze factors enters entre 85 i 100. Un debilitament possible amb la tirada màxima pot no produir-se amb la mínima. v14 aproxima aquest interval.
2. **Precisió:** un moviment pot fallar; per tant, el dany esperat no coincideix amb el nominal.

3. **Cop crític:** a la Generació IX, la probabilitat base és $1/24$ i el multiplicador de dany és 1,5 [60].

Aquestes fonts d'aleatorietat, juntament amb la generació dels equips, exigeixen informar la incertesa de la taxa de victòries.

2.3 El format Random Battle

2.3.1 Combat individual amb equips aleatoris

El format `gen9randombattle` [62, 65] assigna a cada jugador un equip aleatori de sis Pokémon de la Generació IX, amb configuracions extretes d'una base pública de Smogon i Showdown. Propietats útils per a la recerca:

- **Sense construcció d'equips.** La variable estudiada és la decisió durant el combat. Ambdues bandes reben equips de la mateixa distribució, tot i que no s'utilitzen parelles d'equips idèntiques entre agents.
- **Posició inicial del servidor.** Showdown determina el Pokémon actiu inicial; l'agent decideix moviments, Teracristal·lització i canvis durant la partida.
- **Configuracions d'un conjunt conegut.** La creença sobre el rival es pot restringir a partir de l'espècie i dels moviments revelats.
- **Teracristal·lització (Gen 9):** un cop per batalla, canvi de tipus. És la mecànica que `v12` puntua ofensiva i defensivament.
- **Ladder pública.** El mateix format es juga contra humans a `play.pokemonshowdown.com`. `v14` s'hi ha connectat (Capítol 6).

El metagame OU de Smogon [64, 61] és un altre joc (equips portats, stall, weather). El dataset d'imitació d'aquest TFM és Elo 1800+ del *mateix* format Random Battle [62].

2.3.2 Generació IX

La matriu publicada correspon exclusivament a la **Generació IX**. La mida del conjunt de Pokémon no apareix directament a $\text{Var}(\hat{p}) = p(1 - p)/n$.

2.4 L'entorn virtual

La consola no és instrumentable. La comunitat ha construït Showdown i poke-env.

2.4.1 Pokémon Showdown

Showdown [36] implementa en Node.js i TypeScript les mecàniques de dany, tipus, objectes i habilitats, i és mantingut per la comunitat competitiva. Per a aquest TFM:

1. Precisió de mecàniques: *T* no l'hem reescrit.
2. Mode *headless* local, moltes instàncies, ports 8000+.
3. El mateix motor permet l'avaluació local i la classificació pública.

2.4.2 poke-env

poke-env [51] tradueix el protocol WebSocket a objectes Python (`Battle`, `Pokemon`, `Move`) i exposa `Player.choose_move`. Els experiments utilitzen la branca **0.11.x**. El fork de PokéChamp aporta `LocalSim` per a les simulacions de l'MCTS. El Capítol 3 detalla el protocol i el Capítol 5, el programari.

2.5 Cinc paradigmes de decisió

Cada paradigma introdueix un mecanisme diferent: coneixement codificat, anticipació adversària, simulació, supervisió amb dades humanes o optimització per reforç. La comparació estudia si aquests mecanismes modifiquen la taxa de victòries respecte dels agents que utilitzen com a referència.

Taula 2.6: Comparació conceptual dels cinc paradigmes. Tots decideixen sobre el mateix simulador i format; canvia la font de coneixement i el còmput per torn.

Paradigma	Què decideix	Coneixement	Còmput per torn	Aprèn?
Heurística	Argmax d'una puntuació fixa sobre accions legals.	Regles escrites (dany, posició, Tera).	Constant, baix.	No durant l'execució.
Minimax d'un torn	Maximin sobre una matriu d'accions i respostes estimades.	Funció de fulla + prior opcional.	Enumeració d'un torn.	No.
MCTS ras	UCB/PUCT només als fills de l'arrel.	Determinització i, a v20, prior de v14.	100 simulacions de 5 torns.	No (cerca en línia).
Imitació	Classificador atacar/canviar + executor.	Trajectòries humanes Elo 1800+.	Inferència XGBoost.	Supervisat, fora de línia.
PPO	Política estocàstica emmascarada $\pi_{\theta}(a o)$.	Interacció amb recompensa + clonatge inicial.	Un pas de xarxa.	Per reforç, fora de partida.

2.5.1 Heurístiques: coneixement com a ablació

Una heurística no ajusta els seus paràmetres durant l'execució. A cada decisió puntua les accions legals amb regles fixes i tria l'argmax. La seqüència v1–v14 funciona com una **ablació incremental**: permet relacionar blocs de coneixement amb canvis de rendiment, encara que algunes versions incorporen més d'una modificació i, per tant, no sempre aïllen un únic factor.

L'herència no forma una única cadena lineal (Capítol 5): v1–v3–v6 se centren en dany i canvis simples; v7 reescriu l'estratègia; v12 incorpora mecàniques de la Generació IX, i v14 modela patrons de l'oponent. La relació d'herència de codi no implica una ordenació equivalent de rendiment.

2.5.2 Minimax d'un torn: resposta adversària immediata

Minimax [32] assigna a cada estat el valor de la millor acció sota la resposta més desfavorable. Com que a Pokémon les accions del torn són simultànies, la implementació construeix una matriu d'accions pròpies i respostes rivals estimades. No resol el joc d'informació imperfecta

complet: considera els moviments revelats i una resposta de canvi genèrica. v15–v17 són variants analítiques d'un torn; la funció de fulla incorpora aversió al risc:

$$V = \text{HP}_{\text{me}} - 1,5 \text{HP}_{\text{opp}} + \text{bonificacions}. \quad (2.3)$$

Un horitzó d'un torn valora sobretot la rèplica immediata. Els efectes diferits, com els moviments de preparació o els perills d'entrada, només hi entren a través de bonificacions de la funció de fulla de v16 i del prior de v17.

2.5.3 Cerca de Monte Carlo a l'arrel

L'MCTS complet [11, 19] alterna selecció, expansió, simulació i retropropagació en un arbre. La regla de selecció clàssica és UCT [33], que tracta cada aresta com un bandit. La implementació d'aquest treball és més limitada: aplica UCB1 o PUCT només als fills de l'arrel. Cada iteració selecciona una acció, executa una simulació de cinc torns amb `LocalSim` [31] i actualitza el valor del fill. Per precisió, la memòria l'anomena *MCTS ras* o *UCB a l'arrel*; no és una expansió recursiva de l'arbre.




Figura 2.5: Cicle clàssic de l'MCTS. La variant d'aquest treball omet l'expansió recursiva: les 100 visites es reparteixen entre les accions legals de l'arrel i cada simulació dura cinc torns.

La informació oculta es tracta mitjançant una determinització que conserva els moviments rivals ja revelats. Aquest procediment és una aproximació més simple que l'Information Set MCTS [20] i pot introduir biaix si l'estat determinat no representa bé la distribució de configuracions rivals.

UCB1:

$$\text{UCB1}(j) = \bar{X}_j + C \sqrt{\frac{\ln N}{n_j}}, \quad C = 1,4. \quad (2.4)$$

PUCT afegeix un prior $\pi(a)$; a v20, l'acció proposada per v14 rep un pes de 0,70, que concentra part de les 100 visites.

La hipòtesi és que cinc torns simulats poden capturar efectes que l'horitzó d'un torn no observa. El Capítol 6 contrasta aquesta hipòtesi mitjançant la taxa de discrepància, els moviments de preparació i els perills d'entrada.

2.5.4 Imitació / clonatge conductual

L'aprenentatge supervisat sobre trajectòries d'experts (*behavioral cloning*) estima $\pi_E(a | o)$. El precedent clàssic és l'entrenament d'una política a partir de demostracions, com ALVINN [44]; les enquestes d'aprenentatge per demostració [1] en recullen el marc. El problema clàssic és el **biaix d'exposició**: una decisió errònia porta l'agent a estats poc representats a les dades i els errors es poden acumular [48]. En Pokémon també hi ha un problema de **semàntica d'acció**: el mateix índex pot representar moviments diferents segons el Pokémon actiu. Per aquest motiu, el primer model d'aquest treball només prediu {atacar, canviar}, no l'índex concret.

El classificador és XGBoost [18]: 1.150 característiques i aproximadament 1,12 milions de torns de jugadors amb Elo 1800+, amb separació per `battle_id`. El llindar $\tau = 0,5525$ es va seleccionar sobre la partició retinguda; com que aquesta mateixa partició també informa les mètriques del model, aquestes mètriques s'han d'interpretar com a validació de desenvolupament

i no com una prova final independent. **v21** executa amb **v14**, mentre que **v22** utilitza un segon model basat en potència, STAB i efectivitat.

2.5.5 PPO amb emmascarament d'accions

L'aprenentatge per reforç [66] ajusta una política a partir de la interacció amb l'entorn. En el cas tabular, Q-learning [79] estima valors d'acció; amb aproximadors profunds, DQN [38] va mostrar que una xarxa pot jugar Atari a partir de píxels. Les polítiques d'actor-crític [34, 37] separen dues sortides: l'**actor** $\pi_\theta(a | o)$ proposa accions i el **crític** $V_\phi(o)$ estima el retorn esperat. L'actor s'actualitza en la direcció de l'**avantatge** $\hat{A}_t$, sovint estimat amb GAE [52].


PPO [53] simplifica TRPO [54]: en lloc d'una restricció explícita de divergència, retalla la raó de probabilitats

$$r_t(\theta) = \frac{\pi_\theta(a_t | o_t)}{\pi_{\theta_{\text{old}}}(a_t | o_t)}$$

i optimitza

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right]. \quad (2.5)$$

El retall limita l'amplitud de cada actualització respecte de la política anterior i afavoreix l'estabilitat de l'entrenament. La Figura 2.6 il·lustra el cas $\hat{A}_t > 0$: si r_t creix massa, el terme retallat deixa de premiar actualitzacions addicionals.



Cas $\hat{A}_t > 0$: PPO pren el mínim, no la línia oberta

Figura 2.6: Intuïció de l'objectiu retallat de PPO. Per a avantatges positius, una raó r_t massa gran deixa de contribuir un cop supera $1 + \epsilon$; simètricament, per a avantatges negatius es limita la caiguda per sota de $1 - \epsilon$.

L'emascarament d'accions [26, 45] assigna probabilitat nul·la a accions il·legals, com moviments sense PP, una segona Teracristal·lització o el canvi a un Pokémon debilitat. Sense màscara, el gradient malgastaria massa en accions que Showdown rebutjaria. El model també utilitza recompensa modelada [39] i un currículum d'oponents [5]. El clonatge conductual previ situa π_θ a prop d'una heurística abans del reforç; no elimina el biaix d'exposició, però redueix l'exploració inicial d'accions absurdes.

El cinquè paradigma és MaskablePPO [47, 45] sobre Showdown, amb l'API Gymnasium [72, 73, 8]: observació vectorial, espai discret de 14 accions (4 moviments, 4 moviments amb Teracristal·lització i 6 posicions d'equip), clonatge inicial d'una heurística i entrenament contra un oponent fix. El disseny és al Capítol 3, la implementació al Capítol 5 i els resultats al Capítol 6.

2.6 Estat de l'art: IA i Pokémon

poke-env [51, 50] va facilitar l'ús de Pokémon Showdown com a entorn d'aprenentatge. La biblioteca inclou `RandomPlayer`, `MaxBasePowerPlayer` i `SimpleHeuristicsPlayer`. Smogon [64, 61, 60, 62, 65, 63] aporta coneixement expert, configuracions públiques i eines de càlcul.

Huang i Lee [25] entrenen un agent PPO amb *self-play* a Showdown i mostren transferència entre formats. Més recentment, Grigsby et al. [22] apliquen imitació i RL fora de línia amb

Transformers sobre repeticions humanes, especialment a les primeres generacions. PokéChamp [31, 30] combina un model de llenguatge amb minimax d'un pas. PokéLLMon [24] també utilitza models de llenguatge per decidir en combat. Ambdós sistemes LLM es van integrar de manera exploratòria, però el cost d'inferència observat en va impedir una avaluació amb el volum de la matriu principal. El pòquer [9, 10] i StarCraft [75] proporcionen antecedents sobre decisió amb informació oculta.

2.6.1 Què afegeix aquest TFM

1. **Una matriu comuna** per a heurístiques, minimax, MCTS ras i imitació, amb oponents compartits, volums mostrals explícits i telemetria de discrepància.
2. **Una seqüència de catorze heurístiques** que permet estudiar blocs de coneixement específic del format.
3. **Variants guiades i no guiades** de cerca i d'imitació, amb v14 com a prior o executor.
4. **Una avaluació de MaskablePPO** contra v12, amb clonatge inicial i 10.000 partides.

2.7 Justificació

Pokémon Singles Random Battle concentra, en un motor obert, les propietats següents:

- Estocasticitat irreducible (roll, accuracy, crític, speed tie).
- Informació oculta restringida per un conjunt de configuracions conegut.
- Decisions simultànies.
- Un espai d'accions discret i emmascarable.
- Suma zero al terminal.
- Ladder humana al mateix format.

L'objectiu és mesurar com es comporten la cerca rasa, el clonatge d'una decisió humana d'alt nivell i PPO davant d'heurístiques que ja incorporen debilitaments, Teracristal·lització i selecció del substitut. El disseny experimental explicita les diferències de pressupost que limiten aquesta comparació.

2.8 Síntesi

El marc queda definit per un combat individual de Random Battle, cinc paradigmes i el simulador Showdown. Les mecàniques de tipus, velocitat, informació oculta i aleatorietat determinen tant el problema de decisió com la necessitat de quantificar la incertesa. El capítol següent converteix aquest marc en un disseny experimental.

Capítol 3

Metodologia i disseny experimental

Aquest capítol defineix *què* es vol comparar, *per què* s'organitza d'aquesta manera i *com* es valida cada idea. La traducció d'aquest disseny a components de programari es reserva per al Capítol 5; els resultats són al Capítol 6.

3.1 Disseny general de l'estudi

El disseny parteix d'una separació deliberada entre **la idea experimental** i **la seva implementació**. En aquest capítol es defineixen les responsabilitats, les comparacions i els criteris de validació sense dependre dels noms concrets dels fitxers o de les classes. El Capítol 5 explica com aquestes decisions es tradueixen a Python, Showdown, processos i artefactes de dades.

3.1.1 Aïllar la decisió durant el combat

La primera decisió metodològica és estudiar Random Battle. Si cada agent constrúís el seu propi equip, el resultat combinaria dues capacitats: seleccionar l'equip i jugar-lo. En canvi, Showdown genera els equips i permet centrar l'anàlisi en la política de combat. Tots els paradigmes reben observacions del mateix tipus i han de retornar una acció legal: moviment, canvi o moviment amb Teracristal · lització.

La unitat d'anàlisi és una batalla acabada. El resultat principal és binari, però el disseny també exigeix conservar informació sobre el procés de decisió: torns, HP final, membres restants, canvis, Teracristal · lització, moviments de preparació, perills d'entrada, errors i intervencions dels mòduls de cerca o aprenentatge.

3.1.2 Idea d'un gestor de batalles

Una matriu de centenars d'enfrontaments no es pot tractar com una successió manual de scripts. Abans d'escollir cap tecnologia concreta es defineix un **gestor de batalles** amb sis responsabilitats conceptuals:

1. construir la llista d'enfrontaments entre agents;
2. crear els dos participants amb una interfície comuna;
3. assignar-los un simulador disponible;
4. executar un nombre objectiu de batalles sense barrejar l'estat entre partides;
5. persistir cada resultat i la seva telemetria tan aviat com estigui disponible;
6. reprendre una execució interrompuda sense repetir les partides ja registrades.

Aquest disseny condueix naturalment a separar coordinació, simulació i persistència. També permet canviar la política sense reescriure l'avaluació: el gestor no necessita saber si l'acció prové d'una fórmula, d'una cerca, d'XGBoost o d'una xarxa neuronal.




Figura 3.1: Disseny conceptual de l'estudi. La mateixa infraestructura avalua polítiques diferents i retorna dades tant del resultat com del comportament. El PPO comparteix simulador, però no entra a la matriu 28×28 .

3.2 Disseny incremental dels agents

3.2.1 Heurístiques com a seqüència d'hipòtesis

La idea de v1–v14 no és produir catorze agents independents, sinó construir una seqüència de preguntes. Es comença amb el criteri més simple que pot jugar —potència, efectivitat i STAB— i s'afegeixen blocs de coneixement quan la versió anterior mostra una limitació:

1. **Dany i ordre immediat:** estadístiques, clima, terreny, modificadors i prioritat.
2. **Posició:** valorar l'enfrontament i decidir quan és millor canviar que atacar.
3. **Control del ritme:** reservar moviments de preparació i perills d'entrada per a torns segurs.
4. **Mecàniques del format:** utilitzar la Teracristal · lització i escollir el substitut després d'un debilitament.
5. **Model de l'oponent:** moviments revelats, patrons de canvi, sondeig inicial i resolució de finals.

Cada bloc expressa una hipòtesi sobre què falta a l'agent anterior. No totes les versions canvien un únic factor i, per tant, la seqüència és una ablació pragmàtica, no un experiment factorial perfecte. La regla metodològica és conservar les versions anteriors i avaluar-les sota el mateix conjunt d'oponents; així una millora aparent pot ser contrastada amb enfrontaments directes i telemetria.




Figura 3.2: Genealogia de disseny, no una ordenació de força. v7 reescriu el nucli; minimax, MCTS i imitació parteixen de v14 com a fulla, prior o executor. PPO clona v8 i s'avalua contra v12.

3.2.2 Minimax i MCTS com a extensió de la política base

Després de construir una heurística rica, la pregunta deixa de ser «quina regla falta?» i passa a ser «mirar endavant corregeix la decisió?». Es dissenyen dues famílies:

- **Minimax d'un torn:** enumerar accions pròpies i respostes rivals plausibles, i protegir-se del pitjor resultat immediat.
- **MCTS ras:** distribuir un pressupost fix de simulacions entre les accions legals i estimar-ne les conseqüències durant diversos torns.

En tots dos casos es comparen variants menys guiades amb variants que conserven un prior heurístic. Aquesta decisió és central: permet mesurar si la cerca substitueix coneixement útil o si funciona millor com a mòdul residual. Per això no n'hi ha prou amb la taxa de victòries; també es dissenya la mètrica de *discrepància*, que compta quan la cerca escull una acció diferent de la política base.

3.2.3 Imitació jeràrquica

Les repeticions humanes proporcionen l'acció observada, però l'índex d'una acció no té una semàntica estable entre Pokémon. El disseny separa, doncs, dues escales:

1. una política d'alt nivell aprèn si convé mantenir-se al camp o canviar;
2. un executor escull quin moviment o quin membre de l'equip materialitza la decisió.

Es comparen un executor heurístic i un executor basat principalment en atributs apresos. El contrast no només pregunta si XGBoost classifica bé, sinó si una decisió imitada continua sent útil quan l'agent arriba a estats que no apareixen a les demostracions.

3.2.4 PPO com a currículum amb validacions

Entrenar directament contra l'agent més fort produeix una recompensa escassa i pot impedir que la política aprengui fins i tot les convencions bàsiques de l'espai d'accions. El disseny de PPO adopta un currículum de dificultat creixent. Cada fase té un objectiu pedagògic i una avaluació separada de l'entrenament:

Taula 3.1: Disseny del currículum PPO. Els llistats són criteris previstos per avançar; el compliment real es presenta als capítols d'implementació i resultats.

Fase	Oponent	Objectiu conceptual	Validació	Llindar
1	Random	Aprendre legalitat, finalització de batalles i avantatge sobre una política aleatòria.	1.000 partides	$\geq 90\%$
1.5	MaxBP	Superar una política ofensiva simple basada en potència.	1.000 partides	$> 70\%$
2	v8	Incorporar decisions posicionals amb clonatge inicial i reforç posterior.	1.000 partides	$> 55\%$
3	v12	Mesurar la distància respecte de l'heurística de referència més forta.	10.000 partides	50% com a paritat

La taxa observada durant l'entrenament no és el criteri final, perquè prové d'una política que canvia i d'una finestra temporal dependent. Després de cada fase es congela un model i es juga una mostra d'avaluació. Si no s'assoleix un llindar, metodològicament la fase no queda «superada», encara que es pugui continuar l'experiment per diagnosticar el següent oponent. Aquesta distinció és important a la fase 2.




Figura 3.3: Currículum PPO previst. Cada fletxa és una porta de validació independent de la corba d’entrenament. La fase 2 no supera el llindar; la fase 3 es fa igualment com a mesura contra v12.

3.3 Contracte de comparació

Perquè els resultats siguin interpretables, el disseny fixa les condicions comunes següents:

- un únic format, `gen9randombattle`;
- equips generats pel servidor i sense construcció prèvia;
- una interfície d’accions equivalent per a tots els agents;
- fitxers dirigits per observar les dues orientacions;
- taxa de victòries com a mètrica primària i telemetria com a mètrica explicativa;
- 10.000 partides per cel · la com a valor general i 1.000 quan intervé MCTS pel seu cost;
- PPO com a experiment separat contra v12, sense fingir que forma part de la matriu 28×28 .

L’observació conceptual inclou l’equip propi, el rival revelat i l’estat del camp; no inclou la configuració rival encara oculta:

Component	Informació disponible
Equip propi	HP, estadístiques, objecte, habilitat, modificadors, PP i condició d’estat.
Rival	Espècies revelades, percentatge d’HP, tipus, moviments utilitzats i efectes visibles.
Camp	Clima, terreny, perills d’entrada, pantalles, <i>Trick Room</i> i ús de la Teracristal · lització.
Informació oculta	Moviments no revelats, ordre complet de l’equip rival i objecte o habilitat fins que es manifesten.

Taula 3.2: Informació conceptual disponible per a la presa de decisions.

3.4 Justificació de la mida mostral

La mida mostral es fixa a partir de la precisió desitjada i del cost computacional. Cada batalla es tracta com una observació independent; aquesta hipòtesi és raonable perquè cada combat genera equips i aleatorietat nous, però no s’han reutilitzat llavors ni equips aparellats entre agents.

3.4.1 Cada batalla és un Bernoulli

El resultat és binari: $W_i \in \{0, 1\}$ indica si ha guanyat l’agent de la fila. Sigui $p = \mathbb{E}[W]$. L’estimador $\hat{p} = n^{-1} \sum_i W_i$ té, sota independència,

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n} \leq \frac{1}{4n}. \quad (3.1)$$

Per planificar la mostra s'utilitza l'aproximació normal del marge al 95%:

$$m_{95} \approx 1,96 \sqrt{\frac{p(1-p)}{n}}. \quad (3.2)$$

El cas de màxima variància és $p = 0,5$:

$$m_{95,\max} = 1,96 \sqrt{\frac{0,25}{n}}. \quad (3.3)$$

Als resultats s'utilitza l'interval de Wilson [80]; amb $n \geq 1.000$, les diferències respecte de l'aproximació anterior són petites. La substitució directa en el cas de màxima variància dona:

- $n = 10.000$: $1,96 \sqrt{0,25/10.000} = 0,0098 \rightarrow \pm 0,98$ punts percentuals.
- $n = 1.000$: $\approx 0,0310 \rightarrow \pm 3,10$ pp.
- $n = 100$: $\approx \pm 10$ pp.

Taula 3.3: Precisió aproximada al 95% en el cas de màxima variància ($p = 0,5$). La segona columna és el marge d'una proporció; la tercera, el marge de la diferència entre dues proporcions independents amb el mateix n . Són càlculs de planificació, no una anàlisi de potència.

n	Marge d'una TV	Marge d'una diferència	Ús en aquest TFM
100	$\pm 9,80$ pp	$\pm 13,86$ pp	Prova de funcionament
1.000	$\pm 3,10$ pp	$\pm 4,38$ pp	Cel · les amb MCTS i validació PPO
5.000	$\pm 1,39$ pp	$\pm 1,96$ pp	No utilitzat
10.000	$\pm 0,98$ pp	$\pm 1,39$ pp	Cel · la final per defecte
20.000	$\pm 0,69$ pp	$\pm 0,98$ pp	No utilitzat

Per comparar dues taxes independents properes al 50%, l'error estàndard de la diferència és $\sqrt{2 \cdot 0,25/n}$. Amb 10.000 partides per agent, el marge aproximat del 95% per a la diferència és 1,39 pp; una diferència observada de 2 pp és, per tant, potencialment distingible. Amb 1.000 partides, el marge augmenta fins a 4,38 pp. Aquest càlcul és una aproximació de precisió, no una anàlisi de potència completa ni una correcció per comparacions múltiples.

3.4.2 El Pokédex no entra a la variància

$\text{Var}(\hat{p})$ depèn de p i n , no directament de la mida de la Pokédex ni del nombre de configuracions. El protocol no pretén enumerar totes les combinacions: estima l'esperança de W sota la distribució amb què Showdown genera equips i aleatorietat. Sota la hipòtesi d'independència i distribució idèntica, la llei dels grans nombres justifica la convergència de $\hat{p}$.

La composició de l'equip, els cops crítics, els errors, els empats de velocitat i les tirades de dany contribueixen conjuntament a la variància del resultat binari. No cal modelar-les per separat per estimar un interval sobre la taxa marginal de victòries, però sí que serien necessàries per explicar causalment una decisió concreta.

3.4.3 Tres nivells de mostra

Durant el desenvolupament s'usa una escala de tres pisos. Als resultats de tesi entren el segon i el tercer.

Prova de fum ($n = 100$). Comprova que el codi s'executa, que la Teracristal · lització s'activa i que el procés escriu el CSV. El marge és d'uns ± 10 pp i, per tant, aquest nivell només s'utilitza per verificar la implementació.

Validació ($n = 1.000$). El marge màxim per a una proporció és $\pm 3,1$ pp. És la mida de les cel·les amb MCTS, condicionada pel cost de simulació, i de les avaluacions intermèdies del currículum PPO.

Avaluació final ($n = 10.000$). El marge màxim per a una proporció és $\pm 0,98$ pp. És la mida per defecte de la matriu i de l'avaluació PPO contra v12.

3.4.4 Matriu experimental: 784 fitxers CSV

Taula 3.4: Famílies d'agents del disseny experimental. La llista completa de 28 identificadors es reutilitza als resultats (Taula 6.1). El PPO queda fora d'aquesta matriu.

Família	Identificadors	n	Funció
Referències	random, max_power, one_step, safe_one_step, abyssal, simple_heuristic	10.000	Controls i oponents de currículum.
Heurístiques	v1–v14	10.000	Ablació de coneixement.
Minimax	v15–v17	10.000	Cerca analítica d'un torn sobre v14.
MCTS ras	v18–v20	1.000	Simulació rasa; el cost limita n .
Imitació	v21, v22	10.000	Política humana d'alt nivell i executor.
PPO	model A (MaskablePPO)	10.000 vs v12	Experiment separat, no fila de la matriu.

Directori: data/benchmarks/all_10k/gen9randombattle.

- 28 agents (Taula 6.1): 6 agents de referència, v1–v14, v15–v17, v18–v20, v21 i v22.
- Matriu dirigida $28 \times 28 = 784$ fitxers {agent}_vs_{opponent}.csv. La fila correspon a l'agent del camp heuristic del CSV.
- **Cel·la per defecte: 10.000 partides.**
- **Si qualsevol dels dos bàndols és v18, v19 o v20:** $n = 1.000$. Cada decisió de cerca executa 100 simulacions de cinc torns amb LocalSim; el cost per partida és molt superior al d'una heurística.
- Cada fila no MCTS agrega $25 \times 10.000 + 3 \times 1.000 = \mathbf{253.000}$ partides.
- Cada fila MCTS agrega $28 \times 1.000 = \mathbf{28.000}$ partides.
- En total, la matriu conté $625 \times 10.000 + 159 \times 1.000 = \mathbf{6.409.000}$ batalles dirigides.

Les mitjanes globals de les files MCTS i no MCTS no estimen exactament la mateixa quantitat. A les files no MCTS, els tres oponents MCTS pesen una desena part que els altres oponents; a les files MCTS, tots els oponents tenen el mateix pes. Per comparar paradigmes s'utilitzen, per tant, enfrontaments comuns, especialment el resultat contra v12, i no una ordenació única de les mitjanes globals.

3.4.5 Orientacions recíproques i autojoc

El disseny genera `A_vs_B.csv` i `B_vs_A.csv` com a mostres independents, de manera que cada agent ocupa les dues orientacions del programari. Si no hi ha un efecte sistemàtic de l'orientació, la suma de les dues taxes s'espera propera al 100%; l'autojoc s'espera proper al 50%. Són controls de coherència, no partides aparellades amb els mateixos equips o les mateixes llavors.

3.4.6 La taxa global de victòries i l'Elo

La mitjana sobre 28 oponents inclou agents molt febles, autojoc i dues etiquetes que comparteixen implementació (`one_step` i `safe_one_step`). Per aquest motiu és una descripció de la matriu, no una mesura absoluta de força. Les comparacions principals utilitzen Abyssal, Simple Heuristic i `v12-v14`. El model Bradley–Terry (secció 3.6) resumeix els resultats en una escala ancorada a `random = 1000`, però també queda condicionat per la composició i el nombre de partides de la matriu.

3.4.7 Ladder humana

La classificació pública de `v14` és un protocol separat, no una fila de la matriu. Utilitza el mateix format contra persones, però els oponents no es mostregen ni es controlen com en l'avaluació local. La mostra complementa la validesa externa i no substitueix la lliga agent-contra-agent.

3.5 Espais formals

En els agents no neuronals hi ha fins a quatre moviments i cinc canvis legals; la Teracristal · lització es tracta com un modificador d'un moviment. L'observació combina el JSON de `request` amb l'historial d'informació revelada. El model PPO publicat utilitza un vector de 328 dimensions i un espai `Discrete(14)`; una extensió experimental posterior amplia l'observació a 346 dimensions. El model d'imitació utilitza 1.150 característiques tabulars.

Taula 3.5: Com cada paradigma representa observació i acció. El contracte extern (Showdown) és el mateix; canvia la representació interna.

Paradigma	Observació interna	Acció interna
Heurístiques / minimax	Objectes <code>Battle</code> de <i>poke-env</i> : actiu, banc, camp i historial revelat.	Argmax sobre moviments, canvis i Tera com a modificador.
MCTS ras	El mateix, més un estat determinat per a <code>LocalSim</code> .	UCB/PUCT sobre els fills de l'arrel; s'envia l'acció més visitada.
Imitació	1.150 característiques tabulars per a atacar/canviar; l'executor veu l'objecte <code>Battle</code> .	Binari d'alt nivell + moviment o canvi concret.
PPO	Vector de 328 (o 346 a la prova interrompuda) floats en $[0, 1]$.	Enter $0 \dots 13$ emmascarat.

3.6 Mètriques

3.6.1 Mètrica primària: taxa de victòries

$\widehat{TV} = \hat{p}$, amb interval de Wilson del 95% [80]. La interpretació es basa en l'interval i en la mida de l'efecte, no només en si el valor puntual supera el 50%:

- Un interval que inclou el 50% no aporta evidència suficient d'avantatge en aquell enfrontament.

- 55–60% contra un agent de referència fort com Abyssal: avantatge rellevant.
- 98% contra **random**: no discrimina entre agents competents.

Per al PPO, el comparador és **v12**. Un resultat per sota del 50% quantifica la distància respecte d'aquest oponent concret; no permet inferir directament la posició del PPO contra els altres 27 agents.

3.6.2 Mètriques secundàries i telemetria

El CSV de batalla conté identitat, HP final, canvis voluntaris i forçats, cops crítics, errors, efectivitat i comptadors específics:

- Heurístiques: perills d'entrada, preparació, comprovacions de debilitament, canvis segons l'enfrontament i Teracristal · lització.
- Cerca: moviments, canvis i discrepàncies respecte de **v14**. La taxa de discrepància divideix les accions diferents de la proposta heurística pel nombre de decisions resoltes per la cerca.
- Imitació: decisions d'atacar o canviar, probabilitat acumulada i activació de les proteccions tàctiques.

Aquestes columnes permeten descriure quan intervé cada mòdul, i no només el resultat final.

3.6.3 Elo Bradley–Terry

S'ajusta un model Bradley–Terry de comparacions per parelles [7] sobre la matriu dirigida i se'n transforma l'escala perquè **random** = 1000, seguint una interpretació de tipus Elo [21]. És un resum descriptiu de la matriu, diferent de l'Elo de la classificació pública. Com que no s'han calculat intervals de confiança per a aquestes puntuacions, diferències petites o valors arrodonits iguals no s'interpreten com a empats estadístics.

3.7 Protocols específics i abast

3.7.1 Matriu de 28 agents

La taxonomia (Taula 6.1) cobreix agents de referència, heurístiques, minimax, MCTS i imitació. El format és **gen9randombattle**. Cada parella (A, B) genera dos fitxers dirigits independents.

Els agents de referència són **random**, **max_power**, **one_step/safe_one_step** —dues etiquetes de **SafeOneStepPlayer**—, **abyssal** i **simple_heuristic**. La duplicació es conserva per traçabilitat dels experiments, però es té en compte en interpretar agregats.

3.7.2 Agents LLM (PokéChamp i PokéLLMon)

PokéChamp [31, 30] i PokéLLMon [24] es van considerar com una possible família addicional. La prova local va mostrar un cost aproximat de 40 minuts per partida en la configuració disponible, incompatible amb una cel · la de 10.000 partides. Per coherència mostral, es classifiquen com a prova d'integració i no com a sisè paradigma quantitatiu. El detall tècnic de la integració és al Capítol 5.

3.7.3 PPO contra v12

Experiment separat, mateix simulador. Disseny:

- Observació vectorial de l'estat parcial i espai discret emmascarat: 4 moviments, 4 moviments amb Teracristal · lització i 6 posicions d'equip.
- Seqüència d'entrenament: Random → MaxBP → v8 → v12. La fase contra v8 no va assolir el llindar de graduació previst; es documenta com una rampa incompleta.
- Inicialització: clonatge conductual (*behavioral cloning*) des de v8 (400 partides) abans del PPO.
- Avaluació final: contra v12, $n = 10.000$, ambdues orientacions. Control de coherència contra Random a $n = 1.000$.

v12 s'escull perquè és l'agent amb millor resultat observat a la matriu. Aquesta decisió produeix una prova exigent, però no situa el PPO dins d'una classificació completa.

3.8 Amenaces a la validesa i reproductibilitat

- **Comparabilitat computacional.** Els cinc paradigmes comparteixen simulador i format, però no pressupost: l'MCTS utilitza menys partides i el PPO no participa en la matriu. Els resultats comparen sistemes complets sota aquests límits, no la capacitat teòrica màxima de cada algorisme.
- **Selecció de variants.** Es proven diverses versions dins de cada família i se'n destaca la millor observada. Aquesta selecció posterior pot afavorir el màxim mostrat; caldria una nova mostra o múltiples llavors per estimar-ne el rendiment fora de la selecció.
- **Ablacions imperfectes.** Algunes versions heurístiques introdueixen més d'un canvi. Una diferència de taxa es pot associar al bloc incorporat, però no atribuir causalment a una única regla.
- **Independència i aparellament.** Les batalles es tracten com a independents. No s'han reutilitzat equips i llavors idèntics entre agents; un disseny aparellat podria reduir la variància de les diferències.
- **Multiplicitat.** La matriu conté 784 cel·les i nombroses comparacions exploratòries. No s'aplica una correcció familiar de proves; es prioritzen magnituds, intervals i patrons consistents, i s'evita interpretar diferències petites de manera aïllada.
- **Models apresos.** El llindar d'imitació es va seleccionar sobre la partició retinguda que també informa les mètriques del classificador. A més, no hi ha repeticions completes d'entrenament amb diverses llavors per a IL i PPO; la variabilitat d'entrenament queda sense quantificar.
- **Validesa externa.** Les conclusions es limiten a `gen9randombattle`, `poke-env 0.11.x` i les dates dels experiments. La mostra pública de v14 no és controlada i només complementa l'avaluació local.

El codi identifica cada agent mitjançant `AgentFactory`; els resultats de la matriu es desen a `data/benchmarks/all_10k/gen9randombattle`; i els pesos i JSON de PPO es documenten a `src/p05_ppo_dr1/RESULTS.md`. Els CSV s'escriuen incrementalment i permeten reprendre una execució. La reproducció exacta també requereix la versió de Showdown, els fitxers de Random Battle i els artefactes de model, que no queden descrits només pel codi font.

3.9 Fases de desenvolupament

1. Heurístiques v1–v14 com a seqüència d’ablacions.
2. Minimax d’un torn v15–v17 sobre v14.
3. MCTS ras v18–v20, amb $n = 1.000$ a les cel·les corresponents.
4. Imitació v21–v22: un mateix model de decisió d’alt nivell i dues formes d’execució.
5. Integració exploratòria de PokéChamp i PokéLLMon, seguida de la matriu quantitativa sense aquests agents.
6. PPO: clonatge conductual de v8, entrenament per reforç i avaluació contra v12.
7. Avaluació separada de v14 contra persones.

El capítol d’implementació tradueix cada fase a codi. El capítol de resultats manté explícita la mida mostral de cada comparació.

Capítol 4

Entorn de desenvolupament i infraestructura de còmput

La matriu de 784 cel·les i l'entrenament PPO requereixen una màquina estable, accés remot i supervisió d'execucions llargues. Aquest capítol documenta el maquinari, la xarxa, les notificacions i les dependències. El coordinador dels experiments es descriu al Capítol 5.

4.1 Organització del projecte

El desenvolupament s'ha organitzat amb un tauler Kanban dividit en objectius, tasques pendents, treball en curs i tasques completades. Cada targeta representa una unitat verificable, com una versió heurística, un agent de cerca, un entrenament o una secció de la memòria.




Figura 4.1: Tauler Kanban utilitzat per organitzar el desenvolupament del TFM.

4.2 Evolució de l'arquitectura

4.2.1 Fase 1: prototipatge en portàtil

El prototip va córrer en un Intel Core Ultra 7 155H (22 fils) amb 16 GB de RAM. Un disc NVMe d'1 TB dedicat a `data/` es va muntar amb `bind mount`. Amb 16 GB, múltiples Showdown + Python obligaven a `gc.collect()`, chunks petits i reinicis de Node.js: aquestes rutines neixen d'aquesta fase.

4.2.2 Fase 2: estació de treball

Els experiments finals s'executen en una torre amb AMD Ryzen 7 5700X3D (8 nuclis i 16 fils, 96 MB de memòria cau L3), 32 GB DDR4 i una GPU NVIDIA RTX 2080 de 8 GB. La matriu d'heurístiques, minimax, MCTS i imitació utilitza principalment la CPU. La GPU s'empra per a MaskablePPO i les proves amb models de llenguatge. El sistema i les dades de treball resideixen en una unitat NVMe.

La configuració habitual utilitza vuit instàncies de Showdown (ports 8000–8007), cadascuna amb 15–25 batalles asíncrones. Les cel·les heurístiques es completen molt més ràpidament que les d'MCTS; aquesta diferència de cost motiva els volums de 10.000 i 1.000 partides. L'avaluació PPO contra v12 també utilitza vuit ports.

4.3 Accés remot: Tailscale

El portàtil i la torre formen una xarxa privada amb **Tailscale** [67] (WireGuard). SSH va per aquesta malla, sense obrir el port 22 al WAN. L'editor (Cursor / VS Code) treballa amb Remote-SSH sobre el disc del servidor: el codi, els CSV i els checkpoints PPO viuen a la torre.

Les execucions llargues i els entrenaments PPO s'executen dins de **tmux**; així, una desconnexió del portàtil no interromp el coordinador ni el procés CUDA.

4.4 Bot de Telegram

Els scripts de llançament de `src/p00_core/scripts/runs_benchmark/` i el monitor `src/p00_core/scripts/seguretat_tfm.sh` envien notificacions mitjançant un bot de Telegram [68]. El token s'emmagatzema a `.env` i no es versiona.

Funcions que s'han usat de debò:

- **Avisos de progrés:** inici i final d'un enfrontament, reintents, temps d'espera i partides completades.
- **Supervisió de recursos:** temperatura de CPU i NVMe, ús de memòria i aturada d'emergència a 92°C.
- **Comandes interactives** mitjançant `seguretat_tfm.sh`: consulta de l'estat, resum de la sessió, registres i pausa o represa de l'execució.

Aquesta infraestructura permet supervisar les execucions sense exposar serveis directament a Internet: Tailscale proporciona l'accés remot i Telegram informa del progrés.

4.5 Dependències

El gestor de paquets és **uv** [3] amb Python **3.12** i `pyproject.toml`. Node.js [41] construeix Pokémon Showdown. Resum:

- **Nucli de combat:** `poke-env` ≥ 0.11 , < 0.12 [51]; Node.js [41] per a Showdown.
- **Dades / estadística:** `numpy` [23], `pandas` [71], `polars` [74], `scipy` [76].
- **ML tabular:** `scikit-learn` [43], `XGBoost` [18], Hugging Face Datasets [27].
- **Visualització i notebooks:** `matplotlib` [28], `seaborn` [78], `ipykernel`, `nbconvert`.
- **Utilitats:** `tqdm`, `tabulate`, `orjson`, `requests`, `websockets`.

- **Aprenentatge per reforç (extra rl / gpu):** Gymnasium [72], Stable-Baselines3 [46], sb3-contrib (MaskablePPO) [45], PyTorch [42] i TensorBoard [69].
- **LLM / Pokechamp (extra pokechamp):** Ollama [40], transformers, openai / anthropic / google-genai (backends opcionals), rich.
- **Qualitat:** Ruff [2] (format + lint), ty (tipus).
- **Sistema:** Git/GitHub, tmux, Tailscale [67], Telegram Bot API [68], L^AT_EX (report/).

El fork `pokechamp/` s'incorpora al `sys.path` dels processos que necessiten `LocalSim` o `Abyssal`. Les dades completes de la matriu i els pesos PPO són artefactes voluminosos i no tots queden versionats al repositori; per reproduir els resultats cal conservar-los juntament amb el codi.

Capítol 5

Implementació dels cinc paradigmes

Aquest capítol tradueix la metodologia a programari: el coordinador que permet executar milers de partides, les implementacions de cada paradigma i el flux d'entrenament de MaskablePPO.

5.1 Mapa del programari

- `src/p00_core/engine/`: `benchmark.py` (coordinador) i `worker.py` (procés de treball).
- `src/p00_core/core/`: `BaseHeuristicv1`, `AgentFactory`, matemàtica compartida.
- `src/p01_heuristics/agents/internal/`: `v1.py ... v14.py`.
- `src/p03_minimax/`: `v15-v17`.
- `src/p04_mcts/`: `v18-v20`, `LocalSim` via fork `Pokechamp`.
- `src/p02_imitation_learning/`: `dataset` → `features` → `XGBoost` → `v21/v22`.
- `src/p05_ppo_drl/`: `Gymnasium`, vectorització, clonatge conductual i `MaskablePPO`.
- `src/p00_core/online_bot/`: connector amb la classificació pública.
- `src/p00_core/scripts/`: llançament de benchmarks, `seguretat_tfm.sh` (Telegram) i avisos `avis_telegram` als scripts de `runs_benchmark/`.




Figura 5.1: Mapa de mòduls. p00 aïlla simulació i persistència; p01–p05 només afegeixen la política. Minimax, MCTS i imitació reutilitzen coneixement de p01; PPO té entorn, checkpoints i avaluació propis.

5.1.1 Com es reparteixen les responsabilitats

`p00_core` conté tot allò que ha de ser independent del paradigma: interfície base, fàbrica, instrumentació de la batalla, coordinació, escriptura i informes. Els directoris `p01`–`p05` només contenen la lògica específica de cada família. Aquesta separació evita que una nova versió hagi de conèixer ports, noms de fitxers o recuperació d'errors.

`p01_heuristics` és el nucli de coneixement explícit i també proporciona operacions reutilitzades per les famílies posteriors. `p02_imitation_learning` és un flux de dades complet: descàrrega, exploració, extracció de característiques, entrenament i adaptador de l'agent. `p03_minmax` i `p04_mcts` encapsulen les dues cerques. `p05_ppo_dr1` es manté separat perquè utilitza un entorn d'aprenentatge, checkpoints i un protocol d'avaluació propi.

5.2 Motor de batalla i capa d'integració

5.2.1 Servidor local de Pokémon Showdown

Pokémon Showdown [36] s'executa com un procés Node.js local. Cada instància escolta en un port diferent i manté les sales de batalla en memòria. El llançament bàsic és:

```
node pokemon-showdown start --port 8000 --no-security
```

L'opció `--no-security` elimina l'autenticació en el servidor local. Els clients intercanvien missatges de text per WebSocket. Un missatge `|request|` conté les accions legals i la part observable de l'estat; l'agent respon amb una ordre `/choose`. Showdown resol prioritats, velocitats, dany i efectes aleatoris, i retorna el registre del torn.




Figura 5.2: Intercanvi simplificat entre un agent i una instància local de Showdown.

5.2.2 Adaptació amb *poke-env*

poke-env [51] converteix el protocol textual en objectes `Battle`, `Pokemon` i `Move`. L'únic contracte que ha d'implementar una política és una funció de decisió sobre l'objecte `Battle`. La biblioteca torna a convertir l'acció en una ordre vàlida de Showdown.




Figura 5.3: Flux d'adaptació entre el protocol de Showdown i una política Python.

El projecte fixa *poke-env* a la sèrie 0.11.x perquè tota la matriu es va executar amb aquesta API. El fork *pokechamp/* s'afegeix només als processos que necessiten Abyssal, agents de llenguatge o *LocalSim*. L'estat real de la partida continua vivint al servidor Showdown; *LocalSim* només s'utilitza dins de les simulacions de l'MCTS.

5.3 Arquitectura coordinador–processos de treball

5.3.1 Del BattleManager inicial al motor de la matriu

La primera materialització del gestor conceptual és `core/battle_manager.py`. **BattleManager** rep una versió, un oponent, un servidor, el nombre de partides i la concurrència. Crea els dos jugadors, executa lots amb `battle_against`, extreu victòria, torns, equips, HP i comptadors, i afegeix les files a un CSV. Aquest component va permetre validar el cicle complet amb un únic procés i continua sent útil per a execucions petites.

L'escala final en va mostrar tres límits: un sol intèrpret acumulava memòria, el nom de sortida estava lligat a una execució concreta i la coordinació no construïa ni reprenia tota la matriu. `benchmark.py` i `worker.py` conserven les responsabilitats del **BattleManager**, però les separen: el primer calcula treball pendent i administra recursos; el segon executa un lot aïllat i desapareix. Aquesta evolució explica per què el repositori conté totes dues vies i evita presentar el motor final com una arquitectura decidida sense prototipatge.

5.3.2 Per què subprocessos

Les execucions llargues en un únic procés Python acumulaven objectes **Battle**, estructures de cerca i recursos asíncrons. Per aïllar l'estat i obtenir paral·lelisme de CPU, s'utilitza `multiprocessing` amb el context `spawn`; així s'evita heretar bucles d'esdeveniments i connexions obertes. Cada procés de treball inicia un intèrpret nou, utilitza un port exclusiu de Showdown i escriu un CSV temporal. Quan finalitza, el sistema operatiu recupera els recursos del procés.




Figura 5.4: Arquitectura de la matriu experimental, sense memòria compartida entre processos de treball.

5.3.3 Coordinador, cua de ports i processos efímers

`benchmark.py` materialitza el gestor conceptual del Capítol 3. Primer resol les etiquetes d'agent i oponent, construeix el producte d'enfrontaments i consulta quantes files ja existeixen a cada CSV. Després inicia les instàncies de Showdown i crea una cua asíncrona amb els ports lliures. Cada lot consumeix un port, executa `worker.py` com un procés nou i retorna el port a la cua quan acaba.

`worker.py` instancia els dos agents, juga les batalles asíncrones i converteix cada `Battle` acabada en una fila de telemetria. El procés escriu primer en un fitxer temporal exclusiu del port. El coordinador només fusiona lots acabats; així dos processos no escriuen simultàniament sobre el mateix CSV final.

La matriu final utilitza vuit ports. La concurrència és de 25 batalles per procés per als agents ràpids i de 15 quan intervé minimax o MCTS. Això produeix aproximadament entre 120 i 200 batalles simultànies, però manté separats els espais de memòria Python i les instàncies Node.js.

5.3.4 Represa i escriptura per blocs

Si `v12_vs_abyssal.csv` ja té 4.320 files, el coordinador calcula $n_{to_run} = 10.000 - 4.320$ i només executa les partides pendents. El CSV és la font de l'estat de progrés. Cada procés treballa en blocs de 25 batalles, escriu els resultats i executa `reset_battles()` i `gc.collect()` abans de continuar.

El cost varia notablement segons el paradigma: les notes de desenvolupament situen les heurístiques al voltant de 0,01–0,1 s per partida i l'MCTS al voltant de 2–6 s. El temps d'espera d'un lot és $\max(7200, 40 \cdot n_{batch})$ segons, prou ampli per no interrompre una cerca activa i finit per detectar un procés bloquejat.

5.3.5 Reinici de Showdown

En execucions llargues es va observar creixement de memòria al procés V8 de Node.js. El coordinador reinicia les instàncies de Showdown cada N enfrontaments actius, configurable amb `-restart-every`. El motor té un valor per defecte de 3, mentre que el llançador de la matriu final utilitza 20. El reinici sacrifica uns segons de disponibilitat a canvi de limitar l'acumulació de memòria.

5.3.6 Esquema CSV

Cada fila representa una batalla. L'esquema final té **73 columnes**: identitat (`battle_id`, `format`, `heuristic`, `opponent`, `won`, `turns`), errors i accions de reserva, HP i Pokémon debilitats, canvis voluntaris o forçats, esdeveniments aleatoris i telemetria del paradigma (`search_diff`, `xgb_stays`, `ko_guards`, `terastallized`, entre d'altres). `StatsBattle` intercepta missatges del protocol, com `|-crit|`, abans que la capa d'alt nivell els descarti.

5.3.7 Automatització de la matriu

`run_paradigm_comparison_10k.sh` defineix les etiquetes de files i columnes i invoca el coordinador per a cada parella. El mateix script adapta el pressupost: 10.000 partides i concurrència 25 per a les famílies ràpides; concurrència 15 per a minimax; i 1.000 partides amb concurrència 15 quan intervé MCTS. També aplica fins a 100 reintents davant d'un lot fallit, reinicia Showdown cada 20 enfrontaments actius i envia avisos de progrés. Aquesta capa és la que converteix el motor genèric en l'experiment concret de 784 cel · les.




Figura 5.5: Monitoratge durant una execució al prototip de 16 GB. La memòria creix mentre s'acumulen batalles i cau després de reiniciar processos; el patró va motivar els blocs curts, la recollida de memòria i els reinicis de Showdown. Si la captura original no és al directori d'imatges, el diagrama recull el mateix patró de dent de serra.

5.3.8 Contracte BaseHeuristic1v1

S'aplica el patró *Template Method*: `choose_move` crida `_pre_move_hook` per a sortides prioritàries, `_select_action` per a la lògica principal i, si cal, `choose_random_move` com a recurs de reserva. Una excepció incrementa `error_moves` i produeix una acció legal aleatòria, de manera que no bloqueja la batalla.

`AgentFactory.create("v20")` és l'únic punt d'instanciació. La fàbrica també resol àlies històrics: per exemple, `ml_advanced`, `v21` i `v21_xgboost` apunten al mateix agent. Els agents de referència són adaptadors locals de `random`, `max_power`, `simple_heuristic`, `safe_one_step` i `abyssal`. Centralitzar els noms evita que els scripts antics obliguin a duplicar implementacions.

5.4 Heurístiques v1–v14: incorporació de coneixement

La seqüència estudia quins blocs de coneixement s'associen amb canvis de rendiment a Random Battle. La genealogia de codi té branques: `v1`→`v2`→`v3`→`v6`; `v4`/`v5` formen variants laterals; `v7` reescriu l'estratègia, i `v8`–`v14` parteixen d'aquest nucli. Aquesta genealogia no pressuposa una millora monotònica. El diagrama de disseny és la Figura 3.2 del Capítol 3.

5.4.1 Flux de decisió compartit

`BaseHeuristic1v1` proporciona el cicle de vida i els comptadors; `common.py` concentra operacions reutilitzables de tipus, velocitat i estimació de dany. Les versions avançades no copien tot el mètode de decisió: especialitzen els punts d'extensió necessaris.

El flux habitual és:

1. detectar un canvi forçat o una batalla en un estat incomplet;
2. executar dreceres prioritàries, especialment un debilitament segur;
3. construir els candidats de moviment i canvi;
4. assignar una puntuació ofensiva, defensiva i estratègica a cada candidat;

5. decidir si la Teracristal · lització modifica el millor moviment;
6. validar l'ordre i, només si la política no pot retornar-ne cap, utilitzar una acció legal de reserva.

Cada versió afegeix informació a un d'aquests passos. Aquest punt és important: **v12** no és només una fórmula amb més termes, perquè modifica la selecció del substitut i l'ús d'un recurs d'una vegada per partida; **v14** tampoc és simplement **v13** amb un pes diferent, perquè manté estat sobre el comportament rival.

Taula 5.1: Correspondència entre les fases heurístiques i els components implementats.

Versions	Component principal implementat
v1–v6	Estimadors successius de dany, seguiment lleuger de moviments, camp i prioritat.
v7–v8	Nova puntuació de l'enfrontament, canvis voluntaris i immunitats conegudes.
v9–v11	Regles de torn lliure, preparació, perills d'entrada, estats, sacrificis i pivots.
v12	Teracristal · lització ofensiva/defensiva i selecció del substitut per puntuació.
v13	Inferència amb moviments revelats, bloqueig Choice, recuperació i política conservadora.
v14	Perfil persistent del rival, sondeig inicial, rang de dany i resolució de finals.

5.4.2 Evolució de les versions

v1–v6 (altiplà de dany). **v1** maximitza $bp \times eff \times STAB$. **v2** afegeix estadístiques i penalització per cremada; **v3**, seguiment de moviments i canvis simples; **v4/v5**, clima, terreny i modificadors; i **v6**, prioritat. Aquest grup permet estudiar els rendiments decreixents d'afinar només el càlcul de dany.

v7 (salt posicional). La versió reescriu el càlcul amb estadístiques modificades i introdueix el **canvi per puntuació de l'enfrontament**, inspirat en Abyssal. És el primer agent que valora explícitament un canvi voluntari. Els perills d'entrada i els moviments de preparació s'incorporen a **v9**.

v8 / v10. **v8** incorpora objectes, habilitats, pantalles i *Trick Room*. **v10** incorpora condicions d'estat, sacrificis amb pocs HP i moviments de pivot.

v9 / v11 (control del ritme). Els perills d'entrada i els moviments de preparació només es valoren en un torn considerat lliure. **v11** combina **v9** i **v10**.

v12 (Gen 9 al camp). Dues peces natives del format:

1. Teracristal · lització ofensiva i defensiva.
2. Selecció del substitut segons l'enfrontament després d'un debilitament, en lloc d'escollir sempre la primera posició.

v12 conserva les regles anteriors i afegeix dues mecàniques específiques de la Generació IX. És l'agent amb la taxa de victòries observada més alta de la matriu, però l'experiment no separa l'efecte de les dues incorporacions.

v13. Valora l'enfrontament amb els **moviments ja revelats** del rival, i no només amb els tipus. També incorpora bloqueig per objectes Choice, expulsió de rivals amb modificadors, recuperació i una política de Teracristal · lització més conservadora.

v14 (orientat a humans). Classifica el rival com a PREDICTIVE o CONSERVATIVE segons la seva taxa de canvis, i fa sondeig als torns inicials amb moviments com *Protect*, *U-turn* o *Knock Off*. Aproxima el dany amb l'interval $(0,85 \times \text{score}, \text{score})$ i aplica una resolució d'un torn quan queden com a màxim dos Pokémon per bàndol. Aquestes decisions estan orientades a rivals humans i poden cedir ritme contra polítiques deterministes.

Totes les versions registren comptadors. A v14, `ko_checks` arriba aproximadament a 15 per partida perquè l'interval de dany s'avalua sovint.

5.5 Minimax d'un torn v15–v17

Els tres agents hereten `HeuristicV14`. Abans de construir la matriu, apliquen dreceres com un debilitament garantit; v16/v17 també tracten moviments de preparació rivals, absorció d'estats i pivots inicials. Si no hi ha drecera, enumeren les accions pròpies contra moviments rivals revelats i un canvi hipotètic. La velocitat i la prioritat es resolen analíticament; `LocalSim` no intervé.

5.5.1 Construcció de la matriu d'un torn

La implementació crea una fila per cada acció pròpia legal i una columna per cada resposta rival considerada. Les respostes no provenen de l'estat complet de Showdown, que és ocult, sinó dels moviments ja revelats i d'una opció genèrica de canvi quan l'enfrontament és desfavorable. Per a cada parella s'estima:

- quin participant actua primer segons prioritat i velocitat;
- si l'acció ràpida debilita el rival i anul·la la segona;
- els HP esperats després de l'intercanvi;
- bonificacions o penalitzacions de posició.

El valor d'una acció pròpia és el mínim de la seva fila; l'agent escull la fila amb el màxim d'aquests mínims. Aquest càlcul és barat perquè no crea una batalla simulada per cas. També és deliberadament limitat: no veu què succeeix dos torns després d'un canvi o d'un moviment de preparació.

La fulla de v15 combina HP i qualitat de l'enfrontament, amb una penalització multiplicada per 1,5 per al dany rival. v16 afegeix bonificacions de 0,25–0,35 per preparació, perills d'entrada, recuperació i estats. v17 suma 0,15 al pitjor cas de l'acció proposada per v14. Tots tres mantenen un horitzó d'un torn.

Per saber què aporta realment el mòdul, abans de la cerca es demana també l'acció que hauria triat v14. `search_diff` augmenta quan el maximin la substitueix; `search_moves` i `search_switches` descriuen el tipus d'acció resultant. Com que les dreceres s'executen abans, la matriu intervé en el 16–18% dels torns i no defineix tota la política.

5.6 MCTS ras v18–v20

Mateix professor v14, mateix pressupost:

- 100 simulacions per torn de cerca, $C = 1,4$.
- UCB a l'arrel: cada iteració tria un fill, executa una simulació de cinc torns amb `LocalSim` i actualitza el valor del fill.
- La determinització copia els moviments *revelats* del rival.
- Fills arrel: moviments *i* canvis; es juga l'argmax de visites.

5.6.1 Simulació local i actualització de l'arrel

Per a cada decisió, l'agent copia l'estat observable a `LocalSim`, crea un fill per acció legal i inicialitza-ne visites i valor acumulat. Cada iteració selecciona un fill amb UCB1 o PUCT, aplica l'acció i continua amb una política de simulació durant cinc torns. En acabar, una funció de fulla resumeix HP, membres debilitats, modificadors, estats i camp; aquest valor s'acumula al fill de l'arrel.

No es conserva un arbre profund entre iteracions ni entre torns reals. Per això el cost i la interpretació són els d'un bandit a l'arrel amb simulacions, encara que el mòdul es presenti dins de la família MCTS. La decisió final és l'acció amb més visites, no necessàriament la de valor mitjà més alt.

v18: UCB1, fulla basada en HP, modificadors, estats i perills d'entrada, amb només la drecera de debilitament abans de l'arrel. **v19:** UCB1, fulla amb rols i amenaça de debilitament d'un cop, i les dreceres tàctiques de **v14** abans de l'arbre. **v20:** **v19** + **PUCT** amb prior 0,70 sobre l'acció **v14**.

La determinització només pot copiar moviments rivals revelats. A més, `LocalSim` i el procés `Node.js` de `Showdown` no són el mateix motor. Un objecte o efecte no reproduït exactament pot introduir soroll en els valors. El minimax d'un torn no té aquesta font d'error, perquè només utilitza l'estimador analític compartit.

5.7 Imitació v21–v22

5.7.1 Flux de dades

La implementació es divideix en quatre directoris que corresponen a etapes reproduïbles:

1. `s01_download/` descarrega repeticions i conserva metadades de format i Elo;
2. `s02_edu/` valida distribucions, proporció atacar/canviar i composició del metajoc;
3. `s03_training/` transforma els torns en una matriu tabular, separa per batalla i entrena XGBoost;
4. `s04_agent/` carrega els models i converteix-ne la predicció en una acció legal de `Showdown`.

La separació és necessària perquè una repetició no conté directament el mateix objecte que rep l'agent en línia. El procés d'extracció reconstrueix, torn a torn, HP, camp, ús de Tera, identitat dels actius i acció observada. La llista de característiques desada amb el model garanteix que l'agent en producció generi les columnes en el mateix ordre que durant l'entrenament.

5.7.2 Dades

Les dades són repeticions de `gen9randombattle` de jugadors amb Elo ≥ 1800 , obtingudes mitjançant `Hugging Face` i `PokéChamp` entre 2023 i 2025. Contenen aproximadament 1,12 milions de torns. `GroupShuffleSplit` separa les dades per `battle_id` per evitar que torns d'una mateixa batalla apareguin a entrenament i validació. `scale_pos_weight` compensa un desequilibri aproximat de 2,88 entre atacar i canviar.

La classe «canviar» representa aproximadament el 25,8% dels torns. La taxa és especialment alta al començament —on també hi ha canvis forçats o ajustos de posició— i disminueix amb la durada. La identitat del Pokémon actiu conté senyal predictiu, però també pot fer que el model memoritzi patrons del metajoc de 2023–2025. Per això els resultats no s'extrapolen automàticament a una altra generació o a un altre format.




Figura 5.6: Validació exploratòria de les repeticions humanes: desequilibri entre atacar i canviar, evolució de la taxa de canvi amb el torn i espècies més representades. La figura descriu el conjunt de dades, no el rendiment final de l'agent.




Figura 5.7: Taxa de canvi humana per espècie activa en una selecció del conjunt d'experts. La variació justifica incloure identitat i context, però no implica causalitat: espècie, rol, rival i estat de la partida estan correlacionats.

5.7.3 Decisió d'alt nivell

El classificador XGBoost utilitza 1.150 característiques (HP, perills d'entrada, indicadors de Teracristal · lització i codificació de l'espècie activa, entre d'altres), 300 arbres, profunditat màxima 6, taxa d'aprenentatge 0,08, `subsample=0,85` i `colsample_bytree=0,85`. La sortida és $p(\text{canvi})$ i el llindar seleccionat és $\tau = 0,5525$ (`xgboost_advanced_threshold.json`). A la partició retinguda s'obtenen aproximadament 65,5% d'exactitud i 0,72 de ROC-AUC; el mateix conjunt es va utilitzar per seleccionar el llindar, fet que limita la independència d'aquestes mètriques.

5.7.4 Dues piles

v21 (HeuristicV21XGBoost). Hereta **v14**. L'ordre és: debilitament garantit, final amb com a màxim dos Pokémon, regles de preparació o absorció i, finalment, XGBoost. Si el model decideix canviar, utilitza el canvi de pivot o `_get_best_switch`; si decideix atacar, utilitza `_score_move`. Una protecció evita bucles de canvis. XGBoost intervé aproximadament en el 15% dels torns.

v22 (HeuristicV22PureIL). Hereta només de `BaseHeuristic1v1`. Si el model decideix canviar, avalua cada candidat com si fos l'actiu i selecciona el que minimitza $p(\text{canvi})$. Si decideix atacar, un segon model (`xgboost_move_evaluator.json`) puntua atributs com potència, STAB, efectivitat, estat i prioritat. Aquest segon model s'entrena amb candidats sintetitzats, no amb la identitat dels moviments de les repeticions; per tant, **v22** no és un clonatge complet de l'acció humana.

v21 és l'híbrid (macro de dades, micro de **v14**); **v22** executa els dos caps XGBoost.

5.8 Baselines

`random` i `max_power` provenen de *poke-env*; `simple_heuristic` és una còpia local adaptada a la Teracristal · lització, i `abyssal` prové de PokéChamp. `one_step` i `safe_one_step` instancien la mateixa classe, `SafeOneStepPlayer`; es mantenen com a etiquetes separades per traçabilitat, però no constitueixen dos algorismes diferents.

5.8.1 Integració exploratòria d'agents de llenguatge

`src/p01_heuristics/agents/llm/` adapta PokéChamp i PokéLLMon a la mateixa fàbrica. El fork `pokechamp/` prepara el context textual de la batalla i envia la consulta a un backend local d'Ollama [40]; la prova es va fer amb un model de la família Qwen [82]. El temps observat, de l'ordre de 40 minuts per partida, impedia executar la matriu. Aquesta integració es conserva perquè va permetre validar la compatibilitat i reutilitzar `Abyssal` i `LocalSim`, però no produeix un resultat comparatiu de tesi.

5.9 Bot en línia

`run_online_bot.py` connecta qualsevol etiqueta d'`AgentFactory` al servidor públic, en mode de classificació (`ladder`) o d'acceptació de reptes (`accept`). La mostra analitzada correspon a **v14**, usuari `SirPThesis`, els dies 9 i 10 de juny de 2026, amb 431 partides. Aquesta avaluació no és una fila de la matriu local.

5.10 PPO: MaskablePPO sobre Showdown

`src/p05_ppo_dr1/` és el cinquè paradigma, avaluat contra **v12** (Capítol 6).

5.10.1 Organització del mòdul i dels artefactes

El mòdul separa tres responsabilitats:

- `s01_env/`: vectorització de l'observació, correspondència entre índexs i ordres, màscara d'accions i recompensa;
- `s02_training/`: bucle comú, scripts de cada fase, clonatge conductual, callbacks, checkpoints i gràfiques;
- `s03_evaluation/`: càrrega d'un model congelat i avaluació contra un oponent fix amb una o dues orientacions.

Els pesos no s'emmagatzemen al codi font, sinó a `data/models/ppo/`. Cada fase té un directori propi (`p1_random`, `p15_maxbp`, `p2_v8`, `p3_v12`); `plots/` conserva hiperparàmetres i corbes, i `eval/` conserva els JSON de les avaluacions. Aquesta separació evita confondre una corba d'entrenament amb el resultat obtingut per un checkpoint congelat.

5.10.2 Entorn

`PokemonMaskedEnv` encapsula `SinglesEnv` de *poke-env* en el format `gen9randombattle`. L'observació és un vector normalitzat que codifica HP, tipus, estat i modificadors de l'actiu; quatre moviments; l'equip propi; part de l'equip rival revelat; clima, terreny i perills d'entrada; disponibilitat de la Teracristal · lització; velocitat; `force_switch` i `trapped`. El model de l'avaluació final té **328** dimensions. Una extensió posterior n'afegeix 18, però correspon a un experiment interromput i no al resultat principal.

Taula 5.2: Composició del vector d'observació de MaskablePPO. El model A publicat té 328 dimensions; les fases 1 i 1.5 n'utilitzaven 318 (sense dany estimat ni enfrontaments de canvi). Les 18 dimensions addicionals de la fase 4 no entren al resultat principal.

Bloc	Dim.	Contingut
Actiu propi / rival	35 + 35	HP, tipus, condició d'estat i set etapes de modificadors.
Moviments	84 + 4 + 4	Tipus i potència dels 4 slots, PP i STAB×efectivitat.
Banc propi i rival	6 × 6 + 1	HP, debilitats, indicador de capdavanter i estimació de supervivents rivals.
Camp	9 + 14 + 24 + 24	Clima, terreny i condicions laterals d'ambdós bàndols.
Teracristal · lització	3 + 20 + 20	Disponibilitat, ús previ i tipus Tera.
Velocitat i restriccions	5	Comparació de velocitat, <code>force_switch</code> i <code>trapped</code> .
Afegits de fase 2	4 + 6	Dany estimat dels 4 moviments i enfrontament dels 6 canvis.
Total model A	328	Vector en $[0, 1]$, compatible amb els checkpoints de les fases 2 i 3.
Extensió de fase 4	+18	Enfrontaments del banc revelat, millor capdavanter, dany/defensa Tera i cost de perills.

L'acció és `Discrete(14)`:

A cada pas es calcula una màscara de legalitat que exclou moviments sense PP, una Teracristal · lització ja consumida i canvis a posicions no disponibles. `PPOPlayer` tradueix l'índex a `/choose`, també durant un canvi forçat.

5.10.3 Clonatge, arquitectura i recompensa

Abans de l'entrenament per reforç, `bc.py` genera tuples (o, m, a) d'observació, màscara i acció a partir d'un professor heurístic. L'ajust aplica entropia creuada emmascarada només a l'actor,

Taula 5.3: Espai d'accions **Discrete(14)** de MaskablePPO. La màscara de legalitat i la traducció a `/choose` comparteixen el mateix mapeig de slots [26].

Índex	Acció	Quan és legal
0–3	Moviment i de l'actiu	El slot té un moviment amb PP i no hi ha canvi forçat.
4–7	Moviment i + Teracristal · litzar	El moviment i és legal i la Tera encara no s'ha consumit.
8–13	Canvi a l'slot i de l'equip	El membre existeix, no està debilitat, no és l'actiu i no hi ha bloqueig de canvi.




Figura 5.8: Pas d'inferència de MaskablePPO. La màscara s'aplica abans de mostrejar; l'índex no s'envia mai directament al servidor, sinó com a ordre de Showdown.

amb un optimitzador Adam propi de taxa 10^{-3} durant 15 èpoques; no reutilitza la taxa molt menor de PPO. A la fase 2 es recullen 400 partides de `v8`, que produeixen 8.849 decisions. L'acord amb el professor passa del 43% al 88%, i la freqüència de canvi predita s'apropa a la del professor (21% davant del 23%). El clonatge no pretén ser el resultat final: situa la xarxa en una regió que ja produeix accions semblants a una política competent abans d'aplicar PPO.




Figura 5.9: Seqüència clonatge → reforç. El crític no s'entrena al clonatge; PPO n'aprèn el valor a partir de la recompensa modelada un cop l'actor ja imita el professor.

MaskablePPO [45, 53, 47] s'executa sobre PyTorch [42]. La política i la funció de valor utilitzen una xarxa de dues capes de 256 unitats. Els scripts registren `n_steps=2048`, $\gamma = 0,99$ i quatre èpoques d'actualització; el lot és de 256 amb quatre entorns i de 512 amb vuit o més. La taxa d'aprenentatge i l'entropia canvien entre fases. El model A publicat utilitza observació de 328 dimensions, vuit entorns i taxa 5×10^{-5} .

La recompensa d'entrenament combina:

- 30 punts per victòria;
- 2 punts per diferència de Pokémon debilitats;
- 1 punt per diferència d'HP;
- increments per modificadors ofensius, condicions d'estat i perills al camp rival;
- penalització pels perills al camp propi;
- un cost de 0,02 per pas per desincentivar episodis innecessàriament llargs.

El codi desa el valor potencial anterior i només afegeix la diferència de la part tàctica, per no tornar a premiar indefinidament el mateix estat. Tot i així, la recompensa modelada defineix l'objectiu d'entrenament i pot introduir preferències diferents de la victòria terminal. Per aquest motiu, l'avaluació final només utilitza victòries i derrotes.

5.10.4 Execució de les fases 1, 1.5, 2 i 3

La Taula 5.4 diferencia el criteri dissenyat, l'avaluació congelada i la decisió presa. Les taxes de les corbes d'entrenament no substitueixen la columna de validació.

Taula 5.4: Implementació i validació del currículum PPO. «Superada» es refereix al llindar previst, no al fet que s'executés una fase posterior.

Fase	Oponent	Canvi implementat	Validació congelada	Decisió
1	Random	PPO inicial, 318 dimensions, 4 entorns, 500k passos.	91,8% a 1.000; llindar 90%.	Superada
1.5	MaxBP	Reprèn fase 1; taxa 2×10^{-4} , 500k passos.	70,5% a 1.000; llindar $> 70\%$.	Superada per estimació puntual
2	v8	Amplia a 328 dimensions, 400 partides de clonatge, 8 entorns.	40,6% a 1.000; llindar $> 55\%$.	No superada
3	v12	Continua des de fase 2 i prova taxes/entorns diferents.	Model A: 34,1% a 10.000.	Mesura final

Fase 1: Random. La política comença sense coneixement estratègic. L'objectiu és verificar que aprèn la legalitat, redueix la durada dels episodis i domina una política aleatòria. L'avaluació de 1.000 partides obté 91,8%, per sobre del 90%, i el checkpoint passa a la fase 1.5.


Fase 1.5: MaxBasePower. El següent oponent sempre busca potència base alta. Exigeix més que Random, però continua sent previsible. Una primera avaluació va quedar en 64,1% i no va superar la porta. L'entrenament es va reprendre sense aturada prematura i el checkpoint posterior va obtenir 70,5%, lleugerament per sobre del llindar. Com que $n = 1.000$ implica un interval ample, aquesta «graduació» s'ha d'entendre com una regla operativa basada en l'estimació puntual, no com evidència d'un marge sòlid.

Fase 2: v8. També s'amplia l'observació de 318 a 328 dimensions per representar millor els enfrontaments de l'equip. Les primeres passades només amb PPO es van mantenir al voltant del 29–30%. Un primer clonatge reutilitzava l'optimitzador de PPO a 5×10^{-5} i gairebé no ajustava l'actor. La versió final separa els optimitzadors, clona 400 partides de v8 amb Adam a 10^{-3} i continua 100.000 passos amb PPO. La taxa d'entrenament puja, però la validació és 40,6%, lluny del 55% previst. Per tant, el currículum **no supera formalment aquesta fase**.


Fase 3: v12. Tot i el resultat anterior, es continua contra v12 per mesurar si l'entrenament directe redueix la distància respecte del millor agent de la matriu. Es proven dues configuracions. El resultat de tesi és el model A, `p3_v12_lr5e5_flat.zip`, amb taxa 5×10^{-5} i vuit entorns. Una passada secundària amb taxa $1,5 \times 10^{-4}$ i setze entorns produeix la corba guardada al directori de fase 3, però no és el punt de control de la xifra de 10.000 partides.

5.10.5 Avaluació i preservació del model principal


`eval_checkpoint.py` carrega un checkpoint sense actualitzar-lo, l'associa a un `PPOPlayer` i juga en una o dues orientacions. El model A es prova contra v12 en 10.000 partides i contra Random en 1.000 com a control. El codi impedeix sobreescrivre accidentalment el fitxer principal. Els JSON d'avaluació documenten victòries, orientació, durada i interval; algunes validacions intermèdies antigues només es conserven a les notes perquè els noms de JSON es van reutilitzar.




(a) Fase 1 contra Random.



(b) Fase 1.5 contra MaxBP.



(c) Fase 2 contra v8.



(d) Passada secundària de fase 3 contra v12.

Figura 5.10: Corbes de les quatre etapes del currículum. Són taxes durant l'entrenament sobre una política canviant; les validacions independents són les de la Taula 5.4. El panell de fase 3 correspon a la passada secundària, no al model A publicat.

Una extensió posterior amplia l'observació a 346 dimensions i clona **v14** contra **v12**. S'interromp al voltant de 340.000 passos i es presenta només com a diagnòstic. No substitueix el model A ni la seva avaluació final.

Capítol 6

Resultats

Aquest capítol analitza la matriu de 28 agents i l'experiment PPO. Les fonts internes són els 784 CSV de `data/benchmarks/all_10k/gen9randombattle`, els informes de `src/p00_core/reporting/agents/`, `heuristics_and_imitation_thesis_analysis.md` i `src/p05_ppo_drl/RESULTS.md`.

La lectura separa tres nivells. Un **resultat observat** és una taxa o un comptador derivat dels fitxers. Una **interpretació** relaciona diversos indicadors amb el disseny de l'agent. Una **hipòtesi explicativa** proposa què podria haver causat el patró, però requeriria una ablació o una repetició específica per confirmar-se. Aquesta distinció permet explicar els resultats sense convertir una correlació de telemetria en una conclusió causal.

6.1 Protocol de lectura dels resultats

6.1.1 La matriu

28 agents, cadascun com a *nosaltres* contra 28 oponents, format `gen9randombattle`. Fitxers dirigits `A_vs_B.csv`. El PPO es llegeix a part, contra `v12`, a la secció 6.11.

Taula 6.1: Taxonomia dels 28 agents de la matriu `gen9randombattle`. Els identificadors de codi es mantenen en anglès. El prefix del mapa de calor indica la família: (H) heurística, (MM) minimax, (MCT) MCTS, (IL) imitació i (B) agent de referència. El PPO s'avalua separatament contra `v12`.

Identificadors	Paradigma	Descripció
<code>random</code> , <code>max_power</code> , <code>one_step</code> , <code>safe_one_step</code> , <code>abyssal</code> , <code>simple_heuristic</code> <code>v1-v14</code>	Referències (B)	Agents de <i>poke-env</i> i PokéChamp: atzar, potència base, un pas de dany i regles d'enfrontament.
<code>v15-v17</code>	Heurístiques (H)	Seqüència incremental de coneixement: dany, posició, perills d'entrada i Teracristal·lització, entre altres components.
<code>v18-v20</code>	Minimax d'un torn (MM)	Maximin analític d'un torn amb <code>HeuristicV14</code> com a base.
<code>v21</code>	MCTS ras (MCT)	UCB a l'arrel i 100 simulacions de cinc torns amb <code>LocalSim</code> ; cel·les amb $n = 1.000$.
<code>v22</code>	Imitació híbrida (IL)	XGBoost decideix atacar o canviar i <code>v14</code> executa l'acció.
	Imitació (IL)	El mateix classificador d'alt nivell; el model de moviments puntua potència, STAB i efectivitat.

La fila d'una taula o d'un mapa de calor és l'agent analitzat i la columna és l'oponent. Un 59,91 a la cel·la `v12 × Abyssal` indica que `v12` ha guanyat 5.991 de les 10.000 partides d'aquell

fitxer dirigit.

6.1.2 Precisió de les estimacions

Cada partida aporta un resultat binari $W \in \{0, 1\}$. L'equació (3.3) dona el marge màxim aproximat per a una proporció:

$$\pm 1,96\sqrt{0,25/n}.$$

A $n = 10.000$ és $\pm 0,98$ pp i a $n = 1.000$, $\pm 3,1$ pp. Per a la diferència entre dues proporcions independents properes al 50%, els marges aproximats són 1,39 i 4,38 pp, respectivament. Els intervals reportats són de Wilson; aquestes aproximacions serveixen per entendre l'ordre de magnitud.

La mida de la Pokédex no apareix directament a $\text{Var}(\hat{p}) = p(1 - p)/n$. L'objectiu és estimar una taxa marginal sota el generador d'equips de la Generació IX, no cobrir totes les combinacions possibles.

La Taula 3.3 (metodologia) recull els tres pisos. Aquí només cal recordar-los abans de llegir MCTS.

6.1.3 Volum i ponderació

- Una fila no MCTS conté **253.000** partides: 25×10.000 i 3×1.000 contra MCTS.
- Una fila MCTS conté **28.000** partides: 28×1.000 .
- La matriu completa conté **6.409.000** partides dirigides.
- Les orientacions recíproques sumen aproximadament el 100% i l'autojoc se situa prop del 50%, com s'espera en absència d'un efecte sistemàtic de l'orientació.

La taxa global d'una fila no MCTS pondera els oponents MCTS deu vegades menys que la resta; en una fila MCTS tots els oponents pesen igual. Per tant, aquestes taxes globals tenen diferent precisió i diferent ponderació. La comparació entre paradigmes es basa en cel · les comunes, no en una única ordenació global.

Les proves de desenvolupament amb 100 partides no formen part de les conclusions d'aquest capítol.

6.2 Controls globals de la matriu

Abans d'interpretar versions concretes, es comproven la cobertura, la distribució de taxes i la durada de les batalles. Aquests controls detecten cel · les incompletes, errors d'orientació i resultats extrems que podrien dominar una mitjana.

La Figura 6.1 confirma que la reducció de mostra segueix el paradigma i no l'agent que ocupa la primera orientació. Aquesta regularitat és important perquè evita comparar una cel · la MCTS parcial amb una cel · la no MCTS completa.

La distribució no és una campana estreta al voltant del 50%. Hi ha massa a prop dels extrems perquè alguns agents de referència són molt febles i perquè cada cel · la té una orientació recíproca. Aquesta és una altra raó per no interpretar la taxa global com una habilitat absoluta: millorar contra un agent que ja es derrota en el 95–98% de les partides té poc valor discriminant.

La durada complementa la taxa de victòries. Dues polítiques poden guanyar una proporció semblant, però una pot tancar abans mentre l'altra conserva més membres mitjançant canvis i recuperació. La cua drete també fa que la mitjana sigui sensible a bucles o estratègies d'atrició; per això les seccions següents combinen torns, membres restants i motiu dels canvis.




Figura 6.1: Nombre de partides completades a les 784 cel · les. El bloc fosc correspon a 10.000 partides; les files i columnes clares de v18–v20, a 1.000. La creu no és un buit de dades, sinó el pressupost reduït de l'MCTS.




Figura 6.2: Distribució de la taxa de victòries de les 784 cel · les dirigides. El centre prop del 50% conté autojoc i enfrontaments equilibrats; les cues reflecteixen diferències grans, especialment davant de Random i MaxBasePower.




Figura 6.3: Distribució de la durada de les batalles analitzades. La mediana és de 17 torns i hi ha una cua dreta de partides excepcionalment llargues.

6.3 Fil conductor de v1 a v22

La Taula 6.2 resumeix la seqüència abans d’analitzar-la. Les taxes globals són descriptives i no fan comparable l’MCTS amb la resta a causa de la ponderació diferent; la seva funció aquí és mostrar els canvis de règim.

Taula 6.2: Evolució de les preguntes i dels resultats entre v1 i v22.

Versions	Pregunta que materialitzen	TV global	Patró observat
v1–v6	Fins on arriba refinar dany i ordre immediat?	44–46%	Altiplà; telemetria gairebé invariable.
v7, v8, v10	Què aporta valorar la posició i canviar?	54–56%	Salt a v7; afegits posteriors petits.
v9, v11	Preparació i perills només en torns segurs?	59%	Nou augment i aparició dels comptadors de ritme.
v12	Què aporten Tera i el substitut informat?	69,01%	Increment més gran i 59,91% contra Abyssal.
v13, v14	Més inferència i model del rival sempre ajuden?	67,63 / 62,03%	Inversió: més complexitat, menys taxa global.
v15–v17	Un maximin d’un torn corregeix v14?	53,80–57,89%	La variant guiada discrepa menys i és la millor.
v18–v20	Cinc torns simulats superen l’horitzó curt?	53,29–59,66%	PUCT millora UCB1, però no supera v12.
v21, v22	Es pot imitar quan atacar o canviar?	58,71 / 33,49%	L’executor heurístic és determinant.

La primera meitat de la seqüència acumula coneixement explícit fins a v12. La segona canvia de paradigma, però la majoria de decisions encara passen per dreceres o priors derivats de v14. El patró general no és «algorisme més sofisticat, agent més fort», sinó «representació i coneixement adequats, seguits d’un mòdul que no els destrueixi».

PPO no rep un número v23 ni forma part de la taula global. La seva pregunta és paral·lela: si una política neuronal inicialitzada amb v8 pot arribar a v12. El resultat de 34,1% contra aquest comparador es tracta a la secció 6.11.

6.4 L'escala heurística: tres canvis de règim

Taula 6.3: Seqüència heurística v1–v14 (253.000 partides per fila). La taxa global no creix de manera monotònica: els increments principals apareixen a v7, v9 i v12, i les dues versions posteriors disminueixen.

Agent	Règim	TV (%)	contra Abyssal	Incorporació principal
v1–v6	Altiplà	44,25–45,86	30,6–32,5	Dany, clima, modificadors i canvis simples
v7	Posicional	54,25	40,80	Dany modificat i canvi segons l'enfrontament
v8	Posicional	55,43	42,30	Objectes, habilitats, pantalles, Trick Room
v9	Ritme segur	58,86	46,64	Perills i preparació <i>només en torns lliures</i>
v10	Posicional	55,66	41,86	Status, sacrifici $\leq 20\%$ HP, U-turn
v11	Ritme segur	59,26	47,50	Combinació de v9 i v10
v12	Mecànica Gen. IX	69,01	59,91	Tera i selecció del substitut
v13	Moviments revelats	67,63	55,34	Enfrontament amb moviments revelats i Tera conservador
v14	Model de rival	62,03	51,36	Perfil, sondeig inicial, rang de dany i final d'un torn




Figura 6.4: Taxa global de victòries de v1–v14 (253.000 partides per fila; les tres cel·les contra MCTS tenen $n = 1.000$). S'observen canvis destacats a v7, v9 i v12, seguits d'una disminució a v13 i v14.

6.4.1 Altiplà v1–v6: rendiments decreixents del càlcul de dany

La taxa global recorre **1,61 pp** (44,25–45,86%). Els enfrontaments interns se situen prop del 50%, mentre que contra Abyssal obtenen entre el 30,6% i el 32,5%.

En aquestes versions, afinar la fórmula de dany després d'incorporar efectivitat i STAB mostra rendiments decreixents. Els increments posteriors apareixen quan s'afegeixen decisions posicionals i recursos específics del format.

En el subconjunt de cinc oponents utilitzat per a aquesta telemetria (abyssal, v12, v14, v21 i random), registren aproximadament 1,04 canvis voluntaris per partida, cap Teracristal·lització i uns 4,3 recursos de reserva. Aquest perfil correspon a una política principalment ofensiva amb poca gestió posicional.

6.4.2 Primer salt: v7 (i v8/v10)

v7 incorpora dany amb modificadors i canvis segons l'enfrontament. La taxa global passa d'aproximadament 45,5% a **54,25%**; contra Abyssal, d'aproximadament 32% a **40,8%**.

v8 (objectes, habilitats, pantalles i *Trick Room*) afegeix 1,2 pp. v10 (estats, sacrificis i moviments de pivot) obté una taxa similar a v8 (55,66% i 55,43%).

La telemetria també canvia: els canvis voluntaris pugen a 1,47 per partida, `matchup_switches` arriba a 0,41 i les accions de reserva baixen d'aproximadament 4,6 a 2,18. L'agent passa a seleccionar canvis de manera explícita.

Els perills d'entrada i els moviments de preparació s'incorporen a v9; els comptadors `setup_uses` i `hazard_sets` deixen de ser zero.

6.4.3 Segon salt: v9 / v11

Amb v9, els perills d'entrada i els moviments de preparació només s'utilitzen quan l'agent és més ràpid i resisteix l'STAB rival. La taxa global puja a **58,86%** i el resultat contra Abyssal a **46,64%**. v11 combina aquest bloc amb v10 i afegeix 0,4 pp; la contribució addicional és petita en aquesta matriu.

v9/v11 són els primers amb aproximadament 1,6 moviments de preparació i 0,16 perills d'entrada per partida.

6.4.4 Tercer salt: v12

v12 combina Teracristal · lització i selecció del substitut després d'un debilitament. La taxa global és **69,01%**. És el primer agent intern que supera Abyssal i Simple Heuristic: **59,91%** i **59,75%**, respectivament ($n = 10.000$).

En el subconjunt amb telemetria, utilitza la Teracristal · lització **0,96 vegades per partida**, registra només **0,01** accions de reserva i conserva **1,84** Pokémon, davant d'1,44 a v11. El canvi de comportament és substancial.

En `gen9randombattle`, el bloc format per la Teracristal · lització i la selecció del substitut s'associa amb l'increment més gran de la seqüència. Com que totes dues modificacions s'introdueixen alhora, l'experiment no en separa l'efecte individual.




Figura 6.5: v1–v14 contra els sis agents de referència ($n = 10.000$ per cel · la). v12 és el primer que deixa Abyssal i Simple Heuristic clarament per sota del 50%. Contra `random`, totes les heurístiques arriben al 97–98% i la columna deixa de ser discriminant.




Figura 6.6: empremta tàctica de la seqüència heurística. v12 utilitza la Teracristal · lització gairebé una vegada per partida; v13, 0,20 vegades. ko_checks augmenta fins a aproximadament 15 a v14; la preparació i els perills d'entrada apareixen a partir de v9.

6.5 La inversió entre v12, v13 i v14

La complexitat creix de v12 a v14, però la taxa global observada disminueix. Aquest resultat mostra que l'herència de funcionalitats no implica una millora monotònica.

Taula 6.4: Enfrontaments directes, amb $n = 10.000$ partides independents per orientació. v12 i v13 no presenten una separació concloent; v14 queda per sota de tots dos. Les sumes recíproques properes al 100% són un control de coherència, no una prova amb partides aparellades.

Fitxer	TV (%)	Recíproc (%)	Suma
v12_vs_v13	50,65	48,85	99,50
v12_vs_v14	56,01	44,74	100,75
v13_vs_v14	57,71	41,60	99,31




Figura 6.7: Enfrontaments directes, amb $n = 10.000$ per orientació. v12 i v13 no presenten una separació concloent; v14 obté 44,74% contra v12 i 41,60% contra v13.

Les dues orientacions de v12 i v13 difereixen en 1,8 pp i no aporten una separació concloent. En canvi, v14 queda per sota de tots dos en els enfrontaments directes.

6.5.1 On v13 encara guanya

No està estrictament dominat. És el **millor heurístic contra cerca i contra l'IL híbrid**:

Oponent	v12	v13	v14
Minimax v15	63,96	67,59	60,07
Minimax v17	60,37	64,12	56,70
MCTS v18 ($n = 1k$)	66,1	67,7	59,8
IL v21	59,12	62,46	54,74
Baselines (bloc)	76,91	74,36	71,06
Altres heurístiques (bloc)	67,01	64,71	58,58

v13 acaba amb més Pokémon disponibles (avg_hp_us: 2,01, davant d'1,84 i 1,49) i juga partides més llargues (19,1 torns, davant de 17,9 i 18,5). El perfil és més conservador i orientat a l'atrició.

6.5.2 Per què no supera v12 en global

En el subconjunt amb telemetria, v13 utilitza la Teracristal · lització 0,20 vegades per partida, davant de 0,96 a v12; també fa més canvis voluntaris (3,58 davant d'1,37) i més canvis per enfrontament (2,57 davant de 0,25). Aquest comportament preserva més membres de l'equip, però pot cedir torns contra oponents deterministes. Les dades són compatibles amb aquesta explicació, però no aïllen causalment cadascun dels mecanismes.

6.5.3 Especialització de v14 i pèrdua de rendiment local

v14 incorpora modelatge de patrons humans, sondeig inicial, Teracristal · lització defensiva, un interval aproximat de dany i resolució d'un torn al final de la partida. Contra agents deterministes, aquests mecanismes poden consumir torns sense obtenir informació útil:

- El sondeig inicial substitueix algunes accions ofensives.

- El perfil de l'oponent aporta poc quan la política rival és fixa.
- `ko_checks` arriba a aproximadament 15 per partida, mentre que `setup_uses` baixa a 0,22.
- Contra Abyssal obté **51,36%**; v12 obté **59,91%**.




Figura 6.8: Enfrontaments de referència de v12, v13 i v14. Les files representen l'agent avaluat. Les cel·les MCTS tenen $n = 1.000$ i la resta, $n = 10.000$. v12 domina els agents de referència; v13 és més fort contra cerca i v21.




Figura 6.9: Taxa de victòries de la inversió, agregada per paradigma d'oponent. v12 és millor contra agents de referència i altres heurístiques; v13, contra minimax, MCTS i imitació híbrida.




Figura 6.10: Relació entre volum de canvis i taxa de victòries. La freqüència de canvi, per si sola, no mesura la qualitat de la política; cal distingir-ne el motiu.




Figura 6.11: Durada i membres de l'equip disponibles al final. v13 juga partides més llargues i conserva més Pokémon, mentre que v12 obté una taxa de victòries superior.

En aquest banc de proves, afegir modelatge d'oponents humans redueix el rendiment agent-contra-agent. Això indica una possible especialització de domini i justifica mantenir separades la matriu local i l'avaluació pública.

La mostra pública de v14 (secció 6.10) no permet reordenar v12 i v14; de la mateixa manera, la matriu local no permet afirmar quin dels dos obtindria més victòries contra persones.

6.6 Minimax d'un torn

La pregunta és si valorar explícitament la resposta més desfavorable del torn millora v14. La telemetria registra amb quina freqüència s'executa el mòdul i quan la seva acció difereix de la proposta heurística.

Taula 6.5: Minimax analític d'un torn (253.000 partides per fila). La cerca s'executa en aproximadament el 16–18% dels torns. La fulla posicional de **v16** gairebé no modifica la preparació; el prior de **v17** redueix la discrepància respecte de **v14** i obté la taxa més alta de la família.

	v15 HP	v16 bonuses	v17 prior +0,15
TV global (%)	53,80	54,30	57,89
IC 95% (pp)	$\pm 0,19$	$\pm 0,19$	$\pm 0,19$
Cerca (% torns)	17,6	17,6	16,3
Discrepància amb v14 (%)	66,5	67,3	36,6
Preparació / partida	0,21	0,21	0,21
Perills / partida	0,05	0,04	0,04
Tera / partida	0,40	0,39	0,38
Pokémon restants	1,28	1,29	1,39

6.6.1 Frequència d'intervenció

Es registren aproximadament 14 comprovacions de debilitament i 4,5 decisions maximin per partida. La matriu de cerca s'utilitza en el **16–18% dels torns**; la resta es resol principalment amb les regles prioritàries heretades.

Un agent **v14** que prioritza debilitaments garantits i aplica una anàlisi maximin d'un torn a les decisions restants.

Aquest patró és comparable al de **v21**, que consulta XGBoost en aproximadament el 15% dels torns, i al de les variants MCTS.




Figura 6.12: Taxa de discrepància respecte de **v14** en els torns en què s'executa el maximin. **v15/v16** discrepen aproximadament en el 67% dels casos; **v17**, amb prior +0,15, en el 37%. Les derrotes presenten una discrepància mitjana superior, una associació que no implica causalitat.

6.6.2 **v16** i l'avaluació de la fulla

v16 incorpora bonificacions per moviments de preparació i perills d'entrada. La taxa global només augmenta 0,50 pp i els enfrontaments directes queden prop del 50%. Les freqüències de preparació (0,213 i 0,207 per partida) i de perills d'entrada (0,044 i 0,049) pràcticament no canvien. Amb aquesta funció de fulla, el terme de dany rival continua dominant les bonificacions de llarg termini.

La discrepància es manté al voltant del 67%. Per tant, enriquir la fulla en aquesta magnitud no modifica substancialment la política.

Aquest resultat és coherent amb una limitació d'horitzó: afegir una bonificació estàtica no equival a simular les conseqüències futures d'un moviment de preparació.




Figura 6.13: Indicadors d'efectes diferits: preparació, perills d'entrada i Teracristal · lització. v16 manté la preparació al voltant de 0,21 usos per partida, un nivell semblant al de v14 i molt inferior al de v12.

6.6.3 v17: prior heurístic

v17 afegeix 0,15 al valor de l'acció proposada per v14. La discrepància baixa del 67% al 37% i la taxa global augmenta 4,1 pp respecte de v15. En els enfrontaments directes obté 54,7% i 54,3% contra v15 i v16. El resultat mostra que conservar un prior heurístic és més efectiu, en aquesta implementació, que substituir-lo per la matriu d'un torn.

Contra els comparadors principals, amb $n = 10.000$ tret de les cel · les MCTS:

Oponent	v15	v16	v17
v12	36,04	35,92	40,94
v13	32,82	33,50	35,10
v14 (professor)	39,43	39,56	43,61
Abyssal	41,72	41,86	46,79
v20 ($n = 1k$)	39,7	44,6	50,4
v21	43,65	44,75	47,50
v22	69,67	70,22	71,27

v17 obté **43,6%** contra v14, **40,9%** contra v12 i 46,8% contra Abyssal. Contra v20 obté 50,4% amb $n = 1.000$, un resultat compatible amb rendiments similars en aquell enfrontament.

Cap variant de minimax supera v14 o v12. La variant amb millor resultat és precisament la que limita la desviació respecte de l'heurística de partida.

6.6.4 Canvis, durada i supervivència

La millora de v17 no prové d'allargar sistemàticament les batalles: la durada mitjana pràcticament no canvia. Sí que augmenta la massa de resultats amb dos o tres membres restants. Aquesta observació és coherent amb menys decisions maximin agressives que exposen l'actiu, tot i que la figura no identifica per si sola quina acció evita cada debilitament.

La combinació «més canvis decidits per cerca» i «menys discrepància» no és contradictòria. Indica que, quan v14 ja proposa un canvi, el prior de v17 concentra el maximin en la mateixa direcció. El guany no sembla provenir del nombre brut de canvis, sinó de conservar el canvi heurístic en els estats on la matriu no disposa d'un horitzó suficient.




Figura 6.14: Distribució de la durada i dels Pokémon restants a minimax. Les tres variants duren aproximadament 19 torns, però v17 conserva 1,39 membres de mitjana, davant d'1,28–1,29.




Figura 6.15: Distribució dels canvis voluntaris, dels canvis decidits pel maximin i de la fracció de decisions de cerca que són canvis. v17 presenta una mediana superior de canvis tot i discrepar menys de v14.




Figura 6.16: empremta v15–v17: KO checks ~14, cerca ~16–18% dels torns, Tera ~0,39 (nivell v14, no v12).




Figura 6.17: Enfrontaments de referència del minimax d'un torn. Les cel·les contra MCTS tenen $n = 1.000$. v17 millora respecte de les altres variants, però no supera el 50% contra v14.




Figura 6.18: Taxa de victòries agrupada. v15 i v16 se superposen; v17 queda per sobre, encara per sota de v9/v11.




Figura 6.19: Taxa de victòries del minimax per família d'oponent. El prior de v17 s'associa amb les millores principals contra heurístiques i MCTS.

6.7 MCTS ras: UCB a l'arrel i simulacions de cinc torns

Totes les cel·les d'aquesta secció tenen $n = 1.000$. El marge màxim aproximat per a una proporció és $\pm 3,1$ pp. La mitjana global de les files MCTS també té una ponderació diferent de la de les files no MCTS.

La pregunta és si les simulacions de cinc torns milloren les regles de v14 que s'executen abans de la cerca o s'utilitzen com a prior.

Taula 6.6: MCTS ras amb UCB a l'arrel i 100 simulacions de cinc torns. Totes les cel·les tenen $n = 1.000$ (28.000 partides per agent). La fulla més rica de v19 no aporta una millora observable; PUCT amb prior sobre v14 redueix la discrepància i obté la taxa més alta de la família.

	v18 UCB1 HP	v19 UCB1 pos.	v20 PUCT 0,70
TV global (%)	54,02	53,29	59,66
Cerca (% torns)	18,1	17,6	15,5
Discrepància amb v14 (%)	71,3	71,1	18,7
Preparació / partida	0,22	0,22	0,20
Perills / partida	0,05	0,05	0,04
Tera / partida	0,41	0,39	0,39
Pokémon restants	1,21	1,22	1,40

v20 obté una taxa superior a v18 en els **28 enfrontaments** (diferència mitjana de 5,64 pp). v18 i v19 queden prop del 50% en l'enfrontament directe, mentre que v20 obté aproximadament 56,6% contra tots dos. En aquest pressupost, enriquir només la funció de fulla de v19 no aporta una millora observable.

6.7.1 Freqüència d'intervenció

Es registren aproximadament 14 comprovacions de debilitament i 3–4 decisions MCTS per partida. La cerca intervé en el **16–18%** dels torns:

Un agent basat en v14 que prioritza els debilitaments garantits i aplica 100 simulacions de cinc torns a les decisions restants.

Quan s'activa una drecera prèvia, les 100 simulacions no s'executen. Per tant, la cerca només pot modificar el subconjunt de decisions que arriba a l'arrel.




Figura 6.20: Taxa de discrepància respecte de v14 entre les decisions de cerca. UCB1 (v18/v19) discrepa aproximadament en el 71% dels casos i PUCT (v20), en el 19%. Les derrotes mostren més discrepància mitjana, una associació que no estableix causalitat.

6.7.2 Discrepància i resultat

`search_diff` indica que la simulació ha canviat l'acció proposada per v14. Entre els torns en què s'executa:

- v18/v19 discrepen de v14 en el **71%** de les decisions de cerca.
- Les partides perdudes presenten una discrepància superior. Aquest patró pot reflectir decisions pitjors, estats més difícils o ambdues coses.
- Les simulacions de cinc torns i la funció de fulla basada en HP poden afavorir el dany immediat davant d'efectes diferits.

v19 incorpora una fulla posicional, però manté una discrepància del 71,1% i una taxa global 0,7 pp inferior a v18. Les dades no mostren que aquest canvi de fulla resolgui les limitacions del pressupost, de la política de simulació o de la informació oculta.

6.7.3 PUCT i el prior heurístic

Amb un prior de 0,70 sobre v14, la discrepància baixa al **18,7%**. v20 obté una taxa global descriptiva de **59,7%** i conserva 1,40 Pokémon de mitjana al final.

Les diferències de v20 respecte de v18 són especialment grans contra v17 (+11,1 pp), v13 (+10,5), v15 (+9,8) i v12 (+8,7). Contra `random`, la diferència és de 0,3 pp i queda molt per sota de la precisió de la cel·la.

Amb aquest pressupost, la millor variant MCTS és la que utilitza les simulacions per ajustar un prior heurístic, no la que substitueix l'heurística amb UCB1 sense guia.

6.7.4 Indicadors d'efectes diferits

	Setup/partida	Hazards/partida	Tera/partida
v12 (comparador)	~1,75	~0,18	~0,96
v14 (professor)	~0,21	~0,03	~0,34
Minimax d'un torn v15–v17	0,21	0,04–0,05	0,38–0,40
MCTS de cinc torns v18–v20	0,20–0,22	0,04–0,05	0,39–0,41

Les freqüències de preparació i perills d'entrada es mantenen a nivells semblants als de v14, no als de v12. Les simulacions de cinc torns no recuperen, amb aquesta política, el comportament diferit observat a l'heurística amb millor taxa.

v20 presenta més **search_switches** (aproximadament 36% de les decisions de cerca, davant del 16% a v18) i menys discrepància total. Això indica que PUCT reforça sovint els canvis ja proposats per v14.




Figura 6.21: Indicadors d'efectes diferits a les simulacions de cinc torns. La preparació i els perills d'entrada es mantenen a nivells semblants als de v14.

6.7.5 Comparació amb els agents de referència

Oponent	v18	v19	v20
v12	34,0	33,1	42,7
v13	28,6	34,1	39,1
v14	40,0	41,7	47,0
Abyssal	42,2	38,7	49,0
v15	49,3	51,6	59,1
v17	44,7	45,3	55,8
v21	44,1	46,5	49,6
v22	71,1	66,9	73,0

v20 obté **47,0%** contra v14, **42,7%** contra v12 i **49,0%** contra Abyssal. Amb $n = 1.000$, el primer i el tercer resultat són compatibles amb el 50%. També obté 59,1% contra v15 i 73,0% contra v22.

Per blocs, v20 obté 69,9% contra agents de referència, 56,7% contra heurístiques i 57,4% contra minimax. v18/v19 se situen prop del 50% contra heurístiques i per sota del 50% contra minimax.

L'MCTS ras amb 100 simulacions de cinc torns no supera v12 ni aporta evidència de superar v14. Dins de la família, el prior heurístic de v20 és el canvi associat amb la millora principal.

6.7.6 Canvis, durada i supervivència

El patró de v20 no és el d'una política més defensiva que simplement prolonga la partida. Acaba una mica abans i amb més recursos. Una explicació plausible és que el prior redueix simulacions que prefereixen dany immediat però deixen un mal enfrontament al torn següent. És una interpretació compatible amb la telemetria, no una prova causal del mecanisme intern de cada victòria.

v18 gairebé mai escull un canvi des de l'arrel en la mediana, mentre que v20 arriba aproximadament a un terç de decisions de cerca orientades al canvi. Com que al mateix temps baixa **search_diff**, aquests canvis solen coincidir amb la proposta de v14. El resultat reforça la lectura que PUCT preserva posició, més que descobrir una estratègia nova de llarg horitzó.




Figura 6.22: Durada i Pokémon restants a MCTS. v20 acaba lleugerament abans (18,33 torns) i conserva 1,40 membres de mitjana, davant d'1,21–1,22 a UCB1.




Figura 6.23: Distribució dels canvis a MCTS. PUCT augmenta la fracció de decisions de cerca que acaben en canvi i amplia la distribució de canvis voluntaris.




Figura 6.24: Empremta MCTS. Cerca 16–18% dels torns; KO ~ 14 /partida. v20 busca menys i acaba amb més HP. $n = 1.000$ per oponent.




Figura 6.25: Enfrontaments discriminants d'MCTS. Les files representen l'agent avaluat i totes les cel · les tenen $n = 1.000$. v20 s'acosta a Abyssal (49%) i no supera v12 (42,7%).




Figura 6.26: Taxa de victòries agrupada d'MCTS. v18 i v19 se superposen; v20 queda per sobre. Aquesta mitjana de 28.000 partides no té la mateixa ponderació que les files de 253.000.




Figura 6.27: Taxa de victòries d'MCTS per paradigma d'oponent ($n = 1.000$ a cada cel · la). PUCT millora principalment contra heurístiques i minimax.

6.8 Aprenentatge per imitació: dues formes d'execució

Les dues variants comparteixen el classificador XGBoost i el llindar $\tau = 0,5525$, però difereixen en la selecció de l'acció concreta.

Taula 6.7: Imitació amb el mateix classificador XGBoost ($\tau = 0,5525$) i dues formes d'execució (253.000 partides per fila). v21 consulta el model en el 15% dels torns; v22, en el 80%, sense proteccions de debilitament, i activa la protecció de bucle en el 97% de les partides.

	v21 híbrid	v22 atributs
TV global (%)	58,71 $\pm 0,19$	33,49 $\pm 0,18$
Torns mitjans	18,20	20,07
Pokémon restants	1,33	0,70
Canvis voluntaris / partida	1,98	3,72
XGBoost (% torns)	15,2	79,9
Entre decisions XGB, % canvis	35,5	15,2
Mitjana $p(\text{canvi})$	0,080	0,351
Proteccions de KO / partida	13,85	0
Resolucions de final / partida	0,032	0
Proteccions de bucle / partida (% partides)	0,38 (33%)	1,92 (97%)

v21 obté una taxa superior a v22 en els **28 enfrontaments**, amb una diferència mitjana de 25,2 pp. En el cara a cara, les dues orientacions són 71,74% i 29,07%; l'autojoc queda prop del 50%. A v22, els comptadors `ko_guards`, `endgame_solves`, `ko_checks` i `search_*` són zero, fet que confirma que no executa les dreceres de v14.




Figura 6.28: Empremta dels agents d'imitació. v21 registra aproximadament 14 proteccions de debilitament per partida i consulta XGBoost en el 15% dels torns. v22 no té aquestes proteccions, consulta XGBoost en el 80% dels torns i activa la protecció de bucle en el 97% de les partides.

6.8.1 Rendiment dins de la matriu

v21 obté una taxa global descriptiva de 58,71%, propera a v9/v11. v22 obté 33,49%, per sota de v1 (44,25%). En l'enfrontament directe, v1 guanya el 65,72% de les partides contra v22.

Enfrontaments de referència ($n = 10.000$, tret de v20):

	contra v12	contra v13	contra v14	contra Abyssal	contra SimpleH
v21	41,28	38,39	45,43	46,98	47,76
v17	40,94	35,10	43,61	46,79	46,75
v20 ($n = 1k$)	42,7	39,1	47,0	49,0	49,2
v22	19,80	22,03	25,81	22,90	21,73

v14 obté 54,74% contra v21, i l'orientació recíproca és 45,43%. Per tant, afegir el model de decisió atacar/canviar no millora v14 en aquest enfrontament. Les taxes contra Abyssal són 46,98% i 51,36%, respectivament.

6.8.2 Pes efectiu del model a v21

Només el 15% dels torns arriben a XGBoost; les regles prèvies de v14 resolen la resta. En els torns consultats, la probabilitat mitjana de canvi és 0,08, molt inferior a $\tau = 0,5525$. En conseqüència, el model sol indicar que l'agent es mantingui al camp i v14 selecciona el moviment.

Descripció honesta:

Un agent v14 que, en una fracció minoritària dels torns, consulta un model d'imitació per decidir si convé canviar i delega l'execució concreta a la mateixa heurística.

La capa d'imitació funciona, doncs, com un **prior sobre el moment de canviar**, no com un motor tàctic complet. Aquesta descripció és important per no atribuir tot el rendiment de v21 al model supervisat.

La comparació mostra que la decisió d'alt nivell es pot integrar de manera útil quan l'acció concreta queda restringida per una política competent. No mostra que el classificador, per si sol, reproduïx el joc expert.




Figura 6.29: Freqüència d'ús de la política apresada. XGBoost intervé en el 15% dels torns de v21 i en el 80% dels de v22.

6.8.3 Factors que limiten v22

1. **Semàntica de l'acció.** El primer model només prediu {atacar, canviar} i el segon puntua atributs de candidats sintetitzats. Es perd informació sobre la identitat i el context del moviment.
2. **Biaix d'exposició.** Una decisió deficient pot portar la política a estats poc representats a les repeticions. La protecció de bucle s'activa en el **97%** de les partides de v22, que també són més llargues i acaben amb menys Pokémon disponibles.
3. **Absència de restriccions tàctiques.** v21 preserva els debilitaments garantits abans de consultar el model; v22 no. La freqüència de Teracristal · lització de v22 és alta, però la freqüència per si sola no informa de la qualitat del moment triat.

En aquesta implementació, el resultat depèn tant de *què* s'imita —la decisió atacar/canviar— com de *qui* executa l'acció concreta. Disposar d'1,1 milions de torns no compensa una representació que no modela directament la selecció completa de moviments i canvis.

El contrast entre v21 i v22 no compara únicament dos models d'imitació: també compara una arquitectura jeràrquica amb una execució basada en atributs. Aquesta confusió de factors impedeix atribuir els 25,2 pp exclusivament a una sola decisió de disseny, però demostra la importància de l'executor.

6.8.4 Canvis, durada i supervivència

La durada més alta de v22 no és senyal de control. Combinada amb menys membres restants i una taxa de victòries inferior, apunta a canvis que posposen el debilitament sense millorar la posició. Aquest patró concorda amb el biaix d'exposició: després d'un canvi deficient, el model torna a decidir en un estat allunyat de les trajectòries humanes.

Els canvis forçats són semblants perquè depenen sobretot del nombre de debilitaments. La diferència apareix en els canvis voluntaris i en les decisions d'XGBoost. v22 concentra la distribució al voltant de tres o quatre canvis, mentre que v21 n'executa habitualment un o dos. Juntament amb les proteccions de bucle en el 97% de les partides, això suggereix que el problema no és «canviar poc», sinó no disposar d'un executor que valori adequadament el destí del canvi i el cost de tornar enrere.




Figura 6.30: Durada i Pokémon restants dels agents d'imitació. v22 juga partides més llargues (20,07 torns) però acaba amb només 0,70 membres, davant d'1,33 a v21.




Figura 6.31: Distribució dels canvis a imitació. v22 fa aproximadament el doble de canvis voluntaris i rep moltes més ordres de canvi del classificador.




Figura 6.32: Indicadors tàctics. v22 i v12 utilitzen la Teracristal·lització amb freqüències similars, però obtenen resultats molt diferents; la freqüència no mesura la qualitat de la decisió.




Figura 6.33: Taxa de victòries agrupada de les dues arquitectures d'imitació. v21 se situa prop de v9; v22, per sota de v1.




Figura 6.34: Taxa de victòries dels agents d'imitació per família d'oponent. v21 supera v22 en els sis blocs, amb diferències d'aproximadament 20–26 pp.




Figura 6.35: Taxa de victòries de v21 i v22 per oponent. Tots els punts queden sobre la diagonal: v21 obté el valor superior en 28 de 28 enfrontaments. La diferència màxima és de 32,6 pp contra `safe_one_step`.

6.9 Comparació entre els cinc paradigmes

Taula 6.8: Síntesi dels cinc paradigmes amb v12 com a comparador comú. Les variants són les que obtenen el millor resultat observat dins de cada família; aquesta selecció és posterior a l'experiment. L'MCTS té una mostra menor i el PPO no participa en la matriu completa.

Paradigma	Variant	<i>n</i>	vs v12	Lectura
Heurístiques	v12	10.000	50,1%	Autojoc de referència; 59,91% contra Abyssal.
Minimax d'un torn	v17	10.000	40,94%	El prior cap a v14 millora les altres variants, però no supera v12.
MCTS ras	v20	1.000	42,7%	PUCT redueix la discrepància amb v14; marge aproximat de ± 3 pp.
Imitació	v21	10.000	41,28%	El model decideix quan canviar i v14 executa l'acció.
PPO	model A	10.000	34,1%	Experiment separat, inicialitzat per clonatge de v8.

La Taula 6.8 utilitza v12 com a comparador comú. És la comparació més directa disponible per als cinc paradigmes, però no iguala el pressupost de l'MCTS, no controla el cost d'entrenament i

selecciona posteriorment la variant amb millor resultat de cada família. Sota aquestes condicions, cap de les implementacions de minimax, MCTS, imitació o PPO arriba al 50% contra v12.

Taula 6.9: Taxes globals descriptives contra els 28 oponents. Les files no MCTS tenen 253.000 partides i ponderen cada oponent MCTS una desena part que els altres; les files MCTS tenen 28.000 partides i ponderen tots els oponents igual. Els dos blocs no formen una única classificació comparable.

Agent	Partides	TV (%)	Paradigma
<i>Files no MCTS: ponderació 10:1 dels oponents no MCTS/MCTS</i>			
v12	253.000	69,01	Heurística
v13	253.000	67,63	Heurística
v14	253.000	62,03	Heurística
abyssal	253.000	62,00	Agent de referència
simple_heuristic	253.000	61,93	Agent de referència
v11	253.000	59,26	Heurística
v9	253.000	58,86	Heurística
v21	253.000	58,71	Imitació híbrida
v17	253.000	57,89	Minimax
v15	253.000	53,80	Minimax
<i>Files MCTS: ponderació uniforme dels 28 oponents</i>			
v20	28.000	59,66	MCTS
v18	28.000	54,02	MCTS
v19	28.000	53,29	MCTS
<i>Altres referències descriptives</i>			
v1	253.000	44,25	Heurística
v22	253.000	33,49	Imitació per atributs
max_power	253.000	19,66	Agent de referència
random	253.000	4,20	Agent de referència

Taula 6.10: Enfrontaments de referència. Les files amb MCTS tenen $n = 1.000$ i la resta, $n = 10.000$. v12 contra Abyssal (59,91% $\pm 0,96$ pp) és el principal resultat contra un agent extern basat en regles.

Agent	vs Abyssal	vs v12	vs v14	vs SimpleH
v12	59,91	50,1 (autojoc)	56,01	59,75
v13	55,34	48,85	57,71	56,10
v14	51,36	44,74	50,1 (autojoc)	50,66
v20 ($n = 1k$)	49,0	42,7	47,0	49,2
v21	46,98	41,28	45,43	47,76
v17	46,79	40,94	43,61	46,75
v16	41,86	35,92	39,56	40,65
v15	41,72	36,04	39,43	41,23
v18 ($n = 1k$)	42,2	34,0	40,0	42,0
v1	30,64	23,29	32,09	30,26
v22	22,90	19,80	25,81	21,73




Figura 6.36: Mapa de calor de la taxa de victòries a `gen9randombattle`. La fila és l'agent analitzat i la columna, l'oponent. Prefixos: (H) heurística, (MM) minimax, (MCT) MCTS, (IL) imitació i (B) agent de referència. Les cel·les amb MCTS tenen $n = 1.000$; la resta, $n = 10.000$.

6.9.1 Abyssal com a agent de referència

Fins a **v12**, cap heurística interna supera el 50% contra Abyssal. **v7–v11** obtenen entre 41% i 48%; **v12** arriba a 59,91%. **v14** obté 51,36%, **v21** 46,98%, **v20** 49,0% amb $n = 1.000$, **v17** 46,79% i **v22** 22,90%. El resultat de referència és, per tant, **v12 contra Abyssal: 59,91% $\pm 0,96$ pp**, $n = 10.000$.

6.9.2 Elo Bradley–Terry

Taula 6.11: Escala Bradley–Terry a `gen9randombattle`, ancorada a `random = 1000` i ajustada amb les dues orientacions. Els agents no MCTS aporten 506.000 observacions i els MCTS, 56.000. No s’han calculat intervals: valors iguals després d’arrodonir no impliquen equivalència estadística.

Rang	Agent	Elo	Paradigma
1	v12	1812	Heurística
2	v13	1802	Heurística
3	simple_heuristic	1755	Baseline
4	v14	1755	Heurística
5	abyssal	1755	Baseline
6	v20	1742	MCTS (cel · les $n = 1k$)
7	v11	1733	Heurística
8	v9	1730	Heurística
9	v21	1729	IL híbrid
10	v17	1722	Minimax
–	v22	1529	IL (atributs)
–	random	1000	Baseline (àncora)




Figura 6.37: Escala Bradley–Terry ancorada a `random = 1000`, amb les dues orientacions. `v12` i `v13` obtenen les puntuacions més altes. `v14`, `Abyssal` i `Simple Heuristic` comparteixen el mateix valor arrodonit. Les files MCTS aporten menys partides al model.

6.10 Classificació pública: v14 contra persones

Taula 6.12: Classificació pública de v14 contra persones (gen9randombattle, usuari SirPThesis, 9–10 de juny de 2026). La mostra final conté 431 partides; una instantània anterior de 98 partides no s'utilitza com a resultat.

Mètrica	Valor
Partides úniques acabades	431
Victòries	170 / 431
Taxa de victòries principal	39,44% $\pm$ 4,6 pp
Subconjunt de torns ≥ 10 (descriptiu)	35,43% ($n = 398$)
Partides de menys de 10 torns	33
Elo	1085 $\rightarrow$ 1038 (rang 1000–1263)
Errors / accions de reserva	0 / 13
Finestra	2026-06-09 21:54 – 2026-06-10 18:32




Figura 6.38: Taxa de victòries i Elo de v14 a la classificació pública: 431 partides entre el 9 i el 10 de juny de 2026, 39,44% $\pm$ 4,6 pp i Elo de 1085 a 1038 (màxim 1263).




Figura 6.39: Evolució de l'Elo al llarg de les 431 partides. Una mostra prefixa de 98 partides, presa prop del màxim, no representa el resultat final.




Figura 6.40: Victòries i derrotes segons la durada. El subconjunt de partides amb almenys 10 torns és descriptiu; la taxa principal utilitza les 431 partides sense filtrar.

En les partides d'almenys 10 torns, **v14** utilitza la Teracristal·lització en 45 de 398 combats i obté un 20% de victòries en aquest subconjunt. També presenta moltes comprovacions de debilitament i pocs moviments de preparació, un perfil semblant al de la matriu local. Com que la durada és posterior a les decisions i està relacionada amb el resultat, la taxa filtrada no s'interpreta com una estimació alternativa de rendiment.

La mostra pública avalua **v14** fora de l'entorn local, però no és una validació del seu suposat avantatge contra persones: la taxa observada queda per sota del 50% i la selecció d'oponents no està controlada. Tampoc permet inferir el rendiment que hauria obtingut **v12**.

6.11 PPO contra v12

El cinquè paradigma s'avalua contra l'agent amb millor resultat observat a la matriu, **v12**, amb $n = 10.000$ i les dues orientacions. El model és MaskablePPO, amb una observació de 328 dimensions, un espai **Discrete(14)** i inicialització per clonatge conductual de **v8** durant 400 partides.

Taula 6.13: Currículum i avaluacions de MaskablePPO. El resultat principal és el del model A contra **HeuristicV12**, amb $n = 10.000$ i les dues orientacions. La fase 4 només informa la finestra d'entrenament, no una avaluació independent.

Fase	Oponent	n	TV (%)	Notes
1	Random	1.000	91,8	Graduació ($\geq 90\%$)
1.5	MaxBP	1.000	70,5	Graduació
2	v8	1.000	40,6	No assoleix el llindar del 55%
3 (resultat)	v12	10.000	34,1	Model A, 328 dimensions, $\pm 0,93$ pp
3B (diagnòstic)	v12	1.000	32,6	Model B, taxa $1,5 \times 10^{-4}$
4 (interrompuda)	v12	12.554	33,5	Taxa d'entrenament; 346 dimensions i clonatge de v14
Control (model A)	Random	1.000	98,3	Verificació de la política
Matriu (context)	v8 contra v12	10.000	32,9	Professor de clonatge

6.11.1 Resultat principal

Contra **HeuristicV12**, el model A (**p3_v12_lr5e5_flat.zip**) obté:

$$34,1\% \quad (3405/10000) \quad \pm 0,93 \text{ pp} \quad (\text{IC} \sim 33,2\text{--}35,0\%).$$

Per orientació, obté 34,2% (1709/5000) com a p1 i 33,9% (1696/5000) com a p2, amb 17,2 torns de mitjana. En el control contra Random obté **98,3%** amb $n = 1.000$. Això confirma

que la política produeix accions legals i eficaces contra un agent aleatori, però no arriba al 50% contra v12.

A la matriu, v8 obté **32,9%** contra v12 ($n = 10.000$). La diferència puntual respecte del PPO és d'1,2 pp i els intervals se superposen; per tant, no hi ha evidència clara que el model final superi el seu professor de clonatge en aquest comparador.

6.11.2 Currículum

La Taula 5.4 i la Figura 5.10 separen entrenament i validació. Les dues primeres etapes compleixen el criteri operatiu: 91,8% contra Random i 70,5% contra MaxBP, amb $n = 1.000$. Això mostra que la política aprèn l'espai d'accions i supera polítiques simples.

El canvi qualitatiu apareix a v8. Després de 400 partides de clonatge, la validació és només 40,6%, per sota del 55% requerit. Per tant, no és correcte descriure el currículum complet com quatre graduacions reeixides. Les fases 1 i 1.5 es validen; la fase 2 no, i la fase 3 s'executa com una prova de continuació i una mesura contra el comparador final.

Una configuració amb taxa d'aprenentatge $1,5 \times 10^{-4}$ i 16 entorns obté 32,6% contra v12 amb $n = 1.000$. L'extensió a 346 dimensions, inicialitzada amb v14, es va interrompre amb una taxa d'entrenament aproximada del 33,5%. Aquests valors són diagnòstics i no substitueixen l'avaluació final del model A.

6.11.3 Interpretació del límit observat

Hi ha diverses explicacions compatibles amb el 34,1%, però les dades no permeten triar-ne una de manera causal:

1. **Professor inicial.** El clonatge parteix de v8, que obté 32,9% contra v12. El resultat final és proper a aquest punt de partida.
2. **Salt de dificultat.** La política no arriba a paritat amb v8 abans de passar a v12; per tant, la fase següent comença sense haver consolidat l'anterior.
3. **Observació sense memòria.** El vector resumeix l'estat actual, però la política no és recurrent i pot perdre informació temporal útil sobre moviments revelats o patrons del rival.
4. **Recompensa modelada.** HP, debilitaments, modificadors i perills proporcionen senyal dens, però poden premiar estats intermedis que no maximitzen la victòria final.
5. **Variabilitat d'entrenament.** No hi ha repeticions completes amb diversos llavors; una sola trajectòria no estima la distribució de rendiment de PPO.

Amb aquesta observació, recompensa, inicialització i pressupost, MaskablePPO no supera v12. La conclusió es limita al sistema executat, no a PPO en general. El resultat més informatiu és que vèncer Random no prediu l'èxit contra una heurística amb coneixement de posició i mecàniques de format.

6.12 Discussió

6.12.1 Patró d'integració residual

v21 (imitació), v17 (minimax) i v20 (MCTS) comparteixen un patró: conserven les regles tàctiques de v14 i hi afegeixen un mòdul que intervé en una fracció de les decisions. Les figures 6.28, 6.12 i 6.20 mostren que aquests mòduls intervenen aproximadament en el 15–18% dels torns o redueixen la discrepància respecte de l'heurística. Dins de cada família, aquestes

variants obtenen un resultat superior a les alternatives que substitueixen més sovint la proposta de v14.

El patró no demostra que qualsevol arquitectura híbrida sigui superior. Les variants difereixen en més d'un component i s'han seleccionat després d'observar els resultats. Sí que aporta evidència consistent que, amb les representacions i pressupostos implementats, preservar restriccions tàctiques de domini és important.

6.12.2 Resposta conjunta a la pregunta de recerca

1. La seqüència heurística mostra increments associats a posició, control del ritme i mecàniques específiques de la Generació IX. v12 obté el millor resultat observat, però introdueix dues modificacions alhora i no permet separar-ne l'efecte.
2. El minimax d'un torn i l'MCTS ras no superen v12. Les millors variants són les que es mantenen més a prop de v14.
3. El model d'imitació aporta una decisió d'alt nivell aprofitable quan v14 executa l'acció. L'execució basada en atributs de v22 queda clarament per sota.
4. MaskablePPO obté 34,1% contra v12, un resultat proper al de v8 contra el mateix oponent i insuficient per afirmar una millora sobre el professor de clonatge.
5. En el comparador comú v12, cap de les implementacions seleccionades de minimax, MCTS, imitació o PPO arriba al 50%.

6.12.3 Limitacions específiques dels resultats

- Les taxes globals inclouen oponents fàcils, autojoc i etiquetes duplicades, i la ponderació difereix entre files MCTS i no MCTS.
- La telemetria detallada de les heurístiques prové d'un subconjunt de cinc oponents; la de minimax, MCTS i imitació cobreix la matriu completa.
- `endgame_solves` de v18 pot incloure activitat de la sonda v14 posterior a la cerca.
- `LocalSim` no és el mateix motor que `Showdown`; un desajust de mecàniques pot introduir soroll en les simulacions.
- L'avaluació pública de v14 és una mostra no controlada de 431 partides.
- El PPO només es compara amb v12, i no s'han repetit els entrenaments complets amb diversos llavors.

Capítol 7

Conclusions i línies futures

7.1 Resposta a la pregunta de recerca

Aquest treball ha comparat cinc paradigmes d'agents en Pokémon Showdown Random Battle de la Generació IX. Heurístiques, minimax d'un torn, MCTS ras i aprenentatge per imitació formen, amb sis agents de referència, una matriu dirigida de 28×28 . MaskablePPO s'ha avaluat separatament contra v12. La comparació comparteix simulador i format, però no és completament simètrica.

Sota les implementacions i els pressupostos estudiats, les heurístiques obtenen el millor resultat observat. v12 assoleix 69,01% en la seva mitjana global descriptiva i 59,91% contra Abyssal. Amb v12 com a comparador comú, v17 (minimax), v20 (MCTS), v21 (imitació) i el model PPO obtenen 40,94%, 42,7%, 41,28% i 34,1%, respectivament. La cel·la MCTS té $n = 1.000$; les altres, $n = 10.000$.

La conclusió no és que les heurístiques siguin universalment superiors. És que, en aquest entorn, el coneixement explícit sobre Teracristal·lització, selecció del substitut, debilitaments garantits i control del ritme no queda recuperat per la cerca rasa ni pels models apresos amb els recursos utilitzats.

7.2 Resultats principals

1. **La complexitat heurística no produeix una millora monotònica.** v1–v6 formen un atiplà; v7, v9 i v12 introdueixen els increments principals. v13 i v14 afegeixen funcionalitats, però redueixen la taxa global.
2. **El minimax d'un torn no supera l'heurística de partida.** v17 és la millor variant de la família perquè redueix la discrepància respecte de v14, però obté 43,6% contra aquest agent.
3. **L'MCTS ras depèn del prior.** UCB1 discrepa de v14 en aproximadament el 71% de les decisions de cerca; PUCT redueix aquesta taxa al 19% i millora el resultat de la família. Amb tot, v20 obté 42,7% contra v12.
4. **La imitació és sensible a l'executor.** v21, que utilitza XGBoost per decidir quan canviar i v14 per executar, supera v22 en els 28 enfrontaments. El contrast també canvia altres components, de manera que no aïlla un únic efecte causal.
5. **El currículum PPO només valida les dues primeres etapes.** La política supera els llindars contra Random i MaxBasePower, però obté 40,6% contra v8 i no arriba al 55% previst. El model final fa 34,1% contra v12, proper al 32,9% de v8 contra el mateix oponent.

6. **La integració residual és el patró més consistent.** v17, v20 i v21 conserven una part important de v14 i són les variants amb millor resultat dins de les seves famílies.

7.3 Contribucions

- una infraestructura coordinador–processos de treball, recuperable i instrumentada, que ha produït 6.409.000 batalles a la matriu;
- catorze heurístiques que documenten la incorporació de coneixement específic del format;
- variants instrumentades de minimax i MCTS, amb telemetria de freqüència i discrepància;
- dos agents d’imitació entrenats amb dades del mateix format i una anàlisi del paper de l’executor;
- un entorn d’accions emmascarades, clonatge conductual i MaskablePPO sobre Showdown;
- un protocol que separa l’avaluació local, l’experiment PPO i la mostra pública contra persones.

7.4 Limitacions

Els cinc paradigmes no participen en una mateixa lliga: el PPO només s’avalua contra v12 i l’MCTS utilitza una mostra menor. Les taxes globals tenen ponderacions diferents; no hi ha equips o llavors aparellats; es fan moltes comparacions exploratòries; i les millors variants es seleccionen després d’observar la matriu. Algunes versions heurístiques introdueixen diversos canvis alhora, el llinar d’imitació es tria sobre la partició retinguda, i no s’han repetit els entrenaments complets d’IL i PPO amb diverses llavors. Finalment, els resultats només descriuen `gen9randombattle` i les versions de programari utilitzades.

7.5 Línies futures

Les continuacions prioritàries són:

- completar una matriu que inclogui PPO i comparar també cost de decisió i cost d’entrenament;
- utilitzar equips i llavors aparellats, intervals per a diferències i repeticions independents dels entrenaments;
- substituir l’UCB només a l’arrel per un arbre més complet o per Information Set MCTS, amb polítiques de simulació apreses i diversos pressupostos;
- entrenar un model d’imitació condicionat al conjunt de candidats legals, capaç de seleccionar moviments, canvis i Teracristal · lització, amb validació final independent;
- repetir PPO amb clonatge de v12, diverses llavors, ablacions de recompensa i una observació recurrent o explícitament orientada a creences;
- ampliar l’avaluació contra persones amb diversos agents, períodes més llargs i un protocol que controli millor el nivell dels oponents.

7.6 Tancament

El resultat central és metodològic i tècnic: comparar paradigmes exigeix fer explícits el coneixement incorporat, el pressupost de còmput, la representació de l'estat i el protocol d'avaluació. En aquest experiment, conservar coneixement específic de Random Battle és més efectiu que substituir-lo per cerca rasa o per una política apresada. Una comparació futura més simètrica permetrà determinar fins a quin punt aquesta conclusió depèn dels límits de les implementacions actuals.

Referències bibliogràfiques

- [1] Brenna D. Argall et al. «A survey of robot learning from demonstration». A: *Robotics and Autonomous Systems* 57.5 (2009), pàg. 469 - 483. DOI: [10.1016/j.robot.2008.10.016](https://doi.org/10.1016/j.robot.2008.10.016).
- [2] Astral. *Ruff: An extremely fast Python linter and formatter*. <https://github.com/astral-sh/ruff>. 2024.
- [3] Astral. *uv: An extremely fast Python package and project manager*. <https://github.com/astral-sh/uv>. 2024.
- [4] Marc G. Bellemare et al. «The Arcade Learning Environment: An Evaluation Platform for General Agents». A: *Journal of Artificial Intelligence Research* 47 (2013), pàg. 253 - 279. DOI: [10.1613/jair.3912](https://doi.org/10.1613/jair.3912).
- [5] Yoshua Bengio et al. «Curriculum Learning». A: *Proceedings of the 26th International Conference on Machine Learning (ICML)*. 2009, pàg. 41 - 48. DOI: [10.1145/1553374.1553380](https://doi.org/10.1145/1553374.1553380).
- [6] Christopher Berner et al. «Dota 2 with Large Scale Deep Reinforcement Learning». A: *arXiv preprint arXiv:1912.06680* (2019). DOI: [10.48550/arXiv.1912.06680](https://doi.org/10.48550/arXiv.1912.06680).
- [7] Ralph Allan Bradley i Milton E. Terry. «Rank Analysis of Incomplete Block Designs: I. The Method of Paired Comparisons». A: *Biometrika* 39.3/4 (1952), pàg. 324 - 345. DOI: [10.2307/2334029](https://doi.org/10.2307/2334029).
- [8] Greg Brockman et al. «OpenAI Gym». A: *arXiv preprint arXiv:1606.01540* (2016).
- [9] Noam Brown i Tuomas Sandholm. «Superhuman AI for heads-up no-limit poker: Libratus beats top professionals». A: *Science* 359.6374 (2018), pàg. 418 - 424. DOI: [10.1126/science.aao1733](https://doi.org/10.1126/science.aao1733).
- [10] Noam Brown i Tuomas Sandholm. «Superhuman AI for multiplayer poker». A: *Science* 365.6456 (2019), pàg. 885 - 890. DOI: [10.1126/science.aay2400](https://doi.org/10.1126/science.aay2400).
- [11] Cameron B. Browne et al. «A Survey of Monte Carlo Tree Search Methods». A: *IEEE Transactions on Computational Intelligence and AI in Games* 4.1 (2012), pàg. 1 - 43. DOI: [10.1109/TCIAIG.2012.2186810](https://doi.org/10.1109/TCIAIG.2012.2186810).
- [12] Bulbapedia Contributors. *Effort values* — *Bulbapedia*. [Online; accessed 15-August-2026]. 2026. URL: https://bulbapedia.bulbagarden.net/wiki/Effort_values.
- [13] Bulbapedia Contributors. *Individual values* — *Bulbapedia*. [Online; accessed 15-August-2026]. 2026. URL: https://bulbapedia.bulbagarden.net/wiki/Individual_values.
- [14] Bulbapedia Contributors. *Nature* — *Bulbapedia*. [Online; accessed 15-August-2026]. 2026. URL: <https://bulbapedia.bulbagarden.net/wiki/Nature>.
- [15] Bulbapedia Contributors. *Pokémon (species)* — *Bulbapedia*. Enciclopèdia completa de la franquícia Pokémon. 2024. URL: [https://bulbapedia.bulbagarden.net/wiki/Pok%C3%A9mon_\(species\)](https://bulbapedia.bulbagarden.net/wiki/Pok%C3%A9mon_(species)).
- [16] Bulbapedia Contributors. *Statistic* — *Bulbapedia, The community-driven Pokémon encyclopedia*. [Online; accessed 4-March-2026]. 2024. URL: <https://bulbapedia.bulbagarden.net/wiki/Stat>.

- [17] Murray Campbell, A. Joseph Hoane i Feng hsiung Hsu. «Deep Blue». A: *Artificial Intelligence* 134.1 (2002), pàg. 57 - 83. ISSN: 0004-3702. DOI: [10.1016/S0004-3702\(01\)00129-1](https://doi.org/10.1016/S0004-3702(01)00129-1). URL: <https://www.sciencedirect.com/science/article/pii/S0004370201001291>.
- [18] Tianqi Chen i Carlos Guestrin. «XGBoost: A Scalable Tree Boosting System». A: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, pàg. 785 - 794. DOI: [10.1145/2939672.2939785](https://doi.org/10.1145/2939672.2939785).
- [19] Rémi Coulom. «Efficient Selectivity and Backup Operators in Monte-Carlo Tree Search». A: *Computers and Games*. Treball presentat a CG 2006. Springer, 2007, pàg. 72 - 83. DOI: [10.1007/978-3-540-75538-8_7](https://doi.org/10.1007/978-3-540-75538-8_7).
- [20] Peter I. Cowling, Edward J. Powley i Daniel Whitehouse. «Information Set Monte Carlo Tree Search». A: *IEEE Transactions on Computational Intelligence and AI in Games* 4.2 (2012), pàg. 120 - 143. DOI: [10.1109/TCIAIG.2012.2200894](https://doi.org/10.1109/TCIAIG.2012.2200894).
- [21] Arpad E. Elo. *The Rating of Chessplayers, Past and Present*. Batsford, 1978.
- [22] Jake Grigsby et al. «Human-Level Competitive Pokémon via Scalable Offline Reinforcement Learning with Transformers». A: *arXiv preprint arXiv:2504.04395* (2025). DOI: [10.48550/arXiv.2504.04395](https://doi.org/10.48550/arXiv.2504.04395).
- [23] Charles R. Harris et al. «Array programming with NumPy». A: *Nature* 585 (2020), pàg. 357 - 362. DOI: [10.1038/s41586-020-2649-2](https://doi.org/10.1038/s41586-020-2649-2).
- [24] Sihao Hu, Tiansheng Huang i Ling Liu. «PokéLLMon: A Human-Parity Agent for Pokémon Battles with Large Language Models». A: *arXiv preprint arXiv:2402.01118* (2024). DOI: [10.48550/arXiv.2402.01118](https://doi.org/10.48550/arXiv.2402.01118).
- [25] Dan Huang i Scott Lee. «A Self-Play Policy Optimization Approach to Battling Pokémon». A: *2019 IEEE Conference on Games (CoG)*. PPO amb *self-play* a Pokémon Showdown; la clau es conserva per traçabilitat de cites. 2019, pàg. 1 - 4. DOI: [10.1109/CIG.2019.8848014](https://doi.org/10.1109/CIG.2019.8848014).
- [26] Shengyi Huang i Santiago Ontañón. «A Closer Look at Invalid Action Masking in Policy Gradient Algorithms». A: *The International FLAIRS Conference Proceedings*. Vol. 35. 2022. DOI: [10.32473/flairs.v35i.130584](https://doi.org/10.32473/flairs.v35i.130584).
- [27] Hugging Face. *Datasets*. <https://huggingface.co/docs/datasets>. 2024.
- [28] John D. Hunter. «Matplotlib: A 2D graphics environment». A: *Computing in Science & Engineering* 9.3 (2007), pàg. 90 - 95. DOI: [10.1109/MCSE.2007.55](https://doi.org/10.1109/MCSE.2007.55).
- [29] Leslie Pack Kaelbling, Michael L. Littman i Anthony R. Cassandra. «Planning and Acting in Partially Observable Stochastic Domains». A: *Artificial Intelligence* 101.1-2 (1998), pàg. 99 - 134. DOI: [10.1016/S0004-3702\(98\)00023-X](https://doi.org/10.1016/S0004-3702(98)00023-X).
- [30] Seth Karten, Andy L. Nguyen i Chi Jin. «PokéChamp: an Expert-level Minimax Language Agent». A: *Proceedings of the 42nd International Conference on Machine Learning*. Vol. 267. Proceedings of Machine Learning Research. PMLR, 2025, pàg. 29205 - 29222. URL: <https://proceedings.mlr.press/v267/karten25a.html>.
- [31] Seth Karten et al. *Pokechamp: Pokémon Battle AI Agents*. <https://github.com/sethkarten/pokechamp>. Fork amb LocalSim, Abyssal, pokechamp i pokellmon. 2024.
- [32] Donald E. Knuth i Ronald W. Moore. «An analysis of alpha-beta pruning». A: *Artificial Intelligence* 6.4 (1975), pàg. 293 - 326. DOI: [10.1016/0004-3702\(75\)90019-3](https://doi.org/10.1016/0004-3702(75)90019-3).
- [33] Levente Kocsis i Csaba Szepesvári. «Bandit based Monte-Carlo Planning». A: *Proceedings of the 17th European Conference on Machine Learning (ECML)*. 2006, pàg. 282 - 293. DOI: [10.1007/11871842_29](https://doi.org/10.1007/11871842_29).
- [34] Vijay R. Konda i John N. Tsitsiklis. «Actor-Critic Algorithms». A: *Advances in Neural Information Processing Systems*. Vol. 12. 2000, pàg. 1008 - 1014.

- [35] Yann LeCun, Yoshua Bengio i Geoffrey Hinton. «Deep learning». A: *Nature* 521.7553 (2015), pàg. 436 - 444. DOI: [10.1038/nature14539](https://doi.org/10.1038/nature14539).
- [36] Guangcong Luo i Smogon Community. *Pokémon Showdown!* <https://pokemonshowdown.com/>. 2011.
- [37] Volodymyr Mnih et al. «Asynchronous Methods for Deep Reinforcement Learning». A: *Proceedings of the 33rd International Conference on Machine Learning*. Vol. 48. Proceedings of Machine Learning Research. PMLR, 2016, pàg. 1928 - 1937.
- [38] Volodymyr Mnih et al. «Human-level control through deep reinforcement learning». A: *Nature* 518.7540 (2015), pàg. 529 - 533. DOI: [10.1038/nature14236](https://doi.org/10.1038/nature14236).
- [39] Andrew Y. Ng, Daishi Harada i Stuart Russell. «Policy Invariance Under Reward Transformations: Theory and Application to Reward Shaping». A: *Proceedings of the Sixteenth International Conference on Machine Learning (ICML)*. 1999, pàg. 278 - 287.
- [40] Ollama Team. *Ollama: Get up and running with large language models locally*. <https://ollama.com/>. 2023.
- [41] OpenJS Foundation. *Node.js*. <https://nodejs.org/>. 2024.
- [42] Adam Paszke et al. *PyTorch: An Imperative Style, High-Performance Deep Learning Library*. <https://pytorch.org/>. 2019.
- [43] Fabian Pedregosa et al. «Scikit-learn: Machine Learning in Python». A: *Journal of Machine Learning Research* 12 (2011), pàg. 2825 - 2830.
- [44] Dean A. Pomerleau. «ALVINN: An Autonomous Land Vehicle in a Neural Network». A: *Advances in Neural Information Processing Systems*. Vol. 1. 1989, pàg. 305 - 313.
- [45] Antonin Raffin et al. *Stable-Baselines3 Contrib: Reliable Reinforcement Learning Implementations*. <https://github.com/Stable-Baselines-Team/stable-baselines3-contrib>. Inclou MaskablePPO per a entorns amb action masking. 2021.
- [46] Antonin Raffin et al. *Stable-Baselines3: Reliable Reinforcement Learning Implementations*. <https://github.com/DLR-RM/stable-baselines3>. 2021.
- [47] Antonin Raffin et al. «Stable-Baselines3: Reliable Reinforcement Learning Implementations». A: *Journal of Machine Learning Research* 22.268 (2021), pàg. 1 - 8. URL: <http://jmlr.org/papers/v22/20-1364.html>.
- [48] Stéphane Ross, Geoffrey Gordon i J. Andrew Bagnell. «A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning». A: *Proceedings of the 14th International Conference on Artificial Intelligence and Statistics (AISTATS)*. 2011, pàg. 627 - 635.
- [49] Stuart J. Russell i Peter Norvig. *Artificial Intelligence: A Modern Approach*. 4a ed. Pearson, 2020.
- [50] Haris Sahovic. *Creating a Pokémon battling bot with reinforcement learning*. 2021. URL: <https://hsahovic.github.io/poke-env/>.
- [51] Haris Sahovic. *poke-env: A Python Interface for Creating Pokémon Showdown Bots*. <https://github.com/hsahovic/poke-env>. 2020. URL: <https://github.com/hsahovic/poke-env>.
- [52] John Schulman et al. «High-Dimensional Continuous Control Using Generalized Advantage Estimation». A: *International Conference on Learning Representations (ICLR)*. arXiv:1506.02438. 2016.
- [53] John Schulman et al. «Proximal Policy Optimization Algorithms». A: *arXiv preprint arXiv:1707.06347* (2017). DOI: [10.48550/arXiv.1707.06347](https://doi.org/10.48550/arXiv.1707.06347).

- [54] John Schulman et al. «Trust Region Policy Optimization». A: *Proceedings of the 32nd International Conference on Machine Learning*. Vol. 37. Proceedings of Machine Learning Research. PMLR, 2015, pàg. 1889 - 1897.
- [55] Claude E. Shannon. «Programming a Computer for Playing Chess». A: *Philosophical Magazine* 41.314 (1950), pàg. 256 - 275. DOI: [10.1080/14786445008521796](https://doi.org/10.1080/14786445008521796).
- [56] L. S. Shapley. «Stochastic Games». A: *Proceedings of the National Academy of Sciences* 39.10 (1953), pàg. 1095 - 1100. DOI: [10.1073/pnas.39.10.1095](https://doi.org/10.1073/pnas.39.10.1095).
- [57] David Silver et al. «A general reinforcement learning algorithm that masters chess, shogi, and Go through self-play». A: *Science* 362.6419 (2018), pàg. 1140 - 1144. DOI: [10.1126/science.aar6404](https://doi.org/10.1126/science.aar6404).
- [58] David Silver et al. «Mastering the game of Go with deep neural networks and tree search». A: *Nature* 529.7587 (2016), pàg. 484 - 489. DOI: [10.1038/nature16961](https://doi.org/10.1038/nature16961).
- [59] Richard D. Smallwood i Edward J. Sondik. «The optimal control of partially observable Markov processes over a finite horizon». A: *Operations Research* 21.5 (1973), pàg. 1071 - 1088. DOI: [10.1287/opre.21.5.1071](https://doi.org/10.1287/opre.21.5.1071).
- [60] Smogon University. *Damage Formula*. [Online; accessed 4-March-2026]. 2024. URL: https://www.smogon.com/dp/articles/damage_formula.
- [61] Smogon University. *OverUsed (OU) — Smogon Dex*. <https://www.smogon.com/dex/sv/formats/ou/>. Metagame de Singles amb equips portats. 2024.
- [62] Smogon University. *Random Battle — Smogon Dex*. <https://www.smogon.com/dex/sv/formats/random-battle/>. Format d'equips aleatoris de Showdown (Generació IX). 2024.
- [63] Smogon University. *Smogon Forums*. <https://www.smogon.com/forums/>. Discussió de metagame, teambuilding i simulació. 2024.
- [64] Smogon University. *Smogon Strategy Pokédex*. <https://www.smogon.com/>. Comunitat principal d'estratègia Pokémon competitiva. 2024.
- [65] Smogon University i Pokémon Showdown. *Random Battle sets (Generació IX)*. <https://github.com/smogon/pokemon-showdown>. Pool públic de moviments, objectes i habilitats per Random Battle. 2024.
- [66] Richard S. Sutton i Andrew G. Barto. *Reinforcement Learning: An Introduction*. 2nd. MIT Press, 2018. URL: <http://incompleteideas.net/book/the-book.html>.
- [67] Tailscale Inc. *Tailscale: Zero-config VPN built on WireGuard*. <https://tailscale.com/>. 2024.
- [68] Telegram FZ-LLC. *Telegram Bot API*. <https://core.telegram.org/bots/api>. 2024.
- [69] TensorFlow Team. *TensorBoard: TensorFlow's visualization toolkit*. <https://www.tensorflow.org/tensorboard>. 2024.
- [70] Gerald Tesauro. «Temporal Difference Learning and TD-Gammon». A: *Communications of the ACM* 38.3 (1995), pàg. 58 - 68. DOI: [10.1145/203330.203343](https://doi.org/10.1145/203330.203343).
- [71] The pandas development team. *pandas-dev/pandas: Pandas*. Vers. latest. Febr. de 2020. DOI: [10.5281/zenodo.3509134](https://doi.org/10.5281/zenodo.3509134). URL: <https://doi.org/10.5281/zenodo.3509134>.
- [72] Mark Towers et al. *Gymnasium: A Standard API for Reinforcement Learning*. <https://gymnasium.farama.org/>. 2024.
- [73] Mark Towers et al. «Gymnasium: A Standard Interface for Reinforcement Learning Environments». A: *arXiv preprint arXiv:2407.17032* (2024). DOI: [10.48550/arXiv.2407.17032](https://doi.org/10.48550/arXiv.2407.17032).
- [74] Ritchie Vink. *Polars: Blazingly fast DataFrames in Rust and Python*. <https://www.pola.rs/>. 2024.

- [75] Oriol Vinyals et al. «Grandmaster level in StarCraft II using multi-agent reinforcement learning». A: *Nature* 575.7782 (2019), pàg. 350 - 354. DOI: [10.1038/s41586-019-1724-z](https://doi.org/10.1038/s41586-019-1724-z).
- [76] Pauli Virtanen et al. «SciPy 1.0: fundamental algorithms for scientific computing in Python». A: *Nature Methods* 17 (2020), pàg. 261 - 272. DOI: [10.1038/s41592-019-0686-2](https://doi.org/10.1038/s41592-019-0686-2).
- [77] John Von Neumann i Oskar Morgenstern. *Theory of Games and Economic Behavior*. Edició commemorativa de 2007, ISBN 978-0-691-13061-3. Princeton University Press, 1944.
- [78] Michael L. Waskom. «seaborn: statistical data visualization». A: *Journal of Open Source Software* 6.60 (2021), pàg. 3021. DOI: [10.21105/joss.03021](https://doi.org/10.21105/joss.03021).
- [79] Christopher J. C. H. Watkins i Peter Dayan. «Q-learning». A: *Machine Learning* 8.3–4 (1992), pàg. 279 - 292. DOI: [10.1007/BF00992698](https://doi.org/10.1007/BF00992698).
- [80] Edwin B. Wilson. «Probable Inference, the Law of Succession, and Statistical Inference». A: *Journal of the American Statistical Association* 22.158 (1927), pàg. 209 - 212. DOI: [10.1080/01621459.1927.10502953](https://doi.org/10.1080/01621459.1927.10502953).
- [81] Michael Wooldridge. *An Introduction to MultiAgent Systems*. 2a ed. John Wiley & Sons, 2009.
- [82] An Yang et al. *Qwen2 Technical Report*. 2024. arXiv: [2407.10671](https://arxiv.org/abs/2407.10671) [[cs.CL](#)].