Desenvolupament d'un agent de Deep Reinforcement Learning per a la presa de decisions estratègiques en entorns estocàstics d'informació imperfecta: El cas de Pokémon VGC

Gerard Pascual Fontanilles

March 4, 2026

Contents

1 Marc Teòric i Contextualització **1**
1.1 Contextualització de la IA en jocs . . . 1
1.1.1 L'Evolució a través de la Informació Perfecta . . . 1
1.1.2 Processos de Decisió de Màrkov i Entorns Estocàstics . . . 1
1.2 El Subjecte d'Estudi: Construint l'Entorn Pokémon . . . 2
1.2.1 Estadístiques i Fórmules (Stats) . . . 3
1.2.2 Matemàtiques del Dany: La Taula de Tipus, STAB i Categories d'Atacs . 5
1.2.3 L'Ordre d'Execució: Velocitat i Prioritat (Speed Dynamics) . . . 6
1.2.4 Estats Alterats (Status Conditions) . . . 6
1.2.5 L'Estocasticitat i el trencament Determinista . . . 6
1.3 Teoria de Jocs: Competitiu "VGC" (Suma Zero) . . . 7
1.3.1 El Model de Lliure Decisió i Meta-game . . . 7
1.4 L'Entorn Virtual i Eines de Recerca . . . 9
1.4.1 L'Ecosistema de Simulació: Showdown i Poke-env . . . 9
1.5 Intel·ligència Artificial i Reinforcement Learning . . . 9
1.6 Justificació Metodològica de la Recerca . . . 10

2 Metodologia: Entorn, Arquitectura i Baselines **11**
2.1 Entorn i Simulació: Infraestructura Escalable . . . 11
2.2 Fases de Desenvolupament i Models de Referència . . . 11
2.2.1 Fase 1: Models de Regles Expertes (Heurístiques) . . . 11
2.2.2 Fase 2: Models d'Aprenentatge Profund (Cares al Futur) . . . 12
2.2.3 La línia de control nativa (*Poke-env Baselines*) . . . 12
2.3 Espai d'Estats (State Space) i Accions (Action Space) . . . 13
2.3.1 Espai d'Estats (S) . . . 13
2.3.2 Espai d'Accions (A) . . . 13
2.4 Mètriques d'Avaluació Mètrica . . . 13

3 Implementació d'Agents: De les Fases Heurístiques a l'Aprenentatge Profund **14**
3.1 Orquestració Operacional i Entorn Parallelitzat . . . 14
3.2 Fase 1.1: Desenvolupament d'Heurístiques per Singles (1vs1) . . . 14
3.3 Fase 1.2: L'Ascens al Competitiu Real (Dobles VGC) . . . 15
3.4 Fase 2: Implementació Neuronal per Aprenentatge . . . 15

4 Resultats i Avaluació de les Heurístiques **17**
4.1 Avaluació Exhaustiva al Format 1 vs 1 (Singles) . . . 17
4.2 Avaluació al Format 2 vs 2 (Doubles) . . . 17

Abstract

Els videojocs d'estratègia complexos constitueixen un banc de proves valuós per a la recerca en Intel·ligència Artificial. En contrast amb jocs d'informació perfecta (com els escacs o el Go), els entorns amb informació parcial i dinàmiques estocàstiques presenten reptes addicionals significatius en predicció i planificació. Aquest Treball de Final de Màster proposa el disseny, implementació i avaluació d'un agent basat en Deep Reinforcement Learning (DRL) per al format competitiu VGC de Pokémon, utilitzant el simulador de codi obert Pokémon Showdown [12] i la llibreria poke-env [5] com a entorn d'entrenament.

El problema s'aborda com un Procés de Decisió de Markov Parcialment Observable (POMDP) [8], caracteritzat per un espai d'estats i d'accions d'alta dimensionalitat i múltiples fonts d'incertesa (informació oculta sobre l'equip rival i resultats estocàstics dels moviments). L'objectiu no és la resolució perfecta del joc, sinó l'aproximació d'una política d'actuació que maximitzi l'esperança de victòria sota incertesa.

La proposta integra: (1) una representació vectorial de l'estat que inclou estadístiques, tipus, condicions de camp i historial d'accions; (2) una arquitectura neuronal (p. ex., xarxa recurrent o encoder + policy network) per captar dependències temporals i la parcialitat de la informació; i (3) estratègies d'entrenament basades en self-play i algorismes actor-crític (com PPO [6]), complementats potencialment amb components d'aprenentatge supervisat per a la predicció de moviments rivals.

L'avaluació es durà a terme en un entorn de simulació local controlat. S'analitzarà el rendiment quantitatiu de l'agent (taxa de victòries i recompensa mitjana acumulada) enfront d'una bateria d'agents basats en regles (scripted baselines) que implementen heurístiques competitives estàndard. Addicionalment, es realitzaran estudis d'ablació (ablation studies) per determinar la contribució de cada mòdul de l'arquitectura. Qualitativament, s'examinarà l'emergència de comportaments avançats com la predicció de canvis de Pokémon (switch prediction) i la gestió del risc, discutint finalment la viabilitat computacional i les limitacions del model proposat.

Paraules clau: Deep Reinforcement Learning (DRL), POMDP, Teoria de Jocs, Sistemes Estocàstics, Pokémon VGC, Xarxes Neuronals.

Chapter 1

Marc Teòric i Contextualització

Aquest capítol estableix els fonaments teòrics i algorísmics necessaris per comprendre el desenvolupament d'un agent d'intel·ligència artificial aplicat a entorns complexos. S'hi introdueixen els conceptes clau sobre teoria de jocs, s'analitza l'entorn de Pokémon VGC com a cas d'estudi i es defineixen les metodologies modernes d'aprenentatge per reforç.

1.1 Contextualització de la IA en jocs

1.1.1 L'Evolució a través de la Informació Perfecta

Històricament, els jocs han estat utilitzats per la comunitat científica com a banc de proves idoni per avaluar les capacitats de la Intel·ligència Artificial (IA). Clàssics com els Escacs o el Go s'emmarquen dins dels anomenats jocs d'**informació perfecta**. En aquests entorns, tots els jugadors coneixen completament i en tot moment l'estat exacte del joc; no hi ha elements amagats ni incertesa fora de l'estratègia del rival. La resolució d'aquests jocs s'ha assolit mitjançant algorismes de cerca avançats, com ara *Minimax* amb esporgada alfa-beta, pilar fonamental de màquines com Deep Blue (desenvolupada per IBM) en la seva cèlebre victòria als escacs [3]; o la Cerca d'Arbre de Monte Carlo (MCTS), component crucial darrere de l'èxit històric del programa AlphaGo de Google DeepMind en el joc del Go [7].

1.1.2 Processos de Decisió de Màrkov i Entorns Estocàstics

Malgrat aquests èxits memorables, el món real (i molts entorns virtuals moderns) es caracteritza freqüentment per la **informació imperfecta** i l'**estocasticitat**. A diferència dels escacs, on tota la informació està sobre el tauler en cada torn, els jocs estocàstics d'informació imperfecta inclouen incertesa inherent i variables ocultes (com les cartes de l'oponent a jocs d'atzar o la precisió d'un atac a Pokémon).

Des d'una perspectiva matemàtica, la seqüència de decisions de l'agent en aquests escenaris aleatoris es formalitza d'inici utilitzant un **Procès de Decisió de Màrkov (MDP)**. Un MDP estableix que qualsevol acció i els seus efectes només depenen de l'estat directament actual i no de tota la història prèvia. Un exemple clar i intuïtiu dintre de Pokémon seria trobar-se davant el rival: si l'estat S és tenir un *Charizard* amb 50% de vida enfrontant-se a un *Venusaur*, l'acció escollida A podria ser utilitzar l'atac *Llançaflames*. L'execució d'aquest atac genera conseqüències incertes a través de la funció de transició de probabilitat. L'atac pot tenir una probabilitat d'errar, encertar críticament o causar impacte normal, i aquesta simple transició produeix en retrospectiva una recompensa immediata (dany realitzat). L'agent que decideix està completament sotmès a aquestes probabilitats modelades.

Això no obstant, si augmentem la complexitat i la IA perd informació, entrem purament als Processos de Decisió de Màrkov Parcialment Observables o **POMDP** (*Partially Observable Markov Decision Processes*) [8]. Un POMDP estén el model MDP perquè l'agent només

disposa d'observacions limitades de l'estat de l'entorn. Es defineix formalment com una tupla $(S, A, T, R, \Omega, O, \gamma)$, on:

- S: Conjunt d'estats del joc.
- A: Conjunt d'accions possibles.
- T: $P(s'|s, a)$, la funció de transició de probabilitat.
- R: $R(s, a)$, la funció de recompensa esperada.
- Ω: Conjunt de possibles observacions que rep l'agent.
- O: $P(o|s', a)$, la funció de probabilitat d'observació condicionada a l'estat i l'acció.
- γ: El factor de descompte ($\gamma \in [0, 1)$).

Sota el paradigma de POMDP a l'espectre de Pokémon, l'agent **ja no rep l'estat S real sencer**. Tot i veure el seu *Venusaur*, ell no podrà observar els valors ocults amagats a l'estat (*Effort Values*, objectes equipats de l'aliat ni tan sols els quatre atacs del rival fins que ocorren). En utilitzar *Llançaflames*, únicament s'obté una observació de l'entorn Ω com a resposta: veure quant ha baixat la barra de vida de l'oponent. L'agent utilitza la reducció residual d'aquesta barra o l'ordre en el qual l'oponent l'ha atacat (comprovació empírica de Velocitat) per mantenir un *belief state* — una distribució de probabilitat que ell creu i actualitza on es dedueix si ha lluitat contra un *Venusaur* defensiu, ofensiu, lent o veloç. Això força als sistemes d'IA a incloure algorismes de memòria inferencial profunda per resoldre l'estat S.

1.2 El Subjecte d'Estudi: Construint l'Entorn Pokémon

Abans d'endinsar-nos en el format competitiu d'alta escala (*VGC*) o el comportament algorísmic, és essencial i didàctic comprendre què és Pokémon respecte la seva base matemàtica i estructural. *Pokémon*, originat com a contracció del terme japonès *Poketto Monsutā* (*Pocket Monsters* o Monstres de Butxaca), no només és la franquícia d'entreteniment més rendible del món, sinó que recentment ha celebrat el seu 30è aniversari (Figura 1.1). Sota la seva aparença accessible de videojoc on els jugadors capturen i entrenen criatures per fer-les combatre entre si de forma asíncrona per torns, s'amaga un motor d'una complexitat matemàtica extraordinària.

Figure 1.1: Logotip commemoratiu del 30è aniversari de la creació de la franquícia Pokémon.

Cada Pokémon es caracteritza fonamentalment per tres elements primordials de combinació: el seu "tipus" (Aigua, Foc, Planta, etc.) que determina les seves debilitats i resistències mecàniques;

un set tancat i decisiu de quatre moviments o atacs com a màxim per criatura; i un perfil d'estadístiques intrínseques (*Stats*) que quantifica el seu rendiment de combat en nombres absoluts.

1.2.1 Estadístiques i Fórmules (Stats)

Com s'ha introduït prèviament, les estadístiques defineixen el paper absolut de cada criatura, de la mateixa manera que les peces d'escacs tenen funcions determinades, però suportades per polinomis ocults en lloc de posicions fixes. Concretament parlem de sis valors numèrics constants: Punts de Salut (HP), Atac (Físic), Defensa (Física), Atac Especial, Defensa Especial, i Velocitat. Algunes criatures estan dissenyades exclusivament per aguantar molt dany i ser escuts frontals massius (ressaltant defenses sobre la resta), i d'altres dissenys apunten només a colpejar de forma letal i caure ràpidament.

De manera gràfica, a la Figura 1.2 s'observa la distribució paramètrica real abstracta d'un simple ratolí elèctric, en Pikachu. En aquest diagrama cartesià s'evidencia de ple quines són les seves rellevàncies mecàniques establertes de joc (destacada Velocitat despunta en pic junt l'Atac Especial) mentre exposa al seu centre debilitats severes generalitzades (poca salut de defensa i nul·la resistència).

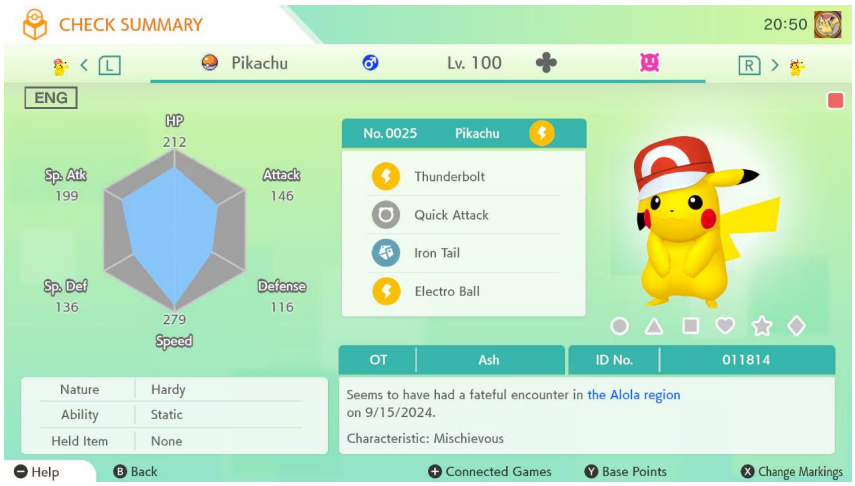

Figure 1.2: Distribució paramètrica visual de les estadístiques base naturals d'un Pikachu analitzat: valors absoluts respectius en Punts de Salut (HP), Atac, Defensa, Atac Especial, Defensa Especial i Velocitat.

Per poder connectar eficaçment el substrat cognitiu predictiu d'un agent a les possibilitats de cada unitat, cal entendre purament com la base estàtica és alterable en variables. Les 6 estadístiques constants presentats a la imatge no són innates un cop el combat arranca, sinó al contrari, es consideren completament mal·leables resultants d'operacions variables que configuren completament quin perfil assumirà abans d'iniciar el combat el tàctic al crear-lo, permetent engany respecte el coneixement base o les expectatives prèvies generals del competidor respecte el diagrama d'aranya mostrat. Els tres modificadors són:

1. **Individual Values (IVs):** Variables ocultes i genètiques equivalents a l'espectre de l'ADN que adquireix la criatura des de la captura a l'interior i no canviables. Sumaran una constant de valor tancat entre [0 i 31] directament plana sobre el càlcul numèric pur final sense que l'oponent tingui dades d'entendre o analitzar quin vector l'ha proveït la màquina natural en general respectant l'espècie en si (per ser perfecte generalment les competitives exigeixen constant de 31 en factors fonamentals).

2. **Effort Values (EVs):** Variables d'intervenció lliures tàcitament acumulatives on resideix l'origen formal de l'engany pur del *VGC*. Es proveeix un límit o fons assignable constant finit basat d'escola (510 punts totals d'assignació d'EVS per unitat i 252 a invertir màxim limitats per a una única estadística). És aquí on un rival enganya, ocultant si el seu personatge ha estat creat asimètricament i invertit purament els 252 punts a ser més ofensiu i veloç (desprenent factors de risc sobre caure en atacs lleus) o bé ha sacrificat purament invertint punts a defensiva, aguantant colpejaments per contrarestades enganyant respecte l'estadística estàndard oficial original de la figura de radar base del pokemon en qüestió (ex. Pikachus aguantant atacs vitals).

3. **Naturaleses (Natures):** Modificacions globals multiplicatives sobre els altres que actuen de factors estàtics i atorguen una bonificació fixa absolutista del $+10\%$ a un aspecte rellevant (potenciant ofensiva abstracte general) però obliguen implícits sempre i simètricament a decréixer complet un limitant d'un -10% sobre estadístiques contraries operables pel teòric del rival (reduint general en paral·lel Velocitats).

Un petit exemple sobre la llista de variables mostrats està a la Figura 1.3.

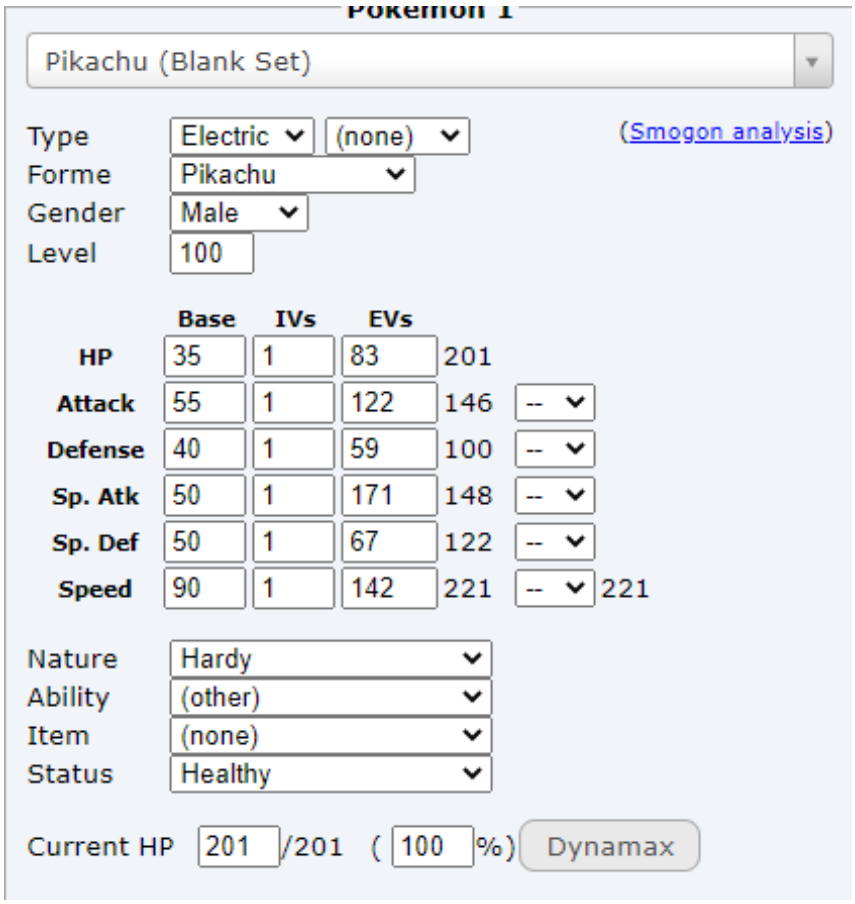

Figure 1.3: Exemple de construcció formal matemàtica respecte valors estipulats per Atribut o format variables lligat general sumatori als Stats constants i els seus màxim determinats com de la natura al perfil.

Aplicat a la realitat formal del motor de joc *Showdown*, tota variable del quadre per al format competitiu global (*Level = 50*) es reajusta limitadament utilitzant sumatoris constants i operacions de Truncament algorísmic ($\lfloor x \rfloor$) a la baixa, esglaonant en números enters complets el càlcul assecat per eliminar qualsevol variable fractal existent un cop sumats els components a deduir per a l'operatiu de dades general (*Stat*) [2]:

$$Stat = \left\lfloor \left(\frac{(2 \times Base + IV + \lfloor \frac{EV}{4} \rfloor) \times Level}{100} + 5 \right) \times Nature \right\rfloor \tag{1.1}$$

Les constants establint la referència esmentada al pur sumatori algorísmic es prenen globals constants fins que passem a avaluar explícitament l'única de les magnituds alienada de càstig abstracte diferent que mereixia canvis substancial per l'entorn limitant on s'ha d'evitar morts a primera fase i necessiten càlcul d'additius en HP purament extra operatiu on es descarta el factor variable purament i multiplicador decimal Nature o l'additiu sumatori planer tancat de +5 per ser amplificat sumatori base fix paral·lel:

$$HP = \left\lfloor \frac{(2 \times Base + IV + \lfloor \frac{EV}{4} \rfloor) \times Level}{100} \right\rfloor + Level + 10 \tag{1.2}$$

1.2.2 Matemàtiques del Dany: La Taula de Tipus, STAB i Categories d'Atacs

A més de les estadístiques, l'eix vertebrador de la presa de decisions és la **Taula de Tipus** (Figura 1.4). Existeixen 18 tipus elementals (Aigua, Foc, Planta, etc.) que defineixen completament matrius de dany. Un atac rebrà un multiplicador de x0.5 si és poc eficaç (*Not Very Effective*), x2 si és molt eficaç (*Super Effective*) o x0 si és immune. Atès que moltes criatures posseeixen **Doble Tipus**, aquests factors es multipliquen junts podent generar febleses extremes on un Pokémon rebi fins a x4 de dany per un sol impacte.

Attacker \ Defender	Normal	Fire	Water	Grass	Electric	Ice	Fighting	Poison	Ground	Flying	Psychic	Bug	Rock	Ghost	Dragon	Dark	Steel	Fairy
Normal													½	0			½	
Fire		½	½	2		2						2	½		½		2	
Water		2	½	½					2				2		½			
Grass		½	2	½				½	2	½		½	2		½		½	
Electric			2	½	½				0	2					½			
Ice		½	½	2		½			2	2					2		½	
Fighting	2					2		½		½	½	½	2	0		2	2	½
Poison				2				½	½				½	½			0	2
Ground		2		½	2			2		0		½	2				2	
Flying				2	½		2					2	½				½	
Psychic							2	2			½					0	½	
Bug		½		2			½	½		½	2			½		2	½	½
Rock		2				2	½		½	2		2					½	
Ghost	0										2			2		½		
Dragon															2		½	0
Dark							½				2			2		½		½
Steel		½	½		½	2							2				½	2
Fairy		½					2	½							2	2	½	

Figure 1.4: Matriu de relacions de la Taula de Tipus oficial de Pokémon. La clau resolutiva principal on els agents han d'inferir debilitats absolutes (x2, x0.5 i immunitats).

D'altra banda, quan l'atac realitzat coincideix de base amb el tipus propi del Pokémon invocador, se li atorga immediatament el **STAB** (*Same Type Attack Bonus*), proporcionant un impuls tàcit de x1.5 al dany base.

La selecció formal d'aquests moviments s'estructura en diverses **Categories i dimensions d'impacte**:

- **Físic i Especial:** L'atac empra el càlcul de força respectiu de Atac Físic contra Defensa Física, o Atac Especial contra Defensa Especial.
- **Objectius Únics vs. Àrea (*Spread*):** Atacs dirigits a una sola unitat, o atacs d'àrea que colpegen a tots els rivals presents simultàniament. La propagació multi-objectiu rebrà penalitzacions per dany distribuït, caient a retorns reals de només un x0.75 per oponent [9].
- **Moviments d'Estat (*Status moves*):** No generen dany directe. Permeten estratègies de mitigació absoluta com *Protect* (escuts d'immunitat temporal pel torn), increments de poder aliat (*Buffs* interns de les *Stats*), o reduccions debilitadores de defensa pures cap als enemics (*Debuffs*).

1.2.3 L'Ordre d'Execució: Velocitat i Prioritat (Speed Dynamics)

Tots els successos anteriorment citats necessiten una estructura lineal seqüencial d'esdeveniments. Per norma general, el moviment és atorgat en ordre decreixent depenent estrictament de quina estadística base de **Velocitat** tingui l'entitat; qui és més ràpid ataca primer. Tanmateix, existeixen els rangs de **Prioritat** (des de +5 fins a -7). Una acció amb prioritat +1 absoluta dictaminarà un avançament obligatori sobre qualsevol rang +0 en la cua de successos del motor, alterant i ignorant qualsevol càlcul teòric de l'estadística general de Velocitat entre ells en aquest torn específicament (per exemple atacs fulminants ràpids o defenses clau).

1.2.4 Estats Alterats (Status Conditions)

De bracet actuen els paràmetres negatius estocàstics no dissenyats completament com a impactes matemàtics purs sinó com **Condicions d'Estat Qualitatives (Status)**. Tot combat posseeix interrupcions dràstiques constants causades per elements qualitatius secundaris fruit probabilístic presentats a la Taula 1.1. L'agent autònom ha d'estar teòricament capaç i preparat per afrontar una pèrdua immediata i contínua o disrupció seqüencial del dany sense tenir en consideració la programació temporal prèvia assumida per planificació òptima.

1.2.5 L'Estocasticitat i el trencament Determinista

Entenent ara l'eix matricial formal darrere la captura numèrica de cada unitat, cal esbombar com l'estocasticitat absolutitza un cert trencament del càlcul i d'informació oculta per esdevenir el col·lapse estèril teòric de cerca asíncrona no observada (*Incertesa Bayesiana*). Determinades decisions queden subjectes purament a multiplicadors fixats aleatòriament (RNG, Random Number Generation):

1. **Dany Aleatori del *Damage Roll*:** Totes i cadascuna de les fórmules prèvies presentades llancen globalment una constant d'RNG. El multiplicador base fa oscil·lar la banda en punts fractals absoluts entre el rang $[\sim 0.85, 1.00]$. Sota l'enginyeria robòtica clàssica es percep fatal, convertint decisions categoritzades on crèiem tenir KOs clars a letalitats absolutament inviables de prop del 85%.
2. **Precisió dels Moviments (Accuracy):** Determinades mecàniques no obren finestres al 100% d'impacte. Un atac danyós letal pot presentar percentatges reduïts com $\sim 85\%$ de *Hit*. El cervell ha d'estimar vectors d'avaluació compensant si el benefici obtingut

Estat	Efecte en Stats	Mecànica de Funcionalitat
Cremada (Burn)	↓ 50% Atac Físic	1/16 de dany de Salut Màx resident en l'inici de cada iteració de torn.
Paràlisi (Para)	↓ 50% Velocitat	25% pur d'atzar on probabilitat de no permetre efectuar moviment seqüencial es manté eternament lligat.
Verí (Poison)	Cap	Dany autònom residual d'1/8 o creixent incrementalment a l'acabar el bucle.
Son (Sleep)	Cap	Tota acció s'inhabilita aleatòriament generalitzant limitacions de rebot constants en la selecció estratègica del competidor intel·ligent.
Congelació	Cap	Restricció total a efectuar atacs; subjecte purament al 20% probabilístic lliure de trencament espontani.

Table 1.1: Resum de les condicions d'estat i el seu impacte disruptiu rellevant modificant dràsticament operacions prèviament predictives establertes a nivell d'optimització màxima de l'IA.

assumit cobreix globalment l'esfondrament massiu per pèrdua estocàstica total en no rebre recompenses del dany.

3. **Cops Crítics (Critical Hits):** Eventualitats incalculables basades només en atzar estadístic normal del $1/24 \approx 4.16\%$. Modifiquen sobtadament l'avaluació en transicions no predites multiplicant brutalment de forma general la constant danyosa per un +50% de valor ignorants alteracions defensives imposades al camp competitiu [9].

1.3 Teoria de Jocs: Competitiu "VGC" (Suma Zero)

Després de detallar com des d'una "estadística del Pokémon" passem a les "condicions RNG inobservables i ocultes de *POMDP*", entra de cop el format on la IA del TFM pren com a marc complet i lligat per ser la modalitat complexa final de base real i avaluativa: el *Format VGC* (Video Game Championships).

Des d'una òptica rigorosa en Teoria de Jocs i basant-nos en postulats generals de la combinatòria establerta, el VGC és de naturalesa i pràctica un **Joc de Suma Zero Simultani** [11]. En ser de Suma Zero, s'estipula directament que qualsevol unitat teòrica guanyadora i atorgada per superioritat mecànica recau purificativament un mal i pèrdua exacta matemàtica contra l'efectivitat a rebre pel contrincant sense que hi puguin existir cooperacions d'estratègia entre tots dos. Sovint la complexitat del Meta de l'orquestració es converteix computacionalment a aquest concepte per ordinadors de gran disseny descrivint literal: *"Jugar amb l'àrdua premissa abstracte perfecta clàssica dels Escacs sobre el tauler i posicionament, limitat per condicions on hi imperen variables probabilístiques d'inobservabilitat Bayesiana purament properes a decisions limitants d'alt risc atzaroses típiques partides del Pòquer"*.

1.3.1 El Model de Lliure Decisió i Meta-game

Aplicant les estandarditzacions regulades en grans servidors oficials de decisió final multivariant, el VGC divergeix radicalment llançant una modalitat de **combat Dobles** simultani (Dos contra Dos presents globalment com observem emulats a la Figura 1.5). El *targeting* objectiu es multidimensionalitza en paral·lel. Cap agent es preocupa singularment d'eliminar un node, ja que cadascuna unitat dels 4 Pokémon d'escenografia regeix operacions independents (fins al punt de

penalitzar directament sobre camp de forma aliada si hi apliquem dany de propagació atmosfèric *Spread*).

Figure 1.5: Aspecte visual d'un combat interactiu de gran envergadura teòrica en format de Dobles VGC sota Pokémon Showdown. Hi impera l'absolutisme de la sobre-informació on s'amunteguen i influeixen sinèrgicament les quatre variables, components globals defensius asimètrics, condicions i paràmetres com el temps atmosfèric (Sol tòrrid). Aquest quadre paramètric alt forçarà processos de deducció lligada per un model seqüencial òptim.

Superat l'enfrontament d'espai intern pur hi preveuen operacions extra-matemàtiques, basades exclusivament de decisions ocultes de **Team Preview** respectant el protocol de les seleccions constants d'un format pur **Bring 6, Pick 4**: Abans de començar els torns ambdós contendents reben exclusivament dades basades en la composició de 6 estructures diferents emmascarades i n'han d'escollir de ple quatre. Totes aquestes operacions s'avaluen en decisions simulatànies basades com dicten asimètricament de models predictius on, gràcies d'estudis analistes dels rivals i conjunts previs coneguts, l'agent pretén deduir exclusivament per endevinaments tàcit quin dels membres portarà la contraoferta tàctica basant-se estrictament asimètricament al seu equip combinat. I afegint com factor essencial dues directius globals o *Clauses*:

- L'*Item Clause i Species Clause*: Obliga per regles internes que sobre les figures dissenyades com base paramètrica en la deducció lliure tancades es formen equips basats absolutament en disseny divers interrelacionats, vetant pur repeticions i clòniques repetitives de criatures i objectes equipats.

- L'*Auto-Level 50*: Forçament paramètric complet global que neutralitza deduccions limitants i absolutes permetent anivellar factors globals d'operació basant en avantatges només subjectes al pensament heurística lliure i de seleccions numèriques combinades estratègiques sense temps diferencial operatiu per decantats de generacions extra per aprenentatge previ extra al sistema del bot original.

I és just en l'observació o ecosistema general del disseny d'una e-Sport asimètric absolutament global i real emparat formal on assoleix o resideix aquest disseny: on la gran envergadura estocàstica dona espai a nivell complet assoleix oficial les magnituds competitius establerts mundial de la delegació com The Pokémon Company en donant els asimptòtic absolut de la complexa intel·ligència als tornejos formals de referenciar on recauen preus lucratius enormes del *Pokémon World Championships* dictant valors al llindar de $30.000 per la consecució final

i reial campió complet o tàcit al format de VGC a nivell de Màster formals i de categories compensacions respectives beques en lligams directes a escalar els estatus complets d'operacions absolut [10].

1.4 L'Entorn Virtual i Eines de Recerca

1.4.1 L'Ecosistema de Simulació: Showdown i Poke-env

A causa de la naturalesa estanca dels cartutxos de consola oficials, l'aplicació d'Intel·ligència Artificial en entorns VGC requereix d'eines externes obertes i manipulables per permetre la simulació de Teoria de Jocs pràctica. És per això que l'orquestració d'aquest estudi fonamenta la seva experimentació tècnica sobre dos pilars *Open-Source*: **Pokémon Showdown** [12] i **Poke-env** [5].

Pokémon Showdown és el simulador de batalles competitiu més cèlebre establert per tota la comunitat. Replica amb un rigor matemàtic i una precisió mil·limètrica (fent enginyeria inversa des dels codis originals) totes i cadascuna de les regles i condicionants detallades en apartats anteriors (Taula de tipus, RNG, IVs i EVs). Aquesta infraestructura, desenvolupada completament en JavaScript/TypeScript, permet aixecar servidors locals lleugers privats per emular centenars de combatents a gran velocitat sense requerir una pantalla gràfica renderitzada; condició vital per jugar escenaris de suma zero durant hores en aprenentatge iteratiu.

Per altra banda, l'escriptura d'IA en entorns d'investigació massius domina avui en dia a Python. L'eina de "pont" és la llibreria *Poke-env*. Aquesta actua com a capa d'abstracció (API *wrapper*) traduint tot el torrent d'informació asíncrona dictat pel servidor local de *Showdown*. Processa les respostes HTML/Sockets a objectes i vectors directes d'estat (MDP), netejant-los de pur soroll operatiu, i generant instàncies legibles aptes pel tractament analític, com ho fa habitualment la factoria unificada d'*OpenAI Gym* [1].

1.5 Intel·ligència Artificial i Reinforcement Learning

L'elevada complexitat computacional del format de Dobles VGC impossibilita l'ús exclusiu d'algorismes clàssics de cerca en arbres. L'aplicació de mètodes pre-avaluatius com *Minimax* col·lapsa ràpidament a causa de l'explosió combinatòria, on la matriu de decisions creix exponencialment davant els conjunts estocàstics concurrents.

Per abordar aquesta hiperdimensió d'estats, la literatura i la indústria s'orienten cap al **Deep Reinforcement Learning (DRL)**. El DRL substitueix la cerca exhaustiva per funcions d'aproximació (xarxes neuronals) que aprenen a estimar el valor de cada estat o estratègia gràcies a l'experiència pròpia transcorreguda a l'entorn. Dos dels algorismes més prolífics en aquest tipus d'estudis continus són:

- **DQN (Deep Q-Network):** Aproximadors fora de política (*off-policy*) introduïts per DeepMind [4] que emulen la funció de valor acció-estat $Q(s, a)$. Utilitzen memòries de repetició d'experiència (*Experience Replay*) per desvincular temporalment les mostres i aprendre el "valor a llarg termini" d'efectuar un atac específic donat l'estat observat del combat.

- **PPO (Proximal Policy Optimization):** Metodologia d'optimització *Actor-Critic* descrita per OpenAI [6]. El seu tret distintiu és l'ús preventiu d'una tècnica anomenada *Clipping*. Aquesta condició lliure de trencament retalla les actualitzacions de les xarxes neuronals per evitar que l'aprenentatge quedi completament destruït si el model rep una recompensa enganyosa deguda a la pura sort estadística (un factor crucial en un entorn tan altament basat en l'RNG com Pokémon).

1.6 Justificació Metodològica de la Recerca

El propòsit últim d'investigar i modelar el competitiu de Pokémon no és resoldre el joc per crear un bot imbatible pel mer entreteniment. Es tracta d'utilitzar aquest ecosistema com un rigorós banc de proves (*sandbox*) on testificar les limitacions i l'escalabilitat d'arquitectures d'intel·ligència artificial autònoma.

Pokémon VGC sintetitza elements idèntics a representatius reptes d'enginyeria en el món real o de gestió on qualsevol agent decisiu ha d'operar sota condicions de "Soroll Estocàstic Alt" i amb informació purament parcial (POMDP). Construir agents que evolucionin des d'heurístiques d'avaluació precompilades fins a models d'aprenentatge pur valida la robustesa dels nostres sistemes de codi operatius paral·lels. Assolir un grau sòlid de win-rate estable en entorns amb tantes variables no observables obre el camí a validar mètodes estadístics capaços de fer que els agents dedueixin la seva causalitat latent aïllada del soroll, consolidant en retroespecció l'avenç computacional en mètodes MDPs.

Chapter 2

Metodologia: Entorn, Arquitectura i Baselines

Per poder dissenyar, analitzar i finalment entrenar intel·ligències artificials en el Meta-game presentat en l'anterior capítol, és requerit estructurar prèviament les bases experimentals i procedimentals de l'arquitectura del projecte. Aquest capítol detalla la construcció de l'entorn de simulació propi i l'establiment dels models numèrics de referència fonamentals.

2.1 Entorn i Simulació: Infraestructura Escalable

Un cop presentats conceptualment *Pokémon Showdown* i l'API de *Poke-env* al Capítol 1, el veritable repte metodològic recau en com orquestrar-los per suportar càrregues de validació científica. La naturalesa per defecte d'executar avaluacions amb un únic servidor central pateix greus limitacions a causa del col·lapse temporal quan es requereix un volum de batalles estadísticament rellevant.

Per resoldre aquest coll d'ampolla, en aquest projecte s'ha elaborat una infraestructura pròpia centralitzada (situada a `src/p03_scripts`). Aquest conjunt d'eines està focalitzat en permetre aixecar dinàmicament múltiples instàncies paral·leles del servidor en diferents ports consecutius (ex. 8000 endavant) tot deshabilitant protocols de seguretat log-in locals innecessaris. D'aquesta manera, el nostre codi orquestrador Python és capaç de llançar tasques asíncrones massives i distribuir els agents entre diversos ports de Showdown.

Aquest component metodològic resulta l'eix clau del treball: permet efectuar una injecció massiva de connexions i extreure altes proporcions d'estudis de casos, aconseguint executar centenars de jocs simultàniament. Garanteix una escalabilitat gairebé il·limitada per als benchmarks heurístics i agilitza dràsticament els futurs processos de recol·lecció d'experiència requerits per qualsevol algoritme de *Reinforcement Learning*.

2.2 Fases de Desenvolupament i Models de Referència

El desplegament d'agències asíncrones sobre *Showdown* s'ha estructurat metodològicament en dues grans fases consecutives per garantir una monitorització i isolació de variables controlada.

2.2.1 Fase 1: Models de Regles Expertes (Heurístiques)

Abans de submergir el codi en hiperparàmetres de *Machine Learning*, la prioritat metodològica ha estat dissenyar models **heurístics propis** basats en regles de decisió expertes (arbres "If-Else" avançats). Aquest acostament primari ha complert un triple propòsit fonamental:

- **Validació de la Infraestructura**: Funcionar com a prova de concepte de l'entorn (PoC) per garantir que el nostre orquestrador de servidors asíncrons llegia i enviava decisions sense caigudes de memòria (Memory Leaks de NodeJS) processant milers d'estats per minut.
- **Depuració de la Lògica Numèrica**: Comprovar físicament que l'accés a les variables d'estat de *poke-env* (HP, climàtologia, efectes secundaris actius) convergia en comportaments teòrics òptims dins de la pista per part del bot de forma pre-programada.
- **Desenvolupar el Límit de Control Propi (Baseline Suprem)**: Mitjançant l'evolució iterativa d'aquestes heurístiques de codi dur, el projecte ha consolidat un "Límit de Control Expert". En lloc de mesurar futurs agents neuronals contra oponents cecs, l'objectiu últim serà llançar-los contra aquesta heurística madura final, forçant la xarxa neuronal a superar raonament matemàtic tancat creat per disseny pur.

2.2.2 Fase 2: Models d'Aprenentatge Profund (Cares al Futur)

Una vegada validada l'arquitectura i disposant del *Baseline Expert* propiament dit en el codi amfitrió, la segona gran fase de la recerca (seccions posteriors) serà la substitució d'aquesta codificació dura per arquitectures d'aprenentatge. L'eix científic del TFM assoleix el seu màxim pragmatisme avaluant si algorismes com les Xarxes Q Profundes (DQN) o l'Actor-Crític (PPO) poden descobrir per si sols, i de forma superior, les normes causals que la Fase 1 programava explícitament (Taula de Tipus, STAB, Predicció de canvis).

2.2.3 La línia de control nativa (*Poke-env Baselines*)

Amb l'entorn escalable definit i prèviament a l'escriptura de qualsevol heurística complexa o xarxa neuronal, cal fixar globalment empírica de base sobre l'enginyeria robòtica del propi proveïdor. Dins d'un entorn basat en reforç i atzar, s'invalida automàticament qualsevol algoritme personal que rebaixi el percentatge de victòria blindat als *baselines* natius que acompanyen la mateixa llibreria d'inici [5]:

Per suplir aquesta referència en l'estudi s'han adoptat tres mòduls intrínsecs ja subministrats nativament per *poke-env* que defineixen la línia de control teòrica:

1. ***RandomPlayer*:** Un estadi base ingenu total que efectua moviments a l'atzar un cop ha estat interrogat de la llista genèrica d'accions legals permeses pel servidor local. Actua exclusivament com una font de distribució gaussiana teòrica del 50% si jugués exclusivament partides simètriques, assenyalant explícitament els valors màxims de variància atorgats per les probabilitats incrustades de la mateixa mecànica (*Damage Rolls, Critical Hits*, etc.). És l'exponent màxim del comportament estocàstic sense intel·ligència.
2. ***MaxBasePowerPlayer*:** Un prototip mínimament cobdiciós (*Greedy*). Valora objectivament les opcions de fer el màxim dany disponible per acció al seleccionar, ignorant les variacions globals defensives com el coeficient (*STAB*) o la resistència teòrica davant atacs oponents. Resulta com el límit pràctic inferior d'estratègia funcional: la mínima barrera a superar de la IA si es busca demostrar que aquesta percep una mínima visió de causalitats.
3. ***SimpleHeuristicPlayer*:** Aquest model actua com el rival més sofisticat ofert de sèrie per la llibreria o, en termes pràctics, com a "final boss" d'aquesta línia base. Va molt més enllà dels anteriors incorporant heurístiques internes preprogramades: avalua debilitats de tipus, prioritza moviments de canvi (*switch*) quan el seu Pokémon actiu es troba en gran perill davant l'oponent, i maximitza el dany utilitzant criteris raonables de matchups. Representa la línia de maduresa; superar de manera consistent aquest agent certifica que les noves funcions d'avaluació pròpies o models neuronals han assolit una intel·ligència genuïnament superior.

El contrast sistemàtic contra aquests tres *baselines* constitueix el filtre fonamental de la metodologia establerta, a través de la qual qualsevol avanç real vinculat a les nostres heurístiques serà estrictament confrontat en cada iteració.

2.3 Espai d'Estats (State Space) i Accions (Action Space)

Tot problema d'intel·ligència artificial ha d'estar encapsulat matricialment per poder ser processat. Pel cas dels estudis emmarcats en el combat, definim la connexió formal de Showdown prenent l'espai i el quadre d'accions:

2.3.1 Espai d'Estats (S)

El conjunt S agrupa l'observació total d'informació de què disposa el bot en qualsevol torn determinat (encara descrivint un entorn parcialment observable, POMDP). Mitjançant un desglossament informatiu de *poke-env*, l'agent avalua al complet la vida percentual i absoluta restant de tots els Pokémon de camp, tots els modificadors estadístics existents (per exemple, si un aliat rep $\uparrow 2$ en Atac Especial), les condicions d'estat (Paràlisi, Cremada), les característiques d'avantatge climàtic sobre la pista de roba, així com l'estat històric infent de l'equip del oponent ja conegut. D'acord amb la profunditat de codificació i memòria de l'agent (en apsectes d'informació oculta sobre *items* deduïts empíricament), el vector global $\mathbf{O}_t \in \mathbb{R}^d$ servirà directament com a component essencial d'entrada a les xarxes d'avaluació heurístiques.

2.3.2 Espai d'Accions (A)

L'espai d'accions A conté exclusivament els moviments i substitucions (*switches*) "legals" i dispostes al camp. En un combat de Singles 1vs1 ordinari, això ascendeix fins a un màxim abstracte de 9 accions viables formals (4 atacs diferents pel personatge operatiu, o la retirada forçada si escull substituir per cap de forma els 5 membres inactius restants al seu equip). No obstant això, en l'univers tractat complet de *Dobles VGC*, tenint a la superfície dos personatges propis funcionant davant dos adversaris en diagonal creuada, el nombre teòric es multiplica exponencialment, per incloure atacs a un *target* específic dels 3 en pista, propiciant desenes d'opcions en una matriu A creixent per iteració de paral·lelisme seqüencial directe.

2.4 Mètriques d'Avaluació Mètrica

Per dotar de gran suport rigorós a l'estudi algorísmic en una arquitectura tan subjecta a variabilitats matemàtiques de l'RNG aleatori o els punts decisius dels cops crítics aleatoris, qualsevol valor dictaminat basat puntual en jocs independents resulta irremeiablement de resultats analítics estèrils. L'avaluació en mètrica no confia en poques confrontacions.

La mètrica nuclear primària implementada i validada des del codi d'orquestració dictamina el **Percentatge de Victòries Real (*Win-Rate* global)**, que només pren pes estadístic rellevant operant sota execucions de validació amb un volum molt superior (ex. cicles tancats de ≥ 100 batalles seguides simultànies asíncrones per a cada confrontament directe Agent vs Agent). Un model en qüestió rellisca com aleatori si la cota inferior estocàstica assenta un 50% freqüent sobre conjunts clàssics o espill (*Mirror Match*); aconseguir superar estadi d'un +60% constant en cicles de grans iteracions demostra significativament intel·lectualitat mecànica prenent avantatge, i un domini clar a prop al $> 85\%$ descriu habitualment erradicació teòrica sobre la presa de lògiques de decisions completament dominades sobre un agent poc intel·ligent a confrontar.

Chapter 3

Implementació d'Agents: De les Fases Heurístiques a l'Aprenentatge Profund

D'acord amb la metodologia evolutiva exposada al capítol anterior, aquest apartat detalla l'arquitectura de software construïda per donar vida als agents racionals dins del simulador *Pokémon Showdown*. Es divideix tècnicament entre la infraestructura d'orquestració creada i l'evolució de les heurístiques del format bàsic (*Singles*) cap a l'alta complexitat (*Dobles VGC*). L'apartat final es reserva a la futura arquitectura d'aprenentatge profund.

3.1 Orquestració Operacional i Entorn Parallelitzat

El motor d'aquest projecte recau en un mòdul orquestrador propi, situat a `src/p03_scripts`, encarregat de trencar la limitació original d'un sol fil de connexió pròpia de *poke-env*. Fent ús intensiu de l'asincronia i sub-processos de Python (`asyncio`), els scripts desenvolupats són capaços de:

1. **Llançament massiu de Showdown**: Aixecar múltiples ports actius sota demandar per instanciar arenes de combat separades geogràficament i lògicament.

2. **Gestió de Memòria (GC)**: S'han establert regles fixes d'alliberament de memòria (neteja manual al Garbage Collector de Python) a l'acabar petits "batches" de partides, evitant excepcions de consum i colls d'ampolla dels servidors node subjacents.

3. **Recuperació per Checkpoints**: Es disposen d'estructures JSON al directori `data/` que mapen quants combats han efectuat l'agent A contra l'agent B. Això fa completament robust el cicle de benchmarking a aturades elèctriques o interrupcions en màquines virtuals.

3.2 Fase 1.1: Desenvolupament d'Heurístiques per Singles (1vs1)

Abans de submergir models al pur format *Dobles VGC*, el projecte exigeix garantir l'abstracció matemàtica dins d'un control màxim i un espai d'accions reduït. El format **Singles** (1vs1) es converteix en l'arena de desenvolupament ideal. Reduint l'espai i problemàtica del *Spread Damage*, on l'agent només interacciona contra una diana visible prenent sobre un màxim limitant de 9 decisions asíncrones per torn dictades lliurement entre Atacar (4) o Substituir el personatge (5) del propi camp.

Mitjançant sis cicles evolutius de codi, s'han consolidat directrius pures allotjades sota `src/p01_heuristics/s01_singles/agents/`:

- **Heurística v1 (Naïve Aggressive)**: Un esbós de prova que prioritza purament els moviments danyosos respecte l'estat lliurement amagat, buscant un petit desmarcatge cognitiu vers els oponents totalment aleatoris del format random.

- **Heurístiques v2 / v3 (Incorporació d'STAB i Taula Tipus)**: El codi fa un salt numèric i llegeix dades del *wrapper*. Multiplica el càlcul pel factor genètic relatiu $x1.5$ de tipus propi i pre-calcula les immunitats i febleses sobre l'enemic abans d'ordenar impactes. Resideix com a tall quantitatiu principal per ratificar efectivitat teòrica de l'operatiu de Poke-env intern en operacions d'escala.

- **Heurística v4 / v5 (Tàctica de Supressió i Mitigació)**: El model es divideix en components i evalua *switches*. Ara l'arquitectura ja no ataca constantment sinó que avalua l'estat tàcit: on, si es troba en clara inferioritat matricial d'atributs d'acord amb el càlcul d'impacte previst vers el *Matchup* frontal, ordena retrocedir al de camp intercanviant per rebre menys dany i col·lapsant dinàmiques de model purament avar *Max Power*.

- **Heurística v6 (Master Heuristic)**: Integra totes les regles i condicionals anteriors al voltant d'un eix comú. Es converteix de lluny d'arquitectura base formal a un vertader agent competent per al seu camp format: preveu debuff, preveu velocitat calculada a priori i determina exactament què i sobre quins lligams estratègics s'aferma la partida general. Aquest model serveix el repte d'una validació clara pel RL tàctic final abstracte de decisió sobre oponents experts en un entorn pur.

3.3 Fase 1.2: L'Ascens al Competitiu Real (Dobles VGC)

Tot repte d'IA queda coix comparativament a la comunitat global si no salta al lligam establert final: **Dobles 2 vs 2**. La base formal dissenyada per a les versions Singles va quedar automàticament invàlida perquè la classe de *Poke-env* no llegeix atacs lineals i obliga a retornar tuples dobles i l'algoritme perd el focus absolut d'optimització unària tancada. Dins de `src/p01_heuristics/s02_doubles/` es reestructura radicalment al pur formal funcional *Score-then-Combine* (Avaluar i Lligar).

- **Escala de Candidats (V1 i V2)**: L'algoritme fragmentada el model V6 antic, on la mecànica numèrica esdevé asíncrona assignant puntuacions teòriques pures de dany a tots moviments generats lliurament i després ho uneix. És on si els nostres agents formals dictaminen decisions enganyoses impossibles el lligam ho corregeix (ex. vetar ordres enganyoses d'intentar que ambdós atacs asimètrics canviïn del *slot* generant excepcions en enviar l'ordre al JSON principal asíncron i provocant tancament del servidor per cridades al dany a unitats diferents al Showdown).

- **Lligams de Propagació Espacial (Spread i Focus V3)**: Amb el sistema tàctic previ s'imposa finalment incloure al càrrec lògic el dany d'àrea pel multiplicador oficial competitiu (*x0.75*) per calcular la utilitat o inclús la mitigació tàctica defensiva preveient un bloc abstracte de *Protect* que un aliat executa al costat de si mateix mitigant absolutament i atracant moviments asimptòtics nuls als enemics per sobre control oponent sobre els danyats al centre del camp paral·lel asimètric a resoldre finalment abans de llançar intel·ligència general total asíncrona sobre RL.

3.4 Fase 2: Implementació Neuronal per Aprenentatge

[Espai d'Avaluació reservat per exposar properes setmanes els codis subjacents de les xarxes DQN / PPO on la integració respectiva a xarxes neuronals sota Pytorch prendran com a límit control

els algoritmes iteratius validats previement, relegant l'escenari manual establert prèviament a una deducció autònoma tàctica per decisió computacional independent formal].

Chapter 4

Resultats i Avaluació de les Heurístiques

Aquest capítol presenta els resultats obtinguts de l'avaluació exhaustiva d'ambdós entorns de simulació (Singles i Doubles). S'analitza l'efectivitat i fiabilitat de les versions estructurades respecte als baselines, utilitzant les eines de *benchmark* internes de l'entorn Core, desenvolupades sota el disseny *Round-Robin* automatitzat explicat prèviament.

4.1 Avaluació Exhaustiva al Format 1 vs 1 (Singles)

L'anàlisi sistemàtic del format *Singles* va procedir a confrontar iterativament tots els agents heurístics dissenyats (des de *v1* fins a *v6*) i els *baselines* absoluts de l'entorn.

Les proves es van estructurar en sèries massives, llançant matrius d'enfrontaments per cada possible par (ex. $v6$ vs *Random*, $v3$ vs *MaxBasePower*), on els milers d'execucions es van processar i sintetitzar de forma paral·lela obtenint el guanyador o perdedor teòric. En l'observació del percentatge de victòries net (*Win Rate*), la tendència generalitzadora marca clarament una **progressió evolutiva de disseny encertada**. Generacions inicials com la $v1$ no obtenien victòries aclaparadores més enllà del 55%-60% en intentar basar decisions únicament en regles ofendents de dany simple respecte atacs a l'atzar del *RandomPlayer*. La introducció en modelat teòric profund amb *The Tracker* ($v3$) i l'establiment expert d'incorporació de tipologies defensives del motor al *The Champion* ($v6$) augmentava de cop en un rendiment tàcit els índexs per sobre del 90%-95% quant es combatien davant els elements de *poke-env*.

El pes de la Estocasticitat: Malgrat crear intel·ligències heurístiques altament sofisticades, de la visió general numèrica se n'extreu que una **victòria del 100% és intrínsecament impossible en aquest entorn i tipus d'agents reaccionaris purs**. Això resideix essencialment a la incommensurable potència de la inobservabilitat, afegit al RNG absolut del joc i al dany latent d'encerts crítics aleatoris que es poden atorgar de manera favorable totalment a un element de sort inferior que utilitzi combinatòries subòptimes (*baselines*). L'anàlisi de matrius presentades indica clarament aquesta resistència asimptòtica.

4.2 Avaluació al Format 2 vs 2 (Doubles)

De manera similar, es va testejar la fiabilitat al *Core Doubles* aprofitant el disseny *Score-then-Combine*. Sota la multiplicitat d'arbre de l'enginyeria, el càlcul d'eficiència es restringia exclusivament en els prototips primigenis del llinatge *v1* al *v3* per simplificació experimental i focalització d'estudi previ al model DRL per xarxes neurals.

La visualització empírica als tornejos demostrà de nou que hi hagué una fita creixent en

benchmarks_singles_v3/placeholder_singles_heatmap.png

Figure 4.1: Matriu de calor mostrant el percentatge de victòries (*Win Rate*) de tots els encreuaments de *Singles* evaluant baselines vs. $v1$-$v6$. Es pot lligar com els iteratius majors assoleixen superioritat al marge inferior esquerre.

els *baselines* quan es presentaven múltiples entitats objectives (*multi-target*). Exigir decisions conjuntes penalitza radicalment als *RandomPlayers* on sovint aquests malgastaven els atacs atacant-se simultàniament les pròpies files si es produïen errors del llançament a l'atzar respecte el tipus objectiu (foc amic). No obstant això, el rendiment estabilitzador a través de combinant parelles òptimes per pes amb el *v3 Doubles* garanteix ser base per establir estratègies pre-predictores suficients i emmagatzemar la pre-avaluació requerida que encoratjarà bases de model entrenables i més complexes.

`benchmarks_doubles_v2/placeholder_doubles_heatmap.png`

Figure 4.2: Avaluació exhaustiva al format *Doubles*. La progressió de $v1$ fins a $v3$ en el comportament de *Score-then-Combine* contra els *baselines* teòrics de *poke-env*.

Bibliography

[1] Greg Brockman et al. "OpenAI Gym". In: *arXiv preprint arXiv:1606.01540* (2016).

[2] Bulbapedia Contributors. *Statistic — Bulbapedia, The community-driven Pokémon encyclopedia*. [Online; accessed 4-March-2026]. 2024. URL: https://bulbapedia.bulbagarden.net/wiki/Stat.

[3] Murray Campbell, A.Joseph Hoane, and Feng-hsiung Hsu. "Deep Blue". In: *Artificial Intelligence* 134.1 (2002), pp. 57–83. ISSN: 0004-3702. DOI: https://doi.org/10.1016/S0004-3702(01)00129-1. URL: https://www.sciencedirect.com/science/article/pii/S0004370201001291.

[4] Volodymyr Mnih et al. "Human-level control through deep reinforcement learning". In: *nature* 518.7540 (2015), pp. 529–533. DOI: https://doi.org/10.1038/nature14236.

[5] Haris Sahovic. *Poke-env: pokemon AI in python*. URL: https://github.com/hsahovic/poke-env.

[6] John Schulman et al. "Proximal policy optimization algorithms". In: *arXiv preprint arXiv:1707.06347* (2017). DOI: https://doi.org/10.48550/arXiv.1707.06347.

[7] David Silver et al. "Mastering the game of Go with deep neural networks and tree search". In: *nature* 529.7587 (2016), pp. 484–489. DOI: https://doi.org/10.1038/nature16961.

[8] Richard D. Smallwood and Edward J. Sondik. "The optimal control of partially observable Markov processes over a finite horizon". In: *Operations Research* 21.5 (1973), pp. 1071–1088. DOI: https://doi.org/10.1287/opre.21.5.1071.

[9] Smogon University. *Damage Formula*. [Online; accessed 4-March-2026]. 2024. URL: https://www.smogon.com/dp/articles/damage_formula.

[10] The Pokémon Company International. *Pokémon World Championships Prize Pool and Awards*. https://www.pokemon.com/us/play-pokemon/worlds/2024/vgc-competitor-info/. 2024.

[11] John Von Neumann and Oskar Morgenstern. *Theory of games and economic behavior*. Princeton university press, 2007. URL: https://press.princeton.edu/books/paperback/9780691130613/theory-of-games-and-economic-behavior.

[12] Guang Zarel et al. *Pokémon Showdown!* https://pokemonshowdown.com/. 2011.